

노이즈에서 다양성으로: 대형 언어 모델 추론에서의 무작위 임베딩 주입

Anonymous Author(s)

Affiliation

Address

email

Abstract

1 학습되지 않은 무작위 임베딩을 LLM 입력에 끼워 넣는 것만으로도 모델의
2 추론 행동이 비자명하게 바뀐다. 최근의 *soft prompt* 계열 방법은 가상 토큰
3 임베딩을 다양한 목적함수로 학습해 수학 추론 성능을 끌어올렸다. 그러나
4 이 이득이 학습에서 오는지 주입 자체에서 오는지는 아직 가르지 못했다. 본
5 논문은 학습 단계를 떼어 놓고 Random Soft Prompt(RSP)를 분석한다. RSP
6 는 사전학습 임베딩 행렬의 행별 평균과 분산만 빌려 등방 가우시안에서 뽑은
7 연속 벡터를 그대로 주입한다. 핵심 통찰은 두 가지다. 첫째, RSP의 영향은
8 생성 초반에 가장 크고 토큰이 쌓일수록 자연스럽게 약해진다. 캐시가 길어
9 지면 어텐션이 무작위 토큰에 배정하는 비중이 줄어들기 때문이다. 둘째, 한
10 번 뽑은 RSP는 그 시도 안에서 고정된 perturbation으로 작동해 baseline과는
11 다른 한 갈래를 결정한다. 시도가 바뀌면 RSP도 새로 뽑히므로 시도들 사이
12 에는 서로 다른 갈래가 살아난다. 그 결과 baseline이 거의 보지 못하던 후보가
13 일부 시도에서 답 후보권 안으로 들어오고, 이런 분기 사건이 반복 시도에서
14 누적된다. 우리는 이 두 통찰을 transformer 구조 안에서 정량적으로 보인다.
15 그리고 baseline 회복, 초반 토큰 다양화 후 후반 안정화, 독립 RSP의 Pass@N
16 누적이라는 세 실험으로 확인한다. 끝으로 이 다양성이 GRPO 학습에 어떤
17 함의를 갖는지 짚는다.

1 서론

19 대형 언어 모델(LLM)의 파라미터 수가 빠르게 늘면서, 모델 전체를 미세조정하는 길은 점점
20 멀어졌다. 그 자리를 소수 파라미터만 추가해 모델을 적응시키는 parameter-efficient 방법이 사실
21 상 표준으로 채웠다 [Hu et al., 2022, Houlsby et al., 2019]. 그중 *soft prompt*는 어휘 바깥의 학습
22 가능한 연속 임베딩을 입력에 끼워 넣는 도구다. 이 임베딩이 attention을 거치며 모델 행동을
23 조정한다 [Li and Liang, 2021, Lester et al., 2021]. 같은 패러다임은 수학 추론을 강화하는 최근
24 연구에도 폭넓게 쓰인다 [Kang et al., 2026, Xu et al., 2025, Ye et al., 2026, Hao et al., 2025, Zhang
25 et al., 2026]. 이들 연구는 어휘 밖 연속 임베딩을 최적화해 정확도를 끌어올린다는 공통 구조를
26 공유한다.

27 그런데 이 효과의 출처가 정말 최적화뿐이라고 단정하기는 어렵다. 학습되지 않은 무작위 연속
28 임베딩을 그대로 끼워 넣어도 출력 분포는 비자명하게 흔들린다. 한 예로 채팅 형식으로 학습되
29 지 않은 base model에 chat template을 적용하면 형식 불일치 탓에 추론 정확도가 크게 떨어진다.
30 그런데 무작위 임베딩을 덧붙이면 그 손실이 도리어 회복된다. 단순 노이즈가 모델을 흔드는 데
31 그친다면 정확도는 더 나빠져야 한다. 따라서 효과의 뿌리는 학습된 의미가 아니라 주입 자체의
32 어떤 성질이라는 가설이 자연스럽게 떠오른다. 기존 평가는 최종 정확도에 초점을 맞춰 “주입”
33 의 효과와 “최적화”의 효과를 분리하지 못했다. 그래서 어휘 바깥 연속 임베딩이 모델 행동을
34 어떻게 바꾸는가는 별도의 미해결 문제로 남았다.

35 본 논문은 학습 없이 주입되는 Random Soft Prompt(RSP)를 분석한다. RSP는 사전학습 임베딩
36 행렬의 행별 평균과 분산만 따 등방 가우시안에서 추출한 연속 벡터의 시퀀스다. 무작위성의

역할은 임베딩 분포를 흉내 내는 것이 아니라, 같은 prompt가 rollout마다 독립된 섭동을 받도록 보장하는 데 있다. 핵심은 시도 수 자체가 아니라, 매 시도가 초반 토큰의 분기를 다르게 연다는 점이다. 본 논문은 두 질문에 답한다. 첫째, 한 번의 RSP 주입은 왜 초반 몇 토큰만 흔들고 나중에는 영향이 사라지는가. 둘째, 시도가 바뀌어 RSP도 새로 뽑힐 때 왜 서로 다른 reasoning path가 시도 사이에서 누적되는가. 첫 질문은 transformer 어텐션 분해가 자연히 만들어 내는 토큰 단위 자기조절에서 답을 찾는다. 두 번째 질문은 N 회 독립 재시도가 작은 분기 확률을 빠르게 누적시키는 사슬에서 답을 찾는다. 한 번의 RSP는 그 시도 안에서 고정된 perturbation으로 작동해 baseline과는 다른 한 갈래를 결정한다. 시도가 누적되면 baseline에서 거의 보이지 않던 후보가 일부 시도에서 답 후보권 안으로 들어오는 사건이 분포로 쌓인다. 마지막으로 이 다양성이 GRPO [Shao et al., 2024] 학습에 어떤 함의를 갖는지 짚는다.

본 논문의 기여는 다음과 같다.

- RSP가 LLM 생성에 어떤 변화를 주는지 실증적으로 분석한다. RSP는 생성 초반의 토큰 엔트로피를 끌어올리고 후반에는 baseline 수준으로 다시 가라앉는다. temperature sampling과 결합하면 더 다양한 추론 궤적이 나온다.
- Soft prompt가 학습 없이도 작동하는 이유를 transformer 수준에서 자연어 직관과 함께 정량적으로 설명한다. RSP의 모든 영향은 어텐션 단의 한 가지 양이 통제하고, 그 양은 캐시가 자라면서 자동으로 약해진다. 등방 분포는 어떤 의미 방향에도 사전 가중치를 두지 않으면서, 동시에 모든 방향에 양의 확률을 부여한다.
- RSP가 유도하는 다양성이 GRPO 학습에 어떤 함의를 갖는지 논의한다. RSP는 토큰 순위를 바꾸는 섭동이고 temperature는 순위를 보존하는 섭동이다. 이 차이 덕분에 두 방법은 직교한 탐색 이득을 제공한다.

2 배경

2.1 LLM 추론을 위한 Soft Prompt 기법

Soft prompt는 전체 미세조정의 대안으로 등장했다. Prefix-Tuning [Li and Liang, 2021]이 학습 가능한 연속 벡터를 각 transformer 레이어 앞에 붙이는 패러다임을 제시한 이후, Prompt Tuning [Lester et al., 2021]은 입력 레이어만 사용하는 단순화된 형태로도 충분히 큰 모델에서 전체 미세조정에 근접한 성능을 보였고, P-tuning [Liu et al., 2024]은 LSTM prompt encoder로 위치 간 의존성까지 포착했다. 이 패러다임은 LLM 추론에도 빠르게 적용되었다. TTSV [Kang et al., 2026]는 테스트 시점에 prefix 임베딩을 엔트로피 최소화로 최적화해 잠재 추론을 활성화하고, SoftCoT [Xu et al., 2025]은 assistant model이 만든 soft token으로 명시적 chain-of-thought를 대체한다. LTPO [Ye et al., 2026]는 confidence 기반 내재 보상으로 latent thought 임베딩을 샘플별로 최적화하며, COCONUT [Hao et al., 2025]은 모델 자신의 은닉 상태를 다시 입력 임베딩으로 되먹여 연속 잠재 공간에서 추론하게 만든다. MemGen [Zhang et al., 2026]은 임베딩이 경험 메모리로 기능할 수 있음을 보였고, Pause token [Goyal et al., 2024]은 학습 가능한 토큰을 입력 중간에 끼워 넣어 추가 계산 단계를 제공한다. 이들 모두 어휘 바깥의 연속 임베딩을 과제 특화 목적함수로 최적화해 정확도를 끌어올린다. 그러나 평가가 최종 정확도에 맞춰져 있어 “주입 자체”의 효과와 “최적화”의 효과가 분리되지 않으며, 단순한 임베딩 주입이 모델 행동을 어떻게 바꾸는지는 별도의 미해결 문제로 남아 있다.

2.2 신경망에서의 노이즈 주입

신경망에는 여러 단계에서 노이즈가 도입되어 왔다. 학습 시점에서는 dropout [Srivastava et al., 2014]이 은닉 유닛을 무작위로 비활성화해 과적합을 막고, NEFTune [Jain et al., 2024]은 instruction fine-tuning 중 토큰 임베딩에 노이즈를 더해 instruction following을 개선한다. 추론 시점의 섭동은 주로 강건성을 겨냥한다. Randomized smoothing [Cohen et al., 2019]은 입력 가우시안 노이즈로 certified robustness를 얻고, SmoothLLM [Robey et al., 2025]은 문자 단위 프롬프트 변형으로 jailbreak를 방어한다. 강화학습에서는 NoisyNet [Fortunato et al., 2018]이 가중치에 학습 가능한 노이즈를 넣어 탐색 성능을 높였다.

RSP는 이들과 세 가지 점에서 구별된다. (1) 어떠한 학습도 없이 추론 시점에만 동작하므로 모델 파라미터를 건드리지 않는다(dropout, NEFTune, NoisyNet과 다르다). (2) 원래 입력을 보존한 채 새 임베딩을 한 번의 forward pass에 덧붙일 뿐이며, 강건성 방법이 요구하는 “여러 번의 noisy pass와 출력 집계”가 필요 없다. (3) 학습된 파라미터 없이 사전학습 임베딩 통계에서 직접 샘플링한 무작위 벡터를 그대로 쓴다(NoisyNet은 노이즈 파라미터 자체를 학습한다). 무엇보다

88 RSP의 목적은 출력 안정성이 아니라 탐색이며, 본 논문은 이 차이가 어텐션 수준에서 어떻게
89 작동하는지 분석한다.

90 3 Random Soft Prompt와 작동 원리

91 이 절은 RSP를 정의하고, 그 작동을 두 면으로 나눈다. 한 번 추천된 RSP는 한 시도 안에서 고정
92 된 perturbation으로 작동해 baseline과 다른 한 갈래를 결정한다. RSP의 영향력은 초반 토큰에서
93 의미 있게 크고 (§3.2), 디코딩이 진행될수록 자동으로 0에 수렴한다 (§3.3). 시도가 바뀌면 RSP
94 도 새로 뽑히므로, 시도들 사이의 갈래 차이가 누적되어 Pass@N의 지수적 개선으로 이어진다
95 (§3.4). 본문에는 정리 statement와 직관만 두고, 형식 증명은 모두 Appendix E에 정리한다.

96 3.1 Random Soft Prompt

97 구현은 단순하다. 사전학습된 토큰 임베딩 행렬의 평균과 스케일만 빌려 같은 모양의 연속
98 벡터를 추천하고, 이를 prompt 앞·중간·뒤 어디에든 붙여 넣는다.

99 형식적으로, 토큰 임베딩 행렬을 $\mathbf{W}_E \in \mathbb{R}^{V \times d}$ 로 둔다(V 는 어휘 크기, d 는 은닉 차원). 그 행별
100 평균과 표준편차를 $\mu_E := \frac{1}{V} \sum_{i,k} [\mathbf{W}_E]_{i,k}$, $\sigma_E := \text{std}(\mathbf{W}_E)$ 라 한다. 길이 L 의 RSP는 다음
101 분포에서 독립 추천한 연속 벡터 시퀀스 $\mathbf{H} = [h_1, \dots, h_L] \in \mathbb{R}^{L \times d}$ 이다:

$$h_j \sim \mathcal{N}(\mu_E \mathbf{1}_d, \sigma_E^2 \mathbf{I}_d), \quad j = 1, \dots, L. \quad (1)$$

102 중심화한 $\bar{h}_j := h_j - \mu_E \mathbf{1}_d \sim \mathcal{N}(0, \sigma_E^2 \mathbf{I}_d)$ 은 평균 0의 등방 가우시안이다. 입력 임베딩 시퀀스 $\mathbf{X}$
103 에 RSP를 결합하는 위치는 prefix $[\mathbf{H}; \mathbf{X}]$, infix($\mathbf{H}$ 를 $\mathbf{X}$ 안쪽에 삽입), suffix $[\mathbf{X}; \mathbf{H}]$ 세 가지다 [Kang
104 et al., 2026, Xu et al., 2025, Ye et al., 2026, Zhang et al., 2026]. 반복 샘플링 프로토콜에서는
105 비교되는 시도들의 prompt 추천과 디코딩 무작위성을 모두 독립으로 가정한다.

106 무작위성의 핵심은 임베딩 분포를 모사하는 데 있지 않다. 같은 prompt가 rollout마다 독립된
107 섭동을 만들도록 해 주는 데 있다 — 탐색이 요구하는 것도 바로 이 독립성이다.

108 3.2 초반 exploration: lower envelope

109 RSP는 hidden state에 직접 더해지지 않고 어텐션 가중치를 통해서만 들어간다. 따라서 RSP의
110 모든 즉각적 영향은 RSP 토큰에 배정된 attention mass 한 양으로 모인다. self-attention 레이어
111 ℓ 이 실제 토큰 n 개와 RSP 토큰 L 개를 함께 attend한다 하고, 어텐션 가중치를 $\alpha_{ij}^{(\ell)}$, value 벡
112 터를 실제·RSP 측에서 각각 $\mathbf{v}_j^{(\ell)}, \mathbf{v}_{r,j}^{(\ell)}$ 라 하자. RSP 토큰에 배정된 총 어텐션 질량을 $w_{r,i}^{(\ell)} :=$
113 $\sum_{j'=1}^L \alpha_{i,n+j'}^{(\ell)}$ 로 두면 어텐션 출력은 다음과 같이 정확히 분해된다.

$$\mathbf{x}_i^{(\ell+1)} = (1 - w_{r,i}^{(\ell)}) \tilde{\mathbf{x}}_i^{(\ell+1)} + \boldsymbol{\eta}_i^{(\ell)}, \quad \tilde{\mathbf{x}}_i^{(\ell+1)} := \sum_{j=1}^n \frac{\alpha_{ij}^{(\ell)}}{1 - w_{r,i}^{(\ell)}} \mathbf{v}_j^{(\ell)}, \quad \boldsymbol{\eta}_i^{(\ell)} := \sum_{j'=1}^L \alpha_{i,n+j'}^{(\ell)} \mathbf{v}_{r,j'}^{(\ell)}. \quad (2)$$

114 이 항등식은 softmax 정규화만 사용한 대수적 분해이고(도출: Appendix E), $\|\boldsymbol{\eta}_i^{(\ell)}\| \leq$
115 $w_{r,i}^{(\ell)} \max_{j'} \|\mathbf{v}_{r,j'}^{(\ell)}\|$ 이므로 같은 스칼라 $w_{r,i}^{(\ell)} \in [0, 1]$ 가 실제 신호 감쇠 비율 $1 - w_{r,i}^{(\ell)}$ 과 무작위
116 기여 진폭의 상계를 동시에 통제한다. RSP의 행동은 다차원 섭동이 아니라 0과 1 사이 한 값을
117 추적하는 문제로 환원된다.

118 핵심 질문은 이 양이 초반에 의미 있는 값을 갖는다는 형식 보장이 있는가다. 다음 명제가 이를
119 lower envelope 형태로 준다. 레이어 ℓ 에서 query를 $\mathbf{q}_i^{(\ell)}$, 실제·RSP key를 각각 $\mathbf{k}_j^{(\ell)}, \mathbf{k}_{r,j}^{(\ell)}$ 라 쓰자.

120 **명제 1** (초반 exploration의 lower envelope). 역방향 logit gap을 $\Delta_i^{(\ell)} := \max_{j \in [n]} (\mathbf{q}_i^{(\ell)})^\top \mathbf{k}_j^{(\ell)} -$
121 $\min_{j' \in [L]} (\mathbf{q}_i^{(\ell)})^\top \mathbf{k}_{r,j'}^{(\ell)}$ 로 두면 scaled-dot-product 어텐션에서 $w_{r,i}^{(\ell)} \geq L / (L + n \exp(\Delta_i^{(\ell)} / \sqrt{d}))$ 가
122 성립한다.

123 증명은 Appendix E(다음 절 Theorem 1 증명의 대칭). 이 부등식은 $n = 0$ 에서 1이고, $\Delta_i^{(\ell)}$ 가
124 과도하게 크지 않은 한 n 이 작은 동안 1에 가까운 값을 유지한다. 따라서 역방향 gap이 지나치게
125 벌어지지 않을 때에 한해 초반 RSP 영향력에 0에서 떨어진 하한이 형식적으로 부여된다 — RSP
126 token 하나의 score가 아주 낮으면 $\Delta_i^{(\ell)}$ 가 커져 하한은 약해질 수 있다.

3.3 후반 수렴: upper envelope과 어닐링

대칭 질문: 같은 양이 후반에 0으로 수렴한다는 형식 보장이 있는가? 정방향 logit gap을 $\Delta_i^{(\ell)} := \min_{j \in [n]} (\mathbf{q}_i^{(\ell)})^\top \mathbf{k}_j^{(\ell)} - \max_{j' \in [L]} (\mathbf{q}_i^{(\ell)})^\top \mathbf{k}_{r,j'}^{(\ell)}$ 로 둔다($\Delta_i^{(\ell)} \leq \Delta_i'^{(\ell)}$).

정리 1 (후반 어닐링의 upper envelope). *scaled-dot-product* 어텐션에서 $w_{r,i}^{(\ell)} \leq L/(L + n \exp(\Delta_i^{(\ell)}/\sqrt{d}))$ 가 성립한다. 우변은 L 과 $\Delta_i^{(\ell)}$ 를 고정한 채 n 에 대해 엄격히 감소하며, *fixed-gap setting*에서 $n \rightarrow \infty$ 이면 0으로 수렴한다.

증명은 Appendix E에 있다. Proposition 1와 결합하면 양방향 sandwich:

$$\frac{L}{L + n \exp(\Delta_i'^{(\ell)}/\sqrt{d})} \leq w_{r,i}^{(\ell)} \leq \frac{L}{L + n \exp(\Delta_i^{(\ell)}/\sqrt{d})}. \quad (3)$$

두 envelope 모두 $n = 0$ 에서 1, $n \rightarrow \infty$ 에서 0으로 수렴하지만 *rate*가 다르다($\Delta_i^{(\ell)} \leq \Delta_i'^{(\ell)}$). 초반에는 두 envelope이 함께 1에 가까이 머무르고, 후반에는 함께 0으로 간다. 정리는 “실현된 mass가 매 step 단조 감소”를 주장하지 않는다 — 디코딩 동안 query · key · hidden state가 갱신되어 두 gap도 함께 변하기 때문. 정리가 보장하는 것은 고정 gap 관점의 envelope이 cache 성장만으로 좁아진다는 점뿐이다.

이 결과는 RSP가 각 attention 위치에서 잠시 작동했다 약해지는 국소 섭동으로 해석할 수 있음을 뜻한다. RSP 기여 항의 disturbance energy를 $V_{\eta,i}^{(\ell)} := \mathbb{E} \|\eta_i^{(\ell)}\|^2$ 로 두면 second moment 유한성 아래 $V_{\eta,i}^{(\ell)} \leq M_v^{(\ell)} (w_{r,i}^{(\ell)})^2$ (Appendix E.1)이고, Theorem 1와 결합하면 고정 gap 아래에서 $V_{\eta,i}^{(\ell)} = O(1/n^2)$ 이다. 다만 이는 한 attention 위치의 상계이며, 전체 hidden-state trajectory의 감소나 transformer의 전역 함수 최소화를 주장하지 않는다.




Figure 1: Qwen2.5-Math-7B의 토큰별 어텐션 질량(suffix, MATH-500 500문제, 문제마다 독립 RSP). (a) RSP 토큰 어텐션은 추론 위치 축(가로)에서 감소하며, Eq. (3)의 양방향 envelope과 일치한다. 레이어 축(세로)의 추가 감소는 별도 경험적 현상으로, 깊은 레이어에서 logit gap이 더 날카로워지는 경향을 시사하지만 Theorem 1만으로 직접 따라오지는 않는다. (b) 질문 토큰 어텐션은 비교적 균일하게 유지된다. 보고한 양은 Appendix F의 per-token mass로, $w_{r,i}^{(\ell)}$ 를 L 로 나눈 평균값이며 본문 양과 상수배 관계다.

3.4 Branch opening과 Pass@N 누적

위 두 envelope은 한 시도 안에서 RSP가 영향을 줄 수 있는 윤곽을 정한다. 그 영향이 출력 분포에서 어떻게 나타나며, 시도들 사이에서 어떻게 누적되는가를 묻는다.

분포 선택부터 정당화한다. Theorem 1와 Proposition 1는 등방성을 사용하지 않는다 — 어텐션 항등식과 logit gap만 쓴다. 반면 *branch opening*은 두 가지 분포 성질을 따로 요구한다. 하나는 모든 방향에 분산 예산을 균등하게 분배하는 등방 공분산이고, 다른 하나는 surrogate 위 모든 비공집합 열린집합에 양의 확률을 주는 *full support*다. 다음 정리는 첫 성질을 형식화한다 — RSP 토큰 한 개 단위에서, 즉 단일 벡터 $\tilde{h} \in \mathbb{R}^d$ 의 분포에 대해 적용한다.

정리 2 (방향 무관 미니맥스 커버리지). $\mathbb{R}^d$ 위 평균 0 분포 D 가 분산 예산 $\text{tr}(\Sigma_D) \leq \rho^2$ 를 만족하면 $\min_{\|b\|=1} \text{Var}_{h \sim D}(b^\top h) = \lambda_{\min}(\Sigma_D) \leq \rho^2/d$ 이고, 등호는 $\Sigma_D = (\rho^2/d)\mathbf{I}_d$ 일 때에만 성립한다.

증명은 Appendix E. 등호는 공분산이 등방인 모든 분포에서 성립한다 — 가우시안만이 유일한 답은 아니다. 학습된 고정 prompt($\Sigma_D = 0$), PCA 정렬 노이즈, 어휘 토큰 추첨, 임베딩 공분산 정합은 등방이 아니므로 모두 적어도 한 방향에서 strictly suboptimal이다. 가우시안 선택의 추가

이유는 두 번째 성질이다. 등방 가우시안은 $\mathbb{R}^d$ 전역에서 양의 밀도(full support)를 가지므로 어떤 방향에도 사전 가중치를 두지 않는다(자세한 statement: Lemma 1). 이 두 성질이 합쳐 다음 절의 branch opening 보장을 가능케 한다.

이제 surrogate 위에서 branch opening을 형식화한다. 중심화된 prompt $\bar{h}$ 근방에서 logit을 1 차로 근사한 surrogate를 $z_i^{\text{lin}}(\bar{h}) := z_i + a_i^\top \bar{h}$, $a_i := \nabla_{\bar{h}} z_i(0)$ 로 둔다. baseline 외 토큰 i 의 top- K 진입 영역을

$$\mathcal{G}_{i,K} := \{\bar{h} \in \mathbb{R}^d : \#\{j \neq i : z_j^{\text{lin}}(\bar{h}) > z_i^{\text{lin}}(\bar{h})\} \leq K - 1\}$$

로 정의한다(이는 실제 top- K 정의와 정확히 일치한다).

명제 2 (조건부 top- K 진입). $\mathcal{G}_{i,K}$ 가 비공집합 열린집합을 포함한다고 하자. 등방 가우시안의 full support가 그 영역에 양의 확률을 부여하므로 $\mu_i := \Pr_{\bar{h}}(\bar{h} \in \mathcal{G}_{i,K}) > 0$ 이다.

증명은 Appendix E. mechanism이 보장하는 범위는 branch가 열린다($\mu_i > 0$)는 데까지다 — 영역 자체의 존재는 surrogate 위 task 측 조건이며 자동 보장되지 않는다. 단발 진입 확률 μ_i 를 task accuracy로 끌어올리려면 두 가지를 추가 가정한다. (M1) 단발 RSP 실행이 정답 trajectory를 만들 주변 확률 $p_{\min}(x) > 0$ 이 양수다. (M2) N 번의 실행은 상호 독립이다.

명제 3 (다중 경로 Pass@ N). (M1)–(M2) 아래에서, N 개의 독립 RSP 실행으로 측정한 Pass@ N 이 다음을 만족한다.

$$\Pr(\text{Pass@}N \text{ on } x) \geq 1 - (1 - p_{\min}(x))^N \geq 1 - \exp(-N p_{\min}(x)).$$

증명은 Appendix E. (M1)은 task 측 가정으로 mechanism만으로는 도출되지 않는다 — 메커니즘은 baseline 외 토큰을 후보권 안으로 들이는 데까지 책임지고, 들인 branch가 생산적이라는 점은 task의 성질이다. 같은 RSP를 모든 sample이 공유하면 이 누적이 사라지므로 독립이 핵심이다. (M1)의 경험적 흔적은 §4에서 직접 확인한다.

4 실험적 확인

앞 절의 설명이 실제 LLM 생성에서 어떻게 드러나는지를 세 장면으로 살펴본다. 먼저 RSP가 baseline 정확도를 크게 깎지 않으면서 일부 설정에서는 오히려 회복시키는지를 확인하고 (§4.2), 다음으로 생성 초반에 토큰 분포가 평탄해졌다가 후반에는 baseline 수준으로 돌아오는 자동 어닐링이 실제로 관찰되는지를 살펴 (§4.3), 끝으로 같은 RSP를 재사용할 때와 매 시도마다 새로 뽑을 때의 Pass@ N 차이가 독립성이 핵심이라는 점을 직접 보여 주는지를 본다 (§4.4).

4.1 실험 설정

평가는 세 가지 수학 추론 벤치마크 MATH-500 [Lightman et al., 2024], GSM8K [Cobbe et al., 2021], AIME24에서 수행한다. 모델은 LLaMA-3.1-8B-Instruct [Grattafiori et al., 2024]와 Qwen2.5-Math 계열 [Yang et al., 2024]을 쓰며, instruct, base, 그리고 chat template이 맞지 않는 base 설정까지 합쳐 총 일곱 가지를 비교한다. 모든 실험은 sampling 자체의 무작위성과 RSP 효과를 분리하기 위해 greedy decoding을 사용하고, fallback 기반 answer extraction pipeline으로 최종 답만 채점한다. RSP는 §3.1의 정의를 따르며 prefix/infix/suffix 세 주입 위치 중 하나에 매 배치마다 새로 추천된 $\mathbf{H}$ 를 결합한다. 전체 실험 설정과 위치별 결과는 Appendix A에 있다.

4.2 RSP는 추론 성능을 개선할까?

먼저 무작위 임베딩 주입이 모델의 추론 성능에 어떤 영향을 주는지 본다. Table 1는 각 벤치마크에서 주입 위치(Prefix, Infix, Suffix)와 $L \in \{10, 15, 20\}$ 가운데 가장 좋은 RSP 결과를 보고한다.

instruct model과 원래 프롬프트 형식을 쓰는 base model에서는 RSP가 baseline 성능을 대체로 몇 퍼센트포인트 이내에서 유지하거나 소폭만 이동시킨다. 더 눈에 띄는 것은 프롬프트 형식 불일치 상황이다. 즉, 채팅 형식으로 학습되지 않은 base model에 ChatML template을 주입했을 때, RSP는 최대 +29%p까지의 큰 성능 향상을 보인다. 단순히 불확실성을 높이는 노이즈였다면 오히려 성능 저하가 커졌어야 하므로, 이 결과는 RSP 효과가 단순한 교란을 넘는다는 점을 시사한다.

또한 RSP를 TTSV, SoftCoT, LTPO처럼 서로 다른 목적 함수로 임베딩을 최적화하는 기존 soft prompt 방법과 비교했다. Table 2은 공통 answer extraction pipeline 아래에서 다시 평가한 결과

Table 1: 모델 설정과 벤치마크별 정확도(%). RSP는 주입 위치(Prefix, Infix, Suffix) 중 최고 성능만 보고한다. 위치별 전체 결과는 Appendix A에 있다. 괄호 안 값은 baseline 대비 변화량이다.

Model	MATH-500		GSM8K		AIME24	
	Baseline	RSP	Baseline	RSP	Baseline	RSP
<i>Instruct Models</i>						
LLaMA-3.1-8B-Inst	52.20	49.40 (−2.8)	85.75	86.73 (+1.0)	6.67	10.00 (+3.3)
Qwen2.5-Math-7B-Inst	83.20	84.20 (+1.0)	95.45	95.68 (+0.2)	13.33	16.67 (+3.3)
Qwen2.5-Math-1.5B-Inst	73.00	75.20 (+2.2)	85.29	85.75 (+0.5)	10.00	20.00 (+10.0)
<i>Base Models (Raw Text)</i>						
Qwen2.5-Math-7B	72.20	71.60 (−0.6)	84.15	84.31 (+0.2)	6.67	16.67 (+10.0)
Qwen2.5-Math-1.5B	61.40	64.40 (+3.0)	77.86	74.30 (−3.6)	16.67	10.00 (−6.7)
<i>Base Models + ChatML (Format Mismatch)</i>						
Qwen2.5-Math-7B	52.20	70.40 (+18.2)	58.30	75.97 (+17.7)	23.33	23.33 (+0.0)
Qwen2.5-Math-1.5B	34.40	63.40 (+29.0)	37.45	67.02 (+29.6)	13.33	20.00 (+6.7)

Table 2: 기존 soft prompt 방법(TTSV, SoftCoT, LTPO)과의 통합 평가 비교. Baseline과 RSP 값은 Table 1에서 가져왔다. **Bold**는 최고 성능, underline은 두 번째 성능이다.

Model	Benchmark	Baseline	RSP	TTSV	SoftCoT	LTPO
Qwen2.5-Math-7B-Instruct	MATH-500	83.20	84.20	83.80	82.80	83.00
	GSM8K	<u>95.45</u>	95.68	95.30	95.00	94.84
	AIME24	13.33	<u>16.67</u>	23.30	16.67	13.33
Qwen2.5-Math-1.5B-Instruct	MATH-500	73.00	<u>75.20</u>	75.20	76.00	72.40
	GSM8K	85.29	85.75	<u>85.70</u>	84.46	84.53
	AIME24	<u>10.00</u>	20.00	6.70	6.67	<u>10.00</u>

를 보여준다. 각 방법은 프롬프트 형식과 채점 규칙이 다르지만, fallback 기반 추출을 사용해
형식에 덜 민감한 비교를 수행했다. 결과적으로 RSP는 추가 학습 없이도 최적화 기반 방법과
맞먹는 수준의 성능을 보인다.

4.3 RSP는 출력 분포를 어떻게 바꾸는가?

다음으로 RSP 주입이 생성 과정의 출력 분포를 어떻게 바꾸는지 살펴본다. 설정은 Qwen2.5-Math-1.5B-Instruct와 MATH-500이며, 토큰별 entropy, top-1 probability, varentropy를 생성 단계에 따라 측정한다. Figure 2와 Table 3는 생성 초반 5% 구간에서 RSP 변형과 기존 soft prompt 방법을 비교한 결과다.




Figure 2: 생성 초반 5% 구간의 평균 entropy, top-1 probability, varentropy (Qwen2.5-Math-1.5B-Instruct, MATH-500). 음영은 ± 1 SEM이다. 실선은 RSP 변형과 baseline, 점선은 기존 soft prompt 방법(LTPO, SoftCoT, TTSV)이다.

결과는 RSP가 생성 초반 출력 분포를 분명히 바꾼다는 점을 보여준다. 세 주입 위치 모두에서
entropy는 증가하고, top-1 probability는 감소하며, varentropy는 증가한다. 이는 분포가 평평해
지고, 단일 우세 토큰에 대한 확신은 약해지며, 다분형 분포가 더 자주 나타남을 뜻한다 [Ahmed
et al., 2026]. 높은 entropy 구간은 추론 궤적이 갈라지는 핵심 분기점으로 알려져 있으므로 [Wang
et al., 2025], 이 변화는 여러 추론 경로가 공존할 수 있는 상태로 모델을 밀어 넣는다. 중요한

Table 3: 생성 초반 5% 구간의 평균 entropy, top-1 probability, varentropy (Qwen2.5-Math-1.5B-Instruct, MATH-500).

Metric	Baseline	Prefix	Infix	Suffix	LTPO	SoftCoT	TTSV
Entropy	0.1332	0.1366	0.1402	0.1941	0.1662	0.4218	0.1359
Top-1 Prob	0.9535	0.9523	0.9525	0.9373	0.9437	0.9156	0.9534
Varentropy	0.2181	0.2207	0.2463	0.4010	0.2953	2.2234	0.2174

215 점은 변화가 생성 초반에 국한된다는 것이다. 생성 중반과 후반에서는 세 지표 모두 baseline
216 수준으로 다시 수렴한다.

217 서로 다른 목적 함수로 학습된 기존 방법들도 같은 패턴을 공유한다. 평균 entropy를 줄이는
218 보상을 쓰는 TTSV조차 초반 구간만큼은 baseline과 비슷하거나 더 높아, 이 entropy 상승은 특정
219 최적화 목적이 아니라 사전학습되지 않은 연속 임베딩 주입 자체에 가까운 효과로 보인다.

220 4.4 RSP는 실제로 추론 궤적의 다양성을 만드는가?

221 Section 4.3는 RSP가 생성 초반 출력 분포를 바꾼다는 사실을 보였다. 이제 이 변화가 실제 추론
222 다양성으로 이어지는지를 세 수준에서 살펴본다. 분석 수준은 토큰 순위, 궤적의 의미적 내용,
223 과제 수준 결과다. 세 분석 모두 Qwen2.5-Math-1.5B-Instruct, MATH-500, suffix 주입, $L = 10$
224 설정을 공유한다.

225 먼저 토큰 수준에서 보면, 자기회귀 생성에서 baseline과 RSP의 궤적 차이는 결국 첫 토큰에서 시작될
226 수밖에 없으므로 baseline $\tau=1.0$ 을 기준으로 단순 flattening의 상한인 baseline $\tau=2.0$ 과 RSP $\tau=1.0$ 을 비교
227 한다. 세 지표—Spearman rank correlation ρ , baseline top-10 밖 확률 질량, Jensen–Shannon divergence—는
228 각각 순위 재배치, 지지 집합 확장, 분포 변화의 크기를 잡아낸다(정의를 Appendix C). Table 4에서 baseline top-10 밖으로 이동하는 질량은 $\tau=2.0$ 에서 5.15%
229 에 그치지만 RSP $\tau=1.0$ 에서는 27.64%이고, Spearman 상관은 1에서 0.651로 떨어진다. Temperature는 단조 변환이라 어떤 τ 에서도 순위를 보존하므로 $\rho = 1$ 이 강제되는 반면, RSP는 순위 자체를 뒤섞는다 — §3.4이 surrogate 수준에서 보인 branch opening의 직접 흔적. JS divergence
230 0.231은 이 변화의 전체 크기를 요약한다.

Table 4: Baseline $\tau=1.0$ 을 기준으로 본 첫 토큰 분포 지표. Baseline $\tau=2.0$ 과 RSP $\tau=1.0$ 을 비교한다.

Metric	$\tau=2.0$	RSP
Spearman ρ	1.0	0.651
Mass outside top-10	5.15%	27.64%
JS divergence	0.086	0.231

238 한 단계 위인 궤적 수준에서는, 첫 토큰의 재배치가 실제로
239 의미적으로 다른 추론 경로를 여는지가 관건이다. 이를 위해
240 MATH-500에서 무작위로 64개 문제를 뽑고, Baseline과 RSP
241 두 조건에서 각 문제마다 temperature $\tau = 1.0$ 으로 300개의 독립
242 궤적을 생성했다. 각 궤적은 BGE-M3 [Chen et al., 2024]로 임베딩한 뒤, 문제 내 평균 pairwise cosine distance, DBSCAN
243 [Ester et al., 1996] 클러스터 중심 사이의 inter-cluster distance, 그리고 intra-cluster distance를 계산했다. Table 5는 RSP가
244 intra-cluster distance는 거의 바꾸지 않으면서 inter-cluster distance를 크게 키운다는 점을 보여준다. 즉, 각 전략 내부의 일관성은 유지하면서 전략 간 거리를 벌린다. Pairwise distance 기준으로
245 RSP는 64개 중 56개 문제(87.5%)에서 baseline보다 컸다.

Table 5: 64개 문제에 대해 평균한 의미적 다양성 지표.

Metric	Baseline	RSP
Pairwise cos. dist.	0.0612	0.0879
Inter-cluster dist.	0.0183	0.0982
Intra-cluster dist.	0.0526	0.0528

249 Figure 3(a)에서 RSP 샘플(파랑)은 baseline 영역을 포함하면서 baseline이 도달하지 못한 별도
250 클러스터까지 확장되고, 그 영역에도 정답 궤적이 포함된다. (b), (c)는 64개 문제 전반에 걸쳐
251 RSP가 더 많은 클러스터와 더 큰 pairwise cosine distance를 만든다는 패턴이 반복됨을 보여준다.
252 즉 RSP는 클러스터 내부 진행은 흐트러뜨리지 않으면서 궤적이 진입하는 전략 클러스터 자체를
253 바꾼다. 문제별 추가 t-SNE는 Appendix B에 있다.

254 마지막 결과 수준에서는, 이러한 다양성이 실제 과제 성과로 이어지는지를 Pass@ N 로 본다
255 (N 개의 샘플 중 적어도 하나가 정답일 확률). MATH-500과 AIME24에서 문제당 $N = 16$, 네
256 조건을 비교한다. (i) baseline + $\tau=1.0$, (ii) RSP를 모든 샘플이 공유 + $\tau=1.0$, (iii) 샘플마다 독립
257 RSP + greedy, (iv) 샘플마다 독립 RSP + $\tau=1.0$.

258 조건 (iv)가 두 벤치마크 모두에서 가장 높은 Pass@ N 을 달성하며 $N = 16$ 에서 MATH-500
259 92.80%, AIME24 36.67%에 이른다. (ii)는 baseline 대비 거의 개선이 없어, 다양성 이득의 핵심




Figure 3: 64개 MATH-500 문제에서의 의미적 다양성 분석(문제당 300개 궤적, Qwen2.5-Math-1.5B-Instruct, $\tau = 1.0$, BGE-M3 임베딩). (a) 대표 문제 `test/prealgebra/951`의 t-SNE 투영: baseline(빨강)은 한 영역에 비교적 집중되지만, RSP suffix(파랑)는 더 넓고 분리된 군집까지 확장된다. 채워진 표식은 정답, 빈 표식은 오답이다. (b) 문제별 평균 pairwise cosine distance. 대각선 위 점은 RSP가 baseline보다 더 다양한 궤적을 만든다는 뜻이다. (c) 문제별 DBSCAN 클러스터 수. 대부분의 문제에서 RSP가 더 많은 클러스터를 만든다.




Figure 4: Qwen2.5-Math-1.5B-Instruct에서의 Pass@N 스케일링. 좌측은 MATH-500, 우측은 AIME24이며, 문제당 $N = 16$ 개의 샘플을 사용했다. Baseline은 temperature sampling만, fixed seed는 고정된 하나의 RSP와 temperature를 함께 쓴 경우, indep. seed는 샘플마다 다른 RSP를 쓰는 경우이다.

이 고정 섭동이 아니라 샘플마다 독립된 무작위 임베딩을 드러낸다. Pass@1은 MATH-500에서 baseline 수준을 유지하고 더 어려운 AIME24에서는 (iv)가 더 높아, 독립 RSP + temperature 결합이 단일 샘플 정확도를 해치지 않으면서 추론 궤적을 다양화한다.

5 결론

본 논문은 사전학습 임베딩 행렬의 항별 통계만 빌려 등방 가우시안에서 추가한 RSP가 학습 없이 LLM 추론에 영향을 주는 이유를 transformer 수준에서 분석했다. 분석은 초반 exploration의 lower envelope(§3.2), 후반 어닐링의 upper envelope(§3.3), 그리고 등방성 정당성과 surrogate 위 branch opening, 독립 재추첨의 결합(§3.4)을 거쳐 $\Pr(\text{Pass}@N) \geq 1 - \exp(-Np_{\min})$ 의 지수 saturation 하한으로 달했다. §4의 세 실험은 이 부등식이 예측한 baseline 회복, 자동 어닐링, 독립 재추첨의 누적을 차례로 확인했다. RSP는 순위를 바꾸는 섭동이고 temperature는 순위를 보존하는 섭동이므로 둘은 직교적이며, 이는 GRPO [Shao et al., 2024]의 entropy collapse를 DAPO [Yu et al., 2025], CE-GPPO [Su et al., 2026] 너머에서 샘플링 단계로 보완할 가능성을 시사한다. RSP를 활용한 학습 시점 비교, 수학 추론을 넘어선 도메인 확장, RSP 길이·주입 위치의 원리적 결정은 향후 과제다.

References

Farhan Ahmed, Yuya Jeremy Ong, and Chad DeLuca. LogitScope: A Framework for Analyzing LLM Uncertainty through Information Metrics. In *ICLR Workshop*, 2026.

277 Nora Belrose, Igor Ostrovsky, Lev McKinney, Zach Furman, Logan Smith, Danny Halawi, Stella
278 Biderman, and Jacob Steinhardt. Eliciting Latent Predictions from Transformers with the Tuned
279 Lens. *arXiv:2303.08112*, 2023.

280 Jianlyu Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, and Zheng Liu. M3-
281 Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through
282 Self-Knowledge Distillation. In *Findings of ACL*, 2024.

283 Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser,
284 Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, Christopher Hesse, and John
285 Schulman. Training Verifiers to Solve Math Word Problems. *arXiv:2110.14168*, 2021.

286 Jeremy M. Cohen, Elan Rosenfeld, and J. Zico Kolter. Certified Adversarial Robustness via Random-
287 ized Smoothing. In *ICML*, 2019.

288 Timothée Darcet, Maxime Oquab, Julien Mairal, and Piotr Bojanowski. Vision Transformers Need
289 Registers. In *ICLR*, 2024.

290 Martin Ester, Hans-Peter Kriegel, Jörg Sander, and Xiaowei Xu. A Density-Based Algorithm for
291 Discovering Clusters in Large Spatial Databases with Noise. In *KDD*, 1996.

292 Meire Fortunato, Mohammad Gheshlaghi Azar, Bilal Piot, Jacob Menick, Ian Osband, Alex Graves,
293 Vlad Mnih, Remi Munos, Demis Hassabis, Olivier Pietquin, Charles Blundell, and Shane Legg.
294 Noisy Networks for Exploration. In *ICLR*, 2018.

295 Mor Geva, Roei Schuster, Jonathan Berant, and Omer Levy. Transformer Feed-Forward Layers Are
296 Key-Value Memories. In *EMNLP*, 2021.

297 Sachin Goyal, Ziwei Ji, Ankit Singh Rawat, Aditya Krishna Menon, Sanjiv Kumar, and Vaishnavh
298 Nagarajan. Think before You Speak: Training Language Models with Pause Tokens. In *ICLR*,
299 2024.

300 Aaron Grattafiori, Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad
301 Al-Dahle, Aiesha Letman, Akhil Mathur, Alan Schelten, Alex Vaughan, Amy Yang, Angela Fan,
302 Anirudh Goyal, Anthony Hartshorn, Aobo Yang, Archi Mitra, Archie Sravankumar, Artem Ko-
303 renev, Arthur Hinsvark, Arun Rao, Aston Zhang, Aurelien Rodriguez, Austen Gregerson, Ava
304 Spataru, Baptiste Roziere, Bethany Biron, Binh Tang, Bobbie Chern, Charlotte Caucheteux, Chaya
305 Nayak, Chloe Bi, Chris Marra, Chris McConnell, Christian Keller, Christophe Touret, Chunyang
306 Wu, Corinne Wong, Cristian Canton Ferrer, Cyrus Nikolaidis, Damien Allonsius, Daniel Song,
307 Danielle Pintz, Danny Livshits, Danny Wyatt, David Esiobu, Dhruv Choudhary, Dhruv Mahajan,
308 Diego Garcia-Olano, Diego Perino, Dieuwke Hupkes, Egor Lakomkin, Ehab AlBadawy, Elina
309 Lobanova, Emily Dinan, Eric Michael Smith, Filip Radenovic, Francisco Guzmán, Frank Zhang,
310 Gabriel Synnaeve, Gabrielle Lee, Georgia Lewis Anderson, Govind Thattai, Graeme Nail, Gre-
311 goire Mialon, Guan Pang, Guillem Cucurell, Hailey Nguyen, Hannah Korevaar, Hu Xu, Hugo
312 Touvron, Iliyan Zarov, Imanol Arrieta Ibarra, Isabel Kloumann, Ishan Misra, Ivan Evtimov, Jack
313 Zhang, Jade Copet, Jaewon Lee, Jan Geffert, Jana Vranes, Jason Park, Jay Mahadeokar, Jeet Shah,
314 Jelmer van der Linde, Jennifer Billock, Jenny Hong, Jenya Lee, Jeremy Fu, Jianfeng Chi, Jianyu
315 Huang, Jiawen Liu, Jie Wang, Jiecao Yu, Joanna Bitton, Joe Spisak, Jongsoo Park, Joseph Rocca,
316 Joshua Johnstun, Joshua Saxe, Junteng Jia, Kalyan Vasuden Alwala, Karthik Prasad, Kartikeya
317 Upasani, Kate Plawiak, Ke Li, Kenneth Heafield, Kevin Stone, Khalid El-Arini, Krithika Iyer,
318 Kshitiz Malik, Kuenley Chiu, Kunal Bhalla, Kushal Lakhotia, Lauren Rantala-Yeary, Laurens
319 van der Maaten, Lawrence Chen, Liang Tan, Liz Jenkins, Louis Martin, Lovish Madaan, Lubo
320 Malo, Lukas Blecher, Lukas Landzaat, Luke de Oliveira, Madeline Muzzi, Mahesh Pasupuleti,
321 Mannat Singh, Manohar Paluri, Marcin Kardas, Maria Tsimpoukelli, Mathew Oldham, Mathieu
322 Rita, Maya Pavlova, Melanie Kambadur, Mike Lewis, Min Si, Mitesh Kumar Singh, Mona Has-
323 san, Naman Goyal, Narjes Torabi, Nikolay Bashlykov, Nikolay Bogoychev, Niladri Chatterji, Ning
324 Zhang, Olivier Duchenne, Onur Çelebi, Patrick Alrassy, Pengchuan Zhang, Pengwei Li, Petar Va-
325 sic, Peter Weng, Prajjwal Bhargava, Pratik Dubal, Praveen Krishnan, Punit Singh Koura, Puxin
326 Xu, Qing He, Qingxiao Dong, Ragavan Srinivasan, Raj Ganapathy, Ramon Calderer, Ricardo Sil-
327 veira Cabral, Robert Stojnic, Roberta Raileanu, Rohan Maheswari, Rohit Girdhar, Rohit Patel,
328 Romain Sauvestre, Ronnie Polidoro, Roshan Sumbaly, Ross Taylor, Ruan Silva, Rui Hou, Rui
329 Wang, Saghar Hosseini, Sahana Chennabasappa, Sanjay Singh, Sean Bell, Seohyun Sonia Kim,

330 Sergey Edunov, Shaoliang Nie, Sharan Narang, Sharath Raparthy, Sheng Shen, Shengye Wan,
 331 Shruti Bhosale, Shun Zhang, Simon Vandenhende, Soumya Batra, Spencer Whitman, Sten Sootla,
 332 Stephane Collot, Suchin Gururangan, Sydney Borodinsky, Tamar Herman, Tara Fowler, Tarek
 333 Sheasha, Thomas Georgiou, Thomas Scialom, Tobias Speckbacher, Todor Mihaylov, Tong Xiao,
 334 Ujjwal Karn, Vedanuj Goswami, Vibhor Gupta, Vignesh Ramanathan, Viktor Kerkez, Vincent
 335 Gonguet, Virginie Do, Vish Vogeti, Vitor Albiero, Vladan Petrovic, Weiwei Chu, Wenhan Xiong,
 336 Wenyin Fu, Whitney Meers, Xavier Martinet, Xiaodong Wang, Xiaofang Wang, Xiaoqing Ellen
 337 Tan, Xide Xia, Xinfeng Xie, Xuchao Jia, Xuwei Wang, Yaelle Goldschlag, Yashesh Gaur, Yas-
 338 mine Babaei, Yi Wen, Yiwen Song, Yuchen Zhang, Yue Li, Yuning Mao, Zacharie Delpierre
 339 Coudert, Zheng Yan, Zhengxing Chen, Zoe Papakipos, Aaditya Singh, Aayushi Srivastava, Abha
 340 Jain, Adam Kelsey, Adam Shajnfeld, Adithya Gangidi, Adolfo Victoria, Ahuva Goldstand, Ajay
 341 Menon, Ajay Sharma, Alex Boesenberg, Alexei Baevski, Allie Feinstein, Amanda Kallet, Amit
 342 Sangani, Amos Teo, Anam Yunus, Andrei Lupu, Andres Alvarado, Andrew Caples, Andrew Gu,
 343 Andrew Ho, Andrew Poulton, Andrew Ryan, Ankit Ramchandani, Annie Dong, Annie Franco,
 344 Anuj Goyal, Aparajita Saraf, Arkabandhu Chowdhury, Ashley Gabriel, Ashwin Bharambe, As-
 345 saf Eisenman, Azadeh Yazdan, Beau James, Ben Maurer, Benjamin Leonhardi, Bernie Huang,
 346 Beth Loyd, Beto De Paola, Bhargavi Paranjape, Bing Liu, Bo Wu, Boyu Ni, Braden Hancock,
 347 Bram Wasti, Brandon Spence, Brani Stojkovic, Brian Gamido, Britt Montalvo, Carl Parker, Carly
 348 Burton, Catalina Mejia, Ce Liu, Changhan Wang, Changkyu Kim, Chao Zhou, Chester Hu, Ching-
 349 Hsiang Chu, Chris Cai, Chris Tindal, Christoph Feichtenhofer, Cynthia Gao, Damon Civin, Dana
 350 Beaty, Daniel Kreymer, Daniel Li, David Adkins, David Xu, Davide Testuggine, Delia David,
 351 Devi Parikh, Diana Liskovich, Didem Foss, Dingkan Wang, Duc Le, Dustin Holland, Edward
 352 Dowling, Eissa Jamil, Elaine Montgomery, Eleonora Presani, Emily Hahn, Emily Wood, Eric-
 353 Tuan Le, Erik Brinkman, Esteban Arcaute, Evan Dunbar, Evan Smothers, Fei Sun, Felix Kreuk,
 354 Feng Tian, Filippos Kokkinos, Firat Ozgenel, Francesco Caggioni, Frank Kanayet, Frank Seide,
 355 Gabriela Medina Florez, Gabriella Schwarz, Gada Badeer, Georgia Swee, Gil Halpern, Grant Her-
 356 man, Grigory Sizov, Guangyi Zhang, Guna Lakshminarayanan, Hakan Inan, Hamid Shojanazeri,
 357 Han Zou, Hannah Wang, Hanwen Zha, Haroun Habeeb, Harrison Rudolph, Helen Suk, Henry
 358 Aspegren, Hunter Goldman, Hongyuan Zhan, Ibrahim Damlaj, Igor Molybog, Igor Tufanov, Il-
 359 ias Leontiadis, Irina-Elena Veliche, Itai Gat, Jake Weissman, James Geboski, James Kohli, Janice
 360 Lam, Japhet Asher, Jean-Baptiste Gaya, Jeff Marcus, Jeff Tang, Jennifer Chan, Jenny Rehm,
 361 Reizenstein, Jeremy Teboul, Jessica Zhong, Jian Jin, Jingyi Yang, Joe Cummings, Jon Carvill, Jon
 362 Shepard, Jonathan McPhie, Jonathan Torres, Josh Ginsburg, Junjie Wang, Kai Wu, Kam Hou U,
 363 Karan Saxena, Kartikay Khandelwal, Katayoun Zand, Kathy Matosich, Kaushik Veeraraghavan,
 364 Kelly Michelena, Keqian Li, Kiran Jagadeesh, Kun Huang, Kunal Chawla, Kyle Huang, Lailin
 365 Chen, Lakshya Garg, Lavender A, Leandro Silva, Lee Bell, Lei Zhang, Liangpeng Guo, Licheng
 366 Yu, Liron Moshkovich, Luca Wehrstedt, Madian Khabsa, Manav Avalani, Manish Bhatt, Martynas
 367 Mankus, Matan Hasson, Matthew Lennie, Matthias Reso, Maxim Groshev, Maxim Naumov, Maya
 368 Lathi, Meghan Keneally, Miao Liu, Michael L. Seltzer, Michal Valko, Michelle Restrepo, Mihir
 369 Patel, Mik Vyatskov, Mikayel Samvelyan, Mike Clark, Mike Macey, Mike Wang, Miquel Jubert
 370 Hermoso, Mo Metanat, Mohammad Rastegari, Munish Bansal, Nandhini Santhanam, Natascha
 371 Parks, Natasha White, Navyata Bawa, Nayan Singhal, Nick Egebo, Nicolas Usunier, Nikhil Mehta,
 372 Nikolay Pavlovich Laptev, Ning Dong, Norman Cheng, Oleg Chernoguz, Olivia Hart, Omkar
 373 Salpekar, Ozlem Kalinli, Parkin Kent, Parth Parekh, Paul Saab, Pavan Balaji, Pedro Rittner, Philip
 374 Bontrager, Pierre Roux, Piotr Dollar, Polina Zvyagina, Prashant Ratanachandani, Pritish Yuvraj,
 375 Qian Liang, Rachad Alao, Rachel Rodriguez, Rafi Ayub, Raghotham Murthy, Raghu Nayani,
 376 Rahul Mitra, Rangaprabhu Parthasarathy, Raymond Li, Rebekkah Hogan, Robin Battey, Rocky
 377 Wang, Russ Howes, Ruty Rinott, Sachin Mehta, Sachin Siby, Sai Jayesh Bondu, Samyak Datta,
 378 Sara Chugh, Sara Hunt, Sargun Dhillon, Sasha Sidorov, Satadru Pan, Saurabh Mahajan, Saurabh
 379 Verma, Seiji Yamamoto, Sharadh Ramaswamy, Shaun Lindsay, Shaun Lindsay, Sheng Feng,
 380 Shenghao Lin, Shengxin Cindy Zha, Shishir Patil, Shiva Shankar, Shuqiang Zhang, Shuqiang
 381 Zhang, Sinong Wang, Sneha Agarwal, Soji Sajuyigbe, Soumith Chintala, Stephanie Max, Stephen
 382 Chen, Steve Kehoe, Steve Satterfield, Sudarshan Govindaprasad, Sumit Gupta, Summer Deng,
 383 Sungmin Cho, Sunny Virk, Suraj Subramanian, Sy Choudhury, Sydney Goldman, Tal Remez,
 384 Tamar Glaser, Tamara Best, Thilo Koehler, Thomas Robinson, Tianhe Li, Tianjun Zhang, Tim
 385 Matthews, Timothy Chou, Tzook Shaked, Varun Vontimitta, Victoria Ajayi, Victoria Montanez,
 386 Vijai Mohan, Vinay Satish Kumar, Vishal Mangla, Vlad Ionescu, Vlad Poenaru, Vlad Tiberiu
 387 Mihailescu, Vladimir Ivanov, Wei Li, Wenchen Wang, Wenwen Jiang, Wes Bouaziz, Will Con-
 388 stable, Xiaocheng Tang, Xiaojuan Wu, Xiaolan Wang, Xilun Wu, Xinbo Gao, Yaniv Kleinman,

389 Yanjun Chen, Ye Hu, Ye Jia, Ye Qi, Yenda Li, Yilin Zhang, Ying Zhang, Yossi Adi, Youngjin
390 Nam, Yu Wang, Yu Zhao, Yuchen Hao, Yundi Qian, Yunlu Li, Yuzi He, Zach Rait, Zachary De-
391 Vito, Zef Rosnbrick, Zhaoduo Wen, Zhenyu Yang, Zhiwei Zhao, and Zhiyu Ma. The Llama 3
392 Herd of Models. *arXiv:2407.21783*, 2024.

393 Shibo Hao, Sainbayar Sukhbaatar, DiJia Su, Xian Li, Zhiting Hu, Jason Weston, and Yuandong Tian.
394 Training Large Language Models to Reason in a Continuous Latent Space. In *ICLR*, 2025.

395 Neil Houlsby, Andrei Giurgiu, Stanislaw Jastrzebski, Bruna Morrone, Quentin de Laroussilhe, An-
396 drea Gesmundo, Mona Attariyan, and Sylvain Gelly. Parameter-Efficient Transfer Learning for
397 NLP. In *ICML*, 2019.

398 Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang,
399 and Weizhu Chen. LoRA: Low-Rank Adaptation of Large Language Models. In *ICLR*, 2022.

400 Neel Jain, Ping-yeh Chiang, Yuxin Wen, John Kirchenbauer, Hong-Min Chu, Gowthami Somepalli,
401 Brian R. Bartoldson, Bhavya Kailkhura, Avi Schwarzschild, Aniruddha Saha, Micah Goldblum,
402 Jonas Geiping, and Tom Goldstein. NEFTune: Noisy Embeddings Improve Instruction Finetuning.
403 In *ICLR*, 2024.

404 Xinyue Kang, Diwei Shi, and Li Chen. Model Whisper: Steering Vectors Unlock Large Language
405 Models’ Potential in Test-time. In *AAAI*, 2026.

406 Brian Lester, Rami Al-Rfou, and Noah Constant. The Power of Scale for Parameter-Efficient Prompt
407 Tuning. In *EMNLP*, 2021.

408 Xiang Lisa Li and Percy Liang. Prefix-Tuning: Optimizing Continuous Prompts for Generation. In
409 *ACL-IJCNLP*, 2021.

410 Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike,
411 John Schulman, Ilya Sutskever, and Karl Cobbe. Let’s Verify Step by Step. In *ICLR*, 2024.

412 Xiao Liu, Yanan Zheng, Zhengxiao Du, Ming Ding, Yujie Qian, Zhilin Yang, and Jie Tang. GPT
413 Understands, Too. *AI Open*, 5:208–215, 2024.

414 Aman Madaan and Amir Yazdanbakhsh. Text and Patterns: For Effective Chain of Thought, It Takes
415 Two to Tango. *arXiv:2209.07686*, 2022.

416 Alexander Robey, Eric Wong, Hamed Hassani, and George J. Pappas. SmoothLLM: Defending Large
417 Language Models Against Jailbreaking Attacks. *Transactions on Machine Learning Research*,
418 2025.

419 Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang,
420 Mingchuan Zhang, Y.K. Li, Y. Wu, and Daya Guo. DeepSeekMath: Pushing the Limits of Math-
421 ematical Reasoning in Open Language Models. *arXiv:2402.03300*, 2024.

422 Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov.
423 Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *Journal of Machine Learn-
424 ing Research*, 15:1929–1958, 2014.

425 Zhenpeng Su, Lei Yu, Minxuan Lv, Yuntao Li, Wenping Hu, Fuzheng Zhang, Kun Gai, and
426 Guorui Zhou. CE-GPPO: Coordinating Entropy via Gradient-Preserving Clipping Policy Opti-
427 mization in Reinforcement Learning. In *ACL*, 2026.

428 Shenzi Wang, Le Yu, Chang Gao, Chujie Zheng, Shixuan Liu, Rui Lu, Kai Dang, Xionghui Chen,
429 Jianxin Yang, Zhenru Zhang, Yuqiong Liu, An Yang, Andrew Zhao, Yang Yue, Shiji Song, Bowen
430 Yu, Gao Huang, and Junyang Lin. Beyond the 80/20 Rule: High-Entropy Minority Tokens Drive
431 Effective Reinforcement Learning for LLM Reasoning. In *NeurIPS*, 2025.

432 Yige Xu, Xu Guo, Zhiwei Zeng, and Chunyan Miao. SoftCoT: Soft Chain-of-Thought for Efficient
433 Reasoning with LLMs. In *ACL*, 2025.

- 434 An Yang, Beichen Zhang, Binyuan Hui, Bofei Gao, Bowen Yu, Chengpeng Li, Dayiheng Liu,
435 Jianhong Tu, Jingren Zhou, Junyang Lin, Keming Lu, Mingfeng Xue, Runji Lin, Tianyu Liu,
436 Xingzhang Ren, and Zhenru Zhang. Qwen2.5-Math Technical Report: Toward Mathematical
437 Expert Model via Self-Improvement. *arXiv:2409.12122*, 2024.
- 438 Wengao Ye, Yan Liang, and Lianlei Shan. Thinking on the Fly: Test-Time Reasoning Enhancement
439 via Latent Thought Policy Optimization. In *ICLR*, 2026.
- 440 Qiying Yu, Zheng Zhang, Ruofei Zhu, Yufeng Yuan, Xiaochen Zuo, Yu Yue, Weinan Dai, Tiantian
441 Fan, Gaohong Liu, Juncai Liu, Lingjun Liu, Xin Liu, Haibin Lin, Zhiqi Lin, Bole Ma, Guangming
442 Sheng, Yuxuan Tong, Chi Zhang, Mofan Zhang, Ru Zhang, Wang Zhang, Hang Zhu, Jinhua Zhu,
443 Jiaze Chen, Jiangjie Chen, Chengyi Wang, Hongli Yu, Yuxuan Song, Xiangpeng Wei, Hao Zhou,
444 Jingjing Liu, Wei-Ying Ma, Ya-Qin Zhang, Lin Yan, Yonghui Wu, and Mingxuan Wang. DAPO:
445 An Open-Source LLM Reinforcement Learning System at Scale. In *NeurIPS*, 2025.
- 446 Guibin Zhang, Muxin Fu, and Shuicheng Yan. MemGen: Weaving Generative Latent Memory for
447 Self-Evolving Agents. In *ICLR*, 2026.

448 A 실험 설정과 전체 정확도 분석

449 Table 6은 본문 Table 1에서 위치별 최고 성능만 요약해 제시한 결과를, Prefix, Infix, Suffix 별 전체
 450 정확도로 다시 펼쳐 보인다. Table 7는 각 모델-벤치마크 조합에서 사용한 RSP 토큰 수 L 을 정리
 451 한 것으로, 후보 집합 {10, 15, 20}에서 선택했다. 모든 실험은 단일 NVIDIA A6000 40GB GPU
 452 에서 greedy decoding으로 수행했으며, 최대 생성 길이는 MATH-500과 GSM8K에서 3,072 토큰,
 453 AIME24에서 4,096 토큰으로 고정했다. 배치 크기는 모델별로 고정했다(LLaMA-3.1-8B-Instruct
 454 와 Qwen2.5-Math-7B 계열은 16, Qwen2.5-Math-1.5B 계열은 32).

Table 6: 모델 설정, 주입 위치, 벤치마크별 정확도(%). 괄호 안 값은 baseline 대비 변화량이다. 굵게는 최고 성능, 밑줄은 각 모델-벤치마크 조합에서 두 번째 성능을 뜻한다.

Model	Mode	MATH-500	GSM8K	AIME24
<i>Instruct Models</i>				
LLaMA-3.1-8B-Instruct	Baseline	52.20	85.75	<u>6.67</u>
	Prefix	45.00 (−7.2)	76.35 (−9.4)	3.33 (−3.3)
	Infix	<u>49.40</u> (−2.8)	85.97 (+0.2)	10.00 (+3.3)
	Suffix	<u>49.40</u> (−2.8)	86.73 (+1.0)	10.00 (+3.3)
Qwen2.5-Math-7B-Instruct	Baseline	83.20	95.45	<u>13.33</u>
	Prefix	81.40 (−1.8)	94.92 (−0.5)	<u>13.33</u> (+0.0)
	Infix	84.20 (+1.0)	<u>95.60</u> (+0.2)	16.67 (+3.3)
	Suffix	<u>83.40</u> (+0.2)	95.68 (+0.2)	16.67 (+3.3)
Qwen2.5-Math-1.5B-Instruct	Baseline	73.00	85.29	10.00
	Prefix	74.80 (+1.8)	85.29 (+0.0)	<u>13.33</u> (+3.3)
	Infix	75.20 (+2.2)	85.75 (+0.5)	<u>6.67</u> (−3.3)
	Suffix	74.20 (+1.2)	84.69 (−0.6)	20.00 (+10.0)
<i>Base Models (Raw Text)</i>				
Qwen2.5-Math-7B	Baseline	72.20	<u>84.15</u>	6.67
	Prefix	<u>71.60</u> (−0.6)	84.31 (+0.2)	16.67 (+10.0)
	Infix	63.20 (−9.0)	64.29 (−19.9)	16.67 (+10.0)
	Suffix	55.60 (−16.6)	54.13 (−30.0)	<u>13.33</u> (+6.7)
Qwen2.5-Math-1.5B	Baseline	<u>61.40</u>	77.86	16.67
	Prefix	64.40 (+3.0)	<u>74.30</u> (−3.6)	<u>10.00</u> (−6.7)
	Infix	63.20 (+1.8)	73.92 (−3.9)	<u>10.00</u> (−6.7)
	Suffix	54.60 (−6.8)	58.61 (−19.3)	3.33 (−13.3)
<i>Base Models + ChatML (Format Mismatch)</i>				
Qwen2.5-Math-7B	Baseline	52.20	58.30	23.33
	Prefix	59.20 (+7.0)	56.41 (−1.9)	<u>3.33</u> (−20.0)
	Infix	<u>62.00</u> (+9.8)	69.07 (+10.8)	23.33 (+0.0)
	Suffix	70.40 (+18.2)	75.97 (+17.7)	23.33 (+0.0)
Qwen2.5-Math-1.5B	Baseline	34.40	37.45	<u>13.33</u>
	Prefix	63.40 (+29.0)	67.02 (+29.6)	20.00 (+6.7)
	Infix	39.20 (+4.8)	50.42 (+13.0)	6.67 (−6.7)
	Suffix	<u>51.00</u> (+16.6)	<u>50.64</u> (+13.2)	<u>13.33</u> (+0.0)

Table 7: 각 모델과 벤치마크에 사용한 RSP 토큰 수 (L).

Model	MATH-500	GSM8K	AIME24
LLaMA-3.1-8B-Instruct	15	20	15
Qwen2.5-Math-7B-Instruct	20	20	20
Qwen2.5-Math-1.5B-Instruct	20	10	20
Qwen2.5-Math-7B	10	10	20
Qwen2.5-Math-1.5B	10	10	20
Qwen2.5-Math-1.5B (ChatML)	20	20	10
Qwen2.5-Math-7B (ChatML)	20	20	20

455 A.1 RSP 주입 위치와 프롬프트 템플릿

456 아래에는 모든 모델 유형에서 주입 위치별 프롬프트 구조를 정리했다. **파란색 텍스트**는 RSP
 457 임베딩, **보라색 텍스트**는 특수 토큰을 뜻한다.

458 A.1.1 Prefix

459 Prefix 주입에서는 RSP 임베딩을 프롬프트 임베딩 앞에 연결한다. 텍스트 자체는 수정하지
460 않는다.

461 ChatML (Qwen Instruct / Base + ChatML).

```
[Random Embeddings (L tokens)]
<|im_start|>system
Please reason step by step, and put your final answer within \boxed{<|im_end|>
<|im_start|>user
{question}<|im_end|>
<|im_start|>assistant
```

463 LLaMA Chat Template.

```
[Random Embeddings (L tokens)]
<|begin_of_text|>
<|start_header_id|>system<|end_header_id|>
Cutting Knowledge Date: December 2023
Today Date: 26 Jul 2024
Please reason step by step, and put your final answer within \boxed{<|eot_id|>
<|start_header_id|>user<|end_header_id|>
{question}<|eot_id|>
<|start_header_id|>assistant<|end_header_id|>
```

465 Raw Text (Qwen Base).

```
[Random Embeddings (L tokens)]
{question}
Please reason step by step, and put your final answer within \boxed{<|im_end|>
```

467 A.1.2 Infix

468 Infix 주입에서는 설명 문구와 특수 토큰을 프롬프트 내부에 넣은 뒤, 그 특수 토큰 위치를 임베딩
469 수준에서 RSP로 교체한다.

470 ChatML (Qwen Instruct / Base + ChatML).

```
<|im_start|>system
Please reason step by step, and put your final answer within \boxed{<|im_end|>
<|im_start|>user
{question}

There are {L} special tokens that contain compressed latent reasoning
information that might be useful for your reasoning. If these tokens are
useful for your case, you can use them as reference. If these tokens are
not useful for your case, you can ignore them and focus back to solving the
problem.

Here are the {L} special tokens: <special_token_1>...<special_token_L>
<|im_end|>
<|im_start|>assistant
```

472 LLaMA Chat Template.

```
<|begin_of_text|>
<|start_header_id|>system<|end_header_id|>
Cutting Knowledge Date: December 2023
Today Date: 26 Jul 2024
Please reason step by step, and put your final answer within \boxed{<|im_end|>
```



```

eot_id|>
<|start_header_id|>user<|end_header_id|>
{question}

There are {L} special tokens that contain compressed latent reasoning
information that might be useful for your reasoning. If these tokens are
useful for your case, you can use them as reference. If these tokens are
not useful for your case, you can ignore them and focus back to solving the
problem.

Here are the {L} special tokens:
<reserved_special_token_0>...
<reserved_special_token_L>
<|eot_id|>
<|start_header_id|>assistant<|end_header_id|>

```

474

475 Raw Text (Qwen Base).

```

{question}

There are {L} special tokens that contain compressed latent reasoning
information that might be useful for your reasoning. If these tokens are
useful for your case, you can use them as reference. If these tokens are
not useful for your case, you can ignore them and focus back to solving the
problem.

Here are the {L} special tokens: <special_token_1>...<special_token_L>
Please reason step by step, and put your final answer within \boxed{ }.

```

476

477 A.1.3 Suffix

478 채팅 템플릿 모델에서는 end-of-turn 토큰 바로 앞에 RSP 임베딩을 넣고, raw text 모델에서는
479 프롬프트 마지막에 RSP 임베딩을 이어 붙인다.

480 ChatML (Qwen Instruct / Base + ChatML).

```

<|im_start|>system
Please reason step by step, and put your final answer within \boxed{ }.<|
im_end|>
<|im_start|>user
{question}[Random Embeddings (L tokens)]<|im_end|>
<|im_start|>assistant

```

481

482 LLaMA Chat Template.

```

<|begin_of_text|>
<|start_header_id|>system<|end_header_id|>
Cutting Knowledge Date: December 2023
Today Date: 26 Jul 2024
Please reason step by step, and put your final answer within \boxed{ }.<|
eot_id|>
<|start_header_id|>user<|end_header_id|>
{question}[Random Embeddings (L tokens)]<|eot_id|>
<|start_header_id|>assistant<|end_header_id|>

```

483

484 Raw Text (Qwen Base).

```

{question}
Please reason step by step, and put your final answer within \boxed{ }.[Random
Embeddings (L tokens)]

```

485

486 A.2 정답 추출과 채점

487 최종 정답은 fallback 체인을 통해 모델 출력에서 추출한다. 각 단계는 순서대로 시도하며, 추출에
488 실패하면 다음 단계로 넘어간다.

정답 추출 fallback 체인

1. "final answer is \$...\$. I hope" 패턴 (Minerva 형식)
2. `\boxed{...}`: 마지막 비어 있지 않은 box를 사용하고, 빈 `\boxed{}`는 건너뛰
3. "the answer is" 뒤 텍스트
4. "final answer is" 뒤 텍스트
5. 출력 마지막 숫자(regex fallback)

489

490 추출된 정답은 `$`, `\left`, `\right`, 단위 문자열을 제거해 정규화한다. 채점은 sym-
491 bolic equivalence checking으로 수행하며, 정확한 문자열 일치, 수치 비교(`math.isclose`,
492 `rel_tol=1e-4`), SymPy symbolic simplification을 차례로 적용한다.

493 A.3 재현한 선행연구의 하이퍼파라미터

494 모든 선행 방법은 Qwen2.5-Math-1.5B-Instruct와 Qwen2.5-Math-7B-Instruct에서 재현했으며,
495 greedy decoding(`temperature = 0`)과 통일된 answer extraction pipeline으로 평가했다.

496 **TTSV.** Prefix 길이는 20이며, AdamW optimizer로 20 epoch 동안 학습했다. 배치 크기는 2,
497 gradient accumulation은 8 step, 스케줄은 선형 learning rate schedule을 사용했다. Learning rate
498 는 Qwen-1.5B에 $1e-3$, Qwen-7B에 $1e-5$ 를 사용했다.

499 **LTPO.** Table 8는 벤치마크별 하이퍼파라미터를 정리한 것이다.

Table 8: LTPO 하이퍼파라미터.

Parameter	GSM8K	MATH-500	AIME24
tokens	8	8	8
steps	20	20	20
top_k	10	10	10
sigma	20	20	5
sigma_decay	0.95	0.95	0.95
lr	$1e-2$	$5e-3$	$5e-2$

500 **SoftCoT.** Projection module은 10 epoch 동안 학습했다. Thought token 수는 학습 시 32, 평가 시
501 4다. 배치 크기는 GSM8K에서 4, MATH에서는 1이며 gradient accumulation 4를 사용했다. 작은
502 모델(assistant)은 두 설정 모두 Qwen2.5-Math-1.5B-Instruct이고, 큰 모델은 Qwen2.5-Math-1.5B-
503 Instruct(`learning rate 2e-5`) 또는 Qwen2.5-Math-7B-Instruct(`learning rate 5e-6`)이다. MATH-500
504 과 AIME24 평가는 GSM8K에서 학습한 projection module을 사용했는데, MATH에서 학습한
505 버전보다 더 높은 정확도를 보였기 때문이다.

506 A.4 전체 엔트로피 곡선

507 Figure 5는 entropy, top-1 probability, varentropy의 전체 정규화 생성 궤적(0-100%)을 보여준다.
508 모든 방법은 생성 초반 단계를 지나면 비슷한 수준으로 수렴하며, 이는 RSP가 유도하는 분포
509 변화가 초기 추론 단계에 국소화되어 있음을 다시 확인해 준다.




Figure 5: 전체 정규화 생성 궤적(0-100%)에서의 평균 entropy(위), top-1 probability(가운데), varentropy(아래). MATH-500 전체 평균이며, 음영은 ± 1 SEM을 뜻한다. 실선은 RSP 변형과 baseline, 점선은 기존 soft prompt 방법이다. 모든 방법은 초반 단계를 지나면 수렴한다.

510 B 의미적 다양성에 대한 추가 분석

511 이 부록은 Section 4.4에서 보고한 의미적 다양성 결과를 보충한다. 더 넓은 문제 집합에 대해
512 문제별 t-SNE 도표를 함께 제시한다.



Figure 6: 평가한 64개 MATH-500 문제 중 48개에 대한 BGE-M3 임베딩의 t-SNE 투영(6×8 격자). 각 subplot은 Qwen2.5-Math-1.5B-Instruct에서 $\tau = 1.0$ 으로 생성한 baseline 300개(빨강)와 RSP suffix 300개(파랑)를 보여준다. 채워진 표식은 정답, 빈 표식은 오답이며, 제목은 subject/problem_id를 뜻한다. 대부분의 문제에서 RSP 궤적은 여러 개의 분리된 영역으로 퍼지는 반면, baseline 샘플은 하나의 지배적 클러스터에 더 집중된다.

513 C 토큰 수준 분포 지표

514 이 부록은 Section 4.4의 토큰 수준 분석에 사용한 세 지표를 형식적으로 정의한다. P_{base} 는
515 $\tau = 1.0$ 에서의 baseline 다음 토큰 분포, P_{target} 은 비교 대상 분포(예: $\tau = 2.0$ 의 baseline, 또는
516 $\tau = 1.0$ 의 RSP)라 하자. 모든 지표는 첫 생성 단계에서 저장한 logits로부터 해석적으로 계산
517 한다.

518 **Spearman 순위 상관.** Spearman의 ρ 는 두 분포의 토큰 순위 사이 Pearson 상관계수다.

$$\rho = \text{Pearson}(\text{rank}(P_{\text{target}}), \text{rank}(P_{\text{base}})). \quad (4)$$

519 Temperature scaling $P^{(\tau)} \propto P^{1/\tau}$ 는 엄격한 단조 변환이므로, 어떤 $\tau > 0$ 에서도 토큰 순서를
520 정확히 보존한다. 따라서 $\rho = 1$ 은 수학적 항등식이다. 그러므로 $\rho < 1$ 은 temperature scaling
521 만으로는 만들 수 없는 순위 재조작이 일어났음을 뜻한다.

522 **Top- K 밖의 질량.** $\text{TopK}(P_{\text{base}})$ 를 P_{base} 에서 확률이 가장 높은 K 개 토큰의 집합이라 하자. 비
523 교 대상 분포가 이 집합 *밖에* 두는 확률 질량은

$$\text{MassOutside}_K = 1 - \sum_{t \in \text{TopK}(P_{\text{base}})} P_{\text{target}}(t). \quad (5)$$

524 이 지표는 지지 집합 확장을 직접 측정한다. 즉 baseline의 선호 집합에 없던 토큰에 비교 대상이
525 얼마나 많은 확률을 배정하는지를 본다. 본문에 보고한 값은 $K = 10$ 을 사용했다.

526 **Jensen–Shannon divergence.** Kullback–Leibler divergence의 대칭적이고 bounded된 형태는 다
527 음과 같다.

$$\text{JS}(P, Q) = \frac{1}{2} \text{KL}(P \parallel M) + \frac{1}{2} \text{KL}(Q \parallel M), \quad M = \frac{1}{2}(P + Q). \quad (6)$$

528 로그는 밑이 2이므로 $\text{JS} \in [0, 1]$ 이다. 저장한 top-100 바깥의 토큰에는 softmax 전에 sentinel
529 $\text{logit}(-10^9)$ 을 넣었는데, 본 설정에서는 top-5가 이미 확률 질량의 99.9% 이상을 덮기 때문에 이
530 근사는 무시 가능하다.

531 D 무작위 프롬프트는 왜 의미적으로 중립적이고 방향적으로 포괄적인가

532 이 부록은 Section 3.4에서 사용한 주장을 형식화한다. 핵심은 무작위 프롬프트가 유용한 잠재
533 의미를 담고 있다는 것이 아니다. 더 약하고 정확한 주장은, 중심화한 뒤에는 어떤 미리 정한
534 의미 방향도 체계적으로 편들지 않으면서도, 고정된 분산 예산 아래 모든 방향을 덮을 수 있다는
535 것이다. 이는 언어학적 의미가 완전히 사라진다는 주장이 아니라, 섭동 방향의 기하학적 성질에
536 관한 명제다.

537 D.1 의미적 중립성

538 $\bar{h} \sim \mathcal{N}(0, \sigma^2 \mathbf{I}_d)$ 라 하고, $\bar{h} \neq 0$ 일 때 $\hat{h} := \bar{h}/\|\bar{h}\|$ 라 하자. 또한 $u_1, \dots, u_M \in \mathbb{S}^{d-1}$ 를 의미
539 anchor 방향을 나타내는 임의의 고정 단위벡터라 하자.

540 **보조정리 1** (의미적 중립성). 보편 상수 C 가 존재하여, 모든 $\delta \in (0, 1)$ 에 대해

$$\Pr \left[\max_{r \in [M]} |\hat{h}^\top u_r| \leq C \sqrt{\frac{\log(M/\delta)}{d}} \right] \geq 1 - \delta.$$

541 즉 등방성 가우시안 프롬프트의 정규화된 방향은, 고정된 유한 개의 의미 anchor 전체에 대해
542 높은 확률로 거의 직교한다.

543 *Proof.* 각 고정 u_r 에 대해 회전 불변성으로부터 $u_r^\top \bar{h} \sim \mathcal{N}(0, \sigma^2)$ 가 성립하므로,

$$\Pr(|u_r^\top \bar{h}| \geq t) \leq 2 \exp\left(-\frac{t^2}{2\sigma^2}\right).$$

544 $r \in [M]$ 전체에 대해 union bound를 적용하면

$$\Pr \left[\max_{r \in [M]} |u_r^\top \bar{h}| \geq t \right] \leq 2M \exp\left(-\frac{t^2}{2\sigma^2}\right).$$

545 한편 표준 chi-square concentration으로부터 보편 상수 $c > 0$ 가 존재하여

$$\Pr \left[\|\bar{h}\| \leq \frac{\sigma\sqrt{d}}{2} \right] \leq \exp(-cd)$$

546 가 성립한다. 사건 $\|\bar{h}\| \geq \sigma\sqrt{d}/2$ 위에서는

$$|\hat{h}^\top u_r| = \frac{|u_r^\top \bar{h}|}{\|\bar{h}\|} \leq \frac{2|u_r^\top \bar{h}|}{\sigma\sqrt{d}}.$$

547 이제

$$t = C' \sigma \sqrt{\log(M/\delta)}$$

548 로 두고 C' 를 충분히 큰 상수로 잡으면, 두 bound를 결합해

$$\max_{r \in [M]} |\hat{h}^\top u_r| \leq C \sqrt{\frac{\log(M/\delta)}{d}}$$

549 가 적어도 $1 - \delta$ 확률로 성립한다. □

550 토큰 임베딩과의 대비는 즉각적이다. $e_s \neq 0$ 를 고정된 토큰 임베딩이라 하고 $\hat{e}_s := e_s/\|e_s\|$ 라
551 하자. 이때 anchor 방향을 $u = \hat{e}_s$ 로 잡으면

$$|\hat{e}_s^\top u| = 1.$$

552 즉 토큰 프롬프트는 적어도 하나의 의미 방향과 최대 정렬을 이루지만, 등방성 무작위 프롬프트
553 는 어떤 고정된 유한 집합의 의미 방향에도 거의 직교한다. 우리가 말하는 “의미적 비개입성”은
554 바로 이 뜻이다. 토큰은 의미적 commitment를 주입하는 반면, 무작위 프롬프트는 의미적으로
555 특정 방향에 묶이지 않은 섭동으로 기능한다.

556 D.2 Theorem 2 (미니맥스 방향 커버리지)의 증명

557 본문에서 사용한 local linear logit surrogate에 직접 등장하는 양은 단위벡터 b 에 대해 b 방향의
 558 1차 섭동 에너지 $\text{Var}_{h \sim D}(b^\top h) = b^\top \Sigma_D b$ 이다. $\min_{\|b\|=1} b^\top \Sigma_D b = \lambda_{\min}(\Sigma_D)$ 이므로 최소 방향
 559 분산은 정확히 $\lambda_{\min}(\Sigma_D)$ 이다.

560 *Theorem 2의 증명.* Σ_D 의 고윳값을 $\lambda_1, \dots, \lambda_d$ 라 하면,

$$\lambda_{\min}(\Sigma_D) \leq \frac{1}{d} \sum_{m=1}^d \lambda_m = \frac{\text{tr}(\Sigma_D)}{d} \leq \frac{\rho^2}{d}.$$

561 모든 고윳값이 같을 때, 즉 $\Sigma_D = (\rho^2/d)\mathbf{I}_d$ 일 때 그리고 그럴 때만 등호가 성립한다. $\square$

562 이 정리는 등방성 무작위성의 장점을 형식화한다. RSP는 어떤 logit-sensitive 방향을 섭동해야
 563 하는지 사전에 알지 못하므로, 고정된 분산 예산 아래에서 등방성 분포는 모든 방향에 대한
 564 최악 경우 섭동량을 유일하게 최대화한다. 고정 토큰 프롬프트는 결정적 섭동이므로 $\Sigma_D = 0$
 565 이고 $\lambda_{\min} = 0$ 이며, 비등방 섭동은 항상 $\lambda_{\min}(\Sigma_D) < \rho^2/d$ 이므로 적어도 한 방향에서 등방
 566 최적해보다 덜 탐색하게 된다.

E 본문 이론 결과의 증명

E.1 RSP가 유도하는 섭동의 성질

본문 Eq. (2)의 분해 $\mathbf{x}_i^{(\ell+1)} = (1 - w_{r,i}^{(\ell)})\tilde{\mathbf{x}}_i^{(\ell+1)} + \boldsymbol{\eta}_i^{(\ell)}$ 에서 무작위 기여 항 $\boldsymbol{\eta}_i^{(\ell)} = \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{r_j}^{(\ell)}$ 의 통계적 성질을 분석한다. 입력층의 RSP는 등방 가우시안이지만, layer ℓ 에서의 value vector $\mathbf{v}_{r_j}^{(\ell)}$ 는 attention, residual, LayerNorm, FFN, value projection을 차례로 통과한 결과이므로 일반적으로 등방 가우시안이 아니다. 따라서 layer 이후의 분석은 *bounded second moment*만 가정한 형태로 약화하는 것이 안전하다.

조건부 기댓값과 상계. 입력층 statistics에 의해 layer-별 mean · norm을

$$m_v^{(\ell)} := \max_j \|\mathbb{E}[\mathbf{v}_{r_j}^{(\ell)}]\|, \quad M_v^{(\ell)} := \max_j \mathbb{E}\|\mathbf{v}_{r_j}^{(\ell)}\|^2 < \infty$$

라 두자(유한성은 implementation-side 가정으로 자연스럽다). 어텐션 가중치에 조건부로 두면

$$\|\mathbb{E}[\boldsymbol{\eta}_i^{(\ell)} \mid \alpha^{(\ell)}]\| \leq w_{r,i}^{(\ell)} m_v^{(\ell)}. \quad (7)$$

입력층($\ell = 0$)에서는 등방 RSP에 대해 $m_v^{(0)} = |\mu_E|$ 이며, 항별 평균이 0에 가까운 임베딩 행렬에서 작아진다 — Table 9 참조.

조건부 disturbance energy(Lyapunov-style upper bound). $V_{\eta,i}^{(\ell)} := \mathbb{E}\|\boldsymbol{\eta}_i^{(\ell)}\|^2$ 로 두면, Cauchy-Schwarz와 $\sum_j \alpha_{i,n+j}^{(\ell)} = w_{r,i}^{(\ell)}$ 에서

$$V_{\eta,i}^{(\ell)} \leq M_v^{(\ell)} (w_{r,i}^{(\ell)})^2. \quad (8)$$

이는 “RSP가 주입하는 disturbance energy의 상계가 w_r^2 로 통제된다”는 Lyapunov-style stability 진술이다 — 정확한 등방성을 layer 이후에도 가정할 필요 없이, value norm의 second moment 유한성만으로 충분하다.

시퀀스 방향 attenuation 결합. Theorem 1와 결합하면 같은 layer, 같은 query 위치, 같은 logit gap 아래에서 $w_{r,i}^{(\ell)} = O(1/n)$ 이고, Eq. (8)로부터 $V_{\eta,i}^{(\ell)} = O(1/n^2)$ 이다. layer 방향에 대한 단조 감소는 $M_v^{(\ell)}$, $\Delta_i^{(\ell)}$, hidden state geometry가 layer마다 달라지므로 일반적으로 보장되지 않는다 — 본문 Figure 1의 layer-축 감소는 이 정리의 직접 귀결이 아니라 deeper layer가 실제 토른 evidence에 더 정렬되는 별개의 경험적 현상이다.

입력층 등방성의 의의. 입력층에서는 RSP가 $\mathcal{N}(\mu_E \mathbf{1}_d, \sigma_E^2 \mathbf{I}_d)$ 로 정의되므로, 중심화한 $\bar{h}$ 는 정확히 등방이고 모든 방향에 양의 밀도(full support)를 갖는다. Lemma 1와 본문 §3.4의 결과는 이 입력층 등방성을 직접 사용하므로 layer 이후의 등방성 보존을 요구하지 않는다.

Table 9: 임베딩 행렬 통계. 모든 모델에서 $|\mu_E|/\sigma_E < 0.02$ 이다.

Model	μ_E	σ_E	$ \mu_E /\sigma_E$
LLaMA-3.1-8B-Instruct	0.00002	0.01057	0.002
Qwen2.5-Math-7B-Instruct	-0.00002	0.01647	0.001
Qwen2.5-Math-1.5B-Instruct	0.00019	0.01585	0.012
Qwen2.5-Math-7B	-0.00003	0.01842	0.001
Qwen2.5-Math-1.5B	0.00038	0.02990	0.013

합의. 입력층에서 RSP가 $\mathcal{N}(\mu_E \mathbf{1}_d, \sigma_E^2 \mathbf{I}_d)$ 로 시작하므로 입력층의 평균 항은 작지만, layer 이후의 $\mathbf{v}_{r_j}^{(\ell)}$ 는 일반적으로 *bounded mean*만 가정한다. Eq. (8)는 이 약한 가정 아래에서도 RSP 기여의 disturbance energy가 attention-local 수준에서 $w_{r,i}^{(\ell)}$ 로 통제됨을 보장한다 — 그 이상의 “zero-mean noise처럼 동작한다”라는 강한 주장은 입력층에 한정된 해석이다.

595 **E.2 Eq. (2) 도출, Theorem 1, Proposition 1의 증명**

596 **Eq. (2)의 도출.** 어텐션 출력 $\sum_{j=1}^{n+L} \alpha_{ij}^{(\ell)} \mathbf{v}_{ij}^{(\ell)}$ 를 실제 토큰 항과 RSP 토큰 항으로 가르고, 실제
597 항에서 정규화 인자 $1 - w_{r,i}^{(\ell)} = \sum_{j=1}^n \alpha_{ij}^{(\ell)}$ 를 묶어 내면 본문 Eq. (2)가 그대로 나온다. softmax
598 정규화 항등식 $\sum_{j=1}^{n+L} \alpha_{ij}^{(\ell)} = 1$ 외에는 어떤 근사도 사용하지 않는다.

599 **Theorem 1 (upper envelope)의 증명.** 실제 토큰과 RSP 토큰의 scaled attention score를 각각
600 $s_j^{(\ell)} := (\mathbf{q}_i^{(\ell)})^\top \mathbf{k}_j^{(\ell)} / \sqrt{d}$ ($j \in [n]$), $s_{r,j'}^{(\ell)} := (\mathbf{q}_i^{(\ell)})^\top \mathbf{k}_{r,j'}^{(\ell)} / \sqrt{d}$ ($j' \in [L]$)라 하고, $s_{r,\max}^{(\ell)} := \max_{j'} s_{r,j'}^{(\ell)}$,
601 $R^{(\ell)} := \sum_{j'=1}^L \exp(s_{r,j'}^{(\ell)})$ 로 둔다. 정방향 gap $\Delta_i^{(\ell)} / \sqrt{d}$ 의 정의에서 모든 $j \in [n]$ 에 대해 $s_j^{(\ell)} \geq$
602 $s_{r,\max}^{(\ell)} + \Delta_i^{(\ell)} / \sqrt{d}$ 이고, $\max \geq \text{avg}$ 에서 $\exp(s_{r,\max}^{(\ell)}) \geq R^{(\ell)} / L$ 이다. 따라서 $\sum_{j=1}^n \exp(s_j^{(\ell)}) \geq$
603 $n \exp(\Delta_i^{(\ell)} / \sqrt{d}) \cdot R^{(\ell)} / L$ 이고, softmax 정규화에서 $w_{r,i}^{(\ell)} = R^{(\ell)} / (\sum_j \exp(s_j^{(\ell)}) + R^{(\ell)}) \leq L / (L +$
604 $n \exp(\Delta_i^{(\ell)} / \sqrt{d}))$. $f(n) = L / (L + n \exp(\Delta_i^{(\ell)} / \sqrt{d}))$ 의 미분이 음수이므로 n 에 대해 엄격 감소
605 하고 $n \rightarrow \infty$ 에서 0으로 간다.

606 **Proposition 1 (lower envelope)의 증명.** 대칭 도출이다. 역방향 gap $\Delta_i'^{(\ell)} / \sqrt{d}$ 의 정의에서 모
607 든 $j \in [n]$ 에 대해 $s_j^{(\ell)} \leq s_{r,\min}^{(\ell)} + \Delta_i'^{(\ell)} / \sqrt{d}$ 이며, $\min \leq \text{avg}$ 에서 $\exp(s_{r,\min}^{(\ell)}) \leq R^{(\ell)} / L$ 이다.
608 따라서 $\sum_{j=1}^n \exp(s_j^{(\ell)}) \leq n \exp(\Delta_i'^{(\ell)} / \sqrt{d}) \cdot R^{(\ell)} / L$ 이고, $w_{r,i}^{(\ell)} = R^{(\ell)} / (\sum_j \exp(s_j^{(\ell)}) + R^{(\ell)}) \geq$
609 $L / (L + n \exp(\Delta_i'^{(\ell)} / \sqrt{d}))$.

610 **E.3 Theorem 1의 따름정리들**

611 위 envelope들로부터 두 가지 따름정리가 따른다.

612 **따름정리 1** (fixed-gap envelope의 시퀀스 방향 단조 감소). L 과 $\Delta_i^{(\ell)}$ 를 고정하면, 상계

$$f(n) = \frac{L}{L + n \exp(\Delta_i^{(\ell)} / \sqrt{d})}$$

613 는 실제 토큰 수 n 에 대해 엄격히 감소한다. 따라서 동일한 logit gap을 유지한다는 가정 아래,
614 cache 성장만으로 그 gap과 양립 가능한 최대 RSP attention mass의 envelope이 단조롭게 줄어든
615 다.

616 자기회귀 디코딩에서는 새 토큰이 생성될 때마다 query · key · hidden state가 갱신되어 $\Delta_i^{(\ell)}$ 도
617 step별로 변하므로, “실현된 attention mass가 매 step 단조 감소한다”가 아니라 “동일한 gap이
618 유지되는 한 가능한 최대 mass의 envelope이 단조 감소한다”가 정확한 진술이다.

619 *Proof.* $f(n)$ 을 n 에 대해 미분하면

$$f'(n) = -\frac{L \exp(\Delta_i^{(\ell)} / \sqrt{d})}{\left(L + n \exp(\Delta_i^{(\ell)} / \sqrt{d})\right)^2} < 0.$$

620 따라서 $f(n)$ 은 엄격히 감소한다. □

621 **따름정리 2** (고정 gap envelope 아래의 disturbance energy 감쇠). L 과 $\Delta_i^{(\ell)}$ 를 고정하고 $n \rightarrow \infty$
622 이면 $w_{r,i}^{(\ell)} \rightarrow 0$ 이다. 본 절의 약화된 가정 하에서 attention-local disturbance energy는 다음과
623 같이 줄어진다.

$$\|\mathbb{E}[\boldsymbol{\eta}_i^{(\ell)} \mid \alpha^{(\ell)}]\| \leq m_v^{(\ell)} w_{r,i}^{(\ell)} \rightarrow 0, \quad V_{\eta,i}^{(\ell)} \leq M_v^{(\ell)} (w_{r,i}^{(\ell)})^2 \rightarrow 0.$$

624 *Proof.* Corollary 1에서 $w_{r,i}^{(\ell)} \rightarrow 0$ 이고, 본 절의 평균 · second-moment 상계 $m_v^{(\ell)}, M_v^{(\ell)} < \infty$ 를
625 곱하면 결과가 따른다. □

626 E.4 출력 분포 이동에 대한 증명

627 본문 §3.4는 surrogate 위 top- K 진입 명제 (Proposition 5)와 다중 경로 Pass@ N 누적 명제 (Propo-
628 sition 6)를 다룬다. 보조적으로 쌍대 순위 무작위화 명제도 함께 둔다.

629 E.4.1 자기회귀 정식화

630 자기회귀 decoding에서 시퀀스 $y_{1:T}$ 의 결합 분포는

$$\Pr(y_{1:T} \mid x) = \prod_{t=1}^T p(y_t \mid x, y_{<t}),$$

631 로 분해된다. 각 단계는 prefix에 조건부인 분포로 결정되므로, RSP가 도입한 섭동은 단일한
632 전역 분포를 한 번에 바꾸는 것이 아니라 $p(y_t \mid x, y_{<t})$ 에 대한 일련의 국소 변화로 작동한다.

633 E.4.2 RSP 하에서의 logits 국소 선형화

634 중심화된 random soft prompt를 $\bar{h}$ 라 하자. 섭동된 logits를 $\bar{h}$ 의 함수로 보고 $\bar{h} = 0$ 근방에서 국소
635 smoothness를 가정하면 $z_i(\bar{h}) = z_i + a_i^\top \bar{h} + O(\|\bar{h}\|^2)$ 이며, 여기서 $a_i := \nabla_{\bar{h}} z_i(0)$ 이다. 본문
636 §3.4와 같은 표기로 l 차 surrogate를 $z_i^{\text{lin}}(\bar{h}) := z_i + a_i^\top \bar{h}$ 로 정의한다. 이 surrogate는 충분히 작은
637 $\|\bar{h}\|$ 에서 유효하며, transformer logits의 전역 모델이라기보다 섭동 방향을 설명하는 1차 근사다.

638 E.4.3 명제 1의 증명 (확률적 순위화)

639 **명제 4** (확률적 순위화). 토큰 쌍 (i, j) 중 $a_i \neq a_j$ 인 것이 존재하면, $0 < \Pr_{\bar{h}}(z_i^{\text{lin}}(\bar{h}) > z_j^{\text{lin}}(\bar{h})) <$
640 1 이 성립한다.

641 *Proof.* $z_i^{\text{lin}}(\bar{h}) - z_j^{\text{lin}}(\bar{h}) = (z_i - z_j) + (a_i - a_j)^\top \bar{h}$ 이고, $b_{ij} := a_i - a_j \neq 0$ 이며 $\bar{h} \sim \mathcal{N}(0, \sigma^2 I)$
642 이면 $b_{ij}^\top \bar{h} \sim \mathcal{N}(0, \sigma^2 \|b_{ij}\|^2)$ 인 비퇴화 가우시안이다. 따라서 섭동된 logit 차이는 0의 양쪽에
643 모두 양의 확률 질량을 갖고, $0 < \Pr_{\bar{h}}(z_i^{\text{lin}}(\bar{h}) > z_j^{\text{lin}}(\bar{h})) < 1$ 이 성립한다. $\square$

644 E.4.4 명제 2의 증명 (지지 집합 확장)

645 **명제 5** (지지 집합 확장). 어떤 토큰 i 에 대해 진입 영역

$$\mathcal{G}_{i,K} := \{\bar{h} \in \mathbb{R}^d : \#\{j \neq i : z_j^{\text{lin}}(\bar{h}) > z_i^{\text{lin}}(\bar{h})\} \leq K - 1\}$$

646 이 비공집합 열린집합을 포함한다고 하자. centered RSP $\bar{h}$ 가 등방 가우시안에서 추출되면
647 $\Pr_{\bar{h}}(\bar{h} \in \mathcal{G}_{i,K}) > 0$ 이 성립한다.

648 *Proof.* $\mathcal{G}_{i,K}$ 가 비공집합 열린집합 U 를 포함한다고 하자. centered 등방 가우시안은 $\mathbb{R}^d$ 전역에서
649 엄밀히 양수인 밀도를 가지므로 모든 비공집합 열린집합에 양의 확률 측도를 부여한다. 따라서
650 $\Pr_{\bar{h}}(\bar{h} \in \mathcal{G}_{i,K}) \geq \Pr_{\bar{h}}(\bar{h} \in U) > 0$ 이다. 정의상 $\mathcal{G}_{i,K}$ 는 정확히 surrogate logit이 i 를 top- K 로
651 진입시키는 사건이다.

652 (충분조건 예시.) i 가 어떤 baseline top- K 부분집합 $S \subseteq J_K(s_t)$ ($|S| = K$)의 모든 원소를 엄격한
653 마진으로 앞서는 $\bar{h}_0$ 가 존재하면, surrogate의 연속성으로 $\bar{h}_0$ 주변 비공집합 열린집합이 $\mathcal{G}_{i,K}$ 에
654 포함된다 (각 부등식이 열린 half-space를 정의). $\square$

655 E.4.5 궤적 수준의 합의: 다중 경로 Pass@ N

656 자기회귀 생성은 조건부 분포를 단계별로 합성하므로, 초기 단계의 섭동이 전혀 다른 궤적으로
657 이어질 수 있다. 적어도 한 번 baseline top- K 바깥 토큰을 포함하는 궤적의 집합을 $\mathcal{R}_{L,K}(x)$
658 라 하자. 만약 RSP가 초기 단계에서 이런 토큰의 접근 가능성을 높인다면, 반복 샘플링에서
659 $\mathcal{R}_{L,K}(x)$ 에 속하는 궤적을 뽑을 확률도 증가한다. 핵심은 시간적 누적이다. 초반의 top- K 진입
660 한 번이 다음 decoding state를 바꾸고, 그것이 다시 다음 후보 집합을 바꾸는 식으로 이어진다.
661 이를 형식적으로 모으면 다음 명제가 된다.

662 **명제 6** (다중 경로 Pass@N). 문제 x 를 고정하고 정답 궤적 집합 $\mathcal{T}^*(x)$ 가 비어 있지 않다고 하자.
 663 *baseline* 정답 지시자를 $p_{\text{base}}(x) \in \{0, 1\}$ 이라 하고, N 개의 독립적이고 새로운 RSP를 추첨하여
 664 표본당 한 번씩 디코딩한다. (M1) 각 n 에 대해, n 번째 RSP 실행이 $\mathcal{T}^*(x)$ 의 궤적을 만들 주변
 665 확률이 적어도 $p_{\min}(x) > 0$ 이고, (M2) N 번의 RSP 실행이 상호 독립이라 가정하자. 그러면

$$\Pr(\text{Pass@N on } x) \geq 1 - (1 - p_{\min}(x))^N \geq 1 - \exp(-Np_{\min}(x)).$$

666 증명은 (M2)에 의한 곱 분해와 (M1)에 의한 단조 하한으로 곧바로 이루어진다. (M1)은 과제
 667 측 가정이며 메커니즘만으로는 유도되지 않는다. 본문 §4.4에서 이 가정의 경험적 흔적을 논의
 668 했다.

669 F Attention Mass 분석

670 이 부록은 Figure 1에 보고한 per-token attention mass를 형식화하고, reasoning span과 layer 축에
 671 적용한 제외 기준을 명시한다. 500개의 MATH-500 문제 각각에 대해 새로운 $\text{RSP } \mathbf{H} \in \mathbb{R}^{L \times d}$ 를
 672 $L = 10$ 으로 독립 샘플링했으므로, 보고한 heatmap은 문제 자체의 변동성과 RSP 벡터 변동성을
 673 함께 평균한 결과다.

674 F.1 토큰당 attention 질량

675 각 문제에서 attention은 연결된 시퀀스 [prompt; $\mathbf{H}$; generation] 위에서 측정하며, generation은
 676 같은 모델이 동일한 RSP 주입 설정 아래 생성한 궤적이다. $\alpha_{i,j}^{(\ell,h)}$ 를 layer ℓ , head h 에서 query
 677 위치 i 가 key 위치 j 로 보내는 post-softmax attention weight라고 하자. 이는 causal mask 아래에서
 678 $\sum_j \alpha_{i,j}^{(\ell,h)} = 1$ 을 만족한다. 질문 토큰과 RSP 토큰의 인덱스 집합을 각각 Q , R 라 하고 크기를
 679 $|Q|$, $|R| = L$, head 수를 H 라 하자. 이때 query i 가 각 그룹으로 보내는 layer ℓ 의 per-token
 680 attention mass는

$$\text{PTM}_Q[\ell, i] = \frac{1}{|Q|H} \sum_{h=1}^H \sum_{j \in Q} \alpha_{i,j}^{(\ell,h)}, \quad \text{PTM}_R[\ell, i] = \frac{1}{|R|H} \sum_{h=1}^H \sum_{j \in R} \alpha_{i,j}^{(\ell,h)}. \quad (9)$$

681 $|Q|$ 와 $|R|$ 로 나누는 정규화는 집합 크기 차이를 보정하므로, 두 양은 동일한 softmax 분모 아래
 682 에서 질문 토큰 또는 RSP 토큰 하나가 평균적으로 얼마나 많은 attention을 받는지를 나타낸다.
 683 따라서 질문 토큰은 시퀀스 길이 효과를 흡수하는 크기 보정 baseline 역할을 한다.

684 F.2 Heatmap 집계

685 Layer 인덱스와 reasoning position 인덱스를 각각 동일 크기의 다섯 구간 $\{B_L^{(b)}\}_{b=1}^5$, $\{B_P^{(b)}\}_{b=1}^5$
 686 로 나눈다. 샘플 s 와 목표 집합 $\bullet \in \{Q, R\}$ 에 대해 셀 (b_L, b_P) 의 값은

$$M_{\bullet}^{(s)}[b_L, b_P] = \frac{1}{|B_L^{(b_L)}| \cdot |B_P^{(b_P)}|} \sum_{\ell \in B_L^{(b_L)}} \sum_{i \in B_P^{(b_P)}} \text{PTM}_{\bullet}[\ell, i]. \quad (10)$$

687 Figure 1는 Eq. (10)를 500개의 유효 샘플에 대해 평균한 결과를 보고한다.

688 F.3 \boxed{\dots} 구간 제외

689 Reasoning position 범위는 마지막 \boxed{\dots} 구간이 시작되기 직전에 끝나도록 잡는다.
 690 Chain-of-thought 출력은 *text*(내용)와 *pattern*(형식) 성분으로 나뉘며, 이 둘은 downstream 성
 691 능에 독립적으로 기여할 수 있다 [Madaan and Yazdanbakhsh, 2022]. \boxed{\dots} 래퍼는 전형
 692 적인 pattern 성분이다. 이는 추론을 더 전개하기보다는 답 형식을 마무리하는 짧고 정형화된
 693 span이기 때문이다. 이 구간을 포함하면 reasoning dynamics와 무관한 template-driven attention
 694 signature가 섞이게 된다.

695 F.4 마지막 두 레이어 제외

696 Layer 축에서는 마지막 두 transformer layer도 제외한다. 이는 우리 설정에만 특수한 것이 아니라,
 697 late layer의 두 가지 잘 알려진 성질에서 비롯된다.

698 **출력 투영 특화.** 마지막 레이어 근방의 hidden state는 vocabulary logits와 거의 선형 관계를 이
 699 루므로, 표현을 바꾸는 블록이라기보다 점진적 선형 readout으로 기능한다 [Belrose et al., 2023].
 700 같은 맥락에서 late-layer feed-forward module도 출력 분포를 조정하는 메커니즘으로 해석되어
 701 왔다 [Geva et al., 2021]. 따라서 이 레이어들의 attention은 reasoning computation보다 output
 702 formation을 더 강하게 반영한다.

703 **Register-token 가설.** Vision Transformer에서 정보가 거의 없는 patch token은 deeper layer에서
 704 attention을 흡수하는 *register*로 재활용될 수 있음이 알려져 있다 [Darcet et al., 2024]. RSP 역시
 705 사전학습된 의미를 갖지 않는 연속 토큰이라는 점에서 유사한 성질을 가지므로, late transformer

layer에서 비슷한 재활용이 일어날 가능성을 배제할 수 없다. 마지막 두 레이어를 제외하면 이런 register 유도 교란이 reasoning-phase 신호를 오염시키는 일을 막을 수 있다.

위의 두 근거는 late layer에서 나타나는 잘 알려진 현상, 즉 선형 readout과 잠재적 register 재활용이 reasoning-phase dynamics와 직교하는 attention signature를 만들 수 있음을 뜻한다. 마지막 두 레이어를 제거하는 것은 모델 특이적 tuning이 아니라 문헌에 근거한 원칙적 제외에 해당하며, 본문에서 강조한 시퀀스 방향(*autoregressive position*) attenuation은 이 제외 없이 모든 레이어를 포함했을 때에도 동일하게 관찰된다 — Theorem 1이 직접 보장하는 것은 sequence-direction attenuation이지 layer-direction monotonicity가 아니므로, 마지막 두 레이어를 포함시키더라도 본문 claim에 변화는 없다.

F.5 추가적인 suffix heatmap

Figure 7는 suffix 주입에서 Qwen2.5-Math-1.5B-Instruct와 LLaMA-3.1-8B-Instruct에 대해 동일한 per-token RSP attention 분석을 보고한다. 앞서 설명한 late-layer 이유 때문에 모든 셀에서 패턴이 완전히 동일하게 일반화되지는 않지만, 두 모델 모두에서 시퀀스 방향(가로축)의 단조 감소는 §3.3의 cache-growth upper envelope가 예측한 것과 일치한다. layer 축(세로)의 추가 감소는 별개의 경험적 sharpening 현상으로, Theorem 1만으로 직접 따라오는 결과는 아니다.




Figure 7: 나머지 두 모델(각각 500개 MATH-500 샘플)에서 suffix 주입 시 측정된 per-token RSP attention mass. 축과 전처리는 Figure 1와 동일하다. x축은 다섯 분위로 나눈 reasoning position, y축은 다섯 분위로 나눈 layer depth(위가 얇은 층), 색은 RSP 토큰에 할당된 per-token attention의 500샘플 평균을 뜻한다. `\boxed{ }` 구간 내부 토큰과 마지막 두 레이어는 제외했다.

721 G GRPO 정식화

722 주어진 프롬프트 q 에 대해, behavior policy $\pi_{\theta_{\text{old}}}$ 는 보상 $\{R_i\}_{i=1}^G$ 를 갖는 응답 집합 $\{o_i\}_{i=1}^G$ 를
723 샘플링한다. 각 응답의 advantage는 그룹 수준 보상을 정규화해 계산한다.

$$\hat{A}_{i,t} = \frac{R_i - \text{mean}(\{R_i\}_{i=1}^G)}{\text{std}(\{R_i\}_{i=1}^G)}. \quad (11)$$

724 정책은 KL penalty가 포함된 clipped objective로 업데이트한다.

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left(\min \left(r_{i,t} \hat{A}_{i,t}, \text{clip}(r_{i,t}, 1-\varepsilon, 1+\varepsilon) \hat{A}_{i,t} \right) - \beta D_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}}) \right) \right], \quad (12)$$

725 여기서 $r_{i,t} = \pi_{\theta}(o_{i,t} \mid q, o_{i,<t}) / \pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})$ 는 importance sampling ratio이고, ε 는 clipping
726 범위, β 는 reference policy π_{ref} 에 대한 KL penalty 세기를 조절한다.

727 H 광범위한 영향

728 본 연구는 무작위 임베딩 주입이 대형 언어 모델의 추론 행동에 어떤 영향을 주는지에 대한
729 실험적·이론적 분석을 제공한다. 기여의 성격은 주로 기초 연구에 가깝지만, GRPO와 같은
730 강화학습 기반 추론 모델 후속학습에는 잠재적 함의를 가진다.

731 **긍정적 영향.** RSP가 유도하는 궤적 다양성은 group-relative advantage estimation 안에서 더
732 풍부한 학습 신호를 제공함으로써, RL 기반 LLM 후속학습의 sample efficiency를 높일 수 있다.
733 이는 reasoning 중심 fine-tuning과 alignment에 필요한 계산 비용을 줄여, 자원이 제한된 연구
734 그룹에도 관련 방법을 더 접근 가능하게 만들 수 있다.

735 **잠재적 우려.** LLM의 유효 출력 지지 집합을 넓히는 방법은 바람직한 대안적 추론 경로뿐
736 아니라, 바람직하지 않거나 분포 밖에 있는 출력의 도달 가능성도 함께 높일 수 있다. 따라서
737 RSP를 실제 시스템에 적용할 때는 이를 독립적인 다양성 원천으로만 보지 말고, 기존의 안전
738 필터링 및 alignment 메커니즘과 함께 사용해야 한다.

739 **영향 범위의 한계.** 본 연구는 새로운 모델이나 데이터셋을 배포하기보다 분석을 제공하는 데
740 초점을 두므로, 직접적인 사회적 영향은 제한적이다. 여기서 논의한 더 넓은 함의는 RSP가 실제
741 학습 파이프라인에 통합되는 향후 연구가 이루어질 때에만 현실화될 수 있다.