

노이즈에서 다양성으로: 대형 언어 모델 추론에서의 무작위 임베딩 주입

Anonymous Author(s)

Affiliation

Address

email

Abstract

최근 *soft prompt* 연구는 학습으로 만든 특수 벡터를 입력에 끼워 넣어 추론 성능을 향상시키려 했다. 하지만, 효과의 출처가 학습된 의미 때문인지 주입한다는 행위 자체 때문인지는 깊이 연구되지 않았다. 본 논문은 학습 단계를 완전히 빼고 무작위로 뽑은 벡터들의 시퀀스를 입력 끝에 덧붙이는 Random Soft Prompt(RSP)를 분석한다. RSP는 사전학습 임베딩의 통계(평균·분산)에 맞춘 등방 가우시안에서 매 시도마다 새로 뽑힌 벡터로, 학습된 의미가 전혀 없는 데도 다섯 개 수학 벤치마크에서 학습된 *soft prompt*와 비등한 정확도를 낸다. 메커니즘은 두 단계로 작동한다. 처음 보는 무작위 위치를 어텐션이 받아내야 하므로 답의 첫 몇 토큰 분포가 평탄해져 추론 궤적이 갈라지고 (*branching*), 답이 길어질수록 그 영향은 자연스럽게 열려져 응답이 목표로 수렴한다 (*goal-directed convergence*). 우리는 RSP가 추론 과정에서 초반 토큰 다양성을 올리고 temperature와 결합하면 Pass@N(여러 시도 중 한 번이라도 맞출 확률)을 더 크게 넓힌다는 사실을 보여준다. 한편, 이 효과를 추론에 한정하지 않고 DAPO [Yu et al., 2025] 학습 단계로 확장해 실용적 적용 가능성을 보인다. 본 연구는 (i) 학습 없는 무작위 임베딩 주입만으로도 latent reasoning이 작동함을 새롭게 발견하고, (ii) 이론과 실험으로 그 메커니즘을 검증하며, (iii) 추론을 넘어 학습 과정까지 확장한다.

1 서론

대형 언어 모델(LLM)이 수십억 파라미터로 커지면서 전체 미세조정 비용은 빠르게 증가했고, 소수의 추가 파라미터만 도입해 적응시키는 parameter-efficient 방법이 주목받고 있다 [Hu et al., 2022, Houlsby et al., 2019]. 그중 *soft prompt*는 학습 가능한 연속 임베딩을 입력에 삽입해 attention을 통해 모델 행동을 조정한다 [Li and Liang, 2021, Lester et al., 2021]. 이 패러다임은 수학 추론 강화에도 활발히 쓰이며 [Kang et al., 2026, Xu et al., 2025, Ye et al., 2026, Hao et al., 2025, Zhang et al., 2026], 세부 설계는 달라도 모두 어휘 바깥 연속 임베딩을 최적화해 downstream 성능을 올린다는 공통 구조를 갖는다. 이러한 최적화는 과제별·데이터셋별로 이뤄지며, 기존 연구는 그 성능 이득을 임베딩의 학습된 값이 만들어 낸 결과로 해석해 왔다.

그러나 우리는 이 효과에 최적화가 필수가 아님을 관찰했다. 학습되지 않은 무작위 임베딩을 그대로 주입해도 일부 downstream task에서 성능 향상이 나타난다. 예를 들어 chat 형식으로 학습되지 않은 base model에 chat template을 적용하면 형식 불일치로 추론 성능이 크게 떨어지는데, 이때 무작위 임베딩을 덧붙이면 그 손실이 회복됐다. 단순 노이즈가 모델을 혼드는 데 그친다면 정확도는 더 나빠져야 한다. 따라서 학습된 의미와 무관하게 주입 자체가 모델 행동을 비자명하게 바꾼다. 기존 연구는 최종 정확도에만 집중해 주입과 최적화의 효과를 분리하지 못했고, 임베딩 주입이 출력 분포를 어떻게 바꾸는지는 충분히 탐구되지 않았다.

본 연구는 학습 없이 주입되는 Random Soft Prompt(RSP)가 LLM의 추론에 가지는 효과를 분석한다. RSP는 사전학습 임베딩의 항별 평균·분산에 맞춘 등방 가우시안에서 추출한 연속 벡터로, rollout마다 독립된 샘플을 공급해 더 넓은 탐색을 가능케 한다. 랜덤 입력의 탐색 개선




Figure 1: RSP가 유도하는 추론 궤적 다양성 개념도. 본 그림의 hidden state는 next-token 분포를 결정하는 마지막 layer의 출력이다. (a) 디코딩 초반: RSP 섭동이 *branching state*(빨강; §3.1에서 형식화)에 도달해 no-RSP baseline과 다른 top- K 를 만들고 다양한 출력 분포를 연다. (b) 디코딩 후반: KV 캐시가 자라며 RSP 어텐션 질량 상계가 좁아지고(Theorem 1), branching event는 드물어지며 hidden state(파랑)는 이미 열린 분기에 commit된다. (c) Rollout 사이에서 초반 RSP 섭동이 연 궤적들이 독립 경로로 누적돼 목표를 향한 완성형 응답으로 수렴한다.

37 효과는 특히 넓은 탐색이 필요한 추론 초반에 강하게 작용해 hidden state를 다양하게 *branching*
 38 시키다가, 추론 단계가 깊어질수록 안정화되어 목표를 향한 응답으로 수렴한다. 실험 결과 RSP
 39 는 초반 entropy를 높이고 temperature와 결합해 Pass@ N 다양성을 확장한다는 사실을 확인할
 40 수 있었다. RSP의 탐색 성능 향상 효과를 추론에만이 아닌 DAPO [Yu et al., 2025] 학습으로
 41 확장할 수 있다는 것까지 보인다. 이 지점에서 본 연구는 세 가지 기여를 가진다. 먼저, 학습
 42 없는 무작위 임베딩 주입만으로 latent reasoning 능력이 발현된다는 새로운 발견을 통해 기존
 43 soft prompt 효과의 일정 부분이 학습된 의미가 아니라 주입 자체에서 올 수 있음을 확인하였다.
 44 다음으로, 이론적 기반과 다양한 실험을 통해 그 메커니즘을 검증하였다. 마지막으로, 이러한
 45 효과를 추론만이 아닌 학습 과정에도 도입해 실용적 적용 가능성을 확인하였다.

46 2 배경

47 2.1 LLM 추론을 위한 Soft Prompt 기법

48 기존 *soft prompt* 계열은 모두 어휘 바깥 연속 임베딩을 과제별 목적함수로 최적화한다는 공통
 49 구조를 갖는다. 일반 fine-tuning 대안으로 Prefix-Tuning [Li and Liang, 2021], Prompt Tuning
 50 [Lester et al., 2021], P-tuning [Liu et al., 2024]이 학습 가능 연속 벡터로 미세조정에 근접한
 51 성능을 얻은 뒤, LLM 추론에 특화된 변형들이 빠르게 등장했다. TTSV [Kang et al., 2026]는
 52 테스트 시점에 prefix 임베딩을 궤적 엔트로피 최소화로 최적화하고, SoftCoT [Xu et al., 2025]
 53 는 assistant model이 만든 soft token으로 chain-of-thought를 대체하며, LTPO [Ye et al., 2026]는
 54 문제별로 soft prompt를 최적화해 그 문제에 대한 confidence를 최대화한다. COCONUT [Hao
 55 et al., 2025]은 은닉 상태를 입력으로 되먹이고, MemGen [Zhang et al., 2026]은 임베딩을 경험
 56 메모리로, Pause token [Goyal et al., 2024]은 학습 가능 토큰으로 추가 계산 단계를 마련한다. 그
 57 러나 일련의 연구들은 평가가 최종 정확도에 맞춰져 “주입 자체”와 “최적화”의 효과가 분리되지
 58 않으며, 단순 임베딩 주입이 모델 행동을 어떻게 바꾸는지는 미해결 문제다.

59 2.2 신경망에서의 노이즈 주입

60 신경망에 노이즈를 주입하는 방법은 학습·추론 시점뿐 아니라 주입 위치까지 다양한 층위에서
 61 연구돼 왔다. 학습 시점에서는 dropout [Srivastava et al., 2014]이 은닉 활성값을 무작위 비활성화
 62 하고, NEFTune [Jain et al., 2024]은 instruction fine-tuning 중 입력 임베딩에 가우시안 노이즈를
 63 더해 instruction following을 개선한다. 추론 시점에서는 randomized smoothing [Cohen et al.,
 64 2019]이 원시 입력에 가우시안 노이즈를 주입해 certified robustness를 얻고, SmoothLLM [Robey
 65 et al., 2025]은 이산 문자 수준의 변형으로 jailbreak를 방어한다. RL에서는 NoisyNet [Fortunato
 66 et al., 2018]이 네트워크 가중치에 학습되는 노이즈를 더해 탐색을 돕는다.

67 RSP는 임베딩에 노이즈를 덧붙이며, 세 가지 점에서 이러한 노이즈 주입 연구들과 구별된다. (1)
 68 학습 없이 추론 시점에만 동작해 모델 파라미터를 건드리지 않는다(dropout/NEFTune/NoisyNet
 69 과 다름). (2) 원래 입력을 보존한 채 한 번의 forward pass에 임베딩만 덧붙이며, 강건성 방법의

70 “여러 noisy pass + 집계”가 필요 없다. (3) 학습된 파라미터 없이 사전학습 임베딩 통계에서 직접
71 추출한 벡터를 그대로 쓴다(NoisyNet은 노이즈 파라미터를 학습).

72 3 Random Soft Prompt와 작동 원리

73 RSP는 hidden state에 직접 더해지지 않고 self-attention을 통해 들어간다. 한 attention head 안에
74 서 RSP의 즉각적 영향은 RSP 토큰들에 배정된 어텐션 질량 w 라는 단 하나의 스칼라로 환원되고,
75 이 질은 그 스칼라가 디코딩 동안 어떻게 변하는지를 추적한다. 디코딩 초반에는 이 양이 충분히
76 커서 hidden state를 여러 방향으로 분기시키고(§3.2), KV 캐시가 자라면 같은 스칼라의 상계가
77 자동으로 좁아져 응답이 목표로 수렴한다(§3.3). 무작위성의 역할은 임베딩 분포 모양이 아니라
78 rollout 사이에 독립 섭동을 공급해 매번 새로운 분기를 여는 데 있다. 본문에는 핵심 명제와
79 직관만 두고, 추가 증명은 Appendix D에 있다.

80 3.1 Random Soft Prompt

81 먼저 분석 대상부터 정리한다. 토큰 임베딩 행렬을 $\mathbf{W}_E \in \mathbb{R}^{V \times d}$ 로 두자(V 는 어휘 크기, d 는
82 은닉 차원). 그 행별 평균과 표준편차를 $\mu_E := \frac{1}{V \cdot d} \sum_{i,k} [\mathbf{W}_E]_{i,k}$ (모든 $V \cdot d$ 개 entry의 산술
83 평균), $\sigma_E := \text{std}(\mathbf{W}_E)$ 라 하자. 길이 L 의 RSP는 다음 분포에서 독립 추출한 연속 벡터 시퀀스
84 $\mathbf{H} = [h_1, \dots, h_L] \in \mathbb{R}^{L \times d}$ 이다.

$$h_j \sim \mathcal{N}(\mu_E \mathbf{1}_d, \sigma_E^2 \mathbf{I}_d), \quad j = 1, \dots, L. \quad (1)$$

85 중심화한 $\bar{h}_j := h_j - \mu_E \mathbf{1}_d \sim \mathcal{N}(0, \sigma_E^2 \mathbf{I}_d)$ 은 평균 0의 등방 가우시안이다. 입력 토큰 임베딩
86 시퀀스 $\mathbf{X} \in \mathbb{R}^{T \times d}$ (T 는 프롬프트 토큰 수, $\mathbf{X}$ 의 각 행은 $\mathbf{W}_E$ 의 해당 토큰 임베딩)를 두면, 본
87 문은 RSP를 그 뒤에 이어 붙이는 *suffix* 주입 $[\mathbf{X}; \mathbf{H}] \in \mathbb{R}^{(T+L) \times d}$ 를 기본 형태로 다루며, 다른
88 위치(prefix, infix [Kang et al., 2026, Xu et al., 2025, Ye et al., 2026, Zhang et al., 2026])는 §4.2와
89 Appendix A에서 ablation으로 보고한다. RSP는 학습 가능 파라미터가 아니므로 gradient를 받지
90 않으며, 매 rollout마다 새로 추출된다.

91 이후 분석은 한 가지 객체의 변화를 따라간다. 디코딩 step t 의 마지막 layer hidden state $\mathbf{s}^{(t)}$
92 이 만드는 top- K 가 RSP 미주입 baseline $\bar{\mathbf{s}}^{(t)}$ 의 top- K 와 다르면 step t 를 *branching event*, $\mathbf{s}^{(t)}$ 를
93 *branching state*라 부른다(Figure 1의 빨강).¹ 이렇게 두면 §3.2는 branching이 언제 가능한지를,
94 §3.3는 그 가능성이 디코딩 진행에 따라 어떻게 잦아드는지를 다루는 두 질문으로 정리된다.

95 3.2 Exploration: RSP가 초반 탐색을 강화한다

96 랜덤 프롬프트를 삽입할 경우, 어텐션이 랜덤 프롬프트에 몰리면서 탐색을 강화한다. 한 번의
97 RSP 주입이 hidden state에 미치는 영향은 두 가지 질문으로 살펴볼 수 있다: *얼마나*, 그리고
98 *어디로*. 첫 번째는 한 attention head 안의 한 스칼라 w 가 결정하고, 두 번째는 $\mathbf{H}$ 의 분포가 결정
99 한다. 등방 가우시안이라는 RSP의 설계가 두 측면을 동시에 풀어 낸다.

100 self-attention layer ℓ 의 한 attention head를 보자. query 위치 i 에서 query는 마스크되지 않은 실제
101 토큰 $n \geq 1$ 개와 RSP 토큰 $L \geq 1$ 개를 함께 attend하며 모든 attention logit은 유한하다. 어텐션
102 가중치를 $\alpha_{ij}^{(\ell)}$, value 벡터를 실제 측과 RSP 측에서 각각 $\mathbf{v}_j^{(\ell)}, \mathbf{v}_{rj}^{(\ell)}$ 로 쓰고, 무작위 토큰의 총
103 어텐션 질량을 $w_{r,i}^{(\ell)} := \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)}$ 로 정의한다. 실제 토큰 질량 $1 - w_{r,i}^{(\ell)}$ 은 양수이며, head
104 output $\mathbf{o}_i^{(\ell)}$ 은 정규화된 실제 토큰 항 $\tilde{\mathbf{o}}_i^{(\ell)}$ 과 RSP 기여 $\boldsymbol{\eta}_i^{(\ell)}$ 로 정확히 분해된다.

$$\mathbf{o}_i^{(\ell)} = (1 - w_{r,i}^{(\ell)}) \tilde{\mathbf{o}}_i^{(\ell)} + \boldsymbol{\eta}_i^{(\ell)}, \quad \tilde{\mathbf{o}}_i^{(\ell)} := \sum_{j=1}^n \frac{\alpha_{ij}^{(\ell)}}{1 - w_{r,i}^{(\ell)}} \mathbf{v}_j^{(\ell)}, \quad \boldsymbol{\eta}_i^{(\ell)} := \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{rj}^{(\ell)}. \quad (2)$$

105 Eq. (2)의 도출. head output을 $\sum_{j=1}^n \alpha_{ij}^{(\ell)} \mathbf{v}_j^{(\ell)} + \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{rj}^{(\ell)}$ 로 나눈 뒤, 실제 토큰 항에서
106 정규화 인자 $1 - w_{r,i}^{(\ell)} = \sum_{j=1}^n \alpha_{ij}^{(\ell)} > 0$ 를 묶어 내면 된다. softmax 정규화 항등식 외에는 어떤
107 근사도 쓰이지 않는다. $\square$

¹italic h_j 는 RSP 입력 공간; bold $\mathbf{s}^{(t)}$ 는 모델 hidden state. K 는 next-token sampler의 후보 집합 크기로, top- K truncation의 고정 cutoff 또는 top- p sampling의 동적 nucleus 크기 둘 다를 포괄한다. t 는 디코딩 step, ℓ 은 self-attention layer.

이 한 양 $w_{r,i}^{(\ell)}$ 이 실제 신호의 감쇠 비율 $1 - w_{r,i}^{(\ell)}$ 과 무작위 기여 항의 진폭 상계 $\|\eta_i^{(\ell)}\| \leq w_{r,i}^{(\ell)} \max_j \|\mathbf{v}_{r,j}^{(\ell)}\|$ 를 동시에 통제하므로, RSP가 만드는 변동의 진폭은 0과 1 사이 한 스칼라로 환원된다. 캐시가 짧은 디코딩 초반에는 이 값이 무시할 수 없어 한 번의 RSP가 next-token 결정을 흔들 수 있다.

그러나 한 스칼라 w 는 얼마나만 통제할 뿐 어디로 흔들지는 결정하지 않으며, 그 방향은 $\mathbf{H}$ 의 분포에 달려 있다. 한 위치만 분리해 본다. $\bar{h} \in \mathbb{R}^d$ 를 단일 centered RSP 토큰(Eq. (1)의 어떤 $\bar{h}_j$ 의 i.i.d. marginal)이라 두고, $z_i(\bar{h})$ 를 그 위치의 섭동을 변수로 보았을 때의 vocab 토큰 i 출력 logit으로 정의한다(나머지 $L - 1$ 개 centered 토큰은 0에 고정). vocab-logit gap을 $\Delta_{ij}(\bar{h}) := z_i(\bar{h}) - z_j(\bar{h})$ 로 쓴다($\bar{h} = 0$ 은 centered RSP가 entrywise 평균일 때이지 no-RSP 상태가 아니며, Appendix C에서 $z^{\text{Base}}, z^{\text{RSP}}$ 를 분리한다). transformer의 logit map은 $\bar{h}$ 에 대해 비선형이지만, $\bar{h} = 0$ 주변의 1차 Taylor 전개는 국소 surrogate $\Delta_{ij}(\bar{h}) \approx \Delta_{ij}(0) + b_{ij}^\top \bar{h}$ 를 준다. 여기서 $b_{ij} := \nabla_{\bar{h}}(z_i - z_j)|_{\bar{h}=0} \in \mathbb{R}^d$ 는 두 토큰의 순위가 바뀌는 gradient 방향이다(일반적으로 단위 벡터 아님). RSP는 학습되지 않으므로 어떤 문제에서 어떤 b_{ij} 가 유용한 분기를 여는지 사전에 알 수 없고, 이 정보 부족이 분포 설계를 제약한다. deterministic 주입 시퀀스는 그 기여가 한 방향에 고정되어 직교 방향 perturbation이 0이 된다. 어휘에서 무작위 토큰을 추첨하면 random성은 없지만 어휘 임베딩의 anisotropic 구조를 물려받아 특정 방향이 systematically 약하게 섭동된다. 사전 정보가 없을 때 합리적인 설계는 같은 분산 예산 안에서 최악의 방향이 갖는 분산을 최대화하는 공분산이며, 그 해는 등방이 유일하다.

명제 1 (Maximin directional coverage). $\mathcal{D}_\rho$ 를 $\mathbb{R}^d$ 위 평균 0 분포 중 공분산이 분산 예산 $\text{tr}(\Sigma_D) \leq \rho^2$ 를 만족하는 분포군으로 두자. 각 $D \in \mathcal{D}_\rho$ 에 대해 $\min_{\|b\|=1} \text{Var}_{h \sim D}(b^\top h) = \lambda_{\min}(\Sigma_D)$ 이고, 최악 방향 분산의 maximin 값은 ρ^2/d 이다.

$$\sup_{D \in \mathcal{D}_\rho} \min_{\|b\|=1} \text{Var}_{h \sim D}(b^\top h) = \rho^2/d,$$

이 supremum은 $\Sigma_D = (\rho^2/d)\mathbf{I}_d$ 일 때만 달성된다.

이 maximin 진술은 prompt law의 설계 기준일 뿐, 어느 분기가 정답을 만든다는 보장은 아니다. 정답성은 §3.3의 task-side $p_{\min}(x)$ 가정과 rollout 사이의 독립 재추첨에서 들어온다.²

가우시안 RSP는 $\Sigma = \sigma_E^2 \mathbf{I}_d$ ($\rho^2 = d\sigma_E^2$)로 등방 조건을 충족하면서, 가우시안 형태가 $\mathbb{R}^d$ 전역에 양의 밀도(full support)를 추가로 제공한다(Appendix C). 등방성은 어느 방향도 systematically 무시되지 않게 보장하고, full support는 baseline top-1을 떨어뜨리고 다른 토큰을 top- K 로 들이는 열린 영역(§3.1의 branching event 영역)이 비공집합인 경우 양의 확률로 도달할 수 있게 만든다(Appendix D.3.3). 단조 변환인 temperature는 토큰 순위를 보존하므로 같은 영역에 닿을 수 없어, RSP가 만드는 rank-changing 분기는 두 성질이 함께 만들어 내는 결과이며, 추론 초반에 hidden state를 여러 branching state로 갈라 놓는 메커니즘이 된다.

3.3 Annealing: KV 캐시 성장이 RSP 어텐션을 희석한다

RSP가 다양화하는 초반의 분기는 디코딩이 진행되며 자동으로 안정적이 된다. §3.2에서 정의한 한 스칼라 $w_{r,i}^{(\ell)}$ 의 상계가 자기회귀 캐시 성장과 함께 시퀀스 길이 방향으로 좁아지기 때문이다. 실제 토큰 항은 매 step 하나씩 추가되지만 RSP 항의 개수는 고정되어 있으므로, 실제 토큰과 RSP 토큰 사이의 attention-logit gap을 고정한 채로 보면 이 비대칭은 다음 상계로 정확히 나타난다.

정리 1 (캐시 성장에 의한 어텐션 질량 감쇠). key 차원 d_{head} 을 갖는 한 attention head에서 query 벡터 $\mathbf{q}_i$ (위치 i)가 실제 key $\mathbf{k}_j$ ($n \geq 1$ 개)와 RSP key $\mathbf{k}_{r,j'}$ ($L \geq 1$ 개)를 attend하며 모든 logit이 유한하다고 하자. 사전 스케일 attention-logit gap을 $\Delta_i := \min_{j \in [n]} \mathbf{q}_i^\top \mathbf{k}_j - \max_{j' \in [L]} \mathbf{q}_i^\top \mathbf{k}_{r,j'}$ 로 정의하면(§3.2의 vocab-logit gap Δ_{ij} 와는 다른 양임에 유의) scaled-dot-product 어텐션에서

$$w_{r,i} \leq \frac{L}{L + n \exp(\Delta_i / \sqrt{d_{\text{head}}})}$$

가 성립하며, 우변은 L 과 Δ_i 를 고정한 채 n 에 대해 엄격히 감소하고 0으로 수렴한다.

²Maximin은 입력 공간에서 진술된다. transformer 내부 layer를 거쳐 등방성이 그대로 보존된다고 주장하지 않는다. 어떤 국소 logit 방향도 모델 Jacobian을 통해 입력 공간 방향 b 로 pullback될 수 있고, 등방성은 그렇게 pullback된 어떤 방향도 systematically zero variance를 갖지 않음을 보장할 뿐이다.

149 *Proof.* $s_j := \mathbf{q}_i^\top \mathbf{k}_j / \sqrt{d_{\text{head}}}$, $s_{r,j'} := \mathbf{q}_i^\top \mathbf{k}_{r,j'} / \sqrt{d_{\text{head}}}$, $s_{r,\max} := \max_{j'} s_{r,j'}$, $R := \sum_{j'=1}^L \exp(s_{r,j'})$
 150 로 두자. gap 정의에서 모든 실제 토큰 j 에 대해 $s_j \geq \Delta_i / \sqrt{d_{\text{head}}} + s_{r,\max}$ 이고, max는 average
 151 보다 크므로 $\exp(s_{r,\max}) \geq R/L$ 이다. 두 사실을 결합해 n 개 실제 토큰을 합하면 $\sum_{j=1}^n \exp(s_j) \geq$
 152 $(n/L) \exp(\Delta_i / \sqrt{d_{\text{head}}}) R$ 이다. 이를 $w_{r,i} = R / (\sum_j \exp(s_j) + R)$ 에 대입하면

$$w_{r,i} \leq \frac{R}{(n/L) \exp(\Delta_i / \sqrt{d_{\text{head}}}) R + R} = \frac{L}{L + n \exp(\Delta_i / \sqrt{d_{\text{head}}})}$$

153 가 따른다. 우변의 미분은 $-L \exp(\Delta_i / \sqrt{d_{\text{head}}}) / (L + n \exp(\Delta_i / \sqrt{d_{\text{head}}}))^2 < 0$ 이므로 n 에 대해
 154 엄격히 감소하고, $n \rightarrow \infty$ 일 때 0으로 수렴한다. $\square$

155 각 layer ℓ 에 적용하면 §3.2의 per-layer scalar $w_{r,i}^{(\ell)}$ 를 gap $\Delta_i^{(\ell)}$ 와 함께 통제한다. RSP 길이 L 은
 156 분자로 들어가 최대 영향력을 정한다. 실제 토큰 수 n 은 매 step 자동으로 늘어 분모를 키우므로
 157 같은 L 아래에서도 영향력 상계는 좁아진다. 정리가 보장하는 것은 같은 layer·query 위치·
 158 attention-logit gap에서 RSP attention 상계가 시퀀스 길이 방향으로 좁아진다는 점이며, layer 방
 159 향 단조 감소는 아니다. $\Delta_i^{(\ell)}$ 는 디코딩 동안 query·key·hidden state와 함께 변하지만 깊은 layer
 160 와 긴 sequence에서 실제 토큰 간 상관관계가 누적되며 sharpen되는 경향을 보이고, Figure 2(a)
 161 의 layer 축 추가 감소가 그 간접 증거다. 따라서 정확한 진술은 “실현 mass의 step별 단조 감소”
 162 가 아니라 “같은 gap에서 가능한 상계의 단조 감소”다. Eq. (2)이 무작위 기여를 같은 스칼라로
 163 묶으므로 §3.1의 branching event 가능 확률 역시 같은 envelope에 통제되며, 캐시가 자랄수록 새
 164 branching은 드물어지고 응답은 이미 열린 분기로 commit되어 생성 초반에 열리고 캐시 누적과
 165 함께 줄어지는 암묵적 explore-then-exploit이 된다. Figure 2는 이 envelope이 실제 모델에서 어
 166 떻게 발현되는지 보여 준다: 가로(sequence) 축의 감소는 Theorem 1이 직접 예측한 패턴이고,
 167 세로(layer) 축의 추가 감소는 경험적으로 관찰되지만 본문 정리의 범위를 벗어난다.




Figure 2: Qwen2.5-Math-7B에서 측정된 토큰별 어텐션 질량(suffix, MATH-500 500문제, 문제마다 독립 RSP). (a) RSP 토큰 어텐션은 추론 위치 축(가로)에서 감소하며, 이는 Theorem 1의 cache-growth 상계와 일치한다. 레이어 축(세로)의 추가 감소는 별도의 경험적 현상으로, 깊은 레이어에서 실제 토큰과 RSP 토큰 사이의 attention-logit gap이 더 날카로워지는 경향을 시사하지만 Theorem 1만으로 직접 따라오지는 않는다. (b) 질문 토큰 어텐션은 비교적 균일하게 유지된다. 그림에 보고한 양은 Appendix E의 per-token mass로, RSP 길이 L 로 나눈 평균 값이며 본문 $w_{r,i}^{(\ell)}$ 와는 상수배 관계다.

168 매 rollout 독립 재추첨(§3.1)이 이 단발 분기를 task 정확도로 끌어올리려면 두 가정이 필요하다:
 169 (M1) 한 번의 실행이 정답 trajectory를 만들 주변 확률 $p_{\min}(x) > 0$, (M2) N 번의 실행이 상호
 170 독립. 두 가정 아래 standard ensemble 논변은 $\Pr(\text{Pass}@N \text{ on } x) \geq 1 - (1 - p_{\min}(x))^N$ 을 준다
 171 (Appendix D.3.4). §3.2의 등방성과 full support가 단발 분기를 가능하게 했다면 여기서는 독립
 172 재추첨이 그 위에 얹혀 N 번에 걸친 누적 이득으로 바뀐다. 같은 RSP를 모든 sample이 공유하면
 173 (M2)가 깨져 누적이 사라지므로 독립이 핵심이고, §4는 바로 이 서명을 실험적으로 확인한다.

174 4 실험적 확인

175 §3는 세 가지 분리된 메커니즘을 예측한다. RSP는 (i) 출력 분포를 평탄화·재배열해 token-
 176 level branching을 열고, (ii) 그 branching이 디코딩 동안 의미적으로 다른 trajectory-level 궤적
 177 으로 propagate되며, (iii) rollout 사이의 독립 재추첨이 그 분기들을 N 번에 걸쳐 outcome-level
 178 Pass@ N 으로 누적시킨다. 이 세 예측을 같은 순서로 검증한다. §4.2는 RSP가 baseline 정확
 179 도를 보존하거나 회복하는 setting을 짚어 메커니즘이 동작할 대상 영역을 확정하고, §4.3는 (i)
 180 의 첫 측면인 출력 분포 평탄화(entropy 상승, top-1 probability 감소, varentropy 증가)가 RSP와

Table 1: 모델 설정과 벤치마크별 정확도(%). 괄호 안 값은 baseline 대비 변화량이다. *infix*를 포함한 위치별 전체 결과는 Appendix A에 있다.

Model	MATH-500			GSM8K			AIME24		
	Baseline	RSP(prefix)	RSP(suffix)	Baseline	RSP(prefix)	RSP(suffix)	Baseline	RSP(prefix)	RSP(suffix)
<i>Instruct Models</i>									
LLaMA-3.1-8B-Inst	52.20	45.00 (−7.2)	49.40 (−2.8)	85.75	76.35 (−9.4)	86.73 (+1.0)	6.67	3.33 (−3.3)	10.00 (+3.3)
Qwen2.5-Math-7B-Inst	83.20	81.40 (−1.8)	83.40 (+0.2)	95.45	94.92 (−0.5)	95.68 (+0.2)	13.33	13.33 (+0.0)	16.67 (+3.3)
Qwen2.5-Math-1.5B-Inst	73.00	74.80 (+1.8)	74.20 (+1.2)	85.29	85.29 (+0.0)	84.69 (−0.6)	10.00	13.33 (+3.3)	20.00 (+10.0)
<i>Base Models (Raw Text)</i>									
Qwen2.5-Math-7B	72.20	71.60 (−0.6)	55.60 (−16.6)	84.15	84.31 (+0.2)	54.13 (−30.0)	6.67	16.67 (+10.0)	13.33 (+6.7)
Qwen2.5-Math-1.5B	61.40	64.40 (+3.0)	54.60 (−6.8)	77.86	74.30 (−3.6)	58.61 (−19.3)	16.67	10.00 (−6.7)	3.33 (−13.3)
<i>Base Models + ChatML (Format Mismatch)</i>									
Qwen2.5-Math-7B	52.20	59.20 (+7.0)	70.40 (+18.2)	58.30	56.41 (−1.9)	75.97 (+17.7)	23.33	3.33 (−20.0)	23.33 (+0.0)
Qwen2.5-Math-1.5B	34.40	63.40 (+29.0)	51.00 (+16.6)	37.45	67.02 (+29.6)	50.64 (+13.2)	13.33	20.00 (+6.7)	13.33 (+0.0)

Table 2: 기존 soft prompt 방법(TTSV, SoftCoT, LTPO)과의 통합 평가 비교. **Baseline**은 Table 1에서 가져왔고, **RSP**는 평가셋에서 위치 및 $L \in \{10, 15, 20\}$ 에 대한 best 값을 보고한다(위치별 분해는 Appendix A). **Bold**는 최고 성능, underline은 두 번째 성능이다.

Model	Benchmark	Baseline	RSP	TTSV	SoftCoT	LTPO
Qwen2.5-Math-7B-Instruct	MATH-500	83.20	84.20	83.80	82.80	83.00
	GSM8K	<u>95.45</u>	95.68	<u>95.30</u>	95.00	94.84
	AIME24	13.33	<u>16.67</u>	23.30	<u>16.67</u>	13.33
Qwen2.5-Math-1.5B-Instruct	MATH-500	73.00	<u>75.20</u>	<u>75.20</u>	76.00	72.40
	GSM8K	85.29	85.75	<u>85.70</u>	84.46	84.53
	AIME24	<u>10.00</u>	20.00	6.70	6.67	<u>10.00</u>

181 다른 latent prompt 방법에서 공유되는지를 보며, §4.4는 (i)의 두 번째 측면인 *rank-changing* 변화
 182 (temperature가 만들 수 없는 순위 재배치), (ii) 의미적 trajectory diversity, (iii) 독립 RSP에서만
 183 누적되는 Pass@N을 차례로 검증한다.

184 4.1 실험 설정

185 평가는 세 가지 수학 추론 벤치마크 MATH-500 [Lightman et al., 2024], GSM8K [Cobbe et al.,
 186 2021], AIME24에서 수행한다. 모델은 LLaMA-3.1-8B-Instruct [Grattafiori et al., 2024]와
 187 Qwen2.5-Math 계열 [Yang et al., 2024]을 쓰며, instruct·base·chat template 불일치 base를 비
 188 교한다. 모든 실험은 sampling 자체의 무작위성과 RSP 효과를 분리하기 위해 greedy decoding을
 189 사용한다. RSP는 §3.1의 정의를 따르며 기본 *suffix* 위치에 batch마다 새로 추첨된 **H**를 결합한다.
 190 Theorem 1이 RSP 길이 L 을 최대 섭동 영향력을 정하는 설계 파라미터로 식별하므로, 모델별로
 191 $L \in \{10, 15, 20\}$ 를 ablate해 적절한 섭동 강도를 찾는다. Table 1와 Table 2는 모델별로 선택된 L
 192 의 결과를 보고한다. §4.3–§4.4의 메커니즘 분석은 fixed $L = 10$, *suffix*로 통일해 selection effect
 193 에서 분리했다. 전체 설정과 위치별 결과는 Appendix A에 있다.

194 4.2 RSP는 추론 성능을 개선할까?

195 먼저 무작위 임베딩 주입이 추론 성능에 어떤 영향을 주는지 본다. Table 1는 기본 *suffix* 위치와
 196 *prefix* ablation 결과를 보고한다.

197 instruct model에서 RSP는 baseline 대비 $\pm$ 몇 %p 안에서 거동한다. 가장 두드러지는 것은 형식
 198 불일치 회복이다. chat 형식으로 학습되지 않은 base model에 ChatML template을 적용하면
 199 *Suffix*(Qwen2.5-Math-7B에서 +18.2/+17.7 pp)와 *prefix*(Qwen2.5-Math-1.5B에서 +29.0/+29.6 pp
 200 까지)가 손실을 회복한다 — 단순 노이즈였다면 추가 저하가 나타나야 한다. 한편 base raw-text
 201 환경에서 *suffix*는 큰 손해를 보이고(−16.6/−30.0 pp) *prefix*는 손실이 작은데, base가 EOS 인접
 202 신호를 탈선 trigger로 처리하고 *prefix*가 그것을 회피한다고 볼 수 있다. 즉 RSP의 직접적 정확도
 203 이득은 misaligned 입력 회복에 집중되고 잘 정렬된 instruct에서는 $\pm$ 몇 pp에 머문다. 본 논문이
 204 강조하는 효과는 §4.4의 token·trajectory·outcome diversity이고, 정확도 회복은 부수적 결과다.

205 또한 RSP를 TTSV, SoftCoT, LTPO처럼 서로 다른 목적 함수로 임베딩을 최적화하는 기존 soft
 206 prompt 방법과 비교했다. Table 2는 공통 answer extraction pipeline(Appendix A.2) 아래에서 다

시 평가한 결과를 보여 준다. 각 방법은 프롬프트 형식과 채점 규칙이 다르지만, fallback 기반
추출로 형식 민감도를 낮춘 비교를 수행했다. RSP는 일관된 우월성을 보이지 않는다. 예컨
대 Qwen2.5-Math-7B-Inst의 AIME24에서 TTSV가 23.30%로 RSP의 16.67%를 앞선다. 그러나
RSP가 추가 학습 없이도 학습 기반 방법과 비교 가능한 범위에 도달한다는 사실 자체가, soft
prompt 효과의 일정 부분이 학습된 의미가 아니라 주입 구조에서 비롯될 수 있음을 가리키는 본
논문의 주된 증거가 된다.

4.3 RSP는 출력 분포를 어떻게 바꾸는가?

다음으로 RSP 주입이 생성 과정의 출력 분포를 어떻게 바꾸는지 살펴본다. 설정은 Qwen2.5-
Math-1.5B-Instruct와 MATH-500이며, 토큰별 entropy, top-1 probability, varentropy를 생성 단
계에 따라 측정한다. Figure 3는 생성 초반 5% 구간에서 RSP 변형과 기존 soft prompt 방법을
비교한 결과이며, 전체 곡선은 Appendix A.4에 있다.




Figure 3: 생성 초반 5% 구간의 평균 entropy, top-1 probability, varentropy (Qwen2.5-Math-1.5B-Instruct, MATH-500). 음영은 ± 1 SEM이다. 실선은 RSP 변형과 baseline, 점선은 기존 soft prompt 방법(LTPO, SoftCoT, TTSV)이다.

RSP를 포함한 latent prompt 방법들은 공통적으로 생성 초반 entropy 상승 $\rightarrow$ 후반 baseline 수렴이라는 동일한 시그니처를 보인다. 메커니즘 측면에서 자연스러운 설명은 OOV(out-of-vocabulary) 효과다 — 어휘 바깥의 연속 임베딩이 입력으로 들어오면 모델은 익숙한 토큰 분포 위에서 한 번도 본 적 없는 토크 위치를 attend해야 하므로 초반 next-token 분포에서 확률 질량이 여러 후보로 재분배된다. 세 RSP 주입 위치 모두에서 초반 entropy $\uparrow$, top-1 probability $\downarrow$, varentropy $\uparrow$ 가 함께 나타나며, 이는 multimodal 분포와 정합한다 [Ahmed et al., 2026]. 변화가 생성 초반에 국한되고 중·후반에는 세 지표 모두 baseline 수준으로 수렴한다는 점이 중요한데, 이는 §3.3의 cache-growth attenuation이 예측한 초반 영향력 $\rightarrow$ 캐시 성장에 따른 자동 감쇠 패턴과 정합한다.

서로 다른 목적 함수로 학습된 prior 방법(LTPO, SoftCoT, TTSV)도 같은 시그니처를 공유한다. 평균 entropy를 줄이는 보상을 쓰는 TTSV조차 초반 구간만큼은 baseline과 비슷하다. entropy 수치 자체가 quality score가 아닌 점은 짚어 둘 만하다 — 높은 entropy가 무조건 좋은 것이 아니라, 시그니처가 드러내는 것은 학습 목적과 무관하게 OOV 임베딩 주입이 같은 fingerprint를 만든다는 공유 메커니즘이다. latent reasoning을 가능케 하는 핵심 요소가 학습된 의미가 아니라 주입 자체에 있다는 가설을 이 시그니처가 뒷받침한다.

4.4 RSP는 실제로 추론 궤적의 다양성을 만드는가?

§4.3는 RSP가 생성 초반 출력 분포를 바꾼다는 사실을 보였다. 이제 이 변화가 실제 추론 다양성으로 이어지는지를 세 수준에서 살펴본다. 분석 수준은 토큰 순위, 궤적의 의미적 내용, 과제 수준 결과다. 세 분석 모두 Qwen2.5-Math-1.5B-Instruct, MATH-500, suffix 주입, $L = 10$ 설정을 공유한다.

토큰 수준: temperature를 넘어서는 분포 변화. RSP가 첫 토큰 분포를 얼마나 흔드는지를 정량화한다 — 추론 궤적의 분기점이다 [Wang et al., 2025]. Baseline $\tau=1.0$ 을 기준으로, 더 높은 temperature($\tau=2.0, 3.0$, 문제당 16개 샘플)와 RSP $\tau=1.0$ (16 seed 평균)을 세 지표로 비교한다: 순위 재배치를 감지하는

Table 3: Baseline $\tau=1.0$ 을 기준으로 본 첫 토큰 분포 지표. 더 높은 temperature의 baseline($\tau=2.0, 3.0$)과 RSP $\tau=1.0$ 을 비교한다. RSP 지표는 16개 random seed 평균이며, Acc는 문제당 16개 샘플의 평균 $\pm$ 표준편차다.

Metric	$\tau=2.0$	$\tau=3.0$	RSP
Spearman ρ	1.000	1.000	0.709
Mass outside top-10	5.18%	29.11%	21.86%
JS divergence	0.060	0.218	0.131
Acc($\uparrow$ %)	20.77 ± 1.47	1.42 ± 0.35	73.30 ± 1.07

245 Spearman rank correlation ρ , support 확장
 246 을 측정하는 baseline top-10 밖 확률 질
 247 량, 전체 분포 변화 크기를 정량화하는
 248 Jensen–Shannon divergence (정식 정의는
 249 Appendix B). Table 3의 대비는 명확하다. RSP의 분포 변화 크기는 $\tau=2.0$ 과 $\tau=3.0$ 사이지만
 250 메커니즘이 다르다 — temperature는 단조 변환이라 $\rho = 1$ 이 강제되는 반면 RSP는 $\rho = 0.709$
 251 로 순위를 일부 보존하면서 재배치한다. Pass@1 행이 비용을 드러낸다 — temperature를 RSP와
 252 같은 크기로 키우면 정확도는 1.42%까지 무너지지만 RSP는 73.30%를 유지한다. 따라서 RSP
 253 는 temperature와 근본적으로 다른 섭동을 만든다. 또한 RSP의 16 seed 정확도 변동성(± 1.07)
 254 은 $\tau=2.0$ 16 샘플의 변동성(± 1.47)과 비교 가능한 수준이다.

255 **궤적 수준: 의미적 다양성.** 토큰 수준 재배치는 두 번째 질
 256 문을 만든다 — 첫 토큰 섭동이 서로 다른 궤적으로 갈라지
 257 는가, 아니면 비슷한 궤적으로 수렴하는가? MATH-500에서
 258 무작위 64개 문제를 뽑고, Baseline과 RSP 두 조건에서 각 문
 259 제마다 $\tau=1.0$ 으로 300개의 독립 궤적을 생성했다. 각 궤적
 260 을 BGE-M3 [Chen et al., 2024]로 임베딩하고 세 지표를 계산
 261 한다 — 의미적 spread 전체를 보는 *pairwise cosine distance*,
 262 density 기반 클러스터링 알고리즘인 DBSCAN [Ester et al.,
 263 1996] 군집 중심 사이의 *inter-cluster distance* (서로 다른 궤적 그룹의 분리), 그리고 군집 내 응집
 264 을 보는 *intra-cluster distance*. Table 4는 세 패턴을 동시에 드러낸다 — *pairwise cosine distance*가
 265 1.4배로 커지고, *inter-cluster distance*가 5.4배로 뛴데, *intra-cluster distance*는 거의 변하지 않는다.
 266 즉 궤적 집합이 더 다양해지고 더 분리된 군집들로 갈라지면서도 군집 내부 응집은 유지된다.
 267 RSP는 *pairwise distance* 기준으로 64개 중 56개 문제에서 baseline보다 컸다.

Table 4: 64개 문제에 대해 평균
한 의미적 다양성 지표.

Metric	Baseline	RSP
Pairwise cos. dist.	0.0612	0.0879
Inter-cluster dist.	0.0183	0.0982
Intra-cluster dist.	0.0526	0.0528

268 **결과 수준: Pass@N 스케일링.** 마지막 결과 수준에서는, 이러한 다양성이 실제 과제 성과로
 269 이어지는지를 Pass@N [Chen et al., 2021]로 본다 (N 개 샘플 중 적어도 하나가 정답일 확률).
 270 MATH-500과 AIME24에서 문제당 16개 샘플을 생성하고 네 조건을 비교한다 — (i) *Baseline*
 271 + $\tau=1.0$, (ii) *RSP (single seed)* + $\tau=1.0$, 모든 샘플이 같은 RSP 공유, (iii) *RSP (indep. seed)* +
 272 *greedy*, 샘플마다 새 RSP, (iv) *RSP (indep. seed)* + $\tau=1.0$, 샘플마다 새 RSP.




Figure 4: Qwen2.5-Math-1.5B-Instruct에서의 Pass@N 스케일링. 좌측은 MATH-500, 우측은 AIME24이며, 문제당 16개 샘플 사용. *Baseline*: temperature sampling만. *RSP (single seed)*: 고정된 하나의 RSP와 temperature를 함께. *RSP (indep. seed)*: 샘플마다 다른 RSP를 쓰는 경우 (temperature 유무).

273 조건 (iv)가 두 벤치마크 모두에서 가장 높은 Pass@N을 달성하며 $N = 16$ 에서 MATH-500
 274 92.80%, AIME24 36.67%에 이른다. (ii)는 baseline 대비 거의 개선이 없어, 다양성 이득의 핵심
 275 이 고정 섭동이 아니라 샘플마다 독립된 무작위 임베딩임을 드러낸다. Pass@1은 MATH-500
 276 에서 baseline 수준을 유지하고 더 어려운 AIME24에서는 (iv)가 더 높아, 독립 RSP + temperature
 277 결합이 단일 샘플 정확도를 해치지 않으면서 추론 궤적을 다양화한다.

278 5 Application: RSP를 이용한 DAPO 학습

279 §3–4는 RSP가 무엇을 하는지(어텐션 매개의 분기 개방)와 추론 시점에서 어떻게 동작하는지
 280 (Pass@N 향상, temperature로는 도달할 수 없는 rank-changing 다양성)를 정립했다. 이 효과를
 281 학습 시점에서도 활용해볼 수 있을까? sampling 기반 RL의 학습 결과를 좌우하는 핵심 요소는
 282 rollout 다양성이며, DAPO [Yu et al., 2025]는 이를 손실 단에서 보존하도록 설계된 최근의 GRPO
 283 [Shao et al., 2024] 변형이다. 우리는 이를 까다로운 testbed로 사용한다. 입력 단 분기 개방이

손실 단 다양성 보존과 결합해 추가 이득을 만드는가? 구현 세부와 step별 결과는 Appendix F에 있다.

DAPO는 GRPO의 손실 항을 수정해 긴 chain-of-thought RL 학습 동안 rollout 다양성을 손실 단에서 유지하며, rollout의 가중과 clip 방식을 다듬어 다양성을 형성한다. 반면 RSP는 손실 계산 이전 단계에서 rollout 분포 자체에 섭동을 주어 입력 단에서 다양성을 유발한다 (§4.4). 각 rollout의 토큰 시퀀스를 $y_i = (y_{i,1}, \dots, y_{i,|y_i|})$ 로 적고 (§3.2의 head output $\mathbf{o}_i^{(\ell)}$)와의 표기 충돌을 피하기 위해 y 를 사용한다, rollout마다 독립 추첨된 RSP $\mathbf{H}_i$ 와 짝지운다. update 시점에도 같은 $\mathbf{H}_i$ 를 재사용해 policy 업데이트가 RSP-conditioned 분포에 대해 on-policy를 유지하게 한다. 중요도 비를 $r_{i,t}(\theta) = \pi_\theta(y_{i,t} | q, \mathbf{H}_i, y_{i,<t}) / \pi_{\theta_{\text{old}}}(y_{i,t} | q, \mathbf{H}_i, y_{i,<t})$, 그룹 상대 advantage를 $\hat{A}_{i,t}$, 비대칭 clip 범위를 $(\varepsilon_{\text{low}}, \varepsilon_{\text{high}})$ 라 하면 DAPO + RSP의 목적함수는

$$\mathcal{J}_{\text{DAPO+RSP}}(\theta) = \mathbb{E} \left[\frac{1}{\sum_i |y_i|} \sum_{i,t} \min \left(r_{i,t} \hat{A}_{i,t}, \text{clip}(r_{i,t}, 1 - \varepsilon_{\text{low}}, 1 + \varepsilon_{\text{high}}) \hat{A}_{i,t} \right) \right]. \quad (3)$$

Table 5: Qwen2.5-Math-7B에서 각 방법의 peak step 벤치마크별 정확도(%). 굵게는 두 RL 방법 중 더 높은 쪽이고, Avg는 가중치 없는 5-벤치마크 평균이다.

Method	GSM8K	MATH-500	College	Minerva	AIME 24	Avg
Base	57.2	52.6	18.3	13.6	8.6	30.06
DAPO	86.3	78.2	41.4	37.5	22.6	53.20
DAPO + RSP	87.7	78.6	42.2	39.7	23.6	54.36

Qwen2.5-Math-7B를 MATH Level-3–5 subset(약 8,500 prompt)에서 SimpleRL-Zoo [Zeng et al., 2025] 파이프라인과 Eq. (3)로 학습한다. 매 step은 prompt 1,024개 배치 위에서 $\tau=1.0$, $G=8$ rollout으로 추첨한 뒤 prompt 256개씩 4번의 PPO mini-batch 업데이트를 진행하며, 총 100 step(약 12 epoch). DAPO와 DAPO + RSP를 비교하며, 후자는 rollout에만 suffix RSP($L=20$)를 적용하고 평가는 RSP 없이 수행한다. 평가는 5개 수학 추론 벤치마크(GSM8K [Cobbe et al., 2021], MATH-500 [Lightman et al., 2024], College Math, Minerva Math [Lewkowycz et al., 2022], AIME 2024)에서 진행한다. AIME 2024는 분산 축소를 위해 $\tau=1.0$ 에서 Avg@32, 큰 셋은 greedy로 채점한다. 보고는 5-벤치마크의 가중치 없는 평균이다.

Figure 5와 Table 5에서 두 가지가 동시에 드러난다. 첫째, 학습 후반의 일관된 우위가 보인다. DAPO + RSP의 5-벤치마크 평균은 step 90에서 54.36%로 DAPO 자체 peak(step 80, 53.20%)을 +1.16 pp 증가하고 step 100에서는 53.64% vs 50.54%(+3.10 pp)로 격차가 더 벌어지며, DAPO 단독에서 관찰되는 step 80 이후 감소가 RSP 결합 시 지연된다. 둘째, 초반에는 reward 성장이 지연돼 두 곡선이 step 20 부근에서 교차한다. 두 패턴은 RSP와 DAPO의 손실 항 수정이 최적화의 분리된 단계에 작용한다는 점에서 자연스럽게 설명된다. DAPO 수정은 이미 생성된 rollout과 logit을 입력으로 받아 손실 단에서 다양성을 보존하는 반면, RSP는 그 rollout을 만들어 내는 은닉 상태 자체를 입력 단에서 섭동한다 (§3.2). 입력 단 섭동은 policy가 평소라면 선택했을 궤적에서 벗어나게 해 더 넓은 학습 신호 분포에 정책을 노출시키며, 그 노출이 누적돼 천장 상승과 붕괴 지연으로 나타난다. 이는 RL의 exploration–exploitation 동역학 [Sutton and Barto, 2018]이 은닉 상태 단 섭동을 통해 입력 측에서도 유도될 수 있음을 보이는 결과다. 보고된 결과는 단일 학습 seed로 얻은 것이며 multi-seed 평가는 향후 작업이다. 본 절은 확정적 비교가 아닌 적용 가능성에 대한 feasibility demonstration으로 읽어 주기를 권한다.




Figure 5: Qwen2.5-Math-7B의 5-벤치마크 평균 정확도. DAPO + RSP는 step 90에서 더 높은 peak에 도달해 step 100까지 안정 유지된다.

6 결론

본 연구는 사전학습 임베딩의 항별 평균·분산에 맞춘 등방 가우시안 벡터를 학습 없이 주입하는 RSP를 분석했다. 이론적으로 RSP의 기여는 어텐션 레이어마다 단일 스칼라 $w_{r,i}^{(\ell)}$ 로 포착되고 fixed-gap 상계가 캐시 성장에 따라 좁아지며, 국소 affine 분석에서 등방 재추첨은 temperature

가 만들 수 없는 top- K 진입 영역에 양의 확률을 부여한다 (§3). 실험적으로 RSP를 포함한 latent prompt 방법들은 같은 entropy 시그니처(초반 상승, 후반 안정화)를 공유하고, 같은 RSP를 sample 간 공유하면 누적 이득이 사라져 핵심이 독립성임을 직접 확인했으며 (§4), DAPO와 결합하면 학습 후반의 안정성과 평균 정확도에서 완만한 이득을 얻는다 (§5). 학습된 의미 없이 입력 단 무작위 섭동만으로 latent reasoning의 핵심 패턴이 발현된다는 점은 *soft prompt* 효과의 일정 부분이 주입 구조의 부산물일 가능성을 가리키며, RSP가 ensemble·self-consistency와 직교 결합 가능한 무비용 다양성 확장기로 활용될 수 있음을 시사한다. 한계로는 RoPE decoder와 수학 추론 외 도메인으로의 일반화, Theorem 1 fixed-gap 외부의 sharpening dynamics, multi-seed DAPO 분산, held-out hyperparameter selection (§4.1)이 남는다.

References

- Farhan Ahmed, Yuya Jeremy Ong, and Chad DeLuca. LogitScope: A Framework for Analyzing LLM Uncertainty through Information Metrics. In *ICLR Workshop*, 2026.
- Nora Belrose, Igor Ostrovsky, Lev McKinney, Zach Furman, Logan Smith, Danny Halawi, Stella Biderman, and Jacob Steinhardt. Eliciting Latent Predictions from Transformers with the Tuned Lens. *arXiv:2303.08112*, 2023.
- Jianlyu Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, and Zheng Liu. M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation. In *Findings of ACL*, 2024.
- Mark Chen, Jerry Tworek, Heewoo Jun, Qiming Yuan, Henrique Ponde de Oliveira Pinto, Jared Kaplan, Harri Edwards, Yuri Burda, Nicholas Joseph, Greg Brockman, Alex Ray, Raul Puri, Gretchen Krueger, Michael Petrov, Heidy Khlaaf, Girish Sastry, Pamela Mishkin, Brooke Chan, Scott Gray, Nick Ryder, Mikhail Pavlov, Alethea Power, Lukasz Kaiser, Mohammad Bavarian, Clemens Winter, Philippe Tillet, Felipe Petroski Such, Dave Cummings, Matthias Plappert, Fotios Chantzis, Elizabeth Barnes, Ariel Herbert-Voss, William Hebgen Guss, Alex Nichol, Alex Paino, Nikolas Tezak, Jie Tang, Igor Babuschkin, Suchir Balaji, Shantanu Jain, William Saunders, Christopher Hesse, Andrew N. Carr, Jan Leike, Josh Achiam, Vedant Misra, Evan Morikawa, Alec Radford, Matthew Knight, Miles Brundage, Mira Murati, Katie Mayer, Peter Welinder, Bob McGrew, Dario Amodei, Sam McCandlish, Ilya Sutskever, and Wojciech Zaremba. Evaluating Large Language Models Trained on Code. *arXiv:2107.03374*, 2021.
- Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, Christopher Hesse, and John Schulman. Training Verifiers to Solve Math Word Problems. *arXiv:2110.14168*, 2021.
- Jeremy M. Cohen, Elan Rosenfeld, and J. Zico Kolter. Certified Adversarial Robustness via Randomized Smoothing. In *ICML*, 2019.
- Martin Ester, Hans-Peter Kriegel, Jörg Sander, and Xiaowei Xu. A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise. In *KDD*, 1996.
- Meire Fortunato, Mohammad Gheshlaghi Azar, Bilal Piot, Jacob Menick, Ian Osband, Alex Graves, Vlad Mnih, Remi Munos, Demis Hassabis, Olivier Pietquin, Charles Blundell, and Shane Legg. Noisy Networks for Exploration. In *ICLR*, 2018.
- Mor Geva, Roei Schuster, Jonathan Berant, and Omer Levy. Transformer Feed-Forward Layers Are Key-Value Memories. In *EMNLP*, 2021.
- Sachin Goyal, Ziwei Ji, Ankit Singh Rawat, Aditya Krishna Menon, Sanjiv Kumar, and Vaishnavh Nagarajan. Think before You Speak: Training Language Models with Pause Tokens. In *ICLR*, 2024.
- Aaron Grattafiori, Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad Al-Dahle, Aiesha Letman, Akhil Mathur, Alan Schelten, Alex Vaughan, Amy Yang, Angela Fan, Anirudh Goyal, Anthony Hartshorn, Aobo Yang, Archi Mitra, Archie Sravankumar, Artem Korenev, Arthur Hinsvark, Arun Rao, Aston Zhang, Aurelien Rodriguez, Austen Gregerson, Ava Spataru, Baptiste Roziere, Bethany Biron, Binh Tang, Bobbie Chern, Charlotte Caucheteux, Chaya Nayak, Chloe Bi, Chris Marra, Chris McConnell, Christian Keller, Christophe Touret, Chunyang

375 Wu, Corinne Wong, Cristian Canton Ferrer, Cyrus Nikolaidis, Damien Allonsius, Daniel Song,
 376 Danielle Pintz, Danny Livshits, Danny Wyatt, David Esiobu, Dhruv Choudhary, Dhruv Mahajan,
 377 Diego Garcia-Olano, Diego Perino, Dieuwke Hupkes, Egor Lakomkin, Ehab AlBadawy, Elina
 378 Lobanova, Emily Dinan, Eric Michael Smith, Filip Radenovic, Francisco Guzmán, Frank Zhang,
 379 Gabriel Synnaeve, Gabrielle Lee, Georgia Lewis Anderson, Govind Thattai, Graeme Nail, Gre-
 380 goire Mialon, Guan Pang, Guillem Cucurell, Hailey Nguyen, Hannah Korevaar, Hu Xu, Hugo
 381 Touvron, Iliyan Zarov, Imanol Arrieta Ibarra, Isabel Kloumann, Ishan Misra, Ivan Evtimov, Jack
 382 Zhang, Jade Copet, Jaewon Lee, Jan Geffert, Jana Vranes, Jason Park, Jay Mahadeokar, Jeet Shah,
 383 Jelmer van der Linde, Jennifer Billock, Jenny Hong, Jenya Lee, Jeremy Fu, Jianfeng Chi, Jianyu
 384 Huang, Jiawen Liu, Jie Wang, Jiecao Yu, Joanna Bitton, Joe Spisak, Jongsoo Park, Joseph Rocca,
 385 Joshua Johnstun, Joshua Saxe, Junteng Jia, Kalyan Vasuden Alwala, Karthik Prasad, Kartikeya
 386 Upasani, Kate Plawiak, Ke Li, Kenneth Heafield, Kevin Stone, Khalid El-Arini, Krithika Iyer,
 387 Kshitiz Malik, Kuenley Chiu, Kunal Bhalla, Kushal Lakhotia, Lauren Rantala-Yearly, Laurens
 388 van der Maaten, Lawrence Chen, Liang Tan, Liz Jenkins, Louis Martin, Lovish Madaan, Lubo
 389 Malo, Lukas Blecher, Lukas Landzaat, Luke de Oliveira, Madeline Muzzi, Mahesh Pasupuleti,
 390 Mannat Singh, Manohar Paluri, Marcin Kardas, Maria Tsimpoukelli, Mathew Oldham, Mathieu
 391 Rita, Maya Pavlova, Melanie Kambadur, Mike Lewis, Min Si, Mitesh Kumar Singh, Mona Has-
 392 san, Naman Goyal, Narjes Torabi, Nikolay Bashlykov, Nikolay Bogoychev, Niladri Chatterji, Ning
 393 Zhang, Olivier Duchenne, Onur Çelebi, Patrick Alrassy, Pengchuan Zhang, Pengwei Li, Petar Vas-
 394 sic, Peter Weng, Prajjwal Bhargava, Pratik Dubal, Praveen Krishnan, Punit Singh Koura, Puxin
 395 Xu, Qing He, Qingxiao Dong, Ragavan Srinivasan, Raj Ganapathy, Ramon Calderer, Ricardo Sil-
 396 veira Cabral, Robert Stojnic, Roberta Raileanu, Rohan Maheswari, Rohit Girdhar, Rohit Patel,
 397 Romain Sauvestre, Ronnie Polidoro, Roshan Sumbaly, Ross Taylor, Ruan Silva, Rui Hou, Rui
 398 Wang, Saghar Hosseini, Sahana Chennabasappa, Sanjay Singh, Sean Bell, Seohyun Sonia Kim,
 399 Sergey Edunov, Shaoliang Nie, Sharan Narang, Sharath Raparthy, Sheng Shen, Shengye Wan,
 400 Shruti Bhosale, Shun Zhang, Simon Vandenhende, Soumya Batra, Spencer Whitman, Sten Sootla,
 401 Stephane Collot, Suchin Gururangan, Sydney Borodinsky, Tamar Herman, Tara Fowler, Tarek
 402 Sheasha, Thomas Georgiou, Thomas Scialom, Tobias Speckbacher, Todor Mihaylov, Tong Xiao,
 403 Ujjwal Karn, Vedanuj Goswami, Vibhor Gupta, Vignesh Ramanathan, Viktor Kerkez, Vincent
 404 Gouget, Virginie Do, Vish Vogeti, Vitor Albiero, Vladan Petrovic, Weiwei Chu, Wenhan Xiong,
 405 Wenjin Fu, Whitney Meers, Xavier Martinet, Xiaodong Wang, Xiaofang Wang, Xiaoqing Ellen
 406 Tan, Xide Xia, Xinfeng Xie, Xuchao Jia, Xuewei Wang, Yaelle Goldschlag, Yashesh Gaur, Yas-
 407 mine Babaei, Yi Wen, Yiwen Song, Yuchen Zhang, Yue Li, Yuning Mao, Zacharie Delpierre
 408 Coudert, Zheng Yan, Zhengxing Chen, Zoe Papakipos, Aaditya Singh, Aayushi Srivastava, Abha
 409 Jain, Adam Kelsey, Adam Shajnfeld, Adithya Gangidi, Adolfo Victoria, Ahuva Goldstand, Ajay
 410 Menon, Ajay Sharma, Alex Boesenberg, Alexei Baevski, Allie Feinstein, Amanda Kallet, Amit
 411 Sangani, Amos Teo, Anam Yunus, Andrei Lupu, Andres Alvarado, Andrew Caples, Andrew Gu,
 412 Andrew Ho, Andrew Poulton, Andrew Ryan, Ankit Ramchandani, Annie Dong, Annie Franco,
 413 Anuj Goyal, Aparajita Saraf, Arkabandhu Chowdhury, Ashley Gabriel, Ashwin Bharambe, As-
 414 saf Eisenman, Azadeh Yazdan, Beau James, Ben Maurer, Benjamin Leonhardi, Bernie Huang,
 415 Beth Loyd, Beto De Paola, Bhargavi Paranjape, Bing Liu, Bo Wu, Boyu Ni, Braden Hancock,
 416 Bram Wasti, Brandon Spence, Brani Stojkovic, Brian Gamido, Britt Montalvo, Carl Parker, Carly
 417 Burton, Catalina Mejia, Ce Liu, Changhan Wang, Changkyu Kim, Chao Zhou, Chester Hu, Ching-
 418 Hsiang Chu, Chris Cai, Chris Tindal, Christoph Feichtenhofer, Cynthia Gao, Damon Civin, Dana
 419 Beaty, Daniel Kreymer, Daniel Li, David Adkins, David Xu, Davide Testuggine, Delia David,
 420 Devi Parikh, Diana Liskovich, Didem Foss, Dingkan Wang, Duc Le, Dustin Holland, Edward
 421 Dowling, Eissa Jamil, Elaine Montgomery, Eleonora Presani, Emily Hahn, Emily Wood, Eric-
 422 Tuan Le, Erik Brinkman, Esteban Arcaute, Evan Dunbar, Evan Smothers, Fei Sun, Felix Kreuk,
 423 Feng Tian, Filippos Kokkinos, Firat Ozgenel, Francesco Caggioni, Frank Kanayet, Frank Seide,
 424 Gabriela Medina Florez, Gabriella Schwarz, Gada Badeer, Georgia Swee, Gil Halpern, Grant Her-
 425 man, Grigory Sizov, Guangyi Zhang, Guna Lakshminarayanan, Hakan Inan, Hamid Shojanazeri,
 426 Han Zou, Hannah Wang, Hanwen Zha, Haroun Habeeb, Harrison Rudolph, Helen Suk, Henry
 427 Aspegren, Hunter Goldman, Hongyuan Zhan, Ibrahim Damlaj, Igor Molybog, Igor Tufanov, Il-
 428 ias Leontiadis, Irina-Elena Veliche, Itai Gat, Jake Weissman, James Geboski, James Kohli, Janice
 429 Lam, Japhet Asher, Jean-Baptiste Gaya, Jeff Marcus, Jeff Tang, Jennifer Chan, Jenny Zhen, Jeremy
 430 Reizenstein, Jeremy Teboul, Jessica Zhong, Jian Jin, Jingyi Yang, Joe Cummings, Jon Carvill, Jon
 431 Shepard, Jonathan McPhie, Jonathan Torres, Josh Ginsburg, Junjie Wang, Kai Wu, Kam Hou U,
 432 Karan Saxena, Kartikay Khandelwal, Katayoun Zand, Kathy Matosich, Kaushik Veeraraghavan,
 433 Kelly Michelena, Keqian Li, Kiran Jagadeesh, Kun Huang, Kunal Chawla, Kyle Huang, Lailin

Chen, Lakshya Garg, Lavender A, Leandro Silva, Lee Bell, Lei Zhang, Liangpeng Guo, Licheng Yu, Liron Moshkovich, Luca Wehrstedt, Madian Khabsa, Manav Avalani, Manish Bhatt, Martynas Mankus, Matan Hasson, Matthew Lennie, Matthias Reso, Maxim Groshev, Maxim Naumov, Maya Lathi, Meghan Keneally, Miao Liu, Michael L. Seltzer, Michal Valko, Michelle Restrepo, Mihir Patel, Mik Vyatskov, Mikayel Samvelyan, Mike Clark, Mike Macey, Mike Wang, Miquel Jubert Hermoso, Mo Metanat, Mohammad Rastegari, Munish Bansal, Nandhini Santhanam, Natascha Parks, Natasha White, Navyata Bawa, Nayan Singhal, Nick Egebo, Nicolas Usunier, Nikhil Mehta, Nikolay Pavlovich Laptev, Ning Dong, Norman Cheng, Oleg Chernoguz, Olivia Hart, Omkar Salpekar, Ozlem Kalinli, Parkin Kent, Parth Parekh, Paul Saab, Pavan Balaji, Pedro Rittner, Philip Bontrager, Pierre Roux, Piotr Dollar, Polina Zvyagina, Prashant Ratanchandani, Pritish Yuvraj, Qian Liang, Rachad Alao, Rachel Rodriguez, Rafi Ayub, Raghotham Murthy, Raghu Nayani, Rahul Mitra, Rangaprabhu Parthasarathy, Raymond Li, Rebekkah Hogan, Robin Battey, Rocky Wang, Russ Howes, Ruty Rinott, Sachin Mehta, Sachin Siby, Sai Jayesh Bondu, Samyak Datta, Sara Chugh, Sara Hunt, Sargun Dhillon, Sasha Sidorov, Satadru Pan, Saurabh Mahajan, Saurabh Verma, Seiji Yamamoto, Sharadh Ramaswamy, Shaun Lindsay, Sheng Feng, Shenghao Lin, Shengxin Cindy Zha, Shishir Patil, Shiva Shankar, Shuqiang Zhang, Shuqiang Zhang, Sinong Wang, Sneha Agarwal, Soji Sajuyigbe, Soumith Chintala, Stephanie Max, Stephen Chen, Steve Kehoe, Steve Satterfield, Sudarshan Govindaprasad, Sumit Gupta, Summer Deng, Sungmin Cho, Sunny Virk, Suraj Subramanian, Sy Choudhury, Sydney Goldman, Tal Remez, Tamar Glaser, Tamara Best, Thilo Koehler, Thomas Robinson, Tianhe Li, Tianjun Zhang, Tim Matthews, Timothy Chou, Tzook Shaked, Varun Vontimitta, Victoria Ajayi, Victoria Montanez, Vijai Mohan, Vinay Satish Kumar, Vishal Mangla, Vlad Ionescu, Vlad Poenaru, Vlad Tiberiu Mihailescu, Vladimir Ivanov, Wei Li, Wenchen Wang, Wenwen Jiang, Wes Bouaziz, Will Constable, Xiaocheng Tang, Xiaojian Wu, Xiaolan Wang, Xilun Wu, Xinbo Gao, Yaniv Kleinman, Yanjun Chen, Ye Hu, Ye Jia, Ye Qi, Yenda Li, Yilin Zhang, Ying Zhang, Yossi Adi, Youngjin Nam, Yu Wang, Yu Zhao, Yuchen Hao, Yundi Qian, Yunlu Li, Yuzi He, Zach Rait, Zachary DeVito, Zef Rosnbrick, Zhaoduo Wen, Zhenyu Yang, Zhiwei Zhao, and Zhiyu Ma. The Llama 3 Herd of Models. *arXiv:2407.21783*, 2024.

Shibo Hao, Sainbayar Sukhbaatar, DiJia Su, Xian Li, Zhiting Hu, Jason Weston, and Yuandong Tian. Training Large Language Models to Reason in a Continuous Latent Space. In *ICLR*, 2025.

Chaoqun He, Renjie Luo, Yuzhuo Bai, Shengding Hu, Zhen Thai, Junhao Shen, Jinyi Hu, Xu Han, Yujie Huang, Yuxiang Zhang, Jie Liu, Lei Qi, Zhiyuan Liu, and Maosong Sun. OlympiadBench: A Challenging Benchmark for Promoting AGI with Olympiad-Level Bilingual Multimodal Scientific Problems. In *ACL*, 2024.

Neil Houlsby, Andrei Giurgiu, Stanislaw Jastrzebski, Bruna Morrone, Quentin de Laroussilhe, Andrea Gesmundo, Mona Attariyan, and Sylvain Gelly. Parameter-Efficient Transfer Learning for NLP. In *ICML*, 2019.

Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-Rank Adaptation of Large Language Models. In *ICLR*, 2022.

Neel Jain, Ping-yeh Chiang, Yuxin Wen, John Kirchenbauer, Hong-Min Chu, Gowthami Somepalli, Brian R. Bartoldson, Bhavya Kailkhura, Avi Schwarzschild, Aniruddha Saha, Micah Goldblum, Jonas Geiping, and Tom Goldstein. NEFTune: Noisy Embeddings Improve Instruction Finetuning. In *ICLR*, 2024.

Xinyue Kang, Diwei Shi, and Li Chen. Model Whisper: Steering Vectors Unlock Large Language Models’ Potential in Test-time. In *AAAI*, 2026.

Brian Lester, Rami Al-Rfou, and Noah Constant. The Power of Scale for Parameter-Efficient Prompt Tuning. In *EMNLP*, 2021.

Aitor Lewkowycz, Anders Andreassen, David Dohan, Ethan Dyer, Henryk Michalewski, Vinay Ramasesh, Ambrose Slone, Cem Anil, Imanol Schlag, Theo Gutman-Solo, Yuhuai Wu, Behnam Neyshabur, Guy Gur-Ari, and Vedant Misra. Solving Quantitative Reasoning Problems with Language Models. In *NeurIPS*, 2022.

Xiang Lisa Li and Percy Liang. Prefix-Tuning: Optimizing Continuous Prompts for Generation. In *ACL-IJCNLP*, 2021.

487 Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike,
488 John Schulman, Ilya Sutskever, and Karl Cobbe. Let’s Verify Step by Step. In *ICLR*, 2024.

489 Xiao Liu, Yanan Zheng, Zhengxiao Du, Ming Ding, Yujie Qian, Zhilin Yang, and Jie Tang. GPT
490 Understands, Too. *AI Open*, 5:208–215, 2024.

491 Aman Madaan and Amir Yazdanbakhsh. Text and Patterns: For Effective Chain of Thought, It Takes
492 Two to Tango. *arXiv:2209.07686*, 2022.

493 Alexander Robey, Eric Wong, Hamed Hassani, and George J. Pappas. SmoothLLM: Defending Large
494 Language Models Against Jailbreaking Attacks. *Transactions on Machine Learning Research*,
495 2025.

496 Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang,
497 Mingchuan Zhang, Y.K. Li, Y. Wu, and Daya Guo. DeepSeekMath: Pushing the Limits of Math-
498 ematical Reasoning in Open Language Models. *arXiv:2402.03300*, 2024.

499 Guangming Sheng, Chi Zhang, Zilingfeng Ye, Xibin Wu, Wang Zhang, Ru Zhang, Yanghua Peng,
500 Haibin Lin, and Chuan Wu. HybridFlow: A Flexible and Efficient RLHF Framework. In *EuroSys*,
501 2025.

502 Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov.
503 Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *Journal of Machine Learn-
504 ing Research*, 15:1929–1958, 2014.

505 Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2
506 edition, 2018.

507 Shenzhi Wang, Le Yu, Chang Gao, Chuji Zheng, Shixuan Liu, Rui Lu, Kai Dang, Xionghui Chen,
508 Jianxin Yang, Zhenru Zhang, Yuqiong Liu, An Yang, Andrew Zhao, Yang Yue, Shiji Song, Bowen
509 Yu, Gao Huang, and Junyang Lin. Beyond the 80/20 Rule: High-Entropy Minority Tokens Drive
510 Effective Reinforcement Learning for LLM Reasoning. In *NeurIPS*, 2025.

511 Yige Xu, Xu Guo, Zhiwei Zeng, and Chunyan Miao. SoftCoT: Soft Chain-of-Thought for Efficient
512 Reasoning with LLMs. In *ACL*, 2025.

513 An Yang, Beichen Zhang, Binyuan Hui, Bofei Gao, Bowen Yu, Chengpeng Li, Dayiheng Liu,
514 Jianhong Tu, Jingren Zhou, Junyang Lin, Keming Lu, Mingfeng Xue, Runji Lin, Tianyu Liu,
515 Xingzhang Ren, and Zhenru Zhang. Qwen2.5-Math Technical Report: Toward Mathematical
516 Expert Model via Self-Improvement. *arXiv:2409.12122*, 2024.

517 Wengao Ye, Yan Liang, and Lianlei Shan. Thinking on the Fly: Test-Time Reasoning Enhancement
518 via Latent Thought Policy Optimization. In *ICLR*, 2026.

519 Qiying Yu, Zheng Zhang, Ruofei Zhu, Yufeng Yuan, Xiaochen Zuo, Yu Yue, Weinan Dai, Tiantian
520 Fan, Gaohong Liu, Juncai Liu, Lingjun Liu, Xin Liu, Haibin Lin, Zhiqi Lin, Bole Ma, Guangming
521 Sheng, Yuxuan Tong, Chi Zhang, Mofan Zhang, Ru Zhang, Wang Zhang, Hang Zhu, Jinhua Zhu,
522 Jiaze Chen, Jiangjie Chen, Chengyi Wang, Hongli Yu, Yuxuan Song, Xiangpeng Wei, Hao Zhou,
523 Jingjing Liu, Wei-Ying Ma, Ya-Qin Zhang, Lin Yan, Yonghui Wu, and Mingxuan Wang. DAPO:
524 An Open-Source LLM Reinforcement Learning System at Scale. In *NeurIPS*, 2025.

525 Weihao Zeng, Yuzhen Huang, Qian Liu, Wei Liu, Keqing He, Zejun Ma, and Junxian He. SimpleRL-
526 Zoo: Investigating and Taming Zero Reinforcement Learning for Open Base Models in the Wild.
527 In *COLM*, 2025.

528 Guibin Zhang, Muxin Fu, and Shuicheng Yan. MemGen: Weaving Generative Latent Memory for
529 Self-Evolving Agents. In *ICLR*, 2026.

530 A 실험 설정과 전체 정확도 분석

531 Table 6은 본문 Table 1을 보완하여 Prefix와 Suffix 별 전체 정확도를 모델·벤치마크 조합으로 정
 532 리한다(본문 표는 두 위치를 동시 보고하므로 별도 max 가공은 없다). Table 7는 각 모델-벤치마
 533 크 조합에서 사용한 RSP 토큰 수 L 을 정리한 것으로, 후보 집합 $\{10, 15, 20\}$ 에서 선택했다. 모든
 534 실험은 단일 NVIDIA A6000 40GB GPU에서 greedy decoding으로 수행했으며, 최대 생성 길이는
 535 MATH-500과 GSM8K에서 3,072 토큰, AIME24에서 4,096 토큰으로 고정했다. 배치 크기는
 536 모델별로 고정했다(LLaMA-3.1-8B-Instruct와 Qwen2.5-Math-7B 계열은 16, Qwen2.5-Math-1.5B
 537 계열은 32).

Table 6: 모델 설정, 주입 위치, 벤치마크별 정확도(%). 괄호 안 값은 baseline 대비 변화량이다. 굵게는 최고 성능, 밑줄은 각 모델-벤치마크 조합에서 두 번째 성능을 뜻한다.

Model	Mode	MATH-500	GSM8K	AIME24
<i>Instruct Models</i>				
LLaMA-3.1-8B-Instruct	Baseline	52.20	85.75	<u>6.67</u>
	Prefix	45.00 (−7.2)	76.35 (−9.4)	3.33 (−3.3)
	Suffix	<u>49.40</u> (−2.8)	86.73 (+1.0)	10.00 (+3.3)
Qwen2.5-Math-7B-Instruct	Baseline	83.20	95.45	<u>13.33</u>
	Prefix	81.40 (−1.8)	94.92 (−0.5)	<u>13.33</u> (+0.0)
	Suffix	83.40 (+0.2)	95.68 (+0.2)	16.67 (+3.3)
Qwen2.5-Math-1.5B-Instruct	Baseline	73.00	<u>85.29</u>	10.00
	Prefix	74.80 (+1.8)	85.29 (+0.0)	<u>13.33</u> (+3.3)
	Suffix	<u>74.20</u> (+1.2)	84.69 (−0.6)	20.00 (+10.0)
<i>Base Models (Raw Text)</i>				
Qwen2.5-Math-7B	Baseline	72.20	84.15	6.67
	Prefix	<u>71.60</u> (−0.6)	84.31 (+0.2)	16.67 (+10.0)
	Suffix	55.60 (−16.6)	54.13 (−30.0)	<u>13.33</u> (+6.7)
Qwen2.5-Math-1.5B	Baseline	<u>61.40</u>	77.86	16.67
	Prefix	64.40 (+3.0)	<u>74.30</u> (−3.6)	<u>10.00</u> (−6.7)
	Suffix	54.60 (−6.8)	58.61 (−19.3)	3.33 (−13.3)
<i>Base Models + ChatML (Format Mismatch)</i>				
Qwen2.5-Math-7B	Baseline	52.20	58.30	23.33
	Prefix	59.20 (+7.0)	56.41 (−1.9)	<u>3.33</u> (−20.0)
	Suffix	70.40 (+18.2)	75.97 (+17.7)	23.33 (+0.0)
Qwen2.5-Math-1.5B	Baseline	34.40	37.45	<u>13.33</u>
	Prefix	63.40 (+29.0)	67.02 (+29.6)	20.00 (+6.7)
	Suffix	<u>51.00</u> (+16.6)	<u>50.64</u> (+13.2)	<u>13.33</u> (+0.0)

Table 7: 각 모델과 벤치마크에 사용한 RSP 토큰 수(L).

Model	MATH-500	GSM8K	AIME24
LLaMA-3.1-8B-Instruct	15	20	15
Qwen2.5-Math-7B-Instruct	20	20	20
Qwen2.5-Math-1.5B-Instruct	20	10	20
Qwen2.5-Math-7B	10	10	20
Qwen2.5-Math-1.5B	10	10	20
Qwen2.5-Math-1.5B (ChatML)	20	20	10
Qwen2.5-Math-7B (ChatML)	20	20	20

538 A.1 RSP 주입 위치와 프롬프트 템플릿

539 아래에는 모든 모델 유형에서 주입 위치별 프롬프트 구조를 정리했다. **파란색 텍스트**는 RSP
 540 임베딩, **보라색 텍스트**는 특수 토큰을 뜻한다.

541 A.1.1 Prefix

542 Prefix 주입에서는 RSP 임베딩을 프롬프트 임베딩 앞에 연결한다. 텍스트 자체는 수정하지
 543 않는다.

544 **ChatML (Qwen Instruct / Base + ChatML).**

```
[Random Embeddings (L tokens)]
<|im_start|>system
Please reason step by step, and put your final answer within \boxed{}.<|
im_end|>
<|im_start|>user
{question}<|im_end|>
<|im_start|>assistant
```

546 **LLaMA Chat Template.**

```
[Random Embeddings (L tokens)]
<|begin_of_text|>
<|start_header_id|>system<|end_header_id|>
Cutting Knowledge Date: December 2023
Today Date: 26 Jul 2024
Please reason step by step, and put your final answer within \boxed{}.<|
eot_id|>
<|start_header_id|>user<|end_header_id|>
{question}<|eot_id|>
<|start_header_id|>assistant<|end_header_id|>
```

548 **Raw Text (Qwen Base).**

```
[Random Embeddings (L tokens)]
{question}
Please reason step by step, and put your final answer within \boxed{}.
```

550 **A.1.2 Infix**

551 Infix 주입에서는 설명 문구와 특수 토큰을 프롬프트 내부에 넣은 뒤, 그 특수 토큰 위치를 임베딩
552 수준에서 RSP로 교체한다.

553 **ChatML (Qwen Instruct / Base + ChatML).**

```
<|im_start|>system
Please reason step by step, and put your final answer within \boxed{}.<|
im_end|>
<|im_start|>user
{question}

There are {L} special tokens that contain compressed latent reasoning
information that might be useful for your reasoning. If these tokens are
useful for your case, you can use them as reference. If these tokens are
not useful for your case, you can ignore them and focus back to solving the
problem.

Here are the {L} special tokens: <special_token_1>...<special_token_L>
<|im_end|>
<|im_start|>assistant
```

555 **LLaMA Chat Template.**

```
<|begin_of_text|>
<|start_header_id|>system<|end_header_id|>
Cutting Knowledge Date: December 2023
Today Date: 26 Jul 2024
Please reason step by step, and put your final answer within \boxed{}.<|
eot_id|>
<|start_header_id|>user<|end_header_id|>
{question}

There are {L} special tokens that contain compressed latent reasoning
information that might be useful for your reasoning. If these tokens are
useful for your case, you can use them as reference. If these tokens are
```

not useful for your case, you can ignore them and focus back to solving the problem.

Here are the $\{L\}$ special tokens:

```
<reserved_special_token_0>...  
<reserved_special_token_L>  
<|eot_id|>  
<|start_header_id|>assistant<|end_header_id|>
```

557

558 Raw Text (Qwen Base).

{question}

There are $\{L\}$ special tokens that contain compressed latent reasoning information that might be useful for your reasoning. If these tokens are useful for your case, you can use them as reference. If these tokens are not useful for your case, you can ignore them and focus back to solving the problem.

Here are the $\{L\}$ special tokens: $\langle \text{special_token_1} \rangle \dots \langle \text{special_token_L} \rangle$

Please reason step by step, and put your final answer within `\boxed{\}`.

559

560 A.1.3 Suffix

561 채팅 템플릿 모델에서는 end-of-turn 토큰 바로 앞에 RSP 임베딩을 넣고, raw text 모델에서는
562 프롬프트 마지막에 RSP 임베딩을 이어 붙인다.

563 ChatML (Qwen Instruct / Base + ChatML).

```
<|im_start|>system  
Please reason step by step, and put your final answer within \boxed{\}.<|  
im_end|>  
<|im_start|>user  
{question}[Random Embeddings ( $L$  tokens)]<|im_end|>  
<|im_start|>assistant
```

564

565 LLaMA Chat Template.

```
<|begin_of_text|>  
<|start_header_id|>system<|end_header_id|>  
Cutting Knowledge Date: December 2023  
Today Date: 26 Jul 2024  
Please reason step by step, and put your final answer within \boxed{\}.<|  
eot_id|>  
<|start_header_id|>user<|end_header_id|>  
{question}[Random Embeddings ( $L$  tokens)]<|eot_id|>  
<|start_header_id|>assistant<|end_header_id|>
```

566

567 Raw Text (Qwen Base).

```
{question}  
Please reason step by step, and put your final answer within \boxed{\}.[Random  
Embeddings ( $L$  tokens)]
```

568

569 A.2 정답 추출과 채점

570 최종 정답은 fallback 체인을 통해 모델 출력에서 추출한다. 각 단계는 순서대로 시도하며, 추출에
571 실패하면 다음 단계로 넘어간다.

정답 추출 fallback 체인

1. "final answer is \$...\$. I hope" 패턴 (Minerva 형식)
2. `\boxed{...}`: 마지막 비어 있지 않은 box를 사용하고, 빈 `\boxed{}`는 건너뛴
3. "the answer is" 뒤 텍스트
4. "final answer is" 뒤 텍스트
5. 출력 마지막 숫자(regex fallback)

572

573 추출된 정답은 `$`, `\left`, `\right`, 단위 문자열을 제거해 정규화한다. 채점은 sym-
574 bolic equivalence checking으로 수행하며, 정확한 문자열 일치, 수치 비교(`math.isclose`,
575 `rel_tol=1e-4`), SymPy symbolic simplification을 차례로 적용한다.

576 A.3 재현한 선행연구의 하이퍼파라미터

577 모든 선행 방법은 Qwen2.5-Math-1.5B-Instruct와 Qwen2.5-Math-7B-Instruct에서 재현했으며,
578 greedy decoding(`temperature = 0`)과 통일된 answer extraction pipeline으로 평가했다.

579 **TTSV.** *Prefix* 길이는 20이며, AdamW optimizer로 20 epoch 동안 학습했다. 배치 크기는 2,
580 gradient accumulation은 8 step, 스케줄은 선형 learning rate schedule을 사용했다. Learning rate
581 는 Qwen-1.5B에 1e-3, Qwen-7B에 1e-5를 사용했다.

582 **LTPO.** Table 8는 벤치마크별 하이퍼파라미터를 정리한 것이다.

Table 8: LTPO 하이퍼파라미터.

Parameter	GSM8K	MATH-500	AIME24
tokens	8	8	8
steps	20	20	20
top_k	10	10	10
sigma	20	20	5
sigma_decay	0.95	0.95	0.95
lr	1e-2	5e-3	5e-2

583 **SoftCoT.** Projection module은 10 epoch 동안 학습했다. Thought token 수는 학습 시 32, 평가 시
584 4다. 배치 크기는 GSM8K에서 4, MATH에서는 1이며 gradient accumulation 4를 사용했다. 작은
585 모델(assistant)은 두 설정 모두 Qwen2.5-Math-1.5B-Instruct이고, 큰 모델은 Qwen2.5-Math-1.5B-
586 Instruct(`learning rate 2e-5`) 또는 Qwen2.5-Math-7B-Instruct(`learning rate 5e-6`)이다. MATH-500
587 과 AIME24 평가는 GSM8K에서 학습한 projection module을 사용했는데, MATH에서 학습한
588 버전보다 더 높은 정확도를 보였기 때문이다.

589 A.4 전체 엔트로피 곡선

590 Figure 6는 entropy, top-1 probability, varentropy의 전체 정규화 생성 궤적(0-100%)을 보여주고,
591 Table 9는 그에 대응하는 스칼라 통계(전체 평균, 첫 5% 평균, 문제당 평균 생성 토큰 수)를 보고
592 한다. 모든 방법은 생성 초반 단계를 지나면 비슷한 수준으로 수렴하며, 이는 RSP가 유도하는
593 분포 변화가 초기 추론 단계에 국소화되어 있음을 다시 확인해 준다.

Table 9: Qwen2.5-Math-1.5B-Instruct, MATH-500에서 측정한 step별 통계. 전체 생성과 첫 5% 구간의 평균 그리고 문제당 평균 생성 토큰 수를 함께 보고한다. Top-1 Prob (overall)은 첫 10% / 중간 / 마지막 10% 구간 평균을 가중치 0.1/0.8/0.1로 가중평균한 값이다. 본문 Figure 3와 Figure 6의 확장이다.

Metric	Baseline	Prefix	Infix	Suffix	LTPO	SoftCoT	TTSV
Tokens (mean)	575.7	558.4	549.9	573.3	592.3	594.4	577.4
Entropy (first 5%)	0.1332	0.1366	0.1402	0.1941	0.1662	0.4218	0.1359
Entropy (overall)	0.0871	0.0881	0.0899	0.1049	0.0909	0.1059	0.0864
Top-1 Prob (first 5%)	0.9535	0.9523	0.9525	0.9373	0.9437	0.9156	0.9534
Top-1 Prob (overall)	0.9684	0.9681	0.9678	0.9647	0.9683	0.9651	0.9685
Varentropy (first 5%)	0.2181	0.2207	0.2463	0.4010	0.2953	2.2234	0.2174
Varentropy (overall)	0.1353	0.1375	0.1422	0.2038	0.1452	0.2404	0.1361




Figure 6: 전체 정규화 생성 궤적(0-100%)에서의 평균 entropy(위), top-1 probability(가운데), varentropy(아래). MATH-500 전체 평균이며, 음영은 ± 1 SEM을 뜻한다. 실선은 RSP 변형과 baseline, 점선은 prior soft prompt 방법이다. 모든 방법은 초반 단계를 지나면 수렴한다.

594 B 토큰 수준 분포 지표

595 이 부록은 Section 4.4의 토큰 수준 분석에 사용한 세 지표를 형식적으로 정의한다. P_{base} 는 $\tau=1.0$
 596 에서의 baseline 다음 토큰 분포, P_{target} 은 비교 대상 분포(예: $\tau=2.0$ 의 baseline, 또는 $\tau=1.0$ 의
 597 RSP)라 하자. 모든 지표는 첫 생성 단계에서 저장한 logits로부터 해석적으로 계산한다.

598 **Spearman 순위 상관.** Spearman의 ρ 는 두 분포의 토큰 순위 사이 Pearson 상관계수다.

$$\rho = \text{Pearson}(\text{rank}(P_{\text{target}}), \text{rank}(P_{\text{base}})). \quad (4)$$

599 Temperature scaling $P^{(\tau)} \propto P^{1/\tau}$ 는 엄격한 단조 변환이므로, 어떤 $\tau > 0$ 에서도 토큰 순서를
 600 정확히 보존한다. 따라서 $\rho = 1$ 은 수학적 항등식이다. 그러므로 $\rho < 1$ 은 temperature scaling
 601 만으로는 만들 수 없는 순위 재조작이 일어났음을 뜻한다.

602 **Top- K 밖의 질량.** $\text{TopK}(P_{\text{base}})$ 를 P_{base} 에서 확률이 가장 높은 K 개 토큰의 집합이라 하자. 비
 603 교 대상 분포가 이 집합 밖에 두는 확률 질량은

$$\text{MassOutside}_K = 1 - \sum_{t \in \text{TopK}(P_{\text{base}})} P_{\text{target}}(t). \quad (5)$$

604 이 지표는 지지 집합 확장을 직접 측정한다. 즉 baseline의 선호 집합에 없던 토큰에 비교 대상이
 605 얼마나 많은 확률을 배정하는지를 본다. 본문에 보고한 값은 $K = 10$ 을 사용했다.

606 **Jensen-Shannon divergence.** Kullback-Leibler divergence의 대칭적이고 bounded된 형태는 다
 607 음과 같다.

$$\text{JS}(P, Q) = \frac{1}{2} \text{KL}(P \parallel M) + \frac{1}{2} \text{KL}(Q \parallel M), \quad M = \frac{1}{2}(P + Q). \quad (6)$$

608 로그는 밑이 2이므로 $\text{JS} \in [0, 1]$ 이다. 저장한 top-100 바깥의 토큰에는 softmax 전에 sentinel
 609 $\text{logit}(-10^9)$ 을 넣었는데, 본 설정에서는 top-5가 이미 확률 질량의 99.9% 이상을 덮기 때문에 이
 610 근사는 무시 가능하다.

611 C 이론에 필요한 Prompt 법칙의 성질

612 이 부록은 본문에서 실제로 사용하는 성질만 남긴다: 중심성, 분산 예산 아래의 방향 무관 공
613 분산, 그리고 모든 비공집합 열린집합에 대한 양의 확률이다. Section 3.2의 메커니즘에는 이
614 기하학적·측도론적 사실만 필요하므로, 더 강한 의미론적 해석은 쓰지 않는다.

615 C.1 중심화된 섭동은 체계적인 1차 드리프트를 만들지 않는다

616 z_i^{Base} 를 RSP 없는 forward pass의 vocab 토큰 i logit, $z_i^{\text{RSP}}(\bar{h})$ 를 centered RSP 섭동이 $\bar{h}$ 일 때의 logit
617 이라 하자. RSP 하 (참) vocab-logit gap은 $\Delta_{ij}(\bar{h}) := z_i^{\text{RSP}}(\bar{h}) - z_j^{\text{RSP}}(\bar{h})$ 이며, no-RSP baseline gap
618 $\Delta_{ij}^{\text{Base}} := z_i^{\text{Base}} - z_j^{\text{Base}}$ 와 구분된다. $\bar{h} = 0$ 은 centered RSP가 entrywise 평균일 때이지 no-RSP
619 forward pass가 아니므로 일반적으로 $\Delta_{ij}(0) \neq \Delta_{ij}^{\text{Base}}$ 이다. transformer의 logit map은 $\bar{h}$ 에 대해
620 비선형이지만, $\bar{h} = 0$ 주변의 1차 Taylor 전개는 국소 surrogate

$$\Delta_{ij}^{\text{lin}}(\bar{h}) := \Delta_{ij} + b_{ij}^\top \bar{h}$$

621 를 준다. 여기서 $\Delta_{ij} := \Delta_{ij}(0)$ 이고 $b_{ij} := \nabla_{\bar{h}}(z_i^{\text{RSP}} - z_j^{\text{RSP}})|_{\bar{h}=0}$ 이다. 아래 명제는 surrogate
622 Δ_{ij}^{lin} 에 대한 진술이다. 참 비선형 gap $\Delta_{ij}(\bar{h})$ 의 경우, centered 섭동 아래 1차 항은 평균 0이지만
623 Taylor 잔차 $r_{ij}(\bar{h}) = O(\|\bar{h}\|^2)$ 는 2차 평균 편향을 줄 수 있으며 그 부호·크기에 대해서는 주장
624 하지 않는다.

625 **명제 2** (surrogate에서 체계적인 1차 드리프트의 부재). $\mathbb{E}[\bar{h}] = 0$ 이면 모든 토큰 쌍 (i, j) 에 대해

$$\mathbb{E}[\Delta_{ij}^{\text{lin}}(\bar{h})] = \Delta_{ij}$$

626 가 성립한다. 반대로 결정적 centered prompt $\bar{h}_0$ 을 모든 run에 재사용하면

$$\Delta_{ij}^{\text{lin}}(\bar{h}_0) - \Delta_{ij} = b_{ij}^\top \bar{h}_0$$

627 는 고정된 방향 편향이다.

628 *Proof.* 중심화된 경우는 기대값의 선형성으로 바로 나온다.

$$\mathbb{E}[\Delta_{ij}^{\text{lin}}(\bar{h})] = \Delta_{ij} + b_{ij}^\top \mathbb{E}[\bar{h}] = \Delta_{ij}.$$

629 결정적 경우는 그대로 대입하면 된다. □

630 이 명제가 뜻하는 것은 run 평균에서의 1차 편향이 없다는 점이지, 개별 샘플이 logit을 바꾸지
631 않는다는 뜻은 아니다.

632 C.2 Proposition 1의 증명

633 본문의 local linear logit surrogate에 직접 등장하는 양은 단위벡터 b 에 대한 1차 섭동 에너지
634 $\text{Var}_{h \sim D}(b^\top h) = b^\top \Sigma_D b$ 이다. 따라서 최악 방향의 에너지는 Σ_D 의 최소 Rayleigh quotient와
635 같다.

636 *Proposition 1의 증명.* Σ_D 의 고윳값을 $\lambda_1, \dots, \lambda_d$ 라 하면,

$$\lambda_{\min}(\Sigma_D) \leq \frac{1}{d} \sum_{m=1}^d \lambda_m = \frac{\text{tr}(\Sigma_D)}{d} \leq \frac{\rho^2}{d}.$$

637 모든 고윳값이 같을 때, 즉 $\Sigma_D = (\rho^2/d)\mathbf{I}_d$ 일 때 그리고 그럴 때만 등호가 성립한다. □

638 이 증명에는 공분산만 필요하다. RSP에서 가우시안을 택하는 이유는 다음 소절의 열린집합
639 도달 가능성까지 함께 얻기 위해서다.

640 **C.3 등방 가우시안 프롬프트의 열린집합 도달 가능성**

641 **명제 3** (열린집합 도달 가능성). $\sigma > 0$ 이고 $\bar{h} \sim \mathcal{N}(0, \sigma^2 \mathbf{I}_d)$ 라 하자. 그러면 모든 비공집합
 642 열린집합 $U \subseteq \mathbb{R}^d$ 에 대해

$$\Pr(\bar{h} \in U) > 0$$

643 가 성립한다.

644 *Proof.* 가우시안 밀도

$$(2\pi\sigma^2)^{-d/2} \exp\left(-\frac{\|\bar{h}\|^2}{2\sigma^2}\right)$$

645 는 $\mathbb{R}^d$ 의 모든 점에서 엄밀히 양수다. 모든 비공집합 열린집합은 양의 르베그 측도를 갖는 ball
 646 하나를 포함하므로, 그 ball 위에서 양의 밀도를 적분하면 양의 확률이 얻어진다. $\square$

647 이것이 §3.2의 informal 분기 영역 논변과 Appendix D.3.3에서 쓰이는 유일한 support 성질이다.

648 D 본문 이론 결과의 증명

649 이 부록은 본문 이론결과와 같은 순서를 따른다: exploration, annealing, 성능 향상. 그보다 앞에서
650 필요한 prompt 법칙의 성질은 Appendix C에 모아 두었다.

651 D.1 Exploration: attention decomposition과 perturbation 크기

652 **명제 4** (Attention decomposition). *Layer ℓ 의 한 attention head가 query 위치 i 에서 마스크되지*
653 *않은 실제 토큰 $n \geq 1$ 개와 RSP 토큰 $L \geq 1$ 개를 attend하며, attention logit은 모두 유한하다고*
654 *하자. Attention weight를 $\alpha_{ij}^{(\ell)}$ 로 두고, RSP attention mass를*

$$w_{r,i}^{(\ell)} := \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)}$$

655 로 두고, $j \in [n]$ 에 대해

$$\tilde{\alpha}_{ij}^{(\ell)} := \frac{\alpha_{ij}^{(\ell)}}{1 - w_{r,i}^{(\ell)}}$$

656 라 정의하면,

$$\mathbf{o}_i^{(\ell)} = (1 - w_{r,i}^{(\ell)}) \tilde{\mathbf{o}}_i^{(\ell)} + \boldsymbol{\eta}_i^{(\ell)}$$

657 이고

$$\tilde{\mathbf{o}}_i^{(\ell)} := \sum_{j=1}^n \tilde{\alpha}_{ij}^{(\ell)} \mathbf{v}_j^{(\ell)}, \quad \boldsymbol{\eta}_i^{(\ell)} := \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{r_j}^{(\ell)}.$$

658 *Proof.* Head output은 실제 토큰 항과 RSP 토큰 항으로 정확히 나뉜다.

$$\mathbf{o}_i^{(\ell)} = \sum_{j=1}^n \alpha_{ij}^{(\ell)} \mathbf{v}_j^{(\ell)} + \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{r_j}^{(\ell)}.$$

659 마스크되지 않은 실제 토큰이 있고 softmax 가중치가 양수이므로 $\sum_{j=1}^n \alpha_{ij}^{(\ell)} = 1 - w_{r,i}^{(\ell)} > 0$
660 이다. 따라서 실제 토큰 항은

$$\sum_{j=1}^n \alpha_{ij}^{(\ell)} \mathbf{v}_j^{(\ell)} = (1 - w_{r,i}^{(\ell)}) \sum_{j=1}^n \frac{\alpha_{ij}^{(\ell)}}{1 - w_{r,i}^{(\ell)}} \mathbf{v}_j^{(\ell)} = (1 - w_{r,i}^{(\ell)}) \tilde{\mathbf{o}}_i^{(\ell)}$$

661 가 된다. 이를 대입하면 분해가 바로 따른다. □

662 **따름정리 1** (크기는 RSP attention mass로 통제된다). 무작위 value가 어떤 값으로 실현되었든,

$$\|\boldsymbol{\eta}_i^{(\ell)}\| \leq w_{r,i}^{(\ell)} \max_{j \in [L]} \|\mathbf{v}_{r_j}^{(\ell)}\|.$$

663 *Proof.* 삼각부등식을 쓰면

$$\|\boldsymbol{\eta}_i^{(\ell)}\| = \left\| \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{r_j}^{(\ell)} \right\| \leq \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \|\mathbf{v}_{r_j}^{(\ell)}\| \leq w_{r,i}^{(\ell)} \max_{j \in [L]} \|\mathbf{v}_{r_j}^{(\ell)}\|.$$

664 □

665 Corollary 1가 본문에 필요한 유일한 정량적 사실이다. Attention weight와 random key 사이의 독
666 립성은 가정하지 않는다. $w_{r,i}^{(\ell)}$ 가 작아지면 RSP 기여의 크기도 같은 스칼라에 의해 작게 묶인다.

667 D.2 Theorem 1의 따름정리

668 **따름정리 2** (fixed-gap envelope의 시퀀스 방향 단조 감소). L 과 $\Delta_i^{(\ell)}$ 를 고정하면, 상계 $f(n) =$
 669 $L/(L + n \exp(\Delta_i^{(\ell)}/\sqrt{d_{\text{head}}}))$ 는 n 에 대해 엄격히 감소하고 $n \rightarrow \infty$ 에서 0으로 수렴한다. 따라서
 670 같은 gap이 유지된다는 가정 아래, cache 성장만으로 그 gap과 양립 가능한 최대 RSP attention
 671 mass의 envelope이 단조롭게 줄어진다.

672 자기회귀 디코딩에서는 새 토큰이 생성될 때마다 query · key · hidden state가 함께 갱신되어 $\Delta_i^{(\ell)}$
 673 도 step별로 변하므로, “실현된 mass가 매 step 단조 감소”가 아니라 “같은 gap이 유지되는 한
 674 가능한 최대 mass의 envelope이 단조 감소한다”가 정확한 진술이다.

675 *Proof.* $f'(n) = -L \exp(\Delta_i^{(\ell)}/\sqrt{d_{\text{head}}}) / (L + n \exp(\Delta_i^{(\ell)}/\sqrt{d_{\text{head}}}))^2 < 0$ 이므로 엄격히 감소한다.
 676 또한 분자는 고정되어 있고 분모는 n 에 대해 선형으로 발산하므로 $f(n) \rightarrow 0$ 이다. $\square$

677 **따름정리 3** (고정 gap envelope 아래의 RSP 기여 감쇠). L 과 $\Delta_i^{(\ell)}$ 를 고정하고 $n \rightarrow \infty$ 이면
 678 $w_{r,i}^{(\ell)} \rightarrow 0$ 이고, RSP value의 고정된 실현에 대해 $\|\eta_i^{(\ell)}\| \leq w_{r,i}^{(\ell)} \max_{j \in [L]} \|\mathbf{v}_{r,j}^{(\ell)}\| \rightarrow 0$ 이다.

679 *Proof.* Corollary 2에서 $w_{r,i}^{(\ell)} \rightarrow 0$ 이고, Corollary 1의 상계를 그대로 적용하면 된다. 유한한
 680 개수의 sampled value에 대한 최대 norm은 고정 실현에서 유한하다. $\square$

681 D.3 성능 향상: local admission에서 Pass@N까지

682 이 절부터는 layer-wise 표기 ℓ 을 떼고 vocab logit · task 수준에서 작업한다. 본문은 1차 surrogate
 683 위에서 두 가지를 주장한다: §3.2의 “baseline 밖 vocab 토큰이 국소 top- K 집합에 진입할 수
 684 있다”와 §3.3 끝의 “독립 재실행이 그런 국소 진입을 Pass@N 이득으로 바꾼다”. 아래 증명은
 685 centered prompt 법칙 D 의 다음 support 조건만 사용한다.

$$(S1) \quad D(U) > 0 \quad \text{for every nonempty open set } U \subseteq \mathbb{R}^d.$$

686 Section 3.2의 등방 가우시안 법칙은 Proposition 3에 의해 (S1)을 만족한다.

687 D.3.1 자기회귀 정식화

688 자기회귀 decoding에서 시퀀스 $y_{1:T}$ 의 결합 분포는

$$\Pr(y_{1:T} \mid x) = \prod_{t=1}^T p(y_t \mid x, y_{<t}),$$

689 로 분해된다. 각 단계는 prefix에 조건부인 분포로 결정되므로, RSP가 도입한 섭동은 단일한
 690 전역 분포를 한 번에 바꾸는 것이 아니라 $p(y_t \mid x, y_{<t})$ 에 대한 일련의 국소 변화로 작동한다.

691 D.3.2 RSP 하에서의 logits 국소 선형화

692 이 소절에서 $\bar{h} \in \mathbb{R}^d$ 는 RSP 정의(Eq. (1) in §3.1)에 등장하는 centered prompt 벡터 하나를 뜻
 693 한다. 실제 구현은 길이 L 의 prompt $\mathbf{H} = (h_1, \dots, h_L)$ 를 사용하지만, 아래 논리는 개별 국소
 694 섭동이 logits를 어떻게 움직일 수 있는지를 분리해서 본다. 섭동된 logits를 $z_i(\bar{h})$ 로 두고 $\bar{h} = 0$
 695 근방에서 국소 smoothness를 가정하면

$$z_i(\bar{h}) = z_i(0) + \nabla_{\bar{h}} z_i(0)^\top \bar{h} + r_i(\bar{h}),$$

696 여기서 $r_i(\bar{h}) = O(\|\bar{h}\|^2)$ 이다. $a_i := \nabla_{\bar{h}} z_i(0)$, $z_i := z_i(0)$ 라 두면 1차 affine surrogate는

$$z_i^{\text{lin}}(\bar{h}) := z_i + a_i^\top \bar{h}$$

697 가 된다. 이는 branch opening을 설명하는 1차 surrogate이지, transformer logits 전체의 정확한
 698 전역 모델은 아니다.

699 **D.3.3 Top- K 진입 영역 (Remark)**

700 본문 §3.2의 informal 논변을 보충한다. 진입 영역

$$\mathcal{G}_{i,K} := \{\bar{h} \in \mathbb{R}^d : \#\{j \neq i : z_j^{\text{lin}}(\bar{h}) > z_i^{\text{lin}}(\bar{h})\} \leq K - 1\}$$

701 이 비공집합 열린집합 U 를 포함하면 (S1)에 의해 $D(U) > 0$ 이고, $U \subseteq \mathcal{G}_{i,K}$ 이므로 $\Pr_{\bar{h}}(\bar{h} \in$
 702 $\mathcal{G}_{i,K}) \geq D(U) > 0$ 이다. 실용적 충분조건은 어떤 $\bar{h}_0$ 에서 토큰 i 가 많아야 $K - 1$ 개의 토큰만
 703 자신보다 앞서도록 엄격한 마진을 만드는 경우이며, 연속성에 의해 그 근방 비공집합 열린집합이
 704 $\mathcal{G}_{i,K}$ 에 포함된다. 이는 단조 변환인 temperature sampling으로는 도달할 수 없는 rank-changing
 705 사건이지만, (M1)을 자동으로 도출하지는 않는다.

706 **D.3.4 Pass@ N Ensemble 식 (Remark)**

707 본문의 $\Pr(\text{Pass@}N \text{ on } x) \geq 1 - (1 - p_{\min}(x))^N$ 은 standard 독립 Bernoulli 시행 합집합 식이다. A_n
 708 을 문제 x 에서 n 번째 실행이 정답 궤적에 도달하는 사건이라 하고 (M1)에 따라 $\Pr(A_n) \geq p_{\min}(x)$
 709 라 하면, (M2) 아래

$$\Pr\left(\bigcap_{n=1}^N A_n^c\right) \leq (1 - p_{\min}(x))^N, \quad \Pr\left(\bigcup_{n=1}^N A_n\right) \geq 1 - (1 - p_{\min}(x))^N \geq 1 - e^{-N p_{\min}(x)}.$$

710 RSP에 특이적이지 않은 generic 사실이며, RSP의 역할은 (M1, M2)를 만족시키는 메커니즘에
 711 한정된다.

E Attention Mass 분석

이 부록은 Figure 2에 보고한 per-token attention mass를 형식화하고, reasoning span과 layer 축에 적용한 제외 기준을 명시한다. 500개의 MATH-500 문제 각각에 대해 새로운 $\mathbf{RSP} \mathbf{H} \in \mathbb{R}^{L \times d}$ 를 $L = 10$ 으로 독립 샘플링했으므로, 보고한 heatmap은 문제 자체의 변동성과 RSP 벡터 변동성을 함께 평균한 결과다.

E.1 토큰당 attention 질량

각 문제에서 attention은 연결된 시퀀스 [prompt; $\mathbf{H}$; generation] 위에서 측정하며, generation은 같은 모델이 동일한 RSP 주입 설정 아래 생성한 궤적이다. $\alpha_{i,j}^{(\ell,a)}$ 를 layer ℓ , head index a (RSP 행렬 $\mathbf{H}$ 와의 충돌을 피하기 위해 head 인덱스로 a 를 사용)에서 query 위치 i 가 key 위치 j 로 보내는 post-softmax attention weight라고 하자. 이는 causal mask 아래에서 $\sum_j \alpha_{i,j}^{(\ell,a)} = 1$ 을 만족한다. 질문 토큰과 RSP 토큰의 인덱스 집합을 각각 Q , R 라 하고 크기를 $|Q|$, $|R| = L$, head 수를 N_{head} 라 하자. 이때 query i 가 각 그룹으로 보내는 layer ℓ 의 per-token attention mass는

$$\text{PTM}_Q[\ell, i] = \frac{1}{|Q| N_{\text{head}}} \sum_{a=1}^{N_{\text{head}}} \sum_{j \in Q} \alpha_{i,j}^{(\ell,a)}, \quad \text{PTM}_R[\ell, i] = \frac{1}{|R| N_{\text{head}}} \sum_{a=1}^{N_{\text{head}}} \sum_{j \in R} \alpha_{i,j}^{(\ell,a)}. \quad (7)$$

$|Q|$ 와 $|R|$ 로 나누는 정규화는 집합 크기 차이를 보정하므로, 두 양은 동일한 softmax 분모 아래에서 질문 토큰 또는 RSP 토큰 하나가 평균적으로 얼마나 많은 attention을 받는지를 나타낸다. 따라서 질문 토큰은 시퀀스 길이 효과를 흡수하는 크기 보정 baseline 역할을 한다.

E.2 Heatmap 집계

Layer 인덱스와 reasoning position 인덱스를 각각 동일 크기의 다섯 구간 $\{B_L^{(b)}\}_{b=1}^5$, $\{B_P^{(b)}\}_{b=1}^5$ 로 나눈다. 샘플 s 와 목표 집합 $\bullet \in \{Q, R\}$ 에 대해 셀 (b_L, b_P) 의 값은

$$M_{\bullet}^{(s)}[b_L, b_P] = \frac{1}{|B_L^{(b_L)}| \cdot |B_P^{(b_P)}|} \sum_{\ell \in B_L^{(b_L)}} \sum_{i \in B_P^{(b_P)}} \text{PTM}_{\bullet}[\ell, i]. \quad (8)$$

Figure 2는 Eq. (8)를 500개의 유효 샘플에 대해 평균한 결과를 보고한다.

E.3 \boxed{\dots} 구간 제외

Reasoning position 범위는 마지막 \boxed{\dots} 구간이 시작되기 직전에 끝나도록 잡는다. Chain-of-thought 출력은 *text*(내용)와 *pattern*(형식) 성분으로 나뉘며, 이 둘은 downstream 성능에 독립적으로 기여할 수 있다 [Madaan and Yazdanbakhsh, 2022]. \boxed{\dots} 래퍼는 전형적인 pattern 성분이다. 이는 추론을 더 전개하기보다는 답 형식을 마무리하는 짧고 정형화된 span이기 때문이다. 이 구간을 포함하면 reasoning dynamics와 무관한 template-driven attention signature가 섞이게 된다.

E.4 마지막 두 레이어 제외

Layer 축에서는 마지막 두 transformer layer도 제외한다. 이는 모델 특이적 tuning이 아니라, late layer에서 나타나는 표준적 현상을 피하기 위한 선택이다.

출력 투영 특화. 마지막 레이어 근방의 hidden state는 vocabulary logits와 거의 선형 관계를 이루므로, 표현을 바꾸는 블록이라기보다 점진적 선형 readout으로 기능한다 [Belrose et al., 2023]. 같은 맥락에서 late-layer feed-forward module도 출력 분포를 조정하는 메커니즘으로 해석되어 왔다 [Geva et al., 2021]. 따라서 이 레이어들의 attention은 reasoning computation보다 output formation을 더 강하게 반영한다.

마지막 두 레이어를 제외하면 heatmap이 readout 단계보다 reasoning 단계의 attention dynamics에 더 집중한다. 이 제외는 본문 claim에 필수적이지 않다. 본문이 강조하는 시퀀스 방향 *attenuation*은 이 제외 없이도 관찰되며, Theorem 1이 다루는 것도 layer 방향 단조성이 아니라 sequence-direction attenuation이기 때문이다.

750 E.5 추가적인 suffix heatmap

751 Figure 7는 suffix 주입에서 Qwen2.5-Math-1.5B-Instruct와 LLaMA-3.1-8B-Instruct에 대해 동일한
 752 per-token RSP attention 분석을 보고한다. 앞서 설명한 late-layer 이유 때문에 모든 셀에서 패턴이
 753 완전히 동일하게 일반화되지는 않지만, 두 모델 모두에서 시퀀스 방향(가로축)의 단조 감소는
 754 §3.3의 cache-growth upper envelope가 예측한 것과 일치한다. layer 축(세로)의 추가 감소는 별
 755 개의 경험적 sharpening 현상으로, Theorem 1만으로 직접 따라오는 결과는 아니다.




Figure 7: 나머지 두 모델(각각 500개 MATH-500 샘플)에서 suffix 주입 시 측정한 per-token RSP attention mass. 축과 전처리는 Figure 2와 동일하다. x축은 다섯 분위로 나눈 reasoning position, y축은 다섯 분위로 나눈 layer depth(위가 얇은 층), 색은 RSP 토큰에 할당된 per-token attention의 500샘플 평균을 뜻한다. `\boxed{ }` 구간 내부 토큰과 마지막 두 레이어는 제외했다.

756 F DAPO 구현

757 이 부록은 §5을 보충하여 GRPO 대비 DAPO 손실 변경, DAPO + RSP 구현, 그리고 step별 전체
758 결과를 정리한다.

759 F.1 GRPO에서 DAPO로

760 원본 GRPO [Shao et al., 2024]는 보상 $\{R_i\}_{i=1}^G$ 를 갖는 G 개 rollout $\{y_i\}_{i=1}^G$ (각 $y_i =$
761 $(y_{i,1}, \dots, y_{i,|y_i|})$ 는 토큰 시퀀스다. §3.2의 head output $\mathbf{o}_i^{(\ell)}$ 와의 표기 충돌을 피하려고 본 부
762 록 전반에서 o 대신 y 를 쓴다)에 대해 다음 목적함수를 사용한다.

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} \left(\min(r_{i,t} \hat{A}_{i,t}, \text{clip}(r_{i,t}, 1-\varepsilon, 1+\varepsilon) \hat{A}_{i,t}) - \beta D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}}) \right) \right], \quad (9)$$

763 여기서 importance ratio는 $r_{i,t} = \pi_\theta(y_{i,t} | q, y_{i,<t}) / \pi_{\theta_{\text{old}}}(y_{i,t} | q, y_{i,<t})$, 그룹 상대 advantage는
764 $\hat{A}_{i,t} = (R_i - \text{mean}(\{R_i\})) / \text{std}(\{R_i\})$, ε 는 clipping 범위, βD_{KL} 은 reference π_{ref} 에 대한 KL 페
765 널티다.

766 학습 파이프라인은 SimpleRL-Zoo [Zeng et al., 2025]를 기반으로 하고 DAPO를 VeRL [Sheng
767 et al., 2025] 위에서 구현한다. DAPO는 Eq. (9)를 네 가지 측면에서 수정한다. (i) 토큰 단위 손실
768 집계 $1/\sum_i |y_i|$ ($1/|y_i|$ 대신), (ii) 비대칭 clipping ($\varepsilon_{\text{low}}, \varepsilon_{\text{high}} = (0.2, 0.28)$), (iii) 음수 advantage
769 안전장치인 구현 측 dual-clipping $\max(L_{\text{clipped}}, c\hat{A})$ ($c = 10$, $\hat{A} < 0$ 일 때만 발동; 가독성을 위해
770 아래 Eq. (10)에서는 생략), (iv) KL 항 제거. 결과적으로 DAPO 목적함수는

$$\mathcal{J}_{\text{DAPO}}(\theta) = \mathbb{E} \left[\frac{1}{\sum_i |y_i|} \sum_{i,t} \min(r_{i,t} \hat{A}_{i,t}, \text{clip}(r_{i,t}, 1-\varepsilon_{\text{low}}, 1+\varepsilon_{\text{high}}) \hat{A}_{i,t}) \right]. \quad (10)$$

771 F.2 DAPO + RSP 구현

772 DAPO + RSP에서는 추가로 rollout별 RSP $\mathbf{H}_i \in \mathbb{R}^{L \times d}$ ($L = 20$)를 각 rollout에 주입한다. 각 $\mathbf{H}_i$
773 는 step별 rollout seed로 결정적으로 생성하고 forward hook으로 주입하므로 학습 가능 파라미터
774 가 아니다. 따라서 학습 신호는 학습된 prompt에서 오는 것이 아니라, policy가 임의의 $\mathbf{H}_i$ 에 적
775 응하는 데서 온다. rollout 시점과 update 시점 모두에서 $\mathbf{H}_i$ 를 log-prob에 포함해 RSP-conditioned
776 분포에 대한 on-policy 업데이트를 유지한다(off-policy mismatch 회피). prompt당 $G = 8$ rollouts
777 에서 각 rollout은 독립 추천된 $\mathbf{H}_i$ 를 받는다.

Table 10: Qwen2.5-Math-7B에서의 DAPO / DAPO + RSP 학습 설정.

항목	값
학습 데이터	MATH Level 3-5 subset (simplelr_math_35, 약 8,500 prompt)
Prompt template	qwen-boxed
학습 배치 크기	1024
PPO mini-batch 크기	256 (rollout당 4회 PPO 업데이트)
prompt당 rollout 수 G	8
최대 prompt / response 길이	2,028 / 2,048
Rollout sampling	temperature 1.0, top- p 1.0, top- k 50
$(\epsilon_{\text{low}}, \epsilon_{\text{high}})$	(0.2, 0.28)
Dual clip c	10.0
손실 집계	token-mean ($1/\sum_i y_i $)
KL 항	사용 안 함
Entropy 계수	0
Optimizer	AdamW, learning rate 5×10^{-7} (constant), warmup 없음
총 학습	약 10 epoch, ≥ 80 최적화 step
저장 / 평가 주기	매 10 step
RSP (DAPO + RSP에만)	suffix 주입, $L = 20$, rollout마다 새로 추첨
하드웨어	4× NVIDIA B200 GPU
실측 학습 시간	run당 약 12시간

780 저장된 각 체크포인트는 HuggingFace 형식으로 변환한 뒤 SimpleRL-Zoo
 781 eval_math_nodes.sh 파이프라인으로 평가한다. 작은 경시대회 셋의 분산을 줄이기
 782 위해 벤치마크별로 sampling 파라미터를 다르게 둔다.

Table 11: SimpleRL-Zoo sh/eval.sh의 벤치마크별 평가 프로토콜.

벤치마크	문제 수	Temperature	n_{sampling}	Metric
AIME 2024	30	1.0	32	Avg@32
AMC 2023	40	1.0	32	Avg@32
MATH-500	500	0.0	1	accuracy (mean@1)
GSM8K	1,319	0.0	1	accuracy
OlympiadBench	675	0.0	1	accuracy
Minerva Math	272	0.0	1	accuracy
GaoKao 2023-EN	385	0.0	1	accuracy

783 모든 벤치마크에서 최대 생성 토큰 수는 16,000이다. 보고하는 평균은 5개 벤치마크(GSM8K,
 784 MATH-500, College Math, Minerva Math, AIME 2024)의 가중치 없는 평균이다.

Table 12: 체크포인트별 5-벤치마크 평균 정확도(%): GSM8K, MATH-500, College Math, Minerva Math, AIME 2024 기준. 굵게는 각 방법의 peak.

Step	DAPO	DAPO + RSP
0	30.06	30.06
10	46.40	46.22
20	49.02	49.54
30	49.58	50.72
40	50.62	52.06
50	50.88	52.40
60	51.84	52.96
70	52.52	53.86
80	53.20	54.04
90	52.52	54.36
100	50.54	53.64

786 G 광범위한 영향

787 본 연구는 무작위 임베딩 주입이 대형 언어 모델의 추론 행동에 어떤 영향을 주는지에 대한
788 실험적·이론적 분석을 제공한다. 기여의 성격은 주로 기초 연구에 가깝지만, GRPO와 같은
789 강화학습 기반 추론 모델 후속학습에는 잠재적 함의를 가진다.

790 **긍정적 영향.** RSP가 유도하는 궤적 다양성은 group-relative advantage estimation 안에서 더
791 풍부한 학습 신호를 제공함으로써, RL 기반 LLM 후속학습의 sample efficiency를 높일 수 있다.
792 이는 reasoning 중심 fine-tuning과 alignment에 필요한 계산 비용을 줄여, 자원이 제한된 연구
793 그룹에도 관련 방법을 더 접근 가능하게 만들 수 있다.

794 **잠재적 우려.** LLM의 유효 출력 지지 집합을 넓히는 방법은 바람직한 대안적 추론 경로뿐
795 아니라, 바람직하지 않거나 분포 밖에 있는 출력의 도달 가능성도 함께 높일 수 있다. 따라서
796 RSP를 실제 시스템에 적용할 때는 이를 독립적인 다양성 원천으로만 보지 말고, 기존의 안전
797 필터링 및 alignment 메커니즘과 함께 사용해야 한다.

798 **영향 범위의 한계.** 본 연구는 새로운 모델이나 데이터셋을 배포하기보다 분석을 제공하는 데
799 초점을 두므로, 직접적인 사회적 영향은 제한적이다. 여기서 논의한 더 넓은 함의는 RSP가 실제
800 학습 파이프라인에 통합되는 향후 연구가 이루어질 때에만 현실화될 수 있다.

NeurIPS Paper Checklist

1. Claims

Question: Do the main claims made in the abstract and introduction accurately reflect the paper’s contributions and scope?

Answer: [\[Yes\]](#)

Justification: The abstract and §1 state four scoped claims, each tied to a section: (i) RSP’s contribution at each attention layer is captured by a single scalar with a fixed-gap upper-envelope cache-growth bound (Theorem 1, §3.3); (ii) under a local affine surrogate, isotropic re-sampling reaches top- K entry regions unattainable by rank-preserving temperature sampling (§3.2); (iii) RSP raises early-token entropy and stabilizes later, with Pass@ N gains under independent re-sampling (§4); and (iv) the diversity transfers to RL training when combined with DAPO (§5). We do not claim a theorem that directly explains the format-mismatch recovery (Table 1); the wrong-attractor hypothesis there is explicitly informal.

2. Limitations

Question: Does the paper discuss the limitations of the work performed by the authors?

Answer: [\[Yes\]](#)

Justification: Limitations are noted in several places rather than in a dedicated section: (a) the multi-path Pass@ N argument requires the task-side assumption $p_{\min}(x) > 0$, flagged in §3.2 and §6; (b) the +18–29 pp recovery on the format-mismatch rows of Table 1 is empirically observed but not formally derived from any theorem in §3, with the wrong-attractor account stated as a hypothesis to be quantified in future work (§4.2); (c) Table 1 reports the best-position accuracy across {Prefix, Infix, Suffix}, and per-position variance is large with several cases below baseline (Appendix A), so position is treated as a hyperparameter rather than something we justify principally; (d) DAPO + RSP results (§5) use a single training seed under a reduced DAPO configuration that omits Dynamic Sampling and over-long reward shaping; (e) main accuracy comparisons are single-seed without bootstrap or significance tests (item 7). Future work in §6 addresses training-time comparisons, domain expansion, and principled position selection.

3. Theory assumptions and proofs

Question: For each theoretical result, does the paper provide the full set of assumptions and a complete (and correct) proof?

Answer: [\[Yes\]](#)

Justification: Theorem 1 (cache-growth attenuation) carries an inline proof in §3.3. Proposition 1 is stated in §3.2 with its proof in Appendix C; the supporting top- K entry and Pass@ N ensemble arguments around it are presented as informal discussion in §3.2 with formal write-ups in the appendix. Each statement explicitly lists its assumptions: finite logits and $n, L \geq 1$ for Theorem 1; finite second-moment budget for Proposition 1; and the locally affine surrogate plus $p_{\min}(x) > 0$ task-side condition together with mutual independence of the N runs for the Pass@ N argument.

4. Experimental result reproducibility

Question: Does the paper fully disclose all the information needed to reproduce the main experimental results of the paper to the extent that it affects the main claims and/or conclusions of the paper (regardless of whether the code and data are provided or not)?

Answer: [\[Yes\]](#)

Justification: §4.1 and Appendix A specify benchmarks (MATH-500, GSM8K, AIME 2024 in the main table; further sets used for the DAPO study), models (LLaMA-3.1-8B-Instruct and Qwen2.5-Math 1.5B/7B variants), the RSP injection grid (Prefix/Infix/Suffix; $L \in \{10, 15, 20\}$), greedy decoding, and the answer extraction pipeline. Appendix F provides the full DAPO + RSP training recipe (batch of 1,024 prompts, $G = 8$ rollouts per prompt at $\tau = 1.0$, four PPO mini-batch updates of 256 prompts each, 100 training steps, suffix RSP $L = 20$ during rollouts only).

5. Open access to data and code

Question: Does the paper provide open access to the data and code, with sufficient instructions to faithfully reproduce the main experimental results, as described in supplemental material?

Answer: [No]

Justification: All datasets and base models used in the paper are publicly available and cited (MATH-500, GSM8K, AIME 2024, AMC 2023, OlympiadBench, Minerva Math, GaoKao 2023-EN, College Math; Qwen2.5-Math 1.5B/7B and LLaMA-3.1-8B-Instruct). RSP itself is described to a level of detail sufficient for re-implementation (Eq. (1) and §4.1). However, our RSP injection harness and DAPO + RSP training pipeline are not yet released; we will release an anonymized implementation alongside the camera-ready submission.

6. Experimental setting/details

Question: Does the paper specify all the training and test details (e.g., data splits, hyperparameters, how they were chosen, type of optimizer) necessary to understand the results?

Answer: [Yes]

Justification: §4.1 and Appendix A list all benchmarks, models, RSP injection settings (positions, lengths, per-row L choice in Appendix Table 7), maximum generation length per benchmark, and decoding strategy. Appendix F provides the full DAPO + RSP training settings, including optimizer, batch composition, mini-batch updates, asymmetric clipping range $(\epsilon_{\text{low}}, \epsilon_{\text{high}}) = (0.2, 0.28)$, dual clipping safeguard, and RSP injection protocol during rollouts.

7. Experiment statistical significance

Question: Does the paper report error bars suitably and correctly defined or other appropriate information about the statistical significance of the experiments?

Answer: [No]

Justification: Pass@ N experiments use $N = 16$ samples per problem (§4.4), Table 3 reports mean±standard deviation over 16 RSP seeds, and AIME 2024 is scored by Avg@32 to reduce variance. However, Table 1 (Table 1) reports single-run accuracies without bootstrap confidence intervals or paired tests, and the DAPO + RSP training in §5 uses a single training seed. Multi-seed evaluation, particularly on small competition sets (AIME 2024, AMC 2023) where variance is highest, is left for future work.

8. Experiments compute resources

Question: For each experiment, does the paper provide sufficient information on the computer resources (type of compute workers, memory, time of execution) needed to reproduce the experiments?

Answer: [Yes]

Justification: Inference experiments (Tables 1, 2; Figure 3) run on a single NVIDIA A6000 40GB GPU with greedy decoding (Appendix A). DAPO + RSP training (§5) runs on 4× NVIDIA B200 GPUs for approximately 12 hours per run (Appendix F, hardware row of the configuration table).

9. Code of ethics

Question: Does the research conducted in the paper conform, in every respect, with the NeurIPS Code of Ethics <https://neurips.cc/public/EthicsGuidelines?>

Answer: [Yes]

Justification: The work uses publicly available math reasoning benchmarks and pretrained language models, involves no human subjects or personal data, and does not introduce a release that bypasses standard model-safety considerations. We have reviewed the NeurIPS Code of Ethics and identify no conflicts.

10. Broader impacts

Question: Does the paper discuss both potential positive societal impacts and negative societal impacts of the work performed?

Answer: [Yes]

Justification: Appendix G discusses both directions: positive impact via more sample-efficient RL post-training of reasoning LLMs, and a potential downside that broadening the effective output support also increases reachability of undesirable trajectories, which we argue should keep RSP coupled with existing safety filtering rather than replacing it.

11. Safeguards

Question: Does the paper describe safeguards that have been put in place for responsible release of data or models that have a high risk for misuse (e.g., pre-trained language models, image generators, or scraped datasets)?

Answer: [N/A]

Justification: The paper does not release new pretrained models, generative systems, or scraped datasets. RSP is a generation-time perturbation applied to existing pretrained models and introduces no separate artifact requiring safeguards.

12. Licenses for existing assets

Question: Are the creators or original owners of assets (e.g., code, data, models), used in the paper, properly credited and are the license and terms of use explicitly mentioned and properly respected?

Answer: [Yes]

Justification: All datasets (MATH-500 [Lightman et al., 2024], GSM8K [Cobbe et al., 2021], AIME 2024, AMC 2023, OlympiadBench [He et al., 2024], Minerva Math [Lewkowycz et al., 2022], GaoKao 2023-EN, College Math) and pretrained models (Qwen2.5-Math [Yang et al., 2024], LLaMA-3.1 [Grattafiori et al., 2024]) are publicly available and cited at first use. The training pipeline builds on SimpleRL-Zoo [Zeng et al., 2025] and VeRL [Sheng et al., 2025], also cited. Each asset is used under its original publicly stated terms.

13. New assets

Question: Are new assets introduced in the paper well documented and is the documentation provided alongside the assets?

Answer: [N/A]

Justification: The paper does not release new datasets or pretrained models. The implementation code planned for camera-ready release (item 5) will be accompanied by configuration files and a README; no derived dataset or model checkpoint is part of the submission.

14. Crowdsourcing and research with human subjects

Question: For crowdsourcing experiments and research with human subjects, does the paper include the full text of instructions given to participants and screenshots, if applicable, as well as details about compensation (if any)?

Answer: [N/A]

Justification: The paper involves no crowdsourcing and no research with human subjects. All evaluations use static, publicly available math reasoning benchmarks.

15. Institutional review board (IRB) approvals or equivalent for research with human subjects

Question: Does the paper describe potential risks incurred by study participants, whether such risks were disclosed to the subjects, and whether Institutional Review Board (IRB) approvals (or an equivalent approval/review based on the requirements of your country or institution) were obtained?

Answer: [N/A]

Justification: As noted in item 14, the paper involves no human subjects, so IRB review is not applicable.

16. Declaration of LLM usage

Question: Does the paper describe the usage of LLMs if it is an important, original, or non-standard component of the core methods in this research? Note that if the LLM is used only for writing, editing, or formatting purposes and does *not* impact the core methodology, scientific rigor, or originality of the research, declaration is not required.

957

Answer: [N/A]

958

Justification: Pretrained LLMs (Qwen2.5-Math, LLaMA-3.1) appear in the paper as the experimental subject of analysis, not as a non-standard component of the methods themselves.

959

960

The methods (RSP definition, attention decomposition, DAPO + RSP training) do not rely on auxiliary LLMs in any non-standard or originality-affecting role.

961