

노이즈에서 다양성으로: 대형 언어 모델 추론에서의 무작위 임베딩 주입

Anonymous Author(s)

Affiliation

Address

email

Abstract

1 학습되지 않은 무작위 임베딩을 LLM 입력에 끼워 넣는 것만으로도 모델의
2 추론 행동은 비자명하게 바뀐다. 최근의 *soft prompt* 계열 방법은 가상 토큰 임
3 베딩을 최적화해 수학 추론 성능을 끌어올렸지만, 그 이득이 학습에서 오는지
4 주입 자체에서 오는지는 분리되어 있지 않다. 본 논문은 학습 단계를 완전히
5 제거한 Random Soft Prompt(RSP)를 분석한다. RSP는 사전학습 임베딩 행렬
6 의 항별 평균과 분산에 맞춘 등방 가우시안에서 샘플한 연속 벡터를 그대로
7 주입한 것이다. 분석은 두 부분으로 이루어진다. 한 rollout 안에서는 exact
8 attention decomposition이 RSP가 생성 초반의 next-token 결정을 흔들 수 있지
9 만 자기회귀 캐시가 자라면서 그 영향이 약해짐을 보인다. rollout 사이에서는
10 등방 prompt가 고정 분산 예산 아래 방향 무관이며 모든 비공집합 열린집합에
11 양의 확률을 부여하므로, 독립 재추첨이 초반 branch를 다시 열 수 있고 별도의
12 과제 측 성공 가정 아래 Pass@N 증가로 이어진다. 실험은 이 구조와 맞물린다.
13 학습 없는 RSP는 최적화된 soft prompt와 경쟁적인 성능을 보이고, 초반 토큰
14 분포는 더 다양해진 뒤 후반에 안정화되며, 같은 RSP를 모든 sample에 공유
15 하면 Pass@N 이득이 사라진다. 마지막으로 이 다양성이 GRPO 학습에 갖는
16 함의를 논의한다.

1 서론

18 대형 언어 모델(LLM)의 파라미터 수가 빠르게 늘면서, 모델 전체를 미세조정하는 길은 점점
19 멀어졌다. 그 자리를 소수 파라미터만 추가해 모델을 적응시키는 parameter-efficient 방법이 사실
20 상 표준으로 채웠다 [Hu et al., 2022, Houlsby et al., 2019]. 그중 *soft prompt*는 어휘 바깥의 학습
21 가능한 연속 임베딩을 입력에 끼워 넣는 도구다. 이 임베딩이 attention을 거치며 모델 행동을
22 조정한다 [Li and Liang, 2021, Lester et al., 2021]. 같은 패러다임은 수학 추론을 강화하는 최근
23 연구에도 폭넓게 쓰인다 [Kang et al., 2026, Xu et al., 2025, Ye et al., 2026, Hao et al., 2025, Zhang
24 et al., 2026]. 이들 연구는 어휘 밖 연속 임베딩을 최적화해 정확도를 끌어올린다는 공통 구조를
25 공유한다.

26 그런데 이 효과의 출처가 정말 최적화뿐이라고 단정하기는 어렵다. 학습되지 않은 무작위 연속
27 임베딩을 그대로 끼워 넣어도 출력 분포는 비자명하게 흔들린다. 한 예로 채팅 형식으로 학습되
28 지 않은 base model에 chat template을 적용하면 형식 불일치 탓에 추론 정확도가 크게 떨어진다.
29 그런데 무작위 임베딩을 덧붙이면 그 손실이 도리어 회복된다. 단순 노이즈가 모델을 흔드는 데
30 그친다면 정확도는 더 나빠져야 한다. 따라서 효과의 뿌리는 학습된 의미가 아니라 주입 자체의
31 어떤 성질이라는 가설이 자연스럽게 떠오른다. 기존 평가는 최종 정확도에 초점을 맞춰 “주입”
32 의 효과와 “최적화”의 효과를 분리하지 못했다. 그래서 어휘 바깥 연속 임베딩이 모델 행동을
33 어떻게 바꾸는가는 별도의 미해결 문제로 남았다.

34 본 논문은 학습 없이 주입되는 Random Soft Prompt(RSP)를 분석한다. RSP는 사전학습 임베딩
35 행렬의 항별 평균과 분산에 맞춘 등방 가우시안에서 추첨한 연속 벡터의 시퀀스다. 무작위성의
36 역할은 임베딩 분포를 흉내 내는 데 있지 않다. 반복 rollout이 독립된 섭동을 받게 하는 데 있다.

본 논문은 두 질문에 답한다. 첫째, 왜 한 번 샘플한 RSP는 생성 초반의 next-token 결정을 흔들 수 있지만 곧 약해지는가. Exact attention decomposition과 두 envelope 부등식은 동일한 attention mass가 perturbation의 주입과 감쇠를 함께 통제하고, 캐시 성장으로 생성 후반의 가능한 mass가 줄어든다는 점을 보인다. 둘째, 왜 새로 뽑은 RSP는 시도 사이에서 누적되는가. 고정 분산 예산 아래 등방 섭동은 방향 무관이고, 가우시안 법칙은 모든 비공집합 열린집합에 양의 확률을 부여한다. 따라서 독립 재추첨은 rollout마다 국소 top- K 진입 영역을 다시 열 수 있고, 여기에 별도의 과제 측 성공 가정이 더해지면 Pass@ N 증가로 이어진다. 마지막으로 이 다양성이 GRPO [Shao et al., 2024] 학습에 어떤 함의를 갖는지 짚는다.

본 논문의 기여는 다음과 같다.

- RSP가 LLM 생성에 어떤 변화를 주는지 실증적으로 분석한다. RSP는 생성 초반의 토큰 엔트로피를 끌어올리고 후반에는 baseline 수준으로 다시 가라앉는다. temperature sampling과 결합하면 더 다양한 추론 궤적이 나온다.
- 학습되지 않은 RSP가 왜 영향을 줄 수 있는지를 transformer 수준에서 설명한다. 하나의 attention-side scalar가 perturbation의 크기와 후반 감쇠를 함께 통제하고, 중심화된 등방 prompt 법칙은 고정된 1차 드리프트를 만들지 않으면서도 국소적인 열린 분기 영역을 배제하지 않는다.
- RSP가 유도하는 다양성이 GRPO 학습에 어떤 함의를 갖는지 논의한다. RSP는 토큰 순위를 바꾸는 섭동이고 temperature는 순위를 보존하는 섭동이다. 이 차이 덕분에 두 방법은 직교한 탐색 이득을 제공한다.

2 배경

2.1 LLM 추론을 위한 Soft Prompt 기법

Soft prompt는 전체 미세조정의 대안으로 등장했다. Prefix-Tuning [Li and Liang, 2021]이 학습 가능한 연속 벡터를 각 transformer 레이어 앞에 붙이는 패러다임을 제시한 이후, Prompt Tuning [Lester et al., 2021]은 입력 레이어만 사용하는 단순화된 형태로도 충분히 큰 모델에서 전체 미세조정에 근접한 성능을 보였고, P-tuning [Liu et al., 2024]은 LSTM prompt encoder로 위치 간 의존성까지 포착했다. 이 패러다임은 LLM 추론에도 빠르게 적용되었다. TTSV [Kang et al., 2026]는 테스트 시점에 prefix 임베딩을 엔트로피 최소화해 최적화해 잠재 추론을 활성화하고, SoftCoT [Xu et al., 2025]은 assistant model이 만든 soft token으로 명시적 chain-of-thought를 대체한다. LTPO [Ye et al., 2026]는 confidence 기반 내재 보상으로 latent thought 임베딩을 샘플별로 최적화하며, COCONUT [Hao et al., 2025]은 모델 자신의 은닉 상태를 다시 입력 임베딩으로 되먹여 연속 잠재 공간에서 추론하게 만든다. MemGen [Zhang et al., 2026]은 임베딩이 경험 메모리로 기능할 수 있음을 보였고, Pause token [Goyal et al., 2024]은 학습 가능한 토큰을 입력 중간에 끼워 넣어 추가 계산 단계를 제공한다. 이들 모두 어휘 바깥의 연속 임베딩을 과제 특화 목적함수로 최적화해 정확도를 끌어올린다. 그러나 평가가 최종 정확도에 맞춰져 있어 “주입 자체”의 효과와 “최적화”의 효과가 분리되지 않으며, 단순한 임베딩 주입이 모델 행동을 어떻게 바꾸는지는 별도의 미해결 문제로 남아 있다.

2.2 신경망에서의 노이즈 주입

신경망에는 여러 단계에서 노이즈가 도입되어 왔다. 학습 시점에서는 dropout [Srivastava et al., 2014]이 은닉 유닛을 무작위로 비활성화해 과적합을 막고, NEFTune [Jain et al., 2024]은 instruction fine-tuning 중 토큰 임베딩에 노이즈를 더해 instruction following을 개선한다. 추론 시점의 섭동은 주로 강건성을 겨냥한다. Randomized smoothing [Cohen et al., 2019]은 입력 가우시안 노이즈로 certified robustness를 얻고, SmoothLLM [Robey et al., 2025]은 문자 단위 프롬프트 변형으로 jailbreak를 방어한다. 강화학습에서는 NoisyNet [Fortunato et al., 2018]이 가중치에 학습 가능한 노이즈를 넣어 탐색 성능을 높였다.

RSP는 이들과 세 가지 점에서 구별된다. (1) 어떠한 학습도 없이 추론 시점에만 동작하므로 모델 파라미터를 건드리지 않는다(dropout, NEFTune, NoisyNet과 다르다). (2) 원래 입력을 보존한 채 새 임베딩을 한 번의 forward pass에 덧붙일 뿐이며, 강건성 방법이 요구하는 “여러 번의 noisy pass와 출력 집계”가 필요 없다. (3) 학습된 파라미터 없이 사전학습 임베딩 통계를 직접 샘플링한 무작위 벡터를 그대로 쓴다(NoisyNet은 노이즈 파라미터 자체를 학습한다). 무엇보다 RSP의 목적은 출력 안정성이 아니라 탐색이며, 본 논문은 이 차이가 어텐션 수준에서 어떻게 작동하는지 분석한다.

88 3 Random Soft Prompt와 작동 원리

89 이 절은 논문에서 사용하는 핵심 메커니즘을 정리한다. rollout은 한 번 샘플한 RSP를 고정된 채
90 끝까지 수행한 자기회귀 디코딩 한 번을 뜻한다. 한 rollout 안에서 RSP는 attention을 통해 생성
91 초반의 next-token 결정을 흔들 수 있고, 캐시가 자라면서 그 영향은 약해진다. rollout마다 RSP를
92 다시 뽑으면 그 분기 차이가 Pass@N 이득으로 누적될 수 있다. 본문에는 핵심 명제와 직관만
93 두고, 도출과 증명은 Appendix E로 보낸다.

94 3.1 Random Soft Prompt

95 먼저 분석 대상부터 정리한다. 토큰 임베딩 행렬을 $\mathbf{W}_E \in \mathbb{R}^{V \times d}$ 로 두자(V 는 어휘 크기, d 는
96 은닉 차원). 그 행별 평균과 표준편차를 $\mu_E := \frac{1}{Vd} \sum_{i,k} [\mathbf{W}_E]_{i,k}$, $\sigma_E := \text{std}(\mathbf{W}_E)$ 라 하자. 길이
97 L 의 RSP는 다음 분포에서 독립 추출한 연속 벡터 시퀀스 $\mathbf{H} = [h_1, \dots, h_L] \in \mathbb{R}^{L \times d}$ 이다.

$$h_j \sim \mathcal{N}(\mu_E \mathbf{1}_d, \sigma_E^2 \mathbf{I}_d), \quad j = 1, \dots, L. \quad (1)$$

98 중심화한 $\bar{h}_j := h_j - \mu_E \mathbf{1}_d \sim \mathcal{N}(0, \sigma_E^2 \mathbf{I}_d)$ 은 평균 0의 등방 가우시안이다. 입력 임베딩 시퀀스
99 $\mathbf{X}$ 에는 prefix $[\mathbf{H}; \mathbf{X}]$, infix, suffix $[\mathbf{X}; \mathbf{H}]$ 세 방식 가운데 하나로 주입한다 [Kang et al., 2026, Xu
100 et al., 2025, Ye et al., 2026, Zhang et al., 2026]. 반복 샘플링 프로토콜에서는 비교하는 rollout
101 들의 prompt 추출과 디코딩 무작위성을 모두 독립으로 둔다.

102 무작위성의 목적은 임베딩 분포를 흉내 내는 데 있지 않다. 같은 텍스트 prompt를 여러 번 실행할
103 때 각 rollout이 독립적인 섭동을 받도록 하는 데 있다. 탐색에 필요한 것은 바로 그 독립성이다.

104 3.2 Exploration: 왜 첫 몇 토큰이 움직이는가

105 RSP가 초반에 영향을 줄 수 있는 이유는, 캐시가 아직 짧을 때는 무작위 토큰에도 무시할 수
106 없는 attention mass가 갈 수 있기 때문이다. self-attention 레이어 ℓ 이 실제 토큰 n 개와 RSP 토큰
107 L 개를 함께 attend하고, attention 가중치를 $\alpha_{ij}^{(\ell)}$, value 벡터를 실제 측과 RSP 측에서 각각 $\mathbf{v}_j^{(\ell)}$,
108 $\mathbf{v}_{r,j}^{(\ell)}$ 라 하자. 이때 RSP 토큰에 배정된 attention mass를

$$w_{r,i}^{(\ell)} := \sum_{j'=1}^L \alpha_{i,n+j'}^{(\ell)}$$

109 로 두면 attention 출력은 정확히

$$\mathbf{x}_i^{(\ell+1)} = (1 - w_{r,i}^{(\ell)}) \tilde{\mathbf{x}}_i^{(\ell+1)} + \boldsymbol{\eta}_i^{(\ell)}, \quad \tilde{\mathbf{x}}_i^{(\ell+1)} := \sum_{j=1}^n \frac{\alpha_{ij}^{(\ell)}}{1 - w_{r,i}^{(\ell)}} \mathbf{v}_j^{(\ell)}, \quad \boldsymbol{\eta}_i^{(\ell)} := \sum_{j'=1}^L \alpha_{i,n+j'}^{(\ell)} \mathbf{v}_{r,j'}^{(\ell)} \quad (2)$$

110 로 분해된다. 이는 근사가 아니라 대수적 항등식이다. 그리고 $\|\boldsymbol{\eta}_i^{(\ell)}\| \leq w_{r,i}^{(\ell)} \max_{j'} \|\mathbf{v}_{r,j'}^{(\ell)}\|$ 이므로,
111 같은 스칼라 $w_{r,i}^{(\ell)} \in [0, 1]$ 가 실제 신호 감쇠와 무작위 기여 크기를 동시에 통제한다.

112 이제 남은 질문은 이 스칼라가 초반에 실제로 0에서 떨어져 있느냐다. 레이어 ℓ 에서 query를
113 $\mathbf{q}_i^{(\ell)}$, 실제와 RSP key를 각각 $\mathbf{k}_j^{(\ell)}$, $\mathbf{k}_{r,j'}^{(\ell)}$ 로 두자.

114 **명제 1** (초반 exploration의 lower envelope). 역방향 logit gap을 $\Delta_i^{(\ell)} := \max_{j \in [n]} (\mathbf{q}_i^{(\ell)})^\top \mathbf{k}_j^{(\ell)} -$
115 $\min_{j' \in [L]} (\mathbf{q}_i^{(\ell)})^\top \mathbf{k}_{r,j'}^{(\ell)}$ 로 두면, scaled-dot-product attention에서

$$w_{r,i}^{(\ell)} \geq \frac{L}{L + n \exp(\Delta_i^{(\ell)} / \sqrt{d})}$$

116 가 성립한다.

117 증명은 softmax 부등식의 대칭형으로 Appendix E에 있다. Proposition 1의 의미는 단순하다.
118 최악의 RSP token score가 best real-token score보다 너무 낮지 않다면, 생성 초반에는 무작위
119 토큰이 여전히 양의 attention mass를 받아 한 rollout 안에서 다른 초기 분기를 열 수 있다.

120 3.3 Annealing: 왜 효과가 사라지는가

121 초반 영향을 만들었던 바로 그 스칼라가 후반에는 RSP를 사라지게 만든다. 정방향 logit gap을

$$\Delta_i^{(\ell)} := \min_{j \in [n]} (\mathbf{q}_i^{(\ell)})^\top \mathbf{k}_j^{(\ell)} - \max_{j' \in [L]} (\mathbf{q}_i^{(\ell)})^\top \mathbf{k}_{r,j'}^{(\ell)}, \quad \Delta_i^{(\ell)} \leq \Delta_i'^{(\ell)}$$

122 로 두자.

123 **정리 1** (후반 어닐링의 upper envelope). *scaled-dot-product attention*에서

$$w_{r,i}^{(\ell)} \leq \frac{L}{L + n \exp(\Delta_i^{(\ell)} / \sqrt{d})}$$

124 가 성립한다. 우변은 L 과 $\Delta_i^{(\ell)}$ 를 고정하면 n 에 대해 엄격히 감소하고, $n \rightarrow \infty$ 이면 0으로 간다.

125 Proposition 1와 결합하면 양방향 sandwich가 된다.

$$\frac{L}{L + n \exp(\Delta_i'^{(\ell)} / \sqrt{d})} \leq w_{r,i}^{(\ell)} \leq \frac{L}{L + n \exp(\Delta_i^{(\ell)} / \sqrt{d})}. \quad (3)$$

126 정리의 해석은 조심스럽다. 실현된 $w_{r,i}^{(\ell)}$ 가 step마다 반드시 단조 감소한다는 뜻은 아니다. query,
127 key, hidden state가 함께 변하므로 두 gap도 계속 움직인다. 다만 같은 gap을 유지한다면, 캐시
128 성장만으로 가능한 최대 RSP attention mass가 줄어든다는 뜻이다. Eq. (2)가 무작위 기여를 같은
129 스칼라로 묶어 두므로, perturbation도 이 fixed-gap envelope의 제약을 받는다. 전체 블록을 통한
130 유한 길이 전파 제어는 Appendix E에 정리한다.




Figure 1: Qwen2.5-Math-7B의 토큰별 attention 질량(suffix, MATH-500 500문제, 문제마다 독립 RSP). (a) RSP 토큰 attention은 추론 위치 축에서 감소하며 Eq. (3)와 맞는다. 레이어 축의 추가 감소는 깊은 레이어가 real-vs-random gap을 더 날카롭게 만든다는 별도 경험적 현상이지, Theorem 1만의 직접 귀결은 아니다. (b) 질문 토큰 attention은 비교적 균일하게 유지된다. 보고한 양은 Appendix F의 per-token mass로, $w_{r,i}^{(\ell)} / L$ 을 head와 sample에 대해 평균한 값이다.

131 3.4 성능 향상: 왜 독립 재실행이 도움이 되는가

132 앞의 두 envelope은 한 rollout 안에서 RSP가 얼마나 움직일 수 있는지를 설명했다. 이제 남은
133 질문은 성능이다. 왜 새로운 RSP로 다시 실행할 때, 하나의 고정된 prompt를 반복하는 것보다
134 이득이 커질 수 있는가? 여기에는 prompt 분포에 대한 사실 하나와, 열린 branch가 실제로 정답에
135 도움이 되는지에 대한 별도의 task-side 사실 하나가 필요하다.

136 먼저 분포 쪽 사실부터 보자. 위 attention 항등식과 gap 부등식은 등방성을 요구하지 않지만,
137 branch opening은 현재 prompt에 중요한 방향을 미리 편들지 않는 분포를 선호한다.

138 **정리 2** (방향 무관 미니맥스 커버리지). $\mathbb{R}^d$ 위 평균 0 분포 D 가 분산 예산 $\text{tr}(\Sigma_D) \leq \rho^2$ 를 만족
139 하면

$$\min_{\|b\|=1} \text{Var}_{h \sim D}(b^\top h) = \lambda_{\min}(\Sigma_D) \leq \rho^2 / d$$

140 이고, 등호는 $\Sigma_D = (\rho^2 / d) \mathbf{I}_d$ 일 때에만 성립한다.

141 등호에 필요한 핵심은 가우시안 그 자체가 아니라 등방 공분산이다. 여기서 가우시안을 택한
142 이유는 둘째 성질 때문이다. 가우시안 법칙은 모든 비공집합 열린집합에 양의 확률을 부여하므
143 로, 2차 모멘트 수준에서 특정 방향을 미리 편들지 않으면서도 국소적인 branch-opening 영역을
144 배제하지 않는다(Proposition 5).

145 이제 centered prompt $\bar{h} = 0$ 주변에서 next-token logit의 1차 affine surrogate를

$$z_i^{\text{lin}}(\bar{h}) := z_i + a_i^\top \bar{h}, \quad a_i := \nabla_{\bar{h}} z_i(0)$$

146 로 둔다. baseline에서 제외된 토큰 i 의 top- K 진입 영역은

$$\mathcal{G}_{i,K} := \{\bar{h} \in \mathbb{R}^d : \#\{j \neq i : z_j^{\text{lin}}(\bar{h}) > z_i^{\text{lin}}(\bar{h})\} \leq K - 1\}$$

147 로 쓸 수 있다.

148 **명제 2** (조건부 top- K 진입). $\mathcal{G}_{i,K}$ 가 비공집합 열린집합을 포함하면, 등방 가우시안 *prompt*
149 법칙이 그 영역에 양의 확률을 부여하므로

$$\mu_i := \Pr_{\bar{h}}(\bar{h} \in \mathcal{G}_{i,K}) > 0$$

150 이다.

151 Proposition 2이 설명하는 메커니즘은 의도적으로 제한적이다. branch가 열릴 수 있다는 뜻이지,
152 열린 branch가 유용하다는 뜻은 아니다. 이를 task accuracy로 연결하려면 task-side 가정을 따로
153 뒤야 한다. 문제 x 에 대해 (M1) 각 독립 RSP 실행이 정답 trajectory에 도달할 주변 확률이 적어도
154 $p_{\min}(x) > 0$ 이고, (M2) N 번의 실행이 서로 독립이라고 하자.

155 **명제 3** (다중 경로 Pass@ N). (M1)–(M2) 아래에서, N 개의 독립 RSP 실행은

$$\Pr(\text{Pass}@N \text{ on } x) \geq 1 - (1 - p_{\min}(x))^N \geq 1 - \exp(-N p_{\min}(x))$$

156 를 만족한다.

157 이 역할 분담이 이 절의 핵심 해석이다. 메커니즘은 baseline 밖 후보를 후보권 안으로 들이는 것
158 까지만 책임진다. 들인 branch가 실제로 생산적인지는 task의 성질에 달려 있으므로 $p_{\min}(x) > 0$
159 가정이 따로 필요하다. 같은 RSP를 모든 sample이 공유하면 누적 이득이 사라지는 이유도 여기
160 있다. 독립 재추첨이 없으면 branch를 다시 여는 것이 아니라 같은 branch를 반복 방문하게 되기
161 때문이다. §4는 바로 이 서명을 실험적으로 확인한다.

162 4 실험적 확인

163 앞 절의 설명이 실제 LLM 생성에서 어떻게 드러나는지를 세 장면으로 살펴본다. 먼저 RSP가
164 baseline 정확도를 크게 깎지 않으면서 일부 설정에서는 오히려 회복시키는지를 확인하고 (§4.2),
165 다음으로 생성 초반에 토큰 분포가 평탄해졌다가 후반에는 baseline 수준으로 돌아오는 자동
166 어닐링이 실제로 관찰되는지를 살펴 (§4.3), 끝으로 같은 RSP를 재사용할 때와 매 시도마다
167 새로 뽑을 때의 Pass@ N 차이가 독립성이 핵심이라는 점을 직접 보여 주는지를 본다 (§4.4).

168 4.1 실험 설정

169 평가는 세 가지 수학 추론 벤치마크 MATH-500 [Lightman et al., 2024], GSM8K [Cobbe et al.,
170 2021], AIME24에서 수행한다. 모델은 LLaMA-3.1-8B-Instruct [Grattafiori et al., 2024]와
171 Qwen2.5-Math 계열 [Yang et al., 2024]을 쓰며, instruct, base, 그리고 chat template이 맞지 않
172 는 base 설정까지 합쳐 총 일곱 가지를 비교한다. 모든 실험은 sampling 자체의 무작위성과 RSP
173 효과를 분리하기 위해 greedy decoding을 사용하고, fallback 기반 answer extraction pipeline으로
174 최종 답만 채점한다. RSP는 §3.1의 정의를 따르며 prefix/infix/suffix 세 주입 위치 중 하나에 매
175 배치마다 새로 주입된 $\mathbf{H}$ 를 결합한다. 전체 실험 설정과 위치별 결과는 Appendix A에 있다.

176 4.2 RSP는 추론 성능을 개선할까?

177 먼저 무작위 임베딩 주입이 모델의 추론 성능에 어떤 영향을 주는지 본다. Table 1는 각 벤치마크
178 에서 주입 위치 (Prefix, Infix, Suffix)와 $L \in \{10, 15, 20\}$ 가운데 가장 좋은 RSP 결과를 보고한다.

179 instruct model과 원래 프롬프트 형식을 쓰는 base model에서는 RSP가 baseline 성능을 대체로
180 몇 퍼센트포인트 이내에서 유지하거나 소폭만 이동시킨다. 더 눈에 띄는 것은 프롬프트 형식
181 불일치 상황이다. 즉, 채팅 형식으로 학습되지 않은 base model에 ChatML template을 주입했을
182 때, RSP는 최대 +29%p까지의 큰 성능 향상을 보인다. 단순히 불확실성을 높이는 노이즈였다

Table 1: 모델 설정과 벤치마크별 정확도(%). RSP는 주입 위치(Prefix, Infix, Suffix) 중 최고 성능만 보고한다. 위치별 전체 결과는 Appendix A에 있다. 괄호 안 값은 baseline 대비 변화량이다.

Model	MATH-500		GSM8K		AIME24	
	Baseline	RSP	Baseline	RSP	Baseline	RSP
<i>Instruct Models</i>						
LLaMA-3.1-8B-Inst	52.20	49.40 (−2.8)	85.75	86.73 (+1.0)	6.67	10.00 (+3.3)
Qwen2.5-Math-7B-Inst	83.20	84.20 (+1.0)	95.45	95.68 (+0.2)	13.33	16.67 (+3.3)
Qwen2.5-Math-1.5B-Inst	73.00	75.20 (+2.2)	85.29	85.75 (+0.5)	10.00	20.00 (+10.0)
<i>Base Models (Raw Text)</i>						
Qwen2.5-Math-7B	72.20	71.60 (−0.6)	84.15	84.31 (+0.2)	6.67	16.67 (+10.0)
Qwen2.5-Math-1.5B	61.40	64.40 (+3.0)	77.86	74.30 (−3.6)	16.67	10.00 (−6.7)
<i>Base Models + ChatML (Format Mismatch)</i>						
Qwen2.5-Math-7B	52.20	70.40 (+18.2)	58.30	75.97 (+17.7)	23.33	23.33 (+0.0)
Qwen2.5-Math-1.5B	34.40	63.40 (+29.0)	37.45	67.02 (+29.6)	13.33	20.00 (+6.7)

Table 2: 기존 soft prompt 방법(TTSV, SoftCoT, LTPO)과의 통합 평가 비교. Baseline과 RSP 값은 Table 1에서 가져왔다. **Bold**는 최고 성능, underline은 두 번째 성능이다.

Model	Benchmark	Baseline	RSP	TTSV	SoftCoT	LTPO
Qwen2.5-Math-7B-Instruct	MATH-500	83.20	84.20	83.80	82.80	83.00
	GSM8K	<u>95.45</u>	95.68	<u>95.30</u>	95.00	94.84
	AIME24	13.33	<u>16.67</u>	23.30	<u>16.67</u>	13.33
Qwen2.5-Math-1.5B-Instruct	MATH-500	73.00	<u>75.20</u>	<u>75.20</u>	76.00	72.40
	GSM8K	85.29	85.75	<u>85.70</u>	84.46	84.53
	AIME24	<u>10.00</u>	20.00	6.70	6.67	<u>10.00</u>

183 면 오히려 성능 저하가 커졌어야 하므로, 이 결과는 RSP 효과가 단순한 교란을 넘는다는 점을
184 시사한다.

185 또한 RSP를 TTSV, SoftCoT, LTPO처럼 서로 다른 목적 함수로 임베딩을 최적화하는 기존 soft
186 prompt 방법과 비교했다. Table 2은 공통 answer extraction pipeline 아래에서 다시 평가한 결과
187 를 보여준다. 각 방법은 프롬프트 형식과 채점 규칙이 다르지만, fallback 기반 추출을 사용해
188 형식에 덜 민감한 비교를 수행했다. 결과적으로 RSP는 추가 학습 없이도 최적화 기반 방법과
189 맞먹는 수준의 성능을 보인다.

190 4.3 RSP는 출력 분포를 어떻게 바꾸는가?

191 다음으로 RSP 주입이 생성 과정의 출력 분포를 어떻게 바꾸는지 살펴본다. 설정은 Qwen2.5-
192 Math-1.5B-Instruct와 MATH-500이며, 토큰별 entropy, top-1 probability, varentropy를 생성 단계
193 에 따라 측정한다. Figure 2와 Table 3는 생성 초반 5% 구간에서 RSP 변형과 기존 soft prompt
194 방법을 비교한 결과다.




Figure 2: 생성 초반 5% 구간의 평균 entropy, top-1 probability, varentropy (Qwen2.5-Math-1.5B-Instruct, MATH-500). 음영은 ± 1 SEM이다. 실선은 RSP 변형과 baseline, 점선은 기존 soft prompt 방법(LTPO, SoftCoT, TTSV)이다.

Table 3: 생성 초반 5% 구간의 평균 entropy, top-1 probability, varentropy (Qwen2.5-Math-1.5B-Instruct, MATH-500).

Metric	Baseline	Prefix	Infix	Suffix	LTPO	SoftCoT	TTSV
Entropy	0.1332	0.1366	0.1402	0.1941	0.1662	0.4218	0.1359
Top-1 Prob	0.9535	0.9523	0.9525	0.9373	0.9437	0.9156	0.9534
Varentropy	0.2181	0.2207	0.2463	0.4010	0.2953	2.2234	0.2174

결과는 RSP가 생성 초반 출력 분포를 분명히 바꾼다는 점을 보여준다. 세 주입 위치 모두에서 entropy는 증가하고, top-1 probability는 감소하며, varentropy는 증가한다. 이는 분포가 평평해지고, 단일 우세 토큰에 대한 확신은 약해지며, 다봉형 분포가 더 자주 나타남을 뜻한다 [Ahmed et al., 2026]. 높은 entropy 구간은 추론 궤적이 갈라지는 핵심 분기점으로 알려져 있으므로 [Wang et al., 2025], 이 변화는 여러 추론 경로가 공존할 수 있는 상태로 모델을 밀어 넣는다. 중요한 점은 변화가 생성 초반에 국한된다는 것이다. 생성 중반과 후반에서는 세 지표 모두 baseline 수준으로 다시 수렴한다.

서로 다른 목적 함수로 학습된 기존 방법들도 같은 패턴을 공유한다. 평균 entropy를 줄이는 보상을 쓰는 TTSV조차 초반 구간만큼은 baseline과 비슷하거나 더 높아, 이 entropy 상승은 특정 최적화 목적이 아니라 사전학습되지 않은 연속 임베딩 주입 자체에 가까운 효과로 보인다.

4.4 RSP는 실제로 추론 궤적의 다양성을 만드는가?

Section 4.3는 RSP가 생성 초반 출력 분포를 바꾼다는 사실을 보였다. 이제 이 변화가 실제 추론 다양성으로 이어지는지를 세 수준에서 살펴본다. 분석 수준은 토큰 순위, 궤적의 의미적 내용, 과제 수준 결과다. 세 분석 모두 Qwen2.5-Math-1.5B-Instruct, MATH-500, suffix 주입, $L = 10$ 설정을 공유한다.

먼저 토큰 수준에서 보면, 자기회귀 생성에서 baseline과 RSP의 궤적 차이는 결국 첫 토큰에서 시작될 수밖에 없으므로 baseline $\tau=1.0$ 을 기준으로 단순 flattening의 상한인 baseline $\tau=2.0$ 과 RSP $\tau=1.0$ 을 비교한다. 세 지표—Spearman rank correlation ρ , baseline top-10 밖 확률 질량, Jensen–Shannon divergence—는 각각 순위 재배치, 지지 집합 확장, 분포 변화의 크기를 잡아낸다(정의는 Appendix C). Table 4에서 baseline top-10 밖으로 이동하는 질량은 $\tau=2.0$ 에서 5.15%에 그치지만 RSP $\tau=1.0$ 에서는 27.64%이고, Spearman 상관은 1에서 0.651로 떨어진다. Temperature는 단조 변환이라 어떤 τ 에서도 순위를 보존하므로 $\rho = 1$ 이 강제되는 반면, RSP는 순위 자체를 뒤섞는다 — §3.4의 surrogate 수준에서 보인 branch opening의 직접 흔적. JS divergence 0.231은 이 변화의 전체 크기를 요약한다.

Table 4: Baseline $\tau=1.0$ 을 기준으로 본 첫 토큰 분포 지표. Baseline $\tau=2.0$ 과 RSP $\tau=1.0$ 을 비교한다.

Metric	$\tau=2.0$	RSP
Spearman ρ	1.0	0.651
Mass outside top-10	5.15%	27.64%
JS divergence	0.086	0.231

한 단계 위인 궤적 수준에서는, 첫 토큰의 재배치가 실제로 의미적으로 다른 추론 경로를 여는지가 관건이다. 이를 위해 MATH-500에서 무작위로 64개 문제를 뽑고, Baseline과 RSP 두 조건에서 각 문제마다 temperature $\tau = 1.0$ 으로 300개의 독립 궤적을 생성했다. 각 궤적은 BGE-M3 [Chen et al., 2024]로 임베딩한 뒤, 문제 내 평균 pairwise cosine distance, DBSCAN [Ester et al., 1996] 클러스터 중심 사이의 inter-cluster distance, 그리고 intra-cluster distance를 계산했다. Table 5는 RSP가 intra-cluster distance는 거의 바꾸지 않으면서 inter-cluster distance를 크게 키운다는 점을 보여준다. 즉, 각 전략 내부의 일관성은 유지하면서 전략 간 거리를 벌린다. Pairwise distance 기준으로 RSP는 64개 중 56개 문제(87.5%)에서 baseline보다 컸다.

Table 5: 64개 문제에 대해 평균한 의미적 다양성 지표.

Metric	Baseline	RSP
Pairwise cos. dist.	0.0612	0.0879
Inter-cluster dist.	0.0183	0.0982
Intra-cluster dist.	0.0526	0.0528

Figure 3(a)에서 RSP 샘플(파랑)은 baseline 영역을 포함하면서 baseline이 도달하지 못한 별도 클러스터까지 확장되고, 그 영역에도 정답 궤적이 포함된다. (b), (c)는 64개 문제 전반에 걸쳐 RSP가 더 많은 클러스터와 더 큰 pairwise cosine distance를 만든다는 패턴이 반복됨을 보여준다. 즉 RSP는 클러스터 내부 진행은 호트트프리지 않으면서 궤적이 진입하는 전략 클러스터 자체를 바꾼다. 문제별 추가 t-SNE는 Appendix B에 있다.




Figure 3: 64개 MATH-500 문제에서의 의미적 다양성 분석(문제당 300개 궤적, Qwen2.5-Math-1.5B-Instruct, $\tau = 1.0$, BGE-M3 임베딩). (a) 대표 문제 `test/prealgebra/951`의 t-SNE 투영: baseline(빨강)은 한 영역에 비교적 집중되지만, RSP suffix(파랑)는 더 넓고 분리된 군집까지 확장된다. 채워진 표식은 정답, 빈 표식은 오답이다. (b) 문제별 평균 pairwise cosine distance. 대각선 위 점은 RSP가 baseline보다 더 다양한 궤적을 만든다는 뜻이다. (c) 문제별 DBSCAN 클러스터 수. 대부분의 문제에서 RSP가 더 많은 클러스터를 만든다.

마지막 결과 수준에서는, 이러한 다양성이 실제 과제 성과로 이어지는지를 Pass@N로 본다 (N 개의 샘플 중 적어도 하나가 정답일 확률). MATH-500과 AIME24에서 문제당 $N = 16$, 네 조건을 비교한다. (i) baseline + $\tau=1.0$, (ii) RSP를 모든 샘플이 공유 + $\tau=1.0$, (iii) 샘플마다 독립 RSP + greedy, (iv) 샘플마다 독립 RSP + $\tau=1.0$.




Figure 4: Qwen2.5-Math-1.5B-Instruct에서의 Pass@N 스케일링. 좌측은 MATH-500, 우측은 AIME24이며, 문제당 $N = 16$ 개의 샘플을 사용했다. Baseline은 temperature sampling만, fixed seed는 고정된 하나의 RSP와 temperature를 함께 쓴 경우, indep. seed는 샘플마다 다른 RSP를 쓰는 경우다.

조건 (iv)가 두 벤치마크 모두에서 가장 높은 Pass@N을 달성하며 $N = 16$ 에서 MATH-500 92.80%, AIME24 36.67%에 이른다. (ii)는 baseline 대비 거의 개선이 없어, 다양성 이득의 핵심이 고정 섭동이 아니라 샘플마다 독립된 무작위 임베딩임을 드러낸다. Pass@1은 MATH-500에서 baseline 수준을 유지하고 더 어려운 AIME24에서는 (iv)가 더 높아, 독립 RSP + temperature 결합이 단일 샘플 정확도를 해치지 않으면서 추론 궤적을 다양화한다.

5 결론

본 논문은 사전학습 임베딩 행렬의 항별 통계에 맞춘 등방 가우시안에서 추가한 RSP가 학습 없이도 영향을 줄 수 있는 이유를 transformer 수준에서 분석했다. 분석의 핵심은 네 가지다. exact attention decomposition, 초반 exploration의 lower envelope (§3.2), 후반 감쇠의 upper envelope (§3.3), 그리고 독립 재추첨과 별도의 과제 측 성공 가정이 더해질 때에만 Pass@N 증가로 이어지는 branch-opening 논리 (§3.4)다. §4의 실험은 이 구조와 맞물린다. 학습 없는 RSP는 경쟁적인 성능을 유지하고, 초반 토큰 분포는 더 다양해진 뒤 후반에 안정화되며, 같은 RSP를 모든 sample에 공유하면 누적 이득이 사라진다. RSP는 순위를 바꾸는 섭동이고 temperature는 순위를 보존하는 섭동이므로 둘은 직교적이며, 이는 GRPO [Shao et al., 2024]의 entropy collapse를 DAPO [Yu et al., 2025], CE-GPPO [Su et al., 2026] 너머에서 샘플링 단계로 보완할 가능성을 시사한다. RSP를 활용한 학습 시점 비교, 수학 추론을 넘어선 도메인 확장, RSP 길이·주입 위치의 원리적 결정은 향후 과제다.

References

- Farhan Ahmed, Yuya Jeremy Ong, and Chad DeLuca. LogitScope: A Framework for Analyzing LLM Uncertainty through Information Metrics. In *ICLR Workshop*, 2026.
- Nora Belrose, Igor Ostrovsky, Lev McKinney, Zach Furman, Logan Smith, Danny Halawi, Stella Biderman, and Jacob Steinhardt. Eliciting Latent Predictions from Transformers with the Tuned Lens. *arXiv:2303.08112*, 2023.
- Jianlyu Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, and Zheng Liu. M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation. In *Findings of ACL*, 2024.
- Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, Christopher Hesse, and John Schulman. Training Verifiers to Solve Math Word Problems. *arXiv:2110.14168*, 2021.
- Jeremy M. Cohen, Elan Rosenfeld, and J. Zico Kolter. Certified Adversarial Robustness via Randomized Smoothing. In *ICML*, 2019.
- Martin Ester, Hans-Peter Kriegel, Jörg Sander, and Xiaowei Xu. A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise. In *KDD*, 1996.
- Meire Fortunato, Mohammad Gheshlaghi Azar, Bilal Piot, Jacob Menick, Ian Osband, Alex Graves, Vlad Mnih, Remi Munos, Demis Hassabis, Olivier Pietquin, Charles Blundell, and Shane Legg. Noisy Networks for Exploration. In *ICLR*, 2018.
- Mor Geva, Roei Schuster, Jonathan Berant, and Omer Levy. Transformer Feed-Forward Layers Are Key-Value Memories. In *EMNLP*, 2021.
- Sachin Goyal, Ziwei Ji, Ankit Singh Rawat, Aditya Krishna Menon, Sanjiv Kumar, and Vaishnavh Nagarajan. Think before You Speak: Training Language Models with Pause Tokens. In *ICLR*, 2024.
- Aaron Grattafiori, Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad Al-Dahle, Aiesha Letman, Akhil Mathur, Alan Schelten, Alex Vaughan, Amy Yang, Angela Fan, Anirudh Goyal, Anthony Hartshorn, Aobo Yang, Archi Mitra, Archie Sravankumar, Artem Korenev, Arthur Hinsvark, Arun Rao, Aston Zhang, Aurelien Rodriguez, Austen Gregerson, Ava Spataru, Baptiste Roziere, Bethany Biron, Binh Tang, Bobbie Chern, Charlotte Caucheteux, Chaya Nayak, Chloe Bi, Chris Marra, Chris McConnell, Christian Keller, Christophe Touret, Chunyang Wu, Corinne Wong, Cristian Canton Ferrer, Cyrus Nikolaidis, Damien Allonsius, Daniel Song, Danielle Pintz, Danny Livshits, Danny Wyatt, David Esiobu, Dhruv Choudhary, Dhruv Mahajan, Diego Garcia-Olano, Diego Perino, Dieuwke Hupkes, Egor Lakomkin, Ehab AlBadawy, Elina Lobanova, Emily Dinan, Eric Michael Smith, Filip Radenovic, Francisco Guzmán, Frank Zhang, Gabriel Synnaeve, Gabrielle Lee, Georgia Lewis Anderson, Govind Thattai, Graeme Nail, Gregoire Mialon, Guan Pang, Guillem Cucurell, Hailey Nguyen, Hannah Korevaar, Hu Xu, Hugo Touvron, Iliyan Zarov, Imanol Arrieta Ibarra, Isabel Kloumann, Ishan Misra, Ivan Evtimov, Jack Zhang, Jade Copet, Jaewon Lee, Jan Geffert, Jana Vranes, Jason Park, Jay Mahadeokar, Jeet Shah, Jelmer van der Linde, Jennifer Billock, Jenny Hong, Jenya Lee, Jeremy Fu, Jianfeng Chi, Jianyu Huang, Jiawen Liu, Jie Wang, Jiecao Yu, Joanna Bitton, Joe Spisak, Jongsoo Park, Joseph Rocca, Joshua Johnstun, Joshua Saxe, Junteng Jia, Kalyan Vasuden Alwala, Karthik Prasad, Kartikeya Upasani, Kate Plawiak, Ke Li, Kenneth Heafield, Kevin Stone, Khalid El-Arini, Krithika Iyer, Kshitiz Malik, Kuenley Chiu, Kunal Bhalla, Kushal Lakhotia, Lauren Rantala-Young, Laurens van der Maaten, Lawrence Chen, Liang Tan, Liz Jenkins, Louis Martin, Lovish Madaan, Lubo Malo, Lukas Blecher, Lukas Landzaat, Luke de Oliveira, Madeline Muzzi, Mahesh Pasupuleti, Mannat Singh, Manohar Paluri, Marcin Kardas, Maria Tsimpoukelli, Mathew Oldham, Mathieu Rita, Maya Pavlova, Melanie Kambadur, Mike Lewis, Min Si, Mitesh Kumar Singh, Mona Hassan, Naman Goyal, Narjes Torabi, Nikolay Bashlykov, Nikolay Bogoychev, Niladri Chatterji, Ning Zhang, Olivier Duchenne, Onur Celebi, Patrick Alrassy, Pengchuan Zhang, Pengwei Li, Petar Vasic, Peter Weng, Prajjwal Bhargava, Pratik Dubal, Praveen Krishnan, Punit Singh Koura, Puxin Xu, Qing He, Qingxiao Dong, Ragavan Srinivasan, Raj Ganapathy, Ramon Calderer, Ricardo Silveira Cabral, Robert Stojnic, Roberta Raileanu, Rohan Maheswari, Rohit Girdhar, Rohit Patel,

312 Romain Sauvestre, Ronnie Polidoro, Roshan Sumbaly, Ross Taylor, Ruan Silva, Rui Hou, Rui
 313 Wang, Saghar Hosseini, Sahana Chennabasappa, Sanjay Singh, Sean Bell, Seohyun Sonia Kim,
 314 Sergey Edunov, Shaoliang Nie, Sharan Narang, Sharath Raparthy, Sheng Shen, Shengye Wan,
 315 Shruti Bhosale, Shun Zhang, Simon Vandenhende, Soumya Batra, Spencer Whitman, Sten Sootla,
 316 Stephane Collot, Suchin Gururangan, Sydney Borodinsky, Tamar Herman, Tara Fowler, Tarek
 317 Sheasha, Thomas Georgiou, Thomas Scialom, Tobias Speckbacher, Todor Mihaylov, Tong Xiao,
 318 Ujjwal Karn, Vedanuj Goswami, Vibhor Gupta, Vignesh Ramanathan, Viktor Kerkez, Vincent
 319 Gonguet, Virginie Do, Vish Vogeti, Vitor Albiero, Vladan Petrovic, Weiwei Chu, Wenhan Xiong,
 320 Wenyin Fu, Whitney Meers, Xavier Martinet, Xiaodong Wang, Xiaofang Wang, Xiaoqing Ellen
 321 Tan, Xide Xia, Xinfeng Xie, Xuchao Jia, Xuewei Wang, Yaelle Goldschlag, Yashesh Gaur, Yas-
 322 mine Babaei, Yi Wen, Yiwen Song, Yuchen Zhang, Yue Li, Yuning Mao, Zacharie Delpierre
 323 Coudert, Zheng Yan, Zhengxing Chen, Zoe Papakipos, Aaditya Singh, Aayushi Srivastava, Abha
 324 Jain, Adam Kelsey, Adam Shajnfeld, Adithya Gangidi, Adolfo Victoria, Ahuva Goldstand, Ajay
 325 Menon, Ajay Sharma, Alex Boesenberg, Alexei Baevski, Allie Feinstein, Amanda Kallet, Amit
 326 Sangani, Amos Teo, Anam Yunus, Andrei Lupu, Andres Alvarado, Andrew Caples, Andrew Gu,
 327 Andrew Ho, Andrew Poulton, Andrew Ryan, Ankit Ramchandani, Annie Dong, Annie Franco,
 328 Anuj Goyal, Aparajita Saraf, Arkabandhu Chowdhury, Ashley Gabriel, Ashwin Bharambe, As-
 329 saf Eisenman, Azadeh Yazdan, Beau James, Ben Maurer, Benjamin Leonhardi, Bernie Huang,
 330 Beth Loyd, Beto De Paola, Bhargavi Paranjape, Bing Liu, Bo Wu, Boyu Ni, Braden Hancock,
 331 Bram Wasti, Brandon Spence, Brani Stojkovic, Brian Gamido, Britt Montalvo, Carl Parker, Carly
 332 Burton, Catalina Mejia, Ce Liu, Changhan Wang, Changkyu Kim, Chao Zhou, Chester Hu, Ching-
 333 Hsiang Chu, Chris Cai, Chris Tindal, Christoph Feichtenhofer, Cynthia Gao, Damon Civin, Dana
 334 Beaty, Daniel Kreymer, Daniel Li, David Adkins, David Xu, Davide Testuggine, Delia David,
 335 Devi Parikh, Diana Liskovich, Didem Foss, Dingkan Wang, Duc Le, Dustin Holland, Edward
 336 Dowling, Eissa Jamil, Elaine Montgomery, Eleonora Presani, Emily Hahn, Emily Wood, Eric-
 337 Tuan Le, Erik Brinkman, Esteban Arcaute, Evan Dunbar, Evan Smothers, Fei Sun, Felix Kreuk,
 338 Feng Tian, Filippos Kokkinos, Firat Ozgenel, Francesco Caggioni, Frank Kanayet, Frank Seide,
 339 Gabriela Medina Florez, Gabriella Schwarz, Gada Badeer, Georgia Swee, Gil Halpern, Grant Her-
 340 man, Grigory Sizov, Guangyi Zhang, Guna Lakshminarayanan, Hakan Inan, Hamid Shojanazeri,
 341 Han Zou, Hannah Wang, Hanwen Zha, Haroun Habeeb, Harrison Rudolph, Helen Suk, Henry
 342 Aspegren, Hunter Goldman, Hongyuan Zhan, Ibrahim Damlaj, Igor Molybog, Igor Tufanov, Il-
 343 ias Leontiadis, Irina-Elena Veliche, Itai Gat, Jake Weissman, James Geboski, James Kohli, Janice
 344 Lam, Japhet Asher, Jean-Baptiste Gaya, Jeff Marcus, Jeff Tang, Jennifer Chan, Jenny Zhen, Jeremy
 345 Reizenstein, Jeremy Teboul, Jessica Zhong, Jian Jin, Jingyi Yang, Joe Cummings, Jon Carvill, Jon
 346 Shepard, Jonathan McPhie, Jonathan Torres, Josh Ginsburg, Junjie Wang, Kai Wu, Kam Hou U,
 347 Karan Saxena, Kartikay Khandelwal, Katayoun Zand, Kathy Matosich, Kaushik Veeraraghavan,
 348 Kelly Michelena, Keqian Li, Kiran Jagadeesh, Kun Huang, Kunal Chawla, Kyle Huang, Lailin
 349 Chen, Lakshya Garg, Lavender A, Leandro Silva, Lee Bell, Lei Zhang, Liangpeng Guo, Licheng
 350 Yu, Liron Moshkovich, Luca Wehrstedt, Madian Khabsa, Manav Avalani, Manish Bhatt, Martynas
 351 Mankus, Matan Hasson, Matthew Lennie, Matthias Reso, Maxim Groshev, Maxim Naumov, Maya
 352 Lathi, Meghan Keneally, Miao Liu, Michael L. Seltzer, Michal Valko, Michelle Restrepo, Mihir
 353 Patel, Mik Vyatskov, Mikayel Samvelyan, Mike Clark, Mike Macey, Mike Wang, Miquel Jubert
 354 Hermoso, Mo Metanat, Mohammad Rastegari, Munish Bansal, Nandhini Santhanam, Natascha
 355 Parks, Natasha White, Navyata Bawa, Nayan Singhal, Nick Egebo, Nicolas Usunier, Nikhil Mehta,
 356 Nikolay Pavlovich Laptev, Ning Dong, Norman Cheng, Oleg Chernoguz, Olivia Hart, Omkar
 357 Salpekar, Ozlem Kalinli, Parkin Kent, Parth Parekh, Paul Saab, Pavan Balaji, Pedro Rittner, Philip
 358 Bontrager, Pierre Roux, Piotr Dollar, Polina Zvyagina, Prashant Ratanchandani, Pritish Yuvraj,
 359 Qian Liang, Rachad Alao, Rachel Rodriguez, Rafi Ayub, Raghotham Murthy, Raghu Nayani,
 360 Rahul Mitra, Rangaprabhu Parthasarathy, Raymond Li, Rebekkah Hogan, Robin Battey, Rocky
 361 Wang, Russ Howes, Ruty Rinott, Sachin Mehta, Sachin Siby, Sai Jayesh Bondu, Samyak Datta,
 362 Sara Chugh, Sara Hunt, Sargun Dhillon, Sasha Sidorov, Satadru Pan, Saurabh Mahajan, Saurabh
 363 Verma, Seiji Yamamoto, Sharadh Ramaswamy, Shaun Lindsay, Shaun Lindsay, Sheng Feng,
 364 Shenghao Lin, Shengxin Cindy Zha, Shishir Patil, Shiva Shankar, Shuqiang Zhang, Shuqiang
 365 Zhang, Sinong Wang, Sneha Agarwal, Soji Sajuyigbe, Soumith Chintala, Stephanie Max, Stephen
 366 Chen, Steve Kehoe, Steve Satterfield, Sudarshan Govindaprasad, Sumit Gupta, Summer Deng,
 367 Sungmin Cho, Sunny Virk, Suraj Subramanian, Sy Choudhury, Sydney Goldman, Tal Remez,
 368 Tamar Glaser, Tamara Best, Thilo Koehler, Thomas Robinson, Tianhe Li, Tianjun Zhang, Tim
 369 Matthews, Timothy Chou, Tzook Shaked, Varun Vontimitta, Victoria Ajayi, Victoria Montanez,
 370 Vijai Mohan, Vinay Satish Kumar, Vishal Mangla, Vlad Ionescu, Vlad Poenaru, Vlad Tiberiu

371 Mihailescu, Vladimir Ivanov, Wei Li, Wenchen Wang, Wenwen Jiang, Wes Bouaziz, Will Con-
372 stable, Xiaocheng Tang, Xiaojian Wu, Xiaolan Wang, Xilun Wu, Xinbo Gao, Yaniv Kleinman,
373 Yanjun Chen, Ye Hu, Ye Jia, Ye Qi, Yenda Li, Yilin Zhang, Ying Zhang, Yossi Adi, Youngjin
374 Nam, Yu Wang, Yu Zhao, Yuchen Hao, Yundi Qian, Yunlu Li, Yuzi He, Zach Rait, Zachary De-
375 Vito, Zef Rosnbrick, Zhaoduo Wen, Zhenyu Yang, Zhiwei Zhao, and Zhiyu Ma. The Llama 3
376 Herd of Models. *arXiv:2407.21783*, 2024.

377 Shibo Hao, Sainbayar Sukhbaatar, DiJia Su, Xian Li, Zhiting Hu, Jason Weston, and Yuandong Tian.
378 Training Large Language Models to Reason in a Continuous Latent Space. In *ICLR*, 2025.

379 Neil Houlsby, Andrei Giurgiu, Stanislaw Jastrzebski, Bruna Morrone, Quentin de Laroussilhe, An-
380 drea Gesmundo, Mona Attariyan, and Sylvain Gelly. Parameter-Efficient Transfer Learning for
381 NLP. In *ICML*, 2019.

382 Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang,
383 and Weizhu Chen. LoRA: Low-Rank Adaptation of Large Language Models. In *ICLR*, 2022.

384 Neel Jain, Ping-yeh Chiang, Yuxin Wen, John Kirchenbauer, Hong-Min Chu, Gowthami Somepalli,
385 Brian R. Bartoldson, Bhavya Kailkhura, Avi Schwarzschild, Aniruddha Saha, Micah Goldblum,
386 Jonas Geiping, and Tom Goldstein. NEFTune: Noisy Embeddings Improve Instruction Finetuning.
387 In *ICLR*, 2024.

388 Xinyue Kang, Diwei Shi, and Li Chen. Model Whisper: Steering Vectors Unlock Large Language
389 Models’ Potential in Test-time. In *AAAI*, 2026.

390 Hyunjik Kim, George Papamakarios, and Andriy Mnih. The Lipschitz Constant of Self-Attention.
391 *Proceedings of the 38th International Conference on Machine Learning (ICML)*, 2021.

392 Brian Lester, Rami Al-Rfou, and Noah Constant. The Power of Scale for Parameter-Efficient Prompt
393 Tuning. In *EMNLP*, 2021.

394 Xiang Lisa Li and Percy Liang. Prefix-Tuning: Optimizing Continuous Prompts for Generation. In
395 *ACL-IJCNLP*, 2021.

396 Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike,
397 John Schulman, Ilya Sutskever, and Karl Cobbe. Let’s Verify Step by Step. In *ICLR*, 2024.

398 Xiao Liu, Yanan Zheng, Zhengxiao Du, Ming Ding, Yujie Qian, Zhilin Yang, and Jie Tang. GPT
399 Understands, Too. *AI Open*, 5:208–215, 2024.

400 Aman Madaan and Amir Yazdanbakhsh. Text and Patterns: For Effective Chain of Thought, It Takes
401 Two to Tango. *arXiv:2209.07686*, 2022.

402 Alexander Robey, Eric Wong, Hamed Hassani, and George J. Pappas. SmoothLLM: Defending Large
403 Language Models Against Jailbreaking Attacks. *Transactions on Machine Learning Research*,
404 2025.

405 Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang,
406 Mingchuan Zhang, Y.K. Li, Y. Wu, and Daya Guo. DeepSeekMath: Pushing the Limits of Math-
407 ematical Reasoning in Open Language Models. *arXiv:2402.03300*, 2024.

408 Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov.
409 Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *Journal of Machine Learn-
410 ing Research*, 15:1929–1958, 2014.

411 Zhenpeng Su, Leiyu Pan, Minxuan Lv, Yuntao Li, Wenping Hu, Fuzheng Zhang, Kun Gai, and
412 Guorui Zhou. CE-GPPO: Coordinating Entropy via Gradient-Preserving Clipping Policy Opti-
413 mization in Reinforcement Learning. In *ACL*, 2026.

414 Shenzhi Wang, Le Yu, Chang Gao, Chujie Zheng, Shixuan Liu, Rui Lu, Kai Dang, Xionghui Chen,
415 Jianxin Yang, Zhenru Zhang, Yuqiong Liu, An Yang, Andrew Zhao, Yang Yue, Shiji Song, Bowen
416 Yu, Gao Huang, and Junyang Lin. Beyond the 80/20 Rule: High-Entropy Minority Tokens Drive
417 Effective Reinforcement Learning for LLM Reasoning. In *NeurIPS*, 2025.

- 418 Ruibin Xiong, Yunchang Yang, Di He, Kai Zheng, Shuxin Zheng, Chen Xing, Huishuai Zhang,
419 Yanyan Lan, Liwei Wang, and Tie-Yan Liu. On Layer Normalization in the Transformer Architec-
420 ture. In *International Conference on Machine Learning (ICML)*, 2020.
- 421 Yige Xu, Xu Guo, Zhiwei Zeng, and Chunyan Miao. SoftCoT: Soft Chain-of-Thought for Efficient
422 Reasoning with LLMs. In *ACL*, 2025.
- 423 An Yang, Beichen Zhang, Binyuan Hui, Bofei Gao, Bowen Yu, Chengpeng Li, Dayiheng Liu,
424 Jianhong Tu, Jingren Zhou, Junyang Lin, Keming Lu, Mingfeng Xue, Runji Lin, Tianyu Liu,
425 Xingzhang Ren, and Zhenru Zhang. Qwen2.5-Math Technical Report: Toward Mathematical
426 Expert Model via Self-Improvement. *arXiv:2409.12122*, 2024.
- 427 Wengao Ye, Yan Liang, and Lianlei Shan. Thinking on the Fly: Test-Time Reasoning Enhancement
428 via Latent Thought Policy Optimization. In *ICLR*, 2026.
- 429 Qiying Yu, Zheng Zhang, Ruofei Zhu, Yufeng Yuan, Xiaochen Zuo, Yu Yue, Weinan Dai, Tiantian
430 Fan, Gaohong Liu, Juncai Liu, Lingjun Liu, Xin Liu, Haibin Lin, Zhiqi Lin, Bole Ma, Guangming
431 Sheng, Yuxuan Tong, Chi Zhang, Mofan Zhang, Ru Zhang, Wang Zhang, Hang Zhu, Jinhua Zhu,
432 Jiaze Chen, Jiangjie Chen, Chengyi Wang, Hongli Yu, Yuxuan Song, Xiangpeng Wei, Hao Zhou,
433 Jingjing Liu, Wei-Ying Ma, Ya-Qin Zhang, Lin Yan, Yonghui Wu, and Mingxuan Wang. DAPO:
434 An Open-Source LLM Reinforcement Learning System at Scale. In *NeurIPS*, 2025.
- 435 Guibin Zhang, Muxin Fu, and Shuicheng Yan. MemGen: Weaving Generative Latent Memory for
436 Self-Evolving Agents. In *ICLR*, 2026.

437 A 실험 설정과 전체 정확도 분석

438 Table 6은 본문 Table 1에서 위치별 최고 성능만 요약해 제시한 결과를, Prefix, Infix, Suffix 별 전체
 439 정확도로 다시 펼쳐 보인다. Table 7는 각 모델-벤치마크 조합에서 사용한 RSP 토큰 수 L 을 정리
 440 한 것으로, 후보 집합 $\{10, 15, 20\}$ 에서 선택했다. 모든 실험은 단일 NVIDIA A6000 40GB GPU
 441 에서 greedy decoding으로 수행했으며, 최대 생성 길이는 MATH-500과 GSM8K에서 3,072 토큰,
 442 AIME24에서 4,096 토큰으로 고정했다. 배치 크기는 모델별로 고정했다(LLaMA-3.1-8B-Instruct
 443 와 Qwen2.5-Math-7B 계열은 16, Qwen2.5-Math-1.5B 계열은 32).

Table 6: 모델 설정, 주입 위치, 벤치마크별 정확도(%). 괄호 안 값은 baseline 대비 변화량이다. 굵게는 최고 성능, 밑줄은 각 모델-벤치마크 조합에서 두 번째 성능을 뜻한다.

Model	Mode	MATH-500	GSM8K	AIME24
<i>Instruct Models</i>				
LLaMA-3.1-8B-Instruct	Baseline	52.20	85.75	<u>6.67</u>
	Prefix	45.00 (−7.2)	76.35 (−9.4)	3.33 (−3.3)
	Infix	<u>49.40</u> (−2.8)	85.97 (+0.2)	10.00 (+3.3)
	Suffix	<u>49.40</u> (−2.8)	86.73 (+1.0)	10.00 (+3.3)
Qwen2.5-Math-7B-Instruct	Baseline	83.20	95.45	<u>13.33</u>
	Prefix	81.40 (−1.8)	94.92 (−0.5)	<u>13.33</u> (+0.0)
	Infix	84.20 (+1.0)	<u>95.60</u> (+0.2)	16.67 (+3.3)
	Suffix	<u>83.40</u> (+0.2)	95.68 (+0.2)	16.67 (+3.3)
Qwen2.5-Math-1.5B-Instruct	Baseline	73.00	85.29	10.00
	Prefix	74.80 (+1.8)	85.29 (+0.0)	<u>13.33</u> (+3.3)
	Infix	75.20 (+2.2)	85.75 (+0.5)	<u>6.67</u> (−3.3)
	Suffix	74.20 (+1.2)	84.69 (−0.6)	20.00 (+10.0)
<i>Base Models (Raw Text)</i>				
Qwen2.5-Math-7B	Baseline	72.20	<u>84.15</u>	6.67
	Prefix	<u>71.60</u> (−0.6)	84.31 (+0.2)	16.67 (+10.0)
	Infix	63.20 (−9.0)	64.29 (−19.9)	16.67 (+10.0)
	Suffix	55.60 (−16.6)	54.13 (−30.0)	<u>13.33</u> (+6.7)
Qwen2.5-Math-1.5B	Baseline	<u>61.40</u>	77.86	16.67
	Prefix	64.40 (+3.0)	<u>74.30</u> (−3.6)	<u>10.00</u> (−6.7)
	Infix	63.20 (+1.8)	73.92 (−3.9)	<u>10.00</u> (−6.7)
	Suffix	54.60 (−6.8)	58.61 (−19.3)	3.33 (−13.3)
<i>Base Models + ChatML (Format Mismatch)</i>				
Qwen2.5-Math-7B	Baseline	52.20	58.30	23.33
	Prefix	59.20 (+7.0)	56.41 (−1.9)	<u>3.33</u> (−20.0)
	Infix	<u>62.00</u> (+9.8)	69.07 (+10.8)	23.33 (+0.0)
	Suffix	70.40 (+18.2)	75.97 (+17.7)	23.33 (+0.0)
Qwen2.5-Math-1.5B	Baseline	34.40	37.45	<u>13.33</u>
	Prefix	63.40 (+29.0)	67.02 (+29.6)	20.00 (+6.7)
	Infix	39.20 (+4.8)	50.42 (+13.0)	6.67 (−6.7)
	Suffix	<u>51.00</u> (+16.6)	<u>50.64</u> (+13.2)	<u>13.33</u> (+0.0)

Table 7: 각 모델과 벤치마크에 사용한 RSP 토큰 수 (L).

Model	MATH-500	GSM8K	AIME24
LLaMA-3.1-8B-Instruct	15	20	15
Qwen2.5-Math-7B-Instruct	20	20	20
Qwen2.5-Math-1.5B-Instruct	20	10	20
Qwen2.5-Math-7B	10	10	20
Qwen2.5-Math-1.5B	10	10	20
Qwen2.5-Math-1.5B (ChatML)	20	20	10
Qwen2.5-Math-7B (ChatML)	20	20	20

444 A.1 RSP 주입 위치와 프롬프트 템플릿

445 아래에는 모든 모델 유형에서 주입 위치별 프롬프트 구조를 정리했다. **파란색 텍스트**는 RSP
 446 임베딩, **보라색 텍스트**는 특수 토큰을 뜻한다.

447 A.1.1 Prefix

448 Prefix 주입에서는 RSP 임베딩을 프롬프트 임베딩 앞에 연결한다. 텍스트 자체는 수정하지
449 않는다.

450 ChatML (Qwen Instruct / Base + ChatML).

```
[Random Embeddings (L tokens)]
<|im_start|>system
Please reason step by step, and put your final answer within \boxed{<|im_end|>
<|im_start|>user
{question}<|im_end|>
<|im_start|>assistant
```

452 LLaMA Chat Template.

```
[Random Embeddings (L tokens)]
<|begin_of_text|>
<|start_header_id|>system<|end_header_id|>
Cutting Knowledge Date: December 2023
Today Date: 26 Jul 2024
Please reason step by step, and put your final answer within \boxed{<|eot_id|>
<|start_header_id|>user<|end_header_id|>
{question}<|eot_id|>
<|start_header_id|>assistant<|end_header_id|>
```

454 Raw Text (Qwen Base).

```
[Random Embeddings (L tokens)]
{question}
Please reason step by step, and put your final answer within \boxed{<|im_end|>
```

456 A.1.2 Infix

457 Infix 주입에서는 설명 문구와 특수 토큰을 프롬프트 내부에 넣은 뒤, 그 특수 토큰 위치를 임베딩
458 수준에서 RSP로 교체한다.

459 ChatML (Qwen Instruct / Base + ChatML).

```
<|im_start|>system
Please reason step by step, and put your final answer within \boxed{<|im_end|>
<|im_start|>user
{question}

There are {L} special tokens that contain compressed latent reasoning
information that might be useful for your reasoning. If these tokens are
useful for your case, you can use them as reference. If these tokens are
not useful for your case, you can ignore them and focus back to solving the
problem.

Here are the {L} special tokens: <special_token_1>...<special_token_L>
<|im_end|>
<|im_start|>assistant
```

461 LLaMA Chat Template.

```
<|begin_of_text|>
<|start_header_id|>system<|end_header_id|>
Cutting Knowledge Date: December 2023
Today Date: 26 Jul 2024
Please reason step by step, and put your final answer within \boxed{<|im_end|>
```



```

eot_id|>
<|start_header_id|>user<|end_header_id|>
{question}

There are {L} special tokens that contain compressed latent reasoning
information that might be useful for your reasoning. If these tokens are
useful for your case, you can use them as reference. If these tokens are
not useful for your case, you can ignore them and focus back to solving the
problem.

Here are the {L} special tokens:
<reserved_special_token_0>...
<reserved_special_token_L>
<|eot_id|>
<|start_header_id|>assistant<|end_header_id|>

```

463

464 Raw Text (Qwen Base).

```

{question}

There are {L} special tokens that contain compressed latent reasoning
information that might be useful for your reasoning. If these tokens are
useful for your case, you can use them as reference. If these tokens are
not useful for your case, you can ignore them and focus back to solving the
problem.

Here are the {L} special tokens: <special_token_1>...<special_token_L>
Please reason step by step, and put your final answer within \boxed{ }.

```

465

466 A.1.3 Suffix

467 채팅 템플릿 모델에서는 end-of-turn 토큰 바로 앞에 RSP 임베딩을 넣고, raw text 모델에서는
468 프롬프트 마지막에 RSP 임베딩을 이어 붙인다.

469 ChatML (Qwen Instruct / Base + ChatML).

```

<|im_start|>system
Please reason step by step, and put your final answer within \boxed{ }.<|
im_end|>
<|im_start|>user
{question}[Random Embeddings (L tokens)]<|im_end|>
<|im_start|>assistant

```

470

471 LLaMA Chat Template.

```

<|begin_of_text|>
<|start_header_id|>system<|end_header_id|>
Cutting Knowledge Date: December 2023
Today Date: 26 Jul 2024
Please reason step by step, and put your final answer within \boxed{ }.<|
eot_id|>
<|start_header_id|>user<|end_header_id|>
{question}[Random Embeddings (L tokens)]<|eot_id|>
<|start_header_id|>assistant<|end_header_id|>

```

472

473 Raw Text (Qwen Base).

```

{question}
Please reason step by step, and put your final answer within \boxed{ }. [Random
Embeddings (L tokens)]

```

474

475 A.2 정답 추출과 채점

476 최종 정답은 fallback 체인을 통해 모델 출력에서 추출한다. 각 단계는 순서대로 시도하며, 추출에
477 실패하면 다음 단계로 넘어간다.

정답 추출 fallback 체인

1. "final answer is \$...\$. I hope" 패턴 (Minerva 형식)
2. `\boxed{...}`: 마지막 비어 있지 않은 box를 사용하고, 빈 `\boxed{}`는 건너뛰
3. "the answer is" 뒤 텍스트
4. "final answer is" 뒤 텍스트
5. 출력 마지막 숫자(regex fallback)

478

479 추출된 정답은 `$`, `\left`, `\right`, 단위 문자열을 제거해 정규화한다. 채점은 sym-
480 bolic equivalence checking으로 수행하며, 정확한 문자열 일치, 수치 비교(`math.isclose`,
481 `rel_tol=1e-4`), SymPy symbolic simplification을 차례로 적용한다.

482 A.3 재현한 선행연구의 하이퍼파라미터

483 모든 선행 방법은 Qwen2.5-Math-1.5B-Instruct와 Qwen2.5-Math-7B-Instruct에서 재현했으며,
484 greedy decoding(`temperature = 0`)과 통일된 answer extraction pipeline으로 평가했다.

485 **TTSV.** Prefix 길이는 20이며, AdamW optimizer로 20 epoch 동안 학습했다. 배치 크기는 2,
486 gradient accumulation은 8 step, 스케줄은 선형 learning rate schedule을 사용했다. Learning rate
487 는 Qwen-1.5B에 1e-3, Qwen-7B에 1e-5를 사용했다.

488 **LTPO.** Table 8는 벤치마크별 하이퍼파라미터를 정리한 것이다.

Table 8: LTPO 하이퍼파라미터.

Parameter	GSM8K	MATH-500	AIME24
tokens	8	8	8
steps	20	20	20
top_k	10	10	10
sigma	20	20	5
sigma_decay	0.95	0.95	0.95
lr	1e-2	5e-3	5e-2

489 **SoftCoT.** Projection module은 10 epoch 동안 학습했다. Thought token 수는 학습 시 32, 평가 시
490 4다. 배치 크기는 GSM8K에서 4, MATH에서는 1이며 gradient accumulation 4를 사용했다. 작은
491 모델(assistant)은 두 설정 모두 Qwen2.5-Math-1.5B-Instruct이고, 큰 모델은 Qwen2.5-Math-1.5B-
492 Instruct(`learning rate 2e-5`) 또는 Qwen2.5-Math-7B-Instruct(`learning rate 5e-6`)이다. MATH-500
493 과 AIME24 평가는 GSM8K에서 학습한 projection module을 사용했는데, MATH에서 학습한
494 버전보다 더 높은 정확도를 보였기 때문이다.

495 A.4 전체 엔트로피 곡선

496 Figure 5는 entropy, top-1 probability, varentropy의 전체 정규화 생성 궤적(0-100%)을 보여준다.
497 모든 방법은 생성 초반 단계를 지나면 비슷한 수준으로 수렴하며, 이는 RSP가 유도하는 분포
498 변화가 초기 추론 단계에 국소화되어 있음을 다시 확인해 준다.




Figure 5: 전체 정규화 생성 궤적(0-100%)에서의 평균 entropy(위), top-1 probability(가운데), varentropy(아래). MATH-500 전체 평균이며, 음영은 ± 1 SEM을 뜻한다. 실선은 RSP 변형과 baseline, 점선은 기존 soft prompt 방법이다. 모든 방법은 초반 단계를 지나면 수렴한다.

499 B 의미적 다양성에 대한 추가 분석

500 이 부록은 Section 4.4에서 보고한 의미적 다양성 결과를 보충한다. 더 넓은 문제 집합에 대해
501 문제별 t-SNE 도표를 함께 제시한다.



Figure 6: 평가한 64개 MATH-500 문제 중 48개에 대한 BGE-M3 임베딩의 t-SNE 투영(6×8 격자). 각 subplot은 Qwen2.5-Math-1.5B-Instruct에서 $\tau = 1.0$ 으로 생성한 baseline 300개(빨강)와 RSP suffix 300개(파랑)를 보여준다. 채워진 표식은 정답, 빈 표식은 오답이며, 제목은 subject/problem_id를 뜻한다. 대부분의 문제에서 RSP 궤적은 여러 개의 분리된 영역으로 퍼지는 반면, baseline 샘플은 하나의 지배적 클러스터에 더 집중된다.

502 C 토큰 수준 분포 지표

503 이 부록은 Section 4.4의 토큰 수준 분석에 사용한 세 지표를 형식적으로 정의한다. P_{base} 는
504 $\tau = 1.0$ 에서의 baseline 다음 토큰 분포, P_{target} 은 비교 대상 분포(예: $\tau = 2.0$ 의 baseline, 또는
505 $\tau = 1.0$ 의 RSP)라 하자. 모든 지표는 첫 생성 단계에서 저장한 logits로부터 해석적으로 계산
506 한다.

507 **Spearman 순위 상관.** Spearman의 ρ 는 두 분포의 토큰 순위 사이 Pearson 상관계수다.

$$\rho = \text{Pearson}(\text{rank}(P_{\text{target}}), \text{rank}(P_{\text{base}})). \quad (4)$$

508 Temperature scaling $P^{(\tau)} \propto P^{1/\tau}$ 는 엄격한 단조 변환이므로, 어떤 $\tau > 0$ 에서도 토큰 순서를
509 정확히 보존한다. 따라서 $\rho = 1$ 은 수학적 항등식이다. 그러므로 $\rho < 1$ 은 temperature scaling
510 만으로는 만들 수 없는 순위 재조작이 일어났음을 뜻한다.

511 **Top- K 밖의 질량.** $\text{TopK}(P_{\text{base}})$ 를 P_{base} 에서 확률이 가장 높은 K 개 토큰의 집합이라 하자. 비
512 교 대상 분포가 이 집합 밖에 두는 확률 질량은

$$\text{MassOutside}_K = 1 - \sum_{t \in \text{TopK}(P_{\text{base}})} P_{\text{target}}(t). \quad (5)$$

513 이 지표는 지지 집합 확장을 직접 측정한다. 즉 baseline의 선호 집합에 없던 토큰에 비교 대상이
514 얼마나 많은 확률을 배정하는지를 본다. 본문에 보고한 값은 $K = 10$ 을 사용했다.

515 **Jensen-Shannon divergence.** Kullback-Leibler divergence의 대칭적이고 bounded된 형태는 다
516 음과 같다.

$$\text{JS}(P, Q) = \frac{1}{2} \text{KL}(P \parallel M) + \frac{1}{2} \text{KL}(Q \parallel M), \quad M = \frac{1}{2}(P + Q). \quad (6)$$

517 로그는 밑이 2이므로 $\text{JS} \in [0, 1]$ 이다. 저장한 top-100 바깥의 토큰에는 softmax 전에 sentinel
518 $\text{logit}(-10^9)$ 을 넣었는데, 본 설정에서는 top-5가 이미 확률 질량의 99.9% 이상을 덮기 때문에 이
519 근사는 무시 가능하다.

520 D 이론에 필요한 Prompt 법칙의 성질

521 이 부록은 본문에서 실제로 사용하는 성질만 남긴다: 중심성, 분산 예산 아래의 방향 무관 공
522 분산, 그리고 모든 비공집합 열린집합에 대한 양의 확률이다. Section 3.4의 메커니즘에는 이
523 기하학적·측도론적 사실만 필요하므로, 더 강한 의미론적 해석은 쓰지 않는다.

524 D.1 중심화된 섭동은 체계적인 1차 드리프트를 만들지 않는다

525 토큰 i, j 의 baseline logit gap을 Δ_{ij} 라 하고 1차 surrogate를

$$\Delta_{ij}(\bar{h}) = \Delta_{ij} + b_{ij}^\top \bar{h}$$

526 로 두자.

527 **명제 4** (체계적인 1차 드리프트의 부재). $\mathbb{E}[\bar{h}] = 0$ 이면 모든 토큰 쌍 (i, j) 에 대해

$$\mathbb{E}[\Delta_{ij}(\bar{h})] = \Delta_{ij}$$

528 가 성립한다. 반대로 결정적 prompt h_0 를 모든 run에 재사용하면

$$\Delta_{ij}(h_0) - \Delta_{ij} = b_{ij}^\top h_0$$

529 는 고정된 방향 편향이다.

530 *Proof.* 중심화된 경우는 기대값의 선형성으로 바로 나온다.

$$\mathbb{E}[\Delta_{ij}(\bar{h})] = \Delta_{ij} + b_{ij}^\top \mathbb{E}[\bar{h}] = \Delta_{ij}.$$

531 결정적 경우는 그대로 대입하면 된다. □

532 이 명제가 뜻하는 것은 run 평균에서의 1차 편향이 없다는 점이지, 개별 샘플이 logit을 바꾸지
533 않는다는 뜻은 아니다.

534 D.2 Theorem 2의 증명

535 본문의 local linear logit surrogate에 직접 등장하는 양은 단위벡터 b 에 대한 1차 섭동 에너지
536 $\text{Var}_{h \sim D}(b^\top h) = b^\top \Sigma_D b$ 이다. 따라서 최악 방향의 에너지는 Σ_D 의 최소 Rayleigh quotient와
537 같다.

538 *Theorem 2의 증명.* Σ_D 의 고윳값을 $\lambda_1, \dots, \lambda_d$ 라 하면,

$$\lambda_{\min}(\Sigma_D) \leq \frac{1}{d} \sum_{m=1}^d \lambda_m = \frac{\text{tr}(\Sigma_D)}{d} \leq \frac{\rho^2}{d}.$$

539 모든 고윳값이 같을 때, 즉 $\Sigma_D = (\rho^2/d)\mathbf{I}_d$ 일 때 그리고 그럴 때만 등호가 성립한다. □

540 이 증명에는 공분산만 필요하다. RSP에서 가우시안을 택하는 이유는 다음 소절의 열린집합
541 도달 가능성까지 함께 얻기 위해서다.

542 D.3 등방 가우시안 프롬프트의 열린집합 도달 가능성

543 **명제 5** (열린집합 도달 가능성). $\sigma > 0$ 이고 $\bar{h} \sim \mathcal{N}(0, \sigma^2 \mathbf{I}_d)$ 라 하자. 그러면 모든 비공집합
544 열린집합 $U \subseteq \mathbb{R}^d$ 에 대해

$$\Pr(\bar{h} \in U) > 0$$

545 가 성립한다.

546 *Proof.* 가우시안 밀도

$$(2\pi\sigma^2)^{-d/2} \exp\left(-\frac{\|\bar{h}\|^2}{2\sigma^2}\right)$$

547 는 $\mathbb{R}^d$ 의 모든 점에서 엄밀히 양수다. 모든 비공집합 열린집합은 양의 르베그 측도를 갖는 ball
548 하나를 포함하므로, 그 ball 위에서 양의 밀도를 적분하면 양의 확률이 얻어진다. □

549 이것이 Proposition 2에 실제로 쓰이는 유일한 support 성질이다.

550 E 본문 이론 결과의 증명

551 이 부록은 본문 이론결과 같은 순서를 따른다: exploration, annealing, 성능 향상. 그보다 앞에서
552 필요한 prompt 법칙의 성질은 Appendix D에 모아 두었다.

553 E.1 Exploration: attention decomposition과 perturbation 크기

554 **명제 6** (Attention decomposition). Query 위치 i , layer ℓ 에서 실제 토큰 n 개와 RSP 토큰 L 개에
555 대한 attention weight를 $\alpha_{ij}^{(\ell)}$ 라 하자. RSP attention mass를

$$w_{r,i}^{(\ell)} := \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)}$$

556 로 두고, $j \in [n]$ 에 대해

$$\tilde{\alpha}_{ij}^{(\ell)} := \frac{\alpha_{ij}^{(\ell)}}{1 - w_{r,i}^{(\ell)}}$$

557 라 정의하면,

$$\mathbf{x}_i^{(\ell+1)} = (1 - w_{r,i}^{(\ell)}) \tilde{\mathbf{x}}_i^{(\ell+1)} + \boldsymbol{\eta}_i^{(\ell)}$$

558 이고

$$\tilde{\mathbf{x}}_i^{(\ell+1)} := \sum_{j=1}^n \tilde{\alpha}_{ij}^{(\ell)} \mathbf{v}_j^{(\ell)}, \quad \boldsymbol{\eta}_i^{(\ell)} := \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{r_j}^{(\ell)}.$$

559 *Proof.* Attention 출력은 실제 토큰 항과 RSP 토큰 항으로 정확히 나뉜다.

$$\mathbf{x}_i^{(\ell+1)} = \sum_{j=1}^n \alpha_{ij}^{(\ell)} \mathbf{v}_j^{(\ell)} + \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{r_j}^{(\ell)}.$$

560 정의상 $\sum_{j=1}^n \alpha_{ij}^{(\ell)} = 1 - w_{r,i}^{(\ell)}$ 이므로 실제 토큰 항은

$$\sum_{j=1}^n \alpha_{ij}^{(\ell)} \mathbf{v}_j^{(\ell)} = (1 - w_{r,i}^{(\ell)}) \sum_{j=1}^n \frac{\alpha_{ij}^{(\ell)}}{1 - w_{r,i}^{(\ell)}} \mathbf{v}_j^{(\ell)} = (1 - w_{r,i}^{(\ell)}) \tilde{\mathbf{x}}_i^{(\ell+1)}$$

561 가 된다. 이를 대입하면 분해가 바로 따른다. □

562 **따름정리 1** (크기는 RSP attention mass로 통제된다). 무작위 value가 어떤 값으로 실현되었든,

$$\|\boldsymbol{\eta}_i^{(\ell)}\| \leq w_{r,i}^{(\ell)} \max_{j \in [L]} \|\mathbf{v}_{r_j}^{(\ell)}\|.$$

563 *Proof.* 삼각부등식을 쓰면

$$\|\boldsymbol{\eta}_i^{(\ell)}\| = \left\| \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{r_j}^{(\ell)} \right\| \leq \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \|\mathbf{v}_{r_j}^{(\ell)}\| \leq w_{r,i}^{(\ell)} \max_{j \in [L]} \|\mathbf{v}_{r_j}^{(\ell)}\|.$$

564 □

565 Corollary 1가 본문에 필요한 유일한 정량적 사실이다. Attention weight와 random key 사이의 독
566 립성은 가정하지 않는다. $w_{r,i}^{(\ell)}$ 가 작아지면 RSP 기여의 크기도 같은 스칼라에 의해 작게 묶인다.

567 E.2 Annealing: upper/lower envelope의 증명

568 **Theorem 1 (upper envelope)의 증명.** 실제 토큰과 RSP 토큰의 scaled attention score를

$$s_j^{(\ell)} := (\mathbf{q}_i^{(\ell)})^\top \mathbf{k}_j^{(\ell)} / \sqrt{d} \quad (j \in [n]), \quad s_{r,j'}^{(\ell)} := (\mathbf{q}_i^{(\ell)})^\top \mathbf{k}_{r,j'}^{(\ell)} / \sqrt{d} \quad (j' \in [L])$$

569 로 두고, $s_{r,\max}^{(\ell)} := \max_{j'} s_{r,j'}^{(\ell)}$, $R^{(\ell)} := \sum_{j'=1}^L \exp(s_{r,j'}^{(\ell)})$ 라 하자. 정방향 gap의 정의에서 모든
570 $j \in [n]$ 에 대해

$$s_j^{(\ell)} \geq s_{r,\max}^{(\ell)} + \Delta_i^{(\ell)} / \sqrt{d}$$

571 이고, $\exp(s_{r,\max}^{(\ell)}) \geq R^{(\ell)} / L$ ($\max \geq \text{avg}$)이므로 n 개 실제 키의 합은

$$\sum_{j=1}^n \exp(s_j^{(\ell)}) \geq n \exp(\Delta_i^{(\ell)} / \sqrt{d}) \exp(s_{r,\max}^{(\ell)}) \geq \frac{n \exp(\Delta_i^{(\ell)} / \sqrt{d})}{L} R^{(\ell)}$$

572 로 묶인다. softmax 정규화에서 RSP 측 mass는

$$w_{r,i}^{(\ell)} = \frac{R^{(\ell)}}{\sum_{j=1}^n \exp(s_j^{(\ell)}) + R^{(\ell)}} \leq \frac{R^{(\ell)}}{(n \exp(\Delta_i^{(\ell)} / \sqrt{d}) / L) R^{(\ell)} + R^{(\ell)}} = \frac{L}{L + n \exp(\Delta_i^{(\ell)} / \sqrt{d})}.$$

573 **Proposition 1 (lower envelope)의 증명.** 대칭이다. $s_{r,\min}^{(\ell)} := \min_{j'} s_{r,j'}^{(\ell)}$ 로 두면 역방향 gap 정
574 의에서 모든 $j \in [n]$ 에 대해

$$s_j^{(\ell)} \leq s_{r,\min}^{(\ell)} + \Delta_i'^{(\ell)} / \sqrt{d}$$

575 이고, $\exp(s_{r,\min}^{(\ell)}) \leq R^{(\ell)} / L$ ($\min \leq \text{avg}$)이므로

$$\sum_{j=1}^n \exp(s_j^{(\ell)}) \leq \frac{n \exp(\Delta_i'^{(\ell)} / \sqrt{d})}{L} R^{(\ell)}$$

576 이다. 따라서

$$w_{r,i}^{(\ell)} = \frac{R^{(\ell)}}{\sum_{j=1}^n \exp(s_j^{(\ell)}) + R^{(\ell)}} \geq \frac{L}{L + n \exp(\Delta_i'^{(\ell)} / \sqrt{d})}.$$

577 E.3 Annealing: cache 성장에 따른 따름정리

578 두 envelope에서 다음 두 따름정리가 따른다.

579 **따름정리 2** (fixed-gap envelope의 시퀀스 방향 단조 감소). L 과 $\Delta_i^{(\ell)}$ 를 고정하면, 상계

$$f(n) = \frac{L}{L + n \exp(\Delta_i^{(\ell)} / \sqrt{d})}$$

580 는 n 에 대해 엄격히 감소한다. 따라서 같은 gap을 유지한다는 가정 아래, cache 성장만으로 그
581 gap과 양립 가능한 최대 RSP attention mass의 envelope이 단조롭게 좁아진다.

582 자기회귀 디코딩에서는 새 토큰이 생성될 때마다 query · key · hidden state가 함께 갱신되어 $\Delta_i^{(\ell)}$
583 도 step별로 변하므로, “실현된 mass가 매 step 단조 감소한다”가 아니라 “같은 gap이 유지되는
584 한 가능한 최대 mass의 envelope이 단조 감소한다”가 정확한 진술이다.

585 *Proof.* $f(n)$ 을 n 에 대해 미분하면

$$f'(n) = -\frac{L \exp(\Delta_i^{(\ell)} / \sqrt{d})}{\left(L + n \exp(\Delta_i^{(\ell)} / \sqrt{d})\right)^2} < 0.$$

586 따라서 $f(n)$ 은 엄격히 감소한다. □

587 **따름정리 3** (고정 gap envelope 아래의 RSP 기여 감쇠). L 과 $\Delta_i^{(\ell)}$ 를 고정하고 $n \rightarrow \infty$ 이면
 588 $w_{r,i}^{(\ell)} \rightarrow 0$ 이다. 또한 RSP value의 고정된 실현에 대해

$$\|\eta_i^{(\ell)}\| \leq w_{r,i}^{(\ell)} \max_{j \in [L]} \|\mathbf{v}_{r_j}^{(\ell)}\| \rightarrow 0.$$

589 *Proof.* Corollary 2에서 $w_{r,i}^{(\ell)} \rightarrow 0$ 이다. 나머지는 Corollary 1의 상계를 그대로 적용하면 된다.
 590 유한한 개수의 sampled value에 대한 최대 norm은 고정 실현에서 유한하다. $\square$

591 E.4 Annealing: 국소 Lipschitz 제어 아래의 유한 깊이 전파

592 transformer block은 attention sublayer + residual + FFN sublayer + residual의 형태로 작동한다.

$$\mathbf{x}_i^{(\ell, \text{attn})} = \mathbf{x}_i^{(\ell)} + \text{Attn}^{(\ell)}(\mathbf{x}_i^{(\ell)}), \quad \mathbf{x}_i^{(\ell+1)} = \mathbf{x}_i^{(\ell, \text{attn})} + F^{(\ell)}(\mathbf{x}_i^{(\ell, \text{attn})}).$$

593 $\mathbf{x}_i^{(\ell, \text{attn}, \text{RSP})}$, $\mathbf{x}_i^{(\ell, \text{attn}, \text{base})}$ 를 같은 입력 $\mathbf{x}_i^{(\ell)}$ 에 RSP attention과 baseline attention을 각각 적용한 post-
 594 attention state라 하자. RSP 길이 L 과 충돌하지 않도록 FFN sublayer Lipschitz 상수를 $\kappa^{(\ell)}$, block
 595 전체 Lipschitz 상수를 $\kappa_B^{(\ell)}$, 모델 깊이를 Λ 로 표기한다.

596 **보조정리 1** (Per-block FFN 전파). *post-attention difference* 는

$$\|\mathbf{x}_i^{(\ell, \text{attn}, \text{RSP})} - \mathbf{x}_i^{(\ell, \text{attn}, \text{base})}\| \leq \|\eta_i^{(\ell)}\| + w_{r,i}^{(\ell)} \|\tilde{\mathbf{x}}_i^{(\ell+1)}\|$$

597 를 만족한다. 또한 $F^{(\ell)}$ 이 두 state를 포함하는 유계 집합 위에서 $\kappa^{(\ell)}$ -Lipschitz 라면

$$\|\mathbf{x}_i^{(\ell+1, \text{RSP})} - \mathbf{x}_i^{(\ell+1, \text{base})}\| \leq (1 + \kappa^{(\ell)}) (\|\eta_i^{(\ell)}\| + w_{r,i}^{(\ell)} \|\tilde{\mathbf{x}}_i^{(\ell+1)}\|).$$

598 *Proof.* Baseline 에서는 $\mathbf{x}_i^{(\ell, \text{attn}, \text{base})} = \mathbf{x}_i^{(\ell)} + \tilde{\mathbf{x}}_i^{(\ell+1)}$ 이고, RSP 측은 Proposition 6에 의해
 599 $\mathbf{x}_i^{(\ell, \text{attn}, \text{RSP})} = \mathbf{x}_i^{(\ell)} + (1 - w_{r,i}^{(\ell)}) \tilde{\mathbf{x}}_i^{(\ell+1)} + \eta_i^{(\ell)}$ 이다. 차를 취하면

$$\mathbf{x}_i^{(\ell, \text{attn}, \text{RSP})} - \mathbf{x}_i^{(\ell, \text{attn}, \text{base})} = \eta_i^{(\ell)} - w_{r,i}^{(\ell)} \tilde{\mathbf{x}}_i^{(\ell+1)}$$

600 이고 삼각부등식이 첫 부등식을 준다. 둘째 부등식은 post-FFN 차이를

$$[\mathbf{x}_i^{(\ell, \text{attn}, \text{RSP})} + F^{(\ell)}(\mathbf{x}_i^{(\ell, \text{attn}, \text{RSP})})] - [\mathbf{x}_i^{(\ell, \text{attn}, \text{base})} + F^{(\ell)}(\mathbf{x}_i^{(\ell, \text{attn}, \text{base})})]$$

601 로 적고 Lipschitz 부등식 $\|F^{(\ell)}(\cdot) - F^{(\ell)}(\cdot)\| \leq \kappa^{(\ell)} \|\cdot - \cdot\|$ 을 적용해 얻는다. $\square$

602 **따름정리 4** (Cross-block 전파 제어). $\Delta^{(\ell)} := \mathbf{x}_i^{(\ell, \text{RSP})} - \mathbf{x}_i^{(\ell, \text{base})}$, $\Delta^{(0)} = \mathbf{0}$ 로 두고, baseline block
 603 map $B_{\text{base}}^{(\ell)} : \mathbf{x} \mapsto \mathbf{x} + \text{Attn}^{(\ell)}(\mathbf{x}) + F^{(\ell)}(\mathbf{x} + \text{Attn}^{(\ell)}(\mathbf{x}))$ 와 RSP-augmented block map $B_{\text{RSP}}^{(\ell)}$ 가 두
 604 trajectory를 포함하는 ball 위에서 공통 국소 Lipschitz 상수 $\kappa_B^{(\ell)}$ 를 갖는다 하자 (표준 transformer
 605 block에서 Attn, LayerNorm, FFN이 모두 임의의 유계 집합 위에서 국소 Lipschitz 이고 [Xiong
 606 et al., 2020, Kim et al., 2021], RSP 토큰은 매 layer에 유한 개의 softmax 항만 추가하므로 이런
 607 상수가 존재한다). 이때

$$\|\Delta^{(\ell+1)}\| \leq (1 + \kappa_B^{(\ell)}) \|\Delta^{(\ell)}\| + (1 + \kappa^{(\ell)}) (\|\eta_i^{(\ell)}\| + w_{r,i}^{(\ell)} \|\tilde{\mathbf{x}}_i^{(\ell+1)}\|)$$

608 가 성립하고, Λ 개 블록을 $\Delta^{(0)} = \mathbf{0}$ 에서 출발해 펼치면

$$\|\Delta^{(\Lambda)}\| \leq \sum_{\ell=0}^{\Lambda-1} \prod_{\ell'=\ell+1}^{\Lambda-1} (1 + \kappa_B^{(\ell')}) \cdot (1 + \kappa^{(\ell)}) (\|\eta_i^{(\ell)}\| + w_{r,i}^{(\ell)} \|\tilde{\mathbf{x}}_i^{(\ell+1)}\|)$$

609 를 얻는다.

610 *Proof.* layer $\ell + 1$ 에서의 cross-block 차이를

$$\Delta^{(\ell+1)} = \underbrace{B_{\text{RSP}}^{(\ell)}(\mathbf{x}^{(\ell, \text{RSP})}) - B_{\text{RSP}}^{(\ell)}(\mathbf{x}^{(\ell, \text{base})})}_{\text{(I) 기존 } \Delta^{(\ell)} \text{의 전파}} + \underbrace{B_{\text{RSP}}^{(\ell)}(\mathbf{x}^{(\ell, \text{base})}) - B_{\text{base}}^{(\ell)}(\mathbf{x}^{(\ell, \text{base})})}_{\text{(II) block } \ell \text{에서의 RSP 주입}}$$

611 로 분해한다. (I)는 block Lipschitz로 $\|(I)\| \leq \kappa_B^{(\ell)} \|\Delta^{(\ell)}\|$ 이고, residual을 합치면 $(1 + \kappa_B^{(\ell)})$ 인자
 612 가 된다. (II)는 Lemma 1의 per-block 주입 상계 $(1 + \kappa^{(\ell)}) (\|\eta_i^{(\ell)}\| + w_{r,i}^{(\ell)} \|\tilde{\mathbf{x}}_i^{(\ell+1)}\|)$ 이다. 삼각부
 613 등식으로 recursion이 따르고, $\Delta^{(0)} = \mathbf{0}$ 에서 펼치면 displayed sum이 나온다. $\square$

표준 architecture에서 $\kappa^{(\ell)}$ 의 유계성. LayerNorm은 원점에서 떨어진 임의의 유계 집합 위에서 $\|\gamma\|/\inf\|x\|$ 정도의 Lipschitz 상수를 가지며 [Xiong et al., 2020], GELU나 SwiGLU는 부드러운 함수이므로 유계 활성 영역에서 국소 Lipschitz, 선형 사영의 Lipschitz 상수는 가중치 행렬의 spectral norm이다. self-attention sublayer의 Lipschitz는 $\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V$ 의 spectral norm과 inverse-temperature β 에 의해 결정된다 [Kim et al., 2021]. 한 forward pass가 지나는 유계 활성 영역 위에서 Corollary 4의 per-block Lipschitz 상수는 모두 유한하므로, 고정 깊이 Λ 에서 $\|\Delta^{(\Lambda)}\|$ 의 누적 상계도 유한하다. depth-uniform 비확장은 추가적인 수축 가정을 요구하므로 본 논문은 주장하지 않는다. 새 주입 한 번의 크기는 $w_{r,i}^{(\ell)}$ 가 결정한다.

622 E.5 성능 향상: local admission에서 Pass@N까지

본문 §3.4는 1차 surrogate 위에서 두 가지를 주장한다. baseline 밖 토큰이 국소 top- K 집합에 진입할 수 있다는 점과, 독립 재실행이 그런 국소 진입을 Pass@ N 이득으로 바꾼다는 점이다. 아래 증명은 centered prompt 법칙 D 의 다음 support 조건만 사용한다.

$$(S1) \quad D(U) > 0 \quad \text{for every nonempty open set } U \subseteq \mathbb{R}^d.$$

Section 3.4의 등방 가우시안 법칙은 Proposition 5에 의해 (S1)을 만족한다.

627 E.5.1 자기회귀 정식화

자기회귀 decoding에서 시퀀스 $y_{1:T}$ 의 결합 분포는

$$\Pr(y_{1:T} | x) = \prod_{t=1}^T p(y_t | x, y_{<t}),$$

로 분해된다. 각 단계는 prefix에 조건부인 분포로 결정되므로, RSP가 도입한 섭동은 단일한 전역 분포를 한 번에 바꾸는 것이 아니라 $p(y_t | x, y_{<t})$ 에 대한 일련의 국소 변화로 작동한다.

631 E.5.2 RSP 하에서의 logits 국소 선형화

이 소절에서 $\bar{h} \in \mathbb{R}^d$ 는 RSP 정의(Eq. (1) in §3.1)에 등장하는 centered prompt 벡터 하나를 뜻한다. 실제 구현은 길이 L 의 prompt $\mathbf{H} = (h_1, \dots, h_L)$ 를 사용하지만, 아래 논리는 개별 국소 섭동이 logits를 어떻게 움직일 수 있는지를 분리해서 본다. 섭동된 logits를 $z_i(\bar{h})$ 로 두고 $\bar{h} = 0$ 근방에서 국소 smoothness를 가정하면

$$z_i(\bar{h}) = z_i(0) + \nabla_h z_i(0)^\top \bar{h} + r_i(\bar{h}),$$

여기서 $r_i(\bar{h}) = O(\|\bar{h}\|^2)$ 이다. $a_i := \nabla_h z_i(0)$ 라 두면 1차 affine surrogate는

$$z_i^{\text{lin}}(\bar{h}) := z_i + a_i^\top \bar{h}$$

가 된다. 이는 branch opening을 설명하는 1차 surrogate이지, transformer logits 전체의 정확한 전역 모델은 아니다.

639 E.5.3 Proposition 2의 증명

진입 영역을

$$\mathcal{G}_{i,K} := \{\bar{h} \in \mathbb{R}^d : \#\{j \neq i : z_j^{\text{lin}}(\bar{h}) > z_i^{\text{lin}}(\bar{h})\} \leq K-1\}$$

로 두자.

Proof. $\mathcal{G}_{i,K}$ 가 비공집합 열린집합 U 를 포함한다고 하자. 그러면 (S1)에 의해 $D(U) > 0$ 이고, $U \subseteq \mathcal{G}_{i,K}$ 이므로

$$\Pr_{\bar{h}}(\bar{h} \in \mathcal{G}_{i,K}) \geq D(U) > 0$$

가 성립한다. 이는 정확히 토큰 i 가 surrogate top- K 집합에 진입하는 사건이다.

실용적인 충분조건은 어떤 $\bar{h}_0$ 에서 토큰 i 가 많아야 $K-1$ 개의 토큰만 자신보다 앞서도록 엄격한 마진을 만드는 경우다. 연속성에 의해 이때 $\bar{h}_0$ 의 근방 비공집합 열린집합이 $\mathcal{G}_{i,K}$ 에 포함된다. $\square$

648 **E.5.4 Proposition 3의 증명**

649 이 명제는 메커니즘만으로 $p_{\min}(x) > 0$ 을 도출하지 않는다. 과제 측 하한과 독립성이 주어졌을
650 때 이를 Pass@N 증가로 바꾸는 역할만 한다.

651 *Proof.* A_n 을 문제 x 에서 n 번째 독립 RSP 실행이 정답 궤적에 도달하는 사건이라 하고, (M1)에
652 따라 $p_n(x) := \Pr(A_n) \geq p_{\min}(x)$ 라 하자. (M2) 아래에서

$$\Pr\left(\bigcap_{n=1}^N A_n^c\right) = \prod_{n=1}^N (1 - p_n(x)) \leq \prod_{n=1}^N (1 - p_{\min}(x)) = (1 - p_{\min}(x))^N.$$

653 여집합을 취하면

$$\Pr(\text{Pass@N on } x) = \Pr\left(\bigcup_{n=1}^N A_n\right) \geq 1 - (1 - p_{\min}(x))^N.$$

654 마지막 부등식 $1 - x \leq e^{-x}$ ($x \in [0, 1]$)을 적용하면

$$1 - (1 - p_{\min}(x))^N \geq 1 - e^{-N p_{\min}(x)}$$

655 을 얻는다. □

656 F Attention Mass 분석

657 이 부록은 Figure 1에 보고한 per-token attention mass를 형식화하고, reasoning span과 layer 축에
 658 적용한 제외 기준을 명시한다. 500개의 MATH-500 문제 각각에 대해 새로운 $\text{RSP } \mathbf{H} \in \mathbb{R}^{L \times d}$ 를
 659 $L = 10$ 으로 독립 샘플링했으므로, 보고한 heatmap은 문제 자체의 변동성과 RSP 벡터 변동성을
 660 함께 평균한 결과다.

661 F.1 토큰당 attention 질량

662 각 문제에서 attention은 연결된 시퀀스 [prompt; $\mathbf{H}$; generation] 위에서 측정하며, generation은
 663 같은 모델이 동일한 RSP 주입 설정 아래 생성한 궤적이다. $\alpha_{i,j}^{(\ell,h)}$ 를 layer ℓ , head h 에서 query
 664 위치 i 가 key 위치 j 로 보내는 post-softmax attention weight라고 하자. 이는 causal mask 아래에서
 665 $\sum_j \alpha_{i,j}^{(\ell,h)} = 1$ 을 만족한다. 질문 토큰과 RSP 토큰의 인덱스 집합을 각각 Q , R 라 하고 크기를
 666 $|Q|$, $|R| = L$, head 수를 H 라 하자. 이때 query i 가 각 그룹으로 보내는 layer ℓ 의 per-token
 667 attention mass는

$$\text{PTM}_Q[\ell, i] = \frac{1}{|Q|H} \sum_{h=1}^H \sum_{j \in Q} \alpha_{i,j}^{(\ell,h)}, \quad \text{PTM}_R[\ell, i] = \frac{1}{|R|H} \sum_{h=1}^H \sum_{j \in R} \alpha_{i,j}^{(\ell,h)}. \quad (7)$$

668 $|Q|$ 와 $|R|$ 로 나누는 정규화는 집합 크기 차이를 보정하므로, 두 양은 동일한 softmax 분모 아래
 669 에서 질문 토큰 또는 RSP 토큰 하나가 평균적으로 얼마나 많은 attention을 받는지를 나타낸다.
 670 따라서 질문 토큰은 시퀀스 길이 효과를 흡수하는 크기 보정 baseline 역할을 한다.

671 F.2 Heatmap 집계

672 Layer 인덱스와 reasoning position 인덱스를 각각 동일 크기의 다섯 구간 $\{B_L^{(b)}\}_{b=1}^5$, $\{B_P^{(b)}\}_{b=1}^5$
 673 로 나눈다. 샘플 s 와 목표 집합 $\bullet \in \{Q, R\}$ 에 대해 셀 (b_L, b_P) 의 값은

$$M_{\bullet}^{(s)}[b_L, b_P] = \frac{1}{|B_L^{(b_L)}| \cdot |B_P^{(b_P)}|} \sum_{\ell \in B_L^{(b_L)}} \sum_{i \in B_P^{(b_P)}} \text{PTM}_{\bullet}[\ell, i]. \quad (8)$$

674 Figure 1는 Eq. (8)를 500개의 유효 샘플에 대해 평균한 결과를 보고한다.

675 F.3 \boxed{\dots} 구간 제외

676 Reasoning position 범위는 마지막 \boxed{\dots} 구간이 시작되기 직전에 끝나도록 잡는다.
 677 Chain-of-thought 출력은 *text*(내용)와 *pattern*(형식) 성분으로 나뉘며, 이 둘은 downstream 성
 678 능에 독립적으로 기여할 수 있다 [Madaan and Yazdanbakhsh, 2022]. \boxed{\dots} 래퍼는 전형
 679 적인 pattern 성분이다. 이는 추론을 더 전개하기보다는 답 형식을 마무리하는 짧고 정형화된
 680 span이기 때문이다. 이 구간을 포함하면 reasoning dynamics와 무관한 template-driven attention
 681 signature가 섞이게 된다.

682 F.4 마지막 두 레이어 제외

683 Layer 축에서는 마지막 두 transformer layer도 제외한다. 이는 모델 특이적 tuning이 아니라, late
 684 layer에서 나타나는 표준적 현상을 피하기 위한 선택이다.

685 **출력 투영 특화.** 마지막 레이어 근방의 hidden state는 vocabulary logits와 거의 선형 관계를 이
 686 루므로, 표현을 바꾸는 블록이라기보다 점진적 선형 readout으로 기능한다 [Belrose et al., 2023].
 687 같은 맥락에서 late-layer feed-forward module도 출력 분포를 조정하는 메커니즘으로 해석되어
 688 왔다 [Geva et al., 2021]. 따라서 이 레이어들의 attention은 reasoning computation보다 output
 689 formation을 더 강하게 반영한다.

690 마지막 두 레이어를 제외하면 heatmap이 readout 단계보다 reasoning 단계의 attention dynamics
 691 에 더 집중한다. 이 제외는 본문 claim에 필수적이지 않다. 본문이 강조하는 시퀀스 방향
 692 attenuation은 이 제외 없이도 관찰되며, Theorem 1이 다루는 것도 layer 방향 단조성이 아니라
 693 sequence-direction attenuation이기 때문이다.

694 F.5 추가적인 suffix heatmap

695 Figure 7는 suffix 주입에서 Qwen2.5-Math-1.5B-Instruct와 LLaMA-3.1-8B-Instruct에 대해 동일한
 696 per-token RSP attention 분석을 보고한다. 앞서 설명한 late-layer 이유 때문에 모든 셀에서 패턴이
 697 완전히 동일하게 일반화되지는 않지만, 두 모델 모두에서 시퀀스 방향(가로축)의 단조 감소는
 698 §3.3의 cache-growth upper envelope가 예측한 것과 일치한다. layer 축(세로)의 추가 감소는 별
 699 개의 경험적 sharpening 현상으로, Theorem 1만으로 직접 따라오는 결과는 아니다.




Figure 7: 나머지 두 모델(각각 500개 MATH-500 샘플)에서 suffix 주입 시 측정한 per-token RSP attention mass. 축과 전처리는 Figure 1와 동일하다. x축은 다섯 분위로 나눈 reasoning position, y축은 다섯 분위로 나눈 layer depth(위가 얇은 층), 색은 RSP 토큰에 할당된 per-token attention의 500샘플 평균을 뜻한다. `\boxed{ }` 구간 내부 토큰과 마지막 두 레이어는 제외했다.

700 G GRPO 정식화

701 주어진 프롬프트 q 에 대해, behavior policy $\pi_{\theta_{\text{old}}}$ 는 보상 $\{R_i\}_{i=1}^G$ 를 갖는 응답 집합 $\{o_i\}_{i=1}^G$ 를
 702 샘플링한다. 각 응답의 advantage는 그룹 수준 보상을 정규화해 계산한다.

$$\hat{A}_{i,t} = \frac{R_i - \text{mean}(\{R_i\}_{i=1}^G)}{\text{std}(\{R_i\}_{i=1}^G)}. \quad (9)$$

703 정책은 KL penalty가 포함된 clipped objective로 업데이트한다.

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left(\min \left(r_{i,t} \hat{A}_{i,t}, \text{clip}(r_{i,t}, 1-\varepsilon, 1+\varepsilon) \hat{A}_{i,t} \right) - \beta D_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}}) \right) \right], \quad (10)$$

704 여기서 $r_{i,t} = \pi_{\theta}(o_{i,t} \mid q, o_{i,<t}) / \pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})$ 는 importance sampling ratio이고, ε 는 clipping
 705 범위, β 는 reference policy π_{ref} 에 대한 KL penalty 세기를 조절한다.

706 H 광범위한 영향

707 본 연구는 무작위 임베딩 주입이 대형 언어 모델의 추론 행동에 어떤 영향을 주는지에 대한
708 실험적·이론적 분석을 제공한다. 기여의 성격은 주로 기초 연구에 가깝지만, GRPO와 같은
709 강화학습 기반 추론 모델 후속학습에는 잠재적 함의를 가진다.

710 **긍정적 영향.** RSP가 유도하는 궤적 다양성은 group-relative advantage estimation 안에서 더
711 풍부한 학습 신호를 제공함으로써, RL 기반 LLM 후속학습의 sample efficiency를 높일 수 있다.
712 이는 reasoning 중심 fine-tuning과 alignment에 필요한 계산 비용을 줄여, 자원이 제한된 연구
713 그룹에도 관련 방법을 더 접근 가능하게 만들 수 있다.

714 **잠재적 우려.** LLM의 유효 출력 지지 집합을 넓히는 방법은 바람직한 대안적 추론 경로뿐
715 아니라, 바람직하지 않거나 분포 밖에 있는 출력의 도달 가능성도 함께 높일 수 있다. 따라서
716 RSP를 실제 시스템에 적용할 때는 이를 독립적인 다양성 원천으로만 보지 말고, 기존의 안전
717 필터링 및 alignment 메커니즘과 함께 사용해야 한다.

718 **영향 범위의 한계.** 본 연구는 새로운 모델이나 데이터셋을 배포하기보다 분석을 제공하는 데
719 초점을 두므로, 직접적인 사회적 영향은 제한적이다. 여기서 논의한 더 넓은 함의는 RSP가 실제
720 학습 파이프라인에 통합되는 향후 연구가 이루어질 때에만 현실화될 수 있다.