

노이즈에서 다양성으로: 대형 언어 모델 추론에서의 무작위 임베딩 주입

Anonymous Author(s)

Affiliation

Address

email

Abstract

최근 *soft prompt* 계열 방법은 가상 토큰 형태의 학습 가능한 연속 임베딩을 LLM 입력 앞이나 중간에 삽입해 수학 추론 성능을 높여 왔다. 그러나 임베딩 주입 자체가, 최적화와는 독립적으로, 모델의 행동에 어떤 영향을 주는지는 거의 분석되지 않았다. 본 논문은 학습 없이 주입되는 Random Soft Prompt(RSP)를 다룬다. RSP는 사전학습된 임베딩 행렬의 행별 평균과 분산을 맞춘 등방 가우시안에서 샘플링한 연속 벡터를 그대로 삽입한 것이다. RSP에서 무작위성은 임베딩 분포를 모사하는 장치가 아니라, 같은 프롬프트가 rollout마다 독립적인 섭동을 만들도록 해 주는 성질이며, 탐색은 바로 이 독립성을 요구한다. 이론적으로는 각 어텐션 레이어에서 RSP의 기여가 무작위 토큰 어텐션 질량이라는 단일 스칼라로 정확히 포착되고, 그 양의 *fixed-gap* 상한 envelope이 자기회귀적 캐시 성장에 따라 좁아짐을 보인다. 또한 섭동된 logits에 대한 국소 affine 분석 아래에서 등방 재추첨은 rank-preserving temperature sampling이 만들 수 없는 top- K 진입 영역에 양의 확률을 부여할 수 있다. 실험적으로 RSP는 생성 초반의 토큰 엔트로피를 높이지만 이후에는 분포가 다시 안정화되며, temperature sampling과 결합할 경우 Pass@ N 으로 측정한 추론 궤적 다양성을 더 크게 확장한다. 마지막으로 이러한 다양성이 학습 신호의 질에 중요한 GRPO 학습에 갖는 함의도 논의한다.

1 서론

대형 언어 모델(LLM)이 수십억 개 이상의 파라미터로 커지면서 전체 파라미터를 모두 미세조정하는 비용도 빠르게 증가했다. 이에 따라 고정된 모델에 소수의 추가 파라미터만 도입해 적응시키는 parameter-efficient 방법이 주목받고 있다 [Hu et al., 2022, Houlsby et al., 2019]. 그중 *soft prompt*는 학습 가능한 연속 임베딩을 입력 시퀀스 앞이나 중간에 삽입해 attention 메커니즘을 통해 모델 행동을 조정하는 대표적 접근이다 [Li and Liang, 2021, Lester et al., 2021]. 이러한 패러다임은 수학 추론을 강화하는 데에도 활발히 활용되고 있다 [Kang et al., 2026, Xu et al., 2025, Ye et al., 2026, Hao et al., 2025, Zhang et al., 2026]. 세부 설계는 다르지만, 이들 방법은 모두 사전학습 어휘 바깥의 연속 임베딩을 주입하고 그것을 최적화해 downstream 성능을 끌어 올린다는 공통 구조를 갖는다.

하지만 우리는 이러한 효과에 최적화가 반드시 필요한 것은 아님을 관찰했다. 무작위로 초기화된, 학습되지 않은 연속 임베딩을 주입하는 것만으로도 출력 분포가 바뀔 수 있다. 예를 들어 채팅 형식으로 학습되지 않은 base model에 chat template을 적용하면 프롬프트 형식 불일치 때문에 추론 성능이 크게 떨어지는데, 여기에 무작위 임베딩을 덧붙이면 이 성능 저하가 완화된다. 단순한 노이즈가 모델을 혼드는 데 그친다면 정확도는 더 나빠져야 한다. 이는 학습된 의미 내용과 무관하게, 어휘 바깥의 연속 임베딩을 입력에 주입하는 행위 자체가 모델 행동을 비자명하게 바꿀 수 있음을 시사한다. 기존 연구는 대체로 *soft prompt* 방법을 최종 정확도로만 평가했기 때문에, 주입 자체의 효과와 최적화의 효과가 분리되어 있지 않으며, 이런 연속 임베딩 주입이 출력 분포를 어떻게 바꾸는지는 여전히 충분히 탐구되지 않았다.

본 연구는 학습 없이 주입되는 Random Soft Prompt(RSP)의 역할을 분석한다. RSP는 사전학습된 임베딩 행렬의 항별 평균과 분산을 맞춘 등방 가우시안에서 샘플링한 연속 벡터다. 여기서 무작위성은 임베딩 분포를 모사하는 장치가 아니라, 같은 프롬프트가 rollout마다 독립적인 섭동을 만들도록 해 주는 성질이며, 탐색은 바로 이 독립성을 요구한다. 이론적으로는 어텐션 수준의 메커니즘을 식별한다. 각 어텐션 레이어에서 RSP의 기여는 무작위 토큰 어텐션 질량이라는 단일 스칼라로 정확히 포착되고, 그 양의 fixed-gap 상한 envelope은 자기회귀적 캐시 성장에 따라 좁아진다. 또한 섭동된 logits에 대한 국소 affine 분석 아래에서, 등방 재추첨이 rank-preserving temperature sampling이 만들 수 없는 top- K 진입 영역에 양의 확률을 부여할 수 있음을 보인다. 실험적으로 RSP는 생성 초반의 토큰 엔트로피를 높이지만 후반으로 갈수록 출력은 다시 안정화되며, temperature sampling과 결합할 경우 Pass@ N 의 증가로 드러나는 더 다양한 추론 궤적을 만들어 낸다. 마지막으로 이러한 다양성이 효과적인 학습 신호에 필수적인 Group Relative Policy Optimization(GRPO) [Shao et al., 2024]와 어떤 관련을 갖는지도 논의한다.

본 논문의 기여는 다음과 같다.

- 트랜스포머 수준 메커니즘을 제시한다. RSP의 기여는 cache-growth 상한 envelope을 갖는 단일 스칼라 어텐션 질량으로 통제되며, 국소 affine surrogate 위의 분포 분석 아래에서 고정 섭동이 아닌 등방 재추첨이 temperature sampling으로 만들 수 없는 top- K 진입 영역에 도달할 수 있음을 보인다.
- RSP가 LLM 생성에 어떤 변화를 주는지 실증적으로 분석하고, RSP가 생성 초반의 토큰 엔트로피를 높이며 temperature sampling과 결합될 때 더 다양한 추론 궤적을 만들고, 같은 RSP를 모든 sample에 공유하면 누적 이득이 사라진다는 점을 보인다.
- RSP가 유도하는 다양성이 GRPO 학습에 어떤 함의를 갖는지 논의하고, RSP는 순위를 바꾸는 섭동인 반면 temperature는 순위를 보존하는 섭동이라는 점에서, 두 방법이 직교하는 탐색 이득을 제공한다고 주장한다.

2 배경

2.1 LLM 추론을 위한 Soft Prompt 기법

Soft prompt는 전체 미세조정의 대안으로 등장했다. Prefix-Tuning [Li and Liang, 2021]이 학습 가능한 연속 벡터를 각 transformer 레이어 앞에 붙이는 패러다임을 제시한 이후, Prompt Tuning [Lester et al., 2021]은 입력 레이어만 사용하는 단순화된 형태로도 충분히 큰 모델에서 전체 미세조정에 근접한 성능을 보였고, P-tuning [Liu et al., 2024]은 LSTM prompt encoder로 위치 간 의존성까지 포착했다. 이 패러다임은 LLM 추론에도 빠르게 적용되었다. TTSV [Kang et al., 2026]는 테스트 시점에 prefix 임베딩을 엔트로피 최소화해 최적화해 잠재 추론을 활성화하고, SoftCoT [Xu et al., 2025]은 assistant model이 만든 soft token으로 명시적 chain-of-thought를 대체한다. LTPO [Ye et al., 2026]는 confidence 기반 내재 보상으로 latent thought 임베딩을 샘플별로 최적화하며, COCONUT [Hao et al., 2025]은 모델 자신의 은닉 상태를 다시 입력 임베딩으로 되먹여 연속 잠재 공간에서 추론하게 만든다. MemGen [Zhang et al., 2026]은 임베딩이 경험 메모리로 기능할 수 있음을 보였고, Pause token [Goyal et al., 2024]은 학습 가능한 토큰을 입력 중간에 끼워 넣어 추가 계산 단계를 제공한다. 이들 모두 어휘 바깥의 연속 임베딩을 과제 특화 목적함수로 최적화해 정확도를 끌어올린다. 그러나 평가가 최종 정확도에 맞춰져 있어 “주입 자체”의 효과와 “최적화”의 효과가 분리되지 않으며, 단순한 임베딩 주입이 모델 행동을 어떻게 바꾸는지는 별도의 미해결 문제로 남아 있다.

2.2 신경망에서의 노이즈 주입

신경망에는 여러 단계에서 노이즈가 도입되어 왔다. 학습 시점에서는 dropout [Srivastava et al., 2014]이 은닉 유닛을 무작위로 비활성화해 과적합을 막고, NEFTune [Jain et al., 2024]은 instruction fine-tuning 중 토큰 임베딩에 노이즈를 더해 instruction following을 개선한다. 추론 시점의 섭동은 주로 강건성을 겨냥한다. Randomized smoothing [Cohen et al., 2019]은 입력 가우시안 노이즈로 certified robustness를 얻고, SmoothLLM [Robey et al., 2025]은 문자 단위 프롬프트 변형으로 jailbreak를 방어한다. 강화학습에서는 NoisyNet [Fortunato et al., 2018]이 가중치에 학습 가능한 노이즈를 넣어 탐색 성능을 높였다.

RSP는 이들과 세 가지 점에서 구별된다. (1) 어떠한 학습도 없이 추론 시점에만 동작하므로 모델 파라미터를 건드리지 않는다(dropout, NEFTune, NoisyNet과 다르다). (2) 원래 입력을 보존한 채 새 임베딩을 한 번의 forward pass에 덧붙일 뿐이며, 강건성 방법이 요구하는 “여러 번의 noisy

88 pass와 출력 집계”가 필요 없다. (3) 학습된 파라미터 없이 사전학습 임베딩 통계에서 직접
 89 샘플링한 무작위 벡터를 그대로 쓴다(NoisyNet은 노이즈 파라미터 자체를 학습한다). 무엇보다
 90 RSP의 목적은 출력 안정성이 아니라 탐색이며, 본 논문은 이 차이가 어텐션 수준에서 어떻게
 91 작동하는지 분석한다.

92 3 Random Soft Prompt와 작동 원리

93 이 절은 논문에서 사용하는 핵심 메커니즘을 정리한다. rollout은 한 번 샘플한 RSP를 고정한 채
 94 끝까지 수행한 자기회귀 디코딩 한 번을 뜻한다. 한 rollout 안에서 RSP는 attention을 통해서만
 95 hidden state에 진입한다. 초반 영향력을 만들 수 있는 같은 어텐션 질량은 실제 토큰이 누적
 96 될수록 cache-growth envelope의 제약을 받는다. rollout 사이에서는 독립 재추첨이, 아래에서
 97 명시하는 task 측 가정 아래, 초반 분기 차이를 Pass@N 이득으로 누적할 수 있다. 본문에는 핵심
 98 명제와 직관만 두고, 추가 도출은 Appendix E에 있다.

99 3.1 Random Soft Prompt

100 먼저 분석 대상부터 정리한다. 토큰 임베딩 행렬을 $\mathbf{W}_E \in \mathbb{R}^{V \times d}$ 로 두자(V 는 어휘 크기, d 는
 101 은닉 차원). 그 행별 평균과 표준편차를 $\mu_E := \frac{1}{Vd} \sum_{i,k} [\mathbf{W}_E]_{i,k}$, $\sigma_E := \text{std}(\mathbf{W}_E)$ 라 하자. 길이
 102 L 의 RSP는 다음 분포에서 독립 추첨한 연속 벡터 시퀀스 $\mathbf{H} = [h_1, \dots, h_L] \in \mathbb{R}^{L \times d}$ 이다.

$$h_j \sim \mathcal{N}(\mu_E \mathbf{1}_d, \sigma_E^2 \mathbf{I}_d), \quad j = 1, \dots, L. \quad (1)$$

103 중심화된 $\bar{h}_j := h_j - \mu_E \mathbf{1}_d \sim \mathcal{N}(0, \sigma_E^2 \mathbf{I}_d)$ 은 평균 0의 등방 가우시안이다. 입력 임베딩 시퀀스
 104 $\mathbf{X}$ 에는 prefix $[\mathbf{H}; \mathbf{X}]$, infix, suffix $[\mathbf{X}; \mathbf{H}]$ 세 방식 가운데 하나로 주입한다 [Kang et al., 2026, Xu
 105 et al., 2025, Ye et al., 2026, Zhang et al., 2026]. 반복 샘플링 프로토콜에서는 비교하는 rollout
 106 들의 prompt 추첨과 디코딩 무작위성을 모두 독립으로 둔다.

107 무작위성의 목적은 임베딩 분포를 흉내 내는 데 있지 않다. 같은 텍스트 prompt를 여러 번 실행할
 108 때 각 rollout이 독립적인 섭동을 받도록 하는 데 있다. 탐색에 필요한 것은 바로 그 독립성이다.

109 3.2 Exploration: RSP가 hidden state에 들어오는 방식

110 먼저 한 번의 RSP 주입이 hidden state를 어떻게 흔드는지부터 묻는다. RSP는 hidden state에
 111 직접 더해지지 않고 어텐션 가중치를 통해서만 들어가므로, 한 attention head 안에서의 즉각적
 112 영향은 RSP 토큰에 배정된 어텐션 질량이라는 한 가지 양으로 모인다.

113 self-attention 레이어 ℓ 의 한 attention head가 마스크되지 않은 실제 토큰 $n \geq 1$ 개와 RSP 토큰
 114 $L \geq 1$ 개를 함께 attend한다고 하자. 모든 attention logit은 유한하다고 두며, 어텐션 가중치를
 115 $\alpha_{ij}^{(\ell)}$, value 벡터를 실제 측과 RSP 측에서 각각 $\mathbf{v}_j^{(\ell)}$, $\mathbf{v}_{r_j}^{(\ell)}$ 로 쓴다. 무작위 토큰에 배정된 총 어텐
 116 션 질량을 $w_{r,i}^{(\ell)} := \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)}$ 로 두면 실제 토큰 질량은 양수이고, head output은 다음 형태로
 117 정확히 정리된다.

$$\mathbf{o}_i^{(\ell)} = (1 - w_{r,i}^{(\ell)}) \tilde{\mathbf{o}}_i^{(\ell)} + \boldsymbol{\eta}_i^{(\ell)}, \quad \tilde{\mathbf{o}}_i^{(\ell)} := \sum_{j=1}^n \frac{\alpha_{ij}^{(\ell)}}{1 - w_{r,i}^{(\ell)}} \mathbf{v}_j^{(\ell)}, \quad \boldsymbol{\eta}_i^{(\ell)} := \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{r_j}^{(\ell)}. \quad (2)$$

118 Eq. (2)의 도출. head output을 $\sum_{j=1}^n \alpha_{ij}^{(\ell)} \mathbf{v}_j^{(\ell)} + \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{r_j}^{(\ell)}$ 로 나눈 뒤, 실제 토큰 항에서
 119 정규화 인자 $1 - w_{r,i}^{(\ell)} = \sum_{j=1}^n \alpha_{ij}^{(\ell)} > 0$ 를 묶어 내면 된다. softmax 정규화 항등식 외에는 어떤
 120 근사도 쓰이지 않는다. $\square$

121 이 한 양 $w_{r,i}^{(\ell)}$ 이 두 가지를 동시에 통제한다는 점에 주목하자. 실제 신호의 감쇠 비율 $1 - w_{r,i}^{(\ell)}$ 과
 122 무작위 기여 항의 진폭 상계 $\|\boldsymbol{\eta}_i^{(\ell)}\| \leq w_{r,i}^{(\ell)} \max_j \|\mathbf{v}_{r_j}^{(\ell)}\|$ 이 모두 같은 스칼라에 매여 있다. RSP
 123 가 만드는 변동은 다차원 섭동이 아니라 0과 1 사이 한 값을 추적하는 문제로 환원된다. 디코딩
 124 초반에는 캐시가 짧아 $w_{r,i}^{(\ell)}$ 이 무시할 수 없는 값을 가질 수 있으므로, 무작위 기여를 묶어 두는
 125 같은 항등식이 동시에 한 번의 RSP가 초반 next-token 결정을 흔들 수 있는 조건도 마련한다.

126 3.3 Annealing: 캐시 성장이 RSP 어텐션을 희석한다

127 다음 자연스러운 질문은 디코딩이 진행되면 이 값이 어떻게 변하는가이다. 자기회귀 생성에서
 128 KV 캐시는 매 step 실제 토큰 항을 하나씩 추가하지만 RSP 항의 개수는 고정되어 있다. 실제
 129 토큰과 RSP 토큰 사이의 logit gap을 고정해 보면, 이 cache growth는 다음 상계로 나타난다.

130 **정리 1** (캐시 성장에 의한 fixed-gap 상계 감소). *Query*가 실제 토큰 $n \geq 1$ 개와 RSP 토큰 $L \geq 1$
 131 개를 *attend*하고 모든 *logit*이 유한하다고 하자. 사전 스케일 *logit gap*을 $\Delta_i^{(\ell)} := \min_{j \in [n]} \mathbf{q}_i^\top \mathbf{k}_j -$
 132 $\max_{j' \in [L]} \mathbf{q}_i^\top \mathbf{k}_{r,j'}$ 로 두면 *scaled-dot-product* 어텐션에서

$$w_{r,i}^{(\ell)} \leq \frac{L}{L + n \exp(\Delta_i^{(\ell)} / \sqrt{d})}$$

133 가 성립하며, 우변은 L 과 $\Delta_i^{(\ell)}$ 를 고정한 채 n 에 대해 엄격히 감소하고 0으로 수렴한다.

134 *Proof.* $s_j := \mathbf{q}_i^\top \mathbf{k}_j / \sqrt{d}$, $s_{r,j'} := \mathbf{q}_i^\top \mathbf{k}_{r,j'} / \sqrt{d}$, $s_{r,\max} := \max_{j'} s_{r,j'}$, $R := \sum_{j'=1}^L \exp(s_{r,j'})$ 로 두
 135 자. gap 정의에서 모든 실제 토큰 j 에 대해 $s_j \geq \Delta_i^{(\ell)} / \sqrt{d} + s_{r,\max}$ 이고, max는 average보다
 136 크므로 $\exp(s_{r,\max}) \geq R/L$ 이다. 두 사실을 결합해 n 개 실제 토큰을 합하면 $\sum_{j=1}^n \exp(s_j) \geq$
 137 $(n/L) \exp(\Delta_i^{(\ell)} / \sqrt{d}) R$ 이다. 이를 $w_{r,i}^{(\ell)} = R / (\sum_j \exp(s_j) + R)$ 에 대입하면

$$w_{r,i}^{(\ell)} \leq \frac{R}{(n/L) \exp(\Delta_i^{(\ell)} / \sqrt{d}) R + R} = \frac{L}{L + n \exp(\Delta_i^{(\ell)} / \sqrt{d})}$$

138 가 따른다. 우변의 미분은 $-L \exp(\Delta_i^{(\ell)} / \sqrt{d}) / (L + n \exp(\Delta_i^{(\ell)} / \sqrt{d}))^2 < 0$ 이므로 n 에 대해 엄격
 139 히 감소하고, $n \rightarrow \infty$ 일 때 0으로 수렴한다. $\square$

140 이 부등식 한 줄에 두 메커니즘이 동시에 담겨 있다. RSP 길이 L 은 우리가 정하는 설계 파라미터
 141 로 분자에 들어가 최대 영향력을 결정한다. 반면 실제 토큰 수 n 은 매 step 자동으로 늘어 분모를
 142 키우므로, 같은 L 아래에서도 영향력의 상계는 시간이 갈수록 좁아진다. 정리가 보장하는 것은
 143 같은 layer, 같은 query 위치, 같은 *logit gap* 아래에서 RSP attention의 상한 *envelope*이 시퀀스
 144 길이 방향으로 좁아진다는 점뿐이다 — 즉 autoregressive position 방향의 attenuation이지 layer
 145 깊이 방향의 monotonic decay는 아니다. 새 토큰이 생성될 때마다 query · key · hidden state가
 146 갱신되어 $\Delta_i^{(\ell)}$ 도 시간에 따라 변하므로, “실행된 attention mass의 매 step 단조 감소”가 아니라
 147 “같은 gap이 유지되는 한 가능한 최대값의 단조 envelope 감소”가 정확하다. Eq. (2)이 무작위
 148 기여를 같은 스칼라로 묶어 두므로 perturbation 크기도 같은 envelope의 제약을 받는다. 따라서
 149 RSP 효과는 생성 초반에 상대적으로 크게 열리고 토큰 누적과 함께 가능한 상계가 좁아지는,
 150 암묵적 explore-then-exploit 해석을 갖는다. 이는 실현값의 stepwise 단조 감소를 주장하는 것이
 151 아니다. Figure 1는 이 sequence-direction 예측을 실증한다.




Figure 1: Qwen2.5-Math-7B에서 측정된 토큰별 어텐션 질량(suffix, MATH-500 500문제, 문제마다 독립 RSP). (a) RSP 토큰 어텐션은 추론 위치 축(가로)에서 감소하며, 이는 Theorem 1의 cache-growth 상계와 일치한다. 레이어 축(세로)의 추가 감소는 별도의 경험적 현상으로, 깊은 레이어에서 실제 토큰과 RSP 토큰 사이의 logit gap이 더 날카로워지는 경향을 시사하지만 Theorem 1만으로 직접 따라오지는 않는다. (b) 질문 토큰 어텐션은 비교적 균일하게 유지된다. 그림에 보고한 양은 Appendix F의 per-token mass로, RSP 길이 L 로 나눈 평균 값이며 본문 $w_{r,i}^{(\ell)}$ 와는 상수배 관계다.

152 3.4 Performance gain: 왜 독립 재실행이 도움이 되는가

153 Theorem 1는 한 rollout 안에서 RSP가 얼마나 움직일 수 있는지를 설명한다. 남은 질문은 성능
154 이다. 왜 새로운 RSP로 다시 실행할 때 하나의 고정된 prompt를 반복하는 것보다 이득이 커질
155 수 있는가? 여기에는 prompt 분포에 대한 사실 하나와, 열린 branch가 정답에 도움이 되는지에
156 대한 별도의 task-side 사실 하나가 필요하다.

157 먼저 분포 쪽 사실. 위 어텐션 항등식은 등방성을 요구하지 않지만, branch opening은 현재
158 prompt에 중요한 방향을 미리 편들지 않는 분포를 선호한다. 여기서는 길이 L prompt 안의
159 centered RSP 벡터 하나를 분리한 국소 surrogate에 대해 서술한다. 이를 미니맥스로 형식화하면
160 다음과 같다.

161 **정리 2** (방향 무관 미니맥스 커버리지). $\mathbb{R}^d$ 위 평균 0 분포 D 가 분산 예산 $\text{tr}(\Sigma_D) \leq \rho^2$ 를
162 만족하면 $\min_{\|b\|=1} \text{Var}_{h \sim D}(b^\top h) = \lambda_{\min}(\Sigma_D) \leq \rho^2/d$ 이고, 등호는 $\Sigma_D = (\rho^2/d)\mathbf{I}_d$ 일 때에만
163 성립한다.

164 등호의 핵심은 가우시안 자체가 아니라 등방 공분산이다. 같은 분산 예산 아래에서 “가장 덜
165 탐색되는 방향”을 가장 크게 만드는 분포는 등방 공분산을 가진 분포다. RSP는 스케일은 임
166 베딩에서 빌려 오되 방향 기하는 의도적으로 버리는 설계가 된다. 등방 가우시안은 추가로 $\mathbb{R}^d$
167 전역에서 양의 밀도 (full support)를 가지므로 어떤 방향에 대해서도 사전 가중치를 두지 않는다
168 (Appendix D). 학습된 고정 prompt($\Sigma_D = 0$), PCA 정렬 노이즈, 어휘 토큰 추첨, 임베딩 공분산
169 정합은 모두 등방이 아니므로 적어도 한 방향에서 덜 탐색하게 된다.

170 이제 surrogate 위에서 branch opening을 형식화한다. 중심화된 prompt $\bar{h}$ 근방에서 logit을 1차로
171 근사한 surrogate $z_i^{\text{lin}}(\bar{h}) := z_i + a_i^\top \bar{h}$, $a_i := \nabla_{\bar{h}} z_i(0)$ 를 둔다. baseline 외 토큰 i 의 top- K 진입
172 영역을 $\mathcal{G}_{i,K} := \{\bar{h} \in \mathbb{R}^d : \#\{j \neq i : z_j^{\text{lin}}(\bar{h}) > z_i^{\text{lin}}(\bar{h})\} \leq K-1\}$ 로 둔다(이는 실제 top- K
173 정의와 정확히 맞는다).

174 **명제 1** (조건부 top- K 진입). $\mathcal{G}_{i,K}$ 가 비공집합 열린집합을 포함한다고 하자. 등방 가우시안의
175 full support가 그 영역에 양의 확률을 부여하므로 $\mu_i := \Pr_{\bar{h}}(\bar{h} \in \mathcal{G}_{i,K}) > 0$ 이다.

176 이 명제는 조건부 도달 가능성을 말한다. surrogate 안에 그런 국소 top- K 영역이 존재하기만
177 하면, RSP 법칙은 그 영역에 양의 확률을 부여한다. 영역 자체의 존재는 여전히 task 측 조건이지,
178 메커니즘만으로 자동 보장되는 결론이 아니다. 단발 진입 확률을 task accuracy로 끌어올리려면
179 두 가지를 추가 가정한다. (M1) 단발 RSP 실행이 정답 trajectory를 만들 주변 확률 $p_{\min}(x) > 0$
180 이 양수다. (M2) N 번의 실행은 상호 독립이다.

181 **명제 2** (다중 경로 Pass@ N). (M1)–(M2) 아래에서, N 개의 독립 RSP 실행은
182 $\Pr(\text{Pass}@N \text{ on } x) \geq 1 - (1 - p_{\min}(x))^N \geq 1 - \exp(-N p_{\min}(x))$ 를 만족한다.

183 이 역할 분담이 이 절의 핵심 해석이다. 해당 진입 영역이 존재할 때 메커니즘은 baseline 외
184 토큰을 후보권 안으로 들일 수 있지만, 들인 branch가 생산적이라는 점은 task의 성질이다. 같은
185 RSP를 모든 sample이 공유하면 이 누적이 사라지므로 독립이 핵심이다. §4는 바로 이 서명을
186 실험적으로 확인한다.

187 4 실험적 확인

188 앞 절의 설명이 실제 LLM 생성에서 어떻게 드러나는지를 세 장면으로 살펴본다. 먼저 RSP가
189 baseline 정확도를 크게 깎지 않으면서 일부 설정에서는 오히려 회복시키는지를 확인하고 (§4.2),
190 다음으로 attention decomposition과 cache-growth envelope가 시사하는 초반 다양화와 후반 안정
191 화가 실제로 관찰되는지를 살펴 (§4.3), 끝으로 같은 RSP를 재사용할 때와 매 시도마다 새로
192 뽑을 때의 Pass@ N 차이가 독립성이 핵심이라는 점을 직접 보여 주는지를 본다 (§4.4).

193 4.1 실험 설정

194 평가는 세 가지 수학 추론 벤치마크 MATH-500 [Lightman et al., 2024], GSM8K [Cobbe et al.,
195 2021], AIME24에서 수행한다. 모델은 LLaMA-3.1-8B-Instruct [Grattafiori et al., 2024]와
196 Qwen2.5-Math 계열 [Yang et al., 2024]을 쓰며, instruct, base, 그리고 chat template이 맞지 않
197 는 base 설정까지 합쳐 총 일곱 가지를 비교한다. 모든 실험은 sampling 자체의 무작위성과 RSP
198 효과를 분리하기 위해 greedy decoding을 사용하고, fallback 기반 answer extraction pipeline으로

Table 1: 모델 설정과 벤치마크별 정확도(%). RSP는 주입 위치(Prefix, Infix, Suffix) 중 최고 성능만 보고한다. 위치별 전체 결과는 Appendix A에 있다. 괄호 안 값은 baseline 대비 변화량이다.

Model	MATH-500		GSM8K		AIME24	
	Baseline	RSP	Baseline	RSP	Baseline	RSP
<i>Instruct Models</i>						
LLaMA-3.1-8B-Inst	52.20	49.40 (−2.8)	85.75	86.73 (+1.0)	6.67	10.00 (+3.3)
Qwen2.5-Math-7B-Inst	83.20	84.20 (+1.0)	95.45	95.68 (+0.2)	13.33	16.67 (+3.3)
Qwen2.5-Math-1.5B-Inst	73.00	75.20 (+2.2)	85.29	85.75 (+0.5)	10.00	20.00 (+10.0)
<i>Base Models (Raw Text)</i>						
Qwen2.5-Math-7B	72.20	71.60 (−0.6)	84.15	84.31 (+0.2)	6.67	16.67 (+10.0)
Qwen2.5-Math-1.5B	61.40	64.40 (+3.0)	77.86	74.30 (−3.6)	16.67	10.00 (−6.7)
<i>Base Models + ChatML (Format Mismatch)</i>						
Qwen2.5-Math-7B	52.20	70.40 (+18.2)	58.30	75.97 (+17.7)	23.33	23.33 (+0.0)
Qwen2.5-Math-1.5B	34.40	63.40 (+29.0)	37.45	67.02 (+29.6)	13.33	20.00 (+6.7)

Table 2: 기존 soft prompt 방법(TTSV, SoftCoT, LTPO)과의 통합 평가 비교. Baseline과 RSP 값은 Table 1에서 가져왔다. **Bold**는 최고 성능, underline은 두 번째 성능이다.

Model	Benchmark	Baseline	RSP	TTSV	SoftCoT	LTPO
Qwen2.5-Math-7B-Instruct	MATH-500	83.20	84.20	<u>83.80</u>	82.80	83.00
	GSM8K	<u>95.45</u>	95.68	95.30	95.00	94.84
	AIME24	13.33	<u>16.67</u>	23.30	<u>16.67</u>	13.33
Qwen2.5-Math-1.5B-Instruct	MATH-500	73.00	<u>75.20</u>	<u>75.20</u>	76.00	72.40
	GSM8K	85.29	85.75	<u>85.70</u>	84.46	84.53
	AIME24	<u>10.00</u>	20.00	6.70	6.67	<u>10.00</u>

199 최종 답만 채점한다. RSP는 §3.1의 정의를 따르며 prefix/infix/suffix 세 주입 위치 중 하나에 매
200 배치마다 새로 주입된 **H**를 결합한다. 전체 실험 설정과 위치별 결과는 Appendix A에 있다.

201 4.2 RSP는 추론 성능을 개선할까?

202 먼저 무작위 임베딩 주입이 모델의 추론 성능에 어떤 영향을 주는지 본다. Table 1는 각 벤치마크
203 에서 주입 위치(Prefix, Infix, Suffix)와 $L \in \{10, 15, 20\}$ 가운데 가장 좋은 RSP 결과를 보고한다.

204 instruct model과 원래 프롬프트 형식을 쓰는 base model에서는 RSP가 baseline 성능을 대체로
205 몇 퍼센트포인트 이내에서 유지하거나 소폭만 이동시킨다. 더 눈에 띄는 것은 프롬프트 형식
206 불일치 상황이다. 즉, 채팅 형식으로 학습되지 않은 base model에 ChatML template을 주입했을
207 때, RSP는 최대 +29%p까지의 큰 성능 향상을 보인다. 단순히 불확실성을 높이는 노이즈였다
208 면 오히려 성능 저하가 커졌어야 하므로, 이 결과는 RSP 효과가 단순한 교란을 넘는다는 점을
209 시사한다.

210 또한 RSP를 TTSV, SoftCoT, LTPO처럼 서로 다른 목적 함수로 임베딩을 최적화하는 기존 soft
211 prompt 방법과 비교했다. Table 2은 공통 answer extraction pipeline 아래에서 다시 평가한 결과
212 를 보여준다. 각 방법은 프롬프트 형식과 채점 규칙이 다르지만, fallback 기반 추출을 사용해
213 형식에 덜 민감한 비교를 수행했다. 결과적으로 RSP는 추가 학습 없이도 최적화 기반 방법과
214 맞먹는 수준의 성능을 보인다.

215 4.3 RSP는 출력 분포를 어떻게 바꾸는가?

216 다음으로 RSP 주입이 생성 과정의 출력 분포를 어떻게 바꾸는지 살펴본다. 설정은 Qwen2.5-
217 Math-1.5B-Instruct와 MATH-500이며, 토큰별 entropy, top-1 probability, varentropy를 생성 단계
218 에 따라 측정한다. Figure 2와 Table 3는 생성 초반 5% 구간에서 RSP 변형과 기존 soft prompt
219 방법을 비교한 결과다.

220 결과는 RSP가 생성 초반 출력 분포를 분명히 바꾼다는 점을 보여준다. 세 주입 위치 모두에서
221 entropy는 증가하고, top-1 probability는 감소하며, varentropy는 증가한다. 이는 분포가 평평해
222 지고, 단일 우세 토큰에 대한 확신은 약해지며, 다분형 분포가 더 자주 나타남을 뜻한다 [Ahmed




Figure 2: 생성 초반 5% 구간의 평균 entropy, top-1 probability, varentropy (Qwen2.5-Math-1.5B-Instruct, MATH-500). 음영은 ± 1 SEM이다. 실선은 RSP 변형과 baseline, 점선은 기존 soft prompt 방법(LTPO, SoftCoT, TTSV)이다.

Table 3: 생성 초반 5% 구간의 평균 entropy, top-1 probability, varentropy (Qwen2.5-Math-1.5B-Instruct, MATH-500).

Metric	Baseline	Prefix	Infix	Suffix	LTPO	SoftCoT	TTSV
Entropy	0.1332	0.1366	0.1402	0.1941	0.1662	0.4218	0.1359
Top-1 Prob	0.9535	0.9523	0.9525	0.9373	0.9437	0.9156	0.9534
Varentropy	0.2181	0.2207	0.2463	0.4010	0.2953	2.2234	0.2174

et al., 2026]. 높은 entropy 구간은 추론 궤적이 갈라지는 핵심 분기점으로 알려져 있으므로 [Wang et al., 2025], 이 변화는 여러 추론 경로가 공존할 수 있는 상태로 모델을 밀어 넣는다. 중요한 점은 변화가 생성 초반에 국한된다는 것이다. 생성 중반과 후반에서는 세 지표 모두 baseline 수준으로 다시 수렴한다.

서로 다른 목적 함수로 학습된 기존 방법들도 같은 패턴을 공유한다. 평균 entropy를 줄이는 보상을 쓰는 TTSV조차 초반 구간만큼은 baseline과 비슷하거나 더 높아, 이 entropy 상승은 특정 최적화 목적이 아니라 사전학습되지 않은 연속 임베딩 주입 자체에 가까운 효과로 보인다.

4.4 RSP는 실제로 추론 궤적의 다양성을 만드는가?

Section 4.3는 RSP가 생성 초반 출력 분포를 바꾼다는 사실을 보였다. 이제 이 변화가 실제 추론 다양성으로 이어지는지를 세 수준에서 살펴본다. 분석 수준은 토큰 순위, 궤적의 의미적 내용, 과제 수준 결과다. 세 분석 모두 Qwen2.5-Math-1.5B-Instruct, MATH-500, suffix 주입, $L = 10$ 설정을 공유한다.

토큰 수준: temperature를 넘어서는 분포 변화. 먼저 토큰 수준에서 보면, 자기회귀 생성에서 baseline과 RSP의 궤적 차이는 첫 생성 step에서 시작되어야 한다. 이 위치가 추론 궤적의 핵심 분기점이기 때문이다 [Wang et al., 2025]. Baseline $\tau=1.0$ 을 기준으로, 더 높은 temperature의 baseline $\tau=2.0, 3.0$ 과 RSP $\tau=1.0$ 을 네 지표로 비교한다. Spearman rank correlation ρ 는 순위 보존 여부를, baseline top-10 밖 확률 질량은 저확률 토큰으로의 support 확장을, Jensen-Shannon divergence는 전체 분포 거리를, Acc는 Pass@1 정확도를 측정한다(정의는 Appendix C).

Table 4: Baseline $\tau=1.0$ 을 기준으로 본 첫 토큰 분포 지표. 더 높은 temperature의 baseline($\tau=2.0, 3.0$)과 RSP $\tau=1.0$ 을 비교한다. RSP 지표는 16개 random seed 평균이며, Acc는 문제당 16개 샘플의 평균 $\pm$ 표준편차다.

Metric	$\tau=2.0$	$\tau=3.0$	RSP
Spearman ρ	1.000	1.000	0.709
Mass outside top-10	5.18%	29.11%	21.86%
JS divergence	0.060	0.218	0.131
Acc (%)	20.77 ± 1.47	1.42 ± 0.35	73.30 ± 1.07

Table 4의 대비는 명확하다. RSP의 분포 변화 크기는 top-10 밖 질량과 JS divergence 기준으로 $\tau=2.0$ 과 $\tau=3.0$ 사이에 놓인다. 그러나 temperature scaling은 단조 변환이라 어떤 τ 에서도 baseline 대비 token ranking을 보존하므로 $\rho = 1$ 이 강제된다. 반면 RSP는 순위를 부분적으로 보존하면서도 재배치하여 $\rho = 0.709$ 를 만든다. Acc 행은 그 비용 차이를 보여 준다. RSP와 비슷한 크기의 분포 변화를 temperature로 만들려면 τ 를 3.0 쪽으로 올려야 하지만, 이 경우 정확도는 1.42%까지 무너진다. RSP는 같은 설정에서 73.30%의 정확도를 유지한다. 따라서

RSP는 temperature처럼 분포를 균일하게 평탄화하는 것이 아니라, 순위를 바꾸는 다른 종류의 섭동을 만든다.

궤적 수준: 의미적 다양성. 한 단계 위인 궤적 수준에서는, 첫 토큰의 재배치가 실제로 의미적으로 다른 추론 경로를 여는지가 관건이다. 이를 위해 MATH-500에서 무작위로 64개 문제를 뽑고, Baseline과 RSP 두 조건에서 각 문제마다 temperature $\tau = 1.0$ 으로 300개의 독립 궤적을 생성했다. 각 궤적은 BGE-M3 [Chen et al., 2024]로 임베딩한 뒤, 문제 내 평균 pairwise cosine distance, DBSCAN [Ester et al., 1996] 클러스터 중심 사이의 inter-cluster distance, 그리고 intra-cluster distance를 계산했다. Table 5는 RSP가 intra-cluster distance는 거의 바꾸지 않으면서 inter-cluster distance를 크게 키운다는 점을 보여준다. 즉, 각 전략 내부의 일관성은 유지하면서 전략 간 거리를 벌린다. Pairwise distance 기준으로 RSP는 64개 중 56개 문제(87.5%)에서 baseline보다 컸다.

Table 5: 64개 문제에 대해 평균한 의미적 다양성 지표.

Metric	Baseline	RSP
Pairwise cos. dist.	0.0612	0.0879
Inter-cluster dist.	0.0183	0.0982
Intra-cluster dist.	0.0526	0.0528




Figure 3: 64개 MATH-500 문제에서의 의미적 다양성 분석(문제당 300개 궤적, Qwen2.5-Math-1.5B-Instruct, $\tau = 1.0$, BGE-M3 임베딩). (a) 대표 문제 test/prealgebra/951의 t-SNE 투영: baseline(빨강)은 한 영역에 비교적 집중되지만, RSP suffix(파랑)는 더 넓고 분리된 군집까지 확장된다. 채워진 표식은 정답, 빈 표식은 오답이다. (b) 문제별 평균 pairwise cosine distance. 대각선 위 점은 RSP가 baseline보다 더 다양한 궤적을 만든다는 뜻이다. (c) 문제별 DBSCAN 클러스터 수. 대부분의 문제에서 RSP가 더 많은 클러스터를 만든다.

Figure 3(a)에서 RSP 샘플(파랑)은 baseline 영역을 포함하면서 baseline이 도달하지 못한 별도 클러스터까지 확장되고, 그 영역에도 정답 궤적이 포함된다. (b), (c)는 64개 문제 전반에 걸쳐 RSP가 더 많은 클러스터와 더 큰 pairwise cosine distance를 만든다는 패턴이 반복됨을 보여준다. 즉 RSP는 클러스터 내부 진행은 호트트프리지 않으면서 궤적이 진입하는 전략 클러스터 자체를 바꾼다. 문제별 추가 t-SNE는 Appendix B에 있다.

결과 수준: Pass@N 스케일링. 마지막 결과 수준에서는, 이러한 다양성이 실제 과제 성과로 이어지는지를 Pass@N로 본다(N 개의 샘플 중 적어도 하나가 정답일 확률). MATH-500과 AIME24에서 문제당 $N = 16$, 네 조건을 비교한다. (i) baseline + $\tau=1.0$, (ii) RSP를 모든 샘플이 공유 + $\tau=1.0$, (iii) 샘플마다 독립 RSP + greedy, (iv) 샘플마다 독립 RSP + $\tau=1.0$.

조건 (iv)가 두 벤치마크 모두에서 가장 높은 Pass@N을 달성하며 $N = 16$ 에서 MATH-500 92.80%, AIME24 36.67%에 이른다. (ii)는 baseline 대비 거의 개선이 없어, 다양성 이득의 핵심이 고정 섭동이 아니라 샘플마다 독립된 무작위 임베딩임을 드러낸다. Pass@1은 MATH-500에서 baseline 수준을 유지하고 더 어려운 AIME24에서는 (iv)가 더 높아, 독립 RSP + temperature 결합이 단일 샘플 정확도를 해치지 않으면서 추론 궤적을 다양화한다.

5 Application: RSP를 이용한 DAPO 학습

지금까지의 실험 분석은 RSP를 추론 시점에서만 평가했다. §3.4는 독립 RSP 추첨이 rollout 다양성에 의존하는 모든 sampling 기반 최적화에 도움이 될 것이라고 예측한다. 이를 검증하기 위해 RSP를 GRPO 기반 RL 학습 파이프라인에 통합한다. 구현 세부와 step별 결과는 Appendix G에 있다.




Figure 4: Qwen2.5-Math-1.5B-Instruct에서의 Pass@N 스케일링. 좌측은 MATH-500, 우측은 AIME24이며, 문제당 $N = 16$ 개의 샘플을 사용했다. Baseline은 temperature sampling만, fixed seed는 고정된 하나의 RSP와 temperature를 함께 쓴 경우, indep. seed는 샘플마다 다른 RSP를 쓰는 경우다.

287 **DAPO.** DAPO [Yu et al., 2025]는 GRPO [Shao et al., 2024]의 손실 항을 수정해 긴 chain-of-
 288 thought RL 학습 동안 rollout 다양성을 유지한다. 여기서 다양성은 rollout이 가중·클립되는 방
 289 식을 손실 단에서 재구성하는 방식으로 형성된다. 반면 RSP는 손실이 계산되기 전 rollout 분포
 290 자체에 섭동을 주어 입력 단에서 다양성을 유발한다 (§4.4). 이 두 다양성 원천이 결합해 추가적
 291 성능 이득을 만들 수 있는지를 묻기 위해 DAPO를 testbed로 사용한다. i 번째 rollout 응답을 o_i ,
 292 중요도 비를 $r_{i,t}(\theta) = \pi_\theta(o_{i,t} | q, [\mathbf{H}_g,]o_{i,<t}) / \pi_{\theta_{\text{old}}}(o_{i,t} | q, [\mathbf{H}_g,]o_{i,<t})$, 그룹 상대 advantage를
 293 $\hat{A}_{i,t}$, 비대칭 clip 범위를 $(\varepsilon_{\text{low}}, \varepsilon_{\text{high}})$ 라 하자. 괄호 안 $\mathbf{H}_g$ 는 prompt에 결합한 RSP다. DAPO +
 294 RSP의 목적함수는 다음과 같다.

$$\mathcal{J}_{\text{DAPO+RSP}}(\theta) = \mathbb{E} \left[\frac{1}{\sum_i |o_i|} \sum_{i,t} \min \left(r_{i,t} \hat{A}_{i,t}, \text{clip}(r_{i,t}, 1 - \varepsilon_{\text{low}}, 1 + \varepsilon_{\text{high}}) \hat{A}_{i,t} \right) \right]. \quad (3)$$

295 **설정.** Qwen2.5-Math-7B를 MATH Level-3-5 subset(약 8,500개 prompt)에서 SimpleRL-Zoo
 296 [Zeng et al., 2025] 학습 파이프라인과 Eq. (3)의 목적함수로 학습한다. 각 step은 1,024개 prompt
 297 배치 위에서 $\tau=1.0$ 으로 prompt당 $G = 8$ 개 rollout을 샘플하고, 총 100 step(대략 12 epoch)
 298 학습한다. DAPO와 DAPO + RSP를 비교하며, 후자에서는 rollout 동안에만 suffix RSP 주입
 299 ($L = 20$)을 적용하고 평가는 RSP 없이 수행한다. 평가는 7개 수학 추론 벤치마크에서 진행
 300 한다(MATH-500 [Lightman et al., 2024], AIME 2024, AMC 2023, GSM8K [Cobbe et al., 2021],
 301 GaoKao 2023-EN, OlympiadBench [He et al., 2024], Minerva Math [Lewkowycz et al., 2022]). 작
 302 은 경시대회 셋(AIME 2024, AMC 2023)은 분산을 줄이기 위해 $\tau=1.0$ 에서 Avg@32로 채점하고,
 303 나머지 큰 벤치마크는 greedy 단일 sample로 평가한다. 보고는 가중치 없는 7-벤치마크 평균
 304 이다.

305 **결과.** Figure 5는 학습 step에 따른 7-벤치마크 평균 정확도이고, Table 6은 각 방법의 peak step
 306 에서의 벤치마크별 정확도다.

Table 6: Qwen2.5-Math-7B에서 각 방법의 peak step 벤치마크별 정확도(%). 굵게는 두 RL 방법 중 더 높은 쪽이고, Avg는 가중치 없는 7-벤치마크 평균이다.

Method	MATH-500	AIME 24	AMC 23	GSM8K	GaoKao 23-EN	Olymp.	Minerva	Avg
Base	52.6	8.6	23.9	57.2	38.7	16.3	13.6	30.13
DAPO	78.2	22.6	62.2	86.3	62.6	38.5	37.5	55.41
DAPO + RSP	78.6	23.6	62.2	87.7	62.6	38.5	39.7	56.13

307 **해석.** 두 패턴이 드러난다. 첫째, DAPO 단독은 step
 308 80에서 peak(55.41%)에 도달한 뒤 감소해 step 100에
 309 서 52.56%까지 떨어지지만, DAPO + RSP는 step 90
 310 에서 56.13% peak까지 계속 상승하고 step 100에서도
 311 55.81%를 유지한다. 이는 입력 공간 재추첨이 DAPO
 312 의 손실 단 entropy 관리와 상호 보완적 다양성 원천으
 313 로 작용한다는 것과 일치한다. RSP는 rollout 사이에
 314 독립 섭동을 주입하며, policy 자체의 entropy에 의존




Figure 5: Qwen2.5-Math-7B의 7-벤치마크 평균 정확도. DAPO + RSP는 step 90에서 더 높은 peak에 도달하고 step 100까지 안정적으로 유지되는 반면, DAPO는 step 80 이후 감소한다.

315 하지 않기 때문이다. 둘째, peak 자체도 약간 상승했다
 316 (+0.72 pp 평균). 즉 RSP는 붕괴를 늦추는 동시에 도달
 317 가능 성능을 끌어올린다. 두 패턴 모두 같은 메커니
 318 즘의 두 측면이다. §3.4의 RSP 초반 branch opening은
 319 RL의 고전적인 exploration–exploitation 패턴 [Sutton
 320 and Barto, 2018]처럼 처음에는 reward 성장을 늦추지
 321 만(두 곡선이 step 20 근처에서 교차한다) 결국 붕괴
 322 지연과 더 높은 peak로 누적된다. 이를 입력 공간과
 323 손실 단 다양성 메커니즘이 결합한다는 예비 증거로 본다. 한계와 더 폭넓은 견고성 점검은
 324 Appendix G.6에서 다룬다.

325 6 결론

326 본 연구는 사전학습된 임베딩 행렬의 항별 평균과 분산에 맞춘 등방 가우시안 벡터를 학습 없이
 327 주입하는 Random Soft Prompt(RSP)의 역할을 분석했다. RSP에서 무작위성은 임베딩 분포를
 328 모사하는 장치가 아니라 rollout 사이의 독립적 섭동을 공급하는 성질이며, 탐색은 바로 이 독립
 329 성을 요구한다. 이론적으로 각 어텐션 레이어에서 RSP의 기여는 단일 스칼라 어텐션 질량으로
 330 정확히 포착되고, 그 fixed-gap 상한 envelope은 캐시 성장에 따라 좁아진다. 또한 국소 affine
 331 분석 아래에서 등방 재추첨은 temperature 스케일링으로 만들 수 없는 top- K 진입 영역에 양의
 332 확률을 부여할 수 있다(§3). 실험적으로 RSP는 생성 초반의 엔트로피를 높이고 후반에는 다시
 333 안정화시키며, 같은 RSP를 모든 sample에 공유하면 누적 이득이 사라진다(§4). RSP는 순위를
 334 바꾸는 섭동인 반면 temperature는 순위를 보존하는 섭동이므로 두 방법은 상보적이며, 이는
 335 GRPO [Shao et al., 2024]의 entropy collapse를 DAPO [Yu et al., 2025], CE-GPPO [Su et al., 2026]
 336 너머에서 샘플링 단계로 보완하는 가능성을 시사한다. 학습 시점 비교, 수학 추론을 넘어선
 337 도메인 확장, RSP 길이와 주입 위치의 원리적 결정은 Proposition 2의 task 측 가정 $p_{\min}(x) > 0$ 과
 338 함께 향후 과제로 남는다.

339 References

- 340 Farhan Ahmed, Yuya Jeremy Ong, and Chad DeLuca. LogitScope: A Framework for Analyzing
 341 LLM Uncertainty through Information Metrics. In *ICLR Workshop*, 2026.
- 342 Nora Belrose, Igor Ostrovsky, Lev McKinney, Zach Furman, Logan Smith, Danny Halawi, Stella
 343 Biderman, and Jacob Steinhardt. Eliciting Latent Predictions from Transformers with the Tuned
 344 Lens. *arXiv:2303.08112*, 2023.
- 345 Jianlyu Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, and Zheng Liu. M3-
 346 Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through
 347 Self-Knowledge Distillation. In *Findings of ACL*, 2024.
- 348 Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser,
 349 Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, Christopher Hesse, and John
 350 Schulman. Training Verifiers to Solve Math Word Problems. *arXiv:2110.14168*, 2021.
- 351 Jeremy M. Cohen, Elan Rosenfeld, and J. Zico Kolter. Certified Adversarial Robustness via Random-
 352 ized Smoothing. In *ICML*, 2019.
- 353 Martin Ester, Hans-Peter Kriegel, Jörg Sander, and Xiaowei Xu. A Density-Based Algorithm for
 354 Discovering Clusters in Large Spatial Databases with Noise. In *KDD*, 1996.
- 355 Meire Fortunato, Mohammad Gheshlaghi Azar, Bilal Piot, Jacob Menick, Ian Osband, Alex Graves,
 356 Vlad Mnih, Remi Munos, Demis Hassabis, Olivier Pietquin, Charles Blundell, and Shane Legg.
 357 Noisy Networks for Exploration. In *ICLR*, 2018.
- 358 Mor Geva, Roei Schuster, Jonathan Berant, and Omer Levy. Transformer Feed-Forward Layers Are
 359 Key-Value Memories. In *EMNLP*, 2021.
- 360 Sachin Goyal, Ziwei Ji, Ankit Singh Rawat, Aditya Krishna Menon, Sanjiv Kumar, and Vaishnavh
 361 Nagarajan. Think before You Speak: Training Language Models with Pause Tokens. In *ICLR*,
 362 2024.

363 Aaron Grattafiori, Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad
 364 Al-Dahle, Aiesha Letman, Akhil Mathur, Alan Schelten, Alex Vaughan, Amy Yang, Angela Fan,
 365 Anirudh Goyal, Anthony Hartshorn, Aobo Yang, Archi Mitra, Archie Sravankumar, Artem Ko-
 366 renev, Arthur Hinsvark, Arun Rao, Aston Zhang, Aurelien Rodriguez, Austen Gregerson, Ava
 367 Spataru, Baptiste Roziere, Bethany Biron, Binh Tang, Bobbie Chern, Charlotte Caucheteux, Chaya
 368 Nayak, Chloe Bi, Chris Marra, Chris McConnell, Christian Keller, Christophe Touret, Chunyang
 369 Wu, Corinne Wong, Cristian Canton Ferrer, Cyrus Nikolaidis, Damien Allonsius, Daniel Song,
 370 Danielle Pintz, Danny Livshits, Danny Wyatt, David Esiobu, Dhruv Choudhary, Dhruv Mahajan,
 371 Diego Garcia-Olano, Diego Perino, Dieuwke Hupkes, Egor Lakomkin, Ehab AlBadawy, Elina
 372 Lobanova, Emily Dinan, Eric Michael Smith, Filip Radenovic, Francisco Guzmán, Frank Zhang,
 373 Gabriel Synnaeve, Gabrielle Lee, Georgia Lewis Anderson, Govind Thattai, Graeme Nail, Gre-
 374 goire Mialon, Guan Pang, Guillem Cucurell, Hailey Nguyen, Hannah Korevaar, Hu Xu, Hugo
 375 Touvron, Iliyan Zarov, Imanol Arrieta Ibarra, Isabel Kloumann, Ishan Misra, Ivan Evtimov, Jack
 376 Zhang, Jade Copet, Jaewon Lee, Jan Geffert, Jana Vranes, Jason Park, Jay Mahadeokar, Jeet Shah,
 377 Jelmer van der Linde, Jennifer Billock, Jenny Hong, Jenya Lee, Jeremy Fu, Jianfeng Chi, Jianyu
 378 Huang, Jiawen Liu, Jie Wang, Jiecao Yu, Joanna Bitton, Joe Spisak, Jongsoo Park, Joseph Rocca,
 379 Joshua Johnstun, Joshua Saxe, Junteng Jia, Kalyan Vasuden Alwala, Karthik Prasad, Kartikeya
 380 Upasani, Kate Plawiak, Ke Li, Kenneth Heafield, Kevin Stone, Khalid El-Arini, Krithika Iyer,
 381 Kshitiz Malik, Kuenley Chiu, Kunal Bhalla, Kushal Lakhotia, Lauren Rantala-Yearly, Laurens
 382 van der Maaten, Lawrence Chen, Liang Tan, Liz Jenkins, Louis Martin, Lovish Madaan, Lubo
 383 Malo, Lukas Blecher, Lukas Landzaat, Luke de Oliveira, Madeline Muzzi, Mahesh Pasupuleti,
 384 Mannat Singh, Manohar Paluri, Marcin Kardas, Maria Tsimpoukelli, Mathew Oldham, Mathieu
 385 Rita, Maya Pavlova, Melanie Kambadur, Mike Lewis, Min Si, Mitesh Kumar Singh, Mona Has-
 386 san, Naman Goyal, Narjes Torabi, Nikolay Bashlykov, Nikolay Bogoychev, Niladri Chatterji, Ning
 387 Zhang, Olivier Duchenne, Onur Çelebi, Patrick Alrassy, Pengchuan Zhang, Pengwei Li, Petar Va-
 388 sic, Peter Weng, Prajjwal Bhargava, Pratik Dubal, Praveen Krishnan, Punit Singh Koura, Puxin
 389 Xu, Qing He, Qingxiao Dong, Ragavan Srinivasan, Raj Ganapathy, Ramon Calderer, Ricardo Sil-
 390 veira Cabral, Robert Stojnic, Roberta Raileanu, Rohan Maheswari, Rohit Girdhar, Rohit Patel,
 391 Romain Sauvestre, Ronnie Polidoro, Roshan Sumbaly, Ross Taylor, Ruan Silva, Rui Hou, Rui
 392 Wang, Saghar Hosseini, Sahana Chennabasappa, Sanjay Singh, Sean Bell, Seohyun Sonia Kim,
 393 Sergey Edunov, Shaoliang Nie, Sharan Narang, Sharath Raparthy, Sheng Shen, Shengye Wan,
 394 Shruti Bhosale, Shun Zhang, Simon Vandenhende, Soumya Batra, Spencer Whitman, Sten Sootla,
 395 Stephane Collot, Suchin Gururangan, Sydney Borodinsky, Tamar Herman, Tara Fowler, Tarek
 396 Sheasha, Thomas Georgiou, Thomas Scialom, Tobias Speckbacher, Todor Mihaylov, Tong Xiao,
 397 Ujjwal Karn, Vedanuj Goswami, Vibhor Gupta, Vignesh Ramanathan, Viktor Kerkez, Vincent
 398 Gonguet, Virginie Do, Vish Vogeti, Vitor Albiero, Vladan Petrovic, Weiwei Chu, Wenhan Xiong,
 399 Wenyin Fu, Whitney Meers, Xavier Martinet, Xiaodong Wang, Xiaofang Wang, Xiaoqing Ellen
 400 Tan, Xide Xia, Xinfeng Xie, Xuchao Jia, Xuewei Wang, Yaelle Goldschlag, Yashesh Gaur, Yas-
 401 mine Babaei, Yi Wen, Yiwen Song, Yuchen Zhang, Yue Li, Yuning Mao, Zacharie Delpierre
 402 Coudert, Zheng Yan, Zhengxing Chen, Zoe Papakipos, Aaditya Singh, Aayushi Srivastava, Abha
 403 Jain, Adam Kelsey, Adam Shajnfeld, Adithya Gangidi, Adolfo Victoria, Ahuva Goldstand, Ajay
 404 Menon, Ajay Sharma, Alex Boesenberg, Alexei Baevski, Allie Feinstein, Amanda Kallet, Amit
 405 Sangani, Amos Teo, Anam Yunus, Andrei Lupu, Andres Alvarado, Andrew Caples, Andrew Gu,
 406 Andrew Ho, Andrew Poulton, Andrew Ryan, Ankit Ramchandani, Annie Dong, Annie Franco,
 407 Anuj Goyal, Aparajita Saraf, Arkabandhu Chowdhury, Ashley Gabriel, Ashwin Bharambe, As-
 408 saf Eisenman, Azadeh Yazdan, Beau James, Ben Maurer, Benjamin Leonhardi, Bernie Huang,
 409 Beth Loyd, Beto De Paola, Bhargavi Paranjape, Bing Liu, Bo Wu, Boyu Ni, Braden Hancock,
 410 Bram Wasti, Brandon Spence, Brani Stojkovic, Brian Gamido, Britt Montalvo, Carl Parker, Carly
 411 Burton, Catalina Mejia, Ce Liu, Changan Wang, Changkyu Kim, Chao Zhou, Chester Hu, Ching-
 412 Hsiang Chu, Chris Cai, Chris Tindal, Christoph Feichtenhofer, Cynthia Gao, Damon Civin, Dana
 413 Beaty, Daniel Kreymer, Daniel Li, David Adkins, David Xu, Davide Testuggine, Delia David,
 414 Devi Parikh, Diana Liskovich, Didem Foss, Dingkan Wang, Duc Le, Dustin Holland, Edward
 415 Dowling, Eissa Jamil, Elaine Montgomery, Eleonora Presani, Emily Hahn, Emily Wood, Eric-
 416 Tuan Le, Erik Brinkman, Esteban Arcaute, Evan Dunbar, Evan Smothers, Fei Sun, Felix Kreuk,
 417 Feng Tian, Filippus Kokkinos, Firat Ozgenel, Francesco Caggioni, Frank Kanayet, Frank Seide,
 418 Gabriela Medina Florez, Gabriella Schwarz, Gada Badeer, Georgia Swee, Gil Halpern, Grant Her-
 419 man, Grigory Sizov, Guangyi Zhang, Guna Lakshminarayanan, Hakan Inan, Hamid Shojanazeri,
 420 Han Zou, Hannah Wang, Hanwen Zha, Haroun Habeeb, Harrison Rudolph, Helen Suk, Henry
 421 Aspegren, Hunter Goldman, Hongyuan Zhan, Ibrahim Damlaj, Igor Molybog, Igor Tufanov, Il-

422 ias Leontiadis, Irina-Elena Veliche, Itai Gat, Jake Weissman, James Geboski, James Kohli, Janice
 423 Lam, Japhet Asher, Jean-Baptiste Gaya, Jeff Marcus, Jeff Tang, Jennifer Chan, Jenny Zhen, Jeremy
 424 Reizenstein, Jeremy Teboul, Jessica Zhong, Jian Jin, Jingyi Yang, Joe Cummings, Jon Carvill, Jon
 425 Shepard, Jonathan McPhie, Jonathan Torres, Josh Ginsburg, Junjie Wang, Kai Wu, Kam Hou U,
 426 Karan Saxena, Kartikay Khandelwal, Katayoun Zand, Kathy Matosich, Kaushik Veeraraghavan,
 427 Kelly Michelena, Keqian Li, Kiran Jagadeesh, Kun Huang, Kunal Chawla, Kyle Huang, Lailin
 428 Chen, Lakshya Garg, Lavender A, Leandro Silva, Lee Bell, Lei Zhang, Liangpeng Guo, Licheng
 429 Yu, Liron Moshkovich, Luca Wehrstedt, Madian Khabisa, Manav Avalani, Manish Bhatt, Martynas
 430 Mankus, Matan Hasson, Matthew Lennie, Matthias Reso, Maxim Groshev, Maxim Naumov, Maya
 431 Lathi, Meghan Keneally, Miao Liu, Michael L. Seltzer, Michal Valko, Michelle Restrepo, Mihir
 432 Patel, Mik Vyatskov, Mikayel Samvelyan, Mike Clark, Mike Macey, Mike Wang, Miquel Jubert
 433 Hermoso, Mo Metanat, Mohammad Rastegari, Munish Bansal, Nandhini Santhanam, Natascha
 434 Parks, Natasha White, Navyata Bawa, Nayan Singhal, Nick Egebo, Nicolas Usunier, Nikhil Mehta,
 435 Nikolay Pavlovich Laptev, Ning Dong, Norman Cheng, Oleg Chernoguz, Olivia Hart, Omkar
 436 Salpekar, Ozlem Kalinli, Parkin Kent, Parth Parekh, Paul Saab, Pavan Balaji, Pedro Rittner, Philip
 437 Bontrager, Pierre Roux, Piotr Dollar, Polina Zvyagina, Prashant Ratanchandani, Pritish Yuvraj,
 438 Qian Liang, Rachad Alao, Rachel Rodriguez, Rafi Ayub, Raghotham Murthy, Raghu Nayani,
 439 Rahul Mitra, Rangaprabhu Parthasarathy, Raymond Li, Rebekkah Hogan, Robin Battey, Rocky
 440 Wang, Russ Howes, Ruty Rinott, Sachin Mehta, Sachin Siby, Sai Jayesh Bondu, Samyak Datta,
 441 Sara Chugh, Sara Hunt, Sargun Dhillon, Sasha Sidorov, Satadru Pan, Saurabh Mahajan, Saurabh
 442 Verma, Seiji Yamamoto, Sharadh Ramaswamy, Shaun Lindsay, Shaun Lindsay, Sheng Feng,
 443 Shenghao Lin, Shengxin Cindy Zha, Shishir Patil, Shiva Shankar, Shuqiang Zhang, Shuqiang
 444 Zhang, Sinong Wang, Sneha Agarwal, Soji Sajuyigbe, Soumith Chintala, Stephanie Max, Stephen
 445 Chen, Steve Kehoe, Steve Satterfield, Sudarshan Govindaprasad, Sumit Gupta, Summer Deng,
 446 Sungmin Cho, Sunny Virk, Suraj Subramanian, Sy Choudhury, Sydney Goldman, Tal Remez,
 447 Tamar Glaser, Tamara Best, Thilo Koehler, Thomas Robinson, Tianhe Li, Tianjun Zhang, Tim
 448 Matthews, Timothy Chou, Tzook Shaked, Varun Vontimitta, Victoria Ajayi, Victoria Montanez,
 449 Vijai Mohan, Vinay Satish Kumar, Vishal Mangla, Vlad Ionescu, Vlad Poenaru, Vlad Tiberiu
 450 Mihailescu, Vladimir Ivanov, Wei Li, Wenchen Wang, Wenwen Jiang, Wes Bouaziz, Will Con-
 451 stable, Xiaocheng Tang, Xiaojian Wu, Xiaolan Wang, Xilun Wu, Xinbo Gao, Yaniv Kleinman,
 452 Yanjun Chen, Ye Hu, Ye Jia, Ye Qi, Yenda Li, Yilin Zhang, Ying Zhang, Yossi Adi, Youngjin
 453 Nam, Yu Wang, Yu Zhao, Yuchen Hao, Yundi Qian, Yunlu Li, Yuzi He, Zach Rait, Zachary De-
 454 Vito, Zef Rosnbrick, Zhaoduo Wen, Zhenyu Yang, Zhiwei Zhao, and Zhiyu Ma. The Llama 3
 455 Herd of Models. *arXiv:2407.21783*, 2024.

456 Shibo Hao, Sainbayar Sukhbaatar, DiJia Su, Xian Li, Zhiting Hu, Jason Weston, and Yuandong Tian.
 457 Training Large Language Models to Reason in a Continuous Latent Space. In *ICLR*, 2025.

458 Chaoqun He, Renjie Luo, Yuzhuo Bai, Shengding Hu, Zhen Leng Thai, Junhao Shen, Jinyi Hu,
 459 Xu Han, Yujie Huang, Yankai Zhang, Jie Liu, Lei Qi, Zhiyuan Liu, and Maosong Sun. Olympiad-
 460 Bench: A Challenging Benchmark for Promoting AGI with Olympiad-Level Bilingual Multimodal
 461 Scientific Problems. In *Findings of ACL*, 2024.

462 Neil Houlsby, Andrei Giurgiu, Stanislaw Jastrzebski, Bruna Morrone, Quentin de Laroussilhe, An-
 463 drea Gesmundo, Mona Attariyan, and Sylvain Gelly. Parameter-Efficient Transfer Learning for
 464 NLP. In *ICML*, 2019.

465 Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang,
 466 and Weizhu Chen. LoRA: Low-Rank Adaptation of Large Language Models. In *ICLR*, 2022.

467 Neel Jain, Ping-yeh Chiang, Yuxin Wen, John Kirchenbauer, Hong-Min Chu, Gowthami Somepalli,
 468 Brian R. Bartoldson, Bhavya Kailkhura, Avi Schwarzschild, Aniruddha Saha, Micah Goldblum,
 469 Jonas Geiping, and Tom Goldstein. NEFTune: Noisy Embeddings Improve Instruction Finetuning.
 470 In *ICLR*, 2024.

471 Xinyue Kang, Diwei Shi, and Li Chen. Model Whisper: Steering Vectors Unlock Large Language
 472 Models’ Potential in Test-time. In *AAAI*, 2026.

473 Brian Lester, Rami Al-Rfou, and Noah Constant. The Power of Scale for Parameter-Efficient Prompt
 474 Tuning. In *EMNLP*, 2021.

475 Aitor Lewkowycz, Anders Andreassen, David Dohan, Ethan Dyer, Henryk Michalewski, Vinay Ra-
476 masesh, Ambrose Slone, Cem Anil, Imanol Schlag, Theo Gutman-Solo, Yuhuai Wu, Behnam
477 Neyshabur, Guy Gur-Ari, and Vedant Misra. Solving Quantitative Reasoning Problems with Lan-
478 guage Models. *arXiv:2206.14858*, 2022.

479 Xiang Lisa Li and Percy Liang. Prefix-Tuning: Optimizing Continuous Prompts for Generation. In
480 *ACL-IJCNLP*, 2021.

481 Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike,
482 John Schulman, Ilya Sutskever, and Karl Cobbe. Let’s Verify Step by Step. In *ICLR*, 2024.

483 Xiao Liu, Yanan Zheng, Zhengxiao Du, Ming Ding, Yujie Qian, Zhilin Yang, and Jie Tang. GPT
484 Understands, Too. *AI Open*, 5:208–215, 2024.

485 Aman Madaan and Amir Yazdanbakhsh. Text and Patterns: For Effective Chain of Thought, It Takes
486 Two to Tango. *arXiv:2209.07686*, 2022.

487 Alexander Robey, Eric Wong, Hamed Hassani, and George J. Pappas. SmoothLLM: Defending Large
488 Language Models Against Jailbreaking Attacks. *Transactions on Machine Learning Research*,
489 2025.

490 Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang,
491 Mingchuan Zhang, Y.K. Li, Y. Wu, and Daya Guo. DeepSeekMath: Pushing the Limits of Math-
492 ematical Reasoning in Open Language Models. *arXiv:2402.03300*, 2024.

493 Guangming Sheng, Chi Zhang, Zilingfeng Ye, Xibin Wu, Wang Zhang, Ru Zhang, Yanghua
494 Peng, Haibin Lin, and Chuan Wu. HybridFlow: A Flexible and Efficient RLHF Framework.
495 *arXiv:2409.19256*, 2024.

496 Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov.
497 Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *Journal of Machine Learn-
498 ing Research*, 15:1929–1958, 2014.

499 Zhenpeng Su, Leiyu Pan, Minxuan Lv, Yuntao Li, Wenping Hu, Fuzheng Zhang, Kun Gai, and
500 Guorui Zhou. CE-GPPO: Coordinating Entropy via Gradient-Preserving Clipping Policy Opti-
501 mization in Reinforcement Learning. In *ACL*, 2026.

502 Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2
503 edition, 2018.

504 Shenzi Wang, Le Yu, Chang Gao, Chujie Zheng, Shixuan Liu, Rui Lu, Kai Dang, Xionghui Chen,
505 Jianxin Yang, Zhenru Zhang, Yuqiong Liu, An Yang, Andrew Zhao, Yang Yue, Shiji Song, Bowen
506 Yu, Gao Huang, and Junyang Lin. Beyond the 80/20 Rule: High-Entropy Minority Tokens Drive
507 Effective Reinforcement Learning for LLM Reasoning. In *NeurIPS*, 2025.

508 Yige Xu, Xu Guo, Zhiwei Zeng, and Chunyan Miao. SoftCoT: Soft Chain-of-Thought for Efficient
509 Reasoning with LLMs. In *ACL*, 2025.

510 An Yang, Beichen Zhang, Binyuan Hui, Bofei Gao, Bowen Yu, Chengpeng Li, Dayiheng Liu,
511 Jianhong Tu, Jingren Zhou, Junyang Lin, Keming Lu, Mingfeng Xue, Runji Lin, Tianyu Liu,
512 Xingzhang Ren, and Zhenru Zhang. Qwen2.5-Math Technical Report: Toward Mathematical
513 Expert Model via Self-Improvement. *arXiv:2409.12122*, 2024.

514 Wengao Ye, Yan Liang, and Lianlei Shan. Thinking on the Fly: Test-Time Reasoning Enhancement
515 via Latent Thought Policy Optimization. In *ICLR*, 2026.

516 Qiying Yu, Zheng Zhang, Ruofei Zhu, Yufeng Yuan, Xiaochen Zuo, Yu Yue, Weinan Dai, Tiantian
517 Fan, Gaohong Liu, Juncai Liu, Lingjun Liu, Xin Liu, Haibin Lin, Zhiqi Lin, Bole Ma, Guangming
518 Sheng, Yuxuan Tong, Chi Zhang, Mofan Zhang, Ru Zhang, Wang Zhang, Hang Zhu, Jinhua Zhu,
519 Jiaze Chen, Jiangjie Chen, Chengyi Wang, Hongli Yu, Yuxuan Song, Xiangpeng Wei, Hao Zhou,
520 Jingjing Liu, Wei-Ying Ma, Ya-Qin Zhang, Lin Yan, Yonghui Wu, and Mingxuan Wang. DAPO:
521 An Open-Source LLM Reinforcement Learning System at Scale. In *NeurIPS*, 2025.

- 522 Weihao Zeng, Yuzhen Huang, Qian Liu, Wei Liu, Keqing He, Zejun Ma, and Junxian He. SimpleRL-
523 Zoo: Investigating and Taming Zero Reinforcement Learning for Open Base Models in the Wild.
524 *arXiv:2503.18892*, 2025.
- 525 Guibin Zhang, Muxin Fu, and Shuicheng Yan. MemGen: Weaving Generative Latent Memory for
526 Self-Evolving Agents. In *ICLR*, 2026.

527 A 실험 설정과 전체 정확도 분석

528 Table 7은 본문 Table 1에서 위치별 최고 성능만 요약해 제시한 결과를, Prefix, Infix, Suffix 별 전체
529 정확도로 다시 펼쳐 보인다. Table 8는 각 모델-벤치마크 조합에서 사용한 RSP 토큰 수 L 을 정리
530 한 것으로, 후보 집합 {10, 15, 20}에서 선택했다. 모든 실험은 단일 NVIDIA A6000 40GB GPU
531 에서 greedy decoding으로 수행했으며, 최대 생성 길이는 MATH-500과 GSM8K에서 3,072 토큰,
532 AIME24에서 4,096 토큰으로 고정했다. 배치 크기는 모델별로 고정했다(LLaMA-3.1-8B-Instruct
533 와 Qwen2.5-Math-7B 계열은 16, Qwen2.5-Math-1.5B 계열은 32).

Table 7: 모델 설정, 주입 위치, 벤치마크별 정확도(%). 괄호 안 값은 baseline 대비 변화량이다. 굵게는 최고 성능, 밑줄은 각 모델-벤치마크 조합에서 두 번째 성능을 뜻한다.

Model	Mode	MATH-500	GSM8K	AIME24
<i>Instruct Models</i>				
LLaMA-3.1-8B-Instruct	Baseline	52.20	85.75	<u>6.67</u>
	Prefix	45.00 (−7.2)	76.35 (−9.4)	3.33 (−3.3)
	Infix	<u>49.40</u> (−2.8)	85.97 (+0.2)	10.00 (+3.3)
	Suffix	<u>49.40</u> (−2.8)	86.73 (+1.0)	10.00 (+3.3)
Qwen2.5-Math-7B-Instruct	Baseline	83.20	95.45	<u>13.33</u>
	Prefix	81.40 (−1.8)	94.92 (−0.5)	<u>13.33</u> (+0.0)
	Infix	84.20 (+1.0)	<u>95.60</u> (+0.2)	16.67 (+3.3)
	Suffix	<u>83.40</u> (+0.2)	95.68 (+0.2)	16.67 (+3.3)
Qwen2.5-Math-1.5B-Instruct	Baseline	73.00	85.29	10.00
	Prefix	74.80 (+1.8)	85.29 (+0.0)	<u>13.33</u> (+3.3)
	Infix	75.20 (+2.2)	85.75 (+0.5)	<u>6.67</u> (−3.3)
	Suffix	74.20 (+1.2)	84.69 (−0.6)	20.00 (+10.0)
<i>Base Models (Raw Text)</i>				
Qwen2.5-Math-7B	Baseline	72.20	<u>84.15</u>	6.67
	Prefix	<u>71.60</u> (−0.6)	84.31 (+0.2)	16.67 (+10.0)
	Infix	63.20 (−9.0)	64.29 (−19.9)	16.67 (+10.0)
	Suffix	55.60 (−16.6)	54.13 (−30.0)	<u>13.33</u> (+6.7)
Qwen2.5-Math-1.5B	Baseline	<u>61.40</u>	77.86	16.67
	Prefix	64.40 (+3.0)	<u>74.30</u> (−3.6)	<u>10.00</u> (−6.7)
	Infix	63.20 (+1.8)	73.92 (−3.9)	<u>10.00</u> (−6.7)
	Suffix	54.60 (−6.8)	58.61 (−19.3)	3.33 (−13.3)
<i>Base Models + ChatML (Format Mismatch)</i>				
Qwen2.5-Math-7B	Baseline	52.20	58.30	23.33
	Prefix	59.20 (+7.0)	56.41 (−1.9)	<u>3.33</u> (−20.0)
	Infix	<u>62.00</u> (+9.8)	69.07 (+10.8)	23.33 (+0.0)
	Suffix	70.40 (+18.2)	75.97 (+17.7)	23.33 (+0.0)
Qwen2.5-Math-1.5B	Baseline	34.40	37.45	<u>13.33</u>
	Prefix	63.40 (+29.0)	67.02 (+29.6)	20.00 (+6.7)
	Infix	39.20 (+4.8)	50.42 (+13.0)	6.67 (−6.7)
	Suffix	<u>51.00</u> (+16.6)	<u>50.64</u> (+13.2)	<u>13.33</u> (+0.0)

Table 8: 각 모델과 벤치마크에 사용한 RSP 토큰 수 (L).

Model	MATH-500	GSM8K	AIME24
LLaMA-3.1-8B-Instruct	15	20	15
Qwen2.5-Math-7B-Instruct	20	20	20
Qwen2.5-Math-1.5B-Instruct	20	10	20
Qwen2.5-Math-7B	10	10	20
Qwen2.5-Math-1.5B	10	10	20
Qwen2.5-Math-1.5B (ChatML)	20	20	10
Qwen2.5-Math-7B (ChatML)	20	20	20

534 A.1 RSP 주입 위치와 프롬프트 템플릿

535 아래에는 모든 모델 유형에서 주입 위치별 프롬프트 구조를 정리했다. **파란색 텍스트**는 RSP
536 임베딩, **보라색 텍스트**는 특수 토큰을 뜻한다.

537 A.1.1 Prefix

538 Prefix 주입에서는 RSP 임베딩을 프롬프트 임베딩 앞에 연결한다. 텍스트 자체는 수정하지
539 않는다.

540 ChatML (Qwen Instruct / Base + ChatML).

```
[Random Embeddings (L tokens)]
<|im_start|>system
Please reason step by step, and put your final answer within \boxed{<|im_end|>
<|im_start|>user
{question}<|im_end|>
<|im_start|>assistant
```

542 LLaMA Chat Template.

```
[Random Embeddings (L tokens)]
<|begin_of_text|>
<|start_header_id|>system<|end_header_id|>
Cutting Knowledge Date: December 2023
Today Date: 26 Jul 2024
Please reason step by step, and put your final answer within \boxed{<|eot_id|>
<|start_header_id|>user<|end_header_id|>
{question}<|eot_id|>
<|start_header_id|>assistant<|end_header_id|>
```

544 Raw Text (Qwen Base).

```
[Random Embeddings (L tokens)]
{question}
Please reason step by step, and put your final answer within \boxed{<|im_end|>
```

546 A.1.2 Infix

547 Infix 주입에서는 설명 문구와 특수 토큰을 프롬프트 내부에 넣은 뒤, 그 특수 토큰 위치를 임베딩
548 수준에서 RSP로 교체한다.

549 ChatML (Qwen Instruct / Base + ChatML).

```
<|im_start|>system
Please reason step by step, and put your final answer within \boxed{<|im_end|>
<|im_start|>user
{question}

There are {L} special tokens that contain compressed latent reasoning
information that might be useful for your reasoning. If these tokens are
useful for your case, you can use them as reference. If these tokens are
not useful for your case, you can ignore them and focus back to solving the
problem.

Here are the {L} special tokens: <special_token_1>...<special_token_L>
<|im_end|>
<|im_start|>assistant
```

551 LLaMA Chat Template.

```
<|begin_of_text|>
<|start_header_id|>system<|end_header_id|>
Cutting Knowledge Date: December 2023
Today Date: 26 Jul 2024
Please reason step by step, and put your final answer within \boxed{<|im_end|>
```

```

eot_id|>
<|start_header_id|>user<|end_header_id|>
{question}

There are {L} special tokens that contain compressed latent reasoning
information that might be useful for your reasoning. If these tokens are
useful for your case, you can use them as reference. If these tokens are
not useful for your case, you can ignore them and focus back to solving the
problem.

Here are the {L} special tokens:
<reserved_special_token_0>...
<reserved_special_token_L>
<|eot_id|>
<|start_header_id|>assistant<|end_header_id|>

```

553

554 Raw Text (Qwen Base).

```

{question}

There are {L} special tokens that contain compressed latent reasoning
information that might be useful for your reasoning. If these tokens are
useful for your case, you can use them as reference. If these tokens are
not useful for your case, you can ignore them and focus back to solving the
problem.

Here are the {L} special tokens: <special_token_1>...<special_token_L>
Please reason step by step, and put your final answer within \boxed{ }.

```

555

556 A.1.3 Suffix

557 채팅 템플릿 모델에서는 end-of-turn 토큰 바로 앞에 RSP 임베딩을 넣고, raw text 모델에서는
558 프롬프트 마지막에 RSP 임베딩을 이어 붙인다.

559 ChatML (Qwen Instruct / Base + ChatML).

```

<|im_start|>system
Please reason step by step, and put your final answer within \boxed{ }.<|
im_end|>
<|im_start|>user
{question}[Random Embeddings (L tokens)]<|im_end|>
<|im_start|>assistant

```

560

561 LLaMA Chat Template.

```

<|begin_of_text|>
<|start_header_id|>system<|end_header_id|>
Cutting Knowledge Date: December 2023
Today Date: 26 Jul 2024
Please reason step by step, and put your final answer within \boxed{ }.<|
eot_id|>
<|start_header_id|>user<|end_header_id|>
{question}[Random Embeddings (L tokens)]<|eot_id|>
<|start_header_id|>assistant<|end_header_id|>

```

562

563 Raw Text (Qwen Base).

```

{question}
Please reason step by step, and put your final answer within \boxed{ }. [Random
Embeddings (L tokens)]

```

564

565 A.2 정답 추출과 채점

566 최종 정답은 fallback 체인을 통해 모델 출력에서 추출한다. 각 단계는 순서대로 시도하며, 추출에
567 실패하면 다음 단계로 넘어간다.

정답 추출 fallback 체인

1. "final answer is \$...\$. I hope" 패턴 (Minerva 형식)
2. `\boxed{...}`: 마지막 비어 있지 않은 box를 사용하고, 빈 `\boxed{}`는 건너뛰
3. "the answer is" 뒤 텍스트
4. "final answer is" 뒤 텍스트
5. 출력 마지막 숫자(regex fallback)

568

569 추출된 정답은 `$`, `\left`, `\right`, 단위 문자열을 제거해 정규화한다. 채점은 sym-
570 bolic equivalence checking으로 수행하며, 정확한 문자열 일치, 수치 비교(`math.isclose`,
571 `rel_tol=1e-4`), SymPy symbolic simplification을 차례로 적용한다.

572 A.3 재현한 선행연구의 하이퍼파라미터

573 모든 선행 방법은 Qwen2.5-Math-1.5B-Instruct와 Qwen2.5-Math-7B-Instruct에서 재현했으며,
574 greedy decoding(`temperature = 0`)과 통일된 answer extraction pipeline으로 평가했다.

575 **TTSV.** Prefix 길이는 20이며, AdamW optimizer로 20 epoch 동안 학습했다. 배치 크기는 2,
576 gradient accumulation은 8 step, 스케줄은 선형 learning rate schedule을 사용했다. Learning rate
577 는 Qwen-1.5B에 $1e-3$, Qwen-7B에 $1e-5$ 를 사용했다.

578 **LTPO.** Table 9는 벤치마크별 하이퍼파라미터를 정리한 것이다.

Table 9: LTPO 하이퍼파라미터.

Parameter	GSM8K	MATH-500	AIME24
tokens	8	8	8
steps	20	20	20
top_k	10	10	10
sigma	20	20	5
sigma_decay	0.95	0.95	0.95
lr	$1e-2$	$5e-3$	$5e-2$

579 **SoftCoT.** Projection module은 10 epoch 동안 학습했다. Thought token 수는 학습 시 32, 평가 시
580 4다. 배치 크기는 GSM8K에서 4, MATH에서는 1이며 gradient accumulation 4를 사용했다. 작은
581 모델(assistant)은 두 설정 모두 Qwen2.5-Math-1.5B-Instruct이고, 큰 모델은 Qwen2.5-Math-1.5B-
582 Instruct(`learning rate 2e-5`) 또는 Qwen2.5-Math-7B-Instruct(`learning rate 5e-6`)이다. MATH-500
583 과 AIME24 평가는 GSM8K에서 학습한 projection module을 사용했는데, MATH에서 학습한
584 버전보다 더 높은 정확도를 보였기 때문이다.

585 A.4 전체 엔트로피 곡선

586 Figure 6는 entropy, top-1 probability, varentropy의 전체 정규화 생성 궤적(0-100%)을 보여준다.
587 모든 방법은 생성 초반 단계를 지나면 비슷한 수준으로 수렴하며, 이는 RSP가 유도하는 분포
588 변화가 초기 추론 단계에 국소화되어 있음을 다시 확인해 준다.




Figure 6: 전체 정규화 생성 궤적(0-100%)에서의 평균 entropy(위), top-1 probability(가운데), varentropy(아래). MATH-500 전체 평균이며, 음영은 ± 1 SEM을 뜻한다. 실선은 RSP 변형과 baseline, 점선은 기존 soft prompt 방법이다. 모든 방법은 초반 단계를 지나면 수렴한다.

589 B 의미적 다양성에 대한 추가 분석

590 이 부록은 Section 4.4에서 보고한 의미적 다양성 결과를 보충한다. 더 넓은 문제 집합에 대해
591 문제별 t-SNE 도표를 함께 제시한다.



Figure 7: 평가한 64개 MATH-500 문제 중 48개에 대한 BGE-M3 임베딩의 t-SNE 투영(6×8 격자). 각 subplot은 Qwen2.5-Math-1.5B-Instruct에서 $\tau = 1.0$ 으로 생성한 baseline 300개(빨강)와 RSP suffix 300개(파랑)를 보여준다. 채워진 표식은 정답, 빈 표식은 오답이며, 제목은 subject/problem_id를 뜻한다. 대부분의 문제에서 RSP 궤적은 여러 개의 분리된 영역으로 퍼지는 반면, baseline 샘플은 하나의 지배적 클러스터에 더 집중된다.

592 C 토큰 수준 분포 지표

593 이 부록은 Section 4.4의 토큰 수준 분석에 사용한 세 지표를 형식적으로 정의한다. P_{base} 는
594 $\tau = 1.0$ 에서의 baseline 다음 토큰 분포, P_{target} 은 비교 대상 분포(예: $\tau = 2.0$ 의 baseline, 또는
595 $\tau = 1.0$ 의 RSP)라 하자. 모든 지표는 첫 생성 단계에서 저장한 logits로부터 해석적으로 계산
596 한다.

597 **Spearman 순위 상관.** Spearman의 ρ 는 두 분포의 토큰 순위 사이 Pearson 상관계수다.

$$\rho = \text{Pearson}(\text{rank}(P_{\text{target}}), \text{rank}(P_{\text{base}})). \quad (4)$$

598 Temperature scaling $P^{(\tau)} \propto P^{1/\tau}$ 는 엄격한 단조 변환이므로, 어떤 $\tau > 0$ 에서도 토큰 순서를
599 정확히 보존한다. 따라서 $\rho = 1$ 은 수학적 항등식이다. 그러므로 $\rho < 1$ 은 temperature scaling
600 만으로는 만들 수 없는 순위 재조직이 일어났음을 뜻한다.

601 **Top- K 밖의 질량.** $\text{TopK}(P_{\text{base}})$ 를 P_{base} 에서 확률이 가장 높은 K 개 토큰의 집합이라 하자. 비
602 교 대상 분포가 이 집합 밖에 두는 확률 질량은

$$\text{MassOutside}_K = 1 - \sum_{t \in \text{TopK}(P_{\text{base}})} P_{\text{target}}(t). \quad (5)$$

603 이 지표는 지지 집합 확장을 직접 측정한다. 즉 baseline의 선호 집합에 없던 토큰에 비교 대상이
604 얼마나 많은 확률을 배정하는지를 본다. 본문에 보고한 값은 $K = 10$ 을 사용했다.

605 **Jensen-Shannon divergence.** Kullback-Leibler divergence의 대칭적이고 bounded된 형태는 다
606 음과 같다.

$$\text{JS}(P, Q) = \frac{1}{2} \text{KL}(P \parallel M) + \frac{1}{2} \text{KL}(Q \parallel M), \quad M = \frac{1}{2}(P + Q). \quad (6)$$

607 로그는 밑이 2이므로 $\text{JS} \in [0, 1]$ 이다. 저장한 top-100 바깥의 토큰에는 softmax 전에 sentinel
608 $\text{logit}(-10^9)$ 을 넣었는데, 본 설정에서는 top-5가 이미 확률 질량의 99.9% 이상을 덮기 때문에 이
609 근사는 무시 가능하다.

610 D 이론에 필요한 Prompt 법칙의 성질

611 이 부록은 본문에서 실제로 사용하는 성질만 남긴다: 중심성, 분산 예산 아래의 방향 무관 공
612 분산, 그리고 모든 비공집합 열린집합에 대한 양의 확률이다. Section 3.4의 메커니즘에는 이
613 기하학적·측도론적 사실만 필요하므로, 더 강한 의미론적 해석은 쓰지 않는다.

614 D.1 중심화된 섭동은 체계적인 1차 드리프트를 만들지 않는다

615 토큰 i, j 의 baseline logit gap을 Δ_{ij} 라 하고 1차 surrogate를

$$\Delta_{ij}(\bar{h}) = \Delta_{ij} + b_{ij}^\top \bar{h}$$

616 로 두자.

617 **명제 3** (체계적인 1차 드리프트의 부재). $\mathbb{E}[\bar{h}] = 0$ 이면 모든 토큰 쌍 (i, j) 에 대해

$$\mathbb{E}[\Delta_{ij}(\bar{h})] = \Delta_{ij}$$

618 가 성립한다. 반대로 결정적 prompt h_0 를 모든 run에 재사용하면

$$\Delta_{ij}(h_0) - \Delta_{ij} = b_{ij}^\top h_0$$

619 는 고정된 방향 편향이다.

620 *Proof.* 중심화된 경우는 기대값의 선형성으로 바로 나온다.

$$\mathbb{E}[\Delta_{ij}(\bar{h})] = \Delta_{ij} + b_{ij}^\top \mathbb{E}[\bar{h}] = \Delta_{ij}.$$

621 결정적 경우는 그대로 대입하면 된다. □

622 이 명제가 뜻하는 것은 run 평균에서의 1차 편향이 없다는 점이지, 개별 샘플이 logit을 바꾸지
623 않는다는 뜻은 아니다.

624 D.2 Theorem 2의 증명

625 본문의 local linear logit surrogate에 직접 등장하는 양은 단위벡터 b 에 대한 1차 섭동 에너지
626 $\text{Var}_{h \sim D}(b^\top h) = b^\top \Sigma_D b$ 이다. 따라서 최악 방향의 에너지는 Σ_D 의 최소 Rayleigh quotient와
627 같다.

628 *Theorem 2의 증명.* Σ_D 의 고윳값을 $\lambda_1, \dots, \lambda_d$ 라 하면,

$$\lambda_{\min}(\Sigma_D) \leq \frac{1}{d} \sum_{m=1}^d \lambda_m = \frac{\text{tr}(\Sigma_D)}{d} \leq \frac{\rho^2}{d}.$$

629 모든 고윳값이 같을 때, 즉 $\Sigma_D = (\rho^2/d)\mathbf{I}_d$ 일 때 그리고 그럴 때만 등호가 성립한다. □

630 이 증명에는 공분산만 필요하다. RSP에서 가우시안을 택하는 이유는 다음 소절의 열린집합
631 도달 가능성까지 함께 얻기 위해서다.

632 D.3 등방 가우시안 프롬프트의 열린집합 도달 가능성

633 **명제 4** (열린집합 도달 가능성). $\sigma > 0$ 이고 $\bar{h} \sim \mathcal{N}(0, \sigma^2 \mathbf{I}_d)$ 라 하자. 그러면 모든 비공집합
634 열린집합 $U \subseteq \mathbb{R}^d$ 에 대해

$$\Pr(\bar{h} \in U) > 0$$

635 가 성립한다.

636 *Proof.* 가우시안 밀도

$$(2\pi\sigma^2)^{-d/2} \exp\left(-\frac{\|\bar{h}\|^2}{2\sigma^2}\right)$$

637 는 $\mathbb{R}^d$ 의 모든 점에서 엄밀히 양수다. 모든 비공집합 열린집합은 양의 르베그 측도를 갖는 ball
638 하나를 포함하므로, 그 ball 위에서 양의 밀도를 적분하면 양의 확률이 얻어진다. □

639 이것이 Proposition 1에 실제로 쓰이는 유일한 support 성질이다.

640 E 본문 이론 결과의 증명

641 이 부록은 본문 이론결과와 같은 순서를 따른다: exploration, annealing, 성능 향상. 그보다 앞에서
642 필요한 prompt 법칙의 성질은 Appendix D에 모아 두었다.

643 E.1 Exploration: attention decomposition과 perturbation 크기

644 **명제 5** (Attention decomposition). Layer ℓ 의 한 attention head가 query 위치 i 에서 마스크되지
645 않은 실제 토큰 $n \geq 1$ 개와 RSP 토큰 $L \geq 1$ 개를 attend하며, attention logit은 모두 유한하다고
646 하자. Attention weight를 $\alpha_{ij}^{(\ell)}$ 로 두고, RSP attention mass를

$$w_{r,i}^{(\ell)} := \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)}$$

647 로 두고, $j \in [n]$ 에 대해

$$\tilde{\alpha}_{ij}^{(\ell)} := \frac{\alpha_{ij}^{(\ell)}}{1 - w_{r,i}^{(\ell)}}$$

648 라 정의하면,

$$\mathbf{o}_i^{(\ell)} = (1 - w_{r,i}^{(\ell)}) \tilde{\mathbf{o}}_i^{(\ell)} + \boldsymbol{\eta}_i^{(\ell)}$$

649 이고

$$\tilde{\mathbf{o}}_i^{(\ell)} := \sum_{j=1}^n \tilde{\alpha}_{ij}^{(\ell)} \mathbf{v}_j^{(\ell)}, \quad \boldsymbol{\eta}_i^{(\ell)} := \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{r_j}^{(\ell)}.$$

650 *Proof.* Head output은 실제 토큰 항과 RSP 토큰 항으로 정확히 나뉜다.

$$\mathbf{o}_i^{(\ell)} = \sum_{j=1}^n \alpha_{ij}^{(\ell)} \mathbf{v}_j^{(\ell)} + \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{r_j}^{(\ell)}.$$

651 마스크되지 않은 실제 토큰이 있고 softmax 가중치가 양수이므로 $\sum_{j=1}^n \alpha_{ij}^{(\ell)} = 1 - w_{r,i}^{(\ell)} > 0$
652 이다. 따라서 실제 토큰 항은

$$\sum_{j=1}^n \alpha_{ij}^{(\ell)} \mathbf{v}_j^{(\ell)} = (1 - w_{r,i}^{(\ell)}) \sum_{j=1}^n \frac{\alpha_{ij}^{(\ell)}}{1 - w_{r,i}^{(\ell)}} \mathbf{v}_j^{(\ell)} = (1 - w_{r,i}^{(\ell)}) \tilde{\mathbf{o}}_i^{(\ell)}$$

653 가 된다. 이를 대입하면 분해가 바로 따른다. □

654 **따름정리 1** (크기는 RSP attention mass로 통제된다). 무작위 value가 어떤 값으로 실현되었든,

$$\|\boldsymbol{\eta}_i^{(\ell)}\| \leq w_{r,i}^{(\ell)} \max_{j \in [L]} \|\mathbf{v}_{r_j}^{(\ell)}\|.$$

655 *Proof.* 삼각부등식을 쓰면

$$\|\boldsymbol{\eta}_i^{(\ell)}\| = \left\| \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{r_j}^{(\ell)} \right\| \leq \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \|\mathbf{v}_{r_j}^{(\ell)}\| \leq w_{r,i}^{(\ell)} \max_{j \in [L]} \|\mathbf{v}_{r_j}^{(\ell)}\|.$$

656 □

657 Corollary 1가 본문에 필요한 유일한 정량적 사실이다. Attention weight와 random key 사이의 독
658 립성은 가정하지 않는다. $w_{r,i}^{(\ell)}$ 가 작아지면 RSP 기여의 크기도 같은 스칼라에 의해 작게 묶인다.

659 E.2 Theorem 1의 따름정리

660 **따름정리 2** (fixed-gap envelope의 시퀀스 방향 단조 감소). L 과 $\Delta_i^{(\ell)}$ 를 고정하면, 상계 $f(n) =$
 661 $L/(L + n \exp(\Delta_i^{(\ell)}/\sqrt{d}))$ 는 n 에 대해 엄격히 감소하고 $n \rightarrow \infty$ 에서 0으로 수렴한다. 따라서
 662 같은 gap이 유지된다는 가정 아래, *cache* 성장만으로 그 gap과 양립 가능한 최대 RSP attention
 663 mass의 envelope이 단조롭게 줄어든다.

664 자기회귀 디코딩에서는 새 토큰이 생성될 때마다 query · key · hidden state가 함께 갱신되어 $\Delta_i^{(\ell)}$
 665 도 step별로 변하므로, “실현된 mass가 매 step 단조 감소”가 아니라 “같은 gap이 유지되는 한
 666 가능한 최대 mass의 envelope이 단조 감소한다”가 정확한 진술이다.

667 *Proof.* $f'(n) = -L \exp(\Delta_i^{(\ell)}/\sqrt{d})/(L + n \exp(\Delta_i^{(\ell)}/\sqrt{d}))^2 < 0$ 이므로 엄격히 감소한다. 또한
 668 분자는 고정되어 있고 분모는 n 에 대해 선형으로 발산하므로 $f(n) \rightarrow 0$ 이다. $\square$

669 **따름정리 3** (고정 gap envelope 아래의 RSP 기여 감쇠). L 과 $\Delta_i^{(\ell)}$ 를 고정하고 $n \rightarrow \infty$ 이면
 670 $w_{r,i}^{(\ell)} \rightarrow 0$ 이고, RSP value의 고정된 실현에 대해 $\|\eta_i^{(\ell)}\| \leq w_{r,i}^{(\ell)} \max_{j \in [L]} \|\mathbf{v}_{r_j}^{(\ell)}\| \rightarrow 0$ 이다.

671 *Proof.* Corollary 2에서 $w_{r,i}^{(\ell)} \rightarrow 0$ 이고, Corollary 1의 상계를 그대로 적용하면 된다. 유한한
 672 개수의 sampled value에 대한 최대 norm은 고정 실현에서 유한하다. $\square$

673 E.3 성능 향상: local admission에서 Pass@N까지

674 본문 §3.4는 1차 surrogate 위에서 두 가지를 주장한다. baseline 밖 토큰이 국소 top- K 집합에
 675 진입할 수 있다는 점과, 독립 재실행이 그런 국소 진입을 Pass@ N 이득으로 바꾼다는 점이다.
 676 아래 증명은 centered prompt 법칙 D 의 다음 support 조건만 사용한다.

$$(S1) \quad D(U) > 0 \quad \text{for every nonempty open set } U \subseteq \mathbb{R}^d.$$

677 Section 3.4의 등방 가우시안 법칙은 Proposition 4에 의해 (S1)을 만족한다.

678 E.3.1 자기회귀 정식화

679 자기회귀 decoding에서 시퀀스 $y_{1:T}$ 의 결합 분포는

$$\Pr(y_{1:T} | x) = \prod_{t=1}^T p(y_t | x, y_{<t}),$$

680 로 분해된다. 각 단계는 prefix에 조건부인 분포로 결정되므로, RSP가 도입한 섭동은 단일한
 681 전역 분포를 한 번에 바꾸는 것이 아니라 $p(y_t | x, y_{<t})$ 에 대한 일련의 국소 변화로 작동한다.

682 E.3.2 RSP 하에서의 logits 국소 선형화

683 이 소절에서 $\bar{h} \in \mathbb{R}^d$ 는 RSP 정의(Eq. (1) in §3.1)에 등장하는 centered prompt 벡터 하나를 뜻
 684 한다. 실제 구현은 길이 L 의 prompt $\mathbf{H} = (h_1, \dots, h_L)$ 를 사용하지만, 아래 논리는 개별 국소
 685 섭동이 logits를 어떻게 움직일 수 있는지를 분리해서 본다. 섭동된 logits를 $z_i(\bar{h})$ 로 두고 $\bar{h} = 0$
 686 근방에서 국소 smoothness를 가정하면

$$z_i(\bar{h}) = z_i(0) + \nabla_h z_i(0)^\top \bar{h} + r_i(\bar{h}),$$

687 여기서 $r_i(\bar{h}) = O(\|\bar{h}\|^2)$ 이다. $a_i := \nabla_h z_i(0)$ 라 두면 1차 affine surrogate는

$$z_i^{\text{lin}}(\bar{h}) := z_i + a_i^\top \bar{h}$$

688 가 된다. 이는 branch opening을 설명하는 1차 surrogate이지, transformer logits 전체의 정확한
 689 전역 모델은 아니다.

690 **E.3.3 Proposition 1의 증명**

691 진입 영역을

$$\mathcal{G}_{i,K} := \{\bar{h} \in \mathbb{R}^d : \#\{j \neq i : z_j^{\text{lin}}(\bar{h}) > z_i^{\text{lin}}(\bar{h})\} \leq K - 1\}$$

692 로 두자.

693 *Proof.* $\mathcal{G}_{i,K}$ 가 비공집합 열린집합 U 를 포함한다고 하자. 그러면 (S1)에 의해 $D(U) > 0$ 이고,
694 $U \subseteq \mathcal{G}_{i,K}$ 이므로

$$\Pr_{\bar{h}}(\bar{h} \in \mathcal{G}_{i,K}) \geq D(U) > 0$$

695 가 성립한다. 이는 정확히 토큰 i 가 surrogate top- K 집합에 진입하는 사건이다.

696 실용적인 충분조건은 어떤 $\bar{h}_0$ 에서 토큰 i 가 많아야 $K - 1$ 개의 토큰만 자신보다 앞서도록
697 엄격한 마진을 만드는 경우다. 연속성에 의해 이때 $\bar{h}_0$ 의 근방 비공집합 열린집합이 $\mathcal{G}_{i,K}$ 에
698 포함된다. $\square$

699 **E.3.4 Proposition 2의 증명**

700 이 명제는 메커니즘만으로 $p_{\min}(x) > 0$ 을 도출하지 않는다. 과제 측 하한과 독립성이 주어졌을
701 때 이를 Pass@ N 증가로 바꾸는 역할만 한다.

702 *Proof.* A_n 을 문제 x 에서 n 번째 독립 RSP 실행이 정답 궤적에 도달하는 사건이라 하고, (M1)에
703 따라 $p_n(x) := \Pr(A_n) \geq p_{\min}(x)$ 라 하자. (M2) 아래에서

$$\Pr\left(\bigcap_{n=1}^N A_n^c\right) = \prod_{n=1}^N (1 - p_n(x)) \leq \prod_{n=1}^N (1 - p_{\min}(x)) = (1 - p_{\min}(x))^N.$$

704 여집합을 취하면

$$\Pr(\text{Pass@}N \text{ on } x) = \Pr\left(\bigcup_{n=1}^N A_n\right) \geq 1 - (1 - p_{\min}(x))^N.$$

705 마지막 부등식 $1 - x \leq e^{-x}$ ($x \in [0, 1]$)을 적용하면

$$1 - (1 - p_{\min}(x))^N \geq 1 - e^{-N p_{\min}(x)}$$

706 을 얻는다. $\square$

707 F Attention Mass 분석

708 이 부록은 Figure 1에 보고한 per-token attention mass를 형식화하고, reasoning span과 layer 축에
 709 적용한 제외 기준을 명시한다. 500개의 MATH-500 문제 각각에 대해 새로운 $\mathbf{RSP} \mathbf{H} \in \mathbb{R}^{L \times d}$ 를
 710 $L = 10$ 으로 독립 샘플링했으므로, 보고한 heatmap은 문제 자체의 변동성과 RSP 벡터 변동성을
 711 함께 평균한 결과다.

712 F.1 토큰당 attention 질량

713 각 문제에서 attention은 연결된 시퀀스 [prompt; $\mathbf{H}$; generation] 위에서 측정하며, generation은
 714 같은 모델이 동일한 RSP 주입 설정 아래 생성한 궤적이다. $\alpha_{i,j}^{(\ell,h)}$ 를 layer ℓ , head h 에서 query
 715 위치 i 가 key 위치 j 로 보내는 post-softmax attention weight라고 하자. 이는 causal mask 아래에서
 716 $\sum_j \alpha_{i,j}^{(\ell,h)} = 1$ 을 만족한다. 질문 토큰과 RSP 토큰의 인덱스 집합을 각각 Q , R 라 하고 크기를
 717 $|Q|$, $|R| = L$, head 수를 H 라 하자. 이때 query i 가 각 그룹으로 보내는 layer ℓ 의 per-token
 718 attention mass는

$$\text{PTM}_Q[\ell, i] = \frac{1}{|Q|H} \sum_{h=1}^H \sum_{j \in Q} \alpha_{i,j}^{(\ell,h)}, \quad \text{PTM}_R[\ell, i] = \frac{1}{|R|H} \sum_{h=1}^H \sum_{j \in R} \alpha_{i,j}^{(\ell,h)}. \quad (7)$$

719 $|Q|$ 와 $|R|$ 로 나누는 정규화는 집합 크기 차이를 보정하므로, 두 양은 동일한 softmax 분모 아래
 720 에서 질문 토큰 또는 RSP 토큰 하나가 평균적으로 얼마나 많은 attention을 받는지를 나타낸다.
 721 따라서 질문 토큰은 시퀀스 길이 효과를 흡수하는 크기 보정 baseline 역할을 한다.

722 F.2 Heatmap 집계

723 Layer 인덱스와 reasoning position 인덱스를 각각 동일 크기의 다섯 구간 $\{B_L^{(b)}\}_{b=1}^5$, $\{B_P^{(b)}\}_{b=1}^5$
 724 로 나눈다. 샘플 s 와 목표 집합 $\bullet \in \{Q, R\}$ 에 대해 셀 (b_L, b_P) 의 값은

$$M_{\bullet}^{(s)}[b_L, b_P] = \frac{1}{|B_L^{(b_L)}| \cdot |B_P^{(b_P)}|} \sum_{\ell \in B_L^{(b_L)}} \sum_{i \in B_P^{(b_P)}} \text{PTM}_{\bullet}[\ell, i]. \quad (8)$$

725 Figure 1는 Eq. (8)를 500개의 유효 샘플에 대해 평균한 결과를 보고한다.

726 F.3 \boxed{\dots} 구간 제외

727 Reasoning position 범위는 마지막 \boxed{\dots} 구간이 시작되기 직전에 끝나도록 잡는다.
 728 Chain-of-thought 출력은 *text*(내용)와 *pattern*(형식) 성분으로 나뉘며, 이 둘은 downstream 성
 729 능에 독립적으로 기여할 수 있다 [Madaan and Yazdanbakhsh, 2022]. \boxed{\dots} 래퍼는 전형
 730 적인 pattern 성분이다. 이는 추론을 더 전개하기보다는 답 형식을 마무리하는 짧고 정형화된
 731 span이기 때문이다. 이 구간을 포함하면 reasoning dynamics와 무관한 template-driven attention
 732 signature가 섞이게 된다.

733 F.4 마지막 두 레이어 제외

734 Layer 축에서는 마지막 두 transformer layer도 제외한다. 이는 모델 특이적 tuning이 아니라, late
 735 layer에서 나타나는 표준적 현상을 피하기 위한 선택이다.

736 **출력 투영 특화.** 마지막 레이어 근방의 hidden state는 vocabulary logits와 거의 선형 관계를 이
 737 루므로, 표현을 바꾸는 블록이라기보다 점진적 선형 readout으로 기능한다 [Belrose et al., 2023].
 738 같은 맥락에서 late-layer feed-forward module도 출력 분포를 조정하는 메커니즘으로 해석되어
 739 왔다 [Geva et al., 2021]. 따라서 이 레이어들의 attention은 reasoning computation보다 output
 740 formation을 더 강하게 반영한다.

741 마지막 두 레이어를 제외하면 heatmap이 readout 단계보다 reasoning 단계의 attention dynamics
 742 에 더 집중한다. 이 제외는 본문 claim에 필수적이지 않다. 본문이 강조하는 시퀀스 방향
 743 *attenuation*은 이 제외 없이도 관찰되며, Theorem 1이 다루는 것도 layer 방향 단조성이 아니라
 744 sequence-direction attenuation이기 때문이다.

745 F.5 추가적인 suffix heatmap

746 Figure 8는 suffix 주입에서 Qwen2.5-Math-1.5B-Instruct와 LLaMA-3.1-8B-Instruct에 대해 동일한
 747 per-token RSP attention 분석을 보고한다. 앞서 설명한 late-layer 이유 때문에 모든 셀에서 패턴이
 748 완전히 동일하게 일반화되지는 않지만, 두 모델 모두에서 시퀀스 방향(가로축)의 단조 감소는
 749 §3.3의 cache-growth upper envelope가 예측한 것과 일치한다. layer 축(세로)의 추가 감소는 별
 750 개의 경험적 sharpening 현상으로, Theorem 1만으로 직접 따라오는 결과는 아니다.




Figure 8: 나머지 두 모델(각각 500개 MATH-500 샘플)에서 suffix 주입 시 측정한 per-token RSP attention mass. 축과 전처리는 Figure 1와 동일하다. x축은 다섯 분위로 나눈 reasoning position, y축은 다섯 분위로 나눈 layer depth(위가 얇은 층), 색은 RSP 토큰에 할당된 per-token attention의 500샘플 평균을 뜻한다. `\boxed{ }` 구간 내부 토큰과 마지막 두 레이어는 제외했다.

751 G DAPO 구현

752 이 부록은 §5을 보충하여 GRPO 대비 DAPO 손실 변경, DAPO + RSP 구현, 그리고 step별 전체
753 결과를 정리한다.

754 G.1 GRPO에서 DAPO로

755 원본 GRPO [Shao et al., 2024]는 보상 $\{R_i\}_{i=1}^G$ 를 갖는 G 개 rollout $\{o_i\}_{i=1}^G$ 에 대해 다음 목적함
756 수를 사용한다.

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left(\min(r_{i,t} \hat{A}_{i,t}, \text{clip}(r_{i,t}, 1-\varepsilon, 1+\varepsilon) \hat{A}_{i,t}) - \beta D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}}) \right) \right], \quad (9)$$

757 여기서 importance ratio는 $r_{i,t} = \pi_\theta(o_{i,t} \mid q, o_{i,<t}) / \pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})$, 그룹 상대 advantage는
758 $\hat{A}_{i,t} = (R_i - \text{mean}(\{R_i\})) / \text{std}(\{R_i\})$, ε 는 clipping 범위, βD_{KL} 은 reference π_{ref} 에 대한 KL 페
759 널티다.

760 학습 파이프라인은 SimpleRL-Zoo [Zeng et al., 2025]를 기반으로 하고 DAPO를 VeRL [Sheng
761 et al., 2024] 위에서 구현한다. DAPO는 Eq. (9)를 네 가지 측면에서 수정한다. (i) 토큰 단위 손실
762 집계 $1 / \sum_i |o_i|$ ($1 / |o_i|$ 대신), (ii) 비대칭 clipping $(\varepsilon_{\text{low}}, \varepsilon_{\text{high}}) = (0.2, 0.28)$, (iii) dual clipping safe-
763 guard $\max(L_{\text{clipped}}, c\hat{A})$ ($c = 10$), (iv) KL 항 제거 (`use_kl_loss=False`, `kl_loss_coef=0`,
764 `algorithm.kl_ctrl.kl_coef=0`).

765 G.2 DAPO + RSP 구현

766 DAPO + RSP에서는 추가로 그룹별 RSP $\mathbf{H}_g \in \mathbb{R}^{L \times d}$ ($L = 20$)를 각 rollout에 주입한다. $\mathbf{H}_g$ 는
767 step별 group seed로 결정적으로 생성하고 forward hook으로 주입하므로 학습 가능 파라미터가
768 아니다. 따라서 학습 신호는 학습된 prompt에서 오는 것이 아니라, policy가 임의의 $\mathbf{H}_g$ 에 적응
769 하는 데서 온다. rollout 시점과 update 시점 모두에서 $\mathbf{H}_g$ 를 log-prob에 포함해 RSP-conditioned
770 분포에 대한 on-policy 업데이트를 유지한다(off-policy mismatch 회피). $G = 8$, $n = 8$ 이라 각
771 그룹에 응답이 하나뿐이므로 rollout마다 사실상 다른 $\mathbf{H}_g$ 를 본다.

772 G.3 데이터, 배치, 하이퍼파라미터

Table 10: Qwen2.5-Math-7B에서의 DAPO / DAPO + RSP 학습 설정.

항목	값
학습 데이터	MATH Level 3–5 subset (<code>simplelr_math_35</code> , 약 8,500 prompt)
Prompt template	<code>qwen-boxed</code>
학습 배치 크기	1024
PPO mini-batch 크기	256 (rollout당 4회 PPO 업데이트)
prompt당 rollout 수 G	8
최대 prompt / response 길이	2,028 / 2,048
Rollout sampling	temperature 1.0, top- p 1.0, top- k 50
$(\varepsilon_{\text{low}}, \varepsilon_{\text{high}})$	(0.2, 0.28)
Dual clip c	10.0
손실 집계	token-mean ($1 / \sum_i o_i $)
KL 항	사용 안 함
Entropy 계수	0
Optimizer	AdamW, learning rate 5×10^{-7} (constant), warmup 없음
총 학습	약 10 epoch, ≥ 80 최적화 step
저장 / 평가 주기	매 10 step
RSP (DAPO + RSP에만)	suffix 주입, $L = 20$, rollout마다 새로 추첨
하드웨어	4× NVIDIA B200 GPU
실측 학습 시간	run당 약 12시간

773 G.4 평가 프로토콜

774 저장된 각 체크포인트는 HuggingFace 형식으로 변환한 뒤 SimpleRL-Zoo
775 eval_math_nodes.sh 파이프라인으로 평가한다. 작은 경시대회 셋의 분산을 줄이기
776 위해 벤치마크별로 sampling 파라미터를 다르게 둔다.

Table 11: SimpleRL-Zoo sh/eval.sh의 벤치마크별 평가 프로토콜.

벤치마크	문제 수	Temperature	n_{sampling}	Metric
AIME 2024	30	1.0	32	Avg@32
AMC 2023	40	1.0	32	Avg@32
MATH-500	500	0.0	1	accuracy (mean@1)
GSM8K	1,319	0.0	1	accuracy
OlympiadBench	675	0.0	1	accuracy
Minerva Math	272	0.0	1	accuracy
GaoKao 2023-EN	385	0.0	1	accuracy

777 모든 벤치마크에서 최대 생성 토큰 수는 16,000이다. 보고하는 평균은 7개 벤치마크의 가중치
778 없는 평균이다.

779 G.5 Step별 평균 정확도

Table 12: 체크포인트별 7-벤치마크 평균 정확도(%). 굵게는 각 방법의 peak.

Step	DAPO	DAPO + RSP
0	30.13	30.13
10	48.63	47.70
20	51.09	51.69
30	51.66	52.51
40	51.96	53.97
50	52.57	54.29
60	53.90	54.96
70	54.97	55.71
80	55.41	56.09
90	54.29	56.13
100	52.56	55.81

780 G.6 한계와 향후 과제

781 DAPO + RSP를 완성된 레시피로 주장하지는 않는다. 본 비교는 Dynamic Sampling과 overlong
782 reward shaping을 생략한 축소된 DAPO 설정을 사용했고, 평가 run은 단일 학습 seed에 기반한다.
783 분산이 큰 작은 경시대회 셋(AIME 2024, AMC 2023)에서 multi-seed 평가와 함께 전체 DAPO
784 설정 아래에서 이득을 재확인하는 작업은 향후 과제로 남는다.

785 H 광범위한 영향

786 본 연구는 무작위 임베딩 주입이 대형 언어 모델의 추론 행동에 어떤 영향을 주는지에 대한
787 실험적·이론적 분석을 제공한다. 기여의 성격은 주로 기초 연구에 가깝지만, GRPO와 같은
788 강화학습 기반 추론 모델 후속학습에는 잠재적 함의를 가진다.

789 **긍정적 영향.** RSP가 유도하는 궤적 다양성은 group-relative advantage estimation 안에서 더
790 풍부한 학습 신호를 제공함으로써, RL 기반 LLM 후속학습의 sample efficiency를 높일 수 있다.
791 이는 reasoning 중심 fine-tuning과 alignment에 필요한 계산 비용을 줄여, 자원이 제한된 연구
792 그룹에도 관련 방법을 더 접근 가능하게 만들 수 있다.

793 **잠재적 우려.** LLM의 유효 출력 지지 집합을 넓히는 방법은 바람직한 대안적 추론 경로뿐
794 아니라, 바람직하지 않거나 분포 밖에 있는 출력의 도달 가능성도 함께 높일 수 있다. 따라서
795 RSP를 실제 시스템에 적용할 때는 이를 독립적인 다양성 원천으로만 보지 말고, 기존의 안전
796 필터링 및 alignment 메커니즘과 함께 사용해야 한다.

797 **영향 범위의 한계.** 본 연구는 새로운 모델이나 데이터셋을 배포하기보다 분석을 제공하는 데
798 초점을 두므로, 직접적인 사회적 영향은 제한적이다. 여기서 논의한 더 넓은 함의는 RSP가 실제
799 학습 파이프라인에 통합되는 향후 연구가 이루어질 때에만 현실화될 수 있다.