

# 노이즈에서 다양성으로: 대형 언어 모델 추론에서의 무작위 임베딩 주입

Anonymous Author(s)

Affiliation

Address

email

## Abstract

최근 *soft prompt* 계열 방법은 가상 토큰 형태의 학습 가능한 연속 임베딩을 LLM 입력 앞이나 중간에 삽입해 수학 추론 성능을 높여 왔다. 그러나 임베딩 주입 자체가, 최적화와는 독립적으로, 모델의 행동에 어떤 영향을 주는지는 거의 분석되지 않았다. 본 논문은 학습 없이 주입되는 Random Soft Prompt(RSP)를 다룬다. RSP는 사전학습된 임베딩 행렬의 항별 평균과 분산을 맞춘 등방 가우시안에서 샘플링한 연속 벡터를 그대로 삽입한 것이다. RSP에서 무작위성은 임베딩 분포를 모사하는 장치가 아니라, 같은 프롬프트가 rollout마다 독립적인 섭동을 만들도록 해 주는 성질이며, 탐색은 바로 이 독립성을 요구한다. 실험적으로 RSP는 생성 초반의 토큰 엔트로피를 높이지만 이후에는 분포가 다시 안정화되며, temperature sampling과 결합할 경우 Pass@ $n$ 으로 측정한 추론 개성 다양성을 더 크게 확장한다. 이론적으로는 각 어텐션 레이어에서 RSP의 기여가 무작위 토큰 어텐션 질량이라는 단일 스칼라로 정확히 포착되고, 그 양은 자기회귀적 캐시 성장이 실제 토큰을 누적할수록 구조적으로 희석됨을 보인다. 또한 섭동된 logits에 대한 국소 affine 분석 아래에서 등방 재추침은 temperature sampling으로는 결코 닿을 수 없는 방식으로 baseline에서 제외되었던 토큰을 유효 top- $K$  후보 집합 안으로 진입시킨다. Hopfield 형 에너지 지형과의 연결은 부록에 해석적 시각으로 기록되었으나, 어떤 형식적 결과에도 사용되지 않는다. 마지막으로 이러한 다양성이 학습 신호의 질에 중요한 GRPO 학습에 갖는 함의도 논의한다.

## 1 서론

대형 언어 모델(LLM)이 수십억 개 이상의 파라미터로 커지면서 전체 파라미터를 모두 미세조정하는 비용도 빠르게 증가했다. 이에 따라 고정된 모델에 소수의 추가 파라미터만 도입해 적응시키는 parameter-efficient 방법이 주목받고 있다 [Hu et al., 2022, Houlsby et al., 2019]. 그중 *soft prompt*는 학습 가능한 연속 임베딩을 입력 시퀀스 앞이나 중간에 삽입해 attention 메커니즘을 통해 모델 행동을 조정하는 대표적 접근이다 [Li and Liang, 2021, Lester et al., 2021]. 이러한 패러다임은 수학 추론을 강화하는 데에도 활발히 활용되고 있다 [Kang et al., 2026, Xu et al., 2025, Ye et al., 2026, Hao et al., 2025, Zhang et al., 2026]. 세부 설계는 다르지만, 이들 방법은 모두 사전학습 어휘 바깥의 연속 임베딩을 주입하고 그것을 최적화해 downstream 성능을 끌어 올린다는 공통 구조를 갖는다.

하지만 우리는 이러한 효과에 최적화가 반드시 필요한 것은 아님을 관찰했다. 무작위로 초기화된, 학습되지 않은 연속 임베딩을 주입하는 것만으로도 출력 분포가 바뀔 수 있다. 예를 들어 채팅 형식으로 학습되지 않은 base model에 chat template을 적용하면 프롬프트 형식 불일치 때문에 추론 성능이 크게 떨어지는데, 여기에 무작위 임베딩을 덧붙이면 이 성능 저하가 완화된다. 이는 학습된 의미 내용과 무관하게, 어휘 바깥의 연속 임베딩을 입력에 주입하는 행위 자체가 모델 행동을 비자명하게 바꿀 수 있음을 시사한다. 기존 연구는 대체로 *soft prompt* 방법을 최종

정확도로만 평가했기 때문에, 주입 자체의 효과와 최적화의 효과가 분리되어 있지 않으며, 이런 연속 임베딩 주입이 출력 분포를 어떻게 바꾸는지는 여전히 충분히 탐구되지 않았다.

본 연구는 학습 없이 주입되는 Random Soft Prompt(RSP)의 역할을 분석한다. RSP는 사전학습된 임베딩 행렬의 항별 평균과 분산을 맞춘 등방 가우시안에서 샘플링한 연속 벡터다. 여기서 무작위성은 임베딩 분포를 모사하는 장치가 아니라, 같은 프롬프트가 rollout마다 독립적인 섭동을 만들도록 해 주는 성질이며, 탐색은 바로 이 독립성을 요구한다. 실험적으로 RSP는 생성 초반의 토큰 엔트로피를 높이지만 후반으로 갈수록 출력을 다시 안정화되며, temperature sampling과 결합할 경우 Pass@n의 증가로 드러나는 더 다양한 추론 궤적을 만들어 낸다. 이론적으로는 어텐션 수준의 메커니즘을 식별한다. 각 어텐션 레이어에서 RSP의 기여는 무작위 토큰 어텐션 질량이라는 단일 스칼라로 정확히 포착되고, 그 양은 자기회귀적 캐시 성장에 의해 구조적으로 희석된다. 또한 섭동된 logits에 대한 국소 affine 분석 아래에서, 등방 재추첨이 temperature sampling으로는 결코 닿을 수 없는 방식으로 baseline에서 제외되었던 토큰을 유효 top-K 후보 집합 안으로 진입시킴을 보인다. 마지막으로 이러한 다양성이 효과적인 학습 신호에 필수적인 Group Relative Policy Optimization(GRPO) [Shao et al., 2024]와 어떤 관련을 갖는지도 논의한다. 본 논문의 기여는 다음과 같다.

- RSP가 LLM 생성에 어떤 변화를 주는지 실증적으로 분석하고, RSP가 생성 초반의 토큰 엔트로피를 높이며 temperature sampling과 결합될 때 더 다양한 추론 궤적을 만든다는 점을 보인다.
- 트랜스포머 수준 메커니즘을 제시한다. RSP의 기여는 단일 스칼라 어텐션 질량으로 통제되고 캐시 성장에 의한 구조적 희석을 받으며, 국소 affine surrogate 위의 분포 분석 아래에서 고정 섭동이 아닌 등방 재추첨이 baseline에서 제외되었던 토큰을 유효 top-K 후보 집합 안으로 진입시킨다는 점을 보인다.
- RSP가 유도하는 다양성이 GRPO 학습에 어떤 함의를 갖는지 논의하고, RSP는 순위를 바꾸는 섭동인 반면 temperature는 순위를 보존하는 섭동이라는 점에서, 두 방법이 직교하는 탐색 이득을 제공한다고 주장한다.

## 2 배경

### 2.1 LLM 추론을 위한 Soft Prompt 기법

Soft prompt는 전체 미세조정 대상이 되는 parameter-efficient 접근으로 등장했다. Prefix-Tuning [Li and Liang, 2021]은 학습 가능한 연속 벡터를 각 transformer 레이어 앞에 붙이는 패러다임을 제안했고, Prompt Tuning [Lester et al., 2021]은 이를 입력 레이어만 사용하는 단순한 형태로 줄이면서 충분히 큰 모델에서는 전체 미세조정과 맞먹는 성능을 낼 수 있음을 보였다. P-tuning [Liu et al., 2024]은 여기에 LSTM 기반 prompt encoder를 도입해 위치 간 의존성을 모델링했다.

최근에는 이러한 soft prompt가 LLM 추론에도 적극적으로 적용되고 있다. TTSV [Kang et al., 2026]는 테스트 시점에 prefix 임베딩을 엔트로피 최소화해 최적화해 모델을 더 확신적인 상태로 유도함으로써 잠재 추론 능력을 활성화한다. SoftCoT [Xu et al., 2025]은 assistant model이 생성한 soft token으로 명시적 chain-of-thought 토큰을 대체해, 연속 표현이 이산 언어보다 더 강한 표현력을 가질 수 있음을 활용한다. LTPO [Ye et al., 2026]는 confidence 기반 내재 보상을 사용한 policy gradient로 테스트 샘플마다 latent thought 임베딩을 최적화한다. COCONUT [Hao et al., 2025]은 모델 자신의 은닉 상태를 다시 입력 임베딩으로 되먹임해 연속 잠재 공간에서 추론하게 만들고, MemGen [Zhang et al., 2026]은 임베딩 벡터가 경험 메모리로 기능할 수 있음을 보이며 추론을 보강하는 latent token 시퀀스를 구성한다. Pause token [Goyal et al., 2024]은 입력 중간에 학습 가능한 토큰을 삽입해 추가 계산 단계를 제공한다.

이들 접근은 모두 과제 특화 목적함수에 맞게 최적화된 어휘 바깥의 연속 임베딩을 주입한다. 그러나 평가는 주로 최종 정확도에 맞춰져 있기 때문에, 주입 자체의 효과와 최적화의 효과는 분리되어 있지 않으며, 이런 연속 임베딩 주입이 모델 행동을 어떻게 바꾸는지는 별도의 미해결 문제로 남아 있다.

### 2.2 신경망에서의 노이즈 주입

신경망은 여러 단계에서 노이즈를 도입해 왔다. 학습 과정에서는 dropout [Srivastava et al., 2014]이 은닉 유닛을 무작위로 비활성화해 과적합을 방지하고, NEFTune [Jain et al., 2024]은 instruction fine-tuning 중 토큰 임베딩에 노이즈를 더해 instruction following 성능 향상을 보고한

다. 그러나 이런 방법은 학습 시점의 regularization에 초점을 두며, 추론 시점의 섭동은 다루지 않는다.

추론 시점의 섭동 기반 접근은 주로 강건성과 안전성을 겨냥한다. Randomized smoothing [Cohen et al., 2019]은 입력에 가우시안 노이즈를 주입해 certified robustness를 얻고, LLM 맥락의 Smooth-LLM [Robey et al., 2025]은 문자 수준의 프롬프트 변형을 통해 jailbreak 공격을 방어한다. 이들 방법은 여러 번의 noisy forward pass와 출력 집계를 필요로 하며, 목표도 출력 다양성이 아니라 예측 안정성이다.

강화학습에서는 NoisyNet [Fortunato et al., 2018]이 네트워크 가중치에 학습 가능한 노이즈를 넣어 탐색 성능을 높였고, 노이즈의 위치와 구조가 탐색 품질을 좌우한다는 점을 보였다. 이 문제의식은 다양성을 겨냥하는 RSP와 가장 가깝지만, 주입 대상이 입력 임베딩이 아니라 네트워크 가중치이며, 노이즈 파라미터를 따로 학습해야 한다는 점에서 다르다.

RSP는 이들과 세 가지 점에서 구별된다. (1) RSP는 어떠한 학습도 없이 추론 시점에만 동작하는 반면, dropout과 NEFTune은 학습 과정에서 노이즈를 넣고 결과적으로 모델 파라미터 자체를 바꾼다. (2) RSP는 원래 입력을 보존한 채 새로운 임베딩 벡터를 한 번의 forward pass 안에 덧붙이지만, 강건성 방법은 입력을 오염시키고 여러 번의 noisy pass를 집계한다. (3) RSP는 사전학습 임베딩 통계에서 샘플링한 순수한 무작위 벡터를 사용하지만, NoisyNet은 노이즈 파라미터 자체를 학습한다.

### 3 실험 분석

#### 3.1 Random Soft Prompt의 정의와 설정

사전학습된 LLM의 토큰 임베딩 행렬을  $\mathbf{W}_E \in \mathbb{R}^{V \times d}$ 라 하자. 여기서  $V$ 는 어휘 크기이고  $d$ 는 은닉 차원이다. 우리는 RSP를  $L$ 개의 연속 벡터 시퀀스  $\mathbf{H} = [h_1, \dots, h_L] \in \mathbb{R}^{L \times d}$ 로 정의하며, 각 벡터는 다음 분포에서 독립적으로 샘플링된다.

$$h_j \sim \mathcal{N}(\mu_E, \sigma_E^2 \mathbf{I}), \quad j = 1, \dots, L, \quad (1)$$

여기서  $\mu_E = \frac{1}{V_d} \sum_{i,k} [\mathbf{W}_E]_{i,k}$ ,  $\sigma_E = \text{std}(\mathbf{W}_E)$ 이다. 원래 입력의 임베딩 시퀀스를  $\mathbf{X} = [x_1, \dots, x_T] \in \mathbb{R}^{T \times d}$ 라 하면, RSP가 주입된 입력  $\hat{\mathbf{X}}$ 는 원래 프롬프트 텍스트는 바꾸지 않은 채 세 위치 중 하나에서  $\mathbf{H}$ 를 연결해 만든다: *prefix* ( $[\mathbf{H}; \mathbf{X}]$ ), *infix* ( $\mathbf{H}$ 가  $\mathbf{X}$  내부에 삽입됨), *suffix* ( $[\mathbf{X}; \mathbf{H}]$ ). 이는 선행 연구의 주입 전략을 따른다 [Kang et al., 2026, Xu et al., 2025, Ye et al., 2026, Zhang et al., 2026]. 각 배치마다 새로운  $\mathbf{H}$ 를 샘플링함으로써, 결과가 특정 무작위 임베딩 실현값 하나에 의존하지 않도록 했다.

평가는 세 가지 수학 추론 벤치마크, MATH-500 [Lightman et al., 2024], GSM8K [Cobbe et al., 2021], AIME24에서 수행한다. 모델은 LLaMA-3.1-8B-Instruct [Grattafiori et al., 2024]와 Qwen2.5-Math 계열 [Yang et al., 2024]을 사용하며, instruct model, base model, 그리고 chat template이 맞지 않는 base model까지 포함해 총 일곱 설정을 비교한다. 모든 실험은 sampling 자체의 무작위성과 RSP 효과를 분리하기 위해 greedy decoding을 사용한다. 평가는 fallback 기반의 answer extraction pipeline으로 최종 답만 채점한다. 전체 실험 설정은 Appendix A에 정리했다.

#### 3.2 RSP는 추론 성능을 떨어뜨리는가?

먼저 무작위 임베딩 주입이 모델의 추론 성능에 어떤 영향을 주는지 본다. Table 1는 각 벤치마크에서 주입 위치(Prefix, Infix, Suffix)와  $L \in \{10, 15, 20\}$  가운데 가장 좋은 RSP 결과를 보고한다.

instruct model과 원래 프롬프트 형식을 쓰는 base model에서는 RSP가 baseline 성능을 대체로 몇 퍼센트포인트 이내에서 유지하거나 소폭만 이동시킨다. 더 눈에 띄는 것은 프롬프트 형식 불일치 상황이다. 즉, 채팅 형식으로 학습되지 않은 base model에 ChatML template을 주입했을 때, RSP는 최대 +29%p까지의 큰 성능 향상을 보인다. 단순히 불확실성을 높이는 노이즈였다면 오히려 성능 저하가 커졌어야 하므로, 이 결과는 RSP 효과가 단순한 교란을 넘는다는 점을 시사한다.

또한 RSP를 TTSV, SoftCoT, LTPO처럼 서로 다른 목적 함수로 임베딩을 최적화하는 기존 soft prompt 방법과 비교했다. Table 2은 공통 answer extraction pipeline 아래에서 다시 평가한 결과를 보여준다. 각 방법은 프롬프트 형식과 채점 규칙이 다르지만, fallback 기반 추출을 사용해

Table 1: 모델 설정과 벤치마크별 정확도(%). RSP는 주입 위치(Prefix, Infix, Suffix) 중 최고 성능만 보고한다. 위치별 전체 결과는 Appendix A에 있다. 괄호 안 값은 baseline 대비 변화량이다.

| Model                                         | MATH-500 |               | GSM8K    |               | AIME24   |               |
|-----------------------------------------------|----------|---------------|----------|---------------|----------|---------------|
|                                               | Baseline | RSP           | Baseline | RSP           | Baseline | RSP           |
| <i>Instruct Models</i>                        |          |               |          |               |          |               |
| LLaMA-3.1-8B-Inst                             | 52.20    | 49.40 (−2.8)  | 85.75    | 86.73 (+1.0)  | 6.67     | 10.00 (+3.3)  |
| Qwen2.5-Math-7B-Inst                          | 83.20    | 84.20 (+1.0)  | 95.45    | 95.68 (+0.2)  | 13.33    | 16.67 (+3.3)  |
| Qwen2.5-Math-1.5B-Inst                        | 73.00    | 75.20 (+2.2)  | 85.29    | 85.75 (+0.5)  | 10.00    | 20.00 (+10.0) |
| <i>Base Models (Raw Text)</i>                 |          |               |          |               |          |               |
| Qwen2.5-Math-7B                               | 72.20    | 71.60 (−0.6)  | 84.15    | 84.31 (+0.2)  | 6.67     | 16.67 (+10.0) |
| Qwen2.5-Math-1.5B                             | 61.40    | 64.40 (+3.0)  | 77.86    | 74.30 (−3.6)  | 16.67    | 10.00 (−6.7)  |
| <i>Base Models + ChatML (Format Mismatch)</i> |          |               |          |               |          |               |
| Qwen2.5-Math-7B                               | 52.20    | 70.40 (+18.2) | 58.30    | 75.97 (+17.7) | 23.33    | 23.33 (+0.0)  |
| Qwen2.5-Math-1.5B                             | 34.40    | 63.40 (+29.0) | 37.45    | 67.02 (+29.6) | 13.33    | 20.00 (+6.7)  |

Table 2: 기존 soft prompt 방법(TTSV, SoftCoT, LTPO)과의 통합 평가 비교. Baseline과 RSP 값은 Table 1에서 가져왔다. **Bold**는 최고 성능, underline은 두 번째 성능이다.

| Model                      | Benchmark | Baseline     | RSP          | TTSV         | SoftCoT      | LTPO         |
|----------------------------|-----------|--------------|--------------|--------------|--------------|--------------|
| Qwen2.5-Math-7B-Instruct   | MATH-500  | 83.20        | <b>84.20</b> | <u>83.80</u> | 82.80        | 83.00        |
|                            | GSM8K     | 95.45        | <b>95.68</b> | <u>95.30</u> | 95.00        | 94.84        |
|                            | AIME24    | 13.33        | <b>16.67</b> | <b>23.30</b> | <u>16.67</u> | 13.33        |
| Qwen2.5-Math-1.5B-Instruct | MATH-500  | 73.00        | <u>75.20</u> | <u>75.20</u> | <b>76.00</b> | 72.40        |
|                            | GSM8K     | 85.29        | <b>85.75</b> | <u>85.70</u> | 84.46        | 84.53        |
|                            | AIME24    | <u>10.00</u> | <b>20.00</b> | 6.70         | 6.67         | <u>10.00</u> |

형식에 덜 민감한 비교를 수행했다. 결과적으로 RSP는 추가 학습 없이도 최적화 기반 방법과 맞먹는 수준의 성능을 보인다.

### 3.3 RSP는 출력 분포를 어떻게 바꾸는가?

다음으로 RSP 주입이 생성 과정의 출력 분포를 어떻게 바꾸는지 살펴본다. 설정은 Qwen2.5-Math-1.5B-Instruct와 MATH-500이며, 토큰별 entropy, top-1 probability, varentropy를 생성 단계에 따라 측정한다. Figure 1와 Table 3는 생성 초반 5% 구간에서 RSP 변형과 기존 soft prompt 방법을 비교한 결과다.




Figure 1: 생성 초반 5% 구간의 평균 entropy, top-1 probability, varentropy (Qwen2.5-Math-1.5B-Instruct, MATH-500). 음영은  $\pm 1$  SEM이다. 실선은 RSP 변형과 baseline, 점선은 기존 soft prompt 방법(LTPO, SoftCoT, TTSV)이다.

결과는 RSP가 생성 초반 출력 분포를 분명히 바꾼다는 점을 보여준다. 세 주입 위치 모두에서 entropy는 증가하고, top-1 probability는 감소하며, varentropy는 증가한다. 이는 분포가 평평해지고, 단일 우세 토큰에 대한 확신은 약해지며, 다분형 분포가 더 자주 나타남을 뜻한다 [Ahmed et al., 2026]. 높은 entropy 구간은 추론 궤적이 갈라지는 핵심 분기점으로 알려져 있으므로 [Wang et al., 2025], 이 변화는 여러 추론 경로가 공존할 수 있는 상태로 모델을 밀어 넣는다. 중요한

Table 3: 생성 초반 5% 구간의 평균 entropy, top-1 probability, varentropy (Qwen2.5-Math-1.5B-Instruct, MATH-500).

| Metric     | Baseline | Prefix | Infix  | Suffix | LTPO   | SoftCoT | TTSV   |
|------------|----------|--------|--------|--------|--------|---------|--------|
| Entropy    | 0.1332   | 0.1366 | 0.1402 | 0.1941 | 0.1662 | 0.4218  | 0.1359 |
| Top-1 Prob | 0.9535   | 0.9523 | 0.9525 | 0.9373 | 0.9437 | 0.9156  | 0.9534 |
| Varentropy | 0.2181   | 0.2207 | 0.2463 | 0.4010 | 0.2953 | 2.2234  | 0.2174 |

점은 변화가 생성 초반에 국한된다는 것이다. 생성 중반과 후반에서는 세 지표 모두 baseline 수준으로 다시 수렴한다.

기존 soft prompt 방법들은 서로 다른 목적 함수로 학습되었음에도, 생성 초반 entropy를 높인다는 공통 패턴을 보인다. 특히 reasoning trajectory의 평균 entropy를 줄이는 보상으로 soft prompt를 최적화하는 TTSV조차 초반 entropy는 baseline과 비슷하거나 더 높은 수준을 보인다. 이는 생성 초반 entropy 상승이 특정 최적화 목적 때문이 아니라, 사전학습되지 않은 연속 임베딩을 주입하는 행위 자체에 가까운 효과일 수 있음을 시사한다.

### 3.4 RSP는 실제로 추론 궤적의 다양성을 만드는가?

Section 3.3는 RSP가 생성 초반 출력 분포를 바꾼다는 사실을 보였다. 이제 이 변화가 실제 추론 다양성으로 이어지는지를 세 수준에서 살펴본다. 분석 수준은 토큰 순위, 궤적의 의미적 내용, 과제 수준 결과다. 세 분석 모두 Qwen2.5-Math-1.5B-Instruct, MATH-500, suffix 주입,  $L = 10$  설정을 공유한다.

**토큰 수준: temperature만으로는 얻을 수 없는 분포 이동.** 자기회귀 생성에서 baseline과 RSP의 궤적 차이는 결국 첫 토큰에서 시작될 수밖에 없다. 따라서 baseline  $\tau=1.0$ 을 기준으로, 단순한 flattening이 만들 수 있는 상한선인 baseline  $\tau=2.0$ 과 RSP  $\tau=1.0$ 을 비교한다. 비교 지표는 세 가지다. Spearman rank correlation  $\rho$ 는 순위 재배치를, baseline의 top-10 밖에 놓이는 확률 질량은 지지 집합 확장을, Jensen-Shannon divergence는 분포 변화의 전체 크기를 측정한다(정의는 Appendix C).

Table 4: Baseline  $\tau=1.0$ 을 기준으로 본 첫 토큰 분포 지표. Baseline  $\tau=2.0$ 과 RSP  $\tau=1.0$ 을 비교한다.

| Metric              | $\tau=2.0$ | RSP           |
|---------------------|------------|---------------|
| Spearman $\rho$     | 1.0        | <b>0.651</b>  |
| Mass outside top-10 | 5.15%      | <b>27.64%</b> |
| JS divergence       | 0.086      | <b>0.231</b>  |

Table 4는 RSP가 temperature scaling과는 질적으로 다른 변화를 만든다는 점을 보여준다.  $\tau=2.0$ 까지 올려도 baseline top-10 밖으로 이동하는 확률 질량은 5.15%에 그치지만, RSP  $\tau=1.0$ 은 27.64%에 도달한다. Spearman 상관은 더 직접적이다. Temperature scaling은  $p_i^{(\tau)} \propto p_i^{1/\tau}$ 라는 단조 변환이므로 어떤  $\tau > 0$ 에서도 토큰 순위를 보존하며, baseline 대비  $\rho$ 는 정확히 1이다. 반면 RSP는 토큰 분포의 순위 자체를 뒤섞어  $\rho$ 를 0.651까지 낮춘다. 이 변화는 temperature만으로는 만들 수 없다. JS divergence 0.231은 이 분포 변화의 전체 크기를 요약한다. 즉, RSP는 같은 순위를 단순히 평평하게 만드는 것이 아니라 분포 구조 자체를 다시 짠다.

**궤적 수준: 의미적 다양성.** 첫 토큰 수준의 재배치가 실제로 의미적으로 다른 추론 경로를 여는지도 중요하다. 이를 위해 MATH-500에서 무작위로 64개 문제를 뽑고, Baseline과 RSP 두 조건에서 각 문제마다 temperature  $\tau = 1.0$ 으로 300개의 독립 궤적을 생성했다. 각 궤적은 BGE-M3 [Chen et al., 2024]로 임베딩한 뒤, 문제 내 평균 pairwise cosine distance, DBSCAN [Ester et al., 1996] 클러스터 중심 사이의 inter-cluster distance, 그리고 intra-cluster distance를 계산했다. Table 5는 RSP가 intra-cluster distance는 거의 바꾸지 않으면서 inter-cluster distance를 크게 키운다는 점을 보여준다. 즉, 각 전략 내부의 일관성은 유지하면서 전략 간 거리를 벌린다. Pairwise distance 기준으로 RSP는 64개 중 56개 문제(87.5%)에서 baseline보다 컸다.

Table 5: 64개 문제에 대해 평균한 의미적 다양성 지표.

| Metric              | Baseline | RSP           |
|---------------------|----------|---------------|
| Pairwise cos. dist. | 0.0612   | <b>0.0879</b> |
| Inter-cluster dist. | 0.0183   | <b>0.0982</b> |
| Intra-cluster dist. | 0.0526   | 0.0528        |

Figure 2(a)는 이 차이를 시각적으로 보여준다. RSP 샘플(파랑)은 baseline 샘플(빨강)이 차지하는 영역을 포함하면서, baseline이 도달하지 못한 별도 클러스터까지 확장된다. 그리고 새로 열린 영역에도 정답 궤적이 포함되어 있어, RSP의 탐색이 단지 오답 변형으로만 흘러지는 것은




Figure 2: 64개 MATH-500 문제에서의 의미적 다양성 분석(문제당 300개 궤적, Qwen2.5-Math-1.5B-Instruct,  $\tau = 1.0$ , BGE-M3 임베딩). (a) 대표 문제 `test/prealgebra/951`의 t-SNE 투영: baseline(빨강)은 한 영역에 비교적 집중되지만, RSP suffix(파랑)는 더 넓고 분리된 군집까지 확장된다. 채워진 표식은 정답, 빈 표식은 오답이다. (b) 문제별 평균 pairwise cosine distance. 대각선 위 점은 RSP가 baseline보다 더 다양한 궤적을 만든다는 뜻이다. (c) 문제별 DBSCAN 클러스터 수. 대부분의 문제에서 RSP가 더 많은 클러스터를 만든다.

아님을 알 수 있다. Figure 2(b), (c)는 이러한 패턴이 64개 문제 전반에 걸쳐 반복됨을 보여준다. 대부분의 문제에서 RSP는 더 많은 클러스터와 더 큰 pairwise cosine distance를 만든다. 큰 inter-cluster 증가와 거의 변하지 않는 intra-cluster 거리는 토른 수준의 결과와도 맞닿아 있다. RSP는 각 클러스터 내부의 진행은 호트러프리지 않으면서, 궤적이 진입하는 전략 클러스터 자체를 바꾼다. 문제별 추가 t-SNE 그림은 Appendix B의 Figure 6에 제시한다.

**결과 수준: Pass@n 스케일링.** 마지막으로 토큰 수준과 궤적 수준의 다양성이 실제 과제 성과의 다양성으로 이어지는지 본다. 지표는 Pass@n이며, 이는  $n$  개의 샘플 중 적어도 하나가 정답일 확률이다. MATH-500과 AIME24에서 문제당  $n = 16$  개의 샘플을 생성하고, 다음 네 조건을 비교한다. (i) Baseline,  $\tau = 1.0$ : temperature sampling만 사용. (ii) RSP (fixed seed),  $\tau = 1.0$ : 하나의 RSP를 모든 샘플이 공유. (iii) RSP (indep. seed), greedy: 샘플마다 다른 RSP를 쓰되 temperature는 사용하지 않음. (iv) RSP (indep. seed),  $\tau = 1.0$ : 샘플마다 다른 RSP와 temperature sampling을 함께 사용.




Figure 3: Qwen2.5-Math-1.5B-Instruct에서의 Pass@n 스케일링. 좌측은 MATH-500, 우측은 AIME24이며, 문제당  $n = 16$  개의 샘플을 사용했다. Baseline은 temperature sampling만, fixed seed는 고정된 하나의 RSP와 temperature를 함께 쓴 경우, indep. seed는 샘플마다 다른 RSP를 쓰는 경우이다.

조건 (iv)가 두 벤치마크 모두에서 가장 높은 Pass@n를 달성한다.  $n = 16$  에서 MATH-500은 92.80%, AIME24는 36.67%까지 올라간다. 반면 (ii)는 baseline 대비 개선이 거의 없어, 다양성 이득의 핵심이 하나의 고정 섭동이 아니라 샘플마다 다른 무작위 임베딩이라는 점을 보여준다. Pass@1은 MATH-500에서 baseline과 비슷한 수준을 유지하고, 더 어려운 AIME24에서는 (iv)가 baseline보다 더 높다. 즉, 독립적인 RSP와 temperature sampling의 결합은 단일 샘플 정확도를 해치지 않으면서 더 다양한 추론 궤적을 생성한다.

**세 수준의 종합.** 세 분석은 하나의 일관된 그림으로 수렴한다. 토큰 수준에서는 RSP가 첫 토큰에 집중된 지지 집합 확장을 만들고, 그 효과는 뒤 토큰으로 갈수록 단조롭게 약해진다. 궤적 수준에서는 이 국소적 섭동이 서로 다른 추론 전략을 열어 큰 inter-cluster 분리를 만들지만,



209 각 전략 내부의 국소적 일관성은 유지된다. 결과 수준에서는 그렇게 생성된 궤적들이 더 많은  
210 정답 해를 덮으면서도 단일 샘플 정확도를 잃지 않는다.

## 211 4 이론적 분석: 어텐션 매개 탐색으로서의 RSP

212 Section 3에서 관찰된 세 가지 실험적 규칙성—생성 초반의 엔트로피 상승, 후반의 안정화, 반복  
213 디코딩 아래의 Pass@N 향상—은 트랜스포머 수준에서 하나의 메커니즘으로 설명된다. RSP는  
214 출력 softmax 이전에 은닉 상태를 단 하나의 스칼라량, 즉 무작위 토큰 어텐션 질량(random-token  
215 attention mass)을 통해 섭동하며, 이 양은 자기회귀적 캐시 성장에 의해 구조적으로 희석된다.  
216 RSP에서 무작위성은 임베딩 분포를 모사하기 위한 것이 아니다. 같은 프롬프트가 rollout마다  
217 독립적인 섭동을 만들도록 해 주는 성질이며, 탐색은 바로 이 독립성을 요구한다. 이하의 논의는  
218 표준 self-attention 항등식만 사용하며, 특히  $\mathbf{K} = \mathbf{V}$ , 가중치 공유, 전역 에너지 함수의 존재 중  
219 어느 것도 가정하지 않는다.

### 220 4.1 스케일 정합 등방 섭동

221 **정의 1** (Random Soft Prompt).  $\mathbf{W}_E \in \mathbb{R}^{V \times d}$ 를 사전학습된 입력 임베딩 행렬,  $\mu_E$ 와  $\sigma_E$ 를 그  
222 항별 스칼라 평균과 표준편차라 하자. 길이  $k$ 의 RSP란  $h_j = \mu_E \mathbf{1}_d + \sigma_E \xi_j$ ,  $\xi_j \stackrel{iid}{\sim} \mathcal{N}(0, \mathbf{I}_d)$ 로 주  
223 어지는 수열  $(h_1, \dots, h_k)$ 를 말한다. 중심화된 프롬프트  $\tilde{h}_j := h_j - \mu_E \mathbf{1}_d$ 는  $\tilde{h}_j \sim \mathcal{N}(0, \sigma_E^2 \mathbf{I}_d)$ 를  
224 만족한다. Pass@N과 같은 반복 샘플링 프로토콜에서, 비교되는 시도들에 사용되는 프롬프트  
225 추첨과 디코딩 무작위성은 모두 독립이라 가정한다.

226 실제 임베딩 분포는 일반적으로 비등방(anisotropic)이며 [Mu and Viswanath, 2018, Ethayarajh,  
227 2019], RSP는 의도적으로 그것에서 벗어난다.  $\sigma_E$ 를 빌려오는 것은 섭동을 모델이 기대하는  
228 크기 영역에 두기 위함이고, 단위 공분산을 쓰는 것은 방향 구조를 일부러 버리기 위함이다. 분  
229 기를 가르는 결정적 방향은 프롬프트, 레이어, 위치, 비교되는 토큰 쌍에 따라 매번 달라지므로,  
230 일반적인 탐색 섭동은 사전에 소수의 임베딩 방향에 자신을 묶어 두어서는 안 된다.

### 231 4.2 왜 무작위성이 필수인가

232 탐색은 시도 간 변동을 요구하며, 그 변동은 고정된 섭동으로는 결코 공급될 수 없다. 학습된  
233 연속 프롬프트는 모델을 한 방향으로 이끌 수 있지만, 같은 벡터를 rollout마다 재사용하면 매번  
234 같은 섭동 방향이 들어가므로 독립적 대안을 만들지 못한다. 이산 무작위 토큰은 다른 방식으로  
235 실패한다. 어휘의 각 토큰은 사전학습에서 물려받은 어휘적·의미적 방향을 갖고 있어, 토큰  
236 수준의 추첨은 통제되지 않은 의미 prior를 주입한다. RSP는 연속이고, 중심화되어 있고, 등  
237 방적이라는 세 성질로 두 실패 모드를 모두 피하며, 다음 두 결과는 그 세 성질이 각각 무엇을  
238 보장하는지를 명시한다.

239 **보조정리 1** (의미적 중립성).  $\tilde{h} \sim \mathcal{N}(0, \sigma^2 \mathbf{I}_d)$ ,  $\hat{h} := \tilde{h} / \|\tilde{h}\|$ 라 하자. 임의의 고정된 단위벡터  
240  $u_1, \dots, u_M \in \mathbb{S}^{d-1}$ 와  $\delta \in (0, 1)$ 에 대해

$$\Pr \left[ \max_{r \in [M]} |\hat{h}^\top u_r| \leq \sqrt{\frac{2 \log(2M/\delta)}{d-1}} \right] \geq 1 - \delta.$$

241 토큰 임베딩은 이 성질을 만족하지 못한다. 어떤 고정 방향  $u = e_s / \|e_s\|$ 에 대해  $|\hat{e}_s^\top u| = 1$ 이기  
242 때문이다. Lemma 1는 그보다 더 약하지만 충분한 주장만 형식화한다. 즉, 등방 무작위 방향은  
243 임의의 유한한 의미 anchor 집합과 높은 확률로 거의 직교한다는 것이며, 단일 무작위 벡터가  
244 모든 우연한 상관에서 자유롭다는 의미가 아니다.

245 **정리 1** (방향 무관 커버리지).  $\mathbb{R}^d$  위의 평균 0 섭동 분포  $D$ 의 공분산을  $\Sigma_D$ , 분산 예산을  $\text{tr}(\Sigma_D) \leq$   
246  $\rho^2$ 라 하자. 이때  $\min_{\|b\|=1} \text{Var}_{h \sim D}(b^\top h) = \lambda_{\min}(\Sigma_D) \leq \rho^2/d$ 이며, 등호는  $\Sigma_D = (\rho^2/d) \mathbf{I}_d$ 일 때  
247 그리고 그때에만 성립한다.

248 Theorem 1은 미니맥스 명제다. 같은 총분산 예산을 갖는 평균 0 섭동들 중에서, 등방 공분산은  
249 최소 탐색 방향을 유일하게 최대화한다. Lemma 1와 합치면 자연스러운 대안들이 한꺼번에  
250 배제된다. 고정된 프롬프트는  $\Sigma_D = 0$ 이라 탐색을 제공하지 못하고, PCA 정렬 노이즈는 비등  
251 방이라 직교 보완 공간을 덜 탐색하며, 어휘 토큰 추첨은 비등방인 동시에 의미적으로도 약속을  
252 한다. 같은 정리는 “경험적 임베딩 공분산을 그대로 맞추기”라는 일견 자연스러운 대안도 함께

배제한다.  $\mathbf{W}_E$ 의 행 공분산을 같은 스칼라 중심  $\mu_E \mathbf{1}_d$  주위에서  $\Sigma_E(\text{tr}(\Sigma_E) = d\sigma_E^2)$ 라 하면,  $\Sigma_E$ 가 비등방인 한  $\lambda_{\min}(\Sigma_E) < \sigma_E^2$ 이므로 임베딩 정합 분포는 등방 비교군보다 적어도 한 방향이 덜 탐색된다. 따라서 방향 기하를 버리고 스케일만 빌려 오는 선택은 단순화가 아니라 의도된 최적화다.

### 4.3 정확한 트랜스포머 수준 메커니즘

표준 트랜스포머에서 RSP의 효과는 무작위 토큰에 배정된 어텐션 질량으로 통제된다. self-attention 레이어  $\ell$ 에 실제 토큰  $n$ 개와 RSP 토큰  $k$ 개가 있고, 어텐션 가중치를  $\alpha_{ij}^{(\ell)}$ , 실제·RSP 토큰의 value 벡터를 각각  $\mathbf{v}_j^{(\ell)}, \mathbf{v}_{r_j}^{(\ell)}$ 라 하자. 무작위 토큰 어텐션 질량을

$$w_{r,i}^{(\ell)} = \sum_{j=1}^k \alpha_{i,n+j}^{(\ell)}$$

로 정의하면, 어텐션 출력은 정확히

$$\mathbf{x}_i^{(\ell+1)} = (1 - w_{r,i}^{(\ell)}) \tilde{\mathbf{x}}_i^{(\ell+1)} + \eta_i^{(\ell)}, \quad \tilde{\mathbf{x}}_i^{(\ell+1)} = \sum_{j=1}^n \frac{\alpha_{ij}^{(\ell)}}{1 - w_{r,i}^{(\ell)}} \mathbf{v}_j^{(\ell)}, \quad (2)$$

로 분해되며, 무작위 기여항  $\eta_i^{(\ell)} = \sum_{j=1}^k \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{r_j}^{(\ell)}$ 는  $\|\eta_i^{(\ell)}\| \leq w_{r,i}^{(\ell)} \max_j \|\mathbf{v}_{r_j}^{(\ell)}\|$ 를 만족한다. 따라서 동일한 스칼라  $w_{r,i}^{(\ell)}$ 가 실제 토큰 신호가 얼마나 밀려나는지와 무작위 기여가 얼마나 커질 수 있는지를 동시에 제어한다. Eq. (2)는 근사가 아니라 대수적 항등식이며, 결정적 norm 상계는 Appendix E.2에 기록되어 있다. (Hopfield 형 에너지 지형 위 반복 retrieval로 보는 보조적 해석은 Appendix E의 관련 절에서 다루지만, 본 절의 형식적 결과들은 그에 의존하지 않는다.)

희석 구조는 즉각적으로 따라온다. 실제 토큰과 무작위 토큰 사이의 사전 스케일 logit gap을  $\Delta_i^{(\ell)} := \min_{j \in [n]} \mathbf{q}_i^\top \mathbf{k}_j - \max_{j' \in [k]} \mathbf{q}_i^\top \mathbf{k}_{r_{j'}}$ 라 하면, scaled dot-product 어텐션은

$$w_{r,i}^{(\ell)} \leq \frac{k}{k + n \exp(\Delta_i^{(\ell)} / \sqrt{d})} \quad (3)$$

를 준다. 이 우변은  $k$ 와  $\Delta_i^{(\ell)}$ 를 고정한 채  $n$ 에 대해 엄격히 감소한다. 따라서 자기회귀적 캐시 성장 그 자체가 해당 gap과 양립 가능한 최대 무작위 토큰 어텐션을 단조롭게 줄인다. 이는 상계의 구조적 희석이며,  $\Delta_i^{(\ell)}$  자체가 상태에 따라 함께 변하기 때문에 모든 실현된  $w_{r,i}^{(\ell)}$ 가 단조 감소한다는 뜻은 아니다. 레이어 깊이에 따라  $\Delta_i^{(\ell)}$ 가 날카로워진다는 모델 측 가설은 Figure 4에서 실험적으로 확인된다. 완전한 트랜스포머 블록은 잔차 연결, 정규화, FFN을 추가하지만, 섭동 궤적과 비섭동 궤적을 동시에 포함하는 공 위에서 공통의 국소 Lipschitz 상수가 성립한다는 가정 [Xiong et al., 2020, Kim et al., 2021] 하에 Appendix E는 블록당 섭동 진폭이  $w_{r,i}^{(\ell)}$ 에 선형이며, 유한 깊이 누적 상계가 따라옴을 보인다. Eq. (3)와 결합하면, 섭동은 초반 블록에서 강하게 들어왔다가 증거가 쌓일수록 줄어드며, 추론 사슬 전체에 걸친 지속이 필요하지 않다.




Figure 4: Qwen2.5-Math-7B의 토큰별 어텐션 질량(suffix, MATH-500 500문제, 각 문제마다 독립적으로 샘플링한 RSP 사용). 레이어 축과 추론 위치 축은 다섯 개의 분위 구간으로 나누었다. (a)에서 RSP 토큰으로 향한 어텐션은 두 축 모두를 따라 감소하는 반면, (b)의 질문 토큰 어텐션은 비교적 균일하게 유지된다.



#### 278 4.4 온도 너머의 출력 지지 집합 확장

279 Temperature sampling은 순위 보존이다.  $p_i^{(\tau)} \propto p_i^{1/\tau}$ 는  $p_i > p_j \iff p_i^{(\tau)} > p_j^{(\tau)}$ 를 임의의  
 280  $\tau > 0$ 에 대해 함의하므로, 고정된 디코딩 상태에서 토큰 순위를 결코 바꾸지 못한다. RSP는  
 281 출력 softmax 이전에 작동하므로 순위를 바꿀 수 있다. 이 조건이 언제 성립하는지를 분리해  
 282 보기 위해 국소 affine surrogate  $z_i^{\text{lin}}(\bar{h}) := z_i + a_i^\top \bar{h}$ ,  $a_i := \nabla_{\bar{h}} z_i(0)$ 를 사용한다. 이 surrogate  
 283 는  $\bar{h} = 0$ 의 근방에서 유효하다(Appendix E). 본 절 전체에서  $\bar{h}$ 는 토큰별 surrogate로 다루며,  
 284 여러 토큰이 softmax 가중 어텐션을 통해 합쳐지는 비선형 누적은 Section 3.4에서 실험적으로  
 285 보고한다.

286 **명제 1** (확률적 순위화). 어떤 토큰 쌍  $(i, j)$ 에 대해  $a_i \neq a_j$ 이고 중심화된 프롬프트 분포가  $\mathbb{R}^d$   
 287 의 모든 비공집합 열린집합에 양의 확률을 부여한다면,  $0 < \Pr_{\bar{h}}(z_i^{\text{lin}}(\bar{h}) > z_j^{\text{lin}}(\bar{h})) < 1$ 이다.

288 **명제 2** (Top-K 진입). 디코딩 상태  $s_t$ 에서의 baseline top-K 토큰 집합을  $J_K(s_t)$ ,  $i \notin J_K(s_t)$ 인  
 289 토큰을 고정하자. 진입 영역

$$\mathcal{G}_{i,K} := \{\bar{h} \in \mathbb{R}^d : \#\{j \neq i : z_j^{\text{lin}}(\bar{h}) > z_i^{\text{lin}}(\bar{h})\} \leq K - 1\}$$

290 이 비공집합 열린집합을 포함하기 위한 충분조건은, 토큰  $i$ 가 다른 모든 토큰을 엄격한 마진으로  
 291 적어도  $K - 1$ 개를 제외한 채 앞서는 어떤  $\bar{h}_0$ 가 존재하는 것이다. affine surrogate는 연속이므로  
 292  $\bar{h}_0$  주위의 열린 공이  $\mathcal{G}_{i,K}$  안에 들어간다(Appendix E). 이 조건과 함께 중심화된 프롬프트 분포가  
 293 모든 비공집합 열린집합에 양의 확률을 부여한다면  $\Pr_{\bar{h}}(\bar{h} \in \mathcal{G}_{i,K}) > 0$ 이다.

294 Proposition 2은 의도적으로 조건부다. surrogate에서 baseline top-K에 의해 지배되는 토큰에  
 295 대해서는 어떤 주장도 하지 않는다. Temperature 스케일링은  $\mathcal{G}_{i,K}$ 에 도달조차 하지 못한다.  
 296 순위를 바꾸지 않기 때문이다. 따라서 surrogate 수준의 메커니즘은 확률 평탄화가 아니라 분기  
 297 열기다.

#### 298 4.5 독립 섭동에서 Pass@N으로

299  $\mu_i := \Pr_{\bar{h}}(\bar{h} \in \mathcal{G}_{i,K}) > 0$ 이라 두자.  $N$ 번의 독립적이고 새로운 RSP 추첨에서 적어도 한 번이  $i$   
 300 를 top-K에 입장시킬 확률은  $1 - (1 - \mu_i)^N \geq 1 - \exp(-N\mu_i)$ 이다. 즉 독립 재추첨은 작은 단발  
 301 분기 확률을 지수적으로 포화하는 커버리지로 전환한다. 이를 과제 정확도로 들어 올리려면  
 302 “열린 분기가 생산적인가”에 대한 과제 측 가정 하나가 필요하다.

303 **명제 3** (탐색이 다중 경로를 만나다). 문제  $x$ 를 고정하자. 결정적 baseline을 한 번 실행하고,  $N$   
 304 개의 독립적이고 새로운 RSP를 추첨하여 표본당 한 번씩 디코딩한다. 정답 궤적 집합  $\mathcal{T}^*(x)$ 가  
 305 비어 있지 않다고 하고, baseline 정답 지시자를  $p_{\text{base}}(x) \in \{0, 1\}$ 이라 하자. (M1) 각  $n$ 에 대해,  $n$   
 306 번째 RSP 실행이  $\mathcal{T}^*(x)$ 의 궤적을 만들 주변 확률이 적어도  $p_{\min}(x) > 0$ 이고, (M2)  $N$ 번의 RSP  
 307 실행이 상호 독립이라 가정하자. 그러면

$$\Pr(\text{Pass}@N \text{ on } x) \geq \max\{p_{\text{base}}(x), 1 - (1 - p_{\min}(x))^N\} \geq 1 - e^{-Np_{\min}(x)}.$$

308 가정 (M1)은 과제 측이며 메커니즘만으로는 유도되지 않는다. Section 3.4는 그 경험적 흔적을  
 309 보고한다. RSP가 만든 궤적은 향상과 후퇴를 모두 포함하며, 반복 샘플링 아래에서 명제가  
 310 예측하는 그대로 순이득이 누적된다.

### 311 5 결론

312 본 연구는 사전학습된 임베딩 행렬의 항별 평균과 분산에 맞춘 등방 가우시안 벡터를 학습 없이  
 313 주입하는 Random Soft Prompt(RSP)의 역할을 분석했다. RSP에서 무작위성은 임베딩 분포를  
 314 모사하는 장치가 아니라 rollout 사이의 독립적 섭동을 공급하는 성질이며, 탐색은 바로 이 독립  
 315 성을 요구한다. 실험적으로 RSP는 생성 초반의 엔트로피를 높이고 후반에는 다시 안정화시킨다  
 316 (Section 3). 이론적으로는 각 어텐션 레이어에서 RSP의 기여가 캐시 성장에 의해 구조적으로  
 317 희석되는 단일 스칼라 어텐션 질량으로 포착되며, 국소 affine 분석 아래에서 등방 재추첨이  
 318 temperature 스케일링으로는 결코 닿을 수 없는 방식으로 baseline에서 제외되었던 토큰을 유효  
 319 top-K 후보 집합 안으로 진입시킨다(Section 4). RSP는 순위를 바꾸는 섭동인 반면 temperature  
 320 는 순위를 보존하는 섭동이므로 두 방법은 상보적이며, 이는 GRPO [Shao et al., 2024]의 entropy  
 321 collapse를 DAPO [Yu et al., 2025], CE-GPPO [Su et al., 2026] 너머에서 샘플링 단계로 보완하는  
 322 가능성을 시사한다. 이 baseline과의 학습 시점 비교, 수학 추론을 넘어서 도메인 확장, RSP  
 323 길이와 주입 위치의 원리적 결정은 모두 향후 과제로 남는다.

## References

- Farhan Ahmed, Yuya Jeremy Ong, and Chad DeLuca. LogitScope: A Framework for Analyzing LLM Uncertainty through Information Metrics. In *ICLR Workshop*, 2026.
- Nora Belrose, Igor Ostrovsky, Lev McKinney, Zach Furman, Logan Smith, Danny Halawi, Stella Biderman, and Jacob Steinhardt. Eliciting Latent Predictions from Transformers with the Tuned Lens. *arXiv:2303.08112*, 2023.
- Jianlyu Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, and Zheng Liu. M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation. In *Findings of ACL*, 2024.
- Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, Christopher Hesse, and John Schulman. Training Verifiers to Solve Math Word Problems. *arXiv:2110.14168*, 2021.
- Jeremy M. Cohen, Elan Rosenfeld, and J. Zico Kolter. Certified Adversarial Robustness via Randomized Smoothing. In *ICML*, 2019.
- Timothée Darcet, Maxime Oquab, Julien Mairal, and Piotr Bojanowski. Vision Transformers Need Registers. In *ICLR*, 2024.
- Martin Ester, Hans-Peter Kriegel, Jörg Sander, and Xiaowei Xu. A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise. In *KDD*, 1996.
- Kawin Ethayarajh. How Contextual are Contextualized Word Representations? Comparing the Geometry of BERT, ELMo, and GPT-2 Embeddings. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2019.
- Meire Fortunato, Mohammad Gheshlaghi Azar, Bilal Piot, Jacob Menick, Ian Osband, Alex Graves, Vlad Mnih, Remi Munos, Demis Hassabis, Olivier Pietquin, Charles Blundell, and Shane Legg. Noisy Networks for Exploration. In *ICLR*, 2018.
- Mor Geva, Roei Schuster, Jonathan Berant, and Omer Levy. Transformer Feed-Forward Layers Are Key-Value Memories. In *EMNLP*, 2021.
- Sachin Goyal, Ziwei Ji, Ankit Singh Rawat, Aditya Krishna Menon, Sanjiv Kumar, and Vaishnavh Nagarajan. Think before You Speak: Training Language Models with Pause Tokens. In *ICLR*, 2024.
- Aaron Grattafiori, Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad Al-Dahle, Aiesha Letman, Akhil Mathur, Alan Schelten, Alex Vaughan, Amy Yang, Angela Fan, Anirudh Goyal, Anthony Hartshorn, Aobo Yang, Archi Mitra, Archie Sravankumar, Artem Korenev, Arthur Hinsvark, Arun Rao, Aston Zhang, Aurelien Rodriguez, Austen Gregerson, Ava Spataru, Baptiste Roziere, Bethany Biron, Binh Tang, Bobbie Chern, Charlotte Caucheteux, Chaya Nayak, Chloe Bi, Chris Marra, Chris McConnell, Christian Keller, Christophe Touret, Chunyang Wu, Corinne Wong, Cristian Canton Ferrer, Cyrus Nikolaidis, Damien Allonsius, Daniel Song, Danielle Pintz, Danny Livshits, Danny Wyatt, David Esiobu, Dhruv Choudhary, Dhruv Mahajan, Diego Garcia-Olano, Diego Perino, Dieuwke Hupkes, Egor Lakomkin, Ehab AlBadawy, Elina Lobanova, Emily Dinan, Eric Michael Smith, Filip Radenovic, Francisco Guzmán, Frank Zhang, Gabriel Synnaeve, Gabrielle Lee, Georgia Lewis Anderson, Govind Thattai, Graeme Nail, Gregoire Mialon, Guan Pang, Guillem Cucurell, Hailey Nguyen, Hannah Korevaar, Hu Xu, Hugo Touvron, Iliyan Zarov, Imanol Arrieta Ibarra, Isabel Kloumann, Ishan Misra, Ivan Evtimov, Jack Zhang, Jade Copet, Jaewon Lee, Jan Geffert, Jana Vranes, Jason Park, Jay Mahadeokar, Jeet Shah, Jelmer van der Linde, Jennifer Billock, Jenny Hong, Jenya Lee, Jeremy Fu, Jianfeng Chi, Jianyu Huang, Jiawen Liu, Jie Wang, Jiecao Yu, Joanna Bitton, Joe Spisak, Jongsoo Park, Joseph Rocca, Joshua Johnstun, Joshua Saxe, Junteng Jia, Kalyan Vasuden Alwala, Karthik Prasad, Kartikeya Upasani, Kate Plawiak, Ke Li, Kenneth Heafield, Kevin Stone, Khalid El-Arini, Krithika Iyer, Kshitiz Malik, Kuenley Chiu, Kunal Bhalla, Kushal Lakhotia, Lauren Rantala-Young, Laurens van der Maaten, Lawrence Chen, Liang Tan, Liz Jenkins, Louis Martin, Lovish Madaan, Lubo Malo, Lukas Blecher, Lukas Landzaat, Luke de Oliveira, Madeline Muzzi, Mahesh Pasupuleti, Mannat Singh, Manohar Paluri, Marcin Kardas, Maria Tsimpoukelli, Mathew Oldham, Mathieu

375 Rita, Maya Pavlova, Melanie Kambadur, Mike Lewis, Min Si, Mitesh Kumar Singh, Mona Has-  
 376 san, Naman Goyal, Narjes Torabi, Nikolay Bashlykov, Nikolay Bogoychev, Niladri Chatterji, Ning  
 377 Zhang, Olivier Duchenne, Onur Çelebi, Patrick Alrassy, Pengchuan Zhang, Pengwei Li, Petar Va-  
 378 sic, Peter Weng, Prajjwal Bhargava, Pratik Dubal, Praveen Krishnan, Punit Singh Koura, Puxin  
 379 Xu, Qing He, Qingxiao Dong, Ragavan Srinivasan, Raj Ganapathy, Ramon Calderer, Ricardo Sil-  
 380 veira Cabral, Robert Stojnic, Roberta Raileanu, Rohan Maheswari, Rohit Girdhar, Rohit Patel,  
 381 Romain Sauvestre, Ronnie Polidoro, Roshan Sumbaly, Ross Taylor, Ruan Silva, Rui Hou, Rui  
 382 Wang, Saghar Hosseini, Sahana Chennabasappa, Sanjay Singh, Sean Bell, Seohyun Sonia Kim,  
 383 Sergey Edunov, Shaoliang Nie, Sharan Narang, Sharath Raparthy, Sheng Shen, Shengye Wan,  
 384 Shruti Bhosale, Shun Zhang, Simon Vandenhende, Soumya Batra, Spencer Whitman, Sten Sootla,  
 385 Stephane Collet, Suchin Gururangan, Sydney Borodinsky, Tamar Herman, Tara Fowler, Tarek  
 386 Sheasha, Thomas Georgiou, Thomas Scialom, Tobias Speckbacher, Todor Mihaylov, Tong Xiao,  
 387 Ujjwal Karn, Vedanuj Goswami, Vibhor Gupta, Vignesh Ramanathan, Viktor Kerkez, Vincent  
 388 Gonguet, Virginie Do, Vish Vogeti, Vitor Albiero, Vladan Petrovic, Weiwei Chu, Wenhan Xiong,  
 389 Wenyin Fu, Whitney Meers, Xavier Martinet, Xiaodong Wang, Xiaofang Wang, Xiaoqing Ellen  
 390 Tan, Xide Xia, Xinfeng Xie, Xuchao Jia, Xuewei Wang, Yaelle Goldschlag, Yashesh Gaur, Yas-  
 391 mine Babaei, Yi Wen, Yiwen Song, Yuchen Zhang, Yue Li, Yuning Mao, Zacharie Delpierre  
 392 Coudert, Zheng Yan, Zhengxing Chen, Zoe Papakipos, Aaditya Singh, Aayushi Srivastava, Abha  
 393 Jain, Adam Kelsey, Adam Shajnfeld, Adithya Gangidi, Adolfo Victoria, Ahuva Goldstand, Ajay  
 394 Menon, Ajay Sharma, Alex Boesenber, Alexei Baevski, Allie Feinstein, Amanda Kallet, Amit  
 395 Sangani, Amos Teo, Anam Yunus, Andrei Lupu, Andres Alvarado, Andrew Caples, Andrew Gu,  
 396 Andrew Ho, Andrew Poulton, Andrew Ryan, Ankit Ramchandani, Annie Dong, Annie Franco,  
 397 Anuj Goyal, Aparajita Saraf, Arkabandhu Chowdhury, Ashley Gabriel, Ashwin Bharambe, As-  
 398 saf Eisenman, Azadeh Yazdan, Beau James, Ben Maurer, Benjamin Leonhardi, Bernie Huang,  
 399 Beth Loyd, Beto De Paola, Bhargavi Paranjape, Bing Liu, Bo Wu, Boyu Ni, Braden Hancock,  
 400 Bram Wasti, Brandon Spence, Brani Stojkovic, Brian Gamido, Britt Montalvo, Carl Parker, Carly  
 401 Burton, Catalina Mejia, Ce Liu, Changan Wang, Changkyu Kim, Chao Zhou, Chester Hu, Ching-  
 402 Hsiang Chu, Chris Cai, Chris Tindal, Christoph Feichtenhofer, Cynthia Gao, Damon Civin, Dana  
 403 Beaty, Daniel Kreymer, Daniel Li, David Adkins, David Xu, Davide Testuggine, Delia David,  
 404 Devi Parikh, Diana Liskovich, Didem Foss, Dingkan Wang, Duc Le, Dustin Holland, Edward  
 405 Dowling, Eissa Jamil, Elaine Montgomery, Eleonora Presani, Emily Hahn, Emily Wood, Eric-  
 406 Tuan Le, Erik Brinkman, Esteban Arcaute, Evan Dunbar, Evan Smothers, Fei Sun, Felix Kreuk,  
 407 Feng Tian, Filippus Kokkinos, Firat Ozgenel, Francesco Caggioni, Frank Kanayet, Frank Seide,  
 408 Gabriela Medina Florez, Gabriella Schwarz, Gada Badeer, Georgia Swee, Gil Halpern, Grant Her-  
 409 man, Grigory Sizov, Guangyi Zhang, Guna Lakshminarayanan, Hakan Inan, Hamid Shojanazeri,  
 410 Han Zou, Hannah Wang, Hanwen Zha, Haroun Habeeb, Harrison Rudolph, Helen Suk, Henry  
 411 Aspegren, Hunter Goldman, Hongyuan Zhan, Ibrahim Damlaj, Igor Molybog, Igor Tufanov, Il-  
 412 ias Leontiadis, Irina-Elena Veliche, Itai Gat, Jake Weissman, James Geboski, James Kohli, Janice  
 413 Lam, Japhet Asher, Jean-Baptiste Gaya, Jeff Marcus, Jeff Tang, Jennifer Chan, Jenny Zhen, Jeremy  
 414 Reizenstein, Jeremy Teboul, Jessica Zhong, Jian Jin, Jingyi Yang, Joe Cummings, Jon Carvill, Jon  
 415 Shepard, Jonathan McPhie, Jonathan Torres, Josh Ginsburg, Junjie Wang, Kai Wu, Kam Hou U,  
 416 Karan Saxena, Kartikay Khandelwal, Katayoun Zand, Kathy Matosich, Kaushik Veeraraghavan,  
 417 Kelly Michelen, Keqian Li, Kiran Jagadeesh, Kun Huang, Kunal Chawla, Kyle Huang, Lailin  
 418 Chen, Lakshya Garg, Lavender A, Leandro Silva, Lee Bell, Lei Zhang, Liangpeng Guo, Licheng  
 419 Yu, Liron Moshkovich, Luca Wehrstedt, Madian Khabsa, Manav Avalani, Manish Bhatt, Martynas  
 420 Mankus, Matan Hasson, Matthew Lennie, Matthias Reso, Maxim Groshev, Maxim Naumov, Maya  
 421 Lathi, Meghan Keneally, Miao Liu, Michael L. Seltzer, Michal Valko, Michelle Restrepo, Mihir  
 422 Patel, Mik Vyatskov, Mikayel Samvelyan, Mike Clark, Mike Macey, Mike Wang, Miquel Jubert  
 423 Hermoso, Mo Metanat, Mohammad Rastegari, Munish Bansal, Nandhini Santhanam, Natascha  
 424 Parks, Natasha White, Navyata Bawa, Nayan Singhal, Nick Egebo, Nicolas Usunier, Nikhil Mehta,  
 425 Nikolay Pavlovich Laptev, Ning Dong, Norman Cheng, Oleg Chernoguz, Olivia Hart, Omkar  
 426 Salpekar, Ozlem Kalinli, Parkin Kent, Parth Parekh, Paul Saab, Pavan Balaji, Pedro Rittner, Philip  
 427 Bontrager, Pierre Roux, Piotr Dollar, Polina Zvyagina, Prashant Ratanchandani, Pritish Yuvraj,  
 428 Qian Liang, Rachad Alao, Rachel Rodriguez, Rafi Ayub, Raghotham Murthy, Raghu Nayani,  
 429 Rahul Mitra, Rangaprabhu Parthasarathy, Raymond Li, Rebekkah Hogan, Robin Battey, Rocky  
 430 Wang, Russ Howes, Ruty Rinott, Sachin Mehta, Sachin Siby, Sai Jayesh Bondu, Samyak Datta,  
 431 Sara Chugh, Sara Hunt, Sargun Dhillon, Sasha Sidorov, Satadru Pan, Saurabh Mahajan, Saurabh  
 432 Verma, Seiji Yamamoto, Sharadh Ramaswamy, Shaun Lindsay, Shaun Lindsay, Sheng Feng,  
 433 Shenghao Lin, Shengxin Cindy Zha, Shishir Patil, Shiva Shankar, Shuqiang Zhang, Shuqiang

434 Zhang, Sinong Wang, Sneha Agarwal, Soji Sajuyigbe, Soumith Chintala, Stephanie Max, Stephen  
435 Chen, Steve Kehoe, Steve Satterfield, Sudarshan Govindaprasad, Sumit Gupta, Summer Deng,  
436 Sungmin Cho, Sunny Virk, Suraj Subramanian, Sy Choudhury, Sydney Goldman, Tal Remez,  
437 Tamar Glaser, Tamara Best, Thilo Koehler, Thomas Robinson, Tianhe Li, Tianjun Zhang, Tim  
438 Matthews, Timothy Chou, Tzook Shaked, Varun Vontimitta, Victoria Ajayi, Victoria Montanez,  
439 Vijai Mohan, Vinay Satish Kumar, Vishal Mangla, Vlad Ionescu, Vlad Poenaru, Vlad Tiberiu  
440 Mihailescu, Vladimir Ivanov, Wei Li, Wenchen Wang, Wenwen Jiang, Wes Bouaziz, Will Con-  
441 stable, Xiaocheng Tang, Xiaojian Wu, Xiaolan Wang, Xilun Wu, Xinbo Gao, Yaniv Kleinman,  
442 Yanjun Chen, Ye Hu, Ye Jia, Ye Qi, Yenda Li, Yilin Zhang, Ying Zhang, Yossi Adi, Youngjin  
443 Nam, Yu Wang, Yu Zhao, Yuchen Hao, Yundi Qian, Yunlu Li, Yuzi He, Zach Rait, Zachary De-  
444 Vito, Zef Rosnbrick, Zhaoduo Wen, Zhenyu Yang, Zhiwei Zhao, and Zhiyu Ma. The Llama 3  
445 Herd of Models. *arXiv:2407.21783*, 2024.

446 Shibo Hao, Sainbayar Sukhbaatar, DiJia Su, Xian Li, Zhiting Hu, Jason Weston, and Yuandong Tian.  
447 Training Large Language Models to Reason in a Continuous Latent Space. In *ICLR*, 2025.

448 Neil Houlsby, Andrei Giurgiu, Stanislaw Jastrzebski, Bruna Morrone, Quentin de Laroussilhe, An-  
449 drea Gesmundo, Mona Attariyan, and Sylvain Gelly. Parameter-Efficient Transfer Learning for  
450 NLP. In *ICML*, 2019.

451 Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang,  
452 and Weizhu Chen. LoRA: Low-Rank Adaptation of Large Language Models. In *ICLR*, 2022.

453 Neel Jain, Ping-yeh Chiang, Yuxin Wen, John Kirchenbauer, Hong-Min Chu, Gowthami Somepalli,  
454 Brian R. Bartoldson, Bhavya Kailkhura, Avi Schwarzschild, Aniruddha Saha, Micah Goldblum,  
455 Jonas Geiping, and Tom Goldstein. NEFTune: Noisy Embeddings Improve Instruction Finetuning.  
456 In *ICLR*, 2024.

457 Xinyue Kang, Diwei Shi, and Li Chen. Model Whisper: Steering Vectors Unlock Large Language  
458 Models’ Potential in Test-time. In *AAAI*, 2026.

459 Hyunjik Kim, George Papamakarios, and Andriy Mnih. The Lipschitz Constant of Self-Attention.  
460 *Proceedings of the 38th International Conference on Machine Learning (ICML)*, 2021.

461 Brian Lester, Rami Al-Rfou, and Noah Constant. The Power of Scale for Parameter-Efficient Prompt  
462 Tuning. In *EMNLP*, 2021.

463 Xiang Lisa Li and Percy Liang. Prefix-Tuning: Optimizing Continuous Prompts for Generation. In  
464 *ACL-IJCNLP*, 2021.

465 Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike,  
466 John Schulman, Ilya Sutskever, and Karl Cobbe. Let’s Verify Step by Step. In *ICLR*, 2024.

467 Xiao Liu, Yanan Zheng, Zhengxiao Du, Ming Ding, Yujie Qian, Zhilin Yang, and Jie Tang. GPT  
468 Understands, Too. *AI Open*, 5:208–215, 2024.

469 Aman Madaan and Amir Yazdanbakhsh. Text and Patterns: For Effective Chain of Thought, It Takes  
470 Two to Tango. *arXiv:2209.07686*, 2022.

471 Jiaqi Mu and Pramod Viswanath. All-but-the-Top: Simple and effective postprocessing for word  
472 representations. In *International Conference on Learning Representations (ICLR)*, 2018.

473 Alexander Robey, Eric Wong, Hamed Hassani, and George J. Pappas. SmoothLLM: Defending Large  
474 Language Models Against Jailbreaking Attacks. *Transactions on Machine Learning Research*,  
475 2025.

476 Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang,  
477 Mingchuan Zhang, Y.K. Li, Y. Wu, and Daya Guo. DeepSeekMath: Pushing the Limits of Math-  
478 ematical Reasoning in Open Language Models. *arXiv:2402.03300*, 2024.

479 Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov.  
480 Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *Journal of Machine Learn-  
481 ing Research*, 15:1929–1958, 2014.

482 Zhenpeng Su, Leiyu Pan, Minxuan Lv, Yuntao Li, Wenping Hu, Fuzheng Zhang, Kun Gai, and  
483 Guorui Zhou. CE-GPPO: Coordinating Entropy via Gradient-Preserving Clipping Policy Opti-  
484 mization in Reinforcement Learning. In *ACL*, 2026.

485 Shenzhi Wang, Le Yu, Chang Gao, Chujie Zheng, Shixuan Liu, Rui Lu, Kai Dang, Xionghui Chen,  
486 Jianxin Yang, Zhenru Zhang, Yuqiong Liu, An Yang, Andrew Zhao, Yang Yue, Shiji Song, Bowen  
487 Yu, Gao Huang, and Junyang Lin. Beyond the 80/20 Rule: High-Entropy Minority Tokens Drive  
488 Effective Reinforcement Learning for LLM Reasoning. In *NeurIPS*, 2025.

489 Ruibin Xiong, Yunchang Yang, Di He, Kai Zheng, Shuxin Zheng, Chen Xing, Huishuai Zhang,  
490 Yanyan Lan, Liwei Wang, and Tie-Yan Liu. On Layer Normalization in the Transformer Architec-  
491 ture. In *International Conference on Machine Learning (ICML)*, 2020.

492 Yige Xu, Xu Guo, Zhiwei Zeng, and Chunyan Miao. SoftCoT: Soft Chain-of-Thought for Efficient  
493 Reasoning with LLMs. In *ACL*, 2025.

494 An Yang, Beichen Zhang, Binyuan Hui, Bofei Gao, Bowen Yu, Chengpeng Li, Dayiheng Liu,  
495 Jianhong Tu, Jingren Zhou, Junyang Lin, Keming Lu, Mingfeng Xue, Runji Lin, Tianyu Liu,  
496 Xingzhang Ren, and Zhenru Zhang. Qwen2.5-Math Technical Report: Toward Mathematical  
497 Expert Model via Self-Improvement. *arXiv:2409.12122*, 2024.

498 Wengao Ye, Yan Liang, and Lianlei Shan. Thinking on the Fly: Test-Time Reasoning Enhancement  
499 via Latent Thought Policy Optimization. In *ICLR*, 2026.

500 Qiying Yu, Zheng Zhang, Ruofei Zhu, Yufeng Yuan, Xiaochen Zuo, Yu Yue, Weinan Dai, Tiantian  
501 Fan, Gaohong Liu, Juncal Liu, Lingjun Liu, Xin Liu, Haibin Lin, Zhiqi Lin, Bole Ma, Guangming  
502 Sheng, Yuxuan Tong, Chi Zhang, Mofan Zhang, Ru Zhang, Wang Zhang, Hang Zhu, Jinhua Zhu,  
503 Jiaze Chen, Jiangjie Chen, Chengyi Wang, Hongli Yu, Yuxuan Song, Xiangpeng Wei, Hao Zhou,  
504 Jingjing Liu, Wei-Ying Ma, Ya-Qin Zhang, Lin Yan, Yonghui Wu, and Mingxuan Wang. DAPO:  
505 An Open-Source LLM Reinforcement Learning System at Scale. In *NeurIPS*, 2025.

506 Guibin Zhang, Muxin Fu, and Shuicheng Yan. MemGen: Weaving Generative Latent Memory for  
507 Self-Evolving Agents. In *ICLR*, 2026.

## 508 A 실험 설정과 전체 정확도 분석

509 Table 6은 본문 Table 1에서 위치별 최고 성능만 요약해 제시한 결과를, Prefix, Infix, Suffix 별 전체  
510 정확도로 다시 펼쳐 보인다. Table 7는 각 모델-벤치마크 조합에서 사용한 RSP 토큰 수  $L$ 을 정리  
511 한 것으로, 후보 집합 {10, 15, 20}에서 선택했다. 모든 실험은 단일 NVIDIA A6000 40GB GPU  
512 에서 greedy decoding으로 수행했으며, 최대 생성 길이는 MATH-500과 GSM8K에서 3,072 토큰,  
513 AIME24에서 4,096 토큰으로 고정했다. 배치 크기는 모델별로 고정했다(LLaMA-3.1-8B-Instruct  
514 와 Qwen2.5-Math-7B 계열은 16, Qwen2.5-Math-1.5B 계열은 32).

Table 6: 모델 설정, 주입 위치, 벤치마크별 정확도(%). 괄호 안 값은 baseline 대비 변화량이다. 굵게는 최고 성능, 밑줄은 각 모델-벤치마크 조합에서 두 번째 성능을 뜻한다.

| Model                                         | Mode     | MATH-500             | GSM8K                | AIME24               |
|-----------------------------------------------|----------|----------------------|----------------------|----------------------|
| <i>Instruct Models</i>                        |          |                      |                      |                      |
| LLaMA-3.1-8B-Instruct                         | Baseline | <b>52.20</b>         | 85.75                | <u>6.67</u>          |
|                                               | Prefix   | 45.00 (−7.2)         | 76.35 (−9.4)         | 3.33 (−3.3)          |
|                                               | Infix    | <u>49.40</u> (−2.8)  | 85.97 (+0.2)         | <b>10.00</b> (+3.3)  |
|                                               | Suffix   | <u>49.40</u> (−2.8)  | <b>86.73</b> (+1.0)  | <b>10.00</b> (+3.3)  |
| Qwen2.5-Math-7B-Instruct                      | Baseline | 83.20                | 95.45                | <u>13.33</u>         |
|                                               | Prefix   | 81.40 (−1.8)         | 94.92 (−0.5)         | <u>13.33</u> (+0.0)  |
|                                               | Infix    | <b>84.20</b> (+1.0)  | <u>95.60</u> (+0.2)  | <b>16.67</b> (+3.3)  |
|                                               | Suffix   | <u>83.40</u> (+0.2)  | <b>95.68</b> (+0.2)  | <b>16.67</b> (+3.3)  |
| Qwen2.5-Math-1.5B-Instruct                    | Baseline | 73.00                | 85.29                | 10.00                |
|                                               | Prefix   | 74.80 (+1.8)         | 85.29 (+0.0)         | <u>13.33</u> (+3.3)  |
|                                               | Infix    | <b>75.20</b> (+2.2)  | <b>85.75</b> (+0.5)  | <u>6.67</u> (−3.3)   |
|                                               | Suffix   | 74.20 (+1.2)         | 84.69 (−0.6)         | <b>20.00</b> (+10.0) |
| <i>Base Models (Raw Text)</i>                 |          |                      |                      |                      |
| Qwen2.5-Math-7B                               | Baseline | <b>72.20</b>         | <u>84.15</u>         | 6.67                 |
|                                               | Prefix   | <u>71.60</u> (−0.6)  | <b>84.31</b> (+0.2)  | <b>16.67</b> (+10.0) |
|                                               | Infix    | 63.20 (−9.0)         | 64.29 (−19.9)        | <b>16.67</b> (+10.0) |
|                                               | Suffix   | 55.60 (−16.6)        | 54.13 (−30.0)        | <u>13.33</u> (+6.7)  |
| Qwen2.5-Math-1.5B                             | Baseline | <u>61.40</u>         | <b>77.86</b>         | <b>16.67</b>         |
|                                               | Prefix   | <b>64.40</b> (+3.0)  | <u>74.30</u> (−3.6)  | <u>10.00</u> (−6.7)  |
|                                               | Infix    | 63.20 (+1.8)         | 73.92 (−3.9)         | <u>10.00</u> (−6.7)  |
|                                               | Suffix   | 54.60 (−6.8)         | 58.61 (−19.3)        | 3.33 (−13.3)         |
| <i>Base Models + ChatML (Format Mismatch)</i> |          |                      |                      |                      |
| Qwen2.5-Math-7B                               | Baseline | 52.20                | 58.30                | <b>23.33</b>         |
|                                               | Prefix   | 59.20 (+7.0)         | 56.41 (−1.9)         | <u>3.33</u> (−20.0)  |
|                                               | Infix    | <u>62.00</u> (+9.8)  | 69.07 (+10.8)        | <b>23.33</b> (+0.0)  |
|                                               | Suffix   | <b>70.40</b> (+18.2) | <b>75.97</b> (+17.7) | <b>23.33</b> (+0.0)  |
| Qwen2.5-Math-1.5B                             | Baseline | 34.40                | 37.45                | <u>13.33</u>         |
|                                               | Prefix   | <b>63.40</b> (+29.0) | <b>67.02</b> (+29.6) | <b>20.00</b> (+6.7)  |
|                                               | Infix    | 39.20 (+4.8)         | 50.42 (+13.0)        | 6.67 (−6.7)          |
|                                               | Suffix   | <u>51.00</u> (+16.6) | <u>50.64</u> (+13.2) | <u>13.33</u> (+0.0)  |

Table 7: 각 모델과 벤치마크에 사용한 RSP 토큰 수 ( $L$ ).

| Model                      | MATH-500 | GSM8K | AIME24 |
|----------------------------|----------|-------|--------|
| LLaMA-3.1-8B-Instruct      | 15       | 20    | 15     |
| Qwen2.5-Math-7B-Instruct   | 20       | 20    | 20     |
| Qwen2.5-Math-1.5B-Instruct | 20       | 10    | 20     |
| Qwen2.5-Math-7B            | 10       | 10    | 20     |
| Qwen2.5-Math-1.5B          | 10       | 10    | 20     |
| Qwen2.5-Math-1.5B (ChatML) | 20       | 20    | 10     |
| Qwen2.5-Math-7B (ChatML)   | 20       | 20    | 20     |

### 515 A.1 RSP 주입 위치와 프롬프트 템플릿

516 아래에는 모든 모델 유형에서 주입 위치별 프롬프트 구조를 정리했다. **파란색 텍스트**는 RSP  
517 임베딩, **보라색 텍스트**는 특수 토큰을 뜻한다.



### 518 A.1.1 Prefix

519 Prefix 주입에서는 RSP 임베딩을 프롬프트 임베딩 앞에 연결한다. 텍스트 자체는 수정하지  
520 않는다.

#### 521 ChatML (Qwen Instruct / Base + ChatML).

```
[Random Embeddings (L tokens)]
<|im_start|>system
Please reason step by step, and put your final answer within \boxed{<|im_end|>
<|im_start|>user
{question}<|im_end|>
<|im_start|>assistant
```

#### 523 LLaMA Chat Template.

```
[Random Embeddings (L tokens)]
<|begin_of_text|>
<|start_header_id|>system<|end_header_id|>
Cutting Knowledge Date: December 2023
Today Date: 26 Jul 2024
Please reason step by step, and put your final answer within \boxed{<|eot_id|>
<|start_header_id|>user<|end_header_id|>
{question}<|eot_id|>
<|start_header_id|>assistant<|end_header_id|>
```

#### 525 Raw Text (Qwen Base).

```
[Random Embeddings (L tokens)]
{question}
Please reason step by step, and put your final answer within \boxed{<|im_end|>
```

### 527 A.1.2 Infix

528 Infix 주입에서는 설명 문구와 특수 토큰을 프롬프트 내부에 넣은 뒤, 그 특수 토큰 위치를 임베딩  
529 수준에서 RSP로 교체한다.

#### 530 ChatML (Qwen Instruct / Base + ChatML).

```
<|im_start|>system
Please reason step by step, and put your final answer within \boxed{<|im_end|>
<|im_start|>user
{question}

There are {L} special tokens that contain compressed latent reasoning
information that might be useful for your reasoning. If these tokens are
useful for your case, you can use them as reference. If these tokens are
not useful for your case, you can ignore them and focus back to solving the
problem.

Here are the {L} special tokens: <special_token_1>...<special_token_L>
<|im_end|>
<|im_start|>assistant
```

#### 532 LLaMA Chat Template.

```
<|begin_of_text|>
<|start_header_id|>system<|end_header_id|>
Cutting Knowledge Date: December 2023
Today Date: 26 Jul 2024
Please reason step by step, and put your final answer within \boxed{<|im_end|>
```

```

eot_id|>
<|start_header_id|>user<|end_header_id|>
{question}

There are {L} special tokens that contain compressed latent reasoning
information that might be useful for your reasoning. If these tokens are
useful for your case, you can use them as reference. If these tokens are
not useful for your case, you can ignore them and focus back to solving the
problem.

Here are the {L} special tokens:
<reserved_special_token_0>...
<reserved_special_token_L>
<|eot_id|>
<|start_header_id|>assistant<|end_header_id|>

```

534

### 535 Raw Text (Qwen Base).

```

{question}

There are {L} special tokens that contain compressed latent reasoning
information that might be useful for your reasoning. If these tokens are
useful for your case, you can use them as reference. If these tokens are
not useful for your case, you can ignore them and focus back to solving the
problem.

Here are the {L} special tokens: <special_token_1>...<special_token_L>
Please reason step by step, and put your final answer within \boxed{ }.

```

536

### 537 A.1.3 Suffix

538 채팅 템플릿 모델에서는 end-of-turn 토큰 바로 앞에 RSP 임베딩을 넣고, raw text 모델에서는  
539 프롬프트 마지막에 RSP 임베딩을 이어 붙인다.

### 540 ChatML (Qwen Instruct / Base + ChatML).

```

<|im_start|>system
Please reason step by step, and put your final answer within \boxed{ }.<|
im_end|>
<|im_start|>user
{question}[Random Embeddings (L tokens)]<|im_end|>
<|im_start|>assistant

```

541

### 542 LLaMA Chat Template.

```

<|begin_of_text|>
<|start_header_id|>system<|end_header_id|>
Cutting Knowledge Date: December 2023
Today Date: 26 Jul 2024
Please reason step by step, and put your final answer within \boxed{ }.<|
eot_id|>
<|start_header_id|>user<|end_header_id|>
{question}[Random Embeddings (L tokens)]<|eot_id|>
<|start_header_id|>assistant<|end_header_id|>

```

543

### 544 Raw Text (Qwen Base).

```

{question}
Please reason step by step, and put your final answer within \boxed{ }. [Random
Embeddings (L tokens)]

```

545

## 546 A.2 정답 추출과 채점

547 최종 정답은 fallback 체인을 통해 모델 출력에서 추출한다. 각 단계는 순서대로 시도하며, 추출에  
548 실패하면 다음 단계로 넘어간다.

### 정답 추출 fallback 체인

1. "final answer is \$...\$. I hope" 패턴 (Minerva 형식)
2. `\boxed{...}`: 마지막 비어 있지 않은 box를 사용하고, 빈 `\boxed{}`는 건너뛰
3. "the answer is" 뒤 텍스트
4. "final answer is" 뒤 텍스트
5. 출력 마지막 숫자(regex fallback)

549

550 추출된 정답은 `$`, `\left`, `\right`, 단위 문자열을 제거해 정규화한다. 채점은 sym-  
551 bolic equivalence checking으로 수행하며, 정확한 문자열 일치, 수치 비교(`math.isclose`,  
552 `rel_tol=1e-4`), SymPy symbolic simplification을 차례로 적용한다.

### 553 A.3 재현한 선행연구의 하이퍼파라미터

554 모든 선행 방법은 Qwen2.5-Math-1.5B-Instruct와 Qwen2.5-Math-7B-Instruct에서 재현했으며,  
555 greedy decoding(`temperature = 0`)과 통일된 answer extraction pipeline으로 평가했다.

556 **TTSV.** Prefix 길이는 20이며, AdamW optimizer로 20 epoch 동안 학습했다. 배치 크기는 2,  
557 gradient accumulation은 8 step, 스케줄은 선형 learning rate schedule을 사용했다. Learning rate  
558 는 Qwen-1.5B에  $1e-3$ , Qwen-7B에  $1e-5$ 를 사용했다.

559 **LTPO.** Table 8는 벤치마크별 하이퍼파라미터를 정리한 것이다.

Table 8: LTPO 하이퍼파라미터.

| Parameter   | GSM8K  | MATH-500 | AIME24 |
|-------------|--------|----------|--------|
| tokens      | 8      | 8        | 8      |
| steps       | 20     | 20       | 20     |
| top_k       | 10     | 10       | 10     |
| sigma       | 20     | 20       | 5      |
| sigma_decay | 0.95   | 0.95     | 0.95   |
| lr          | $1e-2$ | $5e-3$   | $5e-2$ |

560 **SoftCoT.** Projection module은 10 epoch 동안 학습했다. Thought token 수는 학습 시 32, 평가 시  
561 4다. 배치 크기는 GSM8K에서 4, MATH에서는 1이며 gradient accumulation 4를 사용했다. 작은  
562 모델(assistant)은 두 설정 모두 Qwen2.5-Math-1.5B-Instruct이고, 큰 모델은 Qwen2.5-Math-1.5B-  
563 Instruct(`learning rate 2e-5`) 또는 Qwen2.5-Math-7B-Instruct(`learning rate 5e-6`)이다. MATH-500  
564 과 AIME24 평가는 GSM8K에서 학습한 projection module을 사용했는데, MATH에서 학습한  
565 버전보다 더 높은 정확도를 보였기 때문이다.

### 566 A.4 전체 엔트로피 곡선

567 Figure 5는 entropy, top-1 probability, varentropy의 전체 정규화 생성 궤적(0-100%)을 보여준다.  
568 모든 방법은 생성 초반 단계를 지나면 비슷한 수준으로 수렴하며, 이는 RSP가 유도하는 분포  
569 변화가 초기 추론 단계에 국소화되어 있음을 다시 확인해 준다.




Figure 5: 전체 정규화 생성 궤적(0-100%)에서의 평균 entropy(위), top-1 probability(가운데), varentropy(아래). MATH-500 전체 평균이며, 음영은  $\pm 1$  SEM을 뜻한다. 실선은 RSP 변형과 baseline, 점선은 기존 soft prompt 방법이다. 모든 방법은 초반 단계를 지나면 수렴한다.

## 570 B 의미적 다양성에 대한 추가 분석

571 이 부록은 Section 3.4에서 보고한 의미적 다양성 결과를 보충한다. 더 넓은 문제 집합에 대해  
572 문제별 t-SNE 도표를 함께 제시한다.



Figure 6: 평가한 64개 MATH-500 문제 중 48개에 대한 BGE-M3 임베딩의 t-SNE 투영(6×8 격자). 각 subplot은 Qwen2.5-Math-1.5B-Instruct에서  $\tau = 1.0$ 으로 생성한 baseline 300개(빨강)와 RSP suffix 300개(파랑)를 보여준다. 채워진 표식은 정답, 빈 표식은 오답이며, 제목은 subject/problem\_id를 뜻한다. 대부분의 문제에서 RSP 궤적은 여러 개의 분리된 영역으로 퍼지는 반면, baseline 샘플은 하나의 지배적 클러스터에 더 집중된다.

## 573 C 토큰 수준 분포 지표

574 이 부록은 Section 3.4의 토큰 수준 분석에 사용한 세 지표를 형식적으로 정의한다.  $P_{\text{base}}$  는  
575  $\tau = 1.0$ 에서의 baseline 다음 토큰 분포,  $P_{\text{target}}$ 은 비교 대상 분포(예:  $\tau = 2.0$ 의 baseline, 또는  
576  $\tau = 1.0$ 의 RSP)라 하자. 모든 지표는 첫 생성 단계에서 저장한 logits로부터 해석적으로 계산  
577 한다.

578 **Spearman 순위 상관.** Spearman의  $\rho$ 는 두 분포의 토큰 순위 사이 Pearson 상관계수다.

$$\rho = \text{Pearson}(\text{rank}(P_{\text{target}}), \text{rank}(P_{\text{base}})). \quad (4)$$

579 Temperature scaling  $P^{(\tau)} \propto P^{1/\tau}$ 는 엄격한 단조 변환이므로, 어떤  $\tau > 0$ 에서도 토큰 순서를  
580 정확히 보존한다. 따라서  $\rho = 1$ 은 수학적 항등식이다. 그러므로  $\rho < 1$ 은 temperature scaling  
581 만으로는 만들 수 없는 순위 재조작이 일어났음을 뜻한다.

582 **Top- $K$  밖의 질량.**  $\text{TopK}(P_{\text{base}})$ 를  $P_{\text{base}}$ 에서 확률이 가장 높은  $K$ 개 토큰의 집합이라 하자. 비  
583 교 대상 분포가 이 집합 밖에 두는 확률 질량은

$$\text{MassOutside}_K = 1 - \sum_{t \in \text{TopK}(P_{\text{base}})} P_{\text{target}}(t). \quad (5)$$

584 이 지표는 지지 집합 확장을 직접 측정한다. 즉 baseline의 선호 집합에 없던 토큰에 비교 대상이  
585 얼마나 많은 확률을 배정하는지를 본다. 본문에 보고한 값은  $K = 10$ 을 사용했다.

586 **Jensen-Shannon divergence.** Kullback-Leibler divergence의 대칭적이고 bounded된 형태는 다  
587 음과 같다.

$$\text{JS}(P, Q) = \frac{1}{2} \text{KL}(P \parallel M) + \frac{1}{2} \text{KL}(Q \parallel M), \quad M = \frac{1}{2}(P + Q). \quad (6)$$

588 로그는 밑이 2이므로  $\text{JS} \in [0, 1]$ 이다. 저장한 top-100 바깥의 토큰에는 softmax 전에 sentinel  
589  $\text{logit}(-10^9)$ 을 넣었는데, 본 설정에서는 top-5가 이미 확률 질량의 99.9% 이상을 덮기 때문에 이  
590 근사는 무시 가능하다.

## 591 D 무작위 프롬프트는 왜 의미적으로 중립적이고 방향적으로 포괄적인가

592 이 부록은 Section 4.2에서 사용한 주장을 형식화한다. 핵심은 무작위 프롬프트가 유용한 잠재  
593 의미를 담고 있다는 것이 아니다. 더 약하고 정확한 주장은, 중심화한 뒤에는 어떤 미리 정한  
594 의미 방향도 체계적으로 편들지 않으면서도, 고정된 분산 예산 아래 모든 방향을 덮을 수 있다는  
595 것이다. 이는 언어학적 의미가 완전히 사라진다는 주장이 아니라, 섭동 방향의 기하학적 성질에  
596 관한 명제다.

### 597 D.1 의미적 중립성

598  $\bar{h} \sim \mathcal{N}(0, \sigma^2 \mathbf{I}_d)$ 라 하고,  $\bar{h} \neq 0$  일 때  $\hat{h} := \bar{h}/\|\bar{h}\|$ 라 하자. 또한  $u_1, \dots, u_M \in \mathbb{S}^{d-1}$ 를 의미  
599 anchor 방향을 나타내는 임의의 고정 단위벡터라 하자.

600 **보조정리 2** (의미적 중립성). 보편 상수  $C$ 가 존재하여, 모든  $\delta \in (0, 1)$ 에 대해

$$\Pr \left[ \max_{r \in [M]} |\hat{h}^\top u_r| \leq C \sqrt{\frac{\log(M/\delta)}{d}} \right] \geq 1 - \delta.$$

601 즉 등방성 가우시안 프롬프트의 정규화된 방향은, 고정된 유한 개의 의미 anchor 전체에 대해  
602 높은 확률로 거의 직교한다.

603 *Proof.* 각 고정  $u_r$ 에 대해 회전 불변성으로부터  $u_r^\top \bar{h} \sim \mathcal{N}(0, \sigma^2)$ 가 성립하므로,

$$\Pr(|u_r^\top \bar{h}| \geq t) \leq 2 \exp\left(-\frac{t^2}{2\sigma^2}\right).$$

604  $r \in [M]$  전체에 대해 union bound를 적용하면

$$\Pr \left[ \max_{r \in [M]} |u_r^\top \bar{h}| \geq t \right] \leq 2M \exp\left(-\frac{t^2}{2\sigma^2}\right).$$

605 한편 표준 chi-square concentration으로부터 보편 상수  $c > 0$ 가 존재하여

$$\Pr \left[ \|\bar{h}\| \leq \frac{\sigma\sqrt{d}}{2} \right] \leq \exp(-cd)$$

606 가 성립한다. 사건  $\|\bar{h}\| \geq \sigma\sqrt{d}/2$  위에서는

$$|\hat{h}^\top u_r| = \frac{|u_r^\top \bar{h}|}{\|\bar{h}\|} \leq \frac{2|u_r^\top \bar{h}|}{\sigma\sqrt{d}}.$$

607 이제

$$t = C' \sigma \sqrt{\log(M/\delta)}$$

608 로 두고  $C'$ 를 충분히 큰 상수로 잡으면, 두 bound를 결합해

$$\max_{r \in [M]} |\hat{h}^\top u_r| \leq C \sqrt{\frac{\log(M/\delta)}{d}}$$

609 가 적어도  $1 - \delta$  확률로 성립한다. □

610 토큰 임베딩과의 대비는 즉각적이다.  $e_s \neq 0$ 를 고정된 토큰 임베딩이라 하고  $\hat{e}_s := e_s/\|e_s\|$ 라  
611 하자. 이때 anchor 방향을  $u = \hat{e}_s$ 로 잡으면

$$|\hat{e}_s^\top u| = 1.$$

612 즉 토큰 프롬프트는 적어도 하나의 의미 방향과 최대 정렬을 이루지만, 등방성 무작위 프롬프트  
613 는 어떤 고정된 유한 집합의 의미 방향에도 거의 직교한다. 우리가 말하는 “의미적 비개입성”은  
614 바로 이 뜻이다. 토큰은 의미적 commitment를 주입하는 반면, 무작위 프롬프트는 의미적으로  
615 특정 방향에 묶이지 않은 섭동으로 기능한다.



## 616 D.2 미니맥스 방향 커버리지

617 두 번째 요구 사항은 방향 커버리지다. 평균이 0인 섭동 분포  $D$ 를  $\mathbb{R}^d$  위에 두고, 공분산  
 618 을  $\Sigma_D$ , 분산 예산을  $\text{tr}(\Sigma_D) \leq \rho^2$ 라 하자. 단위벡터  $b$ 에 대해  $b$  방향의 1차 섭동 에너지는  
 619  $\text{Var}_{h \sim D}(b^\top h) = b^\top \Sigma_D b$ 로 주어진다. 이것이 본문에서 사용한 local linear logit surrogate에 직접  
 620 등장하는 양이다.

정리 2 (미니맥스 방향 커버리지).

$$\mathcal{E}(D) := \min_{\|b\|=1} \text{Var}_{h \sim D}(b^\top h)$$

621 라 두면,

$$\mathcal{E}(D) = \lambda_{\min}(\Sigma_D) \leq \frac{\rho^2}{d},$$

622 이고, 등호는  $\Sigma_D = (\rho^2/d)\mathbf{I}_d$  일 때 그리고 그럴 때만 성립한다.

623 *Proof.* 임의의 대칭 공분산 행렬  $\Sigma_D$ 에 대해

$$\min_{\|b\|=1} b^\top \Sigma_D b = \lambda_{\min}(\Sigma_D),$$

624 이므로  $\mathcal{E}(D) = \lambda_{\min}(\Sigma_D)$ 이다.  $\Sigma_D$ 의 고윳값을  $\lambda_1, \dots, \lambda_d$ 라 하면,

$$\lambda_{\min}(\Sigma_D) \leq \frac{1}{d} \sum_{m=1}^d \lambda_m = \frac{\text{tr}(\Sigma_D)}{d} \leq \frac{\rho^2}{d}.$$

625 모든 고윳값이 같을 때, 즉  $\Sigma_D = (\rho^2/d)\mathbf{I}_d$ 일 때 그리고 그럴 때만 등호가 성립한다.  $\square$

626 이 정리는 등방성 무작위성이 갖는 장점을 형식화한다. RSP는 주어진 프롬프트에서 어떤 logit-  
 627 sensitive 방향  $b_{ij}$ 를 섭동해야 하는지 사전에 알지 못한다. 고정된 분산 예산 아래에서, 등방성  
 628 분포는 가능한 모든 방향에 대한 최악 경우 섭동량을 최대화하는 유일한 선택이다. 고정된 토큰  
 629 프롬프트는 결정적 섭동에 해당하므로  $\Sigma_D = 0$ 이고, 따라서  $\mathcal{E}(D) = 0$ 이다. 더 일반적으로,  
 630 비등방성 섭동은 언제나  $\lambda_{\min}(\Sigma_D) < \rho^2/d$ 를 만족하므로 적어도 한 방향에서는 등방성 최적해  
 631 보다 덜 탐색하게 된다.

## 632 E 에너지 이론 분석에 대한 증명

### 633 E.1 결정적 포획

634 **보조정리 3** (하강 보조정리). 만약  $E$ 가  $L_E$ -smooth이고  $\eta \leq 1/L_E$  라면,  $E(\sigma^{\text{new}}) \leq E(\sigma) -$   
 635  $\frac{\eta}{2} \|\nabla E(\sigma)\|^2$ 가 성립한다.

636 *Proof.*  $L_E$ -smoothness에 의해  $E(\sigma - \eta \nabla E) \leq E(\sigma) - \eta \|\nabla E\|^2 + \frac{L_E \eta^2}{2} \|\nabla E\|^2 = E(\sigma) - \eta(1 -$   
 637  $\frac{L_E \eta}{2}) \|\nabla E\|^2$ 이다.  $\eta \leq 1/L_E$ 이므로  $L_E \eta/2 \leq 1/2$ 이고, 따라서  $E(\sigma^{\text{new}}) \leq E(\sigma) - \frac{\eta}{2} \|\nabla E\|^2$   
 638 를 얻는다.  $\square$

639 **정리 3** (결정적 포획).  $E$ 가 아래로 유계이고  $L_E$ -smooth이며, 업데이트 step size가  $\eta \leq 1/L_E$   
 640 라고 하자. 섭동이 없을 때 forward pass는 단조 하강 궤적을 만들며  $\sigma^{(0)}$ 의 basin of attraction  
 641 안에 머문다. 특히 다른 basin의 더 낮은 minimum으로 가기 위해 에너지 장벽을 넘을 수 없다.

642 *Proof.* Lemma 3에 의해 모든 레이어  $l$ 에 대해

$$E(\sigma^{(l)}) - E(\sigma^{(l+1)}) \geq \frac{\eta}{2} \|\nabla E(\sigma^{(l)})\|^2$$

643 가 성립한다. 이를  $l = 0, \dots, L-1$ 에 대해 합하면

$$\frac{\eta}{2} \sum_{l=0}^{L-1} \|\nabla E(\sigma^{(l)})\|^2 \leq E(\sigma^{(0)}) - E(\sigma^{(L)}) \leq E(\sigma^{(0)}) - \inf E < \infty,$$

644 이므로 궤적 전체의 squared-gradient 질량은 유한하고, 따라서  $\|\nabla E(\sigma^{(l)})\| \rightarrow 0$ 이다. 즉 모든  
 645 accumulation point는 critical point다. 그러나 본문에 더 중요한 점은, 각 iterate가 이전 iterate에서  
 646 결정적 하강으로 만들어지므로 전체 경로가  $\sigma^{(0)}$ 에 의해 유일하게 정해진다는 사실이다. 초기  
 647 basin을 벗어나려면 어느 순간 에너지 장벽을 넘어야 하고, 그러려면 경로 어딘가에서 상승 step  
 648 이 필요하다. 하지만 업데이트는  $E$ 를 결코 증가시키지 않으므로 그런 crossing은 불가능하다.  
 649 따라서 비섭동 동역학은 초기 basin에서 도달 가능한 critical point에만 접근할 수 있으며, 그  
 650 basin 안에 열등한 local minimum이 있으면 더 나은 basin으로 탈출할 수 없다.  $\square$

### 651 E.2 RSP가 유도하는 섭동의 성질

652 **Attention 출력의 분해.**  $n$ 개의 실제 key와  $k$ 개의 무작위 key가 있을 때 attention 업데이트는  
 653 다음처럼 분해된다.

$$\mathbf{x}_i^{(l+1)} = (1 - w_{r,i}^{(l)}) \tilde{\mathbf{x}}_i^{(l+1)} + \boldsymbol{\eta}_i^{(l)}, \quad (7)$$

654 여기서

$$\tilde{\mathbf{x}}_i^{(l+1)} = \sum_{j=1}^n \tilde{\alpha}_{ij}^{(l)} \mathbf{v}_j^{(l)}, \quad \tilde{\alpha}_{ij}^{(l)} = \frac{\alpha_{ij}^{(l)}}{1 - w_{r,i}^{(l)}}, \quad (8)$$

655 이고,

$$\boldsymbol{\eta}_i^{(l)} = \sum_{j=1}^k \alpha_{i,n+j}^{(l)} \mathbf{v}_{r_j}^{(l)} \quad (9)$$

656 이다.

657 이제 섭동 항  $\boldsymbol{\eta}_i^{(l)}$ 의 성질을 분석한다.

658 **조건부 기댓값.** Attention weight에 조건부로 두면

$$\mathbb{E}[\boldsymbol{\eta}_i^{(l)} \mid \alpha^{(l)}] = \mu_E w_{r,i}^{(l)}, \quad (10)$$

659 여기서  $w_{r,i}^{(l)} := \sum_{j=1}^k \alpha_{i,n+j}^{(l)}$ 이다.

660 **조건부 공분산.** 무작위 벡터들이 공분산  $\sigma_E^2 \mathbf{I}$ 를 갖는 독립 샘플이라고 가정하면

$$\text{Cov}(\boldsymbol{\eta}_i^{(l)} \mid \alpha^{(l)}) = \sigma_E^2 \sum_{j=1}^k (\alpha_{i,n+j}^{(l)})^2 \mathbf{I}. \quad (11)$$

661  $\sum_j \alpha_j^2 \leq (\sum_j \alpha_j)^2$ 를 이용하면

$$\text{Cov}(\boldsymbol{\eta}_i^{(l)} \mid \alpha^{(l)}) \preceq \sigma_E^2 (w_{r,i}^{(l)})^2 \mathbf{I} \quad (12)$$

662 를 얻는다.

663 **Bias-to-variance 비율.** 평균과 표준편차의 비는 다음처럼 상계된다.

$$\frac{\|\mathbb{E}[\boldsymbol{\eta}_i^{(l)} \mid \alpha^{(l)}]\|}{\sqrt{\text{Var}(\boldsymbol{\eta}_i^{(l)} \mid \alpha^{(l)})}} \leq \frac{|\mu_E|}{\sigma_E}. \quad (13)$$

664 실험적으로는  $|\mu_E|/\sigma_E \ll 1$  이므로, 체계적 bias보다 확률적 성분이 지배적이다.

665 **실험적 검증.** Table 9는 실험에 사용한 모든 모델에 대해 임베딩 행렬 통계를 보고한다.

Table 9: 임베딩 행렬 통계. 모든 모델에서  $|\mu_E|/\sigma_E < 0.02$ 이다.

| Model                      | $\mu_E$  | $\sigma_E$ | $ \mu_E /\sigma_E$ |
|----------------------------|----------|------------|--------------------|
| LLaMA-3.1-8B-Instruct      | 0.00002  | 0.01057    | 0.002              |
| Qwen2.5-Math-7B-Instruct   | -0.00002 | 0.01647    | 0.001              |
| Qwen2.5-Math-1.5B-Instruct | 0.00019  | 0.01585    | 0.012              |
| Qwen2.5-Math-7B            | -0.00003 | 0.01842    | 0.001              |
| Qwen2.5-Math-1.5B          | 0.00038  | 0.02990    | 0.013              |

666 **함의.** 따라서 이 섭동은  $w_{r,i}^{(l)}$ 에 의해 크기가 제어되는 거의 zero-mean noise처럼 동작하며,  
667 본문에서 제시한 Langevin 유사 해석을 정당화한다.

### 668 E.3 Attention 감쇠 경계

669 **정리 4** (Attention 감쇠). 무작위 토큰에 할당되는 총 attention 은

$$w_{r,i}^{(l)} \leq \frac{k}{k + n \cdot \exp(\Delta_i^{(l)}/\sqrt{d})}, \quad (14)$$

670 를 만족한다. 여기서  $\Delta_i^{(l)} := \min_{j \in [n]} \mathbf{q}_i^\top \mathbf{k}_j - \max_{j' \in [k]} \mathbf{q}_i^\top \mathbf{k}_{r_{j'}}$ 는 실제 key와 무작위 key 사이의  
671 logit gap이다.

672 *Proof.* 실제 key에 대해  $s_j = \mathbf{q}_i^\top \mathbf{k}_j / \sqrt{d}$ , 무작위 key에 대해  $s_{r_{j'}} = \mathbf{q}_i^\top \mathbf{k}_{r_{j'}} / \sqrt{d}$ 라 하자.  $\Delta_i^{(l)}$ 의  
673 정의에 따라 각 실제 key는  $s_j \geq \Delta_i^{(l)}/\sqrt{d} + s_{r,\max}$ 를 만족하며, 여기서  $s_{r,\max} = \max_{j'} s_{r_{j'}}$ 이다.  
674 따라서 모든 실제 key에 대해  $\exp(s_j) \geq \exp(\Delta_i^{(l)}/\sqrt{d}) \cdot \exp(s_{r,\max})$ 가 성립한다. 이를  $n$ 개의  
675 실제 key에 대해 합하면

$$\sum_{j=1}^n \exp(s_j) \geq n \cdot \exp(\Delta_i^{(l)}/\sqrt{d}) \cdot \exp(s_{r,\max}) \geq n \cdot \exp(\Delta_i^{(l)}/\sqrt{d}) \cdot \frac{1}{k} \sum_{j'=1}^k \exp(s_{r_{j'}}). \quad (15)$$

676 무작위 토큰에 대한 총 attention은  $w_{r,i}^{(l)} = \sum_{j'} \exp(s_{r_{j'}}) / (\sum_j \exp(s_j) + \sum_{j'} \exp(s_{r_{j'}}))$ 이므로,  
677 실제 key 합에 대한 하한을 대입하고  $R = \sum_{j'} \exp(s_{r_{j'}})$ 로 두면

$$w_{r,i}^{(l)} = \frac{R}{\sum_j \exp(s_j) + R} \leq \frac{R}{n \cdot \exp(\Delta_i^{(l)}/\sqrt{d}) \cdot R/k + R} = \frac{k}{k + n \cdot \exp(\Delta_i^{(l)}/\sqrt{d})}. \quad (16)$$

678  $\square$

679 **따름정리 1** (고정된 logit gap 아래의 시퀀스 방향 annealing).  $k$ 와  $\Delta_i^{(l)}$ 를 고정하면, 상계

$$f(n) = \frac{k}{k + n \exp(\Delta_i^{(l)} / \sqrt{d})}$$

680 는 실제 토큰 수  $n$ 에 대해 엄격히 감소한다. 따라서 cache 성장만으로도 그 gap과 양립 가능한  
681 최대 섭동 질량은 감소한다.

682 *Proof.*  $f(n)$ 을  $n$ 에 대해 미분하면

$$f'(n) = -\frac{k \exp(\Delta_i^{(l)} / \sqrt{d})}{\left(k + n \exp(\Delta_i^{(l)} / \sqrt{d})\right)^2} < 0.$$

683 따라서  $f(n)$ 은 엄격히 감소한다. □

684 **따름정리 2** (Annealing 하에서의 섭동 소멸). Decoding 동안  $n \rightarrow \infty$ 이고  $k$ 와  $\Delta_i^{(l)}$ 가 고정되어  
685 있다면,  $w_{r,i}^{(l)} \rightarrow 0$ 가 된다. 따라서

$$\left\| \mathbb{E}[\boldsymbol{\eta}_i^{(l)} \mid \alpha^{(l)}] \right\| = O(w_{r,i}^{(l)}) \quad \text{and} \quad \text{tr Cov}(\boldsymbol{\eta}_i^{(l)} \mid \alpha^{(l)}) = O((w_{r,i}^{(l)})^2)$$

686 도 함께 0으로 간다.

687 *Proof.* Corollary 1에 의해  $w_{r,i}^{(l)} \rightarrow 0$ 이다. 기댓값 경계는

$$\mathbb{E}[\boldsymbol{\eta}_i^{(l)} \mid \alpha^{(l)}] = \mu_E w_{r,i}^{(l)}$$

688 에서 바로 나오고, 공분산 경계는

$$\text{Cov}(\boldsymbol{\eta}_i^{(l)} \mid \alpha^{(l)}) \preceq \sigma_E^2 (w_{r,i}^{(l)})^2 \mathbf{I}$$

689 에서 따른다. □

## 690 E.4 출력 분포 이동에 대한 증명

691 본문은 출력 수준에서 두 가지 주장을 한다. Proposition 1은 쌍대 순위의 무작위화를, Propo-  
692 sition 2은 그보다 한 단계 강한 후보 집합 확장을 다룬다. 두 주장 모두 섭동된 logits의 local  
693 first-order surrogate에 대한 명제다.

### 694 E.4.1 자기회귀 정식화

695 자기회귀 decoding에서 시퀀스  $y_{1:T}$ 의 결합 분포는

$$\Pr(y_{1:T} \mid x) = \prod_{t=1}^T p(y_t \mid x, y_{<t}),$$

696 로 분해된다. 각 단계는 prefix에 조건부인 분포로 결정되므로, RSP가 도입한 섭동은 단일한  
697 전역 분포를 한 번에 바꾸는 것이 아니라  $p(y_t \mid x, y_{<t})$ 에 대한 일련의 국소 변화로 작동한다.

### 698 E.4.2 RSP 하에서의 logits 국소 선형화

699 중심화된 random soft prompt를  $\bar{h}$ 라 하자. 섭동된 logits를  $\bar{h}$ 의 함수  $z_i(\bar{h})$ 로 두고,  $\bar{h} = 0$  근방  
700 에서 국소 smoothness를 가정하면

$$z_i(\bar{h}) = z_i(0) + \nabla_h z_i(0)^\top \bar{h} + r_i(\bar{h}),$$

701 여기서  $r_i(\bar{h}) = O(\|\bar{h}\|^2)$ 이다.  $a_i := \nabla_h z_i(0)$ 라 두면 국소 선형 근사  $z_i(\bar{h}) \approx z_i + a_i^\top \bar{h}$ 를 얻는다.  
702 이 근사는 충분히 작은  $\|\bar{h}\|$ 에서 유효하며, transformer logits의 전역 정확 모델이라기보다 섭동  
703 방향을 설명하는 1차 surrogate로 사용한다.

704 **E.4.3 명제 1의 증명 (확률적 순위화)**

705 토큰 쌍  $(i, j)$  중  $a_i \neq a_j$  인 것이 존재하면,  $0 < \Pr_{\bar{h}}(z_i(\bar{h}) > z_j(\bar{h})) < 1$  이 성립한다.

706 *Proof.* 국소 선형 근사 아래에서

$$z_i(\bar{h}) - z_j(\bar{h}) = (z_i - z_j) + (a_i - a_j)^\top \bar{h}.$$

707  $b_{ij} := a_i - a_j \neq 0$  라 두자. 만약  $\bar{h} \sim \mathcal{N}(0, \sigma^2 I)$  이면,  $b_{ij}^\top \bar{h} \sim \mathcal{N}(0, \sigma^2 \|b_{ij}\|^2)$  인 비퇴화 가우시  
708 안이 된다. 따라서 섭동된 logit 차이

$$\Delta_{ij}(\bar{h}) := (z_i - z_j) + b_{ij}^\top \bar{h}$$

709 는 0의 양쪽에 모두 양의 확률 질량을 가지며, 결과적으로

$$0 < \Pr_{\bar{h}}(\Delta_{ij}(\bar{h}) > 0) < 1$$

710 이 성립한다. □

711 **E.4.4 명제 2의 증명 (지지 집합 확장)**

712 상태  $s_t$  에서 *baseline top-K* 집합을  $J_K(s_t)$  라 하자. 어떤 토큰  $i \notin J_K(s_t)$  에 대해 다음 집합

$$\mathcal{H}_i := \{\bar{h} \in \mathbb{R}^d : z_i + a_i^\top \bar{h} > z_j + a_j^\top \bar{h} \text{ for all } j \in J_K(s_t)\}$$

713 의 내부가 비어 있지 않다고 하자.  $\bar{h}$  를 등방성 가우시안에서 샘플링하면

$$\Pr_{\bar{h}}(i \in \text{TopK}(p^{\text{RSP}}(\cdot \mid s_t, \bar{h}))) > 0$$

714 가 성립한다.

715 *Proof.* 국소 선형 모델에서 토큰  $i$  가  $J_K(s_t)$  의 모든 토큰을 앞지른다는 조건은 정확히  $\bar{h} \in \mathcal{H}_i$   
716 와 동치다. 각 부등식

$$z_i + a_i^\top \bar{h} > z_j + a_j^\top \bar{h}$$

717 는 열린 half-space 를 정의한다. 따라서 유한 개의 열린 half-space 의 교집합인  $\mathcal{H}_i$  역시 열린  
718 집합이다. 가정에 의해 그 내부는 비어 있지 않으므로,  $\mathcal{H}_i$  는  $\mathbb{R}^d$  의 비어 있지 않은 열린 집합  
719 이다. 등방성 가우시안은  $\mathbb{R}^d$  전역에서 엄밀히 양수인 밀도를 가지므로, 모든 비어 있지 않은  
720 열린 집합은 양의 확률 측도를 갖는다. 따라서

$$\Pr_{\bar{h}}(\bar{h} \in \mathcal{H}_i) > 0$$

721 이며, 이것이 바로 섭동된 분포 아래에서 토큰  $i$  가 top-K 집합에 진입하는 사건이다. □

722 **E.4.5 궤적 수준의 합의**

723 자기회귀 생성은 조건부 분포를 단계별로 합성하므로, 초기 단계의 섭동이 전혀 다른 궤적으로  
724 이어질 수 있다. 적어도 한 번 *baseline top-K* 바깥 토큰을 포함하는 궤적의 집합을  $\mathcal{R}_{k,K}(x)$   
725 라 하자. 만약 RSP가 초기 단계에서 이런 토큰의 접근 가능성을 높인다면, 반복 샘플링에서  
726  $\mathcal{R}_{k,K}(x)$  에 속하는 궤적을 뽑을 확률도 증가한다. 핵심은 시간적 누적이다. 초반의 top-K 진입  
727 한 번이 다음 decoding state 를 바꾸고, 그것이 다시 다음 후보 집합을 바꾸는 식으로 이어진다.  
728 이것이 국소적인 순위 섭동이 전역적인 궤적 다양성으로 이어지는 형식적 다리다.

## 729 F Attention Mass 분석

730 이 부록은 Figure 4에 보고한 per-token attention mass를 형식화하고, reasoning span과 layer 축에  
731 적용한 제외 기준을 명시한다. 500개의 MATH-500 문제 각각에 대해 새로운  $\text{RSP } \mathbf{H} \in \mathbb{R}^{L \times d}$ 를  
732  $L = 10$ 으로 독립 샘플링했으므로, 보고한 heatmap은 문제 자체의 변동성과 RSP 벡터 변동성을  
733 함께 평균한 결과다.

### 734 F.1 토큰당 attention 질량

735 각 문제에서 attention은 연결된 시퀀스 [prompt;  $\mathbf{H}$ ; generation] 위에서 측정하며, generation은  
736 같은 모델이 동일한 RSP 주입 설정 아래 생성한 궤적이다.  $\alpha_{i,j}^{(\ell,h)}$ 를 layer  $\ell$ , head  $h$ 에서 query  
737 위치  $i$ 가 key 위치  $j$ 로 보내는 post-softmax attention weight라고 하자. 이는 causal mask 아래에서  
738  $\sum_j \alpha_{i,j}^{(\ell,h)} = 1$ 을 만족한다. 질문 토큰과 RSP 토큰의 인덱스 집합을 각각  $Q$ ,  $R$ 라 하고 크기를  
739  $|Q|$ ,  $|R| = L$ , head 수를  $H$ 라 하자. 이때 query  $i$ 가 각 그룹으로 보내는 layer  $\ell$ 의 per-token  
740 attention mass는

$$\text{PTM}_Q[\ell, i] = \frac{1}{|Q|H} \sum_{h=1}^H \sum_{j \in Q} \alpha_{i,j}^{(\ell,h)}, \quad \text{PTM}_R[\ell, i] = \frac{1}{|R|H} \sum_{h=1}^H \sum_{j \in R} \alpha_{i,j}^{(\ell,h)}. \quad (17)$$

741  $|Q|$ 와  $|R|$ 로 나누는 정규화는 집합 크기 차이를 보정하므로, 두 양은 동일한 softmax 분모 아래  
742 에서 질문 토큰 또는 RSP 토큰 하나가 평균적으로 얼마나 많은 attention을 받는지를 나타낸다.  
743 따라서 질문 토큰은 시퀀스 길이 효과를 흡수하는 크기 보정 baseline 역할을 한다.

### 744 F.2 Heatmap 집계

745 Layer 인덱스와 reasoning position 인덱스를 각각 동일 크기의 다섯 구간  $\{B_L^{(b)}\}_{b=1}^5$ ,  $\{B_P^{(b)}\}_{b=1}^5$   
746 로 나눈다. 샘플  $s$ 와 목표 집합  $\bullet \in \{Q, R\}$ 에 대해 셀  $(b_L, b_P)$ 의 값은

$$M_{\bullet}^{(s)}[b_L, b_P] = \frac{1}{|B_L^{(b_L)}| \cdot |B_P^{(b_P)}|} \sum_{\ell \in B_L^{(b_L)}} \sum_{i \in B_P^{(b_P)}} \text{PTM}_{\bullet}[\ell, i]. \quad (18)$$

747 Figure 4는 Eq. (18)를 500개의 유효 샘플에 대해 평균한 결과를 보고한다.

### 748 F.3 \boxed{\dots} 구간 제외

749 Reasoning position 범위는 마지막 \boxed{\dots} 구간이 시작되기 직전에 끝나도록 잡는다.  
750 Chain-of-thought 출력은 *text*(내용)와 *pattern*(형식) 성분으로 나뉘며, 이 둘은 downstream 성  
751 능에 독립적으로 기여할 수 있다 [Madaan and Yazdanbakhsh, 2022]. \boxed{\dots} 래퍼는 전형  
752 적인 pattern 성분이다. 이는 추론을 더 전개하기보다는 답 형식을 마무리하는 짧고 정형화된  
753 span이기 때문이다. 이 구간을 포함하면 reasoning dynamics와 무관한 template-driven attention  
754 signature가 섞이게 된다.

### 755 F.4 마지막 두 레이어 제외

756 Layer 축에서는 마지막 두 transformer layer도 제외한다. 이는 우리 설정에만 특수한 것이 아니라,  
757 late layer의 두 가지 잘 알려진 성질에서 비롯된다.

758 **출력 투영 특화.** 마지막 레이어 근방의 hidden state는 vocabulary logits와 거의 선형 관계를 이  
759 루므로, 표현을 바꾸는 블록이라기보다 점진적 선형 readout으로 기능한다 [Belrose et al., 2023].  
760 같은 맥락에서 late-layer feed-forward module도 출력 분포를 조정하는 메커니즘으로 해석되어  
761 왔다 [Geva et al., 2021]. 따라서 이 레이어들의 attention은 reasoning computation보다 output  
762 formation을 더 강하게 반영한다.

763 **Register-token 가설.** Vision Transformer에서 정보가 거의 없는 patch token은 deeper layer에서  
764 attention을 흡수하는 *register*로 재활용될 수 있음이 알려져 있다 [Darcet et al., 2024]. RSP 역시  
765 사전학습된 의미를 갖지 않는 연속 토큰이라는 점에서 유사한 성질을 가지므로, late transformer

layer에서 비슷한 재사용이 일어날 가능성을 배제할 수 없다. 마지막 두 레이어를 제외하면 이런 register 유도 교란이 reasoning-phase 신호를 오염시키는 일을 막을 수 있다.

위의 두 근거는 late layer에서 나타나는 잘 알려진 현상, 즉 선형 readout과 잠재적 register 재사용이 reasoning-phase dynamics와 직교하는 attention signature를 만들 수 있음을 뜻한다. 마지막 두 레이어를 제거하는 것은 모델 특이적 tuning이 아니라, 문헌에 근거한 원칙적 제외라고 볼 수 있다.

## F.5 추가적인 suffix heatmap

Figure 7는 suffix 주입에서 Qwen2.5-Math-1.5B-Instruct와 LLaMA-3.1-8B-Instruct에 대해 동일한 per-token RSP attention 분석을 보고한다. 앞서 설명한 late-layer 이유 때문에 모든 셀에서 패턴이 완전히 동일하게 일반화되지는 않지만, 전체적인 경향은 두 모델에서 일관된다. 즉 질문 토큰 attention은 레이어 전반에 걸쳐 폭넓게 변하는 반면, RSP attention은 Eq. (3)이 예측한 것처럼 레이어 방향과 시퀀스 방향으로 함께 감소한다.




Figure 7: 나머지 두 모델(각각 500개 MATH-500 샘플)에서 suffix 주입 시 측정한 per-token RSP attention mass. 축과 전처리는 Figure 4와 동일하다. x축은 다섯 분위로 나눈 reasoning position, y축은 다섯 분위로 나눈 layer depth(위가 얇은 층), 색은 RSP 토큰에 할당된 per-token attention의 500샘플 평균을 뜻한다. `\boxed{}` 구간 내부 토큰과 마지막 두 레이어는 제외했다.

## 778 G GRPO 정식화

779 주어진 프롬프트  $q$ 에 대해, behavior policy  $\pi_{\theta_{\text{old}}}$ 는 보상  $\{R_i\}_{i=1}^G$ 를 갖는 응답 집합  $\{o_i\}_{i=1}^G$ 를  
780 샘플링한다. 각 응답의 advantage는 그룹 수준 보상을 정규화해 계산한다.

$$\hat{A}_{i,t} = \frac{R_i - \text{mean}(\{R_i\}_{i=1}^G)}{\text{std}(\{R_i\}_{i=1}^G)}. \quad (19)$$

781 정책은 KL penalty가 포함된 clipped objective로 업데이트한다.

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E} \left[ \frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left( \min \left( r_{i,t} \hat{A}_{i,t}, \text{clip}(r_{i,t}, 1-\varepsilon, 1+\varepsilon) \hat{A}_{i,t} \right) - \beta D_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}}) \right) \right], \quad (20)$$

782 여기서  $r_{i,t} = \pi_{\theta}(o_{i,t} \mid q, o_{i,<t}) / \pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})$ 는 importance sampling ratio이고,  $\varepsilon$ 는 clipping  
783 범위,  $\beta$ 는 reference policy  $\pi_{\text{ref}}$ 에 대한 KL penalty 세기를 조절한다.



## 784 H 광범위한 영향

785 본 연구는 무작위 임베딩 주입이 대형 언어 모델의 추론 행동에 어떤 영향을 주는지에 대한  
786 실험적·이론적 분석을 제공한다. 기여의 성격은 주로 기초 연구에 가깝지만, GRPO와 같은  
787 강화학습 기반 추론 모델 후속학습에는 잠재적 함의를 가진다.

788 **긍정적 영향.** RSP가 유도하는 궤적 다양성은 group-relative advantage estimation 안에서 더  
789 풍부한 학습 신호를 제공함으로써, RL 기반 LLM 후속학습의 sample efficiency를 높일 수 있다.  
790 이는 reasoning 중심 fine-tuning과 alignment에 필요한 계산 비용을 줄여, 자원이 제한된 연구  
791 그룹에도 관련 방법을 더 접근 가능하게 만들 수 있다.

792 **잠재적 우려.** LLM의 유효 출력 지지 집합을 넓히는 방법은 바람직한 대안적 추론 경로뿐  
793 아니라, 바람직하지 않거나 분포 밖에 있는 출력의 도달 가능성도 함께 높일 수 있다. 따라서  
794 RSP를 실제 시스템에 적용할 때는 이를 독립적인 다양성 원천으로만 보지 말고, 기존의 안전  
795 필터링 및 alignment 메커니즘과 함께 사용해야 한다.

796 **영향 범위의 한계.** 본 연구는 새로운 모델이나 데이터셋을 배포하기보다 분석을 제공하는 데  
797 초점을 두므로, 직접적인 사회적 영향은 제한적이다. 여기서 논의한 더 넓은 함의는 RSP가 실제  
798 학습 파이프라인에 통합되는 향후 연구가 이루어질 때에만 현실화될 수 있다.