

노이즈에서 다양성으로: 대형 언어 모델 추론에서의 무작위 임베딩 주입

Anonymous Author(s)

Affiliation

Address

email

Abstract

1 학습되지 않은 무작위 임베딩을 LLM 입력에 끼워 넣는 것만으로도 모델의
2 추론 행동이 비자명하게 바뀐다. 최근의 *soft prompt* 계열 방법은 가상 토큰
3 임베딩을 다양한 목적함수로 학습해 수학 추론 성능을 끌어올렸다. 그러나
4 이 이득이 학습에서 오는지 주입 자체에서 오는지는 아직 가르지 못했다. 본
5 논문은 학습 단계를 떼어 놓고 Random Soft Prompt(RSP)를 분석한다. RSP
6 는 사전학습 임베딩 행렬의 행별 평균과 분산만 빌려 등방 가우시안에서 뽑은
7 연속 벡터를 그대로 주입한다. 핵심 통찰은 두 가지다. 첫째, RSP의 영향은
8 생성 초반에 가장 크고 토큰이 쌓일수록 자연스럽게 약해진다. 캐시가 길어
9 지면 어텐션이 무작위 토큰에 배정하는 비중이 줄어들기 때문이다. 둘째, 한
10 번 뽑은 RSP는 그 시도 안에서 고정된 perturbation으로 작동해 baseline과는
11 다른 한 갈래를 결정한다. 시도가 바뀌면 RSP도 새로 뽑히므로 시도들 사이
12 에는 서로 다른 갈래가 살아난다. 그 결과 baseline이 거의 보지 못하던 후보가
13 일부 시도에서 답 후보권 안으로 들어오고, 이런 분기 사건이 반복 시도에서
14 누적된다. 우리는 이 두 통찰을 transformer 구조 안에서 정량적으로 보인다.
15 그리고 baseline 회복, 초반 토큰 다양화 후 후반 안정화, 독립 RSP의 Pass@N
16 누적이라는 세 실험으로 확인한다. 끝으로 이 다양성이 GRPO 학습에 어떤
17 함의를 갖는지 짚는다.

1 서론

19 대형 언어 모델(LLM)의 파라미터 수가 빠르게 늘면서, 모델 전체를 미세조정하는 길은 점점
20 멀어졌다. 그 자리를 소수 파라미터만 추가해 모델을 적응시키는 parameter-efficient 방법이 사실
21 상 표준으로 채웠다 [Hu et al., 2022, Houlsby et al., 2019]. 그중 *soft prompt*는 어휘 바깥의 학습
22 가능한 연속 임베딩을 입력에 끼워 넣는 도구다. 이 임베딩이 attention을 거치며 모델 행동을
23 조정한다 [Li and Liang, 2021, Lester et al., 2021]. 같은 패러다임은 수학 추론을 강화하는 최근
24 연구에도 폭넓게 쓰인다 [Kang et al., 2026, Xu et al., 2025, Ye et al., 2026, Hao et al., 2025, Zhang
25 et al., 2026]. 이들 연구는 어휘 밖 연속 임베딩을 최적화해 정확도를 끌어올린다는 공통 구조를
26 공유한다.

27 그런데 이 효과의 출처가 정말 최적화뿐이라고 단정하기는 어렵다. 학습되지 않은 무작위 연속
28 임베딩을 그대로 끼워 넣어도 출력 분포는 비자명하게 흔들린다. 한 예로 채팅 형식으로 학습되
29 지 않은 base model에 chat template을 적용하면 형식 불일치 탓에 추론 정확도가 크게 떨어진다.
30 그런데 무작위 임베딩을 덧붙이면 그 손실이 도리어 회복된다. 단순 노이즈가 모델을 흔드는 데
31 그친다면 정확도는 더 나빠져야 한다. 따라서 효과의 뿌리는 학습된 의미가 아니라 주입 자체의
32 어떤 성질이라는 가설이 자연스럽게 떠오른다. 기존 평가는 최종 정확도에 초점을 맞춰 “주입”
33 의 효과와 “최적화”의 효과를 분리하지 못했다. 그래서 어휘 바깥 연속 임베딩이 모델 행동을
34 어떻게 바꾸는가는 별도의 미해결 문제로 남았다.

35 본 논문은 학습 없이 주입되는 Random Soft Prompt(RSP)를 분석한다. RSP는 사전학습 임베딩
36 행렬의 행별 평균과 분산만 따 등방 가우시안에서 추출한 연속 벡터의 시퀀스다. 무작위성의

역할은 임베딩 분포를 흉내 내는 것이 아니라, 같은 prompt가 rollout마다 독립된 섭동을 받도록 보장하는 데 있다. 핵심은 시도 수 자체가 아니라, 매 시도가 초반 토큰의 분기를 다르게 연다는 점이다. 본 논문은 두 질문에 답한다. 첫째, 한 번의 RSP 주입은 왜 초반 몇 토큰만 흔들고 나중에는 영향이 사라지는가. 둘째, 시도가 바뀌어 RSP도 새로 뽑힐 때 왜 서로 다른 reasoning path가 시도 사이에서 누적되는가. 첫 질문은 transformer 어텐션 분해가 자연히 만들어 내는 토큰 단위 자기조절에서 답을 찾는다. 두 번째 질문은 N 회 독립 재시도가 작은 분기 확률을 빠르게 누적시키는 사슬에서 답을 찾는다. 한 번의 RSP는 그 시도 안에서 고정된 perturbation으로 작동해 baseline과는 다른 한 갈래를 결정한다. 시도가 누적되면 baseline에서 거의 보이지 않던 후보가 일부 시도에서 답 후보권 안으로 들어오는 사건이 분포로 쌓인다. 마지막으로 이 다양성이 GRPO [Shao et al., 2024] 학습에 어떤 함의를 갖는지 짚는다.

본 논문의 기여는 다음과 같다.

- RSP가 LLM 생성에 어떤 변화를 주는지 실증적으로 분석한다. RSP는 생성 초반의 토큰 엔트로피를 끌어올리고 후반에는 baseline 수준으로 다시 가라앉는다. temperature sampling과 결합하면 더 다양한 추론 궤적이 나온다.
- Soft prompt가 학습 없이도 작동하는 이유를 transformer 수준에서 자연어 직관과 함께 정량적으로 설명한다. RSP의 모든 영향은 어텐션 단의 한 가지 양이 통제되고, 그 양은 캐시가 자라면서 자동으로 약해진다. 등방 분포는 어떤 의미 방향에도 사전 가중치를 두지 않으면서, 동시에 모든 방향에 양의 확률을 부여한다.
- RSP가 유도하는 다양성이 GRPO 학습에 어떤 함의를 갖는지 논의한다. RSP는 토큰 순위를 바꾸는 섭동이고 temperature는 순위를 보존하는 섭동이다. 이 차이 덕분에 두 방법은 직교한 탐색 이득을 제공한다.

2 배경

2.1 LLM 추론을 위한 Soft Prompt 기법

Soft prompt는 전체 미세조정의 대안으로 등장했다. Prefix-Tuning [Li and Liang, 2021]이 학습 가능한 연속 벡터를 각 transformer 레이어 앞에 붙이는 패러다임을 제시한 이후, Prompt Tuning [Lester et al., 2021]은 입력 레이어만 사용하는 단순화된 형태로도 충분히 큰 모델에서 전체 미세조정에 근접한 성능을 보였고, P-tuning [Liu et al., 2024]은 LSTM prompt encoder로 위치 간 의존성까지 포착했다. 이 패러다임은 LLM 추론에도 빠르게 적용되었다. TTSV [Kang et al., 2026]는 테스트 시점에 prefix 임베딩을 엔트로피 최소화로 최적화해 잠재 추론을 활성화하고, SoftCoT [Xu et al., 2025]은 assistant model이 만든 soft token으로 명시적 chain-of-thought를 대체한다. LTPO [Ye et al., 2026]는 confidence 기반 내재 보상으로 latent thought 임베딩을 샘플별로 최적화하며, COCONUT [Hao et al., 2025]은 모델 자신의 은닉 상태를 다시 입력 임베딩으로 되먹여 연속 잠재 공간에서 추론하게 만든다. MemGen [Zhang et al., 2026]은 임베딩이 경험 메모리로 기능할 수 있음을 보였고, Pause token [Goyal et al., 2024]은 학습 가능한 토큰을 입력 중간에 끼워 넣어 추가 계산 단계를 제공한다. 이들 모두 어휘 바깥의 연속 임베딩을 과제 특화 목적함수로 최적화해 정확도를 끌어올린다. 그러나 평가가 최종 정확도에 맞춰져 있어 “주입 자체”의 효과와 “최적화”의 효과가 분리되지 않으며, 단순한 임베딩 주입이 모델 행동을 어떻게 바꾸는지는 별도의 미해결 문제로 남아 있다.

2.2 신경망에서의 노이즈 주입

신경망에는 여러 단계에서 노이즈가 도입되어 왔다. 학습 시점에서는 dropout [Srivastava et al., 2014]이 은닉 유닛을 무작위로 비활성화해 과적합을 막고, NEFTune [Jain et al., 2024]은 instruction fine-tuning 중 토큰 임베딩에 노이즈를 더해 instruction following을 개선한다. 추론 시점의 섭동은 주로 강건성을 겨냥한다. Randomized smoothing [Cohen et al., 2019]은 입력 가우시안 노이즈로 certified robustness를 얻고, SmoothLLM [Robey et al., 2025]은 문자 단위 프롬프트 변형으로 jailbreak를 방어한다. 강화학습에서는 NoisyNet [Fortunato et al., 2018]이 가중치에 학습 가능한 노이즈를 넣어 탐색 성능을 높였다.

RSP는 이들과 세 가지 점에서 구별된다. (1) 어떠한 학습도 없이 추론 시점에만 동작하므로 모델 파라미터를 건드리지 않는다(dropout, NEFTune, NoisyNet과 다르다). (2) 원래 입력을 보존한 채 새 임베딩을 한 번의 forward pass에 덧붙일 뿐이며, 강건성 방법이 요구하는 “여러 번의 noisy pass와 출력 집계”가 필요 없다. (3) 학습된 파라미터 없이 사전학습 임베딩 통계에서 직접 샘플링한 무작위 벡터를 그대로 쓴다(NoisyNet은 노이즈 파라미터 자체를 학습한다). 무엇보다

88 RSP의 목적은 출력 안정성이 아니라 탐색이며, 본 논문은 이 차이가 어텐션 수준에서 어떻게
89 작동하는지 분석한다.

90 3 Random Soft Prompt와 작동 원리

91 이 절은 RSP를 정의한다. 그 작동 원리는 두 가닥의 자연스러운 이야기로 풀다. 먼저 한 번의
92 주입에서 RSP의 영향은 transformer 어텐션이 무작위 토큰에 배정하는 비중 한 가지로 모인다.
93 그 비중은 토큰이 쌓일수록 저절로 약해진다. 그래서 효과는 초반 토큰에서 가장 잘 나타난다.
94 한 번 추천된 RSP는 그 시도 안에서 고정된 perturbation으로 작동해 baseline과 다른 한 갈래를
95 정한다. 다만 시도가 바뀌면 RSP도 새로 뽑히므로, 시도들 사이에는 서로 다른 갈래가 활성화
96 된다. 그 결과 baseline이 거의 보지 못하던 후보가 어떤 시도에서는 답 후보권 안으로 들어온다.
97 이 분기 사건은 반복 시도에서 누적된다. 첫 가닥은 §3.2에서 어텐션 분해와 자동 어닐링으로
98 다룬다. 둘째 가닥은 §3.3의 등방성 정당화와 §3.4의 독립 재추첨 누적으로 정리한다. 자세한
99 부등식은 본문 안에서 등장하지만, 직관과 결론은 모두 자연어로 먼저 풀어 둔다.

100 3.1 Random Soft Prompt

101 구현은 단순하다. 사전학습된 토큰 임베딩 행렬의 평균과 스케일만 빌려 같은 모양의 연속 벡
102 터를 추천한다. 이를 prompt 앞·중간·뒤 어디에든 붙여 넣는다. 이렇게 만든 시퀀스가 RSP다.
103 형식적으로, 토큰 임베딩 행렬을 $\mathbf{W}_E \in \mathbb{R}^{V \times d}$ (V 는 어휘 크기, d 는 은닉 차원)로 둔다. 그 행별
104 평균과 표준편차를 $\mu_E := \frac{1}{V} \sum_{i,k} [\mathbf{W}_E]_{i,k}$, $\sigma_E := \text{std}(\mathbf{W}_E)$ 라 쓴다. 길이 L 의 RSP는 다음
105 분포에서 독립적으로 추천한 연속 벡터의 시퀀스 $\mathbf{H} = [h_1, \dots, h_L] \in \mathbb{R}^{L \times d}$ 이다.

$$h_j \sim \mathcal{N}(\mu_E \mathbf{1}_d, \sigma_E^2 \mathbf{I}_d), \quad j = 1, \dots, L. \quad (1)$$

106 중심화한 $\bar{h}_j := h_j - \mu_E \mathbf{1}_d \sim \mathcal{N}(0, \sigma_E^2 \mathbf{I}_d)$ 은 평균이 0인 등방 가우시안이 된다. 원래 입력
107 임베딩 시퀀스 $\mathbf{X}$ 에 RSP를 결합하는 위치는 세 가지다. prefix [$\mathbf{H}; \mathbf{X}$], infix($\mathbf{H}$ 를 $\mathbf{X}$ 안쪽에 삽입),
108 suffix [$\mathbf{X}; \mathbf{H}$] [Kang et al., 2026, Xu et al., 2025, Ye et al., 2026, Zhang et al., 2026]. 반복 샘플링
109 프로토콜에서는 비교되는 시도들의 prompt 추천과 디코딩 무작위성을 모두 독립으로 가정한다.

110 무작위성의 핵심은 같은 prompt가 rollout마다 독립된 섭동을 만들도록 한다는 점이다. RSP는
111 임베딩 분포를 모사하지 않는다. 매 시도의 출발점을 서로 다르게 만드는 일에 의미가 있다.
112 탐색이 요구하는 것도 바로 이 독립성이다.

113 3.2 어텐션 분해와 자동 어닐링

114 RSP는 hidden state에 직접 더해지지 않고 어텐션 가중치를 통해서만 들어간다. 그래서 그 영향이
115 수많은 머리·층을 거치며 흩어지지 않고 한 가지 양으로 모일 가능성이 자연스럽게 떠오른다.
116 self-attention 레이어 ℓ 이 실제 토큰 n 개와 RSP 토큰 L 개를 함께 attend한다고 하자. 어텐션
117 가중치를 $\alpha_{ij}^{(\ell)}$, value 벡터를 실제 측과 RSP 측에서 각각 $\mathbf{v}_j^{(\ell)}, \mathbf{v}_{r_j}^{(\ell)}$ 로 쓴다. 무작위 토큰에 배정된
118 총 어텐션 질량을 $w_{r,i}^{(\ell)} := \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)}$ 로 두자. 그러면 어텐션 출력은 다음 형태로 정확히
119 정리된다.

$$\mathbf{x}_i^{(\ell+1)} = (1 - w_{r,i}^{(\ell)}) \tilde{\mathbf{x}}_i^{(\ell+1)} + \boldsymbol{\eta}_i^{(\ell)}, \quad \tilde{\mathbf{x}}_i^{(\ell+1)} := \sum_{j=1}^n \frac{\alpha_{ij}^{(\ell)}}{1 - w_{r,i}^{(\ell)}} \mathbf{v}_j^{(\ell)}, \quad \boldsymbol{\eta}_i^{(\ell)} := \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{r_j}^{(\ell)}. \quad (2)$$

120 Eq. (2)의 도출. 어텐션 출력 $\sum_{j=1}^{n+L} \alpha_{ij}^{(\ell)} \mathbf{v}_{ij}^{(\ell)}$ 를 실제 토큰 항과 RSP 토큰 항으로 가른다. 실제
121 항에서 정규화 인자 $1 - w_{r,i}^{(\ell)} = \sum_{j=1}^n \alpha_{ij}^{(\ell)}$ 를 묶어 내면 된다. softmax 정규화 항등식 외에는
122 어떤 근사도 쓰지 않는다. $\square$

123 여기서 한 양 $w_{r,i}^{(\ell)}$ 이 두 가지를 동시에 통제한다. 실제 신호의 감쇠 비율 $1 - w_{r,i}^{(\ell)}$ 과 무작위
124 기여 항의 진폭 상계 $\|\boldsymbol{\eta}_i^{(\ell)}\| \leq w_{r,i}^{(\ell)} \max_j \|\mathbf{v}_{r_j}^{(\ell)}\|$ 이 모두 같은 스칼라에 매여 있다. RSP가 만드는
125 변동은 다차원 섭동이 아니다. 0과 1 사이 한 값을 추적하는 문제로 환원된다. 그러면 다음 질
126 문이 자연스럽다. 디코딩이 진행되면 이 값은 어떻게 변하는가? 자기회귀 생성에서 KV 캐시는

127 매 step 한 토큰씩 길어진다. softmax 분모가 커지므로, 그 비중은 자연히 줄어든다. 이 직관이
128 부등식으로 나타난다.

129 레이어 ℓ 에서 query 벡터를 $\mathbf{q}_i^{(\ell)}$, 실제 토큰의 key 벡터를 $\mathbf{k}_j^{(\ell)}$ ($j \in [n]$), RSP 토큰의 key 벡터를
130 $\mathbf{k}_{r_{j'}}^{(\ell)}$ ($j' \in [L]$)로 쓴다. 사전 스케일 logit gap을

$$\Delta_i^{(\ell)} := \min_{j \in [n]} (\mathbf{q}_i^{(\ell)})^\top \mathbf{k}_j^{(\ell)} - \max_{j' \in [L]} (\mathbf{q}_i^{(\ell)})^\top \mathbf{k}_{r_{j'}}^{(\ell)}$$

131 로 정의한다.

132 **정리 1** (캐시 성장에 의한 RSP 어텐션 envelope 감소). *scaled-dot-product* 어텐션에서

$$w_{r,i}^{(\ell)} \leq \frac{L}{L + n \exp(\Delta_i^{(\ell)}/\sqrt{d})}$$

133 가 성립한다. 우변은 L 과 $\Delta_i^{(\ell)}$ 를 고정한 채 n 에 대해 엄격히 감소한다. 따라서 *fixed-gap setting*
134 에서 $n \rightarrow \infty$ 이면 이 upper envelope는 0으로 수렴한다.

135 *Proof.* 실제 토큰과 RSP 토큰의 scaled attention score를 각각

$$s_j^{(\ell)} := \frac{(\mathbf{q}_i^{(\ell)})^\top \mathbf{k}_j^{(\ell)}}{\sqrt{d}} \quad (j \in [n]), \quad s_{r_{j'}}^{(\ell)} := \frac{(\mathbf{q}_i^{(\ell)})^\top \mathbf{k}_{r_{j'}}^{(\ell)}}{\sqrt{d}} \quad (j' \in [L])$$

136 로 쓰고, RSP score의 최대를 $s_{r,\max}^{(\ell)} := \max_{j' \in [L]} s_{r_{j'}}^{(\ell)}$, RSP score 합을 $R^{(\ell)} := \sum_{j'=1}^L \exp(s_{r_{j'}}^{(\ell)})$
137 로 둔다. $\Delta_i^{(\ell)}/\sqrt{d}$ 의 정의에서 모든 $j \in [n]$ 에 대해 $s_j^{(\ell)} \geq s_{r,\max}^{(\ell)} + \Delta_i^{(\ell)}/\sqrt{d}$ 이 성립한다. 또한
138 $\exp(s_{r,\max}^{(\ell)}) \geq R^{(\ell)}/L$ 이다. 따라서

$$\sum_{j=1}^n \exp(s_j^{(\ell)}) \geq n \exp(\Delta_i^{(\ell)}/\sqrt{d}) \cdot R^{(\ell)}/L.$$

139 softmax 정규화에서

$$w_{r,i}^{(\ell)} = \frac{R^{(\ell)}}{\sum_{j=1}^n \exp(s_j^{(\ell)}) + R^{(\ell)}} \leq \frac{L}{L + n \exp(\Delta_i^{(\ell)}/\sqrt{d})}.$$

140 $f(n) := L/(L + n \exp(\Delta_i^{(\ell)}/\sqrt{d}))$ 라 두면 $f'(n) = -L \exp(\Delta_i^{(\ell)}/\sqrt{d})/(L + n \exp(\Delta_i^{(\ell)}/\sqrt{d}))^2 <$
141 0이므로 $f(n)$ 은 n 에 대해 엄격히 감소하고, L 과 $\Delta_i^{(\ell)}$ 가 고정되면 $n \rightarrow \infty$ 에서 $f(n) \rightarrow 0$ 이
142 다. $\square$

143 이 부등식 한 줄에 두 메커니즘이 동시에 담겨 있다. RSP 길이 L 은 우리가 정하는 설계 파라미터
144 다. 분자에 들어가 최대 영향력을 결정한다. 반면 실제 토큰 수 n 은 매 step 자동으로 늘어 분모를
145 키운다. 같은 L 아래에서도 영향력의 상계는 시간이 갈수록 좁아진다. 정리가 보장하는 범위는
146 같은 layer, 같은 query 위치, 같은 logit gap 아래에서 RSP attention의 상한 envelope이 시퀀스 길
147 이 방향으로 좁아진다는 점뿐이다. 즉 autoregressive position 방향의 attenuation이지 layer 깊이
148 방향의 monotonic decay는 아니다. 새 토큰이 생성될 때마다 query · key · hidden state가 갱신되고
149 $\Delta_i^{(\ell)}$ 도 시간에 따라 변한다. 따라서 “실현된 attention mass의 매 step 단조 감소”가 아니라 “같은
150 gap이 유지되는 한 가능한 최대값의 단조 envelope 감소”가 정확하다. 결과적으로 RSP 효과는
151 생성 초반에 가장 크다. 토큰 누적과 함께 envelope이 줄어진다. 그래서 별도 schedule 없이
152 디코딩 자체가 explore-then-exploit 어닐링을 만든다. Figure 1는 이 sequence-direction 예측을
153 실증한다.

154 이 결과는 “RSP가 모델을 흔들면서도 망가뜨리지 않는 이유”를 attention-local 수준에서 설
155 명한다. RSP가 주입하는 무작위 기여 항의 disturbance energy는 $V_{\eta,i}^{(\ell)} := \mathbb{E} \|\mathbf{n}_i^{(\ell)}\|^2$ 이다. Ap-
156 pendix E.1에서 이 양은 $V_{\eta,i}^{(\ell)} \leq M_v^{(\ell)} (w_{r,i}^{(\ell)})^2$ 로 상계된다. Theorem 1와 결합하면, 같은 layer ·
157 query · logit gap 아래에서 이 상계는 시퀀스 길이 방향으로 $O(1/n^2)$ 로 좁아진다. 즉 RSP는
158 attention-local 수준에서 크기가 통제되는 *transient disturbance*로 해석할 수 있다. 다만 우리는
159 전체 hidden-state trajectory $\|h_t^{\text{RSP}} - h_t^{\text{base}}\|$ 의 감소를 주장하지 않는다. layer 방향 단조 안정성도
160 주장하지 않는다. transformer가 어떤 전역 함수를 최소화한다는 주장 역시 하지 않는다. 본문
161 결과는 어디까지나 attention-local disturbance term의 상계다.




Figure 1: Qwen2.5-Math-7B에서 측정한 토큰 어텐션 질량(suffix, MATH-500 500문제, 문제마다 독립 RSP). (a) RSP 토큰 어텐션은 추론 위치 축(가로)에서 감소한다. 이 양상은 Theorem 1의 cache-growth 상계와 일치한다. 레이어 축(세로)의 추가 감소는 별도의 경험적 현상이다. 깊은 레이어에서 실제 토큰과 RSP 토큰 사이의 logit gap이 더 날카로워지는 경향을 시사하지만, Theorem 1만으로 직접 따라오지는 않는다. (b) 질문 토큰 어텐션은 비교적 균일하게 유지된다. 그림에 보고한 양은 Appendix F의 per-token mass다. RSP 길이 L 로 나눈 평균 값이며, 본문 $w_{r,i}^{(\ell)}$ 와는 상수배 관계다.

3.3 등방 가우시안의 미니맥스 정당성

§3.2은 RSP가 어떻게 어텐션 출력에 들어가는지를 설명했다. 분포 선택 자체는 아직 정당화하지 않았다. 학습된 고정 prompt, 어휘 토큰 무작위 추첨, 임베딩 공분산 정합 같은 자연스러운 대안도 후보로 떠오를 수 있다.

문제마다 분기를 가르는 결정적 방향이 다르고 미리 알 수도 없다. 그래서 한두 방향에 힘을 몰아주는 노이즈는 다른 방향을 덜 탐색하게 만든다. 모든 방향을 가장 고르게 탐색하려면 분산 예산을 어느 방향에도 치우치지 않게 분배하는 분포가 필요하다.

이 요건을 미니맥스로 형식화하면 다음과 같다.

정리 2 (방향 무관 미니맥스 커버리지). $\mathbb{R}^d$ 위 평균 0 분포 D 가 분산 예산 $\text{tr}(\Sigma_D) \leq \rho^2$ 를 만족한다고 하자. 그러면

$$\min_{\|b\|=1} \text{Var}_{h \sim D}(b^\top h) = \lambda_{\min}(\Sigma_D) \leq \rho^2/d$$

이 성립한다. 등호는 $\Sigma_D = (\rho^2/d)\mathbf{I}_d$ 일 때에만 성립한다.

Proof. $\text{Var}_{h \sim D}(b^\top h) = b^\top \Sigma_D b$ 이다. 임의 대칭 공분산에서 $\min_{\|b\|=1} b^\top \Sigma_D b = \lambda_{\min}(\Sigma_D)$ 이 성립한다. Σ_D 의 고유값을 $\lambda_1 \leq \dots \leq \lambda_d$ 로 두자. 그러면 $d\lambda_1 \leq \sum_m \lambda_m = \text{tr}(\Sigma_D) \leq \rho^2$ 이므로 $\lambda_{\min} = \lambda_1 \leq \rho^2/d$. 등호는 모든 고유값이 같을 때, 즉 $\Sigma_D = (\rho^2/d)\mathbf{I}_d$ 일 때에만 성립한다. $\square$

같은 분산 예산 아래에서 “가장 덜 탐색되는 방향”을 가장 크게 만드는 분포는 등방 가우시안이 유일하다. 다른 후보들은 이 기준에서 차례로 탈락한다. 학습된 고정 prompt는 분산 자체가 0이라 어떤 방향도 탐색하지 못한다. PCA 정렬 노이즈는 방향이 치우쳐 직교 보완 공간을 덜 탐색한다. 어휘 토큰 추첨은 방향 편향에 더해 사전학습이 새겨 둔 의미 prior까지 끌어들이다. “경험적 임베딩 공분산 그대로 사용”조차도 등방이 아닌 한 적어도 한 방향에서 더 적게 탐색한다. 결국 RSP는 스케일은 임베딩에서 빌려 오되 방향 기하는 의도적으로 버리는 설계가 된다. 등방 가우시안은 $\mathbb{R}^d$ 전역에서 양의 밀도를 가진다(full support). 그래서 어떤 방향에 대해서도 사전 가중치를 두지 않는다는 의미적 중립성이 자동으로 따라온다(자세한 형식 statement는 Lemma 1).

3.4 출력 지지 집합 확장과 Pass@N 누적

두 결과를 결합하면 한 번의 RSP가 출력 분포에 무엇을 할 수 있는지가 정해진다. 다만 무엇을 할 수밖에 없는지는 아니다. 어텐션 단의 비영(非零) 영향(§3.2)과 모든 방향에 양의 확률(§3.3)이 만난다고 하자. 그러면 baseline에서 거의 보이지 않던 토큰이 어떤 prompt 추첨에서는 답 후보권 안으로 들어올 수 있다. 단, 그런 영역이 surrogate 위에 존재한다는 가정 아래에서다. 메커니즘은 영역에 양의 확률을 부여할 뿐, 영역 자체의 존재를 자동으로 보장하지는 않는다.

단발 진입 확률이 작더라도 독립 재추첨이 그 확률을 빠르게 누적시킨다. N 번의 새로운 RSP 가운데 적어도 한 번 진입할 확률은 1에 지수 속도로 다가간다. 한편 temperature sampling은 logit의 단조 변환이라 토큰 순위를 절대 바꾸지 못한다. 그래서 이 영역에는 도달할 수 없다.

194 중심화된 prompt $\bar{h}$ 근방에서 logit을 1차로 근사한 surrogate를 $z_i^{\text{lin}}(\bar{h}) := z_i + a_i^\top \bar{h}$, $a_i := \nabla_{\bar{h}} z_i(0)$
 195 로 둔다. baseline 외 토큰 i 의 top- K 진입 영역은 i 보다 높은 surrogate logit을 갖는 토큰이 $K-1$
 196 개 이하인 prompt들의 집합

$$\mathcal{G}_{i,K} := \{\bar{h} \in \mathbb{R}^d : \#\{j \neq i : z_j^{\text{lin}}(\bar{h}) > z_i^{\text{lin}}(\bar{h})\} \leq K-1\}$$

197 으로 정의한다 (이 정의는 실제 top- K 정의와 정확히 맞는다). 어떤 $\bar{h}_0$ 에서 i 가 다른 후보를
 198 엄격한 마진으로 충분히 앞선다고 하자. 그러면 $\mathcal{G}_{i,K}$ 가 비공집합 열린집합을 포함한다. 등방
 199 가우시안의 full support가 그 영역에 양의 확률을 부여한다. 따라서 $\mathcal{G}_{i,K}$ 가 비공집합 열린집합
 200 을 포함하는 토큰 i 에 대해 단발 진입 확률 $\mu_i := \Pr_{\bar{h}}(\bar{h} \in \mathcal{G}_{i,K}) > 0$ 이 성립한다. 이 명제가
 201 Proposition 2의 조건부 claim이다(정식 statement와 증명: Appendix E).

202 이 단발 확률을 task accuracy로 끌어올리려면 task-side 가정이 하나 필요하다. (M1) 단발 RSP
 203 실행이 정답 trajectory를 만들 주변 확률 $p_{\min}(x) > 0$ 이 양수다. (M2) N 번의 실행은 상호 독립
 204 이다. 두 가정 아래 Proposition 3은 다음 부등식을 준다.

$$\Pr(\text{Pass}@ (N+1) \text{ on } x) \geq \max\{p_{\text{base}}(x), 1 - (1 - p_{\min}(x))^N\} \geq 1 - \exp(-N p_{\min}(x)).$$

205 메커니즘이 보장하는 범위는 branch가 열린다는 데까지다 ($\mu_i > 0$). 열린 branch가 생산적이
 206 라는 점 ($p_{\min}(x) > 0$)은 task의 성질이지, mechanism만으로 도출되는 결과가 아니다. (M1)이
 207 성립하기만 하면 N 이 커질수록 정답 trajectory에 도달할 확률이 1로 지수 속도로 다가간다.
 208 같은 RSP를 모든 sample이 공유하면 이 논적이 사라진다. 이 사실은 독립이 핵심임을 메커니즘
 209 차원에서 다시 한번 확인해 준다. (M1)의 경험적 흔적, 곧 RSP가 만든 새 의미 클러스터에 정답
 210 trajectory가 포함된다는 사실은 §4에서 직접 확인한다.

211 4 실험적 확인

212 앞 절의 설명이 실제 LLM 생성에서 어떻게 드러나는지를 세 장면으로 살펴본다. 먼저 RSP가
 213 baseline 정확도를 크게 깎지 않으면서 일부 설정에서는 오히려 회복시키는지를 확인하고 (§4.2),
 214 다음으로 생성 초반에 토큰 분포가 평탄해졌다가 후반에는 baseline 수준으로 돌아오는 자동
 215 어닐링이 실제로 관찰되는지를 살펴 (§4.3), 끝으로 같은 RSP를 재사용할 때와 매 시도마다
 216 새로 뽑을 때의 Pass@ N 차이가 독립성이 핵심이라는 점을 직접 보여 주는지를 본다 (§4.4).

217 4.1 실험 설정

218 평가는 세 가지 수학 추론 벤치마크 MATH-500 [Lightman et al., 2024], GSM8K [Cobbe et al.,
 219 2021], AIME24에서 수행한다. 모델은 LLaMA-3.1-8B-Instruct [Grattafiori et al., 2024]와
 220 Qwen2.5-Math 계열 [Yang et al., 2024]을 쓰며, instruct, base, 그리고 chat template이 맞지 않
 221 는 base 설정까지 합쳐 총 일곱 가지를 비교한다. 모든 실험은 sampling 자체의 무작위성과 RSP
 222 효과를 분리하기 위해 greedy decoding을 사용하고, fallback 기반 answer extraction pipeline으로
 223 최종 답만 채점한다. RSP는 §3.1의 정의를 따르며 prefix/infix/suffix 세 주입 위치 중 하나에 매
 224 배치마다 새로 주입된 $\mathbf{H}$ 를 결합한다. 전체 실험 설정과 위치별 결과는 Appendix A에 있다.

225 4.2 RSP는 추론 성능을 개선할까?

226 먼저 무작위 임베딩 주입이 모델의 추론 성능에 어떤 영향을 주는지 본다. Table 1는 각 벤치마크
 227 에서 주입 위치(Prefix, Infix, Suffix)와 $L \in \{10, 15, 20\}$ 가운데 가장 좋은 RSP 결과를 보고한다.

228 instruct model과 원래 프롬프트 형식을 쓰는 base model에서는 RSP가 baseline 성능을 대체로
 229 몇 퍼센트포인트 이내에서 유지하거나 소폭만 이동시킨다. 더 눈에 띄는 것은 프롬프트 형식
 230 불일치 상황이다. 즉, 채팅 형식으로 학습되지 않은 base model에 ChatML template을 주입했을
 231 때, RSP는 최대 +29%p까지의 큰 성능 향상을 보인다. 단순히 불확실성을 높이는 노이즈였다
 232 면 오히려 성능 저하가 커졌어야 하므로, 이 결과는 RSP 효과가 단순한 교란을 넘는다는 점을
 233 시사한다.

234 또한 RSP를 TTSV, SoftCoT, LTPO처럼 서로 다른 목적 함수로 임베딩을 최적화하는 기존 soft
 235 prompt 방법과 비교했다. Table 2은 공통 answer extraction pipeline 아래에서 다시 평가한 결과
 236 를 보여준다. 각 방법은 프롬프트 형식과 채점 규칙이 다르지만, fallback 기반 추출을 사용해
 237 형식에 덜 민감한 비교를 수행했다. 결과적으로 RSP는 추가 학습 없이도 최적화 기반 방법과
 238 맞먹는 수준의 성능을 보인다.

Table 1: 모델 설정과 벤치마크별 정확도(%). RSP는 주입 위치(Prefix, Infix, Suffix) 중 최고 성능만 보고한다. 위치별 전체 결과는 Appendix A에 있다. 괄호 안 값은 baseline 대비 변화량이다.

Model	MATH-500		GSM8K		AIME24	
	Baseline	RSP	Baseline	RSP	Baseline	RSP
<i>Instruct Models</i>						
LLaMA-3.1-8B-Inst	52.20	49.40 (−2.8)	85.75	86.73 (+1.0)	6.67	10.00 (+3.3)
Qwen2.5-Math-7B-Inst	83.20	84.20 (+1.0)	95.45	95.68 (+0.2)	13.33	16.67 (+3.3)
Qwen2.5-Math-1.5B-Inst	73.00	75.20 (+2.2)	85.29	85.75 (+0.5)	10.00	20.00 (+10.0)
<i>Base Models (Raw Text)</i>						
Qwen2.5-Math-7B	72.20	71.60 (−0.6)	84.15	84.31 (+0.2)	6.67	16.67 (+10.0)
Qwen2.5-Math-1.5B	61.40	64.40 (+3.0)	77.86	74.30 (−3.6)	16.67	10.00 (−6.7)
<i>Base Models + ChatML (Format Mismatch)</i>						
Qwen2.5-Math-7B	52.20	70.40 (+18.2)	58.30	75.97 (+17.7)	23.33	23.33 (+0.0)
Qwen2.5-Math-1.5B	34.40	63.40 (+29.0)	37.45	67.02 (+29.6)	13.33	20.00 (+6.7)

Table 2: 기존 soft prompt 방법(TTSV, SoftCoT, LTPO)과의 통합 평가 비교. Baseline과 RSP 값은 Table 1에서 가져왔다. **Bold**는 최고 성능, underline은 두 번째 성능이다.

Model	Benchmark	Baseline	RSP	TTSV	SoftCoT	LTPO
Qwen2.5-Math-7B-Instruct	MATH-500	83.20	84.20	83.80	82.80	83.00
	GSM8K	<u>95.45</u>	95.68	95.30	95.00	94.84
	AIME24	13.33	16.67	23.30	16.67	13.33
Qwen2.5-Math-1.5B-Instruct	MATH-500	73.00	<u>75.20</u>	<u>75.20</u>	76.00	72.40
	GSM8K	85.29	85.75	<u>85.70</u>	84.46	84.53
	AIME24	<u>10.00</u>	20.00	6.70	6.67	<u>10.00</u>

4.3 RSP는 출력 분포를 어떻게 바꾸는가?

다음으로 RSP 주입이 생성 과정의 출력 분포를 어떻게 바꾸는지 살펴본다. 설정은 Qwen2.5-Math-1.5B-Instruct와 MATH-500이며, 토큰별 entropy, top-1 probability, varentropy를 생성 단계에 따라 측정한다. Figure 2와 Table 3는 생성 초반 5% 구간에서 RSP 변형과 기존 soft prompt 방법을 비교한 결과다.




Figure 2: 생성 초반 5% 구간의 평균 entropy, top-1 probability, varentropy (Qwen2.5-Math-1.5B-Instruct, MATH-500). 음영은 ± 1 SEM이다. 실선은 RSP 변형과 baseline, 점선은 기존 soft prompt 방법(LTPO, SoftCoT, TTSV)이다.

결과는 RSP가 생성 초반 출력 분포를 분명히 바꾼다는 점을 보여준다. 세 주입 위치 모두에서 entropy는 증가하고, top-1 probability는 감소하며, varentropy는 증가한다. 이는 분포가 평평해지고, 단일 우세 토큰에 대한 확신은 약해지며, 다봉형 분포가 더 자주 나타남을 뜻한다 [Ahmed et al., 2026]. 높은 entropy 구간은 추론 궤적이 갈라지는 핵심 분기점으로 알려져 있으므로 [Wang et al., 2025], 이 변화는 여러 추론 경로가 공존할 수 있는 상태로 모델을 밀어 넣는다. 중요한 점은 변화가 생성 초반에 국한된다는 것이다. 생성 중반과 후반에서는 세 지표 모두 baseline 수준으로 다시 수렴한다.

Table 3: 생성 초반 5% 구간의 평균 entropy, top-1 probability, varentropy (Qwen2.5-Math-1.5B-Instruct, MATH-500).

Metric	Baseline	Prefix	Infix	Suffix	LTPO	SoftCoT	TTSV
Entropy	0.1332	0.1366	0.1402	0.1941	0.1662	0.4218	0.1359
Top-1 Prob	0.9535	0.9523	0.9525	0.9373	0.9437	0.9156	0.9534
Varentropy	0.2181	0.2207	0.2463	0.4010	0.2953	2.2234	0.2174

서로 다른 목적 함수로 학습된 기존 방법들도 같은 패턴을 공유한다. 평균 entropy를 줄이는 보상을 쓰는 TTSV조차 초반 구간만큼은 baseline과 비슷하거나 더 높아, 이 entropy 상승은 특정 최적화 목적이 아니라 사전학습되지 않은 연속 임베딩 주입 자체에 가까운 효과로 보인다.

4.4 RSP는 실제로 추론 궤적의 다양성을 만드는가?

Section 4.3는 RSP가 생성 초반 출력 분포를 바꾼다는 사실을 보였다. 이제 이 변화가 실제 추론 다양성으로 이어지는지를 세 수준에서 살펴본다. 분석 수준은 토큰 순위, 궤적의 의미적 내용, 과제 수준 결과다. 세 분석 모두 Qwen2.5-Math-1.5B-Instruct, MATH-500, suffix 주입, $L = 10$ 설정을 공유한다.

먼저 토큰 수준에서 보면, 자기회귀 생성에서 baseline과 RSP의 궤적 차이는 결국 첫 토큰에서 시작될 수밖에 없으므로 baseline $\tau=1.0$ 을 기준으로 단순 flattening의 상한인 baseline $\tau=2.0$ 과 RSP $\tau=1.0$ 을 비교한다. 세 지표—Spearman rank correlation ρ , baseline top-10 밖 확률 질량, Jensen–Shannon divergence—는 각각 순위 재배치, 지지 집합 확장, 분포 변화의 크기를 잡아낸다(정의는 Appendix C). Table 4에서 baseline top-10 밖으로 이동하는 질량은 $\tau=2.0$ 에서 5.15%에 그치지만 RSP $\tau=1.0$ 에서는 27.64%이고, Spearman 상관은 1에서 0.651로 떨어진다. Temperature는 단조 변환이라 어떤 τ 에서도 순위를 보존하므로 $\rho = 1$ 이 강제되는 반면, RSP는 순위 자체를 뒤섞는다 — §3.4의 surrogate 수준에서 보인 branch opening의 직접 흔적. JS divergence 0.231은 이 변화의 전체 크기를 요약한다.

Table 4: Baseline $\tau=1.0$ 을 기준으로 본 첫 토큰 분포 지표. Baseline $\tau=2.0$ 과 RSP $\tau=1.0$ 을 비교한다.

Metric	$\tau=2.0$	RSP
Spearman ρ	1.0	0.651
Mass outside top-10	5.15%	27.64%
JS divergence	0.086	0.231

한 단계 위인 궤적 수준에서는, 첫 토큰의 재배치가 실제로 의미적으로 다른 추론 경로를 여는지가 관건이다. 이를 위해 MATH-500에서 무작위로 64개 문제를 뽑고, Baseline과 RSP 두 조건에서 각 문제마다 temperature $\tau = 1.0$ 으로 300개의 독립 궤적을 생성했다. 각 궤적은 BGE-M3 [Chen et al., 2024]로 임베딩한 뒤, 문제 내 평균 pairwise cosine distance, DBSCAN [Ester et al., 1996] 클러스터 중심 사이의 inter-cluster distance, 그리고 intra-cluster distance를 계산했다. Table 5는 RSP가 intra-cluster distance는 거의 바꾸지 않으면서 inter-cluster distance를 크게 키운다는 점을 보여준다. 즉, 각 전략 내부의 일관성은 유지하면서 전략 간 거리를 벌린다. Pairwise distance 기준으로 RSP는 64개 중 56개 문제(87.5%)에서 baseline보다 컸다.

Table 5: 64개 문제에 대해 평균한 의미적 다양성 지표.

Metric	Baseline	RSP
Pairwise cos. dist.	0.0612	0.0879
Inter-cluster dist.	0.0183	0.0982
Intra-cluster dist.	0.0526	0.0528

Figure 3(a)에서 RSP 샘플(파랑)은 baseline 영역을 포함하면서 baseline이 도달하지 못한 별도 클러스터까지 확장되고, 그 영역에도 정답 궤적이 포함된다. (b), (c)는 64개 문제 전반에 걸쳐 RSP가 더 많은 클러스터와 더 큰 pairwise cosine distance를 만든다는 패턴이 반복됨을 보여준다. 즉 RSP는 클러스터 내부 진행은 흐트러뜨리지 않으면서 궤적이 진입하는 전략 클러스터 자체를 바꾼다. 문제별 추가 t-SNE는 Appendix B에 있다.

마지막 결과 수준에서는, 이러한 다양성이 실제 과제 성과로 이어지는지를 Pass@ N 로 본다 (N 개의 샘플 중 적어도 하나가 정답일 확률). MATH-500과 AIME24에서 문제당 $N = 16$, 네 조건을 비교한다. (i) baseline + $\tau=1.0$, (ii) RSP를 모든 샘플이 공유 + $\tau=1.0$, (iii) 샘플마다 독립 RSP + greedy, (iv) 샘플마다 독립 RSP + $\tau=1.0$.

조건 (iv)가 두 벤치마크 모두에서 가장 높은 Pass@ N 을 달성하며 $N = 16$ 에서 MATH-500 92.80%, AIME24 36.67%에 이른다. (ii)는 baseline 대비 거의 개선이 없어, 다양성 이득의 핵심이 고정 섭동이 아니라 샘플마다 독립된 무작위 임베딩임을 드러낸다. Pass@1은 MATH-500




Figure 3: 64개 MATH-500 문제에서의 의미적 다양성 분석(문제당 300개 궤적, Qwen2.5-Math-1.5B-Instruct, $\tau = 1.0$, BGE-M3 임베딩). (a) 대표 문제 `test/prealgebra/951`의 t-SNE 투영: baseline(빨강)은 한 영역에 비교적 집중되지만, RSP suffix(파랑)는 더 넓고 분리된 군집까지 확장된다. 채워진 표식은 정답, 빈 표식은 오답이다. (b) 문제별 평균 pairwise cosine distance. 대각선 위 점은 RSP가 baseline보다 더 다양한 궤적을 만든다는 뜻이다. (c) 문제별 DBSCAN 클러스터 수. 대부분의 문제에서 RSP가 더 많은 클러스터를 만든다.




Figure 4: Qwen2.5-Math-1.5B-Instruct에서의 Pass@ N 스케일링. 좌측은 MATH-500, 우측은 AIME24이며, 문제당 $N = 16$ 개의 샘플을 사용했다. Baseline은 temperature sampling만, fixed seed는 고정된 하나의 RSP와 temperature를 함께 쓴 경우, indep. seed는 샘플마다 다른 RSP를 쓰는 경우다.

295 에서 baseline 수준을 유지하고 더 어려운 AIME24에서는 (iv)가 더 높아, 독립 RSP + temperature
296 결합이 단일 샘플 정확도를 해치지 않으면서 추론 궤적을 다양화한다.

297 5 결론

298 본 논문은 사전학습 임베딩 행렬의 항별 통계만 빌려 등방 가우시안에서 추출한 RSP가 학습
299 없이 LLM 추론에 영향을 주는 이유를 transformer 수준에서 분석했다. 분석은 어텐션 분해 (§3.2),
300 등방성의 미니맥스 정당성 (§3.3), 그리고 surrogate 위 출력 지지 집합 확장과 독립 재추첨의 결합
301 (§3.4)을 거쳐 $\Pr(\text{Pass}@ (N+1)) \geq 1 - \exp(-Np_{\min})$ 의 지수 saturation 하한으로 달렸다. §4의 세
302 실험은 이 부등식이 예측한 baseline 회복, 자동 어닐링, 독립 재추첨의 누적을 차례로 확인했다.
303 RSP는 순위를 바꾸는 섭동이고 temperature는 순위를 보존하는 섭동이므로 둘은 직교적이며,
304 이는 GRPO [Shao et al., 2024]의 entropy collapse를 DAPO [Yu et al., 2025], CE-GPPO [Su et al.,
305 2026] 너머에서 샘플링 단계로 보완할 가능성을 시사한다. RSP를 활용한 학습 시점 비교, 수학
306 추론을 넘어선 도메인 확장, RSP 길이·주입 위치의 원리적 결정은 향후 과제다.

307 References

- 308 Farhan Ahmed, Yuya Jeremy Ong, and Chad DeLuca. LogitScope: A Framework for Analyzing
309 LLM Uncertainty through Information Metrics. In *ICLR Workshop*, 2026.
- 310 Nora Belrose, Igor Ostrovsky, Lev McKinney, Zach Furman, Logan Smith, Danny Halawi, Stella
311 Biderman, and Jacob Steinhardt. Eliciting Latent Predictions from Transformers with the Tuned
312 Lens. *arXiv:2303.08112*, 2023.

313 Jianlyu Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, and Zheng Liu. M3-
314 Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through
315 Self-Knowledge Distillation. In *Findings of ACL*, 2024.

316 Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser,
317 Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, Christopher Hesse, and John
318 Schulman. Training Verifiers to Solve Math Word Problems. *arXiv:2110.14168*, 2021.

319 Jeremy M. Cohen, Elan Rosenfeld, and J. Zico Kolter. Certified Adversarial Robustness via Random-
320 ized Smoothing. In *ICML*, 2019.

321 Timothée Darcet, Maxime Oquab, Julien Mairal, and Piotr Bojanowski. Vision Transformers Need
322 Registers. In *ICLR*, 2024.

323 Martin Ester, Hans-Peter Kriegel, Jörg Sander, and Xiaowei Xu. A Density-Based Algorithm for
324 Discovering Clusters in Large Spatial Databases with Noise. In *KDD*, 1996.

325 Meire Fortunato, Mohammad Gheshlaghi Azar, Bilal Piot, Jacob Menick, Ian Osband, Alex Graves,
326 Vlad Mnih, Remi Munos, Demis Hassabis, Olivier Pietquin, Charles Blundell, and Shane Legg.
327 Noisy Networks for Exploration. In *ICLR*, 2018.

328 Mor Geva, Roei Schuster, Jonathan Berant, and Omer Levy. Transformer Feed-Forward Layers Are
329 Key-Value Memories. In *EMNLP*, 2021.

330 Sachin Goyal, Ziwei Ji, Ankit Singh Rawat, Aditya Krishna Menon, Sanjiv Kumar, and Vaishnavh
331 Nagarajan. Think before You Speak: Training Language Models with Pause Tokens. In *ICLR*,
332 2024.

333 Aaron Grattafiori, Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad
334 Al-Dahle, Aiesha Letman, Akhil Mathur, Alan Schelten, Alex Vaughan, Amy Yang, Angela Fan,
335 Anirudh Goyal, Anthony Hartshorn, Aobo Yang, Archi Mitra, Archie Sravankumar, Artem Ko-
336 renev, Arthur Hinsvark, Arun Rao, Aston Zhang, Aurelien Rodriguez, Austen Gregerson, Ava
337 Spataru, Baptiste Roziere, Bethany Biron, Binh Tang, Bobbie Chern, Charlotte Caucheteux, Chaya
338 Nayak, Chloe Bi, Chris Marra, Chris McConnell, Christian Keller, Christophe Touret, Chunyang
339 Wu, Corinne Wong, Cristian Canton Ferrer, Cyrus Nikolaidis, Damien Allonsius, Daniel Song,
340 Danielle Pintz, Danny Livshits, Danny Wyatt, David Esiobu, Dhruv Choudhary, Dhruv Mahajan,
341 Diego Garcia-Olano, Diego Perino, Dieuwke Hupkes, Egor Lakomkin, Ehab AlBadawy, Elina
342 Lobanova, Emily Dinan, Eric Michael Smith, Filip Radenovic, Francisco Guzmán, Frank Zhang,
343 Gabriel Synnaeve, Gabrielle Lee, Georgia Lewis Anderson, Govind Thattai, Graeme Nail, Gre-
344 goire Mialon, Guan Pang, Guillem Cucurell, Hailey Nguyen, Hannah Korevaar, Hu Xu, Hugo
345 Touvron, Iliyan Zarov, Imanol Arrieta Ibarra, Isabel Kloumann, Ishan Misra, Ivan Evtimov, Jack
346 Zhang, Jade Copet, Jaewon Lee, Jan Geffert, Jana Vranes, Jason Park, Jay Mahadeokar, Jeet Shah,
347 Jelmer van der Linde, Jennifer Billock, Jenny Hong, Jenya Lee, Jeremy Fu, Jianfeng Chi, Jianyu
348 Huang, Jiawen Liu, Jie Wang, Jiecao Yu, Joanna Bitton, Joe Spisak, Jongsoo Park, Joseph Rocca,
349 Joshua Johnstun, Joshua Saxe, Junteng Jia, Kalyan Vasuden Alwala, Karthik Prasad, Kartikeya
350 Upasani, Kate Plawiak, Ke Li, Kenneth Heafield, Kevin Stone, Khalid El-Arini, Krithika Iyer,
351 Kshitiz Malik, Kuenley Chiu, Kunal Bhalla, Kushal Lakhotia, Lauren Rantala-Yearly, Laurens
352 van der Maaten, Lawrence Chen, Liang Tan, Liz Jenkins, Louis Martin, Lovish Madaan, Lubo
353 Malo, Lukas Blecher, Lukas Landzaat, Luke de Oliveira, Madeline Muzzi, Mahesh Pasupuleti,
354 Mannat Singh, Manohar Paluri, Marcin Kardas, Maria Tsimpoukelli, Mathew Oldham, Mathieu
355 Rita, Maya Pavlova, Melanie Kambadur, Mike Lewis, Min Si, Mitesh Kumar Singh, Mona Has-
356 san, Naman Goyal, Narjes Torabi, Nikolay Bashlykov, Nikolay Bogoychev, Niladri Chatterji, Ning
357 Zhang, Olivier Duchenne, Onur Çelebi, Patrick Alrassy, Pengchuan Zhang, Pengwei Li, Petar Va-
358 sic, Peter Weng, Prajjwal Bhargava, Pratik Dubal, Praveen Krishnan, Punit Singh Koura, Puxin
359 Xu, Qing He, Qingxiao Dong, Ragavan Srinivasan, Raj Ganapathy, Ramon Calderer, Ricardo Sil-
360 veira Cabral, Robert Stojnic, Roberta Raileanu, Rohan Maheswari, Rohit Girdhar, Rohit Patel,
361 Romain Sauvestre, Ronnie Polidoro, Roshan Sumbaly, Ross Taylor, Ruan Silva, Rui Hou, Rui
362 Wang, Saghar Hosseini, Sahana Chennabasappa, Sanjay Singh, Sean Bell, Seohyun Sonia Kim,
363 Sergey Edunov, Shaoliang Nie, Sharan Narang, Sharath Rapparthi, Sheng Shen, Shengye Wan,
364 Shruti Bhosale, Shun Zhang, Simon Vandenhende, Soumya Batra, Spencer Whitman, Sten Sootla,
365 Stéphane Collot, Suchin Gururangan, Sydney Borodinsky, Tamar Herman, Tara Fowler, Tarek
366 Sheasha, Thomas Georgiou, Thomas Scialom, Tobias Speckbacher, Todor Mihaylov, Tong Xiao,

367 Ujjwal Karn, Vedanuj Goswami, Vibhor Gupta, Vignesh Ramanathan, Viktor Kerkez, Vincent
 368 Gonguet, Virginie Do, Vish Vogeti, Vitor Albiero, Vladan Petrovic, Weiwei Chu, Wenhan Xiong,
 369 Wenyin Fu, Whitney Meers, Xavier Martinet, Xiaodong Wang, Xiaofang Wang, Xiaoqing Ellen
 370 Tan, Xide Xia, Xinfeng Xie, Xuchao Jia, Xuewei Wang, Yaelle Goldschlag, Yashesh Gaur, Yas-
 371 mine Babaei, Yi Wen, Yiwen Song, Yuchen Zhang, Yue Li, Yuning Mao, Zacharie Delpierre
 372 Coudert, Zheng Yan, Zhengxing Chen, Zoe Papakipos, Aaditya Singh, Aayushi Srivastava, Abha
 373 Jain, Adam Kelsey, Adam Shajnfeld, Adithya Gangidi, Adolfo Victoria, Ahuva Goldstand, Ajay
 374 Menon, Ajay Sharma, Alex Boesenberg, Alexei Baevski, Allie Feinstein, Amanda Kallet, Amit
 375 Sangani, Amos Teo, Anam Yunus, Andrei Lupu, Andres Alvarado, Andrew Caples, Andrew Gu,
 376 Andrew Ho, Andrew Poulton, Andrew Ryan, Ankit Ramchandani, Annie Dong, Annie Franco,
 377 Anuj Goyal, Aparajita Saraf, Arkabandhu Chowdhury, Ashley Gabriel, Ashwin Bharambe, As-
 378 saf Eisenman, Azadeh Yazdan, Beau James, Ben Maurer, Benjamin Leonhardi, Bernie Huang,
 379 Beth Loyd, Beto De Paola, Bhargavi Paranjape, Bing Liu, Bo Wu, Boyu Ni, Braden Hancock,
 380 Bram Wasti, Brandon Spence, Brani Stojkovic, Brian Gamido, Britt Montalvo, Carl Parker, Carly
 381 Burton, Catalina Mejia, Ce Liu, Changan Wang, Changkyu Kim, Chao Zhou, Chester Hu, Ching-
 382 Hsiang Chu, Chris Cai, Chris Tindal, Christoph Feichtenhofer, Cynthia Gao, Damon Civin, Dana
 383 Beaty, Daniel Kreymer, Daniel Li, David Adkins, David Xu, Davide Testuggine, Delia David,
 384 Devi Parikh, Diana Liskovich, Didem Foss, Dingkan Wang, Duc Le, Dustin Holland, Edward
 385 Dowling, Eissa Jamil, Elaine Montgomery, Eleonora Presani, Emily Hahn, Emily Wood, Eric-
 386 Tuan Le, Erik Brinkman, Esteban Arcaute, Evan Dunbar, Evan Smothers, Fei Sun, Felix Kreuk,
 387 Feng Tian, Filippus Kokkinos, Firat Ozgenel, Francesco Caggioni, Frank Kanayet, Frank Seide,
 388 Gabriela Medina Florez, Gabriella Schwarz, Gada Badeer, Georgia Swee, Gil Halpern, Grant Her-
 389 man, Grigory Sizov, Guangyi Zhang, Guna Lakshminarayanan, Hakan Inan, Hamid Shojanazeri,
 390 Han Zou, Hannah Wang, Hanwen Zha, Haroun Habeeb, Harrison Rudolph, Helen Suk, Henry
 391 Aspegren, Hunter Goldman, Hongyuan Zhan, Ibrahim Damlaj, Igor Molybog, Igor Tufanov, Il-
 392 ias Leontiadis, Irina-Elena Veliche, Itai Gat, Jake Weissman, James Geboski, James Kohli, Janice
 393 Lam, Japhet Asher, Jean-Baptiste Gaya, Jeff Marcus, Jeff Tang, Jennifer Chan, Jenny Zhen, Jeremy
 394 Reizenstein, Jeremy Teboul, Jessica Zhong, Jian Jin, Jingyi Yang, Joe Cummings, Jon Carvill, Jon
 395 Shepard, Jonathan McPhie, Jonathan Torres, Josh Ginsburg, Junjie Wang, Kai Wu, Kam Hou U,
 396 Karan Saxena, Kartikay Khandelwal, Katayoun Zand, Kathy Matosich, Kaushik Veeraraghavan,
 397 Kelly Michelen, Keqian Li, Kiran Jagadeesh, Kun Huang, Kunal Chawla, Kyle Huang, Lailin
 398 Chen, Lakshya Garg, Lavender A, Leandro Silva, Lee Bell, Lei Zhang, Liangpeng Guo, Licheng
 399 Yu, Liron Moshkovich, Luca Wehrstedt, Madian Khabsa, Manav Avalani, Manish Bhatt, Martynas
 400 Mankus, Matan Hasson, Matthew Lennie, Matthias Reso, Maxim Groshev, Maxim Naumov, Maya
 401 Lathi, Meghan Keneally, Miao Liu, Michael L. Seltzer, Michal Valko, Michelle Restrepo, Mihir
 402 Patel, Mik Vyatskov, Mikayel Samvelyan, Mike Clark, Mike Macey, Mike Wang, Miquel Jubert
 403 Hermoso, Mo Metanat, Mohammad Rastegari, Munish Bansal, Nandhini Santhanam, Natascha
 404 Parks, Natasha White, Navyata Bawa, Nayan Singhal, Nick Egebo, Nicolas Usunier, Nikhil Mehta,
 405 Nikolay Pavlovich Laptev, Ning Dong, Norman Cheng, Oleg Chernoguz, Olivia Hart, Omkar
 406 Salpekar, Ozlem Kalinli, Parkin Kent, Parth Parekh, Paul Saab, Pavan Balaji, Pedro Rittner, Philip
 407 Bontrager, Pierre Roux, Piotr Dollar, Polina Zvyagina, Prashant Ratanchandani, Pritish Yuvraj,
 408 Qian Liang, Rachad Alao, Rachel Rodriguez, Rafi Ayub, Raghotham Murthy, Raghu Nayani,
 409 Rahul Mitra, Rangaprabhu Parthasarathy, Raymond Li, Rebekkah Hogan, Robin Battey, Rocky
 410 Wang, Russ Howes, Ruty Rinott, Sachin Mehta, Sachin Siby, Sai Jayesh Bondu, Samyak Datta,
 411 Sara Chugh, Sara Hunt, Sargun Dhillon, Sasha Sidorov, Satadru Pan, Saurabh Mahajan, Saurabh
 412 Verma, Seiji Yamamoto, Sharadh Ramaswamy, Shaun Lindsay, Shaun Lindsay, Sheng Feng,
 413 Shenghao Lin, Shengxin Cindy Zha, Shishir Patil, Shiva Shankar, Shuqiang Zhang, Shuqiang
 414 Zhang, Sinong Wang, Sneha Agarwal, Soji Sajuyigbe, Soumith Chintala, Stephanie Max, Stephen
 415 Chen, Steve Kehoe, Steve Satterfield, Sudarshan Govindaprasad, Sumit Gupta, Summer Deng,
 416 Sungmin Cho, Sunny Virk, Suraj Subramanian, Sy Choudhury, Sydney Goldman, Tal Remez,
 417 Tamar Glaser, Tamara Best, Thilo Koehler, Thomas Robinson, Tianhe Li, Tianjun Zhang, Tim
 418 Matthews, Timothy Chou, Tzook Shaked, Varun Vontimitta, Victoria Ajayi, Victoria Montanez,
 419 Vijai Mohan, Vinay Satish Kumar, Vishal Mangla, Vlad Ionescu, Vlad Poenaru, Vlad Tiberiu
 420 Mihailescu, Vladimir Ivanov, Wei Li, Wenchen Wang, Wenwen Jiang, Wes Bouaziz, Will Con-
 421 stable, Xiaocheng Tang, Xiaoqian Wu, Xiaolan Wang, Xilun Wu, Xinbo Gao, Yaniv Kleinman,
 422 Yanjun Chen, Ye Hu, Ye Jia, Ye Qi, Yenda Li, Yilin Zhang, Ying Zhang, Yossi Adi, Youngjin
 423 Nam, Yu Wang, Yu Zhao, Yuchen Hao, Yundi Qian, Yunlu Li, Yuzi He, Zach Rait, Zachary De-
 424 Vito, Zef Rosnbrick, Zhaoduo Wen, Zhenyu Yang, Zhiwei Zhao, and Zhiyu Ma. The Llama 3
 425 Herd of Models. *arXiv:2407.21783*, 2024.

426 Shibo Hao, Sainbayar Sukhbaatar, DiJia Su, Xian Li, Zhiting Hu, Jason Weston, and Yuandong Tian.
427 Training Large Language Models to Reason in a Continuous Latent Space. In *ICLR*, 2025.

428 Neil Houlsby, Andrei Giurgiu, Stanislaw Jastrzebski, Bruna Morrone, Quentin de Laroussilhe, An-
429 drea Gesmundo, Mona Attariyan, and Sylvain Gelly. Parameter-Efficient Transfer Learning for
430 NLP. In *ICML*, 2019.

431 Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang,
432 and Weizhu Chen. LoRA: Low-Rank Adaptation of Large Language Models. In *ICLR*, 2022.

433 Neel Jain, Ping-yeh Chiang, Yuxin Wen, John Kirchenbauer, Hong-Min Chu, Gowthami Somepalli,
434 Brian R. Bartoldson, Bhavya Kailkhura, Avi Schwarzschild, Aniruddha Saha, Micah Goldblum,
435 Jonas Geiping, and Tom Goldstein. NEFTune: Noisy Embeddings Improve Instruction Finetuning.
436 In *ICLR*, 2024.

437 Xinyue Kang, Diwei Shi, and Li Chen. Model Whisper: Steering Vectors Unlock Large Language
438 Models’ Potential in Test-time. In *AAAI*, 2026.

439 Brian Lester, Rami Al-Rfou, and Noah Constant. The Power of Scale for Parameter-Efficient Prompt
440 Tuning. In *EMNLP*, 2021.

441 Xiang Lisa Li and Percy Liang. Prefix-Tuning: Optimizing Continuous Prompts for Generation. In
442 *ACL-IJCNLP*, 2021.

443 Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike,
444 John Schulman, Ilya Sutskever, and Karl Cobbe. Let’s Verify Step by Step. In *ICLR*, 2024.

445 Xiao Liu, Yanan Zheng, Zhengxiao Du, Ming Ding, Yujie Qian, Zhilin Yang, and Jie Tang. GPT
446 Understands, Too. *AI Open*, 5:208–215, 2024.

447 Aman Madaan and Amir Yazdanbakhsh. Text and Patterns: For Effective Chain of Thought, It Takes
448 Two to Tango. *arXiv:2209.07686*, 2022.

449 Alexander Robey, Eric Wong, Hamed Hassani, and George J. Pappas. SmoothLLM: Defending Large
450 Language Models Against Jailbreaking Attacks. *Transactions on Machine Learning Research*,
451 2025.

452 Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang,
453 Mingchuan Zhang, Y.K. Li, Y. Wu, and Daya Guo. DeepSeekMath: Pushing the Limits of Math-
454 ematical Reasoning in Open Language Models. *arXiv:2402.03300*, 2024.

455 Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov.
456 Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *Journal of Machine Learn-
457 ing Research*, 15:1929–1958, 2014.

458 Zhenpeng Su, Lei Yu, Minxuan Lv, Yuntao Li, Wenping Hu, Fuzheng Zhang, Kun Gai, and
459 Guorui Zhou. CE-GPPO: Coordinating Entropy via Gradient-Preserving Clipping Policy Opti-
460 mization in Reinforcement Learning. In *ACL*, 2026.

461 Shenzhi Wang, Le Yu, Chang Gao, Chujie Zheng, Shixuan Liu, Rui Lu, Kai Dang, Xionghui Chen,
462 Jianxin Yang, Zhenru Zhang, Yuqiong Liu, An Yang, Andrew Zhao, Yang Yue, Shiji Song, Bowen
463 Yu, Gao Huang, and Junyang Lin. Beyond the 80/20 Rule: High-Entropy Minority Tokens Drive
464 Effective Reinforcement Learning for LLM Reasoning. In *NeurIPS*, 2025.

465 Yige Xu, Xu Guo, Zhiwei Zeng, and Chunyan Miao. SoftCoT: Soft Chain-of-Thought for Efficient
466 Reasoning with LLMs. In *ACL*, 2025.

467 An Yang, Beichen Zhang, Binyuan Hui, Bofei Gao, Bowen Yu, Chengpeng Li, Dayiheng Liu,
468 Jianhong Tu, Jingren Zhou, Junyang Lin, Keming Lu, Mingfeng Xue, Runji Lin, Tianyu Liu,
469 Xingzhang Ren, and Zhenru Zhang. Qwen2.5-Math Technical Report: Toward Mathematical
470 Expert Model via Self-Improvement. *arXiv:2409.12122*, 2024.

471 Wengao Ye, Yan Liang, and Lianlei Shan. Thinking on the Fly: Test-Time Reasoning Enhancement
472 via Latent Thought Policy Optimization. In *ICLR*, 2026.

- 473 Qiying Yu, Zheng Zhang, Ruofei Zhu, Yufeng Yuan, Xiaochen Zuo, Yu Yue, Weinan Dai, Tiantian
474 Fan, Gaohong Liu, Juncai Liu, Lingjun Liu, Xin Liu, Haibin Lin, Zhiqi Lin, Bole Ma, Guangming
475 Sheng, Yuxuan Tong, Chi Zhang, Mofan Zhang, Ru Zhang, Wang Zhang, Hang Zhu, Jinhua Zhu,
476 Jiaze Chen, Jiangjie Chen, Chengyi Wang, Hongli Yu, Yuxuan Song, Xiangpeng Wei, Hao Zhou,
477 Jingjing Liu, Wei-Ying Ma, Ya-Qin Zhang, Lin Yan, Yonghui Wu, and Mingxuan Wang. DAPO:
478 An Open-Source LLM Reinforcement Learning System at Scale. In *NeurIPS*, 2025.
- 479 Guibin Zhang, Muxin Fu, and Shuicheng Yan. MemGen: Weaving Generative Latent Memory for
480 Self-Evolving Agents. In *ICLR*, 2026.

481 A 실험 설정과 전체 정확도 분석

482 Table 6은 본문 Table 1에서 위치별 최고 성능만 요약해 제시한 결과를, Prefix, Infix, Suffix 별 전체
 483 정확도로 다시 펼쳐 보인다. Table 7는 각 모델-벤치마크 조합에서 사용한 RSP 토큰 수 L 을 정리
 484 한 것으로, 후보 집합 {10, 15, 20}에서 선택했다. 모든 실험은 단일 NVIDIA A6000 40GB GPU
 485 에서 greedy decoding으로 수행했으며, 최대 생성 길이는 MATH-500과 GSM8K에서 3,072 토큰,
 486 AIME24에서 4,096 토큰으로 고정했다. 배치 크기는 모델별로 고정했다(LLaMA-3.1-8B-Instruct
 487 와 Qwen2.5-Math-7B 계열은 16, Qwen2.5-Math-1.5B 계열은 32).

Table 6: 모델 설정, 주입 위치, 벤치마크별 정확도(%). 괄호 안 값은 baseline 대비 변화량이다. 굵게는 최고 성능, 밑줄은 각 모델-벤치마크 조합에서 두 번째 성능을 뜻한다.

Model	Mode	MATH-500	GSM8K	AIME24
<i>Instruct Models</i>				
LLaMA-3.1-8B-Instruct	Baseline	52.20	85.75	<u>6.67</u>
	Prefix	45.00 (−7.2)	76.35 (−9.4)	3.33 (−3.3)
	Infix	<u>49.40</u> (−2.8)	85.97 (+0.2)	10.00 (+3.3)
	Suffix	<u>49.40</u> (−2.8)	86.73 (+1.0)	10.00 (+3.3)
Qwen2.5-Math-7B-Instruct	Baseline	83.20	95.45	<u>13.33</u>
	Prefix	81.40 (−1.8)	94.92 (−0.5)	<u>13.33</u> (+0.0)
	Infix	84.20 (+1.0)	<u>95.60</u> (+0.2)	16.67 (+3.3)
	Suffix	<u>83.40</u> (+0.2)	95.68 (+0.2)	16.67 (+3.3)
Qwen2.5-Math-1.5B-Instruct	Baseline	73.00	85.29	10.00
	Prefix	74.80 (+1.8)	85.29 (+0.0)	<u>13.33</u> (+3.3)
	Infix	75.20 (+2.2)	85.75 (+0.5)	<u>6.67</u> (−3.3)
	Suffix	74.20 (+1.2)	84.69 (−0.6)	20.00 (+10.0)
<i>Base Models (Raw Text)</i>				
Qwen2.5-Math-7B	Baseline	72.20	<u>84.15</u>	6.67
	Prefix	<u>71.60</u> (−0.6)	84.31 (+0.2)	16.67 (+10.0)
	Infix	63.20 (−9.0)	64.29 (−19.9)	16.67 (+10.0)
	Suffix	55.60 (−16.6)	54.13 (−30.0)	<u>13.33</u> (+6.7)
Qwen2.5-Math-1.5B	Baseline	<u>61.40</u>	77.86	16.67
	Prefix	64.40 (+3.0)	<u>74.30</u> (−3.6)	<u>10.00</u> (−6.7)
	Infix	63.20 (+1.8)	73.92 (−3.9)	<u>10.00</u> (−6.7)
	Suffix	54.60 (−6.8)	58.61 (−19.3)	3.33 (−13.3)
<i>Base Models + ChatML (Format Mismatch)</i>				
Qwen2.5-Math-7B	Baseline	52.20	58.30	23.33
	Prefix	59.20 (+7.0)	56.41 (−1.9)	<u>3.33</u> (−20.0)
	Infix	<u>62.00</u> (+9.8)	69.07 (+10.8)	23.33 (+0.0)
	Suffix	70.40 (+18.2)	75.97 (+17.7)	23.33 (+0.0)
Qwen2.5-Math-1.5B	Baseline	34.40	37.45	<u>13.33</u>
	Prefix	63.40 (+29.0)	67.02 (+29.6)	20.00 (+6.7)
	Infix	39.20 (+4.8)	50.42 (+13.0)	6.67 (−6.7)
	Suffix	<u>51.00</u> (+16.6)	<u>50.64</u> (+13.2)	<u>13.33</u> (+0.0)

Table 7: 각 모델과 벤치마크에 사용한 RSP 토큰 수 (L).

Model	MATH-500	GSM8K	AIME24
LLaMA-3.1-8B-Instruct	15	20	15
Qwen2.5-Math-7B-Instruct	20	20	20
Qwen2.5-Math-1.5B-Instruct	20	10	20
Qwen2.5-Math-7B	10	10	20
Qwen2.5-Math-1.5B	10	10	20
Qwen2.5-Math-1.5B (ChatML)	20	20	10
Qwen2.5-Math-7B (ChatML)	20	20	20

488 A.1 RSP 주입 위치와 프롬프트 템플릿

489 아래에는 모든 모델 유형에서 주입 위치별 프롬프트 구조를 정리했다. **파란색 텍스트**는 RSP
 490 임베딩, **보라색 텍스트**는 특수 토큰을 뜻한다.

491 A.1.1 Prefix

492 Prefix 주입에서는 RSP 임베딩을 프롬프트 임베딩 앞에 연결한다. 텍스트 자체는 수정하지
493 않는다.

494 ChatML (Qwen Instruct / Base + ChatML).

```
[Random Embeddings (L tokens)]
<|im_start|>system
Please reason step by step, and put your final answer within \boxed{<|im_end|>
<|im_start|>user
{question}<|im_end|>
<|im_start|>assistant
```

496 LLaMA Chat Template.

```
[Random Embeddings (L tokens)]
<|begin_of_text|>
<|start_header_id|>system<|end_header_id|>
Cutting Knowledge Date: December 2023
Today Date: 26 Jul 2024
Please reason step by step, and put your final answer within \boxed{<|eot_id|>
<|start_header_id|>user<|end_header_id|>
{question}<|eot_id|>
<|start_header_id|>assistant<|end_header_id|>
```

498 Raw Text (Qwen Base).

```
[Random Embeddings (L tokens)]
{question}
Please reason step by step, and put your final answer within \boxed{<|im_end|>
```

500 A.1.2 Infix

501 Infix 주입에서는 설명 문구와 특수 토큰을 프롬프트 내부에 넣은 뒤, 그 특수 토큰 위치를 임베딩
502 수준에서 RSP로 교체한다.

503 ChatML (Qwen Instruct / Base + ChatML).

```
<|im_start|>system
Please reason step by step, and put your final answer within \boxed{<|im_end|>
<|im_start|>user
{question}

There are {L} special tokens that contain compressed latent reasoning
information that might be useful for your reasoning. If these tokens are
useful for your case, you can use them as reference. If these tokens are
not useful for your case, you can ignore them and focus back to solving the
problem.

Here are the {L} special tokens: <special_token_1>...<special_token_L>
<|im_end|>
<|im_start|>assistant
```

505 LLaMA Chat Template.

```
<|begin_of_text|>
<|start_header_id|>system<|end_header_id|>
Cutting Knowledge Date: December 2023
Today Date: 26 Jul 2024
Please reason step by step, and put your final answer within \boxed{<|im_end|>
```

```

eot_id|>
<|start_header_id|>user<|end_header_id|>
{question}

There are {L} special tokens that contain compressed latent reasoning
information that might be useful for your reasoning. If these tokens are
useful for your case, you can use them as reference. If these tokens are
not useful for your case, you can ignore them and focus back to solving the
problem.

Here are the {L} special tokens:
<reserved_special_token_0>...
<reserved_special_token_L>
<|eot_id|>
<|start_header_id|>assistant<|end_header_id|>

```

507

508 Raw Text (Qwen Base).

```

{question}

There are {L} special tokens that contain compressed latent reasoning
information that might be useful for your reasoning. If these tokens are
useful for your case, you can use them as reference. If these tokens are
not useful for your case, you can ignore them and focus back to solving the
problem.

Here are the {L} special tokens: <special_token_1>...<special_token_L>
Please reason step by step, and put your final answer within \boxed{ }.

```

509

510 A.1.3 Suffix

511 채팅 템플릿 모델에서는 end-of-turn 토큰 바로 앞에 RSP 임베딩을 넣고, raw text 모델에서는
512 프롬프트 마지막에 RSP 임베딩을 이어 붙인다.

513 ChatML (Qwen Instruct / Base + ChatML).

```

<|im_start|>system
Please reason step by step, and put your final answer within \boxed{ }.<|
im_end|>
<|im_start|>user
{question}[Random Embeddings (L tokens)]<|im_end|>
<|im_start|>assistant

```

514

515 LLaMA Chat Template.

```

<|begin_of_text|>
<|start_header_id|>system<|end_header_id|>
Cutting Knowledge Date: December 2023
Today Date: 26 Jul 2024
Please reason step by step, and put your final answer within \boxed{ }.<|
eot_id|>
<|start_header_id|>user<|end_header_id|>
{question}[Random Embeddings (L tokens)]<|eot_id|>
<|start_header_id|>assistant<|end_header_id|>

```

516

517 Raw Text (Qwen Base).

```

{question}
Please reason step by step, and put your final answer within \boxed{ }.[Random
Embeddings (L tokens)]

```

518

519 A.2 정답 추출과 채점

520 최종 정답은 fallback 체인을 통해 모델 출력에서 추출한다. 각 단계는 순서대로 시도하며, 추출에
521 실패하면 다음 단계로 넘어간다.

정답 추출 fallback 체인

1. "final answer is \$...\$. I hope" 패턴 (Minerva 형식)
2. `\boxed{...}`: 마지막 비어 있지 않은 box를 사용하고, 빈 `\boxed{}`는 건너뛰
3. "the answer is" 뒤 텍스트
4. "final answer is" 뒤 텍스트
5. 출력 마지막 숫자(regex fallback)

522

523 추출된 정답은 `$`, `\left`, `\right`, 단위 문자열을 제거해 정규화한다. 채점은 sym-
524 bolic equivalence checking으로 수행하며, 정확한 문자열 일치, 수치 비교(`math.isclose`,
525 `rel_tol=1e-4`), SymPy symbolic simplification을 차례로 적용한다.

526 A.3 재현한 선행연구의 하이퍼파라미터

527 모든 선행 방법은 Qwen2.5-Math-1.5B-Instruct와 Qwen2.5-Math-7B-Instruct에서 재현했으며,
528 greedy decoding(`temperature = 0`)과 통일된 answer extraction pipeline으로 평가했다.

529 **TTSV.** Prefix 길이는 20이며, AdamW optimizer로 20 epoch 동안 학습했다. 배치 크기는 2,
530 gradient accumulation은 8 step, 스케줄은 선형 learning rate schedule을 사용했다. Learning rate
531 는 Qwen-1.5B에 1e-3, Qwen-7B에 1e-5를 사용했다.

532 **LTPO.** Table 8는 벤치마크별 하이퍼파라미터를 정리한 것이다.

Table 8: LTPO 하이퍼파라미터.

Parameter	GSM8K	MATH-500	AIME24
tokens	8	8	8
steps	20	20	20
top_k	10	10	10
sigma	20	20	5
sigma_decay	0.95	0.95	0.95
lr	1e-2	5e-3	5e-2

533 **SoftCoT.** Projection module은 10 epoch 동안 학습했다. Thought token 수는 학습 시 32, 평가 시
534 4다. 배치 크기는 GSM8K에서 4, MATH에서는 1이며 gradient accumulation 4를 사용했다. 작은
535 모델(assistant)은 두 설정 모두 Qwen2.5-Math-1.5B-Instruct이고, 큰 모델은 Qwen2.5-Math-1.5B-
536 Instruct(`learning rate 2e-5`) 또는 Qwen2.5-Math-7B-Instruct(`learning rate 5e-6`)이다. MATH-500
537 과 AIME24 평가는 GSM8K에서 학습한 projection module을 사용했는데, MATH에서 학습한
538 버전보다 더 높은 정확도를 보였기 때문이다.

539 A.4 전체 엔트로피 곡선

540 Figure 5는 entropy, top-1 probability, varentropy의 전체 정규화 생성 궤적(0-100%)을 보여준다.
541 모든 방법은 생성 초반 단계를 지나면 비슷한 수준으로 수렴하며, 이는 RSP가 유도하는 분포
542 변화가 초기 추론 단계에 국소화되어 있음을 다시 확인해 준다.




Figure 5: 전체 정규화 생성 궤적(0-100%)에서의 평균 entropy(위), top-1 probability(가운데), varentropy(아래). MATH-500 전체 평균이며, 음영은 ± 1 SEM을 뜻한다. 실선은 RSP 변형과 baseline, 점선은 기존 soft prompt 방법이다. 모든 방법은 초반 단계를 지나면 수렴한다.

543 B 의미적 다양성에 대한 추가 분석

544 이 부록은 Section 4.4에서 보고한 의미적 다양성 결과를 보충한다. 더 넓은 문제 집합에 대해
545 문제별 t-SNE 도표를 함께 제시한다.



Figure 6: 평가한 64개 MATH-500 문제 중 48개에 대한 BGE-M3 임베딩의 t-SNE 투영(6×8 격자). 각 subplot은 Qwen2.5-Math-1.5B-Instruct에서 $\tau = 1.0$ 으로 생성한 baseline 300개(빨강)와 RSP suffix 300개(파랑)를 보여준다. 채워진 표식은 정답, 빈 표식은 오답이며, 제목은 subject/problem_id를 뜻한다. 대부분의 문제에서 RSP 궤적은 여러 개의 분리된 영역으로 퍼지는 반면, baseline 샘플은 하나의 지배적 클러스터에 더 집중된다.

546 C 토큰 수준 분포 지표

547 이 부록은 Section 4.4의 토큰 수준 분석에 사용한 세 지표를 형식적으로 정의한다. P_{base} 는
548 $\tau = 1.0$ 에서의 baseline 다음 토큰 분포, P_{target} 은 비교 대상 분포(예: $\tau = 2.0$ 의 baseline, 또는
549 $\tau = 1.0$ 의 RSP)라 하자. 모든 지표는 첫 생성 단계에서 저장한 logits로부터 해석적으로 계산
550 한다.

551 **Spearman 순위 상관.** Spearman의 ρ 는 두 분포의 토큰 순위 사이 Pearson 상관계수다.

$$\rho = \text{Pearson}(\text{rank}(P_{\text{target}}), \text{rank}(P_{\text{base}})). \quad (3)$$

552 Temperature scaling $P^{(\tau)} \propto P^{1/\tau}$ 는 엄격한 단조 변환이므로, 어떤 $\tau > 0$ 에서도 토큰 순서를
553 정확히 보존한다. 따라서 $\rho = 1$ 은 수학적 항등식이다. 그러므로 $\rho < 1$ 은 temperature scaling
554 만으로는 만들 수 없는 순위 재조작이 일어났음을 뜻한다.

555 **Top- K 밖의 질량.** $\text{TopK}(P_{\text{base}})$ 를 P_{base} 에서 확률이 가장 높은 K 개 토큰의 집합이라 하자. 비
556 교 대상 분포가 이 집합 *밖에* 두는 확률 질량은

$$\text{MassOutside}_K = 1 - \sum_{t \in \text{TopK}(P_{\text{base}})} P_{\text{target}}(t). \quad (4)$$

557 이 지표는 지지 집합 확장을 직접 측정한다. 즉 baseline의 선호 집합에 없던 토큰에 비교 대상이
558 얼마나 많은 확률을 배정하는지를 본다. 본문에 보고한 값은 $K = 10$ 을 사용했다.

559 **Jensen-Shannon divergence.** Kullback-Leibler divergence의 대칭적이고 bounded된 형태는 다
560 음과 같다.

$$\text{JS}(P, Q) = \frac{1}{2} \text{KL}(P \parallel M) + \frac{1}{2} \text{KL}(Q \parallel M), \quad M = \frac{1}{2}(P + Q). \quad (5)$$

561 로그는 밑이 2이므로 $\text{JS} \in [0, 1]$ 이다. 저장한 top-100 바깥의 토큰에는 softmax 전에 sentinel
562 $\text{logit}(-10^9)$ 을 넣었는데, 본 설정에서는 top-5가 이미 확률 질량의 99.9% 이상을 덮기 때문에 이
563 근사는 무시 가능하다.

564 D 무작위 프롬프트는 왜 의미적으로 중립적이고 방향적으로 포괄적인가

565 이 부록은 Section 3.3에서 사용한 주장을 형식화한다. 핵심은 무작위 프롬프트가 유용한 잠재
566 의미를 담고 있다는 것이 아니다. 더 약하고 정확한 주장은, 중심화한 뒤에는 어떤 미리 정한
567 의미 방향도 체계적으로 편들지 않으면서도, 고정된 분산 예산 아래 모든 방향을 덮을 수 있다는
568 것이다. 이는 언어학적 의미가 완전히 사라진다는 주장이 아니라, 섭동 방향의 기하학적 성질에
569 관한 명제다.

570 D.1 의미적 중립성

571 $\bar{h} \sim \mathcal{N}(0, \sigma^2 \mathbf{I}_d)$ 라 하고, $\bar{h} \neq 0$ 일 때 $\hat{h} := \bar{h}/\|\bar{h}\|$ 라 하자. 또한 $u_1, \dots, u_M \in \mathbb{S}^{d-1}$ 를 의미
572 anchor 방향을 나타내는 임의의 고정 단위벡터라 하자.

573 **보조정리 1** (의미적 중립성). 보편 상수 C 가 존재하여, 모든 $\delta \in (0, 1)$ 에 대해

$$\Pr \left[\max_{r \in [M]} |\hat{h}^\top u_r| \leq C \sqrt{\frac{\log(M/\delta)}{d}} \right] \geq 1 - \delta.$$

574 즉 등방성 가우시안 프롬프트의 정규화된 방향은, 고정된 유한 개의 의미 anchor 전체에 대해
575 높은 확률로 거의 직교한다.

576 *Proof.* 각 고정 u_r 에 대해 회전 불변성으로부터 $u_r^\top \bar{h} \sim \mathcal{N}(0, \sigma^2)$ 가 성립하므로,

$$\Pr(|u_r^\top \bar{h}| \geq t) \leq 2 \exp\left(-\frac{t^2}{2\sigma^2}\right).$$

577 $r \in [M]$ 전체에 대해 union bound를 적용하면

$$\Pr \left[\max_{r \in [M]} |u_r^\top \bar{h}| \geq t \right] \leq 2M \exp\left(-\frac{t^2}{2\sigma^2}\right).$$

578 한편 표준 chi-square concentration으로부터 보편 상수 $c > 0$ 가 존재하여

$$\Pr \left[\|\bar{h}\| \leq \frac{\sigma\sqrt{d}}{2} \right] \leq \exp(-cd)$$

579 가 성립한다. 사건 $\|\bar{h}\| \geq \sigma\sqrt{d}/2$ 위에서는

$$|\hat{h}^\top u_r| = \frac{|u_r^\top \bar{h}|}{\|\bar{h}\|} \leq \frac{2|u_r^\top \bar{h}|}{\sigma\sqrt{d}}.$$

580 이제

$$t = C' \sigma \sqrt{\log(M/\delta)}$$

581 로 두고 C' 를 충분히 큰 상수로 잡으면, 두 bound를 결합해

$$\max_{r \in [M]} |\hat{h}^\top u_r| \leq C \sqrt{\frac{\log(M/\delta)}{d}}$$

582 가 적어도 $1 - \delta$ 확률로 성립한다. □

583 토큰 임베딩과의 대비는 즉각적이다. $e_s \neq 0$ 를 고정된 토큰 임베딩이라 하고 $\hat{e}_s := e_s/\|e_s\|$ 라
584 하자. 이때 anchor 방향을 $u = \hat{e}_s$ 로 잡으면

$$|\hat{e}_s^\top u| = 1.$$

585 즉 토큰 프롬프트는 적어도 하나의 의미 방향과 최대 정렬을 이루지만, 등방성 무작위 프롬프트
586 는 어떤 고정된 유한 집합의 의미 방향에도 거의 직교한다. 우리가 말하는 “의미적 비개입성”은
587 바로 이 뜻이다. 토큰은 의미적 commitment를 주입하는 반면, 무작위 프롬프트는 의미적으로
588 특정 방향에 묶이지 않은 섭동으로 기능한다.

589 D.2 Theorem 2 (미니맥스 방향 커버리지)의 증명

590 본문에서 사용한 local linear logit surrogate에 직접 등장하는 양은 단위벡터 b 에 대해 b 방향의
 591 1차 섭동 에너지 $\text{Var}_{h \sim D}(b^\top h) = b^\top \Sigma_D b$ 이다. $\min_{\|b\|=1} b^\top \Sigma_D b = \lambda_{\min}(\Sigma_D)$ 이므로 최소 방향
 592 분산은 정확히 $\lambda_{\min}(\Sigma_D)$ 이다.

593 *Theorem 2의 증명.* Σ_D 의 고윳값을 $\lambda_1, \dots, \lambda_d$ 라 하면,

$$\lambda_{\min}(\Sigma_D) \leq \frac{1}{d} \sum_{m=1}^d \lambda_m = \frac{\text{tr}(\Sigma_D)}{d} \leq \frac{\rho^2}{d}.$$

594 모든 고윳값이 같을 때, 즉 $\Sigma_D = (\rho^2/d)\mathbf{I}_d$ 일 때 그리고 그럴 때만 등호가 성립한다. $\square$

595 이 정리는 등방성 무작위성의 장점을 형식화한다. RSP는 어떤 logit-sensitive 방향을 섭동해야
 596 하는지 사전에 알지 못하므로, 고정된 분산 예산 아래에서 등방성 분포는 모든 방향에 대한
 597 최악 경우 섭동량을 유일하게 최대화한다. 고정 토큰 프롬프트는 결정적 섭동이므로 $\Sigma_D = 0$
 598 이고 $\lambda_{\min} = 0$ 이며, 비등방 섭동은 항상 $\lambda_{\min}(\Sigma_D) < \rho^2/d$ 이므로 적어도 한 방향에서 등방
 599 최적해보다 덜 탐색하게 된다.

E 본문 이론 결과의 증명

E.1 RSP가 유도하는 섭동의 성질

본문 Eq. (2)의 분해 $\mathbf{x}_i^{(\ell+1)} = (1 - w_{r,i}^{(\ell)})\tilde{\mathbf{x}}_i^{(\ell+1)} + \boldsymbol{\eta}_i^{(\ell)}$ 에서 무작위 기여 항 $\boldsymbol{\eta}_i^{(\ell)} = \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{r_j}^{(\ell)}$ 의 통계적 성질을 분석한다. 입력층의 RSP는 등방 가우시안이지만, layer ℓ 에서의 value vector $\mathbf{v}_{r_j}^{(\ell)}$ 는 attention, residual, LayerNorm, FFN, value projection을 차례로 통과한 결과이므로 일반적으로 등방 가우시안이 아니다. 따라서 layer 이후의 분석은 *bounded second moment*만 가정한 형태로 약화하는 것이 안전하다.

조건부 기댓값과 상계. 입력층 statistics에 의해 layer-별 mean · norm을

$$m_v^{(\ell)} := \max_j \|\mathbb{E}[\mathbf{v}_{r_j}^{(\ell)}]\|, \quad M_v^{(\ell)} := \max_j \mathbb{E}\|\mathbf{v}_{r_j}^{(\ell)}\|^2 < \infty$$

라 두자(유한성은 implementation-side 가정으로 자연스럽다). 어텐션 가중치에 조건부로 두면

$$\|\mathbb{E}[\boldsymbol{\eta}_i^{(\ell)} \mid \alpha^{(\ell)}]\| \leq w_{r,i}^{(\ell)} m_v^{(\ell)}. \quad (6)$$

입력층($\ell = 0$)에서는 등방 RSP에 대해 $m_v^{(0)} = |\mu_E|$ 이며, 항별 평균이 0에 가까운 임베딩 행렬에서 작아진다 — Table 9 참조.

조건부 disturbance energy(Lyapunov-style upper bound). $V_{\eta,i}^{(\ell)} := \mathbb{E}\|\boldsymbol{\eta}_i^{(\ell)}\|^2$ 로 두면, Cauchy-Schwarz와 $\sum_j \alpha_{i,n+j}^{(\ell)} = w_{r,i}^{(\ell)}$ 에서

$$V_{\eta,i}^{(\ell)} \leq M_v^{(\ell)} (w_{r,i}^{(\ell)})^2. \quad (7)$$

이는 “RSP가 주입하는 disturbance energy의 상계가 w_r^2 로 통제된다”는 Lyapunov-style stability 진술이다 — 정확한 등방성을 layer 이후에도 가정할 필요 없이, value norm의 second moment 유한성만으로 충분하다.

시퀀스 방향 attenuation 결합. Theorem 1와 결합하면 같은 layer, 같은 query 위치, 같은 logit gap 아래에서 $w_{r,i}^{(\ell)} = O(1/n)$ 이고, Eq. (7)로부터 $V_{\eta,i}^{(\ell)} = O(1/n^2)$ 이다. layer 방향에 대한 단조 감소는 $M_v^{(\ell)}$, $\Delta_i^{(\ell)}$, hidden state geometry가 layer마다 달라지므로 일반적으로 보장되지 않는다 — 본문 Figure 1의 layer-축 감소는 이 정리의 직접 귀결이 아니라 deeper layer가 실제 토른 evidence에 더 정렬되는 별개의 경험적 현상이다.

입력층 등방성의 의미. 입력층에서는 RSP가 $\mathcal{N}(\mu_E \mathbf{1}_d, \sigma_E^2 \mathbf{I}_d)$ 로 정의되므로, 중심화한 $\bar{h}$ 는 정확히 등방이고 모든 방향에 양의 밀도(full support)를 갖는다. Lemma 1와 본문 §3.3, §3.4의 결과는 이 입력층 등방성을 직접 사용하므로 layer 이후의 등방성 보존을 요구하지 않는다.

Table 9: 임베딩 행렬 통계. 모든 모델에서 $|\mu_E|/\sigma_E < 0.02$ 이다.

Model	μ_E	σ_E	$ \mu_E /\sigma_E$
LLaMA-3.1-8B-Instruct	0.00002	0.01057	0.002
Qwen2.5-Math-7B-Instruct	-0.00002	0.01647	0.001
Qwen2.5-Math-1.5B-Instruct	0.00019	0.01585	0.012
Qwen2.5-Math-7B	-0.00003	0.01842	0.001
Qwen2.5-Math-1.5B	0.00038	0.02990	0.013

합의. 입력층에서 RSP가 $\mathcal{N}(\mu_E \mathbf{1}_d, \sigma_E^2 \mathbf{I}_d)$ 로 시작하므로 입력층의 평균 항은 작지만, layer 이후의 $\mathbf{v}_{r_j}^{(\ell)}$ 는 일반적으로 *bounded mean*만 가정한다. Eq. (7)는 이 약한 가정 아래에서도 RSP 기여의 disturbance energy가 attention-local 수준에서 $w_{r,i}^{(\ell)}$ 로 통제됨을 보장한다 — 그 이상의 “zero-mean noise처럼 동작한다”라는 강한 주장은 입력층에 한정된 해석이다.

628 E.2 Theorem 1 (Attention 감쇠)의 따름정리들

629 본문 §3.2의 Theorem 1이 제공하는 상계

$$w_{r,i}^{(\ell)} \leq \frac{L}{L + n \cdot \exp(\Delta_i^{(\ell)} / \sqrt{d})}$$

630 는 두 가지 따름정리를 갖는다. 본문 증명을 그대로 받아 다음을 보인다.

631 **따름정리 1** (fixed-gap envelope의 시퀀스 방향 단조 감소). L 과 $\Delta_i^{(\ell)}$ 를 고정하면, 상계

$$f(n) = \frac{L}{L + n \exp(\Delta_i^{(\ell)} / \sqrt{d})}$$

632 는 실제 토큰 수 n 에 대해 엄격히 감소한다. 따라서 동일한 logit gap을 유지한다는 가정 아래,
633 cache 성장만으로 그 gap과 양립 가능한 최대 RSP attention mass의 envelope이 단조롭게 줄어든
634 다.

635 자기회귀 디코딩에서는 새 토큰이 생성될 때마다 query · key · hidden state가 갱신되어 $\Delta_i^{(\ell)}$ 도
636 step별로 변하므로, “실현된 attention mass가 매 step 단조 감소한다”가 아니라 “동일한 gap이
637 유지되는 한 가능한 최대 mass의 envelope이 단조 감소한다”가 정확한 진술이다.

638 *Proof.* $f(n)$ 을 n 에 대해 미분하면

$$f'(n) = -\frac{L \exp(\Delta_i^{(\ell)} / \sqrt{d})}{\left(L + n \exp(\Delta_i^{(\ell)} / \sqrt{d})\right)^2} < 0.$$

639 따라서 $f(n)$ 은 엄격히 감소한다. □

640 **따름정리 2** (고정 gap envelope 아래의 disturbance energy 감쇠). L 과 $\Delta_i^{(\ell)}$ 를 고정하고 $n \rightarrow \infty$
641 이면 $w_{r,i}^{(\ell)} \rightarrow 0$ 이다. 본 절의 약화된 가정 하에서 attention-local disturbance energy는 다음과
642 같이 줄어든다.

$$\|\mathbb{E}[\eta_i^{(\ell)} \mid \alpha^{(\ell)}]\| \leq m_v^{(\ell)} w_{r,i}^{(\ell)} \rightarrow 0, \quad V_{\eta,i}^{(\ell)} \leq M_v^{(\ell)} (w_{r,i}^{(\ell)})^2 \rightarrow 0.$$

643 *Proof.* Corollary 1에서 $w_{r,i}^{(\ell)} \rightarrow 0$ 이고, 본 절의 평균 · second-moment 상계 $m_v^{(\ell)}, M_v^{(\ell)} < \infty$ 를
644 곱하면 결과가 따른다. □

645 E.3 출력 분포 이동에 대한 증명

646 본문은 출력 수준에서 두 가지 주장을 한다. Proposition 1은 쌍대 순위의 무작위화를, Propo-
647 sition 2은 그보다 한 단계 강한 후보 집합 확장을 다룬다. 두 주장 모두 섭동된 logits의 local
648 first-order surrogate에 대한 명제다.

649 E.3.1 자기회귀 정식화

650 자기회귀 decoding에서 시퀀스 $y_{1:T}$ 의 결합 분포는

$$\Pr(y_{1:T} \mid x) = \prod_{t=1}^T p(y_t \mid x, y_{<t}),$$

651 로 분해된다. 각 단계는 prefix에 조건부인 분포로 결정되므로, RSP가 도입한 섭동은 단일한
652 전역 분포를 한 번에 바꾸는 것이 아니라 $p(y_t \mid x, y_{<t})$ 에 대한 일련의 국소 변화로 작동한다.

653 E.3.2 RSP 하에서의 logits 국소 선형화

654 중심화된 random soft prompt를 $\bar{h}$ 라 하자. 섭동된 logits를 $\bar{h}$ 의 함수로 보고 $\bar{h} = 0$ 근방에서 국소
655 smoothness를 가정하면 $z_i(\bar{h}) = z_i + a_i^\top \bar{h} + O(\|\bar{h}\|^2)$ 이며, 여기서 $a_i := \nabla_{\bar{h}} z_i(0)$ 이다. 본문
656 §3.4와 같은 표기로 1차 surrogate를 $z_i^{\text{lin}}(\bar{h}) := z_i + a_i^\top \bar{h}$ 로 정의한다. 이 surrogate는 충분히 작은
657 $\|\bar{h}\|$ 에서 유효하며, transformer logits의 전역 모델이라기보다 섭동 방향을 설명하는 1차 근사다.

658 E.3.3 명제 1의 증명 (확률적 순위화)

659 **명제 1** (확률적 순위화). 토큰 쌍 (i, j) 중 $a_i \neq a_j$ 인 것이 존재하면, $0 < \Pr_{\bar{h}}(z_i^{\text{lin}}(\bar{h}) > z_j^{\text{lin}}(\bar{h})) <$
 660 1 이 성립한다.

661 *Proof.* $z_i^{\text{lin}}(\bar{h}) - z_j^{\text{lin}}(\bar{h}) = (z_i - z_j) + (a_i - a_j)^\top \bar{h}$ 이고, $b_{ij} := a_i - a_j \neq 0$ 이며 $\bar{h} \sim \mathcal{N}(0, \sigma^2 I)$
 662 이면 $b_{ij}^\top \bar{h} \sim \mathcal{N}(0, \sigma^2 \|b_{ij}\|^2)$ 인 비퇴화 가우시안이다. 따라서 섭동된 logit 차이는 0의 양쪽에
 663 모두 양의 확률 질량을 갖고, $0 < \Pr_{\bar{h}}(z_i^{\text{lin}}(\bar{h}) > z_j^{\text{lin}}(\bar{h})) < 1$ 이 성립한다. $\square$

664 E.3.4 명제 2의 증명 (지지 집합 확장)

665 **명제 2** (지지 집합 확장). 상태 s_t 에서 *baseline top-K* 집합을 $J_K(s_t)$ 라 하자. 어떤 토큰 $i \notin$
 666 $J_K(s_t)$ 에 대해 진입 영역

$$\mathcal{G}_{i,K} := \{\bar{h} \in \mathbb{R}^d : z_i^{\text{lin}}(\bar{h}) > z_j^{\text{lin}}(\bar{h}) \text{ for all } j \in J_K(s_t)\}$$

667 의 내부가 비어 있지 않다고 하자. $\bar{h}$ 를 등방성 가우시안에서 샘플링하면 $\Pr_{\bar{h}}(\bar{h} \in \mathcal{G}_{i,K}) > 0$ 이
 668 성립한다.

669 *Proof.* 1차 surrogate에서 토큰 i 가 $J_K(s_t)$ 의 모든 토큰을 앞지른다는 조건은 정확히 $\bar{h} \in \mathcal{G}_{i,K}$
 670 와 동치다. 각 부등식 $z_i^{\text{lin}}(\bar{h}) > z_j^{\text{lin}}(\bar{h})$ 은 열린 half-space를 정의하므로, 유한 개 열린 half-space
 671 의 교집합인 $\mathcal{G}_{i,K}$ 역시 열린 집합이다. 가정에 의해 내부가 비어 있지 않으므로 $\mathcal{G}_{i,K}$ 는 $\mathbb{R}^d$
 672 의 비공집합 열린집합이다. 등방성 가우시안은 $\mathbb{R}^d$ 전역에서 엄밀히 양수인 밀도를 가지므로
 673 비공집합 열린집합은 양의 확률 측도를 갖는다. 따라서 $\Pr_{\bar{h}}(\bar{h} \in \mathcal{G}_{i,K}) > 0$ 이며, 이것이 토큰 i
 674 의 top-K 진입 사건이다. $\square$

675 E.3.5 궤적 수준의 합의: 다중 경로 Pass@N

676 자기회귀 생성은 조건부 분포를 단계별로 합성하므로, 초기 단계의 섭동이 전혀 다른 궤적으로
 677 이어질 수 있다. 적어도 한 번 *baseline top-K* 바깥 토큰을 포함하는 궤적의 집합을 $\mathcal{R}_{L,K}(x)$
 678 라 하자. 만약 RSP가 초기 단계에서 이런 토큰의 접근 가능성을 높인다면, 반복 샘플링에서
 679 $\mathcal{R}_{L,K}(x)$ 에 속하는 궤적을 뽑을 확률도 증가한다. 핵심은 시간적 누적이다. 초반의 top-K 진입
 680 한 번이 다음 decoding state를 바꾸고, 그것이 다시 다음 후보 집합을 바꾸는 식으로 이어진다.
 681 이를 형식적으로 모으면 다음 명제가 된다.

682 **명제 3** (다중 경로 Pass@N). 문제 x 를 고정하고 정답 궤적 집합 $\mathcal{T}^*(x)$ 가 비어 있지 않다고 하자.
 683 *baseline* 정답 지시자를 $p_{\text{base}}(x) \in \{0, 1\}$ 이라 하고, N 개의 독립적이고 새로운 RSP를 추첨하여
 684 표본당 한 번씩 디코딩한다. (M1) 각 n 에 대해, n 번째 RSP 실행이 $\mathcal{T}^*(x)$ 의 궤적을 만들 주변
 685 확률이 적어도 $p_{\min}(x) > 0$ 이고, (M2) N 번의 RSP 실행이 상호 독립이라 가정하자. 그러면

$$\Pr(\text{Pass}@ (N+1) \text{ on } x) \geq \max\{p_{\text{base}}(x), 1 - (1 - p_{\min}(x))^N\} \geq 1 - \exp(-Np_{\min}(x)).$$

686 증명은 (M2)에 의한 곱 분해와 (M1)에 의한 단조 하한으로 곧바로 이루어진다. (M1)은 과제
 687 측 가정이며 메커니즘만으로는 유도되지 않는다. 본문 §4.4에서 이 가정의 경험적 흔적을 논의
 688 했다.

689 F Attention Mass 분석

690 이 부록은 Figure 1에 보고한 per-token attention mass를 형식화하고, reasoning span과 layer 축에
 691 적용한 제외 기준을 명시한다. 500개의 MATH-500 문제 각각에 대해 새로운 RSP $\mathbf{H} \in \mathbb{R}^{L \times d}$ 를
 692 $L = 10$ 으로 독립 샘플링했으므로, 보고한 heatmap은 문제 자체의 변동성과 RSP 벡터 변동성을
 693 함께 평균한 결과다.

694 F.1 토큰당 attention 질량

695 각 문제에서 attention은 연결된 시퀀스 [prompt; $\mathbf{H}$; generation] 위에서 측정하며, generation은
 696 같은 모델이 동일한 RSP 주입 설정 아래 생성한 궤적이다. $\alpha_{i,j}^{(\ell,h)}$ 를 layer ℓ , head h 에서 query
 697 위치 i 가 key 위치 j 로 보내는 post-softmax attention weight라고 하자. 이는 causal mask 아래에서
 698 $\sum_j \alpha_{i,j}^{(\ell,h)} = 1$ 을 만족한다. 질문 토큰과 RSP 토큰의 인덱스 집합을 각각 Q , R 라 하고 크기를
 699 $|Q|$, $|R| = L$, head 수를 H 라 하자. 이때 query i 가 각 그룹으로 보내는 layer ℓ 의 per-token
 700 attention mass는

$$\text{PTM}_Q[\ell, i] = \frac{1}{|Q|H} \sum_{h=1}^H \sum_{j \in Q} \alpha_{i,j}^{(\ell,h)}, \quad \text{PTM}_R[\ell, i] = \frac{1}{|R|H} \sum_{h=1}^H \sum_{j \in R} \alpha_{i,j}^{(\ell,h)}. \quad (8)$$

701 $|Q|$ 와 $|R|$ 로 나누는 정규화는 집합 크기 차이를 보정하므로, 두 양은 동일한 softmax 분모 아래
 702 에서 질문 토큰 또는 RSP 토큰 하나가 평균적으로 얼마나 많은 attention을 받는지를 나타낸다.
 703 따라서 질문 토큰은 시퀀스 길이 효과를 흡수하는 크기 보정 baseline 역할을 한다.

704 F.2 Heatmap 집계

705 Layer 인덱스와 reasoning position 인덱스를 각각 동일 크기의 다섯 구간 $\{B_L^{(b)}\}_{b=1}^5$, $\{B_P^{(b)}\}_{b=1}^5$
 706 로 나눈다. 샘플 s 와 목표 집합 $\bullet \in \{Q, R\}$ 에 대해 셀 (b_L, b_P) 의 값은

$$M_{\bullet}^{(s)}[b_L, b_P] = \frac{1}{|B_L^{(b_L)}| \cdot |B_P^{(b_P)}|} \sum_{\ell \in B_L^{(b_L)}} \sum_{i \in B_P^{(b_P)}} \text{PTM}_{\bullet}[\ell, i]. \quad (9)$$

707 Figure 1는 Eq. (9)를 500개의 유효 샘플에 대해 평균한 결과를 보고한다.

708 F.3 \boxed{\dots} 구간 제외

709 Reasoning position 범위는 마지막 \boxed{\dots} 구간이 시작되기 직전에 끝나도록 잡는다.
 710 Chain-of-thought 출력은 *text*(내용)와 *pattern*(형식) 성분으로 나뉘며, 이 둘은 downstream 성
 711 능에 독립적으로 기여할 수 있다 [Madaan and Yazdanbakhsh, 2022]. \boxed{\dots} 래퍼는 전형
 712 적인 pattern 성분이다. 이는 추론을 더 전개하기보다는 답 형식을 마무리하는 짧고 정형화된
 713 span이기 때문이다. 이 구간을 포함하면 reasoning dynamics와 무관한 template-driven attention
 714 signature가 섞이게 된다.

715 F.4 마지막 두 레이어 제외

716 Layer 축에서는 마지막 두 transformer layer도 제외한다. 이는 우리 설정에만 특수한 것이 아니라,
 717 late layer의 두 가지 잘 알려진 성질에서 비롯된다.

718 **출력 투영 특화.** 마지막 레이어 근방의 hidden state는 vocabulary logits와 거의 선형 관계를 이
 719 루므로, 표현을 바꾸는 블록이라기보다 점진적 선형 readout으로 기능한다 [Belrose et al., 2023].
 720 같은 맥락에서 late-layer feed-forward module도 출력 분포를 조정하는 메커니즘으로 해석되어
 721 왔다 [Geva et al., 2021]. 따라서 이 레이어들의 attention은 reasoning computation보다 output
 722 formation을 더 강하게 반영한다.

723 **Register-token 가설.** Vision Transformer에서 정보가 거의 없는 patch token은 deeper layer에서
 724 attention을 흡수하는 *register*로 재활용될 수 있음이 알려져 있다 [Darcet et al., 2024]. RSP 역시
 725 사전학습된 의미를 갖지 않는 연속 토큰이라는 점에서 유사한 성질을 가지므로, late transformer

layer에서 비슷한 재사용이 일어날 가능성을 배제할 수 없다. 마지막 두 레이어를 제외하면 이런 register 유도 교란이 reasoning-phase 신호를 오염시키는 일을 막을 수 있다.

위의 두 근거는 late layer에서 나타나는 잘 알려진 현상, 즉 선형 readout과 잠재적 register 재사용이 reasoning-phase dynamics와 직교하는 attention signature를 만들 수 있음을 뜻한다. 마지막 두 레이어를 제거하는 것은 모델 특이적 tuning이 아니라 문헌에 근거한 원칙적 제외에 해당하며, 본문에서 강조한 시퀀스 방향(*autoregressive position*) attenuation은 이 제외 없이 모든 레이어를 포함했을 때에도 동일하게 관찰된다 — Theorem 1이 직접 보장하는 것은 sequence-direction attenuation이지 layer-direction monotonicity가 아니므로, 마지막 두 레이어를 포함시키더라도 본문 claim에 변화는 없다.

F.5 추가적인 suffix heatmap

Figure 7는 suffix 주입에서 Qwen2.5-Math-1.5B-Instruct와 LLaMA-3.1-8B-Instruct에 대해 동일한 per-token RSP attention 분석을 보고한다. 앞서 설명한 late-layer 이유 때문에 모든 셀에서 패턴이 완전히 동일하게 일반화되지는 않지만, 두 모델 모두에서 시퀀스 방향(가로축)의 단조 감소는 §3.2의 cache-growth 상계가 예측한 것과 일치한다. layer 축(세로)의 추가 감소는 별개의 경험적 sharpening 현상으로, Theorem 1만으로 직접 따라오는 결과는 아니다.




Figure 7: 나머지 두 모델(각각 500개 MATH-500 샘플)에서 suffix 주입 시 측정된 per-token RSP attention mass. 축과 전처리는 Figure 1와 동일하다. x축은 다섯 분위로 나눈 reasoning position, y축은 다섯 분위로 나눈 layer depth(위가 얇은 층), 색은 RSP 토큰에 할당된 per-token attention의 500샘플 평균을 뜻한다. `boxed{ }` 구간 내부 토큰과 마지막 두 레이어는 제외했다.

741 G GRPO 정식화

742 주어진 프롬프트 q 에 대해, behavior policy $\pi_{\theta_{\text{old}}}$ 는 보상 $\{R_i\}_{i=1}^G$ 를 갖는 응답 집합 $\{o_i\}_{i=1}^G$ 를
 743 샘플링한다. 각 응답의 advantage는 그룹 수준 보상을 정규화해 계산한다.

$$\hat{A}_{i,t} = \frac{R_i - \text{mean}(\{R_i\}_{i=1}^G)}{\text{std}(\{R_i\}_{i=1}^G)}. \quad (10)$$

744 정책은 KL penalty가 포함된 clipped objective로 업데이트한다.

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left(\min \left(r_{i,t} \hat{A}_{i,t}, \text{clip}(r_{i,t}, 1-\varepsilon, 1+\varepsilon) \hat{A}_{i,t} \right) - \beta D_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}}) \right) \right], \quad (11)$$

745 여기서 $r_{i,t} = \pi_{\theta}(o_{i,t} \mid q, o_{i,<t}) / \pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})$ 는 importance sampling ratio이고, ε 는 clipping
 746 범위, β 는 reference policy π_{ref} 에 대한 KL penalty 세기를 조절한다.

747 H 광범위한 영향

748 본 연구는 무작위 임베딩 주입이 대형 언어 모델의 추론 행동에 어떤 영향을 주는지에 대한
749 실험적·이론적 분석을 제공한다. 기여의 성격은 주로 기초 연구에 가깝지만, GRPO와 같은
750 강화학습 기반 추론 모델 후속학습에는 잠재적 함의를 가진다.

751 **긍정적 영향.** RSP가 유도하는 궤적 다양성은 group-relative advantage estimation 안에서 더
752 풍부한 학습 신호를 제공함으로써, RL 기반 LLM 후속학습의 sample efficiency를 높일 수 있다.
753 이는 reasoning 중심 fine-tuning과 alignment에 필요한 계산 비용을 줄여, 자원이 제한된 연구
754 그룹에도 관련 방법을 더 접근 가능하게 만들 수 있다.

755 **잠재적 우려.** LLM의 유효 출력 지지 집합을 넓히는 방법은 바람직한 대안적 추론 경로뿐
756 아니라, 바람직하지 않거나 분포 밖에 있는 출력의 도달 가능성도 함께 높일 수 있다. 따라서
757 RSP를 실제 시스템에 적용할 때는 이를 독립적인 다양성 원천으로만 보지 말고, 기존의 안전
758 필터링 및 alignment 메커니즘과 함께 사용해야 한다.

759 **영향 범위의 한계.** 본 연구는 새로운 모델이나 데이터셋을 배포하기보다 분석을 제공하는 데
760 초점을 두므로, 직접적인 사회적 영향은 제한적이다. 여기서 논의한 더 넓은 함의는 RSP가 실제
761 학습 파이프라인에 통합되는 향후 연구가 이루어질 때에만 현실화될 수 있다.