

노이즈에서 다양성으로: 대형 언어 모델 추론에서의 무작위 임베딩 주입

Anonymous Author(s)

Affiliation

Address

email

Abstract

최근 *soft prompt* 계열 방법은 가상 토큰 형태의 학습 가능한 연속 임베딩을 LLM 입력에 삽입해 수학 추론 성능을 높여 왔지만, 임베딩 주입 자체가 최적화와는 독립적으로 모델 행동에 어떤 영향을 주는지는 거의 분석되지 않았다. 본 논문은 학습 없이 주입되는 Random Soft Prompt(RSP)—사전학습된 임베딩 행렬의 행별 평균과 분산에 맞춘 등방 가우시안에서 샘플링한 연속 벡터—를 다룬다. 실험적으로 RSP는 생성 초반의 토큰 엔트로피를 높이고 후반에는 분포가 다시 안정화되며, temperature sampling과 결합할 때 Pass@N으로 측정한 추론 궤적 다양성을 더 크게 확장한다. 이론적으로는 RSP의 기여가 어텐션 레이어마다 무작위 토큰 어텐션 질량이라는 단일 스칼라로 정확히 포착되고, 그 양은 자기회귀 캐시 성장에 의해 구조적으로 희석됨을 보인다. 또한 등방 재추첨은 temperature가 도달할 수 없는 방식으로 baseline에서 제외된 토큰을 유효 top-K 후보 집합 안으로 진입시킨다. 마지막으로 이러한 다양성이 GRPO 학습에 갖는 함의를 논의한다.

1 서론

대형 언어 모델(LLM)이 수십억 파라미터로 커지면서 전체 미세조정 비용도 빠르게 늘었고, 고정된 모델에 소수의 추가 파라미터만 도입해 적응시키는 parameter-efficient 방법이 주류가 되었다 [Hu et al., 2022, Houlsby et al., 2019]. 그중 *soft prompt*는 학습 가능한 연속 임베딩을 입력에 삽입해 attention을 통해 모델 행동을 조정하는 대표적 접근으로 [Li and Liang, 2021, Lester et al., 2021], 수학 추론 강화에도 활발히 사용되어 왔다 [Kang et al., 2026, Xu et al., 2025, Ye et al., 2026, Hao et al., 2025, Zhang et al., 2026]. 이들은 모두 사전학습 어휘 바깥의 연속 임베딩을 주입하고 그것을 최적화해 downstream 성능을 끌어올린다는 공통 구조를 공유한다.

그러나 우리는 이 효과가 반드시 최적화에서 나오는 것은 아님을 관찰한다. 학습되지 않은 무작위 연속 임베딩만 주입해도 출력 분포가 비자명하게 바뀐다. 예컨대 채팅 형식으로 학습되지 않은 base model에 chat template을 적용하면 형식 불일치로 추론 성능이 크게 떨어지지만, 무작위 임베딩을 덧붙이면 그 저하가 회복된다. 기존 연구는 최종 정확도만 평가했기 때문에 “주입 자체”의 효과와 “최적화”의 효과가 분리되지 않았으며, 어휘 바깥의 연속 임베딩 주입이 모델 출력 분포를 어떻게 바꾸는지는 충분히 탐구되지 않았다.

본 논문은 학습 없이 주입되는 Random Soft Prompt(RSP)를 분석한다. RSP는 사전학습 임베딩 행렬의 행별 평균과 분산에 맞춘 등방 가우시안에서 샘플링한 연속 벡터로, 여기서 무작위성은 임베딩 분포를 모사하는 장치가 아니라 같은 프롬프트가 rollout마다 독립적인 섭동을 만들도록 해 주는 성질이며, 탐색은 바로 이 독립성을 요구한다. 실험적으로 RSP는 생성 초반 토큰 엔트로피를 높이지만 후반에는 안정화되고, temperature sampling과 결합하면 Pass@N의 증가로 드러나는 다양한 추론 궤적을 만든다. 이론적으로는 RSP 기여가 어텐션 레이어마다 단일 스칼라—무작위 토큰 어텐션 질량—로 정확히 포착되어 캐시 성장에 의해 희석되고, 등방 재추첨이 temperature가 도달할 수 없는 방식으로 baseline 외 토큰을 유효 top-K 후보로 진입시킴을 보인다. 마지막으로 이 다양성이 GRPO [Shao et al., 2024]에 갖는 함의를 논의한다.

본 논문의 기여는 다음과 같다.

- RSP가 LLM 생성에 어떤 변화를 주는지 실증적으로 분석한다. RSP는 생성 초반의 토큰 엔트로피를 높이며 temperature sampling과 결합될 때 더 다양한 추론 궤적을 만들어 낸다.
- Soft prompt가 작동하는 이유를 트랜스포머 수준에서 제시한다. RSP의 기여는 단일 스칼라 어텐션 질량으로 통제되며 캐시 성장에 의해 구조적으로 희석된다. 국소 affine surrogate 위에서 고정 섭동이 아닌 등방 재추침이 baseline 외 토큰을 유효 top- K 로 진 입시킨다.
- RSP가 유도하는 다양성이 GRPO 학습에 어떤 함의를 갖는지 논의한다. RSP는 순위를 바꾸는 섭동이고 temperature는 순위를 보존하는 섭동이므로, 두 방법은 직교하는 탐색 이득을 제공한다.

2 배경

2.1 LLM 추론을 위한 Soft Prompt 기법

Soft prompt는 전체 미세조정의 대안으로 등장했다. Prefix-Tuning [Li and Liang, 2021]이 학습 가능한 연속 벡터를 각 transformer 레이어 앞에 붙이는 패러다임을 제시한 이후, Prompt Tuning [Lester et al., 2021]은 입력 레이어만 사용하는 단순화된 형태로도 충분히 큰 모델에서 전체 미세조정에 근접한 성능을 보였고, P-tuning [Liu et al., 2024]은 LSTM prompt encoder로 위치 간 의존성까지 포착했다. 이 패러다임은 LLM 추론에도 빠르게 적용되었다. TTSV [Kang et al., 2026]는 테스트 시점에 prefix 임베딩을 엔트로피 최소화해 최적화해 잠재 추론을 활성화하고, SoftCoT [Xu et al., 2025]은 assistant model이 만든 soft token으로 명시적 chain-of-thought를 대체 한다. LTPO [Ye et al., 2026]는 confidence 기반 내재 보상으로 latent thought 임베딩을 샘플별로 최적화하며, COCONUT [Hao et al., 2025]은 모델 자신의 은닉 상태를 다시 입력 임베딩으로 되먹여 연속 잠재 공간에서 추론하게 만든다. MemGen [Zhang et al., 2026]은 임베딩이 경험 메모리로 기능할 수 있음을 보였고, Pause token [Goyal et al., 2024]은 학습 가능한 토큰을 입력 중간에 끼워 넣어 추가 계산 단계를 제공한다. 이들 모두 어휘 바깥의 연속 임베딩을 과제 특화 목적함수로 최적화해 정확도를 끌어올린다. 그러나 평가가 최종 정확도에 맞춰져 있어 “주입 자체”의 효과와 “최적화”의 효과가 분리되지 않으며, 단순한 임베딩 주입이 모델 행동을 어떻게 바꾸는지는 별도의 미해결 문제로 남아 있다.

2.2 신경망에서의 노이즈 주입

신경망에는 여러 단계에서 노이즈가 도입되어 왔다. 학습 시점에서는 dropout [Srivastava et al., 2014]이 은닉 유닛을 무작위로 비활성화해 과적합을 막고, NEFTune [Jain et al., 2024]은 instruction fine-tuning 중 토큰 임베딩에 노이즈를 더해 instruction following을 개선한다. 추론 시점의 섭동은 주로 강건성을 겨냥한다. Randomized smoothing [Cohen et al., 2019]은 입력 가우시안 노이즈로 certified robustness를 얻고, SmoothLLM [Robey et al., 2025]은 문자 단위 프롬프트 변형으로 jailbreak를 방어한다. 강화학습에서는 NoisyNet [Fortunato et al., 2018]이 가치치에 학습 가능한 노이즈를 넣어 탐색 성능을 높였다.

RSP는 이들과 세 가지 점에서 구별된다. (1) 어떠한 학습도 없이 추론 시점에만 동작하므로 모델 파라미터를 건드리지 않는다(dropout, NEFTune, NoisyNet과 다르다). (2) 원래 입력을 보존한 채 새 임베딩을 한 번의 forward pass에 덧붙일 뿐이며, 강건성 방법이 요구하는 “여러 번의 noisy pass와 출력 집계”가 필요 없다. (3) 학습된 파라미터 없이 사전학습 임베딩 통계에서 직접 샘플링한 무작위 벡터를 그대로 쓴다(NoisyNet은 노이즈 파라미터 자체를 학습한다). 무엇보다 RSP의 목적은 출력 안정성이 아니라 탐색이며, 본 논문은 이 차이가 어텐션 수준에서 어떻게 작동하는지 분석한다.

3 실험 분석

3.1 Random Soft Prompt의 정의와 설정

사전학습된 LLM의 토큰 임베딩 행렬을 $\mathbf{W}_E \in \mathbb{R}^{V \times d}$ 라 하자. 여기서 V 는 어휘 크기이고 d 는 은닉 차원이다. RSP는 L 개의 연속 벡터 시퀀스 $\mathbf{H} = [h_1, \dots, h_L] \in \mathbb{R}^{L \times d}$ 로 정의되며, 각

Table 1: 모델 설정과 벤치마크별 정확도(%). RSP는 주입 위치(Prefix, Infix, Suffix) 중 최고 성능만 보고한다. 위치별 전체 결과는 Appendix A에 있다. 괄호 안 값은 baseline 대비 변화량이다.

Model	MATH-500		GSM8K		AIME24	
	Baseline	RSP	Baseline	RSP	Baseline	RSP
<i>Instruct Models</i>						
LLaMA-3.1-8B-Inst	52.20	49.40 (−2.8)	85.75	86.73 (+1.0)	6.67	10.00 (+3.3)
Qwen2.5-Math-7B-Inst	83.20	84.20 (+1.0)	95.45	95.68 (+0.2)	13.33	16.67 (+3.3)
Qwen2.5-Math-1.5B-Inst	73.00	75.20 (+2.2)	85.29	85.75 (+0.5)	10.00	20.00 (+10.0)
<i>Base Models (Raw Text)</i>						
Qwen2.5-Math-7B	72.20	71.60 (−0.6)	84.15	84.31 (+0.2)	6.67	16.67 (+10.0)
Qwen2.5-Math-1.5B	61.40	64.40 (+3.0)	77.86	74.30 (−3.6)	16.67	10.00 (−6.7)
<i>Base Models + ChatML (Format Mismatch)</i>						
Qwen2.5-Math-7B	52.20	70.40 (+18.2)	58.30	75.97 (+17.7)	23.33	23.33 (+0.0)
Qwen2.5-Math-1.5B	34.40	63.40 (+29.0)	37.45	67.02 (+29.6)	13.33	20.00 (+6.7)

Table 2: 기존 soft prompt 방법(TTSV, SoftCoT, LTPO)과의 통합 평가 비교. Baseline과 RSP 값은 Table 1에서 가져왔다. **Bold**는 최고 성능, underline은 두 번째 성능이다.

Model	Benchmark	Baseline	RSP	TTSV	SoftCoT	LTPO
Qwen2.5-Math-7B-Instruct	MATH-500	83.20	84.20	<u>83.80</u>	82.80	83.00
	GSM8K	95.45	95.68	<u>95.30</u>	95.00	94.84
	AIME24	13.33	16.67	23.30	<u>16.67</u>	13.33
Qwen2.5-Math-1.5B-Instruct	MATH-500	73.00	<u>75.20</u>	<u>75.20</u>	76.00	72.40
	GSM8K	85.29	85.75	<u>85.70</u>	84.46	84.53
	AIME24	<u>10.00</u>	20.00	<u>6.70</u>	6.67	<u>10.00</u>

84 벡터는 다음 분포에서 독립적으로 샘플링된다.

$$h_j \sim \mathcal{N}(\mu_E, \sigma_E^2 \mathbf{I}), \quad j = 1, \dots, L, \quad (1)$$

85 여기서 $\mu_E = \frac{1}{V_d} \sum_{i,k} [\mathbf{W}_E]_{i,k}$, $\sigma_E = \text{std}(\mathbf{W}_E)$ 이다. 원래 입력의 임베딩 시퀀스를 $\mathbf{X} =$
86 $[x_1, \dots, x_T] \in \mathbb{R}^{T \times d}$ 라 하면, RSP가 주입된 입력 $\tilde{\mathbf{X}}$ 는 원래 프롬프트 텍스트는 바꾸지 않은
87 채 세 위치 중 하나에서 $\mathbf{H}$ 를 연결해 만든다: *prefix* ($[\mathbf{H}; \mathbf{X}]$), *infix* ($\mathbf{H}$ 가 $\mathbf{X}$ 내부에 삽입됨), *suffix*
88 ($[\mathbf{X}; \mathbf{H}]$). 이는 선행 연구의 주입 전략을 따른다 [Kang et al., 2026, Xu et al., 2025, Ye et al.,
89 2026, Zhang et al., 2026]. 각 배치마다 새로운 $\mathbf{H}$ 를 샘플링함으로써, 결과가 특정 무작위 임베딩
90 실현값 하나에 의존하지 않도록 했다.

91 평가는 세 가지 수학 추론 벤치마크, MATH-500 [Lightman et al., 2024], GSM8K [Cobbe
92 et al., 2021], AIME24에서 수행한다. 모델은 LLaMA-3.1-8B-Instruct [Grattafiori et al., 2024]
93 와 Qwen2.5-Math 계열 [Yang et al., 2024]을 사용하며, instruct model, base model, 그리고 chat
94 template이 맞지 않는 base model까지 포함해 총 일곱 설정을 비교한다. 모든 실험은 sampling
95 자체의 무작위성과 RSP 효과를 분리하기 위해 greedy decoding을 사용한다. 평가는 fallback
96 기반의 answer extraction pipeline으로 최종 답만 채점한다. 전체 실험 설정은 Appendix A에
97 정리했다.

98 3.2 RSP는 추론 성능을 개선할까?

99 먼저 무작위 임베딩 주입이 모델의 추론 성능에 어떤 영향을 주는지 본다. Table 1는 각 벤치마크
100 에서 주입 위치(Prefix, Infix, Suffix)와 $L \in \{10, 15, 20\}$ 가운데 가장 좋은 RSP 결과를 보고한다.

101 instruct model과 원래 프롬프트 형식을 쓰는 base model에서는 RSP가 baseline 성능을 대체로
102 몇 퍼센트포인트 이내에서 유지하거나 소폭만 이동시킨다. 더 눈에 띄는 것은 프롬프트 형식
103 불일치 상황이다. 즉, 채팅 형식으로 학습되지 않은 base model에 ChatML template을 주입했을
104 때, RSP는 최대 +29%p까지의 큰 성능 향상을 보인다. 단순히 불확실성을 높이는 노이즈였다
105 면 오히려 성능 저하가 커졌어야 하므로, 이 결과는 RSP 효과가 단순한 교란을 넘는다는 점을
106 시사한다.

또한 RSP를 TTSV, SoftCoT, LTPO처럼 서로 다른 목적 함수로 임베딩을 최적화하는 기존 soft prompt 방법과 비교했다. Table 2은 공통 answer extraction pipeline 아래에서 다시 평가한 결과를 보여준다. 각 방법은 프롬프트 형식과 채점 규칙이 다르지만, fallback 기반 추출을 사용해 형식에 덜 민감한 비교를 수행했다. 결과적으로 RSP는 추가 학습 없이도 최적화 기반 방법과 맞먹는 수준의 성능을 보인다.

3.3 RSP는 출력 분포를 어떻게 바꾸는가?

다음으로 RSP 주입이 생성 과정의 출력 분포를 어떻게 바꾸는지 살펴본다. 설정은 Qwen2.5-Math-1.5B-Instruct와 MATH-500이며, 토큰별 entropy, top-1 probability, varentropy를 생성 단계에 따라 측정한다. Figure 1와 Table 3는 생성 초반 5% 구간에서 RSP 변형과 기존 soft prompt 방법을 비교한 결과다.




Figure 1: 생성 초반 5% 구간의 평균 entropy, top-1 probability, varentropy (Qwen2.5-Math-1.5B-Instruct, MATH-500). 음영은 ± 1 SEM이다. 실선은 RSP 변형과 baseline, 점선은 기존 soft prompt 방법(LTPO, SoftCoT, TTSV)이다.

Table 3: 생성 초반 5% 구간의 평균 entropy, top-1 probability, varentropy (Qwen2.5-Math-1.5B-Instruct, MATH-500).

Metric	Baseline	Prefix	Infix	Suffix	LTPO	SoftCoT	TTSV
Entropy	0.1332	0.1366	0.1402	0.1941	0.1662	0.4218	0.1359
Top-1 Prob	0.9535	0.9523	0.9525	0.9373	0.9437	0.9156	0.9534
Varentropy	0.2181	0.2207	0.2463	0.4010	0.2953	2.2234	0.2174

결과는 RSP가 생성 초반 출력 분포를 분명히 바꾼다는 점을 보여준다. 세 주입 위치 모두에서 entropy는 증가하고, top-1 probability는 감소하며, varentropy는 증가한다. 이는 분포가 평평해지고, 단일 우세 토큰에 대한 확신은 약해지며, 다분형 분포가 더 자주 나타남을 뜻한다 [Ahmed et al., 2026]. 높은 entropy 구간은 추론 궤적이 갈라지는 핵심 분기점으로 알려져 있으므로 [Wang et al., 2025], 이 변화는 여러 추론 경로가 공존할 수 있는 상태로 모델을 밀어 넣는다. 중요한 점은 변화가 생성 초반에 국한된다는 것이다. 생성 중반과 후반에서는 세 지표 모두 baseline 수준으로 다시 수렴한다.

서로 다른 목적 함수로 학습된 기존 방법들도 같은 패턴을 공유한다. 평균 entropy를 줄이는 보상을 쓰는 TTSV조차 초반 구간만큼은 baseline과 비슷하거나 더 높아, 이 entropy 상승은 특정 최적화 목적이 아니라 사전학습되지 않은 연속 임베딩 주입 자체에 가까운 효과로 보인다.

3.4 RSP는 실제로 추론 궤적의 다양성을 만드는가?

Section 3.3는 RSP가 생성 초반 출력 분포를 바꾼다는 사실을 보였다. 이제 이 변화가 실제 추론 다양성으로 이어지는지를 세 수준에서 살펴본다. 분석 수준은 토큰 순위, 궤적의 의미적 내용, 과제 수준 결과다. 세 분석 모두 Qwen2.5-Math-1.5B-Instruct, MATH-500, suffix 주입, $L = 10$ 설정을 공유한다.

먼저 토큰 수준에서 보면, 자기회귀 생성에서 baseline과 RSP의 궤적 차이는 결국 첫 토큰에서 시작될 수밖에 없으므로 baseline $\tau=1.0$ 을 기준으로 단순 flattening의 상한인 baseline $\tau=2.0$ 과 RSP $\tau=1.0$ 을 비교

Table 4: Baseline $\tau=1.0$ 을 기준으로 본 첫 토큰 분포 지표. Baseline $\tau=2.0$ 과 RSP $\tau=1.0$ 을 비교한다.

Metric	$\tau=2.0$	RSP
Spearman ρ	1.0	0.651
Mass outside top-10	5.15%	27.64%
JS divergence	0.086	0.231

한다. 세 지표—Spearman rank correlation ρ , baseline top-10 밖 확률 질량, Jensen–Shannon divergence—는 각각 순위 재배치, 지지 집합 확장, 분포 변화의 크기를 잡아낸다(정의는 Appendix C). Table 4에서 baseline top-10 밖으로 이동하는 질량은 $\tau=2.0$ 에서 5.15%에 그치지만 RSP $\tau=1.0$ 에서는 27.64%이고, Spearman 상관은 1에서 0.651로 떨어진다. Temperature는 단조 변환이라 어떤 τ 에서도 순위를 보존하므로 $\rho = 1$ 이 강제되는 반면, RSP는 순위 자체를 뒤섞는다(이 차이의 메커니즘적 근거는 §4.3). JS divergence 0.231은 이 변화의 전체 크기를 요약한다.

한 단계 위인 궤적 수준에서는, 첫 토큰의 재배치가 실제로 의미적으로 다른 추론 경로를 여는지가 관건이다. 이를 위해 MATH-500에서 무작위로 64개 문제를 뽑고, Baseline과 RSP 두 조건에서 각 문제마다 temperature $\tau = 1.0$ 으로 300개의 독립 궤적을 생성했다. 각 궤적은 BGE-M3 [Chen et al., 2024]로 임베딩한 뒤, 문제 내 평균 pairwise cosine distance, DBSCAN [Ester et al., 1996] 클러스터 중심 사이의 inter-cluster distance, 그리고 intra-cluster distance를 계산했다. Table 5는 RSP가 intra-cluster distance는 거의 바꾸지 않으면서 inter-cluster distance를 크게 키운다는 점을 보여준다. 즉, 각 전략 내부의 일관성은 유지하면서 전략 간 거리를 벌린다. Pairwise distance 기준으로도 RSP는 64개 중 56개 문제(87.5%)에서 baseline보다 컸다.

Table 5: 64개 문제에 대해 평균한 의미적 다양성 지표.

Metric	Baseline	RSP
Pairwise cos. dist.	0.0612	0.0879
Inter-cluster dist.	0.0183	0.0982
Intra-cluster dist.	0.0526	0.0528




Figure 2: 64개 MATH-500 문제에서의 의미적 다양성 분석(문제당 300개 궤적, Qwen2.5-Math-1.5B-Instruct, $\tau = 1.0$, BGE-M3 임베딩). (a) 대표 문제 test/prealgebra/951의 t-SNE 투영: baseline(빨강)은 한 영역에 비교적 집중되지만, RSP suffix(파랑)는 더 넓고 분리된 군집까지 확장된다. 채워진 표식은 정답, 빈 표식은 오답이다. (b) 문제별 평균 pairwise cosine distance. 대각선 위 점은 RSP가 baseline보다 더 다양한 궤적을 만든다는 뜻이다. (c) 문제별 DBSCAN 클러스터 수. 대부분의 문제에서 RSP가 더 많은 클러스터를 만든다.

Figure 2(a)에서 RSP 샘플(파랑)은 baseline 영역을 포함하면서 baseline이 도달하지 못한 별도 클러스터까지 확장되고, 그 영역에도 정답 궤적이 포함된다. (b), (c)는 64개 문제 전반에 걸쳐 RSP가 더 많은 클러스터와 더 큰 pairwise cosine distance를 만든다는 패턴이 반복됨을 보여준다. 즉 RSP는 클러스터 내부 진행은 호트러프리지 않으면서 궤적이 진입하는 전략 클러스터 자체를 바꾼다. 문제별 추가 t-SNE는 Appendix B에 있다.

마지막 결과 수준에서는, 이러한 다양성이 실제 과제 성과로 이어지는지를 Pass@N로 본다 (N 개의 샘플 중 적어도 하나가 정답일 확률). MATH-500과 AIME24에서 문제당 $N = 16$, 네 조건을 비교한다. (i) baseline + $\tau=1.0$, (ii) RSP를 모든 샘플이 공유 + $\tau=1.0$, (iii) 샘플마다 독립 RSP + greedy, (iv) 샘플마다 독립 RSP + $\tau=1.0$.

조건 (iv)가 두 벤치마크 모두에서 가장 높은 Pass@N을 달성하며 $N = 16$ 에서 MATH-500 92.80%, AIME24 36.67%에 이른다. (ii)는 baseline 대비 거의 개선이 없어, 다양성 이득의 핵심이 고정 섭동이 아니라 샘플마다 독립된 무작위 임베딩임을 드러낸다. Pass@1은 MATH-500에서 baseline 수준을 유지하고 더 어려운 AIME24에서는 (iv)가 더 높아, 독립 RSP + temperature 결합이 단일 샘플 정확도를 해치지 않으면서 추론 궤적을 다양화한다.




Figure 3: Qwen2.5-Math-1.5B-Instruct에서의 Pass@N 스케일링. 좌측은 MATH-500, 우측은 AIME24이며, 문제당 $N = 16$ 개의 샘플을 사용했다. Baseline은 temperature sampling만, fixed seed는 고정된 하나의 RSP와 temperature를 함께 쓴 경우, indep. seed는 샘플마다 다른 RSP를 쓰는 경우다.

4 이론적 분석: 어텐션 매개 탐색으로서의 RSP

§3의 세 관찰—초반 엔트로피 상승, 후반 안정화, Pass@N 향상—은 트랜스포머 구조 자체에서 비롯되는 단일 메커니즘으로 설명된다. 본 절은 이를 무작위 토큰 어텐션 질량이라는 어텐션 수준의 단일 스칼라량 위에서 통합한다. 핵심 통찰은 RSP의 무작위성 자체가 탐색의 필수 조건이라는 점이며, 등방 가우시안 재추첨만이 고정 프롬프트(독립 대안 부재), 어휘 토큰(의미 prior), 비등방 분포(방향 미달)의 세 실패 모드를 동시에 피한다.

4.1 RSP는 왜 등방 가우시안 재추첨인가

§3.1의 정의를 따른다. 길이 L 의 RSP $\mathbf{H} = [h_1, \dots, h_L]$ 은 $h_j \sim \mathcal{N}(\mu_E, \sigma_E^2 \mathbf{I}_d)$ 이며, 중심화된 형태 $\bar{h}_j := h_j - \mu_E \mathbf{1}_d \sim \mathcal{N}(0, \sigma_E^2 \mathbf{I}_d)$ 는 평균 0의 등방 가우시안이다. 이 설계의 세 성질—연속, 중심화, 등방—은 각각 다른 실패 모드를 막는다.

먼저 무작위성이 없으면 탐색이 불가능하다. 학습된 고정 프롬프트는 rollout마다 같은 섭동 방향만 더해 독립적 대안을 만들지 못하므로 Pass@N의 누적 이득을 봉쇄한다. 어휘 토큰 추첨은 다른 방식으로 실패한다. 각 토큰 임베딩은 사전학습이 새겨 둔 의미·어휘 방향을 떠안고 있어 통제되지 않은 의미 편향을 주입한다. 등방 무작위 방향은 임의의 유한 의미 anchor 집합과 높은 확률로 거의 직교한다(Lemma 1, Appendix E).

다음으로 등방성 자체가 분산 예산 한 단위당 탐색 방향을 미니맥스 의미에서 최대화한다.

정리 1 (방향 무관 미니맥스 커버리지). $\mathbb{R}^d$ 위 평균 0 분포 D 가 $\text{tr}(\Sigma_D) \leq \rho^2$ 이면 $\lambda_{\min}(\Sigma_D) \leq \rho^2/d$ 이며, 등호는 $\Sigma_D = (\rho^2/d)\mathbf{I}_d$ 일 때에만 성립한다.

따라서 “경험적 임베딩 공분산 Σ_E 를 그대로 사용하기”와 같은 일견 자연스러운 대안조치, Σ_E 가 비등방인 한 적어도 한 방향이 덜 탐색되어 등방 비교군보다 strictly suboptimal이다. RSP는 결국 스케일은 임베딩에서 빌리되 방향 기하는 의도적으로 버린다.

4.2 정확한 어텐션 수준 메커니즘

self-attention 레이어 ℓ 이 실제 토큰 n 개와 RSP 토큰 L 개를 함께 attend한다고 하자. 어텐션 가중치를 $\alpha_{ij}^{(\ell)}$, value 벡터를 실제·RSP 측에서 각각 $\mathbf{v}_j^{(\ell)}, \mathbf{v}_{r_j}^{(\ell)}$ 라 하고, 무작위 토큰에 배정된 총 어텐션을 $w_{r,i}^{(\ell)} := \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)}$ 로 정의한다. softmax 정규화 항등식 $\sum_{j=1}^{n+L} \alpha_{ij}^{(\ell)} = 1$ 아래에서 어텐션 출력은 정확히

$$\mathbf{x}_i^{(\ell+1)} = (1 - w_{r,i}^{(\ell)}) \tilde{\mathbf{x}}_i^{(\ell+1)} + \boldsymbol{\eta}_i^{(\ell)}, \quad \tilde{\mathbf{x}}_i^{(\ell+1)} := \sum_{j=1}^n \frac{\alpha_{ij}^{(\ell)}}{1 - w_{r,i}^{(\ell)}} \mathbf{v}_j^{(\ell)}, \quad \boldsymbol{\eta}_i^{(\ell)} := \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{r_j}^{(\ell)}, \quad (2)$$

로 분해된다. 도출은 직접적이다. 어텐션 출력 $\sum_{j=1}^{n+L} \alpha_{ij}^{(\ell)} \mathbf{v}_j^{(\ell)}$ 를 실제·RSP 두 항으로 가르 뒤 실제 항에서 정규화 인자 $1 - w_{r,i}^{(\ell)} = \sum_{j=1}^n \alpha_{ij}^{(\ell)}$ 를 묶어 내면 위 식이 그대로 나온다. 근사가 아닌 항등식이며, $\|\boldsymbol{\eta}_i^{(\ell)}\| \leq w_{r,i}^{(\ell)} \max_j \|\mathbf{v}_{r_j}^{(\ell)}\|$ 이므로 같은 스칼라 $w_{r,i}^{(\ell)}$ 가 실제 신호의 감쇠와 무작위 기여의 진폭을 동시에 통제한다.

이 양은 자기회귀 디코딩에서 구조적으로 희석된다. 사전 스케일 logit gap $\Delta_i^{(\ell)} := \min_{j \in [n]} \mathbf{q}_i^\top \mathbf{k}_j - \max_{j' \in [L]} \mathbf{q}_i^\top \mathbf{k}_{r_{j'}}$ 아래에서 scaled-dot-product 어텐션은 $w_{r,i}^{(\ell)} \leq L/(L + n \exp(\Delta_i^{(\ell)}/\sqrt{d}))$ 를 만족하고, 우변은 n 에 대해 엄격히 감소한다. 즉 캐시가 실제 토큰을 누적하는 그 자체로 RSP 영향력 상계가 단조롭게 좁혀지며, 이는 §3.3의 후반 안정화의 메커니즘적 근원이다. Figure 4가 Qwen2.5-Math-7B에서 두 축 모두를 따라 감소하는 실제 $w_{r,i}^{(\ell)}$ 를 보고한다.




Figure 4: Qwen2.5-Math-7B의 토큰별 어텐션 질량(suffix, MATH-500 500문제, 문제마다 독립 RSP). (a) RSP 토큰 어텐션은 레이어와 추론 위치 두 축 모두에서 감소하고, (b) 질문 토큰 어텐션은 비교적 균일하게 유지된다.

205 4.3 독립 재추첨에서 Pass@N으로

Temperature는 $p_i^{(\tau)} \propto p_i^{1/\tau}$ 로 순위를 보존하므로 어떤 τ 에서도 baseline top- K 밖 토큰을 안으로 들여보내지 못한다. RSP는 출력 softmax 이전에 작동해 순위를 바꿀 수 있다. 국소 affine surrogate $z_i^{\text{lin}}(\bar{h}) := z_i + a_i^\top \bar{h}$ 위에서 baseline 외 토큰 i 가 다른 후보를 엄격한 마진으로 $K-1$ 개 이상 앞서는 $\bar{h}_0$ 가 존재하면, 연속성과 등방 가우시안의 full support로부터 진입 확률 $\mu_i := \Pr_{\bar{h}}(\bar{h} \in \mathcal{G}_{i,K}) > 0$ 이 따라온다(Proposition 2). 이는 모든 τ 에서 0인 temperature와 본질적으로 다르다.

독립 재추첨은 이 단발 확률을 지수적으로 포화시킨다. N 번 중 적어도 한 번 진입할 확률은 $1 - (1 - \mu_i)^N \geq 1 - e^{-N\mu_i}$ 이며, 정답 궤적이 비어 있지 않은 문제 x 에 대해 RSP 한 번이 정답을 만들 주변 확률 $p_{\min}(x) > 0$ 및 실행 독립성 (M1, M2) 아래 $\Pr(\text{Pass}@ (N+1) \text{ on } x) \geq 1 - e^{-Np_{\min}(x)}$ 의 하한이 성립한다(Proposition 3). (M1)은 과제 측 가정으로 §3.4의 의미 클러스터 · Pass@N 누적이 그 경험적 흔적이다.

217 5 결론

본 논문은 사전학습 임베딩 행렬의 항별 통계에 맞춘 등방 가우시안 벡터를 학습 없이 주입하는 RSP를 분석했다. 실험적으로 RSP는 생성 초반 엔트로피를 높이고 후반에는 안정화되며 (§3), 이론적으로는 어텐션 레이어마다 RSP 기여가 무작위 토큰 어텐션 질량이라는 단일 스칼라로 포착되어 캐시 성장에 의해 구조적으로 희석되고, 등방 재추첨은 temperature가 도달할 수 없는 방식으로 baseline 외 토큰을 유효 top- K 로 진입시킨다 (§4). RSP는 순위를 바꾸는 섭동, temperature는 순위를 보존하는 섭동이므로 둘은 상보적이며, 이는 GRPO [Shao et al., 2024]의 entropy collapse를 DAPO [Yu et al., 2025], CE-GPPO [Su et al., 2026] 너머에서 샘플링 단계로 보완할 가능성을 시사한다. 학습 시점 비교, 도메인 확장, RSP 길이·위치의 원리적 결정은 향후 과제다.

227 References

- 228 Farhan Ahmed, Yuya Jeremy Ong, and Chad DeLuca. LogitScope: A Framework for Analyzing
229 LLM Uncertainty through Information Metrics. In *ICLR Workshop*, 2026.
- 230 Nora Belrose, Igor Ostrovsky, Lev McKinney, Zach Furman, Logan Smith, Danny Halawi, Stella
231 Biderman, and Jacob Steinhardt. Eliciting Latent Predictions from Transformers with the Tuned
232 Lens. *arXiv:2303.08112*, 2023.
- 233 Jianlyu Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, and Zheng Liu. M3-
234 Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through
235 Self-Knowledge Distillation. In *Findings of ACL*, 2024.

236 Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser,
237 Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, Christopher Hesse, and John
238 Schulman. Training Verifiers to Solve Math Word Problems. *arXiv:2110.14168*, 2021.

239 Jeremy M. Cohen, Elan Rosenfeld, and J. Zico Kolter. Certified Adversarial Robustness via Random-
240 ized Smoothing. In *ICML*, 2019.

241 Timothée Darcet, Maxime Oquab, Julien Mairal, and Piotr Bojanowski. Vision Transformers Need
242 Registers. In *ICLR*, 2024.

243 Martin Ester, Hans-Peter Kriegel, Jörg Sander, and Xiaowei Xu. A Density-Based Algorithm for
244 Discovering Clusters in Large Spatial Databases with Noise. In *KDD*, 1996.

245 Meire Fortunato, Mohammad Gheshlaghi Azar, Bilal Piot, Jacob Menick, Ian Osband, Alex Graves,
246 Vlad Mnih, Remi Munos, Demis Hassabis, Olivier Pietquin, Charles Blundell, and Shane Legg.
247 Noisy Networks for Exploration. In *ICLR*, 2018.

248 Mor Geva, Roei Schuster, Jonathan Berant, and Omer Levy. Transformer Feed-Forward Layers Are
249 Key-Value Memories. In *EMNLP*, 2021.

250 Sachin Goyal, Ziwei Ji, Ankit Singh Rawat, Aditya Krishna Menon, Sanjiv Kumar, and Vaishnavh
251 Nagarajan. Think before You Speak: Training Language Models with Pause Tokens. In *ICLR*,
252 2024.

253 Aaron Grattafiori, Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad
254 Al-Dahle, Aiesha Letman, Akhil Mathur, Alan Schelten, Alex Vaughan, Amy Yang, Angela Fan,
255 Anirudh Goyal, Anthony Hartshorn, Aobo Yang, Archi Mitra, Archie Sravankumar, Artem Ko-
256 renev, Arthur Hinsvark, Arun Rao, Aston Zhang, Aurelien Rodriguez, Austen Gregerson, Ava
257 Spataru, Baptiste Roziere, Bethany Biron, Binh Tang, Bobbie Chern, Charlotte Caucheteux, Chaya
258 Nayak, Chloe Bi, Chris Marra, Chris McConnell, Christian Keller, Christophe Touret, Chunyang
259 Wu, Corinne Wong, Cristian Canton Ferrer, Cyrus Nikolaidis, Damien Allonsius, Daniel Song,
260 Danielle Pintz, Danny Livshits, Danny Wyatt, David Esiobu, Dhruv Choudhary, Dhruv Mahajan,
261 Diego Garcia-Olano, Diego Perino, Dieuwke Hupkes, Egor Lakomkin, Ehab AlBadawy, Elina
262 Lobanova, Emily Dinan, Eric Michael Smith, Filip Radenovic, Francisco Guzmán, Frank Zhang,
263 Gabriel Synnaeve, Gabrielle Lee, Georgia Lewis Anderson, Govind Thattai, Graeme Nail, Gre-
264 goire Mialon, Guan Pang, Guillem Cucurell, Hailey Nguyen, Hannah Korevaar, Hu Xu, Hugo
265 Touvron, Iliyan Zarov, Imanol Arrieta Ibarra, Isabel Kloumann, Ishan Misra, Ivan Evtimov, Jack
266 Zhang, Jade Copet, Jaewon Lee, Jan Geffert, Jana Vranes, Jason Park, Jay Mahadeokar, Jeet Shah,
267 Jelmer van der Linde, Jennifer Billock, Jenny Hong, Jenya Lee, Jeremy Fu, Jianfeng Chi, Jianyu
268 Huang, Jiawen Liu, Jie Wang, Jiecao Yu, Joanna Bitton, Joe Spisak, Jongsoo Park, Joseph Rocca,
269 Joshua Johnstun, Joshua Saxe, Junteng Jia, Kalyan Vasuden Alwala, Karthik Prasad, Kartikeya
270 Upasani, Kate Plawiak, Ke Li, Kenneth Heafield, Kevin Stone, Khalid El-Arini, Krithika Iyer,
271 Kshitiz Malik, Kuenley Chiu, Kunal Bhalla, Kushal Lakhotia, Lauren Rantala-Yearly, Laurens
272 van der Maaten, Lawrence Chen, Liang Tan, Liz Jenkins, Louis Martin, Lovish Madaan, Lubo
273 Malo, Lukas Blecher, Lukas Landzaat, Luke de Oliveira, Madeline Muzzi, Mahesh Pasupuleti,
274 Mannat Singh, Manohar Paluri, Marcin Kardas, Maria Tsimpoukelli, Mathew Oldham, Mathieu
275 Rita, Maya Pavlova, Melanie Kambadur, Mike Lewis, Min Si, Mitesh Kumar Singh, Mona Has-
276 san, Naman Goyal, Narjes Torabi, Nikolay Bashlykov, Nikolay Bogoychev, Niladri Chatterji, Ning
277 Zhang, Olivier Duchenne, Onur Çelebi, Patrick Alrassy, Pengchuan Zhang, Pengwei Li, Petar Va-
278 sic, Peter Weng, Prajjwal Bhargava, Pratik Dubal, Praveen Krishnan, Punit Singh Koura, Puxin
279 Xu, Qing He, Qingxiao Dong, Ragavan Srinivasan, Raj Ganapathy, Ramon Calderer, Ricardo Sil-
280 veira Cabral, Robert Stojnic, Roberta Raileanu, Rohan Maheswari, Rohit Girdhar, Rohit Patel,
281 Romain Sauvestre, Ronnie Polidoro, Roshan Sumbaly, Ross Taylor, Ruan Silva, Rui Hou, Rui
282 Wang, Saghar Hosseini, Sahana Chennabasappa, Sanjay Singh, Sean Bell, Seohyun Sonia Kim,
283 Sergey Edunov, Shaoliang Nie, Sharan Narang, Sharath Raparthy, Sheng Shen, Shengye Wan,
284 Shruti Bhosale, Shun Zhang, Simon Vandenhende, Soumya Batra, Spencer Whitman, Sten Sootla,
285 Stephane Collot, Suchin Gururangan, Sydney Borodinsky, Tamar Herman, Tara Fowler, Tarek
286 Sheasha, Thomas Georgiou, Thomas Scialom, Tobias Speckbacher, Todor Mihaylov, Tong Xiao,
287 Ujjwal Karn, Vedanuj Goswami, Vibhor Gupta, Vignesh Ramanathan, Viktor Kerkez, Vincent
288 Gouget, Virginie Do, Vish Vogeti, Vitor Albiero, Vladan Petrovic, Weiwei Chu, Wenhan Xiong,
289 Wenyan Fu, Whitney Meers, Xavier Martinet, Xiaodong Wang, Xiaofang Wang, Xiaoqing Ellen

290 Tan, Xide Xia, Xinfeng Xie, Xuchao Jia, Xuewei Wang, Yaelle Goldschlag, Yashesh Gaur, Yas-
 291 mine Babaei, Yi Wen, Yiwen Song, Yuchen Zhang, Yue Li, Yuning Mao, Zacharie Delpierre
 292 Coudert, Zheng Yan, Zhengxing Chen, Zoe Papakipos, Aaditya Singh, Aayushi Srivastava, Abha
 293 Jain, Adam Kelsey, Adam Shajnfeld, Adithya Gangidi, Adolfo Victoria, Ahuva Goldstand, Ajay
 294 Menon, Ajay Sharma, Alex Boesenberg, Alexei Baevski, Allie Feinstein, Amanda Kallet, Amit
 295 Sangani, Amos Teo, Anam Yunus, Andrei Lupu, Andres Alvarado, Andrew Caples, Andrew Gu,
 296 Andrew Ho, Andrew Poulton, Andrew Ryan, Ankit Ramchandani, Annie Dong, Annie Franco,
 297 Anuj Goyal, Aparajita Saraf, Arkabandhu Chowdhury, Ashley Gabriel, Ashwin Bharambe, As-
 298 saf Eisenman, Azadeh Yazdan, Beau James, Ben Maurer, Benjamin Leonhardi, Bernie Huang,
 299 Beth Loyd, Beto De Paola, Bhargavi Paranjape, Bing Liu, Bo Wu, Boyu Ni, Braden Hancock,
 300 Bram Wasti, Brandon Spence, Brani Stojkovic, Brian Gamido, Britt Montalvo, Carl Parker, Carly
 301 Burton, Catalina Mejia, Ce Liu, Changan Wang, Changkyu Kim, Chao Zhou, Chester Hu, Ching-
 302 Hsiang Chu, Chris Cai, Chris Tindal, Christoph Feichtenhofer, Cynthia Gao, Damon Civin, Dana
 303 Beaty, Daniel Kreymer, Daniel Li, David Adkins, David Xu, Davide Testuggine, Delia David,
 304 Devi Parikh, Diana Liskovich, Didem Foss, Dingkan Wang, Duc Le, Dustin Holland, Edward
 305 Dowling, Eissa Jamil, Elaine Montgomery, Eleonora Presani, Emily Hahn, Emily Wood, Eric-
 306 Tuan Le, Erik Brinkman, Esteban Arcaute, Evan Dunbar, Evan Smothers, Fei Sun, Felix Kreuk,
 307 Feng Tian, Filippus Kokkinos, Firat Ozgenel, Francesco Caggioni, Frank Kanayet, Frank Seide,
 308 Gabriela Medina Florez, Gabriella Schwarz, Gada Badeer, Georgia Swee, Gil Halpern, Grant Her-
 309 man, Grigory Sizov, Guangyi Zhang, Guna Lakshminarayanan, Hakan Inan, Hamid Shojanazeri,
 310 Han Zou, Hannah Wang, Hanwen Zha, Haroun Habeeb, Harrison Rudolph, Helen Suk, Henry
 311 Aspegren, Hunter Goldman, Hongyuan Zhan, Ibrahim Damlaj, Igor Molybog, Igor Tufanov, Il-
 312 ias Leontiadis, Irina-Elena Veliche, Itai Gat, Jake Weissman, James Geboski, James Kohli, Janice
 313 Lam, Japhet Asher, Jean-Baptiste Gaya, Jeff Marcus, Jeff Tang, Jennifer Chan, Jenny Zhen, Jeremy
 314 Reizenstein, Jeremy Teboul, Jessica Zhong, Jian Jin, Jingyi Yang, Joe Cummings, Jon Carvill, Jon
 315 Shepard, Jonathan McPhie, Jonathan Torres, Josh Ginsburg, Junjie Wang, Kai Wu, Kam Hou U,
 316 Karan Saxena, Kartikay Khandelwal, Katayoun Zand, Kathy Matosich, Kaushik Veeraraghavan,
 317 Kelly Michelena, Keqian Li, Kiran Jagadeesh, Kun Huang, Kunal Chawla, Kyle Huang, Lailin
 318 Chen, Lakshya Garg, Lavender A, Leandro Silva, Lee Bell, Lei Zhang, Liangpeng Guo, Licheng
 319 Yu, Liron Moshkovich, Luca Wehrstedt, Madian Khabsa, Manav Avalani, Manish Bhatt, Martynas
 320 Mankus, Matan Hasson, Matthew Lennie, Matthias Reso, Maxim Groshev, Maxim Naumov, Maya
 321 Lathi, Meghan Keneally, Miao Liu, Michael L. Seltzer, Michal Valko, Michelle Restrepo, Mihir
 322 Patel, Mik Vyatskov, Mikayel Samvelyan, Mike Clark, Mike Macey, Mike Wang, Miquel Jubert
 323 Hermoso, Mo Metanat, Mohammad Rastegari, Munish Bansal, Nandhini Santhanam, Natascha
 324 Parks, Natasha White, Navyata Bawa, Nayan Singhal, Nick Egebo, Nicolas Usunier, Nikhil Mehta,
 325 Nikolay Pavlovich Laptev, Ning Dong, Norman Cheng, Oleg Chernoguz, Olivia Hart, Omkar
 326 Salpekar, Ozlem Kalinli, Parkin Kent, Parth Parekh, Paul Saab, Pavan Balaji, Pedro Rittner, Philip
 327 Bontrager, Pierre Roux, Piotr Dollar, Polina Zvyagina, Prashant Ratanchandani, Pritish Yuvraj,
 328 Qian Liang, Rachad Alao, Rachel Rodriguez, Rafi Ayub, Raghotham Murthy, Raghu Nayani,
 329 Rahul Mitra, Rangaprabhu Parthasarathy, Raymond Li, Rebekkah Hogan, Robin Battey, Rocky
 330 Wang, Russ Howes, Ruty Rinott, Sachin Mehta, Sachin Siby, Sai Jayesh Bondu, Samyak Datta,
 331 Sara Chugh, Sara Hunt, Sargun Dhillon, Sasha Sidorov, Satadru Pan, Saurabh Mahajan, Saurabh
 332 Verma, Seiji Yamamoto, Sharadh Ramaswamy, Shaun Lindsay, Shaun Lindsay, Sheng Feng,
 333 Shenghao Lin, Shengxin Cindy Zha, Shishir Patil, Shiva Shankar, Shuqiang Zhang, Shuqiang
 334 Zhang, Sinong Wang, Sneha Agarwal, Soji Sajuyigbe, Soumith Chintala, Stephanie Max, Stephen
 335 Chen, Steve Kehoe, Steve Satterfield, Sudarshan Govindaprasad, Sumit Gupta, Summer Deng,
 336 Sungmin Cho, Sunny Virk, Suraj Subramanian, Sy Choudhury, Sydney Goldman, Tal Remez,
 337 Tamar Glaser, Tamara Best, Thilo Koehler, Thomas Robinson, Tianhe Li, Tianjun Zhang, Tim
 338 Matthews, Timothy Chou, Tzook Shaked, Varun Vontimitta, Victoria Ajayi, Victoria Montanez,
 339 Vijai Mohan, Vinay Satish Kumar, Vishal Mangla, Vlad Ionescu, Vlad Poenaru, Vlad Tiberiu
 340 Mihailescu, Vladimir Ivanov, Wei Li, Wenchen Wang, Wenwen Jiang, Wes Bouaziz, Will Con-
 341 stable, Xiaocheng Tang, Xiaoqian Wu, Xiaolan Wang, Xilun Wu, Xinbo Gao, Yaniv Kleinman,
 342 Yanjun Chen, Ye Hu, Ye Jia, Ye Qi, Yenda Li, Yilin Zhang, Ying Zhang, Yossi Adi, Youngjin
 343 Nam, Yu Wang, Yu Zhao, Yuchen Hao, Yundi Qian, Yunlu Li, Yuzi He, Zach Rait, Zachary De-
 344 Vito, Zef Rosnbrick, Zhaoduo Wen, Zhenyu Yang, Zhiwei Zhao, and Zhiyu Ma. The Llama 3
 345 Herd of Models. *arXiv:2407.21783*, 2024.

346 Shibo Hao, Sainbayar Sukhbaatar, DiJia Su, Xian Li, Zhiting Hu, Jason Weston, and Yuandong Tian.
 347 Training Large Language Models to Reason in a Continuous Latent Space. In *ICLR*, 2025.

348 Neil Houlsby, Andrei Giurgiu, Stanislaw Jastrzebski, Bruna Morrone, Quentin de Laroussilhe, An-
349 drea Gesmundo, Mona Attariyan, and Sylvain Gelly. Parameter-Efficient Transfer Learning for
350 NLP. In *ICML*, 2019.

351 Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang,
352 and Weizhu Chen. LoRA: Low-Rank Adaptation of Large Language Models. In *ICLR*, 2022.

353 Neel Jain, Ping-yeh Chiang, Yuxin Wen, John Kirchenbauer, Hong-Min Chu, Gowthami Somepalli,
354 Brian R. Bartoldson, Bhavya Kailkhura, Avi Schwarzschild, Aniruddha Saha, Micah Goldblum,
355 Jonas Geiping, and Tom Goldstein. NEFTune: Noisy Embeddings Improve Instruction Finetuning.
356 In *ICLR*, 2024.

357 Xinyue Kang, Diwei Shi, and Li Chen. Model Whisper: Steering Vectors Unlock Large Language
358 Models’ Potential in Test-time. In *AAAI*, 2026.

359 Brian Lester, Rami Al-Rfou, and Noah Constant. The Power of Scale for Parameter-Efficient Prompt
360 Tuning. In *EMNLP*, 2021.

361 Xiang Lisa Li and Percy Liang. Prefix-Tuning: Optimizing Continuous Prompts for Generation. In
362 *ACL-IJCNLP*, 2021.

363 Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike,
364 John Schulman, Ilya Sutskever, and Karl Cobbe. Let’s Verify Step by Step. In *ICLR*, 2024.

365 Xiao Liu, Yanan Zheng, Zhengxiao Du, Ming Ding, Yujie Qian, Zhilin Yang, and Jie Tang. GPT
366 Understands, Too. *AI Open*, 5:208–215, 2024.

367 Aman Madaan and Amir Yazdanbakhsh. Text and Patterns: For Effective Chain of Thought, It Takes
368 Two to Tango. *arXiv:2209.07686*, 2022.

369 Alexander Robey, Eric Wong, Hamed Hassani, and George J. Pappas. SmoothLLM: Defending Large
370 Language Models Against Jailbreaking Attacks. *Transactions on Machine Learning Research*,
371 2025.

372 Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang,
373 Mingchuan Zhang, Y.K. Li, Y. Wu, and Daya Guo. DeepSeekMath: Pushing the Limits of Math-
374 ematical Reasoning in Open Language Models. *arXiv:2402.03300*, 2024.

375 Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov.
376 Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *Journal of Machine Learn-
377 ing Research*, 15:1929–1958, 2014.

378 Zhenpeng Su, Lei Yu, Minxuan Lv, Yuntao Li, Wenping Hu, Fuzheng Zhang, Kun Gai, and
379 Guorui Zhou. CE-GPPO: Coordinating Entropy via Gradient-Preserving Clipping Policy Opti-
380 mization in Reinforcement Learning. In *ACL*, 2026.

381 Shenzhi Wang, Le Yu, Chang Gao, Chujie Zheng, Shixuan Liu, Rui Lu, Kai Dang, Xionghui Chen,
382 Jianxin Yang, Zhenru Zhang, Yuqiong Liu, An Yang, Andrew Zhao, Yang Yue, Shiji Song, Bowen
383 Yu, Gao Huang, and Junyang Lin. Beyond the 80/20 Rule: High-Entropy Minority Tokens Drive
384 Effective Reinforcement Learning for LLM Reasoning. In *NeurIPS*, 2025.

385 Yige Xu, Xu Guo, Zhiwei Zeng, and Chunyan Miao. SoftCoT: Soft Chain-of-Thought for Efficient
386 Reasoning with LLMs. In *ACL*, 2025.

387 An Yang, Beichen Zhang, Binyuan Hui, Bofei Gao, Bowen Yu, Chengpeng Li, Dayiheng Liu,
388 Jianhong Tu, Jingren Zhou, Junyang Lin, Keming Lu, Mingfeng Xue, Runji Lin, Tianyu Liu,
389 Xingzhang Ren, and Zhenru Zhang. Qwen2.5-Math Technical Report: Toward Mathematical
390 Expert Model via Self-Improvement. *arXiv:2409.12122*, 2024.

391 Wengao Ye, Yan Liang, and Lianlei Shan. Thinking on the Fly: Test-Time Reasoning Enhancement
392 via Latent Thought Policy Optimization. In *ICLR*, 2026.

- 393 Qiying Yu, Zheng Zhang, Ruofei Zhu, Yufeng Yuan, Xiaochen Zuo, Yu Yue, Weinan Dai, Tiantian
394 Fan, Gaohong Liu, Juncai Liu, Lingjun Liu, Xin Liu, Haibin Lin, Zhiqi Lin, Bole Ma, Guangming
395 Sheng, Yuxuan Tong, Chi Zhang, Mofan Zhang, Ru Zhang, Wang Zhang, Hang Zhu, Jinhua Zhu,
396 Jiaze Chen, Jiangjie Chen, Chengyi Wang, Hongli Yu, Yuxuan Song, Xiangpeng Wei, Hao Zhou,
397 Jingjing Liu, Wei-Ying Ma, Ya-Qin Zhang, Lin Yan, Yonghui Wu, and Mingxuan Wang. DAPO:
398 An Open-Source LLM Reinforcement Learning System at Scale. In *NeurIPS*, 2025.
- 399 Guibin Zhang, Muxin Fu, and Shuicheng Yan. MemGen: Weaving Generative Latent Memory for
400 Self-Evolving Agents. In *ICLR*, 2026.

401 A 실험 설정과 전체 정확도 분석

402 Table 6은 본문 Table 1에서 위치별 최고 성능만 요약해 제시한 결과를, Prefix, Infix, Suffix 별 전체
 403 정확도로 다시 펼쳐 보인다. Table 7는 각 모델-벤치마크 조합에서 사용한 RSP 토큰 수 L 을 정리
 404 한 것으로, 후보 집합 {10, 15, 20}에서 선택했다. 모든 실험은 단일 NVIDIA A6000 40GB GPU
 405 에서 greedy decoding으로 수행했으며, 최대 생성 길이는 MATH-500과 GSM8K에서 3,072 토큰,
 406 AIME24에서 4,096 토큰으로 고정했다. 배치 크기는 모델별로 고정했다(LLaMA-3.1-8B-Instruct
 407 와 Qwen2.5-Math-7B 계열은 16, Qwen2.5-Math-1.5B 계열은 32).

Table 6: 모델 설정, 주입 위치, 벤치마크별 정확도(%). 괄호 안 값은 baseline 대비 변화량이다. 굵게는 최고 성능, 밑줄은 각 모델-벤치마크 조합에서 두 번째 성능을 뜻한다.

Model	Mode	MATH-500	GSM8K	AIME24
<i>Instruct Models</i>				
LLaMA-3.1-8B-Instruct	Baseline	52.20	85.75	<u>6.67</u>
	Prefix	45.00 (−7.2)	76.35 (−9.4)	3.33 (−3.3)
	Infix	<u>49.40</u> (−2.8)	85.97 (+0.2)	10.00 (+3.3)
	Suffix	<u>49.40</u> (−2.8)	86.73 (+1.0)	10.00 (+3.3)
Qwen2.5-Math-7B-Instruct	Baseline	83.20	95.45	<u>13.33</u>
	Prefix	81.40 (−1.8)	94.92 (−0.5)	<u>13.33</u> (+0.0)
	Infix	84.20 (+1.0)	<u>95.60</u> (+0.2)	16.67 (+3.3)
	Suffix	<u>83.40</u> (+0.2)	95.68 (+0.2)	16.67 (+3.3)
Qwen2.5-Math-1.5B-Instruct	Baseline	73.00	85.29	10.00
	Prefix	74.80 (+1.8)	85.29 (+0.0)	<u>13.33</u> (+3.3)
	Infix	75.20 (+2.2)	85.75 (+0.5)	<u>6.67</u> (−3.3)
	Suffix	74.20 (+1.2)	84.69 (−0.6)	20.00 (+10.0)
<i>Base Models (Raw Text)</i>				
Qwen2.5-Math-7B	Baseline	72.20	<u>84.15</u>	6.67
	Prefix	<u>71.60</u> (−0.6)	84.31 (+0.2)	16.67 (+10.0)
	Infix	63.20 (−9.0)	64.29 (−19.9)	16.67 (+10.0)
	Suffix	55.60 (−16.6)	54.13 (−30.0)	<u>13.33</u> (+6.7)
Qwen2.5-Math-1.5B	Baseline	<u>61.40</u>	77.86	16.67
	Prefix	64.40 (+3.0)	<u>74.30</u> (−3.6)	<u>10.00</u> (−6.7)
	Infix	63.20 (+1.8)	73.92 (−3.9)	<u>10.00</u> (−6.7)
	Suffix	54.60 (−6.8)	58.61 (−19.3)	3.33 (−13.3)
<i>Base Models + ChatML (Format Mismatch)</i>				
Qwen2.5-Math-7B	Baseline	52.20	58.30	23.33
	Prefix	59.20 (+7.0)	56.41 (−1.9)	<u>3.33</u> (−20.0)
	Infix	<u>62.00</u> (+9.8)	69.07 (+10.8)	23.33 (+0.0)
	Suffix	70.40 (+18.2)	75.97 (+17.7)	23.33 (+0.0)
Qwen2.5-Math-1.5B	Baseline	34.40	37.45	<u>13.33</u>
	Prefix	63.40 (+29.0)	67.02 (+29.6)	20.00 (+6.7)
	Infix	39.20 (+4.8)	50.42 (+13.0)	6.67 (−6.7)
	Suffix	<u>51.00</u> (+16.6)	<u>50.64</u> (+13.2)	<u>13.33</u> (+0.0)

Table 7: 각 모델과 벤치마크에 사용한 RSP 토큰 수 (L).

Model	MATH-500	GSM8K	AIME24
LLaMA-3.1-8B-Instruct	15	20	15
Qwen2.5-Math-7B-Instruct	20	20	20
Qwen2.5-Math-1.5B-Instruct	20	10	20
Qwen2.5-Math-7B	10	10	20
Qwen2.5-Math-1.5B	10	10	20
Qwen2.5-Math-1.5B (ChatML)	20	20	10
Qwen2.5-Math-7B (ChatML)	20	20	20

408 A.1 RSP 주입 위치와 프롬프트 템플릿

409 아래에는 모든 모델 유형에서 주입 위치별 프롬프트 구조를 정리했다. **파란색 텍스트**는 RSP
 410 임베딩, **보라색 텍스트**는 특수 토큰을 뜻한다.

411 A.1.1 Prefix

412 Prefix 주입에서는 RSP 임베딩을 프롬프트 임베딩 앞에 연결한다. 텍스트 자체는 수정하지
413 않는다.

414 ChatML (Qwen Instruct / Base + ChatML).

```
[Random Embeddings (L tokens)]
<|im_start|>system
Please reason step by step, and put your final answer within \boxed{>
im_end|>
<|im_start|>user
{question}<|im_end|>
<|im_start|>assistant
```

416 LLaMA Chat Template.

```
[Random Embeddings (L tokens)]
<|begin_of_text|>
<|start_header_id|>system<|end_header_id|>
Cutting Knowledge Date: December 2023
Today Date: 26 Jul 2024
Please reason step by step, and put your final answer within \boxed{>
eot_id|>
<|start_header_id|>user<|end_header_id|>
{question}<|eot_id|>
<|start_header_id|>assistant<|end_header_id|>
```

418 Raw Text (Qwen Base).

```
[Random Embeddings (L tokens)]
{question}
Please reason step by step, and put your final answer within \boxed{>.
```

420 A.1.2 Infix

421 Infix 주입에서는 설명 문구와 특수 토큰을 프롬프트 내부에 넣은 뒤, 그 특수 토큰 위치를 임베딩
422 수준에서 RSP로 교체한다.

423 ChatML (Qwen Instruct / Base + ChatML).

```
<|im_start|>system
Please reason step by step, and put your final answer within \boxed{>
im_end|>
<|im_start|>user
{question}

There are {L} special tokens that contain compressed latent reasoning
information that might be useful for your reasoning. If these tokens are
useful for your case, you can use them as reference. If these tokens are
not useful for your case, you can ignore them and focus back to solving the
problem.

Here are the {L} special tokens: <special_token_1>...<special_token_L>
<|im_end|>
<|im_start|>assistant
```

425 LLaMA Chat Template.

```
<|begin_of_text|>
<|start_header_id|>system<|end_header_id|>
Cutting Knowledge Date: December 2023
Today Date: 26 Jul 2024
Please reason step by step, and put your final answer within \boxed{>.
```

```

eot_id|>
<|start_header_id|>user<|end_header_id|>
{question}

There are {L} special tokens that contain compressed latent reasoning
information that might be useful for your reasoning. If these tokens are
useful for your case, you can use them as reference. If these tokens are
not useful for your case, you can ignore them and focus back to solving the
problem.

Here are the {L} special tokens:
<reserved_special_token_0>...
<reserved_special_token_L>
<|eot_id|>
<|start_header_id|>assistant<|end_header_id|>

```

427

428 Raw Text (Qwen Base).

```

{question}

There are {L} special tokens that contain compressed latent reasoning
information that might be useful for your reasoning. If these tokens are
useful for your case, you can use them as reference. If these tokens are
not useful for your case, you can ignore them and focus back to solving the
problem.

Here are the {L} special tokens: <special_token_1>...<special_token_L>
Please reason step by step, and put your final answer within \boxed{ }.

```

429

430 A.1.3 Suffix

431 채팅 템플릿 모델에서는 end-of-turn 토큰 바로 앞에 RSP 임베딩을 넣고, raw text 모델에서는
432 프롬프트 마지막에 RSP 임베딩을 이어 붙인다.

433 ChatML (Qwen Instruct / Base + ChatML).

```

<|im_start|>system
Please reason step by step, and put your final answer within \boxed{ }.<|
im_end|>
<|im_start|>user
{question}[Random Embeddings (L tokens)]<|im_end|>
<|im_start|>assistant

```

434

435 LLaMA Chat Template.

```

<|begin_of_text|>
<|start_header_id|>system<|end_header_id|>
Cutting Knowledge Date: December 2023
Today Date: 26 Jul 2024
Please reason step by step, and put your final answer within \boxed{ }.<|
eot_id|>
<|start_header_id|>user<|end_header_id|>
{question}[Random Embeddings (L tokens)]<|eot_id|>
<|start_header_id|>assistant<|end_header_id|>

```

436

437 Raw Text (Qwen Base).

```

{question}
Please reason step by step, and put your final answer within \boxed{ }. [Random
Embeddings (L tokens)]

```

438

439 A.2 정답 추출과 채점

440 최종 정답은 fallback 체인을 통해 모델 출력에서 추출한다. 각 단계는 순서대로 시도하며, 추출에
441 실패하면 다음 단계로 넘어간다.

정답 추출 fallback 체인

1. "final answer is \$...\$. I hope" 패턴 (Minerva 형식)
2. `\boxed{...}`: 마지막 비어 있지 않은 box를 사용하고, 빈 `\boxed{}`는 건너뛰
3. "the answer is" 뒤 텍스트
4. "final answer is" 뒤 텍스트
5. 출력 마지막 숫자(regex fallback)

추출된 정답은 `$`, `\left`, `\right`, 단위 문자열을 제거해 정규화한다. 채점은 symbolic equivalence checking으로 수행하며, 정확한 문자열 일치, 수치 비교(`math.isclose`, `rel_tol=1e-4`), SymPy symbolic simplification을 차례로 적용한다.

A.3 재현한 선행연구의 하이퍼파라미터

모든 선행 방법은 Qwen2.5-Math-1.5B-Instruct와 Qwen2.5-Math-7B-Instruct에서 재현했으며, greedy decoding(`temperature = 0`)과 통일된 answer extraction pipeline으로 평가했다.

TTSV. Prefix 길이는 20이며, AdamW optimizer로 20 epoch 동안 학습했다. 배치 크기는 2, gradient accumulation은 8 step, 스케줄은 선형 learning rate schedule을 사용했다. Learning rate는 Qwen-1.5B에 $1e-3$, Qwen-7B에 $1e-5$ 를 사용했다.

LTPO. Table 8는 벤치마크별 하이퍼파라미터를 정리한 것이다.

Table 8: LTPO 하이퍼파라미터.

Parameter	GSM8K	MATH-500	AIME24
tokens	8	8	8
steps	20	20	20
top_k	10	10	10
sigma	20	20	5
sigma_decay	0.95	0.95	0.95
lr	$1e-2$	$5e-3$	$5e-2$

SoftCoT. Projection module은 10 epoch 동안 학습했다. Thought token 수는 학습 시 32, 평가 시 4다. 배치 크기는 GSM8K에서 4, MATH에서는 1이며 gradient accumulation 4를 사용했다. 작은 모델(assistant)은 두 설정 모두 Qwen2.5-Math-1.5B-Instruct이고, 큰 모델은 Qwen2.5-Math-1.5B-Instruct(`learning rate 2e-5`) 또는 Qwen2.5-Math-7B-Instruct(`learning rate 5e-6`)이다. MATH-500과 AIME24 평가는 GSM8K에서 학습한 projection module을 사용했는데, MATH에서 학습한 버전보다 더 높은 정확도를 보였기 때문이다.

A.4 전체 엔트로피 곡선

Figure 5는 entropy, top-1 probability, varentropy의 전체 정규화 생성 궤적(0-100%)을 보여준다. 모든 방법은 생성 초반 단계를 지나면 비슷한 수준으로 수렴하며, 이는 RSP가 유도하는 분포 변화가 초기 추론 단계에 국소화되어 있음을 다시 확인해 준다.




Figure 5: 전체 정규화 생성 궤적(0-100%)에서의 평균 entropy(위), top-1 probability(가운데), varentropy(아래). MATH-500 전체 평균이며, 음영은 ± 1 SEM을 뜻한다. 실선은 RSP 변형과 baseline, 점선은 기존 soft prompt 방법이다. 모든 방법은 초반 단계를 지나면 수렴한다.

463 B 의미적 다양성에 대한 추가 분석

464 이 부록은 Section 3.4에서 보고한 의미적 다양성 결과를 보충한다. 더 넓은 문제 집합에 대해
465 문제별 t-SNE 도표를 함께 제시한다.




Figure 6: 평가한 64개 MATH-500 문제 중 48개에 대한 BGE-M3 임베딩의 t-SNE 투영(6×8 격자). 각 subplot은 Qwen2.5-Math-1.5B-Instruct에서 $\tau = 1.0$ 으로 생성한 baseline 300개(빨강)와 RSP suffix 300개(파랑)를 보여준다. 채워진 표식은 정답, 빈 표식은 오답이며, 제목은 subject/problem_id를 뜻한다. 대부분의 문제에서 RSP 궤적은 여러 개의 분리된 영역으로 퍼지는 반면, baseline 샘플은 하나의 지배적 클러스터에 더 집중된다.

466 C 토큰 수준 분포 지표

467 이 부록은 Section 3.4의 토큰 수준 분석에 사용한 세 지표를 형식적으로 정의한다. P_{base} 는
468 $\tau = 1.0$ 에서의 baseline 다음 토큰 분포, P_{target} 은 비교 대상 분포(예: $\tau = 2.0$ 의 baseline, 또는
469 $\tau = 1.0$ 의 RSP)라 하자. 모든 지표는 첫 생성 단계에서 저장한 logits로부터 해석적으로 계산
470 한다.

471 **Spearman 순위 상관.** Spearman의 ρ 는 두 분포의 토큰 순위 사이 Pearson 상관계수다.

$$\rho = \text{Pearson}(\text{rank}(P_{\text{target}}), \text{rank}(P_{\text{base}})). \quad (3)$$

472 Temperature scaling $P^{(\tau)} \propto P^{1/\tau}$ 는 엄격한 단조 변환이므로, 어떤 $\tau > 0$ 에서도 토큰 순서를
473 정확히 보존한다. 따라서 $\rho = 1$ 은 수학적 항등식이다. 그러므로 $\rho < 1$ 은 temperature scaling
474 만으로는 만들 수 없는 순위 재조작이 일어났음을 뜻한다.

475 **Top- K 밖의 질량.** $\text{TopK}(P_{\text{base}})$ 를 P_{base} 에서 확률이 가장 높은 K 개 토큰의 집합이라 하자. 비
476 교 대상 분포가 이 집합 밖에 두는 확률 질량은

$$\text{MassOutside}_K = 1 - \sum_{t \in \text{TopK}(P_{\text{base}})} P_{\text{target}}(t). \quad (4)$$

477 이 지표는 지지 집합 확장을 직접 측정한다. 즉 baseline의 선호 집합에 없던 토큰에 비교 대상이
478 얼마나 많은 확률을 배정하는지를 본다. 본문에 보고한 값은 $K = 10$ 을 사용했다.

479 **Jensen-Shannon divergence.** Kullback-Leibler divergence의 대칭적이고 bounded된 형태는 다
480 음과 같다.

$$\text{JS}(P, Q) = \frac{1}{2} \text{KL}(P \parallel M) + \frac{1}{2} \text{KL}(Q \parallel M), \quad M = \frac{1}{2}(P + Q). \quad (5)$$

481 로그는 밑이 2이므로 $\text{JS} \in [0, 1]$ 이다. 저장한 top-100 바깥의 토큰에는 softmax 전에 sentinel
482 $\text{logit}(-10^9)$ 을 넣었는데, 본 설정에서는 top-5가 이미 확률 질량의 99.9% 이상을 덮기 때문에 이
483 근사는 무시 가능하다.

484 D 무작위 프롬프트는 왜 의미적으로 중립적이고 방향적으로 포괄적인가

485 이 부록은 Section 4.1에서 사용한 주장을 형식화한다. 핵심은 무작위 프롬프트가 유용한 잠재
486 의미를 담고 있다는 것이 아니다. 더 약하고 정확한 주장은, 중심화한 뒤에는 어떤 미리 정한
487 의미 방향도 체계적으로 편들지 않으면서도, 고정된 분산 예산 아래 모든 방향을 덮을 수 있다는
488 것이다. 이는 언어학적 의미가 완전히 사라진다는 주장이 아니라, 섭동 방향의 기하학적 성질에
489 관한 명제다.

490 D.1 의미적 중립성

491 $\bar{h} \sim \mathcal{N}(0, \sigma^2 \mathbf{I}_d)$ 라 하고, $\bar{h} \neq 0$ 일 때 $\hat{h} := \bar{h}/\|\bar{h}\|$ 라 하자. 또한 $u_1, \dots, u_M \in \mathbb{S}^{d-1}$ 를 의미
492 anchor 방향을 나타내는 임의의 고정 단위벡터라 하자.

493 **보조정리 1** (의미적 중립성). 보편 상수 C 가 존재하여, 모든 $\delta \in (0, 1)$ 에 대해

$$\Pr \left[\max_{r \in [M]} |\hat{h}^\top u_r| \leq C \sqrt{\frac{\log(M/\delta)}{d}} \right] \geq 1 - \delta.$$

494 즉 등방성 가우시안 프롬프트의 정규화된 방향은, 고정된 유한 개의 의미 anchor 전체에 대해
495 높은 확률로 거의 직교한다.

496 *Proof.* 각 고정 u_r 에 대해 회전 불변성으로부터 $u_r^\top \bar{h} \sim \mathcal{N}(0, \sigma^2)$ 가 성립하므로,

$$\Pr(|u_r^\top \bar{h}| \geq t) \leq 2 \exp\left(-\frac{t^2}{2\sigma^2}\right).$$

497 $r \in [M]$ 전체에 대해 union bound를 적용하면

$$\Pr \left[\max_{r \in [M]} |u_r^\top \bar{h}| \geq t \right] \leq 2M \exp\left(-\frac{t^2}{2\sigma^2}\right).$$

498 한편 표준 chi-square concentration으로부터 보편 상수 $c > 0$ 가 존재하여

$$\Pr \left[\|\bar{h}\| \leq \frac{\sigma\sqrt{d}}{2} \right] \leq \exp(-cd)$$

499 가 성립한다. 사건 $\|\bar{h}\| \geq \sigma\sqrt{d}/2$ 위에서는

$$|\hat{h}^\top u_r| = \frac{|u_r^\top \bar{h}|}{\|\bar{h}\|} \leq \frac{2|u_r^\top \bar{h}|}{\sigma\sqrt{d}}.$$

500 이제

$$t = C' \sigma \sqrt{\log(M/\delta)}$$

501 로 두고 C' 를 충분히 큰 상수로 잡으면, 두 bound를 결합해

$$\max_{r \in [M]} |\hat{h}^\top u_r| \leq C \sqrt{\frac{\log(M/\delta)}{d}}$$

502 가 적어도 $1 - \delta$ 확률로 성립한다. □

503 토큰 임베딩과의 대비는 즉각적이다. $e_s \neq 0$ 를 고정된 토큰 임베딩이라 하고 $\hat{e}_s := e_s/\|e_s\|$ 라
504 하자. 이때 anchor 방향을 $u = \hat{e}_s$ 로 잡으면

$$|\hat{e}_s^\top u| = 1.$$

505 즉 토큰 프롬프트는 적어도 하나의 의미 방향과 최대 정렬을 이루지만, 등방성 무작위 프롬프트
506 는 어떤 고정된 유한 집합의 의미 방향에도 거의 직교한다. 우리가 말하는 “의미적 비개입성”은
507 바로 이 뜻이다. 토큰은 의미적 commitment를 주입하는 반면, 무작위 프롬프트는 의미적으로
508 특정 방향에 묶이지 않은 섭동으로 기능한다.

509 **D.2 Theorem 1 (미니맥스 방향 커버리지)의 증명**

510 본문에서 사용한 local linear logit surrogate에 직접 등장하는 양은 단위벡터 b 에 대해 b 방향의
 511 1차 섭동 에너지 $\text{Var}_{h \sim D}(b^\top h) = b^\top \Sigma_D b$ 이다. $\min_{\|b\|=1} b^\top \Sigma_D b = \lambda_{\min}(\Sigma_D)$ 이므로 최소 방향
 512 분산은 정확히 $\lambda_{\min}(\Sigma_D)$ 이다.

513 *Theorem 1의 증명.* Σ_D 의 고윳값을 $\lambda_1, \dots, \lambda_d$ 라 하면,

$$\lambda_{\min}(\Sigma_D) \leq \frac{1}{d} \sum_{m=1}^d \lambda_m = \frac{\text{tr}(\Sigma_D)}{d} \leq \frac{\rho^2}{d}.$$

514 모든 고윳값이 같을 때, 즉 $\Sigma_D = (\rho^2/d)\mathbf{I}_d$ 일 때 그리고 그럴 때만 등호가 성립한다. $\square$

515 이 정리는 등방성 무작위성의 장점을 형식화한다. RSP는 어떤 logit-sensitive 방향을 섭동해야
 516 하는지 사전에 알지 못하므로, 고정된 분산 예산 아래에서 등방성 분포는 모든 방향에 대한
 517 최악 경우 섭동량을 유일하게 최대화한다. 고정 토큰 프롬프트는 결정적 섭동이므로 $\Sigma_D = 0$
 518 이고 $\lambda_{\min} = 0$ 이며, 비등방 섭동은 항상 $\lambda_{\min}(\Sigma_D) < \rho^2/d$ 이므로 적어도 한 방향에서 등방
 519 최적해보다 덜 탐색하게 된다.

520 E 본문 이론 결과의 증명

521 E.1 RSP가 유도하는 섭동의 성질

522 본문 Eq. (2)의 분해 $\mathbf{x}_i^{(\ell+1)} = (1 - w_{r,i}^{(\ell)})\tilde{\mathbf{x}}_i^{(\ell+1)} + \boldsymbol{\eta}_i^{(\ell)}$ 에서 무작위 기여 항 $\boldsymbol{\eta}_i^{(\ell)} = \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{rj}^{(\ell)}$
 523 의 통계적 성질을 분석한다.

524 **조건부 기댓값.** Attention weight에 조건부로 두면, 본문 §4.2에서 정의한 무작위 토큰 어텐션
 525 질량 $w_{r,i}^{(\ell)}$ 를 써서

$$\mathbb{E}[\boldsymbol{\eta}_i^{(\ell)} \mid \alpha^{(\ell)}] = \mu_E w_{r,i}^{(\ell)}. \quad (6)$$

526 **조건부 공분산.** 무작위 벡터들이 공분산 $\sigma_E^2 \mathbf{I}$ 를 갖는 독립 샘플이라고 가정하면

$$\text{Cov}(\boldsymbol{\eta}_i^{(\ell)} \mid \alpha^{(\ell)}) = \sigma_E^2 \sum_{j=1}^L (\alpha_{i,n+j}^{(\ell)})^2 \mathbf{I}. \quad (7)$$

527 $\sum_j \alpha_j^2 \leq (\sum_j \alpha_j)^2$ 를 이용하면

$$\text{Cov}(\boldsymbol{\eta}_i^{(\ell)} \mid \alpha^{(\ell)}) \preceq \sigma_E^2 (w_{r,i}^{(\ell)})^2 \mathbf{I} \quad (8)$$

528 를 얻는다.

529 **Bias-to-variance 비율.** 평균과 표준편차의 비는 다음처럼 상계된다.

$$\frac{\|\mathbb{E}[\boldsymbol{\eta}_i^{(\ell)} \mid \alpha^{(\ell)}]\|}{\sqrt{\text{Var}(\boldsymbol{\eta}_i^{(\ell)} \mid \alpha^{(\ell)})}} \leq \frac{|\mu_E|}{\sigma_E}. \quad (9)$$

530 실험적으로는 $|\mu_E|/\sigma_E \ll 1$ 이므로, 체계적 bias보다 확률적 성분이 지배적이다.

531 **실험적 검증.** Table 9는 실험에 사용한 모든 모델에 대해 임베딩 행렬 통계를 보고한다.

Table 9: 임베딩 행렬 통계. 모든 모델에서 $|\mu_E|/\sigma_E < 0.02$ 이다.

Model	μ_E	σ_E	$ \mu_E /\sigma_E$
LLaMA-3.1-8B-Instruct	0.00002	0.01057	0.002
Qwen2.5-Math-7B-Instruct	-0.00002	0.01647	0.001
Qwen2.5-Math-1.5B-Instruct	0.00019	0.01585	0.012
Qwen2.5-Math-7B	-0.00003	0.01842	0.001
Qwen2.5-Math-1.5B	0.00038	0.02990	0.013

532 **함의.** 따라서 이 섭동은 $w_{r,i}^{(\ell)}$ 에 의해 크기가 제어되는 거의 zero-mean noise처럼 동작하며,
 533 본문에서 제시한 Langevin 유사 해석을 정당화한다.

534 E.2 Attention 감쇠 경계

535 **정리 2** (Attention 감쇠). 본문 §4.2의 *logit gap* $\Delta_i^{(\ell)}$ 아래에서, 무작위 토큰에 할당되는 총 *attention*
 536 은

$$w_{r,i}^{(\ell)} \leq \frac{L}{L + n \cdot \exp(\Delta_i^{(\ell)} / \sqrt{d})} \quad (10)$$

537 를 만족한다.

538 *Proof.* 실제 key에 대해 $s_j = \mathbf{q}_i^\top \mathbf{k}_j / \sqrt{d}$, 무작위 key에 대해 $s_{r,j'} = \mathbf{q}_i^\top \mathbf{k}_{r,j'} / \sqrt{d}$ 라 하자. $\Delta_i^{(\ell)}$ 의
 539 정의에 따라 각 실제 key는 $s_j \geq \Delta_i^{(\ell)} / \sqrt{d} + s_{r,\max}$ 를 만족하며, 여기서 $s_{r,\max} = \max_{j'} s_{r,j'}$ 이다.

따라서 모든 실제 key에 대해 $\exp(s_j) \geq \exp(\Delta_i^{(\ell)}/\sqrt{d}) \cdot \exp(s_{r,\max})$ 가 성립한다. 이를 n 개의 실제 key에 대해 합하면

$$\sum_{j=1}^n \exp(s_j) \geq n \cdot \exp(\Delta_i^{(\ell)}/\sqrt{d}) \cdot \exp(s_{r,\max}) \geq n \cdot \exp(\Delta_i^{(\ell)}/\sqrt{d}) \cdot \frac{1}{L} \sum_{j'=1}^L \exp(s_{r,j'}). \quad (11)$$

무작위 토큰에 대한 총 attention은 $w_{r,i}^{(\ell)} = \sum_{j'} \exp(s_{r,j'}) / (\sum_j \exp(s_j) + \sum_{j'} \exp(s_{r,j'}))$ 이므로, 실제 key 합에 대한 하한을 대입하고 $R = \sum_{j'} \exp(s_{r,j'})$ 로 두면

$$w_{r,i}^{(\ell)} = \frac{R}{\sum_j \exp(s_j) + R} \leq \frac{R}{n \cdot \exp(\Delta_i^{(\ell)}/\sqrt{d}) \cdot R/L + R} = \frac{L}{L + n \cdot \exp(\Delta_i^{(\ell)}/\sqrt{d})}. \quad (12)$$

□

따름정리 1 (고정된 logit gap 아래의 시퀀스 방향 annealing). L 과 $\Delta_i^{(\ell)}$ 를 고정하면, 상계

$$f(n) = \frac{L}{L + n \exp(\Delta_i^{(\ell)}/\sqrt{d})}$$

는 실제 토큰 수 n 에 대해 엄격히 감소한다. 따라서 cache 성장만으로도 그 gap과 양립 가능한 최대 섭동 질량은 감소한다.

Proof. $f(n)$ 을 n 에 대해 미분하면

$$f'(n) = -\frac{L \exp(\Delta_i^{(\ell)}/\sqrt{d})}{\left(L + n \exp(\Delta_i^{(\ell)}/\sqrt{d})\right)^2} < 0.$$

따라서 $f(n)$ 은 엄격히 감소한다. □

따름정리 2 (Annealing 하에서의 섭동 소멸). Decoding 동안 $n \rightarrow \infty$ 이고 L 과 $\Delta_i^{(\ell)}$ 가 고정되어 있다면, $w_{r,i}^{(\ell)} \rightarrow 0$ 가 된다. 따라서

$$\left\| \mathbb{E}[\boldsymbol{\eta}_i^{(\ell)} \mid \alpha^{(\ell)}] \right\| = O(w_{r,i}^{(\ell)}) \quad \text{and} \quad \text{tr Cov}(\boldsymbol{\eta}_i^{(\ell)} \mid \alpha^{(\ell)}) = O((w_{r,i}^{(\ell)})^2)$$

도 함께 0으로 간다.

Proof. Corollary 1에 의해 $w_{r,i}^{(\ell)} \rightarrow 0$ 이다. 기댓값 경계는

$$\mathbb{E}[\boldsymbol{\eta}_i^{(\ell)} \mid \alpha^{(\ell)}] = \mu_E w_{r,i}^{(\ell)}$$

에서 바로 나오고, 공분산 경계는

$$\text{Cov}(\boldsymbol{\eta}_i^{(\ell)} \mid \alpha^{(\ell)}) \preceq \sigma_E^2 (w_{r,i}^{(\ell)})^2 \mathbf{I}$$

에서 따른다. □

E.3 출력 분포 이동에 대한 증명

본문은 출력 수준에서 두 가지 주장을 한다. Proposition 1은 쌍대 순위의 무작위화를, Proposition 2은 그보다 한 단계 강한 후보 집합 확장을 다룬다. 두 주장 모두 섭동된 logits의 local first-order surrogate에 대한 명제다.

E.3.1 자기회귀 정식화

자기회귀 decoding에서 시퀀스 $y_{1:T}$ 의 결합 분포는

$$\Pr(y_{1:T} \mid x) = \prod_{t=1}^T p(y_t \mid x, y_{<t}),$$

로 분해된다. 각 단계는 prefix에 조건부인 분포로 결정되므로, RSP가 도입한 섭동은 단일한 전역 분포를 한 번에 바꾸는 것이 아니라 $p(y_t \mid x, y_{<t})$ 에 대한 일련의 국소 변화로 작동한다.

564 E.3.2 RSP 하에서의 logits 국소 선형화

565 중심화된 random soft prompt를 $\bar{h}$ 라 하자. 섭동된 logits를 $\bar{h}$ 의 함수로 보고 $\bar{h} = 0$ 근방에서 국소
 566 smoothness를 가정하면 $z_i(\bar{h}) = z_i + a_i^\top \bar{h} + O(\|\bar{h}\|^2)$ 이며, 여기서 $a_i := \nabla_{\bar{h}} z_i(0)$ 이다. 본문
 567 §4.3와 같은 표기로 1차 surrogate를 $z_i^{\text{lin}}(\bar{h}) := z_i + a_i^\top \bar{h}$ 로 정의한다. 이 surrogate는 충분히 작은
 568 $\|\bar{h}\|$ 에서 유효하며, transformer logits의 전역 모델이라기보다 섭동 방향을 설명하는 1차 근사다.

569 E.3.3 명제 1의 증명 (확률적 순위화)

570 **명제 1** (확률적 순위화). 토큰 쌍 (i, j) 중 $a_i \neq a_j$ 인 것이 존재하면, $0 < \Pr_{\bar{h}}(z_i^{\text{lin}}(\bar{h}) > z_j^{\text{lin}}(\bar{h})) <$
 571 1 이 성립한다.

572 *Proof.* $z_i^{\text{lin}}(\bar{h}) - z_j^{\text{lin}}(\bar{h}) = (z_i - z_j) + (a_i - a_j)^\top \bar{h}$ 이고, $b_{ij} := a_i - a_j \neq 0$ 이며 $\bar{h} \sim \mathcal{N}(0, \sigma^2 I)$
 573 이면 $b_{ij}^\top \bar{h} \sim \mathcal{N}(0, \sigma^2 \|b_{ij}\|^2)$ 인 비퇴화 가우시안이다. 따라서 섭동된 logit 차이는 0의 양쪽에
 574 모두 양의 확률 질량을 갖고, $0 < \Pr_{\bar{h}}(z_i^{\text{lin}}(\bar{h}) > z_j^{\text{lin}}(\bar{h})) < 1$ 이 성립한다. $\square$

575 E.3.4 명제 2의 증명 (지지 집합 확장)

576 **명제 2** (지지 집합 확장). 상태 s_t 에서 baseline top- K 집합을 $J_K(s_t)$ 라 하자. 어떤 토큰 $i \notin$
 577 $J_K(s_t)$ 에 대해 진입 영역

$$\mathcal{G}_{i,K} := \{\bar{h} \in \mathbb{R}^d : z_i^{\text{lin}}(\bar{h}) > z_j^{\text{lin}}(\bar{h}) \text{ for all } j \in J_K(s_t)\}$$

578 의 내부가 비어 있지 않다고 하자. $\bar{h}$ 를 등방성 가우시안에서 샘플링하면 $\Pr_{\bar{h}}(\bar{h} \in \mathcal{G}_{i,K}) > 0$ 이
 579 성립한다.

580 *Proof.* 1차 surrogate에서 토큰 i 가 $J_K(s_t)$ 의 모든 토큰을 앞지른다는 조건은 정확히 $\bar{h} \in \mathcal{G}_{i,K}$
 581 와 동치다. 각 부등식 $z_i^{\text{lin}}(\bar{h}) > z_j^{\text{lin}}(\bar{h})$ 은 열린 half-space를 정의하므로, 유한 개 열린 half-space
 582 의 교집합인 $\mathcal{G}_{i,K}$ 역시 열린 집합이다. 가정에 의해 내부가 비어 있지 않으므로 $\mathcal{G}_{i,K}$ 는 $\mathbb{R}^d$
 583 의 비공집합 열린집합이다. 등방성 가우시안은 $\mathbb{R}^d$ 전역에서 엄밀히 양수인 밀도를 가지므로
 584 비공집합 열린집합은 양의 확률 측도를 갖는다. 따라서 $\Pr_{\bar{h}}(\bar{h} \in \mathcal{G}_{i,K}) > 0$ 이며, 이것이 토큰 i
 585 의 top- K 진입 사건이다. $\square$

586 E.3.5 궤적 수준의 합의: 다중 경로 Pass@ N

587 자기회귀 생성은 조건부 분포를 단계별로 합성하므로, 초기 단계의 섭동이 전혀 다른 궤적으로
 588 이어질 수 있다. 적어도 한 번 baseline top- K 바깥 토큰을 포함하는 궤적의 집합을 $\mathcal{R}_{L,K}(x)$
 589 라 하자. 만약 RSP가 초기 단계에서 이런 토큰의 접근 가능성을 높인다면, 반복 샘플링에서
 590 $\mathcal{R}_{L,K}(x)$ 에 속하는 궤적을 뽑을 확률도 증가한다. 핵심은 시간적 누적이다. 초반의 top- K 진입
 591 한 번이 다음 decoding state를 바꾸고, 그것이 다시 다음 후보 집합을 바꾸는 식으로 이어진다.
 592 이를 형식적으로 모으면 다음 명제가 된다.

593 **명제 3** (다중 경로 Pass@ N). 문제 x 를 고정하고 정답 궤적 집합 $\mathcal{T}^*(x)$ 가 비어 있지 않다고 하자.
 594 baseline 정답 지시자를 $p_{\text{base}}(x) \in \{0, 1\}$ 이라 하고, N 개의 독립적이고 새로운 RSP를 추첨하여
 595 표본당 한 번씩 디코딩한다. (M1) 각 n 에 대해, n 번째 RSP 실행이 $\mathcal{T}^*(x)$ 의 궤적을 만들 주변
 596 확률이 적어도 $p_{\min}(x) > 0$ 이고, (M2) N 번의 RSP 실행이 상호 독립이라 가정하자. 그러면

$$\Pr(\text{Pass}@ (N+1) \text{ on } x) \geq \max\{p_{\text{base}}(x), 1 - (1 - p_{\min}(x))^N\} \geq 1 - e^{-N p_{\min}(x)}.$$

597 증명은 (M2)에 의한 곱 분해와 (M1)에 의한 단조 하한으로 곧바로 이루어진다. (M1)은 과제
 598 측 가정이며 메커니즘만으로는 유도되지 않는다. 본문 §3.4에서 이 가정의 경험적 흔적을 논의
 599 했다.

F Attention Mass 분석

이 부록은 Figure 4에 보고한 per-token attention mass를 형식화하고, reasoning span과 layer 축에 적용한 제외 기준을 명시한다. 500개의 MATH-500 문제 각각에 대해 새로운 $\text{RSP } \mathbf{H} \in \mathbb{R}^{L \times d}$ 를 $L = 10$ 으로 독립 샘플링했으므로, 보고한 heatmap은 문제 자체의 변동성과 RSP 벡터 변동성을 함께 평균한 결과다.

F.1 토큰당 attention 질량

각 문제에서 attention은 연결된 시퀀스 [prompt; $\mathbf{H}$; generation] 위에서 측정하며, generation은 같은 모델이 동일한 RSP 주입 설정 아래 생성한 궤적이다. $\alpha_{i,j}^{(\ell,h)}$ 를 layer ℓ , head h 에서 query 위치 i 가 key 위치 j 로 보내는 post-softmax attention weight라고 하자. 이는 causal mask 아래에서 $\sum_j \alpha_{i,j}^{(\ell,h)} = 1$ 을 만족한다. 질문 토큰과 RSP 토큰의 인덱스 집합을 각각 Q , R 라 하고 크기를 $|Q|$, $|R| = L$, head 수를 H 라 하자. 이때 query i 가 각 그룹으로 보내는 layer ℓ 의 per-token attention mass는

$$\text{PTM}_Q[\ell, i] = \frac{1}{|Q|H} \sum_{h=1}^H \sum_{j \in Q} \alpha_{i,j}^{(\ell,h)}, \quad \text{PTM}_R[\ell, i] = \frac{1}{|R|H} \sum_{h=1}^H \sum_{j \in R} \alpha_{i,j}^{(\ell,h)}. \quad (13)$$

$|Q|$ 와 $|R|$ 로 나누는 정규화는 집합 크기 차이를 보정하므로, 두 양은 동일한 softmax 분모 아래에서 질문 토큰 또는 RSP 토큰 하나가 평균적으로 얼마나 많은 attention을 받는지를 나타낸다. 따라서 질문 토큰은 시퀀스 길이 효과를 흡수하는 크기 보정 baseline 역할을 한다.

F.2 Heatmap 집계

Layer 인덱스와 reasoning position 인덱스를 각각 동일 크기의 다섯 구간 $\{B_L^{(b)}\}_{b=1}^5$, $\{B_P^{(b)}\}_{b=1}^5$ 로 나눈다. 샘플 s 와 목표 집합 $\bullet \in \{Q, R\}$ 에 대해 셀 (b_L, b_P) 의 값은

$$M_{\bullet}^{(s)}[b_L, b_P] = \frac{1}{|B_L^{(b_L)}| \cdot |B_P^{(b_P)}|} \sum_{\ell \in B_L^{(b_L)}} \sum_{i \in B_P^{(b_P)}} \text{PTM}_{\bullet}[\ell, i]. \quad (14)$$

Figure 4는 Eq. (14)를 500개의 유효 샘플에 대해 평균한 결과를 보고한다.

F.3 \boxed{\dots} 구간 제외

Reasoning position 범위는 마지막 \boxed{\dots} 구간이 시작되기 직전에 끝나도록 잡는다. Chain-of-thought 출력은 *text*(내용)와 *pattern*(형식) 성분으로 나뉘며, 이 둘은 downstream 성능에 독립적으로 기여할 수 있다 [Madaan and Yazdanbakhsh, 2022]. \boxed{\dots} 래퍼는 전형적인 pattern 성분이다. 이는 추론을 더 전개하기보다는 답 형식을 마무리하는 짧고 정형화된 span이기 때문이다. 이 구간을 포함하면 reasoning dynamics와 무관한 template-driven attention signature가 섞이게 된다.

F.4 마지막 두 레이어 제외

Layer 축에서는 마지막 두 transformer layer도 제외한다. 이는 우리 설정에만 특수한 것이 아니라, late layer의 두 가지 잘 알려진 성질에서 비롯된다.

출력 투영 특화. 마지막 레이어 근방의 hidden state는 vocabulary logits와 거의 선형 관계를 이루므로, 표현을 바꾸는 블록이라기보다 점진적 선형 readout으로 기능한다 [Belrose et al., 2023]. 같은 맥락에서 late-layer feed-forward module도 출력 분포를 조정하는 메커니즘으로 해석되어 왔다 [Geva et al., 2021]. 따라서 이 레이어들의 attention은 reasoning computation보다 output formation을 더 강하게 반영한다.

Register-token 가설. Vision Transformer에서 정보가 거의 없는 patch token은 deeper layer에서 attention을 흡수하는 *register*로 재활용될 수 있음이 알려져 있다 [Darcet et al., 2024]. RSP 역시 사전학습된 의미를 갖지 않는 연속 토큰이라는 점에서 유사한 성질을 가지므로, late transformer

layer에서 비슷한 재사용이 일어날 가능성을 배제할 수 없다. 마지막 두 레이어를 제외하면 이런 register 유도 교란이 reasoning-phase 신호를 오염시키는 일을 막을 수 있다.

위의 두 근거는 late layer에서 나타나는 잘 알려진 현상, 즉 선형 readout과 잠재적 register 재사용이 reasoning-phase dynamics와 직교하는 attention signature를 만들 수 있음을 뜻한다. 마지막 두 레이어를 제거하는 것은 모델 특이적 tuning이 아니라, 문헌에 근거한 원칙적 제외라고 볼 수 있다.

F.5 추가적인 suffix heatmap

Figure 7는 suffix 주입에서 Qwen2.5-Math-1.5B-Instruct와 LLaMA-3.1-8B-Instruct에 대해 동일한 per-token RSP attention 분석을 보고한다. 앞서 설명한 late-layer 이유 때문에 모든 셀에서 패턴이 완전히 동일하게 일반화되지는 않지만, 전체적인 경향은 두 모델에서 일관된다. 즉 질문 토큰 attention은 레이어 전반에 걸쳐 폭넓게 변하는 반면, RSP attention은 §4.2의 회석 상계가 예측한 것처럼 레이어 방향과 시퀀스 방향으로 함께 감소한다.




Figure 7: 나머지 두 모델(각각 500개 MATH-500 샘플)에서 suffix 주입 시 측정한 per-token RSP attention mass. 축과 전처리는 Figure 4와 동일하다. x축은 다섯 분위로 나눈 reasoning position, y축은 다섯 분위로 나눈 layer depth(위가 얇은 층), 색은 RSP 토큰에 할당된 per-token attention의 500샘플 평균을 뜻한다. `\boxed{}` 구간 내부 토큰과 마지막 두 레이어는 제외했다.

649 G GRPO 정식화

650 주어진 프롬프트 q 에 대해, behavior policy $\pi_{\theta_{\text{old}}}$ 는 보상 $\{R_i\}_{i=1}^G$ 를 갖는 응답 집합 $\{o_i\}_{i=1}^G$ 를
 651 샘플링한다. 각 응답의 advantage는 그룹 수준 보상을 정규화해 계산한다.

$$\hat{A}_{i,t} = \frac{R_i - \text{mean}(\{R_i\}_{i=1}^G)}{\text{std}(\{R_i\}_{i=1}^G)}. \quad (15)$$

652 정책은 KL penalty가 포함된 clipped objective로 업데이트한다.

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left(\min \left(r_{i,t} \hat{A}_{i,t}, \text{clip}(r_{i,t}, 1-\varepsilon, 1+\varepsilon) \hat{A}_{i,t} \right) - \beta D_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}}) \right) \right], \quad (16)$$

653 여기서 $r_{i,t} = \pi_{\theta}(o_{i,t} \mid q, o_{i,<t}) / \pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})$ 는 importance sampling ratio이고, ε 는 clipping
 654 범위, β 는 reference policy π_{ref} 에 대한 KL penalty 세기를 조절한다.

655 H 광범위한 영향

656 본 연구는 무작위 임베딩 주입이 대형 언어 모델의 추론 행동에 어떤 영향을 주는지에 대한
657 실험적·이론적 분석을 제공한다. 기여의 성격은 주로 기초 연구에 가깝지만, GRPO와 같은
658 강화학습 기반 추론 모델 후속학습에는 잠재적 함의를 가진다.

659 **긍정적 영향.** RSP가 유도하는 궤적 다양성은 group-relative advantage estimation 안에서 더
660 풍부한 학습 신호를 제공함으로써, RL 기반 LLM 후속학습의 sample efficiency를 높일 수 있다.
661 이는 reasoning 중심 fine-tuning과 alignment에 필요한 계산 비용을 줄여, 자원이 제한된 연구
662 그룹에도 관련 방법을 더 접근 가능하게 만들 수 있다.

663 **잠재적 우려.** LLM의 유효 출력 지지 집합을 넓히는 방법은 바람직한 대안적 추론 경로뿐
664 아니라, 바람직하지 않거나 분포 밖에 있는 출력의 도달 가능성도 함께 높일 수 있다. 따라서
665 RSP를 실제 시스템에 적용할 때는 이를 독립적인 다양성 원천으로만 보지 말고, 기존의 안전
666 필터링 및 alignment 메커니즘과 함께 사용해야 한다.

667 **영향 범위의 한계.** 본 연구는 새로운 모델이나 데이터셋을 배포하기보다 분석을 제공하는 데
668 초점을 두므로, 직접적인 사회적 영향은 제한적이다. 여기서 논의한 더 넓은 함의는 RSP가 실제
669 학습 파이프라인에 통합되는 향후 연구가 이루어질 때에만 현실화될 수 있다.