

노이즈에서 다양성으로: 대형 언어 모델 추론에서의 무작위 임베딩 주입

Anonymous Author(s)

Affiliation

Address

email

Abstract

최근 *soft prompt* 계열은 학습 가능한 연속 임베딩을 LLM 입력에 삽입해 수학 추론 성능을 높여 왔지만, 주입 자체가 최적화와 독립적으로 모델 행동에 미치는 영향은 거의 분석되지 않았다. 본 논문은 학습 없이 주입되는 Random Soft Prompt(RSP)를 다룬다. RSP는 사전학습 임베딩 행렬의 항별 평균·분산에 맞춘 등방 가우시안에서 추출한 연속 벡터로, 여기서 무작위성은 임베딩 분포 모사가 아니라 같은 프롬프트가 rollout마다 독립된 섭동을 만들도록 해 주는 성질이며 탐색은 이 독립성을 요구한다. 이론적으로 각 어텐션 레이어에서 RSP의 기여는 무작위 토큰 어텐션 질량이라는 단일 스칼라로 정확히 포착되고, 그 fixed-gap 상한 envelope이 자기회귀 캐시 성장에 따라 좁아진다. 또한 섭동 logits의 국소 affine 분석에서 등방 재추첨은 rank-preserving temperature sampling이 만들 수 없는 top- K 진입 영역에 양의 확률을 부여한다. 실험적으로 RSP는 초반 엔트로피를 높이고 이후 안정화되며, temperature와 결합하면 Pass@ N 이 측정하는 궤적 다양성을 더 크게 확장한다. 마지막으로 이 다양성이 GRPO 학습 신호의 질에 갖는 함의를 논의한다.

1 서론

대형 언어 모델(LLM)이 수십억 파라미터로 커지면서 전체 미세조정 비용은 빠르게 증가했고, 소수의 추가 파라미터만 도입해 적응시키는 parameter-efficient 방법이 주목받고 있다 [Hu et al., 2022, Houlshby et al., 2019]. 그중 *soft prompt*는 학습 가능한 연속 임베딩을 입력에 삽입해 attention을 통해 모델 행동을 조정한다 [Li and Liang, 2021, Lester et al., 2021]. 이 패러다임은 수학 추론 강화에도 활발히 쓰이며 [Kang et al., 2026, Xu et al., 2025, Ye et al., 2026, Hao et al., 2025, Zhang et al., 2026], 세부 설계는 달라도 모두 어휘 바깥 연속 임베딩을 최적화해 downstream 성능을 올린다는 공통 구조를 갖는다.

그러나 이 효과에 최적화가 필수는 아니다. 학습되지 않은 무작위 연속 임베딩을 그대로 주입해도 출력 분포는 바뀐다. 예를 들어 chat 형식으로 학습되지 않은 base model에 chat template을 적용하면 형식 불일치로 추론 성능이 크게 떨어지는데, 여기에 무작위 임베딩을 덧붙이면 그 손실이 도리어 회복된다. 단순 노이즈가 모델을 흔드는 데 그친다면 정확도는 더 나빠져야 한다. 즉 학습된 의미와 무관하게 주입 자체가 모델 행동을 비자명하게 바꾼다. 기존 연구는 최종 정확도에만 집중해 주입과 최적화의 효과를 분리하지 못했고, 임베딩 주입이 출력 분포를 어떻게 바꾸는지는 충분히 탐구되지 않았다.

본 연구는 이 문제를 학습 없이 주입되는 Random Soft Prompt(RSP)로 분석한다. RSP는 사전학습 임베딩의 항별 평균·분산에 맞춘 등방 가우시안에서 추출한 연속 벡터로, rollout마다 독립된 섭동을 공급해 탐색을 가능케 한다. RSP의 기여는 어텐션 레이어마다 단일 스칼라로 포착되고 그 fixed-gap 상한 envelope은 캐시 성장에 따라 좁아지며, 국소 affine 분석에서 등방 재추첨은 temperature가 도달할 수 없는 top- K 진입 영역에 양의 확률을 부여한다. 실증적으로 RSP는 초반 entropy를 높이고 temperature와 결합해 Pass@ N 다양성을 확장하며, 이 다양성은 GRPO [Shao et al., 2024] 학습으로 확장된다.

2 배경

2.1 LLM 추론을 위한 Soft Prompt 기법

*Soft prompt*는 전체 미세조정의 대안이다. Prefix-Tuning [Li and Liang, 2021]이 학습 가능한 연속 벡터를 각 transformer 레이어 앞에 붙이는 패러다임을 제시한 이후, Prompt Tuning [Lester et al., 2021]은 입력 레이어만 사용해도 큰 모델에서 전체 미세조정에 근접한 성능을 보였고, P-tuning [Liu et al., 2024]은 LSTM encoder로 위치 의존성을 더했다. LLM 추론에서도 빠르게 적용되었다. TTSV [Kang et al., 2026]는 테스트 시점에 prefix 임베딩을 엔트로피 최소화하여 최적화하고, SoftCoT [Xu et al., 2025]은 assistant model이 만든 soft token으로 명시적 chain-of-thought를 대체한다. LTPO [Ye et al., 2026]는 confidence 보상으로 latent thought 임베딩을 샘플별로 최적화하며, COCONUT [Hao et al., 2025]은 모델 은닉 상태를 입력으로 되먹여 연속 잠재 공간에서 추론한다. MemGen [Zhang et al., 2026]은 임베딩을 경험 메모리로 활용하고, Pause token [Goyal et al., 2024]은 학습 가능한 토큰을 끼워 추가 계산 단계를 만든다. 이들 모두 어휘 바깥 연속 임베딩을 과제별 목적함수로 최적화한다. 그러나 평가가 최종 정확도에 맞춰져 “주입 자체”와 “최적화”의 효과가 분리되지 않으며, 단순 임베딩 주입이 모델 행동을 어떻게 바꾸는지는 미해결 문제다.

2.2 신경망에서의 노이즈 주입

신경망에는 여러 단계에서 노이즈가 도입된다. 학습 시점에서는 dropout [Srivastava et al., 2014]이 은닉 유닛을 무작위 비활성화하고, NEFTune [Jain et al., 2024]은 instruction fine-tuning 중 임베딩 노이즈로 instruction following을 개선한다. 추론 시점에서는 randomized smoothing [Cohen et al., 2019]이 가우시안 노이즈로 certified robustness를 얻고, SmoothLLM [Robey et al., 2025]은 문자 단위 변형으로 jailbreak를 방어한다. RL에서는 NoisyNet [Fortunato et al., 2018]이 가중치에 학습 가능한 노이즈를 넣어 탐색을 돕는다.

RSP는 세 가지 점에서 구별된다. (1) 학습 없이 추론 시점에만 동작해 모델 파라미터를 건드리지 않는다(dropout/NEFTune/NoisyNet과 다름). (2) 원래 입력을 보존한 채 한 번의 forward pass에 임베딩만 덧붙이며, 강건성 방법의 “여러 noisy pass + 집계”가 필요 없다. (3) 학습된 파라미터 없이 사전학습 임베딩 통계에서 직접 추출한 벡터를 그대로 쓴다(NoisyNet은 노이즈 파라미터를 학습). RSP의 목적은 출력 안정성이 아니라 탐색이며, 본 논문은 이 차이가 어텐션 수준에서 어떻게 작동하는지 분석한다.

3 Random Soft Prompt와 작동 원리

이 절은 논문에서 사용하는 핵심 메커니즘을 정리한다. rollout은 한 번 샘플한 RSP를 고정한 채 끝까지 수행한 자기회귀 디코딩 한 번을 뜻한다. 한 rollout 안에서 RSP는 attention을 통해서만 hidden state에 진입한다. 초반 영향력을 만들 수 있는 같은 어텐션 질량은 실제 토큰이 누적될수록 cache-growth envelope의 제약을 받는다. rollout 사이에서는 독립 재추첨이, 아래에서 명시하는 task 측 가정 아래, 초반 분기 차이를 Pass@N 이득으로 누적할 수 있다. 본문에는 핵심 명제와 직관만 두고, 추가 도출은 Appendix E에 있다.

3.1 Random Soft Prompt

먼저 분석 대상부터 정리한다. 토큰 임베딩 행렬을 $\mathbf{W}_E \in \mathbb{R}^{V \times d}$ 로 두자(V 는 어휘 크기, d 는 은닉 차원). 그 행별 평균과 표준편차를 $\mu_E := \frac{1}{V} \sum_{i,k} [\mathbf{W}_E]_{i,k}$, $\sigma_E := \text{std}(\mathbf{W}_E)$ 라 하자. 길이 L 의 RSP는 다음 분포에서 독립 추출한 연속 벡터 시퀀스 $\mathbf{H} = [h_1, \dots, h_L] \in \mathbb{R}^{L \times d}$ 이다.

$$h_j \sim \mathcal{N}(\mu_E \mathbf{1}_d, \sigma_E^2 \mathbf{I}_d), \quad j = 1, \dots, L. \quad (1)$$

중심화한 $\bar{h}_j := h_j - \mu_E \mathbf{1}_d \sim \mathcal{N}(0, \sigma_E^2 \mathbf{I}_d)$ 은 평균 0의 등방 가우시안이다. 입력 임베딩 시퀀스 $\mathbf{X}$ 에는 prefix $[\mathbf{H}; \mathbf{X}]$, infix, suffix $[\mathbf{X}; \mathbf{H}]$ 세 방식 가운데 하나로 주입한다 [Kang et al., 2026, Xu et al., 2025, Ye et al., 2026, Zhang et al., 2026]. 반복 샘플링 프로토콜에서는 비교하는 rollout들의 prompt 추출과 디코딩 무작위성을 모두 독립으로 둔다.

무작위성의 목적은 임베딩 분포를 흉내 내는 데 있지 않다. 같은 텍스트 prompt를 여러 번 실행할 때 각 rollout이 독립적인 섭동을 받도록 하는 데 있다. 탐색에 필요한 것은 바로 그 독립성이다.

82 3.2 Exploration: RSP가 hidden state에 들어오는 방식

83 먼저 한 번의 RSP 주입이 hidden state를 어떻게 흔드는지부터 묻는다. RSP는 hidden state에
84 직접 더해지지 않고 어텐션 가중치를 통해서만 들어가므로, 한 attention head 안에서의 즉각적
85 영향은 RSP 토큰에 배정된 어텐션 질량이라는 한 가지 양으로 모인다.

86 self-attention 레이어 ℓ 의 한 attention head가 마스크되지 않은 실제 토큰 $n \geq 1$ 개와 RSP 토큰
87 $L \geq 1$ 개를 함께 attend한다고 하자. 모든 attention logit은 유한하다고 두며, 어텐션 가중치를
88 $\alpha_{ij}^{(\ell)}$, value 벡터를 실제 측과 RSP 측에서 각각 $\mathbf{v}_j^{(\ell)}, \mathbf{v}_{r_j}^{(\ell)}$ 로 쓴다. 무작위 토큰에 배정된 총 어텐
89 션 질량을 $w_{r,i}^{(\ell)} := \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)}$ 로 두면 실제 토큰 질량은 양수이고, head output은 다음 형태로
90 정확히 정리된다.

$$\mathbf{o}_i^{(\ell)} = (1 - w_{r,i}^{(\ell)}) \tilde{\mathbf{o}}_i^{(\ell)} + \boldsymbol{\eta}_i^{(\ell)}, \quad \tilde{\mathbf{o}}_i^{(\ell)} := \sum_{j=1}^n \frac{\alpha_{ij}^{(\ell)}}{1 - w_{r,i}^{(\ell)}} \mathbf{v}_j^{(\ell)}, \quad \boldsymbol{\eta}_i^{(\ell)} := \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{r_j}^{(\ell)}. \quad (2)$$

91 Eq. (2)의 도출. head output을 $\sum_{j=1}^n \alpha_{ij}^{(\ell)} \mathbf{v}_j^{(\ell)} + \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{r_j}^{(\ell)}$ 로 나눈 뒤, 실제 토큰 항에서
92 정규화 인자 $1 - w_{r,i}^{(\ell)} = \sum_{j=1}^n \alpha_{ij}^{(\ell)} > 0$ 를 묶어 내면 된다. softmax 정규화 항등식 외에는 어떤
93 근사도 쓰이지 않는다. $\square$

94 이 한 양 $w_{r,i}^{(\ell)}$ 이 두 가지를 동시에 통제한다는 점에 주목하자. 실제 신호의 감쇠 비율 $1 - w_{r,i}^{(\ell)}$ 과
95 무작위 기여 항의 진폭 상계 $\|\boldsymbol{\eta}_i^{(\ell)}\| \leq w_{r,i}^{(\ell)} \max_j \|\mathbf{v}_{r_j}^{(\ell)}\|$ 이 모두 같은 스칼라에 매여 있다. RSP
96 가 만드는 변동은 다차원 섭동이 아니라 0과 1 사이 한 값을 추적하는 문제로 환원된다. 디코딩
97 초반에는 캐시가 짧아 $w_{r,i}^{(\ell)}$ 이 무시할 수 없는 값을 가질 수 있으므로, 무작위 기여를 묶어 두는
98 같은 항등식이 동시에 한 번의 RSP가 초반 next-token 결정을 흔들 수 있는 조건도 마련한다.

99 3.3 Annealing: KV 캐시 성장이 RSP 어텐션을 희석한다

100 다음 자연스러운 질문은 디코딩이 진행되면 이 값이 어떻게 변하는가이다. 자기회귀 생성에서
101 KV 캐시는 매 step 실제 토큰 항을 하나씩 추가하지만 RSP 항의 개수는 고정되어 있다. 실제
102 토큰과 RSP 토큰 사이의 logit gap을 고정해 보면, 이 cache growth는 다음 상계로 나타난다.

103 **정리 1** (캐시 성장에 의한 어텐션 질량 감쇠). Query가 실제 토큰 $n \geq 1$ 개와 RSP 토큰 $L \geq 1$
104 개를 attend하고 모든 logit이 유한하다고 하자. 사전 스케일 logit gap을 $\Delta_i^{(\ell)} := \min_{j \in [n]} \mathbf{q}_i^\top \mathbf{k}_j -$
105 $\max_{j' \in [L]} \mathbf{q}_i^\top \mathbf{k}_{r_{j'}}$ 로 두면 scaled-dot-product 어텐션에서

$$w_{r,i}^{(\ell)} \leq \frac{L}{L + n \exp(\Delta_i^{(\ell)} / \sqrt{d})}$$

106 가 성립하며, 우변은 L 과 $\Delta_i^{(\ell)}$ 를 고정한 채 n 에 대해 엄격히 감소하고 0으로 수렴한다.

107 *Proof.* $s_j := \mathbf{q}_i^\top \mathbf{k}_j / \sqrt{d}$, $s_{r_{j'}} := \mathbf{q}_i^\top \mathbf{k}_{r_{j'}} / \sqrt{d}$, $s_{r,\max} := \max_{j'} s_{r_{j'}}$, $R := \sum_{j'=1}^L \exp(s_{r_{j'}})$ 로 두
108 자. gap 정의에서 모든 실제 토큰 j 에 대해 $s_j \geq \Delta_i^{(\ell)} / \sqrt{d} + s_{r,\max}$ 이고, max는 average보다
109 크므로 $\exp(s_{r,\max}) \geq R/L$ 이다. 두 사실을 결합해 n 개 실제 토큰을 합하면 $\sum_{j=1}^n \exp(s_j) \geq$
110 $(n/L) \exp(\Delta_i^{(\ell)} / \sqrt{d}) R$ 이다. 이를 $w_{r,i}^{(\ell)} = R / (\sum_j \exp(s_j) + R)$ 에 대입하면

$$w_{r,i}^{(\ell)} \leq \frac{R}{(n/L) \exp(\Delta_i^{(\ell)} / \sqrt{d}) R + R} = \frac{L}{L + n \exp(\Delta_i^{(\ell)} / \sqrt{d})}$$

111 가 따른다. 우변의 미분은 $-L \exp(\Delta_i^{(\ell)} / \sqrt{d}) / (L + n \exp(\Delta_i^{(\ell)} / \sqrt{d}))^2 < 0$ 이므로 n 에 대해 엄격
112 히 감소하고, $n \rightarrow \infty$ 일 때 0으로 수렴한다. $\square$

113 이 한 줄에 두 메커니즘이 담겨 있다. RSP 길이 L 은 분자에 들어가 최대 영향력을 결정하고,
114 실제 토큰 수 n 은 매 step 자동으로 늘어 분모를 키우므로 같은 L 아래에서도 영향력의 상계는
115 좁아진다. 정리가 보장하는 것은 같은 layer, 같은 query 위치, 같은 logit gap에서 RSP attention

116 의 상한 *envelope*이 시퀀스 길이 방향으로 좁아진다는 점이며, layer 방향의 단조 감소는 아니다.
 117 $\Delta_i^{(\ell)}$ 도 디코딩 동안 query · key · hidden state와 함께 변하지만, 기존 토큰 사이의 상관관계가 누
 118 적되면서 대체로 증가하는 경향이 있다. 따라서 정확한 진술은 “실현 mass의 step별 단조 감소”
 119 가 아니라 “같은 gap에서 가능한 상계의 단조 감소”다. Eq. (2)이 무작위 기여를 같은 스칼라로
 120 묶으므로 perturbation 크기도 같은 envelope을 따르며, RSP는 생성 초반에 크게 열리고 캐시
 121 누적과 함께 좁아지는 암묵적 explore-then-exploit 해석을 갖는다. Figure 1는 sequence와 layer
 122 두 축의 경험적 dual decay를 함께 보여 준다.




Figure 1: Qwen2.5-Math-7B에서 측정한 토큰별 어텐션 질량(suffix, MATH-500 500문제, 문제마다 독립 RSP). (a) RSP 토큰 어텐션은 추론 위치 축(가로)에서 감소하며, 이는 Theorem 1의 cache-growth 상계와 일치한다. 레이어 축(세로)의 추가 감소는 별도의 경험적 현상으로, 깊은 레이어에서 실제 토큰과 RSP 토큰 사이의 logit gap이 더 날카로워지는 경향을 시사하지만 Theorem 1만으로 직접 따라오지는 않는다. (b) 질문 토큰 어텐션은 비교적 균일하게 유지된다. 그림에 보고한 양은 Appendix F의 per-token mass로, RSP 길이 L 로 나눈 평균 값이며 본문 $w_{r,i}^{(\ell)}$ 와는 상수배 관계다.

123 3.4 Performance gain: 왜 독립 재실행이 도움이 되는가

124 Theorem 1는 한 rollout 안에서 RSP가 얼마나 움직일 수 있는지를 설명한다. 남은 질문은 성능
 125 이다. 왜 새로운 RSP로 다시 실행할 때 하나의 고정된 prompt를 반복하는 것보다 이득이 커질
 126 수 있는가? 여기에는 prompt 분포에 대한 사실 하나와, 열린 branch가 정답에 도움이 되는지에
 127 대한 별도의 task-side 사실 하나가 필요하다.

128 먼저 분포 쪽 사실. 어텐션 항등식은 등방성을 요구하지 않지만, branch opening은 현재 prompt
 129 에 중요한 방향을 미리 편들지 않는 분포를 선호한다. 길이 L prompt 안의 centered RSP 벡터
 130 하나를 분리한 국소 surrogate에 대해 미니맥스로 형식화하면 다음 명제를 얻는다.

131 **명제 1** (방향 무관 미니맥스 커버리지). $\mathbb{R}^d$ 위 평균 0 분포 D 가 분산 예산 $\text{tr}(\Sigma_D) \leq \rho^2$ 를
 132 만족하면 $\min_{\|b\|=1} \text{Var}_{h \sim D}(b^\top h) = \lambda_{\min}(\Sigma_D) \leq \rho^2/d$ 이고, 등호는 $\Sigma_D = (\rho^2/d)\mathbf{I}_d$ 일 때에만
 133 성립한다.

134 가우시안 RSP는 임베딩에서 스케일만 빌리고 방향 기하는 버리는 설계로, 어떤 방향이 의미
 135 있는지 사전에 모를 때 worst-case 방향 분산을 최소화하는 안전한 선택이다. 가우시안은 추
 136 가로 $\mathbb{R}^d$ 전역에서 양의 밀도(full support)를 가져 어떤 방향에도 사전 가중치를 두지 않는다
 137 (Appendix D). 사전학습 임베딩의 anisotropic 구조 활용이 더 유리한 task가 있을 수 있으나,
 138 이는 task-specific 정보가 필요한 별도 문제다.

139 이제 surrogate 위에서 branch opening을 형식화한다. centered prompt $\bar{h}$ 근방의 1차 surrogate
 140 $z_i^{\text{lin}}(\bar{h}) := z_i + a_i^\top \bar{h}$ ($a_i := \nabla_{\bar{h}} z_i(0)$)와 baseline 외 토큰 i 의 top- K 진입 영역 $\mathcal{G}_{i,K} := \{\bar{h} \in \mathbb{R}^d : \#\{j \neq i : z_j^{\text{lin}}(\bar{h}) > z_i^{\text{lin}}(\bar{h})\} \leq K-1\}$ 을 둔다.

142 **정리 2** (조건부 top- K 진입). $\mathcal{G}_{i,K}$ 가 비공집합 열린집합을 포함하면 등방 가우시안의 full support
 143 가 그 영역에 양의 확률을 부여하므로 $\mu_i := \Pr_{\bar{h}}(\bar{h} \in \mathcal{G}_{i,K}) > 0$ 이다. 이 결과는 단조 변환인
 144 temperature sampling으로는 도달할 수 없는 rank-changing 사건에 대한 양의 확률 보장을 준다.

145 영역 자체의 존재는 task 측 조건이지 메커니즘만으로 자동 보장되지 않는다. 단발 진입 확
 146 률을 task accuracy로 끌어올리려면 (M1) 단발 RSP 실행이 정답 trajectory를 만들 주변 확률
 147 $p_{\min}(x) > 0$ 이고 (M2) N 번의 실행이 상호 독립이라는 두 가정이 필요하다.

148 **명제 2** (다중 경로 Pass@ N). (M1)–(M2) 아래에서, N 개의 독립 RSP 실행은
 149 $\Pr(\text{Pass}@N \text{ on } x) \geq 1 - (1 - p_{\min}(x))^N \geq 1 - \exp(-N p_{\min}(x))$ 를 만족한다.

150 이 역할 분담이 이 절의 핵심 해석이다. 해당 진입 영역이 존재할 때 메커니즘은 baseline 외
 151 토큰을 후보권 안으로 들일 수 있지만, 들인 branch가 생산적이라는 점은 task의 성질이다. 같은

Table 1: 모델 설정과 벤치마크별 정확도(%). RSP는 주입 위치(Prefix, Infix, Suffix) 중 최고 성능만 보고한다. 위치별 전체 결과는 Appendix A에 있다. 괄호 안 값은 baseline 대비 변화량이다.

Model	MATH-500		GSM8K		AIME24	
	Baseline	RSP	Baseline	RSP	Baseline	RSP
<i>Instruct Models</i>						
LLaMA-3.1-8B-Inst	52.20	49.40 (−2.8)	85.75	86.73 (+1.0)	6.67	10.00 (+3.3)
Qwen2.5-Math-7B-Inst	83.20	84.20 (+1.0)	95.45	95.68 (+0.2)	13.33	16.67 (+3.3)
Qwen2.5-Math-1.5B-Inst	73.00	75.20 (+2.2)	85.29	85.75 (+0.5)	10.00	20.00 (+10.0)
<i>Base Models (Raw Text)</i>						
Qwen2.5-Math-7B	72.20	71.60 (−0.6)	84.15	84.31 (+0.2)	6.67	16.67 (+10.0)
Qwen2.5-Math-1.5B	61.40	64.40 (+3.0)	77.86	74.30 (−3.6)	16.67	10.00 (−6.7)
<i>Base Models + ChatML (Format Mismatch)</i>						
Qwen2.5-Math-7B	52.20	70.40 (+18.2)	58.30	75.97 (+17.7)	23.33	23.33 (+0.0)
Qwen2.5-Math-1.5B	34.40	63.40 (+29.0)	37.45	67.02 (+29.6)	13.33	20.00 (+6.7)

RSP를 모든 sample이 공유하면 이 누적이 사라지므로 독립이 핵심이다. §4는 바로 이 서명을 실험적으로 확인한다.

4 실험적 확인

앞 절의 설명이 실제 LLM 생성에서 어떻게 드러나는지를 세 장면으로 살펴본다. 먼저 RSP가 baseline 정확도를 크게 깎지 않으면서 일부 설정에서는 오히려 회복시키는지를 확인하고 (§4.2), 다음으로 attention decomposition과 cache-growth envelope가 시사하는 초반 다양화와 후반 안정화가 실제로 관찰되는지를 살펴 (§4.3), 끝으로 같은 RSP를 재사용할 때와 매 시도마다 새로 뽑을 때의 Pass@N 차이가 독립성이 핵심이라는 점을 직접 보여 주는지를 본다 (§4.4).

4.1 실험 설정

평가는 세 가지 수학 추론 벤치마크 MATH-500 [Lightman et al., 2024], GSM8K [Cobbe et al., 2021], AIME24에서 수행한다. 모델은 LLaMA-3.1-8B-Instruct [Grattafiori et al., 2024]와 Qwen2.5-Math 계열 [Yang et al., 2024]을 쓰며, instruct, base, 그리고 chat template이 맞지 않는 base 설정까지 합쳐 총 일곱 가지를 비교한다. 모든 실험은 sampling 자체의 무작위성과 RSP 효과를 분리하기 위해 greedy decoding을 사용하고, fallback 기반 answer extraction pipeline으로 최종 답만 채점한다. RSP는 §3.1의 정의를 따르며 prefix/infix/suffix 세 주입 위치 중 하나에 매 배치마다 새로 주입된 H를 결합한다. 전체 실험 설정과 위치별 결과는 Appendix A에 있다.

4.2 RSP는 추론 성능을 개선할까?

먼저 무작위 임베딩 주입이 모델의 추론 성능에 어떤 영향을 주는지 본다. Table 1는 각 벤치마크에서 주입 위치(Prefix, Infix, Suffix)와 $L \in \{10, 15, 20\}$ 가운데 가장 좋은 RSP 결과를 보고한다.

instruct model과 원래 형식을 쓰는 base model에서 RSP는 baseline 성능을 대체로 몇 퍼센트포인트 이내에서 유지하거나 소폭만 이동시킨다. 가장 두드러지는 것은 형식 불일치다. chat 형식으로 학습되지 않은 base model에 ChatML template을 주입했을 때 RSP는 최대 +29%p의 큰 향상을 보인다. 단순 노이즈였다면 성능 저하가 더 커졌어야 하므로 이 효과는 단순한 교란을 넘는다. 가설은 다음과 같다 — base model이 익숙하지 않은 chat token 위에서 비정상적으로 confident한 wrong attractor에 갇히는데, RSP가 초반 분포를 평탄화해 그 attractor에서 빠져나오게 한다. §4.3의 entropy 상승 신호와 정합하며, 정량 분석은 향후 과제다.

또한 RSP를 TTSV, SoftCoT, LTPO처럼 서로 다른 목적 함수로 임베딩을 최적화하는 기존 soft prompt 방법과 비교했다. Table 2는 공통 answer extraction pipeline 아래에서 다시 평가한 결과를 보여준다. 각 방법은 프롬프트 형식과 채점 규칙이 다르지만, fallback 기반 추출을 사용해 형식에 덜 민감한 비교를 수행했다. 결과적으로 RSP는 추가 학습 없이도 최적화 기반 방법과 맞먹는 수준의 성능을 보인다.

Table 2: 기존 soft prompt 방법(TTSV, SoftCoT, LTPO)과의 통합 평가 비교. Baseline과 RSP 값은 Table 1에서 가져왔다. **Bold**는 최고 성능, underline은 두 번째 성능이다.

Model	Benchmark	Baseline	RSP	TTSV	SoftCoT	LTPO
Qwen2.5-Math-7B-Instruct	MATH-500	83.20	84.20	83.80	82.80	83.00
	GSM8K	<u>95.45</u>	95.68	95.30	95.00	94.84
	AIME24	13.33	<u>16.67</u>	23.30	<u>16.67</u>	13.33
Qwen2.5-Math-1.5B-Instruct	MATH-500	73.00	<u>75.20</u>	75.20	76.00	72.40
	GSM8K	85.29	85.75	<u>85.70</u>	84.46	84.53
	AIME24	<u>10.00</u>	20.00	6.70	6.67	<u>10.00</u>

4.3 RSP는 출력 분포를 어떻게 바꾸는가?

다음으로 RSP 주입이 생성 과정의 출력 분포를 어떻게 바꾸는지 살펴본다. 설정은 Qwen2.5-Math-1.5B-Instruct와 MATH-500이며, 토큰별 entropy, top-1 probability, varentropy를 생성 단계에 따라 측정한다. Figure 2와 Table 3는 생성 초반 5% 구간에서 RSP 변형과 기존 soft prompt 방법을 비교한 결과다.




Figure 2: 생성 초반 5% 구간의 평균 entropy, top-1 probability, varentropy (Qwen2.5-Math-1.5B-Instruct, MATH-500). 음영은 ± 1 SEM이다. 실선은 RSP 변형과 baseline, 점선은 기존 soft prompt 방법(LTPO, SoftCoT, TTSV)이다.

Table 3: 생성 초반 5% 구간의 평균 entropy, top-1 probability, varentropy (Qwen2.5-Math-1.5B-Instruct, MATH-500).

Metric	Baseline	Prefix	Infix	Suffix	LTPO	SoftCoT	TTSV
Entropy	0.1332	0.1366	0.1402	0.1941	0.1662	0.4218	0.1359
Top-1 Prob	0.9535	0.9523	0.9525	0.9373	0.9437	0.9156	0.9534
Varentropy	0.2181	0.2207	0.2463	0.4010	0.2953	2.2234	0.2174

결과는 RSP가 생성 초반 출력 분포를 분명히 바꾼다는 점을 보여준다. 세 주입 위치 모두에서 entropy는 증가하고, top-1 probability는 감소하며, varentropy는 증가한다. 이는 분포가 평평해지고, 단일 우세 토큰에 대한 확신은 약해지며, 다분형 분포가 더 자주 나타남을 뜻한다 [Ahmed et al., 2026]. 높은 entropy 구간은 추론 궤적이 갈라지는 핵심 분기점으로 알려져 있으므로 [Wang et al., 2025], 이 변화는 여러 추론 경로가 공존할 수 있는 상태로 모델을 밀어 넣는다. 중요한 점은 변화가 생성 초반에 국한된다는 것이다. 생성 중반과 후반에서는 세 지표 모두 baseline 수준으로 다시 수렴한다.

서로 다른 목적 함수로 학습된 기존 방법들도 같은 패턴을 공유한다. 평균 entropy를 줄이는 보상을 쓰는 TTSV조차 초반 구간만큼은 baseline과 비슷하거나 더 높아, 이 entropy 상승은 특정 최적화 목적이 아니라 사전학습되지 않은 연속 임베딩 주입 자체에 가까운 효과로 보인다.

4.4 RSP는 실제로 추론 궤적의 다양성을 만드는가?

Section 4.3는 RSP가 생성 초반 출력 분포를 바꾼다는 사실을 보였다. 이제 이 변화가 실제 추론 다양성으로 이어지는지를 세 수준에서 살펴본다. 분석 수준은 토큰 순위, 궤적의 의미적 내용, 과제 수준 결과다. 세 분석 모두 Qwen2.5-Math-1.5B-Instruct, MATH-500, suffix 주입, $L = 10$ 설정을 공유한다.

203 **토큰 수준: temperature를 넘어서는 분**
 204 **포 변화.** 토큰 수준에서 baseline과 RSP
 205 의 궤적 차이는 첫 생성 step에서 시작
 206 되어야 한다 [Wang et al., 2025]. Base-
 207 line $\tau=1.0$ 을 기준으로 더 높은 tempera-
 208 ture($\tau=2.0, 3.0$)와 RSP $\tau=1.0$ 을 네 지표
 209 로 비교한다: Spearman rank correlation
 210 ρ (순위 보존), baseline top-10 밖 확률 질
 211 량 (저확률 토큰 확장), JS divergence (전
 212 체 분포 거리), Acc (Pass@1, 정의는 Ap-
 213 pendix C).

Table 4: Baseline $\tau=1.0$ 을 기준으로 본 첫 토큰 분포 지표. 더 높은 temperature의 baseline($\tau=2.0, 3.0$)과 RSP $\tau=1.0$ 을 비교한다. RSP 지표는 16개 random seed 평균이며, Acc는 문제당 16개 샘플의 평균 $\pm$ 표준편차다.

Metric	$\tau=2.0$	$\tau=3.0$	RSP
Spearman ρ	1.000	1.000	0.709
Mass outside top-10	5.18%	29.11%	21.86%
JS divergence	0.060	0.218	0.131
Acc (%)	20.77 ± 1.47	1.42 ± 0.35	73.30 ± 1.07

214 Table 4의 대비는 명확하다. RSP의 분포
 215 변화 크기는 top-10 밖 질량과 JS divergence 기준으로 $\tau=2.0$ 과 $\tau=3.0$ 사이지만, temperature는
 216 단조 변환이라 $\rho = 1$ 이 강제되는 반면 RSP는 $\rho = 0.709$ 로 순위를 재배치한다. RSP와 비슷한
 217 크기의 분포 변화를 temperature로 만들려면 $\tau=3.0$ 쪽이 필요한데 이때 정확도는 1.42%까지
 218 무너지고, RSP는 같은 설정에서 73.30%를 유지한다. 즉 RSP는 분포를 균일하게 평탄화하는
 219 게 아니라 순위를 바꾸는 다른 종류의 섭동을 만든다.

220 **궤적 수준: 의미적 다양성.** 한 단계 위인 궤적 수준에서는,
 221 첫 토큰의 재배치가 실제로 의미적으로 다른 추론 경로를
 222 여는지가 관건이다. 이를 위해 MATH-500에서 무작위로 64
 223 개 문제를 뽑고, Baseline과 RSP 두 조건에서 각 문제마다
 224 temperature $\tau = 1.0$ 으로 300개의 독립 궤적을 생성했다. 각
 225 궤적은 BGE-M3 [Chen et al., 2024]로 임베딩한 뒤, 문제 내
 226 평균 pairwise cosine distance, DBSCAN [Ester et al., 1996] 클
 227 러스터 중심 사이의 inter-cluster distance, 그리고 intra-cluster
 228 distance를 계산했다. Table 5는 RSP가 intra-cluster distance는 거의 바꾸지 않으면서 inter-cluster
 229 distance를 크게 키운다는 점을 보여준다. 즉, 각 전략 내부의 일관성은 유지하면서 전략 간
 230 거리를 벌린다. Pairwise distance 기준으로 RSP는 64개 중 56개 문제(87.5%)에서 baseline
 231 보다 컸다.

Table 5: 64개 문제에 대해 평균
한 의미적 다양성 지표.

Metric	Baseline	RSP
Pairwise cos. dist.	0.0612	0.0879
Inter-cluster dist.	0.0183	0.0982
Intra-cluster dist.	0.0526	0.0528




Figure 3: 64개 MATH-500 문제에서의 의미적 다양성 분석(문제당 300개 궤적, Qwen2.5-Math-1.5B-Instruct, $\tau = 1.0$, BGE-M3 임베딩). (a) 대표 문제 test/prealgebra/951의 t-SNE 투영: baseline(빨강)은 한 영역에 비교적 집중되지만, RSP suffix(파랑)는 더 넓고 분리된 군집까지 확장된다. 채워진 표식은 정답, 빈 표식은 오답이다. (b) 문제별 평균 pairwise cosine distance. 대각선 위 점은 RSP가 baseline보다 더 다양한 궤적을 만든다는 뜻이다. (c) 문제별 DBSCAN 클러스터 수. 대부분의 문제에서 RSP가 더 많은 클러스터를 만든다.

232 Figure 3(a)에서 RSP 샘플(파랑)은 baseline 영역을 포함하면서 baseline이 도달하지 못한 별도
 233 클러스터까지 확장되고, 그 영역에도 정답 궤적이 포함된다. (b), (c)는 64개 문제 전반에 걸쳐
 234 RSP가 더 많은 클러스터와 더 큰 pairwise cosine distance를 만든다는 패턴이 반복됨을 보여준다.
 235 즉 RSP는 클러스터 내부 진행은 호트르프리지 않으면서 궤적이 진입하는 전략 클러스터 자체를
 236 바꾼다. 문제별 추가 t-SNE는 Appendix B에 있다.

237 **결과 수준: Pass@N 스케일링.** 마지막 결과 수준에서는, 이러한 다양성이 실제 과제 성과로
 238 이어지는지를 Pass@N로 본다(N 개의 샘플 중 적어도 하나가 정답일 확률). MATH-500과
 239 AIME24에서 문제당 $N = 16$, 네 조건을 비교한다. (i) baseline + $\tau=1.0$, (ii) RSP를 모든 샘플이
 240 공유 + $\tau=1.0$, (iii) 샘플마다 독립 RSP + greedy, (iv) 샘플마다 독립 RSP + $\tau=1.0$.




Figure 4: Qwen2.5-Math-1.5B-Instruct에서의 Pass@N 스케일링. 좌측은 MATH-500, 우측은 AIME24이며, 문제당 $N = 16$ 개의 샘플을 사용했다. Baseline은 temperature sampling만, fixed seed는 고정된 하나의 RSP와 temperature를 함께 쓴 경우, indep. seed는 샘플마다 다른 RSP를 쓰는 경우다.

241 조건 (iv)가 두 벤치마크 모두에서 가장 높은 Pass@N을 달성하며 $N = 16$ 에서 MATH-500
 242 92.80%, AIME24 36.67%에 이른다. (ii)는 baseline 대비 거의 개선이 없어, 다양성 이득의 핵심
 243 이 고정 섭동이 아니라 샘플마다 독립된 무작위 임베딩임을 드러낸다. Pass@1은 MATH-500
 244 에서 baseline 수준을 유지하고 더 어려운 AIME24에서는 (iv)가 더 높아, 독립 RSP + temperature
 245 결합이 단일 샘플 정확도를 해치지 않으면서 추론 궤적을 다양화한다.

246 5 Application: RSP를 이용한 DAPO 학습

247 §3-4는 RSP가 무엇을 하는지(어텐션 매개의 분기 개방)와 추론 시점에서 어떻게 동작하는지
 248 (Pass@N 향상, temperature로는 도달할 수 없는 rank-changing 다양성)를 정립했다. 남은 질문은
 249 이 효과가 학습 시점 성능 향상으로 이어지는가다. sampling 기반 RL의 학습 결과를 좌우하는
 250 핵심 요소는 rollout 다양성이며, DAPO [Yu et al., 2025]는 이를 손실 단에서 보존하도록 설계된
 251 최근의 GRPO [Shao et al., 2024] 변형이다. 우리는 이를 까다로운 testbed로 사용한다 — 입력 단
 252 분기 개방이 손실 단 다양성 보존과 결합해 추가 이득을 만드는가? 구현 세부와 step 별 결과는
 253 Appendix G에 있다.

254 DAPO는 GRPO의 손실 항을 수정해 긴 chain-of-thought RL 학습 동안 rollout 다양성을 손실
 255 단에서 유지하며, rollout의 가중과 clip 방식을 다듬어 다양성을 형성한다. 반면 RSP는 손실
 256 계산 이전 단계에서 rollout 분포 자체에 섭동을 주어 입력 단에서 다양성을 유발한다(§4.4). i
 257 번째 rollout 응답을 o_i , 중요도 비를 $r_{i,t}(\theta) = \pi_\theta(o_{i,t} | q, [\mathbf{H}_g,]o_{i,<t}) / \pi_{\theta_{\text{old}}}(o_{i,t} | q, [\mathbf{H}_g,]o_{i,<t})$,
 258 그룹 상대 advantage를 $\hat{A}_{i,t}$, 비대칭 clip 범위를 $(\epsilon_{\text{low}}, \epsilon_{\text{high}})$, prompt에 결합한 RSP를 $\mathbf{H}_g$ 라 하면
 259 DAPO + RSP의 목적함수는

$$\mathcal{J}_{\text{DAPO+RSP}}(\theta) = \mathbb{E} \left[\frac{1}{\sum_i |o_i|} \sum_{i,t} \min \left(r_{i,t} \hat{A}_{i,t}, \text{clip}(r_{i,t}, 1 - \epsilon_{\text{low}}, 1 + \epsilon_{\text{high}}) \hat{A}_{i,t} \right) \right]. \quad (3)$$

Table 6: Qwen2.5-Math-7B에서 각 방법의 peak step 벤치마크별 정확도(%). 굵게는 두 RL 방법 중 더 높은 쪽이고, Avg는 가중치 없는 5-벤치마크 평균이다.

Method	GSM8K	MATH-500	College	Minerva	AIME 24	Avg
Base	57.2	52.6	18.3	13.6	8.6	30.06
DAPO	86.3	78.2	41.4	37.5	22.6	53.20
DAPO + RSP	87.7	78.6	42.2	39.7	23.6	54.36

260 Qwen2.5-Math-7B를 MATH Level-3-5 subset(약 8,500 prompt)에서 SimpleRL-Zoo [Zeng et al.,
 261 2025] 파이프라인과 Eq. (3)로 학습한다. 매 step은 prompt 1,024개 배치 위에서 $\tau=1.0$, $G = 8$
 262 rollout으로 추첨한 뒤 prompt 256개씩 4번의 PPO mini-batch 업데이트를 진행하며, 총 100

step(약 12 epoch). *DAPO*와 *DAPO + RSP*를 비교하며, 후자는 rollout에만 *suffix RSP*($L = 20$)를 적용하고 평가는 *RSP* 없이 수행한다. 평가는 5개 수학 추론 벤치마크(GSM8K [Cobbe et al., 2021], MATH-500 [Lightman et al., 2024], College Math, Minerva Math [Lewkowycz et al., 2022], AIME 2024)에서 진행한다. AIME 2024는 분산 축소를 위해 $\tau=1.0$ 에서 Avg@32, 큰 셋은 greedy로 채점한다. 보고는 5-벤치마크의 가중치 없는 평균이다.

첫 번째 관찰. Figure 5와 Table 6에서 학습 후반의 일관된 우위가 드러난다. *DAPO + RSP*의 5-벤치마크 평균은 step 90에서 54.36%로, *DAPO* 자체 peak인 step 80의 53.20%를 +1.16 pp 증가한다. step 100에서는 차이가 53.64% vs 50.54%(+3.10 pp)로 더 벌어지며, *DAPO* 단독에서 관찰되는 step 80 이후 감소가 *RSP* 결합 시 지연된다. 이 패턴은 *RSP*와 *DAPO*의 손실 함수 차이가 최적화의 분리된 단계에 작용한다는 점에서 자연스럽다 — *DAPO* 수정은 이미 생성된 rollout과 logit을 입력으로 받아 손실 단에서 다양성을 보존하지만, *RSP*는 그 rollout을 만들어 내는 은닉 상태 자체를 섭동한다 (§3.2). *DAPO*의 적극적인 손실 단 다양성 보존 위에 추가 이득이 관찰된다는 사실은, 은닉 상태 단의 섭동이 손실 단 보존이 닿지 못하는 표면에서 작동함을 시사한다.




Figure 5: Qwen2.5-Math-7B의 5-벤치마크 평균 정확도. *DAPO + RSP*는 step 90에서 더 높은 peak에 도달해 step 100까지 안정 유지된다.

두 번째 관찰. 두 곡선은 step 20 부근에서 교차하고, 초반엔 *DAPO + RSP*의 reward 성장이 느리다. 이 교차는 §3.4의 다중 경로 논변이 학습 동역학에서 재현되는 것과 정합한다 — policy가 평소라면 선택했을 궤적에서 벗어남으로써 더 넓은 궤적 분포가 학습 신호에 노출되는 것이다. 그 노출 누적이 후반의 천장 상승과 붕괴 지연으로 나타난다. 같은 패턴은 RL의 exploration-exploitation 동역학으로 오랫동안 기록되어 왔으며 [Sutton and Barto, 2018], 본 결과는 그 동역학이 은닉 상태 단의 섭동을 통해 입력 측에서도 유도될 수 있음을 보여 준다.

6 결론

본 연구는 사전학습 임베딩의 항별 평균과 분산에 맞춘 등방 가우시안 벡터를 학습 없이 주입하는 *RSP*를 분석했다. 무작위성은 임베딩 모사가 아니라 rollout 사이 독립 섭동을 공급해 탐색을 가능케 하는 성질이다. 이론적으로 *RSP*의 기여는 어텐션 레이어마다 단일 스칼라로 포착되고 fixed-gap 상한 envelope은 캐시 성장에 따라 줄아지며, 국소 affine 분석에서 등방 재추침은 temperature 스케일링이 만들 수 없는 top- K 진입 영역에 양의 확률을 부여한다 (§3). 실험적으로 *RSP*는 초반 엔트로피를 높이고 후반에 안정화하며, 같은 *RSP*를 sample 간 공유하면 누적 이득이 사라진다 (§4). *RSP*는 순위를 바꾸는 섭동, temperature는 보존하는 섭동이므로 두 방법은 상보적이며, GRPO [Shao et al., 2024]의 entropy collapse를 *DAPO* [Yu et al., 2025], CE-GPPO [Su et al., 2026] 너머에서 샘플링 단계로 보완할 가능성을 시사한다. 학습 시점 비교, 도메인 확장, *RSP* 길이·주입 위치 원리적 결정은 Proposition 2의 $p_{\min}(x) > 0$ 가정과 함께 향후 과제다.

References

- Farhan Ahmed, Yuya Jeremy Ong, and Chad DeLuca. LogitScope: A Framework for Analyzing LLM Uncertainty through Information Metrics. In *ICLR Workshop*, 2026.
- Nora Belrose, Igor Ostrovsky, Lev McKinney, Zach Furman, Logan Smith, Danny Halawi, Stella Biderman, and Jacob Steinhardt. Eliciting Latent Predictions from Transformers with the Tuned Lens. *arXiv:2303.08112*, 2023.
- Jianlyu Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, and Zheng Liu. M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation. In *Findings of ACL*, 2024.
- Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, Christopher Hesse, and John Schulman. Training Verifiers to Solve Math Word Problems. *arXiv:2110.14168*, 2021.
- Jeremy M. Cohen, Elan Rosenfeld, and J. Zico Kolter. Certified Adversarial Robustness via Randomized Smoothing. In *ICML*, 2019.

314 Martin Ester, Hans-Peter Kriegel, Jörg Sander, and Xiaowei Xu. A Density-Based Algorithm for
315 Discovering Clusters in Large Spatial Databases with Noise. In *KDD*, 1996.

316 Meire Fortunato, Mohammad Gheshlaghi Azar, Bilal Piot, Jacob Menick, Ian Osband, Alex Graves,
317 Vlad Mnih, Remi Munos, Demis Hassabis, Olivier Pietquin, Charles Blundell, and Shane Legg.
318 Noisy Networks for Exploration. In *ICLR*, 2018.

319 Mor Geva, Roei Schuster, Jonathan Berant, and Omer Levy. Transformer Feed-Forward Layers Are
320 Key-Value Memories. In *EMNLP*, 2021.

321 Sachin Goyal, Ziwei Ji, Ankit Singh Rawat, Aditya Krishna Menon, Sanjiv Kumar, and Vaishnavh
322 Nagarajan. Think before You Speak: Training Language Models with Pause Tokens. In *ICLR*,
323 2024.

324 Aaron Grattafiori, Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad
325 Al-Dahle, Aiesha Letman, Akhil Mathur, Alan Schelten, Alex Vaughan, Amy Yang, Angela Fan,
326 Anirudh Goyal, Anthony Hartshorn, Aobo Yang, Archi Mitra, Archie Sravankumar, Artem Ko-
327 renev, Arthur Hinsvark, Arun Rao, Aston Zhang, Aurelien Rodriguez, Austen Gregerson, Ava
328 Spataru, Baptiste Roziere, Bethany Biron, Binh Tang, Bobbie Chern, Charlotte Caucheteux, Chaya
329 Nayak, Chloe Bi, Chris Marra, Chris McConnell, Christian Keller, Christophe Touret, Chunyang
330 Wu, Corinne Wong, Cristian Canton Ferrer, Cyrus Nikolaidis, Damien Allonsius, Daniel Song,
331 Danielle Pintz, Danny Livshits, Danny Wyatt, David Esiobu, Dhruv Choudhary, Dhruv Mahajan,
332 Diego Garcia-Olano, Diego Perino, Dieuwke Hupkes, Egor Lakomkin, Ehab AlBadawy, Elina
333 Lobanova, Emily Dinan, Eric Michael Smith, Filip Radenovic, Francisco Guzmán, Frank Zhang,
334 Gabriel Synnaeve, Gabrielle Lee, Georgia Lewis Anderson, Govind Thattai, Graeme Nail, Gre-
335 goire Mialon, Guan Pang, Guillem Cucurell, Hailey Nguyen, Hannah Korevaar, Hu Xu, Hugo
336 Touvron, Iliyan Zarov, Imanol Arrieta Ibarra, Isabel Kloumann, Ishan Misra, Ivan Evtimov, Jack
337 Zhang, Jade Copet, Jaewon Lee, Jan Geffert, Jana Vranes, Jason Park, Jay Mahadeokar, Jeet Shah,
338 Jelmer van der Linde, Jennifer Billock, Jenny Hong, Jenya Lee, Jeremy Fu, Jianfeng Chi, Jianyu
339 Huang, Jiawen Liu, Jie Wang, Jiecao Yu, Joanna Bitton, Joe Spisak, Jongsoo Park, Joseph Rocca,
340 Joshua Johnstun, Joshua Saxe, Junteng Jia, Kalyan Vasuden Alwala, Karthik Prasad, Kartikeya
341 Upasani, Kate Plawiak, Ke Li, Kenneth Heafield, Kevin Stone, Khalid El-Arini, Krithika Iyer,
342 Kshitiz Malik, Kuenley Chiu, Kunal Bhalla, Kushal Lakhotia, Lauren Rantala-Yearly, Laurens
343 van der Maaten, Lawrence Chen, Liang Tan, Liz Jenkins, Louis Martin, Lovish Madaan, Lubo
344 Malo, Lukas Blecher, Lukas Landzaat, Luke de Oliveira, Madeline Muzzi, Mahesh Pasupuleti,
345 Mannat Singh, Manohar Paluri, Marcin Kardas, Maria Tsimpoukelli, Mathew Oldham, Mathieu
346 Rita, Maya Pavlova, Melanie Kambadur, Mike Lewis, Min Si, Mitesh Kumar Singh, Mona Has-
347 san, Naman Goyal, Narjes Torabi, Nikolay Bashlykov, Nikolay Bogoychev, Niladri Chatterji, Ning
348 Zhang, Olivier Duchenne, Onur Çelebi, Patrick Alrassy, Pengchuan Zhang, Pengwei Li, Petar Va-
349 sic, Peter Weng, Prajjwal Bhargava, Pratik Dubal, Praveen Krishnan, Punit Singh Koura, Puxin
350 Xu, Qing He, Qingxiao Dong, Ragavan Srinivasan, Raj Ganapathy, Ramon Calderer, Ricardo Sil-
351 veira Cabral, Robert Stojnic, Roberta Raileanu, Rohan Maheswari, Rohit Girdhar, Rohit Patel,
352 Romain Sauvestre, Ronnie Polidoro, Roshan Sumbaly, Ross Taylor, Ruan Silva, Rui Hou, Rui
353 Wang, Saghar Hosseini, Sahana Chennabasappa, Sanjay Singh, Sean Bell, Seohyun Sonia Kim,
354 Sergey Edunov, Shaoliang Nie, Sharan Narang, Sharath Rapparthi, Sheng Shen, Shengye Wan,
355 Shruti Bhosale, Shun Zhang, Simon Vandenhende, Soumya Batra, Spencer Whitman, Sten Sootla,
356 Stephane Collot, Suchin Gururangan, Sydney Borodinsky, Tamar Herman, Tara Fowler, Tarek
357 Sheasha, Thomas Georgiou, Thomas Scialom, Tobias Speckbacher, Todor Mihaylov, Tong Xiao,
358 Ujjwal Karn, Vedanuj Goswami, Vibhor Gupta, Vignesh Ramanathan, Viktor Kerkez, Vincent
359 Gonguet, Virginie Do, Vish Vogeti, Vítor Albiero, Vladan Petrovic, Weiwei Chu, Wenhan Xiong,
360 Wenyin Fu, Whitney Meers, Xavier Martinet, Xiaodong Wang, Xiaofang Wang, Xiaoqing Ellen
361 Tan, Xide Xia, Xinfeng Xie, Xuchao Jia, Xuwei Wang, Yaelle Goldschlag, Yashesh Gaur, Yas-
362 mine Babaei, Yi Wen, Yiwen Song, Yuchen Zhang, Yue Li, Yuning Mao, Zacharie Delpierre
363 Coudert, Zheng Yan, Zhengxing Chen, Zoe Papakipos, Aaditya Singh, Aayushi Srivastava, Abha
364 Jain, Adam Kelsey, Adam Shajnfeld, Adithya Gangidi, Adolfo Victoria, Ahuva Goldstand, Ajay
365 Menon, Ajay Sharma, Alex Boesenberg, Alexei Baevski, Allie Feinstein, Amanda Kallet, Amit
366 Sangani, Amos Teo, Anam Yunus, Andrei Lupu, Andres Alvarado, Andrew Caples, Andrew Gu,
367 Andrew Ho, Andrew Poulton, Andrew Ryan, Ankit Ramchandani, Annie Dong, Annie Franco,
368 Anuj Goyal, Aparajita Saraf, Arkabandhu Chowdhury, Ashley Gabriel, Ashwin Bharambe, As-
369 saf Eisenman, Azadeh Yazdan, Beau James, Ben Maurer, Benjamin Leonhardi, Bernie Huang,

370 Beth Loyd, Beto De Paola, Bhargavi Paranjape, Bing Liu, Bo Wu, Boyu Ni, Braden Hancock,
 371 Bram Wasti, Brandon Spence, Brani Stojkovic, Brian Gamido, Britt Montalvo, Carl Parker, Carly
 372 Burton, Catalina Mejia, Ce Liu, Changan Wang, Changkyu Kim, Chao Zhou, Chester Hu, Ching-
 373 Hsiang Chu, Chris Cai, Chris Tindal, Christoph Feichtenhofer, Cynthia Gao, Damon Civin, Dana
 374 Beaty, Daniel Kreymer, Daniel Li, David Adkins, David Xu, Davide Testuggine, Delia David,
 375 Devi Parikh, Diana Liskovich, Didem Foss, Dingkan Wang, Duc Le, Dustin Holland, Edward
 376 Dowling, Eissa Jamil, Elaine Montgomery, Eleonora Presani, Emily Hahn, Emily Wood, Eric-
 377 Tuan Le, Erik Brinkman, Esteban Arcaute, Evan Dunbar, Evan Smothers, Fei Sun, Felix Kreuk,
 378 Feng Tian, Filippos Kokkinos, Firat Ozgenel, Francesco Caggioni, Frank Kanayet, Frank Seide,
 379 Gabriela Medina Florez, Gabriella Schwarz, Gada Badeer, Georgia Swee, Gil Halpern, Grant Her-
 380 man, Grigory Sizov, Guangyi Zhang, Guna Lakshminarayanan, Hakan Inan, Hamid Shojanazeri,
 381 Han Zou, Hannah Wang, Hanwen Zha, Haroun Habeeb, Harrison Rudolph, Helen Suk, Henry
 382 Aspegren, Hunter Goldman, Hongyuan Zhan, Ibrahim Damlaj, Igor Molybog, Igor Tufanov, Il-
 383 ias Leontiadis, Irina-Elena Veliche, Itai Gat, Jake Weissman, James Geboski, James Kohli, Janice
 384 Lam, Japhet Asher, Jean-Baptiste Gaya, Jeff Marcus, Jeff Tang, Jennifer Chan, Jenny Zhen, Jeremy
 385 Reizenstein, Jeremy Teboul, Jessica Zhong, Jian Jin, Jingyi Yang, Joe Cummings, Jon Carvill, Jon
 386 Shepard, Jonathan McPhie, Jonathan Torres, Josh Ginsburg, Junjie Wang, Kai Wu, Kam Hou U,
 387 Karan Saxena, Kartikay Khandelwal, Katayoun Zand, Kathy Matosich, Kaushik Veeraraghavan,
 388 Kelly Michelena, Keqian Li, Kiran Jagadeesh, Kun Huang, Kunal Chawla, Kyle Huang, Lailin
 389 Chen, Lakshya Garg, Lavender A, Leandro Silva, Lee Bell, Lei Zhang, Liangpeng Guo, Licheng
 390 Yu, Liron Moshkovich, Luca Wehrstedt, Madian Khabsa, Manav Avalani, Manish Bhatt, Martynas
 391 Mankus, Matan Hasson, Matthew Lennie, Matthias Reso, Maxim Groshev, Maxim Naumov, Maya
 392 Lathi, Meghan Keneally, Miao Liu, Michael L. Seltzer, Michal Valko, Michelle Restrepo, Mihir
 393 Patel, Mik Vyatskov, Mikayel Samvelyan, Mike Clark, Mike Macey, Mike Wang, Miquel Jubert
 394 Hermoso, Mo Metanat, Mohammad Rastegari, Munish Bansal, Nandhini Santhanam, Natascha
 395 Parks, Natasha White, Navyata Bawa, Nayan Singhal, Nick Egebo, Nicolas Usunier, Nikhil Mehta,
 396 Nikolay Pavlovich Laptev, Ning Dong, Norman Cheng, Oleg Chernoguz, Olivia Hart, Omkar
 397 Salpekar, Ozlem Kalinli, Parkin Kent, Parth Parekh, Paul Saab, Pavan Balaji, Pedro Rittner, Philip
 398 Bontrager, Pierre Roux, Piotr Dollar, Polina Zvyagina, Prashant Ratanchandani, Pritish Yuvraj,
 399 Qian Liang, Rachad Alao, Rachel Rodriguez, Rafi Ayub, Raghotham Murthy, Raghu Nayani,
 400 Rahul Mitra, Rangaprabhu Parthasarathy, Raymond Li, Rebekkah Hogan, Robin Battey, Rocky
 401 Wang, Russ Howes, Ruty Rinott, Sachin Mehta, Sachin Siby, Sai Jayesh Bondu, Samyak Datta,
 402 Sara Chugh, Sara Hunt, Sargun Dhillon, Sasha Sidorov, Satadru Pan, Saurabh Mahajan, Saurabh
 403 Verma, Seiji Yamamoto, Sharadh Ramaswamy, Shaun Lindsay, Shaun Lindsay, Sheng Feng,
 404 Shenghao Lin, Shengxin Cindy Zha, Shishir Patil, Shiva Shankar, Shuqiang Zhang, Shuqiang
 405 Zhang, Sinong Wang, Sneha Agarwal, Soji Sajuyigbe, Soumith Chintala, Stephanie Max, Stephen
 406 Chen, Steve Kehoe, Steve Satterfield, Sudarshan Govindaprasad, Sumit Gupta, Summer Deng,
 407 Sungmin Cho, Sunny Virk, Suraj Subramanian, Sy Choudhury, Sydney Goldman, Tal Remez,
 408 Tamar Glaser, Tamara Best, Thilo Koehler, Thomas Robinson, Tianhe Li, Tianjun Zhang, Tim
 409 Matthews, Timothy Chou, Tzook Shaked, Varun Vontimitta, Victoria Ajayi, Victoria Montanez,
 410 Vijai Mohan, Vinay Satish Kumar, Vishal Mangla, Vlad Ionescu, Vlad Poenaru, Vlad Tiberiu
 411 Mihailescu, Vladimir Ivanov, Wei Li, Wenchen Wang, Wenwen Jiang, Wes Bouaziz, Will Con-
 412 stable, Xiaocheng Tang, Xiaojuan Wu, Xiaolan Wang, Xilun Wu, Xinbo Gao, Yaniv Kleinman,
 413 Yanjun Chen, Ye Hu, Ye Jia, Ye Qi, Yenda Li, Yilin Zhang, Ying Zhang, Yossi Adi, Youngjin
 414 Nam, Yu Wang, Yu Zhao, Yuchen Hao, Yundi Qian, Yunlu Li, Yuzi He, Zach Rait, Zachary De-
 415 Vito, Zef Rosnbrick, Zhaoduo Wen, Zhenyu Yang, Zhiwei Zhao, and Zhiyu Ma. The Llama 3
 416 Herd of Models. *arXiv:2407.21783*, 2024.

417 Shibo Hao, Sainbayar Sukhbaatar, DiJia Su, Xian Li, Zhiting Hu, Jason Weston, and Yuandong Tian.
 418 Training Large Language Models to Reason in a Continuous Latent Space. In *ICLR*, 2025.

419 Chaoqun He, Renjie Luo, Yuzhuo Bai, Shengding Hu, Zhen Leng Thai, Junhao Shen, Jinyi Hu,
 420 Xu Han, Yujie Huang, Yankai Zhang, Jie Liu, Lei Qi, Zhiyuan Liu, and Maosong Sun. Olympiad-
 421 Bench: A Challenging Benchmark for Promoting AGI with Olympiad-Level Bilingual Multimodal
 422 Scientific Problems. In *Findings of ACL*, 2024.

423 Neil Houlsby, Andrei Giurgiu, Stanislaw Jastrzebski, Bruna Morrone, Quentin de Laroussilhe, An-
 424 drea Gesmundo, Mona Attariyan, and Sylvain Gelly. Parameter-Efficient Transfer Learning for
 425 NLP. In *ICML*, 2019.

426 Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang,
427 and Weizhu Chen. LoRA: Low-Rank Adaptation of Large Language Models. In *ICLR*, 2022.

428 Neel Jain, Ping-yeh Chiang, Yuxin Wen, John Kirchenbauer, Hong-Min Chu, Gowthami Somepalli,
429 Brian R. Bartoldson, Bhavya Kailkhura, Avi Schwarzschild, Aniruddha Saha, Micah Goldblum,
430 Jonas Geiping, and Tom Goldstein. NEFTune: Noisy Embeddings Improve Instruction Finetuning.
431 In *ICLR*, 2024.

432 Xinyue Kang, Diwei Shi, and Li Chen. Model Whisper: Steering Vectors Unlock Large Language
433 Models’ Potential in Test-time. In *AAAI*, 2026.

434 Brian Lester, Rami Al-Rfou, and Noah Constant. The Power of Scale for Parameter-Efficient Prompt
435 Tuning. In *EMNLP*, 2021.

436 Aitor Lewkowycz, Anders Andreassen, David Dohan, Ethan Dyer, Henryk Michalewski, Vinay Ra-
437 masesh, Ambrose Slone, Cem Anil, Imanol Schlag, Theo Gutman-Solo, Yuhuai Wu, Behnam
438 Neyshabur, Guy Gur-Ari, and Vedant Misra. Solving Quantitative Reasoning Problems with Lan-
439 guage Models. *arXiv:2206.14858*, 2022.

440 Xiang Lisa Li and Percy Liang. Prefix-Tuning: Optimizing Continuous Prompts for Generation. In
441 *ACL-IJCNLP*, 2021.

442 Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike,
443 John Schulman, Ilya Sutskever, and Karl Cobbe. Let’s Verify Step by Step. In *ICLR*, 2024.

444 Xiao Liu, Yanan Zheng, Zhengxiao Du, Ming Ding, Yujie Qian, Zhilin Yang, and Jie Tang. GPT
445 Understands, Too. *AI Open*, 5:208–215, 2024.

446 Aman Madaan and Amir Yazdanbakhsh. Text and Patterns: For Effective Chain of Thought, It Takes
447 Two to Tango. *arXiv:2209.07686*, 2022.

448 Alexander Robey, Eric Wong, Hamed Hassani, and George J. Pappas. SmoothLLM: Defending Large
449 Language Models Against Jailbreaking Attacks. *Transactions on Machine Learning Research*,
450 2025.

451 Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang,
452 Mingchuan Zhang, Y.K. Li, Y. Wu, and Daya Guo. DeepSeekMath: Pushing the Limits of Math-
453 ematical Reasoning in Open Language Models. *arXiv:2402.03300*, 2024.

454 Guangming Sheng, Chi Zhang, Zilingfeng Ye, Xibin Wu, Wang Zhang, Ru Zhang, Yanghua
455 Peng, Haibin Lin, and Chuan Wu. HybridFlow: A Flexible and Efficient RLHF Framework.
456 *arXiv:2409.19256*, 2024.

457 Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov.
458 Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *Journal of Machine Learn-
459 ing Research*, 15:1929–1958, 2014.

460 Zhenpeng Su, Leiyu Pan, Minxuan Lv, Yuntao Li, Wenping Hu, Fuzheng Zhang, Kun Gai, and
461 Guorui Zhou. CE-GPPO: Coordinating Entropy via Gradient-Preserving Clipping Policy Opti-
462 mization in Reinforcement Learning. In *ACL*, 2026.

463 Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2
464 edition, 2018.

465 Shenzi Wang, Le Yu, Chang Gao, Chujie Zheng, Shixuan Liu, Rui Lu, Kai Dang, Xionghui Chen,
466 Jianxin Yang, Zhenru Zhang, Yuqiong Liu, An Yang, Andrew Zhao, Yang Yue, Shiji Song, Bowen
467 Yu, Gao Huang, and Junyang Lin. Beyond the 80/20 Rule: High-Entropy Minority Tokens Drive
468 Effective Reinforcement Learning for LLM Reasoning. In *NeurIPS*, 2025.

469 Yige Xu, Xu Guo, Zhiwei Zeng, and Chunyan Miao. SoftCoT: Soft Chain-of-Thought for Efficient
470 Reasoning with LLMs. In *ACL*, 2025.

- 471 An Yang, Beichen Zhang, Binyuan Hui, Bofei Gao, Bowen Yu, Chengpeng Li, Dayiheng Liu,
472 Jianhong Tu, Jingren Zhou, Junyang Lin, Keming Lu, Mingfeng Xue, Runji Lin, Tianyu Liu,
473 Xingzhang Ren, and Zhenru Zhang. Qwen2.5-Math Technical Report: Toward Mathematical
474 Expert Model via Self-Improvement. *arXiv:2409.12122*, 2024.
- 475 Wengao Ye, Yan Liang, and Lianlei Shan. Thinking on the Fly: Test-Time Reasoning Enhancement
476 via Latent Thought Policy Optimization. In *ICLR*, 2026.
- 477 Qiying Yu, Zheng Zhang, Ruofei Zhu, Yufeng Yuan, Xiaochen Zuo, Yu Yue, Weinan Dai, Tiantian
478 Fan, Gaohong Liu, Juncai Liu, Lingjun Liu, Xin Liu, Haibin Lin, Zhiqi Lin, Bole Ma, Guangming
479 Sheng, Yuxuan Tong, Chi Zhang, Mofan Zhang, Ru Zhang, Wang Zhang, Hang Zhu, Jinhua Zhu,
480 Jiaze Chen, Jiangjie Chen, Chengyi Wang, Hongli Yu, Yuxuan Song, Xiangpeng Wei, Hao Zhou,
481 Jingjing Liu, Wei-Ying Ma, Ya-Qin Zhang, Lin Yan, Yonghui Wu, and Mingxuan Wang. DAPO:
482 An Open-Source LLM Reinforcement Learning System at Scale. In *NeurIPS*, 2025.
- 483 Weihao Zeng, Yuzhen Huang, Qian Liu, Wei Liu, Keqing He, Zejun Ma, and Junxian He. SimpleRL-
484 Zoo: Investigating and Taming Zero Reinforcement Learning for Open Base Models in the Wild.
485 *arXiv:2503.18892*, 2025.
- 486 Guibin Zhang, Muxin Fu, and Shuicheng Yan. MemGen: Weaving Generative Latent Memory for
487 Self-Evolving Agents. In *ICLR*, 2026.

488 A 실험 설정과 전체 정확도 분석

489 Table 7은 본문 Table 1에서 위치별 최고 성능만 요약해 제시한 결과를, Prefix, Infix, Suffix 별 전체
 490 정확도로 다시 펼쳐 보인다. Table 8는 각 모델-벤치마크 조합에서 사용한 RSP 토큰 수 L 을 정리
 491 한 것으로, 후보 집합 {10, 15, 20}에서 선택했다. 모든 실험은 단일 NVIDIA A6000 40GB GPU
 492 에서 greedy decoding으로 수행했으며, 최대 생성 길이는 MATH-500과 GSM8K에서 3,072 토큰,
 493 AIME24에서 4,096 토큰으로 고정했다. 배치 크기는 모델별로 고정했다(LLaMA-3.1-8B-Instruct
 494 와 Qwen2.5-Math-7B 계열은 16, Qwen2.5-Math-1.5B 계열은 32).

Table 7: 모델 설정, 주입 위치, 벤치마크별 정확도(%). 괄호 안 값은 baseline 대비 변화량이다. 굵게는 최고 성능, 밑줄은 각 모델-벤치마크 조합에서 두 번째 성능을 뜻한다.

Model	Mode	MATH-500	GSM8K	AIME24
<i>Instruct Models</i>				
LLaMA-3.1-8B-Instruct	Baseline	52.20	85.75	<u>6.67</u>
	Prefix	45.00 (−7.2)	76.35 (−9.4)	3.33 (−3.3)
	Infix	<u>49.40</u> (−2.8)	85.97 (+0.2)	10.00 (+3.3)
	Suffix	<u>49.40</u> (−2.8)	86.73 (+1.0)	10.00 (+3.3)
Qwen2.5-Math-7B-Instruct	Baseline	83.20	95.45	<u>13.33</u>
	Prefix	81.40 (−1.8)	94.92 (−0.5)	<u>13.33</u> (+0.0)
	Infix	84.20 (+1.0)	<u>95.60</u> (+0.2)	16.67 (+3.3)
	Suffix	<u>83.40</u> (+0.2)	95.68 (+0.2)	16.67 (+3.3)
Qwen2.5-Math-1.5B-Instruct	Baseline	73.00	85.29	10.00
	Prefix	74.80 (+1.8)	85.29 (+0.0)	<u>13.33</u> (+3.3)
	Infix	75.20 (+2.2)	85.75 (+0.5)	<u>6.67</u> (−3.3)
	Suffix	74.20 (+1.2)	84.69 (−0.6)	20.00 (+10.0)
<i>Base Models (Raw Text)</i>				
Qwen2.5-Math-7B	Baseline	72.20	<u>84.15</u>	6.67
	Prefix	<u>71.60</u> (−0.6)	84.31 (+0.2)	16.67 (+10.0)
	Infix	63.20 (−9.0)	64.29 (−19.9)	16.67 (+10.0)
	Suffix	55.60 (−16.6)	54.13 (−30.0)	<u>13.33</u> (+6.7)
Qwen2.5-Math-1.5B	Baseline	<u>61.40</u>	77.86	16.67
	Prefix	64.40 (+3.0)	<u>74.30</u> (−3.6)	<u>10.00</u> (−6.7)
	Infix	63.20 (+1.8)	73.92 (−3.9)	<u>10.00</u> (−6.7)
	Suffix	54.60 (−6.8)	58.61 (−19.3)	3.33 (−13.3)
<i>Base Models + ChatML (Format Mismatch)</i>				
Qwen2.5-Math-7B	Baseline	52.20	58.30	23.33
	Prefix	59.20 (+7.0)	56.41 (−1.9)	<u>3.33</u> (−20.0)
	Infix	<u>62.00</u> (+9.8)	69.07 (+10.8)	23.33 (+0.0)
	Suffix	70.40 (+18.2)	75.97 (+17.7)	23.33 (+0.0)
Qwen2.5-Math-1.5B	Baseline	34.40	37.45	<u>13.33</u>
	Prefix	63.40 (+29.0)	67.02 (+29.6)	20.00 (+6.7)
	Infix	39.20 (+4.8)	50.42 (+13.0)	6.67 (−6.7)
	Suffix	<u>51.00</u> (+16.6)	<u>50.64</u> (+13.2)	<u>13.33</u> (+0.0)

Table 8: 각 모델과 벤치마크에 사용한 RSP 토큰 수 (L).

Model	MATH-500	GSM8K	AIME24
LLaMA-3.1-8B-Instruct	15	20	15
Qwen2.5-Math-7B-Instruct	20	20	20
Qwen2.5-Math-1.5B-Instruct	20	10	20
Qwen2.5-Math-7B	10	10	20
Qwen2.5-Math-1.5B	10	10	20
Qwen2.5-Math-1.5B (ChatML)	20	20	10
Qwen2.5-Math-7B (ChatML)	20	20	20

495 A.1 RSP 주입 위치와 프롬프트 템플릿

496 아래에는 모든 모델 유형에서 주입 위치별 프롬프트 구조를 정리했다. **파란색 텍스트**는 RSP
 497 임베딩, **보라색 텍스트**는 특수 토큰을 뜻한다.

498 A.1.1 Prefix

499 Prefix 주입에서는 RSP 임베딩을 프롬프트 임베딩 앞에 연결한다. 텍스트 자체는 수정하지
500 않는다.

501 ChatML (Qwen Instruct / Base + ChatML).

```
[Random Embeddings (L tokens)]
<|im_start|>system
Please reason step by step, and put your final answer within \boxed{<|im_end|>
<|im_start|>user
{question}<|im_end|>
<|im_start|>assistant
```

503 LLaMA Chat Template.

```
[Random Embeddings (L tokens)]
<|begin_of_text|>
<|start_header_id|>system<|end_header_id|>
Cutting Knowledge Date: December 2023
Today Date: 26 Jul 2024
Please reason step by step, and put your final answer within \boxed{<|eot_id|>
<|start_header_id|>user<|end_header_id|>
{question}<|eot_id|>
<|start_header_id|>assistant<|end_header_id|>
```

505 Raw Text (Qwen Base).

```
[Random Embeddings (L tokens)]
{question}
Please reason step by step, and put your final answer within \boxed{<|im_end|>
```

507 A.1.2 Infix

508 Infix 주입에서는 설명 문구와 특수 토큰을 프롬프트 내부에 넣은 뒤, 그 특수 토큰 위치를 임베딩
509 수준에서 RSP로 교체한다.

510 ChatML (Qwen Instruct / Base + ChatML).

```
<|im_start|>system
Please reason step by step, and put your final answer within \boxed{<|im_end|>
<|im_start|>user
{question}

There are {L} special tokens that contain compressed latent reasoning
information that might be useful for your reasoning. If these tokens are
useful for your case, you can use them as reference. If these tokens are
not useful for your case, you can ignore them and focus back to solving the
problem.

Here are the {L} special tokens: <special_token_1>...<special_token_L>
<|im_end|>
<|im_start|>assistant
```

512 LLaMA Chat Template.

```
<|begin_of_text|>
<|start_header_id|>system<|end_header_id|>
Cutting Knowledge Date: December 2023
Today Date: 26 Jul 2024
Please reason step by step, and put your final answer within \boxed{<|im_end|>
```

```

eot_id|>
<|start_header_id|>user<|end_header_id|>
{question}

There are {L} special tokens that contain compressed latent reasoning
information that might be useful for your reasoning. If these tokens are
useful for your case, you can use them as reference. If these tokens are
not useful for your case, you can ignore them and focus back to solving the
problem.

Here are the {L} special tokens:
<reserved_special_token_0>...
<reserved_special_token_L>
<|eot_id|>
<|start_header_id|>assistant<|end_header_id|>

```

514

515 Raw Text (Qwen Base).

```

{question}

There are {L} special tokens that contain compressed latent reasoning
information that might be useful for your reasoning. If these tokens are
useful for your case, you can use them as reference. If these tokens are
not useful for your case, you can ignore them and focus back to solving the
problem.

Here are the {L} special tokens: <special_token_1>...<special_token_L>
Please reason step by step, and put your final answer within \boxed{ }.

```

516

517 A.1.3 Suffix

518 채팅 템플릿 모델에서는 end-of-turn 토큰 바로 앞에 RSP 임베딩을 넣고, raw text 모델에서는
519 프롬프트 마지막에 RSP 임베딩을 이어 붙인다.

520 ChatML (Qwen Instruct / Base + ChatML).

```

<|im_start|>system
Please reason step by step, and put your final answer within \boxed{ }.<|
im_end|>
<|im_start|>user
{question}[Random Embeddings (L tokens)]<|im_end|>
<|im_start|>assistant

```

521

522 LLaMA Chat Template.

```

<|begin_of_text|>
<|start_header_id|>system<|end_header_id|>
Cutting Knowledge Date: December 2023
Today Date: 26 Jul 2024
Please reason step by step, and put your final answer within \boxed{ }.<|
eot_id|>
<|start_header_id|>user<|end_header_id|>
{question}[Random Embeddings (L tokens)]<|eot_id|>
<|start_header_id|>assistant<|end_header_id|>

```

523

524 Raw Text (Qwen Base).

```

{question}
Please reason step by step, and put your final answer within \boxed{ }. [Random
Embeddings (L tokens)]

```

525

526 A.2 정답 추출과 채점

527 최종 정답은 fallback 체인을 통해 모델 출력에서 추출한다. 각 단계는 순서대로 시도하며, 추출에
528 실패하면 다음 단계로 넘어간다.

정답 추출 fallback 체인

1. "final answer is \$...\$. I hope" 패턴 (Minerva 형식)
2. `\boxed{...}`: 마지막 비어 있지 않은 box를 사용하고, 빈 `\boxed{}`는 건너뛰
3. "the answer is" 뒤 텍스트
4. "final answer is" 뒤 텍스트
5. 출력 마지막 숫자(regex fallback)

529

530 추출된 정답은 `$`, `\left`, `\right`, 단위 문자열을 제거해 정규화한다. 채점은 sym-
531 bolic equivalence checking으로 수행하며, 정확한 문자열 일치, 수치 비교(`math.isclose`,
532 `rel_tol=1e-4`), SymPy symbolic simplification을 차례로 적용한다.

533 A.3 재현한 선행연구의 하이퍼파라미터

534 모든 선행 방법은 Qwen2.5-Math-1.5B-Instruct와 Qwen2.5-Math-7B-Instruct에서 재현했으며,
535 greedy decoding(`temperature = 0`)과 통일된 answer extraction pipeline으로 평가했다.

536 **TTSV.** Prefix 길이는 20이며, AdamW optimizer로 20 epoch 동안 학습했다. 배치 크기는 2,
537 gradient accumulation은 8 step, 스케줄은 선형 learning rate schedule을 사용했다. Learning rate
538 는 Qwen-1.5B에 $1e-3$, Qwen-7B에 $1e-5$ 를 사용했다.

539 **LTPO.** Table 9는 벤치마크별 하이퍼파라미터를 정리한 것이다.

Table 9: LTPO 하이퍼파라미터.

Parameter	GSM8K	MATH-500	AIME24
tokens	8	8	8
steps	20	20	20
top_k	10	10	10
sigma	20	20	5
sigma_decay	0.95	0.95	0.95
lr	$1e-2$	$5e-3$	$5e-2$

540 **SoftCoT.** Projection module은 10 epoch 동안 학습했다. Thought token 수는 학습 시 32, 평가 시
541 4다. 배치 크기는 GSM8K에서 4, MATH에서는 1이며 gradient accumulation 4를 사용했다. 작은
542 모델(assistant)은 두 설정 모두 Qwen2.5-Math-1.5B-Instruct이고, 큰 모델은 Qwen2.5-Math-1.5B-
543 Instruct(`learning rate 2e-5`) 또는 Qwen2.5-Math-7B-Instruct(`learning rate 5e-6`)이다. MATH-500
544 과 AIME24 평가는 GSM8K에서 학습한 projection module을 사용했는데, MATH에서 학습한
545 버전보다 더 높은 정확도를 보였기 때문이다.

546 A.4 전체 엔트로피 곡선

547 Figure 6는 entropy, top-1 probability, varentropy의 전체 정규화 생성 궤적(0-100%)을 보여준다.
548 모든 방법은 생성 초반 단계를 지나면 비슷한 수준으로 수렴하며, 이는 RSP가 유도하는 분포
549 변화가 초기 추론 단계에 국소화되어 있음을 다시 확인해 준다.




Figure 6: 전체 정규화 생성 궤적(0-100%)에서의 평균 entropy(위), top-1 probability(가운데), varentropy(아래). MATH-500 전체 평균이며, 음영은 ± 1 SEM을 뜻한다. 실선은 RSP 변형과 baseline, 점선은 기존 soft prompt 방법이다. 모든 방법은 초반 단계를 지나면 수렴한다.

550 B 의미적 다양성에 대한 추가 분석

551 이 부록은 Section 4.4에서 보고한 의미적 다양성 결과를 보충한다. 더 넓은 문제 집합에 대해
552 문제별 t-SNE 도표를 함께 제시한다.




Figure 7: 평가한 64개 MATH-500 문제 중 48개에 대한 BGE-M3 임베딩의 t-SNE 투영(6×8 격자). 각 subplot은 Qwen2.5-Math-1.5B-Instruct에서 $\tau = 1.0$ 으로 생성한 baseline 300개(빨강)와 RSP suffix 300개(파랑)를 보여준다. 채워진 표식은 정답, 빈 표식은 오답이며, 제목은 subject/problem_id를 뜻한다. 대부분의 문제에서 RSP 궤적은 여러 개의 분리된 영역으로 퍼지는 반면, baseline 샘플은 하나의 지배적 클러스터에 더 집중된다.

553 C 토큰 수준 분포 지표

554 이 부록은 Section 4.4의 토큰 수준 분석에 사용한 세 지표를 형식적으로 정의한다. P_{base} 는
555 $\tau = 1.0$ 에서의 baseline 다음 토큰 분포, P_{target} 은 비교 대상 분포(예: $\tau = 2.0$ 의 baseline, 또는
556 $\tau = 1.0$ 의 RSP)라 하자. 모든 지표는 첫 생성 단계에서 저장한 logits로부터 해석적으로 계산
557 한다.

558 **Spearman 순위 상관.** Spearman의 ρ 는 두 분포의 토큰 순위 사이 Pearson 상관계수다.

$$\rho = \text{Pearson}(\text{rank}(P_{\text{target}}), \text{rank}(P_{\text{base}})). \quad (4)$$

559 Temperature scaling $P^{(\tau)} \propto P^{1/\tau}$ 는 엄격한 단조 변환이므로, 어떤 $\tau > 0$ 에서도 토큰 순서를
560 정확히 보존한다. 따라서 $\rho = 1$ 은 수학적 항등식이다. 그러므로 $\rho < 1$ 은 temperature scaling
561 만으로는 만들 수 없는 순위 재조작이 일어났음을 뜻한다.

562 **Top- K 밖의 질량.** $\text{TopK}(P_{\text{base}})$ 를 P_{base} 에서 확률이 가장 높은 K 개 토큰의 집합이라 하자. 비
563 교 대상 분포가 이 집합 *밖에* 두는 확률 질량은

$$\text{MassOutside}_K = 1 - \sum_{t \in \text{TopK}(P_{\text{base}})} P_{\text{target}}(t). \quad (5)$$

564 이 지표는 지지 집합 확장을 직접 측정한다. 즉 baseline의 선호 집합에 없던 토큰에 비교 대상이
565 얼마나 많은 확률을 배정하는지를 본다. 본문에 보고한 값은 $K = 10$ 을 사용했다.

566 **Jensen–Shannon divergence.** Kullback–Leibler divergence의 대칭적이고 bounded된 형태는 다
567 음과 같다.

$$\text{JS}(P, Q) = \frac{1}{2} \text{KL}(P \parallel M) + \frac{1}{2} \text{KL}(Q \parallel M), \quad M = \frac{1}{2}(P + Q). \quad (6)$$

568 로그는 밑이 2이므로 $\text{JS} \in [0, 1]$ 이다. 저장한 top-100 바깥의 토큰에는 softmax 전에 sentinel
569 $\text{logit}(-10^9)$ 을 넣었는데, 본 설정에서는 top-5가 이미 확률 질량의 99.9% 이상을 덮기 때문에 이
570 근사는 무시 가능하다.

571 D 이론에 필요한 Prompt 법칙의 성질

572 이 부록은 본문에서 실제로 사용하는 성질만 남긴다: 중심성, 분산 예산 아래의 방향 무관 공
573 분산, 그리고 모든 비공집합 열린집합에 대한 양의 확률이다. Section 3.4의 메커니즘에는 이
574 기하학적·측도론적 사실만 필요하므로, 더 강한 의미론적 해석은 쓰지 않는다.

575 D.1 중심화된 섭동은 체계적인 1차 드리프트를 만들지 않는다

576 토큰 i, j 의 baseline logit gap을 Δ_{ij} 라 하고 1차 surrogate를

$$\Delta_{ij}(\bar{h}) = \Delta_{ij} + b_{ij}^\top \bar{h}$$

577 로 두자.

578 **명제 3** (체계적인 1차 드리프트의 부재). $\mathbb{E}[\bar{h}] = 0$ 이면 모든 토큰 쌍 (i, j) 에 대해

$$\mathbb{E}[\Delta_{ij}(\bar{h})] = \Delta_{ij}$$

579 가 성립한다. 반대로 결정적 prompt h_0 를 모든 run에 재사용하면

$$\Delta_{ij}(h_0) - \Delta_{ij} = b_{ij}^\top h_0$$

580 는 고정된 방향 편향이다.

581 *Proof.* 중심화된 경우는 기대값의 선형성으로 바로 나온다.

$$\mathbb{E}[\Delta_{ij}(\bar{h})] = \Delta_{ij} + b_{ij}^\top \mathbb{E}[\bar{h}] = \Delta_{ij}.$$

582 결정적 경우는 그대로 대입하면 된다. □

583 이 명제가 뜻하는 것은 run 평균에서의 1차 편향이 없다는 점이지, 개별 샘플이 logit을 바꾸지
584 않는다는 뜻은 아니다.

585 D.2 Theorem 1의 증명

586 본문의 local linear logit surrogate에 직접 등장하는 양은 단위벡터 b 에 대한 1차 섭동 에너지
587 $\text{Var}_{h \sim D}(b^\top h) = b^\top \Sigma_D b$ 이다. 따라서 최악 방향의 에너지는 Σ_D 의 최소 Rayleigh quotient와
588 같다.

589 *Theorem 1의 증명.* Σ_D 의 고윳값을 $\lambda_1, \dots, \lambda_d$ 라 하면,

$$\lambda_{\min}(\Sigma_D) \leq \frac{1}{d} \sum_{m=1}^d \lambda_m = \frac{\text{tr}(\Sigma_D)}{d} \leq \frac{\rho^2}{d}.$$

590 모든 고윳값이 같을 때, 즉 $\Sigma_D = (\rho^2/d)\mathbf{I}_d$ 일 때 그리고 그럴 때만 등호가 성립한다. □

591 이 증명에는 공분산만 필요하다. RSP에서 가우시안을 택하는 이유는 다음 소절의 열린집합
592 도달 가능성까지 함께 얻기 위해서다.

593 D.3 등방 가우시안 프롬프트의 열린집합 도달 가능성

594 **명제 4** (열린집합 도달 가능성). $\sigma > 0$ 이고 $\bar{h} \sim \mathcal{N}(0, \sigma^2 \mathbf{I}_d)$ 라 하자. 그러면 모든 비공집합
595 열린집합 $U \subseteq \mathbb{R}^d$ 에 대해

$$\Pr(\bar{h} \in U) > 0$$

596 가 성립한다.

597 *Proof.* 가우시안 밀도

$$(2\pi\sigma^2)^{-d/2} \exp\left(-\frac{\|\bar{h}\|^2}{2\sigma^2}\right)$$

598 는 $\mathbb{R}^d$ 의 모든 점에서 엄밀히 양수다. 모든 비공집합 열린집합은 양의 르베그 측도를 갖는 ball
599 하나를 포함하므로, 그 ball 위에서 양의 밀도를 적분하면 양의 확률이 얻어진다. □

600 이것이 Proposition 2에 실제로 쓰이는 유일한 support 성질이다.

601 E 본문 이론 결과의 증명

602 이 부록은 본문 이론결과와 같은 순서를 따른다: exploration, annealing, 성능 향상. 그보다 앞에서
603 필요한 prompt 법칙의 성질은 Appendix D에 모아 두었다.

604 E.1 Exploration: attention decomposition과 perturbation 크기

605 **명제 5** (Attention decomposition). *Layer ℓ 의 한 attention head가 query 위치 i 에서 마스크되지*
606 *않은 실제 토큰 $n \geq 1$ 개와 RSP 토큰 $L \geq 1$ 개를 attend하며, attention logit은 모두 유한하다고*
607 *하자. Attention weight를 $\alpha_{ij}^{(\ell)}$ 로 두고, RSP attention mass를*

$$w_{r,i}^{(\ell)} := \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)}$$

608 로 두고, $j \in [n]$ 에 대해

$$\tilde{\alpha}_{ij}^{(\ell)} := \frac{\alpha_{ij}^{(\ell)}}{1 - w_{r,i}^{(\ell)}}$$

609 라 정의하면,

$$\mathbf{o}_i^{(\ell)} = (1 - w_{r,i}^{(\ell)}) \tilde{\mathbf{o}}_i^{(\ell)} + \boldsymbol{\eta}_i^{(\ell)}$$

610 이고

$$\tilde{\mathbf{o}}_i^{(\ell)} := \sum_{j=1}^n \tilde{\alpha}_{ij}^{(\ell)} \mathbf{v}_j^{(\ell)}, \quad \boldsymbol{\eta}_i^{(\ell)} := \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{r_j}^{(\ell)}.$$

611 *Proof.* Head output은 실제 토큰 항과 RSP 토큰 항으로 정확히 나뉜다.

$$\mathbf{o}_i^{(\ell)} = \sum_{j=1}^n \alpha_{ij}^{(\ell)} \mathbf{v}_j^{(\ell)} + \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{r_j}^{(\ell)}.$$

612 마스크되지 않은 실제 토큰이 있고 softmax 가중치가 양수이므로 $\sum_{j=1}^n \alpha_{ij}^{(\ell)} = 1 - w_{r,i}^{(\ell)} > 0$
613 이다. 따라서 실제 토큰 항은

$$\sum_{j=1}^n \alpha_{ij}^{(\ell)} \mathbf{v}_j^{(\ell)} = (1 - w_{r,i}^{(\ell)}) \sum_{j=1}^n \frac{\alpha_{ij}^{(\ell)}}{1 - w_{r,i}^{(\ell)}} \mathbf{v}_j^{(\ell)} = (1 - w_{r,i}^{(\ell)}) \tilde{\mathbf{o}}_i^{(\ell)}$$

614 가 된다. 이를 대입하면 분해가 바로 따른다. □

615 **따름정리 1** (크기는 RSP attention mass로 통제된다). 무작위 value가 어떤 값으로 실현되었든,

$$\|\boldsymbol{\eta}_i^{(\ell)}\| \leq w_{r,i}^{(\ell)} \max_{j \in [L]} \|\mathbf{v}_{r_j}^{(\ell)}\|.$$

616 *Proof.* 삼각부등식을 쓰면

$$\|\boldsymbol{\eta}_i^{(\ell)}\| = \left\| \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \mathbf{v}_{r_j}^{(\ell)} \right\| \leq \sum_{j=1}^L \alpha_{i,n+j}^{(\ell)} \|\mathbf{v}_{r_j}^{(\ell)}\| \leq w_{r,i}^{(\ell)} \max_{j \in [L]} \|\mathbf{v}_{r_j}^{(\ell)}\|.$$

617 □

618 Corollary 1가 본문에 필요한 유일한 정량적 사실이다. Attention weight와 random key 사이의 독
619 립성은 가정하지 않는다. $w_{r,i}^{(\ell)}$ 가 작아지면 RSP 기여의 크기도 같은 스칼라에 의해 작게 묶인다.

620 E.2 Theorem 1의 따름정리

621 **따름정리 2** (fixed-gap envelope의 시퀀스 방향 단조 감소). L 과 $\Delta_i^{(\ell)}$ 를 고정하면, 상계 $f(n) =$
 622 $L/(L + n \exp(\Delta_i^{(\ell)}/\sqrt{d}))$ 는 n 에 대해 엄격히 감소하고 $n \rightarrow \infty$ 에서 0으로 수렴한다. 따라서
 623 같은 gap이 유지된다는 가정 아래, *cache* 성장만으로 그 gap과 양립 가능한 최대 RSP attention
 624 mass의 envelope이 단조롭게 줄어진다.

625 자기회귀 디코딩에서는 새 토큰이 생성될 때마다 query · key · hidden state가 함께 갱신되어 $\Delta_i^{(\ell)}$
 626 도 step별로 변하므로, “실현된 mass가 매 step 단조 감소”가 아니라 “같은 gap이 유지되는 한
 627 가능한 최대 mass의 envelope이 단조 감소한다”가 정확한 진술이다.

628 *Proof.* $f'(n) = -L \exp(\Delta_i^{(\ell)}/\sqrt{d})/(L + n \exp(\Delta_i^{(\ell)}/\sqrt{d}))^2 < 0$ 이므로 엄격히 감소한다. 또한
 629 분자는 고정되어 있고 분모는 n 에 대해 선형으로 발산하므로 $f(n) \rightarrow 0$ 이다. $\square$

630 **따름정리 3** (고정 gap envelope 아래의 RSP 기여 감쇠). L 과 $\Delta_i^{(\ell)}$ 를 고정하고 $n \rightarrow \infty$ 이면
 631 $w_{r,i}^{(\ell)} \rightarrow 0$ 이고, RSP value의 고정된 실현에 대해 $\|\eta_i^{(\ell)}\| \leq w_{r,i}^{(\ell)} \max_{j \in [L]} \|\mathbf{v}_{r_j}^{(\ell)}\| \rightarrow 0$ 이다.

632 *Proof.* Corollary 2에서 $w_{r,i}^{(\ell)} \rightarrow 0$ 이고, Corollary 1의 상계를 그대로 적용하면 된다. 유한한
 633 개수의 sampled value에 대한 최대 norm은 고정 실현에서 유한하다. $\square$

634 E.3 성능 향상: local admission에서 Pass@N까지

635 본문 §3.4는 1차 surrogate 위에서 두 가지를 주장한다. baseline 밖 토큰이 국소 top- K 집합에
 636 진입할 수 있다는 점과, 독립 재실행이 그런 국소 진입을 Pass@ N 이득으로 바꾼다는 점이다.
 637 아래 증명은 centered prompt 법칙 D 의 다음 support 조건만 사용한다.

$$(S1) \quad D(U) > 0 \quad \text{for every nonempty open set } U \subseteq \mathbb{R}^d.$$

638 Section 3.4의 등방 가우시안 법칙은 Proposition 4에 의해 (S1)을 만족한다.

639 E.3.1 자기회귀 정식화

640 자기회귀 decoding에서 시퀀스 $y_{1:T}$ 의 결합 분포는

$$\Pr(y_{1:T} | x) = \prod_{t=1}^T p(y_t | x, y_{<t}),$$

641 로 분해된다. 각 단계는 prefix에 조건부인 분포로 결정되므로, RSP가 도입한 섭동은 단일한
 642 전역 분포를 한 번에 바꾸는 것이 아니라 $p(y_t | x, y_{<t})$ 에 대한 일련의 국소 변화로 작동한다.

643 E.3.2 RSP 하에서의 logits 국소 선형화

644 이 소절에서 $\bar{h} \in \mathbb{R}^d$ 는 RSP 정의(Eq. (1) in §3.1)에 등장하는 centered prompt 벡터 하나를 뜻
 645 한다. 실제 구현은 길이 L 의 prompt $\mathbf{H} = (h_1, \dots, h_L)$ 를 사용하지만, 아래 논리는 개별 국소
 646 섭동이 logits를 어떻게 움직일 수 있는지를 분리해서 본다. 섭동된 logits를 $z_i(\bar{h})$ 로 두고 $\bar{h} = 0$
 647 근방에서 국소 smoothness를 가정하면

$$z_i(\bar{h}) = z_i(0) + \nabla_h z_i(0)^\top \bar{h} + r_i(\bar{h}),$$

648 여기서 $r_i(\bar{h}) = O(\|\bar{h}\|^2)$ 이다. $a_i := \nabla_h z_i(0)$ 라 두면 1차 affine surrogate는

$$z_i^{\text{lin}}(\bar{h}) := z_i + a_i^\top \bar{h}$$

649 가 된다. 이는 branch opening을 설명하는 1차 surrogate이지, transformer logits 전체의 정확한
 650 전역 모델은 아니다.

651 **E.3.3 Proposition 2의 증명**

652 진입 영역을

$$\mathcal{G}_{i,K} := \{\bar{h} \in \mathbb{R}^d : \#\{j \neq i : z_j^{\text{lin}}(\bar{h}) > z_i^{\text{lin}}(\bar{h})\} \leq K - 1\}$$

653 로 두자.

654 *Proof.* $\mathcal{G}_{i,K}$ 가 비공집합 열린집합 U 를 포함한다고 하자. 그러면 (S1)에 의해 $D(U) > 0$ 이고,
655 $U \subseteq \mathcal{G}_{i,K}$ 이므로

$$\Pr_{\bar{h}}(\bar{h} \in \mathcal{G}_{i,K}) \geq D(U) > 0$$

656 가 성립한다. 이는 정확히 토큰 i 가 surrogate top- K 집합에 진입하는 사건이다.

657 실용적인 충분조건은 어떤 $\bar{h}_0$ 에서 토큰 i 가 많아야 $K - 1$ 개의 토큰만 자신보다 앞서도록
658 엄격한 마진을 만드는 경우다. 연속성에 의해 이때 $\bar{h}_0$ 의 근방 비공집합 열린집합이 $\mathcal{G}_{i,K}$ 에
659 포함된다. $\square$

660 **E.3.4 Proposition 2의 증명**

661 이 명제는 메커니즘만으로 $p_{\min}(x) > 0$ 을 도출하지 않는다. 과제 측 하한과 독립성이 주어졌을
662 때 이를 Pass@ N 증가로 바꾸는 역할만 한다.

663 *Proof.* A_n 을 문제 x 에서 n 번째 독립 RSP 실행이 정답 궤적에 도달하는 사건이라 하고, (M1)에
664 따라 $p_n(x) := \Pr(A_n) \geq p_{\min}(x)$ 라 하자. (M2) 아래에서

$$\Pr\left(\bigcap_{n=1}^N A_n^c\right) = \prod_{n=1}^N (1 - p_n(x)) \leq \prod_{n=1}^N (1 - p_{\min}(x)) = (1 - p_{\min}(x))^N.$$

665 여집합을 취하면

$$\Pr(\text{Pass@}N \text{ on } x) = \Pr\left(\bigcup_{n=1}^N A_n\right) \geq 1 - (1 - p_{\min}(x))^N.$$

666 마지막 부등식 $1 - x \leq e^{-x}$ ($x \in [0, 1]$)을 적용하면

$$1 - (1 - p_{\min}(x))^N \geq 1 - e^{-N p_{\min}(x)}$$

667 을 얻는다. $\square$

668 F Attention Mass 분석

669 이 부록은 Figure 1에 보고한 per-token attention mass를 형식화하고, reasoning span과 layer 축에
 670 적용한 제외 기준을 명시한다. 500개의 MATH-500 문제 각각에 대해 새로운 $\text{RSP } \mathbf{H} \in \mathbb{R}^{L \times d}$ 를
 671 $L = 10$ 으로 독립 샘플링했으므로, 보고한 heatmap은 문제 자체의 변동성과 RSP 벡터 변동성을
 672 함께 평균한 결과다.

673 F.1 토큰당 attention 질량

674 각 문제에서 attention은 연결된 시퀀스 [prompt; $\mathbf{H}$; generation] 위에서 측정하며, generation은
 675 같은 모델이 동일한 RSP 주입 설정 아래 생성한 궤적이다. $\alpha_{i,j}^{(\ell,h)}$ 를 layer ℓ , head h 에서 query
 676 위치 i 가 key 위치 j 로 보내는 post-softmax attention weight라고 하자. 이는 causal mask 아래에서
 677 $\sum_j \alpha_{i,j}^{(\ell,h)} = 1$ 을 만족한다. 질문 토큰과 RSP 토큰의 인덱스 집합을 각각 Q , R 라 하고 크기를
 678 $|Q|$, $|R| = L$, head 수를 H 라 하자. 이때 query i 가 각 그룹으로 보내는 layer ℓ 의 per-token
 679 attention mass는

$$\text{PTM}_Q[\ell, i] = \frac{1}{|Q|H} \sum_{h=1}^H \sum_{j \in Q} \alpha_{i,j}^{(\ell,h)}, \quad \text{PTM}_R[\ell, i] = \frac{1}{|R|H} \sum_{h=1}^H \sum_{j \in R} \alpha_{i,j}^{(\ell,h)}. \quad (7)$$

680 $|Q|$ 와 $|R|$ 로 나누는 정규화는 집합 크기 차이를 보정하므로, 두 양은 동일한 softmax 분모 아래
 681 에서 질문 토큰 또는 RSP 토큰 하나가 평균적으로 얼마나 많은 attention을 받는지를 나타낸다.
 682 따라서 질문 토큰은 시퀀스 길이 효과를 흡수하는 크기 보정 baseline 역할을 한다.

683 F.2 Heatmap 집계

684 Layer 인덱스와 reasoning position 인덱스를 각각 동일 크기의 다섯 구간 $\{B_L^{(b)}\}_{b=1}^5$, $\{B_P^{(b)}\}_{b=1}^5$
 685 로 나눈다. 샘플 s 와 목표 집합 $\bullet \in \{Q, R\}$ 에 대해 셀 (b_L, b_P) 의 값은

$$M_{\bullet}^{(s)}[b_L, b_P] = \frac{1}{|B_L^{(b_L)}| \cdot |B_P^{(b_P)}|} \sum_{\ell \in B_L^{(b_L)}} \sum_{i \in B_P^{(b_P)}} \text{PTM}_{\bullet}[\ell, i]. \quad (8)$$

686 Figure 1는 Eq. (8)를 500개의 유효 샘플에 대해 평균한 결과를 보고한다.

687 F.3 \boxed{\dots} 구간 제외

688 Reasoning position 범위는 마지막 \boxed{\dots} 구간이 시작되기 직전에 끝나도록 잡는다.
 689 Chain-of-thought 출력은 *text*(내용)와 *pattern*(형식) 성분으로 나뉘며, 이 둘은 downstream 성
 690 능에 독립적으로 기여할 수 있다 [Madaan and Yazdanbakhsh, 2022]. \boxed{\dots} 래퍼는 전형
 691 적인 pattern 성분이다. 이는 추론을 더 전개하기보다는 답 형식을 마무리하는 짧고 정형화된
 692 span이기 때문이다. 이 구간을 포함하면 reasoning dynamics와 무관한 template-driven attention
 693 signature가 섞이게 된다.

694 F.4 마지막 두 레이어 제외

695 Layer 축에서는 마지막 두 transformer layer도 제외한다. 이는 모델 특이적 tuning이 아니라, late
 696 layer에서 나타나는 표준적 현상을 피하기 위한 선택이다.

697 **출력 투영 특화.** 마지막 레이어 근방의 hidden state는 vocabulary logits와 거의 선형 관계를 이
 698 루므로, 표현을 바꾸는 블록이라기보다 점진적 선형 readout으로 기능한다 [Belrose et al., 2023].
 699 같은 맥락에서 late-layer feed-forward module도 출력 분포를 조정하는 메커니즘으로 해석되어
 700 왔다 [Geva et al., 2021]. 따라서 이 레이어들의 attention은 reasoning computation보다 output
 701 formation을 더 강하게 반영한다.

702 마지막 두 레이어를 제외하면 heatmap이 readout 단계보다 reasoning 단계의 attention dynamics
 703 에 더 집중한다. 이 제외는 본문 claim에 필수적이지 않다. 본문이 강조하는 시퀀스 방향
 704 *attenuation*은 이 제외 없이도 관찰되며, Theorem 1이 다루는 것도 layer 방향 단조성이 아니라
 705 sequence-direction attenuation이기 때문이다.

706 F.5 추가적인 suffix heatmap

707 Figure 8는 suffix 주입에서 Qwen2.5-Math-1.5B-Instruct와 LLaMA-3.1-8B-Instruct에 대해 동일한
 708 per-token RSP attention 분석을 보고한다. 앞서 설명한 late-layer 이유 때문에 모든 셀에서 패턴이
 709 완전히 동일하게 일반화되지는 않지만, 두 모델 모두에서 시퀀스 방향(가로축)의 단조 감소는
 710 §3.3의 cache-growth upper envelope가 예측한 것과 일치한다. layer 축(세로)의 추가 감소는 별
 711 개의 경험적 sharpening 현상으로, Theorem 1만으로 직접 따라오는 결과는 아니다.




Figure 8: 나머지 두 모델(각각 500개 MATH-500 샘플)에서 suffix 주입 시 측정한 per-token RSP attention mass. 축과 전처리는 Figure 1와 동일하다. x축은 다섯 분위로 나눈 reasoning position, y축은 다섯 분위로 나눈 layer depth(위가 얇은 층), 색은 RSP 토큰에 할당된 per-token attention의 500샘플 평균을 뜻한다. `\boxed{}` 구간 내부 토큰과 마지막 두 레이어는 제외했다.

712 G DAPO 구현

713 이 부록은 §5을 보충하여 GRPO 대비 DAPO 손실 변경, DAPO + RSP 구현, 그리고 step 별 전체
714 결과를 정리한다.

715 G.1 GRPO에서 DAPO로

716 원본 GRPO [Shao et al., 2024]는 보상 $\{R_i\}_{i=1}^G$ 를 갖는 G 개 rollout $\{o_i\}_{i=1}^G$ 에 대해 다음 목적함
717 수를 사용한다.

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left(\min(r_{i,t} \hat{A}_{i,t}, \text{clip}(r_{i,t}, 1-\varepsilon, 1+\varepsilon) \hat{A}_{i,t}) - \beta D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}}) \right) \right], \quad (9)$$

718 여기서 importance ratio는 $r_{i,t} = \pi_\theta(o_{i,t} \mid q, o_{i,<t}) / \pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})$, 그룹 상대 advantage는
719 $\hat{A}_{i,t} = (R_i - \text{mean}(\{R_i\})) / \text{std}(\{R_i\})$, ε 는 clipping 범위, βD_{KL} 은 reference π_{ref} 에 대한 KL 페
720 널티다.

721 학습 파이프라인은 SimpleRL-Zoo [Zeng et al., 2025]를 기반으로 하고 DAPO를 VeRL [Sheng
722 et al., 2024] 위에서 구현한다. DAPO는 Eq. (9)를 네 가지 측면에서 수정한다. (i) 토큰 단위 손실
723 집계 $1 / \sum_i |o_i|$ ($1 / |o_i|$ 대신), (ii) 비대칭 clipping ($\varepsilon_{\text{low}}, \varepsilon_{\text{high}} = (0.2, 0.28)$), (iii) dual clipping
724 safeguard $\max(L_{\text{clipped}}, c\hat{A})$ ($c = 10$), (iv) KL 항 제거. 결과적으로 DAPO 목적함수는

$$\mathcal{J}_{\text{DAPO}}(\theta) = \mathbb{E} \left[\frac{1}{\sum_i |o_i|} \sum_{i,t} \min(r_{i,t} \hat{A}_{i,t}, \text{clip}(r_{i,t}, 1-\varepsilon_{\text{low}}, 1+\varepsilon_{\text{high}}) \hat{A}_{i,t}) \right]. \quad (10)$$

725 G.2 DAPO + RSP 구현

726 DAPO + RSP에서는 추가로 그룹별 RSP $\mathbf{H}_g \in \mathbb{R}^{L \times d}$ ($L = 20$)를 각 rollout에 주입한다. $\mathbf{H}_g$ 는
727 step 별 group seed로 결정적으로 생성하고 forward hook으로 주입하므로 학습 가능 파라미터가
728 아니다. 따라서 학습 신호는 학습된 prompt에서 오는 것이 아니라, policy가 임의의 $\mathbf{H}_g$ 에 적응
729 하는 데서 온다. rollout 시점과 update 시점 모두에서 $\mathbf{H}_g$ 를 log-prob에 포함해 RSP-conditioned
730 분포에 대한 on-policy 업데이트를 유지한다(off-policy mismatch 회피). $G = 8, n = 8$ 이라 각
731 그룹에 응답이 하나뿐이므로 rollout마다 사실상 다른 $\mathbf{H}_g$ 를 본다.

Table 10: Qwen2.5-Math-7B에서의 DAPO / DAPO + RSP 학습 설정.

항목	값
학습 데이터	MATH Level 3-5 subset (simplelr_math_35, 약 8,500 prompt)
Prompt template	qwen-boxed
학습 배치 크기	1024
PPO mini-batch 크기	256 (rollout당 4회 PPO 업데이트)
prompt당 rollout 수 G	8
최대 prompt / response 길이	2,028 / 2,048
Rollout sampling	temperature 1.0, top- p 1.0, top- k 50
$(\epsilon_{\text{low}}, \epsilon_{\text{high}})$	(0.2, 0.28)
Dual clip c	10.0
손실 집계	token-mean ($1/\sum_i o_i $)
KL 항	사용 안 함
Entropy 계수	0
Optimizer	AdamW, learning rate 5×10^{-7} (constant), warmup 없음
총 학습	약 10 epoch, ≥ 80 최적화 step
저장 / 평가 주기	매 10 step
RSP (DAPO + RSP에만)	suffix 주입, $L = 20$, rollout마다 새로 추첨
하드웨어	4 × NVIDIA B200 GPU
실측 학습 시간	run당 약 12시간

734 저장된 각 체크포인트는 HuggingFace 형식으로 변환한 뒤 SimpleRL-Zoo
 735 eval_math_nodes.sh 파이프라인으로 평가한다. 작은 경시대회 셋의 분산을 줄이기
 736 위해 벤치마크별로 sampling 파라미터를 다르게 둔다.

Table 11: SimpleRL-Zoo sh/eval.sh의 벤치마크별 평가 프로토콜.

벤치마크	문제 수	Temperature	n_{sampling}	Metric
AIME 2024	30	1.0	32	Avg@32
AMC 2023	40	1.0	32	Avg@32
MATH-500	500	0.0	1	accuracy (mean@1)
GSM8K	1,319	0.0	1	accuracy
OlympiadBench	675	0.0	1	accuracy
Minerva Math	272	0.0	1	accuracy
GaoKao 2023-EN	385	0.0	1	accuracy

737 모든 벤치마크에서 최대 생성 토큰 수는 16,000이다. 보고하는 평균은 5개 벤치마크(GSM8K,
 738 MATH-500, College Math, Minerva Math, AIME 2024)의 가중치 없는 평균이다.

Table 12: 체크포인트별 5-벤치마크 평균 정확도(%) — GSM8K, MATH-500, College Math, Minerva Math, AIME 2024 기준. 굵게는 각 방법의 peak.

Step	DAPO	DAPO + RSP
0	30.06	30.06
10	46.40	46.22
20	49.02	49.54
30	49.58	50.72
40	50.62	52.06
50	50.88	52.40
60	51.84	52.96
70	52.52	53.86
80	53.20	54.04
90	52.52	54.36
100	50.54	53.64

740 H 광범위한 영향

741 본 연구는 무작위 임베딩 주입이 대형 언어 모델의 추론 행동에 어떤 영향을 주는지에 대한
742 실험적·이론적 분석을 제공한다. 기여의 성격은 주로 기초 연구에 가깝지만, GRPO와 같은
743 강화학습 기반 추론 모델 후속학습에는 잠재적 함의를 가진다.

744 **긍정적 영향.** RSP가 유도하는 궤적 다양성은 group-relative advantage estimation 안에서 더
745 풍부한 학습 신호를 제공함으로써, RL 기반 LLM 후속학습의 sample efficiency를 높일 수 있다.
746 이는 reasoning 중심 fine-tuning과 alignment에 필요한 계산 비용을 줄여, 자원이 제한된 연구
747 그룹에도 관련 방법을 더 접근 가능하게 만들 수 있다.

748 **잠재적 우려.** LLM의 유효 출력 지지 집합을 넓히는 방법은 바람직한 대안적 추론 경로뿐
749 아니라, 바람직하지 않거나 분포 밖에 있는 출력의 도달 가능성도 함께 높일 수 있다. 따라서
750 RSP를 실제 시스템에 적용할 때는 이를 독립적인 다양성 원천으로만 보지 말고, 기존의 안전
751 필터링 및 alignment 메커니즘과 함께 사용해야 한다.

752 **영향 범위의 한계.** 본 연구는 새로운 모델이나 데이터셋을 배포하기보다 분석을 제공하는 데
753 초점을 두므로, 직접적인 사회적 영향은 제한적이다. 여기서 논의한 더 넓은 함의는 RSP가 실제
754 학습 파이프라인에 통합되는 향후 연구가 이루어질 때에만 현실화될 수 있다.

NeurIPS Paper Checklist

1. Claims

Question: Do the main claims made in the abstract and introduction accurately reflect the paper’s contributions and scope?

Answer: [Yes]

Justification: The abstract and §1 state four scoped claims, each tied to a section: (i) RSP’s contribution at each attention layer is captured by a single scalar with a fixed-gap upper-envelope cache-growth bound (Theorem 1, §3.3); (ii) under a local affine surrogate, isotropic re-sampling assigns positive probability to a top- K entry region unattainable by rank-preserving temperature sampling (Theorem 2, §3.4); (iii) RSP raises early-token entropy and stabilizes later, with Pass@ N gains under independent re-sampling (§4); and (iv) the diversity transfers to RL training when combined with DAPO (§5). We do not claim a theorem that directly explains the format-mismatch recovery (Table 1); the wrong-attractor hypothesis there is explicitly informal.

Guidelines:

- The answer [N/A] means that the abstract and introduction do not include the claims made in the paper.
- The abstract and/or introduction should clearly state the claims made, including the contributions made in the paper and important assumptions and limitations. A [No] or [N/A] answer to this question will not be perceived well by the reviewers.
- The claims made should match theoretical and experimental results, and reflect how much the results can be expected to generalize to other settings.
- It is fine to include aspirational goals as motivation as long as it is clear that these goals are not attained by the paper.

2. Limitations

Question: Does the paper discuss the limitations of the work performed by the authors?

Answer: [Yes]

Justification: Limitations are noted in several places rather than in a dedicated section: (a) Proposition 2 requires the task-side assumption $p_{\min}(x) > 0$, flagged in §3.4 and §6; (b) the +18–29 pp recovery on the format-mismatch rows of Table 1 is empirically observed but not formally derived from any theorem in §3, with the wrong-attractor account stated as a hypothesis to be quantified in future work (§4.2); (c) Table 1 reports the best-position accuracy across {Prefix, Infix, Suffix}, and per-position variance is large with several cases below baseline (Appendix A), so position is treated as a hyperparameter rather than something we justify principally; (d) DAPO + RSP results (§5) use a single training seed under a reduced DAPO configuration that omits Dynamic Sampling and overlong reward shaping; (e) main accuracy comparisons are single-seed without bootstrap or significance tests (item 7). Future work in §6 addresses training-time comparisons, domain expansion, and principled position selection.

Guidelines:

- The answer [N/A] means that the paper has no limitation while the answer [No] means that the paper has limitations, but those are not discussed in the paper.
- The authors are encouraged to create a separate “Limitations” section in their paper.
- The paper should point out any strong assumptions and how robust the results are to violations of these assumptions (e.g., independence assumptions, noiseless settings, model well-specification, asymptotic approximations only holding locally). The authors should reflect on how these assumptions might be violated in practice and what the implications would be.
- The authors should reflect on the scope of the claims made, e.g., if the approach was only tested on a few datasets or with a few runs. In general, empirical results often depend on implicit assumptions, which should be articulated.
- The authors should reflect on the factors that influence the performance of the approach. For example, a facial recognition algorithm may perform poorly when image resolution

is low or images are taken in low lighting. Or a speech-to-text system might not be used reliably to provide closed captions for online lectures because it fails to handle technical jargon.

- The authors should discuss the computational efficiency of the proposed algorithms and how they scale with dataset size.
- If applicable, the authors should discuss possible limitations of their approach to address problems of privacy and fairness.
- While the authors might fear that complete honesty about limitations might be used by reviewers as grounds for rejection, a worse outcome might be that reviewers discover limitations that aren't acknowledged in the paper. The authors should use their best judgment and recognize that individual actions in favor of transparency play an important role in developing norms that preserve the integrity of the community. Reviewers will be specifically instructed to not penalize honesty concerning limitations.

3. Theory assumptions and proofs

Question: For each theoretical result, does the paper provide the full set of assumptions and a complete (and correct) proof?

Answer: [Yes]

Justification: Theorem 1 (cache-growth attenuation) carries an inline proof in §3.3. Proposition 1, Theorem 2, and Proposition 2 are stated in §3.4 with proofs in Appendix E. Each statement explicitly lists its assumptions: finite logits and $n, L \geq 1$ for Theorem 1; locally affine surrogate around $\bar{h} = 0$ for Theorem 2; and $p_{\min}(x) > 0$ together with mutual independence of the N runs for Proposition 2.

Guidelines:

- The answer [N/A] means that the paper does not include theoretical results.
- All the theorems, formulas, and proofs in the paper should be numbered and cross-referenced.
- All assumptions should be clearly stated or referenced in the statement of any theorems.
- The proofs can either appear in the main paper or the supplemental material, but if they appear in the supplemental material, the authors are encouraged to provide a short proof sketch to provide intuition.
- Inversely, any informal proof provided in the core of the paper should be complemented by formal proofs provided in appendix or supplemental material.
- Theorems and Lemmas that the proof relies upon should be properly referenced.

4. Experimental result reproducibility

Question: Does the paper fully disclose all the information needed to reproduce the main experimental results of the paper to the extent that it affects the main claims and/or conclusions of the paper (regardless of whether the code and data are provided or not)?

Answer: [Yes]

Justification: §4.1 and Appendix A specify benchmarks (MATH-500, GSM8K, AIME 2024 in the main table; further sets used for the DAPO study), models (LLaMA-3.1-8B-Instruct and Qwen2.5-Math 1.5B/7B variants), the RSP injection grid (Prefix/Infix/Suffix; $L \in \{10, 15, 20\}$), greedy decoding, and the answer extraction pipeline. Appendix G provides the full DAPO + RSP training recipe (batch of 1,024 prompts, $G = 8$ rollouts per prompt at $\tau = 1.0$, four PPO mini-batch updates of 256 prompts each, 100 training steps, suffix RSP $L = 20$ during rollouts only).

Guidelines:

- The answer [N/A] means that the paper does not include experiments.
- If the paper includes experiments, a [No] answer to this question will not be perceived well by the reviewers: Making the paper reproducible is important, regardless of whether the code and data are provided or not.
- If the contribution is a dataset and/or model, the authors should describe the steps taken to make their results reproducible or verifiable.

- Depending on the contribution, reproducibility can be accomplished in various ways. For example, if the contribution is a novel architecture, describing the architecture fully might suffice, or if the contribution is a specific model and empirical evaluation, it may be necessary to either make it possible for others to replicate the model with the same dataset, or provide access to the model. In general, releasing code and data is often one good way to accomplish this, but reproducibility can also be provided via detailed instructions for how to replicate the results, access to a hosted model (e.g., in the case of a large language model), releasing of a model checkpoint, or other means that are appropriate to the research performed.
- While NeurIPS does not require releasing code, the conference does require all submissions to provide some reasonable avenue for reproducibility, which may depend on the nature of the contribution. For example
 - (a) If the contribution is primarily a new algorithm, the paper should make it clear how to reproduce that algorithm.
 - (b) If the contribution is primarily a new model architecture, the paper should describe the architecture clearly and fully.
 - (c) If the contribution is a new model (e.g., a large language model), then there should either be a way to access this model for reproducing the results or a way to reproduce the model (e.g., with an open-source dataset or instructions for how to construct the dataset).
 - (d) We recognize that reproducibility may be tricky in some cases, in which case authors are welcome to describe the particular way they provide for reproducibility, and authors should be aware that reproducibility may be limited in such cases.

5. Open access to data and code

Question: Does the paper provide open access to the data and code, with sufficient instructions to faithfully reproduce the main experimental results, as described in supplemental material?

Answer: [No]

Justification: All datasets and base models used in the paper are publicly available and cited (MATH-500, GSM8K, AIME 2024, AMC 2023, OlympiadBench, Minerva Math, GaoKao 2023-EN, College Math; Qwen2.5-Math 1.5B/7B and LLaMA-3.1-8B-Instruct). RSP itself is described to a level of detail sufficient for re-implementation (Eq. (1) and §4.1). However, our RSP injection harness and DAPO + RSP training pipeline are not yet released; we will release an anonymized implementation alongside the camera-ready submission.

Guidelines:

- The answer [N/A] means that paper does not include experiments requiring code.
- Please see the NeurIPS code and data submission guidelines (<https://neurips.cc/public/guides/CodeSubmissionPolicy>) for more details.
- While we encourage the release of code and data, we understand that this might not be possible, so [No] is an acceptable answer. Papers cannot be rejected simply for not including code, unless this is central to the contribution (e.g., for a new open-source benchmark).
- The instructions should contain the exact command and environment needed to run to reproduce the results. See the NeurIPS code and data submission guidelines (<https://neurips.cc/public/guides/CodeSubmissionPolicy>) for more details.
- The authors should provide instructions on data access and preparation, including how to access the raw data, preprocessed data, intermediate data, and generated data, etc.
- The authors should provide scripts to reproduce all experimental results for the new proposed method and baselines. If only a subset of experiments are reproducible, they should state which ones are omitted from the script and why.
- At submission time, to preserve anonymity, the authors should release anonymized versions (if applicable).
- Providing as much information as possible in supplemental material (appended to the paper) is recommended, but including URLs to data and code is permitted.

6. Experimental setting/details

Question: Does the paper specify all the training and test details (e.g., data splits, hyperparameters, how they were chosen, type of optimizer) necessary to understand the results?

Answer: [Yes]

Justification: §4.1 and Appendix A list all benchmarks, models, RSP injection settings (positions, lengths, per-row L choice in Appendix Table 8), maximum generation length per benchmark, and decoding strategy. Appendix G provides the full DAPO + RSP training settings, including optimizer, batch composition, mini-batch updates, asymmetric clipping range ($\epsilon_{\text{low}}, \epsilon_{\text{high}}$) = (0.2, 0.28), dual clipping safeguard, and RSP injection protocol during rollouts.

Guidelines:

- The answer [N/A] means that the paper does not include experiments.
- The experimental setting should be presented in the core of the paper to a level of detail that is necessary to appreciate the results and make sense of them.
- The full details can be provided either with the code, in appendix, or as supplemental material.

7. Experiment statistical significance

Question: Does the paper report error bars suitably and correctly defined or other appropriate information about the statistical significance of the experiments?

Answer: [No]

Justification: Pass@ N experiments use $N = 16$ samples per problem (§4.4), Table 4 reports mean±standard deviation over 16 RSP seeds, and AIME 2024 is scored by Avg@32 to reduce variance. However, Table 1 (Table 1) reports single-run accuracies without bootstrap confidence intervals or paired tests, and the DAPO + RSP training in §5 uses a single training seed. Multi-seed evaluation, particularly on small competition sets (AIME 2024, AMC 2023) where variance is highest, is left for future work.

Guidelines:

- The answer [N/A] means that the paper does not include experiments.
- The authors should answer [Yes] if the results are accompanied by error bars, confidence intervals, or statistical significance tests, at least for the experiments that support the main claims of the paper.
- The factors of variability that the error bars are capturing should be clearly stated (for example, train/test split, initialization, random drawing of some parameter, or overall run with given experimental conditions).
- The method for calculating the error bars should be explained (closed form formula, call to a library function, bootstrap, etc.).
- The assumptions made should be given (e.g., Normally distributed errors).
- It should be clear whether the error bar is the standard deviation or the standard error of the mean.
- It is OK to report 1-sigma error bars, but one should state it. The authors should preferably report a 2-sigma error bar than state that they have a 96% CI, if the hypothesis of Normality of errors is not verified.
- For asymmetric distributions, the authors should be careful not to show in tables or figures symmetric error bars that would yield results that are out of range (e.g., negative error rates).
- If error bars are reported in tables or plots, the authors should explain in the text how they were calculated and reference the corresponding figures or tables in the text.

8. Experiments compute resources

Question: For each experiment, does the paper provide sufficient information on the computer resources (type of compute workers, memory, time of execution) needed to reproduce the experiments?

Answer: [Yes]

Justification: Inference experiments (Tables 1, 2; Figure 2) run on a single NVIDIA A6000 40GB GPU with greedy decoding (Appendix A). DAPO + RSP training (§5) runs on 4× NVIDIA B200 GPUs for approximately 12 hours per run (Appendix G, hardware row of the configuration table).

Guidelines:

- The answer [N/A] means that the paper does not include experiments.
- The paper should indicate the type of compute workers CPU or GPU, internal cluster, or cloud provider, including relevant memory and storage.
- The paper should provide the amount of compute required for each of the individual experimental runs as well as estimate the total compute.
- The paper should disclose whether the full research project required more compute than the experiments reported in the paper (e.g., preliminary or failed experiments that didn’t make it into the paper).

9. Code of ethics

Question: Does the research conducted in the paper conform, in every respect, with the NeurIPS Code of Ethics <https://neurips.cc/public/EthicsGuidelines?>

Answer: [Yes]

Justification: The work uses publicly available math reasoning benchmarks and pretrained language models, involves no human subjects or personal data, and does not introduce a release that bypasses standard model-safety considerations. We have reviewed the NeurIPS Code of Ethics and identify no conflicts.

Guidelines:

- The answer [N/A] means that the authors have not reviewed the NeurIPS Code of Ethics.
- If the authors answer [No], they should explain the special circumstances that require a deviation from the Code of Ethics.
- The authors should make sure to preserve anonymity (e.g., if there is a special consideration due to laws or regulations in their jurisdiction).

10. Broader impacts

Question: Does the paper discuss both potential positive societal impacts and negative societal impacts of the work performed?

Answer: [Yes]

Justification: Appendix H discusses both directions: positive impact via more sample-efficient RL post-training of reasoning LLMs, and a potential downside that broadening the effective output support also increases reachability of undesirable trajectories, which we argue should keep RSP coupled with existing safety filtering rather than replacing it.

Guidelines:

- The answer [N/A] means that there is no societal impact of the work performed.
- If the authors answer [N/A] or [No], they should explain why their work has no societal impact or why the paper does not address societal impact.
- Examples of negative societal impacts include potential malicious or unintended uses (e.g., disinformation, generating fake profiles, surveillance), fairness considerations (e.g., deployment of technologies that could make decisions that unfairly impact specific groups), privacy considerations, and security considerations.
- The conference expects that many papers will be foundational research and not tied to particular applications, let alone deployments. However, if there is a direct path to any negative applications, the authors should point it out. For example, it is legitimate to point out that an improvement in the quality of generative models could be used to generate Deepfakes for disinformation. On the other hand, it is not needed to point out that a generic algorithm for optimizing neural networks could enable people to train models that generate Deepfakes faster.

- The authors should consider possible harms that could arise when the technology is being used as intended and functioning correctly, harms that could arise when the technology is being used as intended but gives incorrect results, and harms following from (intentional or unintentional) misuse of the technology.
- If there are negative societal impacts, the authors could also discuss possible mitigation strategies (e.g., gated release of models, providing defenses in addition to attacks, mechanisms for monitoring misuse, mechanisms to monitor how a system learns from feedback over time, improving the efficiency and accessibility of ML).

11. Safeguards

Question: Does the paper describe safeguards that have been put in place for responsible release of data or models that have a high risk for misuse (e.g., pre-trained language models, image generators, or scraped datasets)?

Answer: [N/A]

Justification: The paper does not release new pretrained models, generative systems, or scraped datasets. RSP is a generation-time perturbation applied to existing pretrained models and introduces no separate artifact requiring safeguards.

Guidelines:

- The answer [N/A] means that the paper poses no such risks.
- Released models that have a high risk for misuse or dual-use should be released with necessary safeguards to allow for controlled use of the model, for example by requiring that users adhere to usage guidelines or restrictions to access the model or implementing safety filters.
- Datasets that have been scraped from the Internet could pose safety risks. The authors should describe how they avoided releasing unsafe images.
- We recognize that providing effective safeguards is challenging, and many papers do not require this, but we encourage authors to take this into account and make a best faith effort.

12. Licenses for existing assets

Question: Are the creators or original owners of assets (e.g., code, data, models), used in the paper, properly credited and are the license and terms of use explicitly mentioned and properly respected?

Answer: [Yes]

Justification: All datasets (MATH-500 [Lightman et al., 2024], GSM8K [Cobbe et al., 2021], AIME 2024, AMC 2023, OlympiadBench [He et al., 2024], Minerva Math [Lewkowycz et al., 2022], GaoKao 2023-EN, College Math) and pretrained models (Qwen2.5-Math [Yang et al., 2024], LLaMA-3.1 [Grattafiori et al., 2024]) are publicly available and cited at first use. The training pipeline builds on SimpleRL-Zoo [Zeng et al., 2025] and VeRL [Sheng et al., 2024], also cited. Each asset is used under its original publicly stated terms.

Guidelines:

- The answer [N/A] means that the paper does not use existing assets.
- The authors should cite the original paper that produced the code package or dataset.
- The authors should state which version of the asset is used and, if possible, include a URL.
- The name of the license (e.g., CC-BY 4.0) should be included for each asset.
- For scraped data from a particular source (e.g., website), the copyright and terms of service of that source should be provided.
- If assets are released, the license, copyright information, and terms of use in the package should be provided. For popular datasets, paperswithcode.com/datasets has curated licenses for some datasets. Their licensing guide can help determine the license of a dataset.
- For existing datasets that are re-packaged, both the original license and the license of the derived asset (if it has changed) should be provided.

- If this information is not available online, the authors are encouraged to reach out to the asset’s creators.

13. New assets

Question: Are new assets introduced in the paper well documented and is the documentation provided alongside the assets?

Answer: [N/A]

Justification: The paper does not release new datasets or pretrained models. The implementation code planned for camera-ready release (item 5) will be accompanied by configuration files and a README; no derived dataset or model checkpoint is part of the submission.

Guidelines:

- The answer [N/A] means that the paper does not release new assets.
- Researchers should communicate the details of the dataset/code/model as part of their submissions via structured templates. This includes details about training, license, limitations, etc.
- The paper should discuss whether and how consent was obtained from people whose asset is used.
- At submission time, remember to anonymize your assets (if applicable). You can either create an anonymized URL or include an anonymized zip file.

14. Crowdsourcing and research with human subjects

Question: For crowdsourcing experiments and research with human subjects, does the paper include the full text of instructions given to participants and screenshots, if applicable, as well as details about compensation (if any)?

Answer: [N/A]

Justification: The paper involves no crowdsourcing and no research with human subjects. All evaluations use static, publicly available math reasoning benchmarks.

Guidelines:

- The answer [N/A] means that the paper does not involve crowdsourcing nor research with human subjects.
- Including this information in the supplemental material is fine, but if the main contribution of the paper involves human subjects, then as much detail as possible should be included in the main paper.
- According to the NeurIPS Code of Ethics, workers involved in data collection, curation, or other labor should be paid at least the minimum wage in the country of the data collector.

15. Institutional review board (IRB) approvals or equivalent for research with human subjects

Question: Does the paper describe potential risks incurred by study participants, whether such risks were disclosed to the subjects, and whether Institutional Review Board (IRB) approvals (or an equivalent approval/review based on the requirements of your country or institution) were obtained?

Answer: [N/A]

Justification: As noted in item 14, the paper involves no human subjects, so IRB review is not applicable.

Guidelines:

- The answer [N/A] means that the paper does not involve crowdsourcing nor research with human subjects.
- Depending on the country in which research is conducted, IRB approval (or equivalent) may be required for any human subjects research. If you obtained IRB approval, you should clearly state this in the paper.
- We recognize that the procedures for this may vary significantly between institutions and locations, and we expect authors to adhere to the NeurIPS Code of Ethics and the guidelines for their institution.

1123 • For initial submissions, do not include any information that would break anonymity (if
1124 applicable), such as the institution conducting the review.

1125 **16. Declaration of LLM usage**

1126 Question: Does the paper describe the usage of LLMs if it is an important, original, or
1127 non-standard component of the core methods in this research? Note that if the LLM is used
1128 only for writing, editing, or formatting purposes and does *not* impact the core methodology,
1129 scientific rigor, or originality of the research, declaration is not required.

1130 Answer: [N/A]

1131 Justification: Pretrained LLMs (Qwen2.5-Math, LLaMA-3.1) appear in the paper as the ex-
1132 perimental subject of analysis, not as a non-standard component of the methods themselves.
1133 The methods (RSP definition, attention decomposition, DAPO + RSP training) do not rely
1134 on auxiliary LLMs in any non-standard or originality-affecting role.

1135 Guidelines:

1136 • The answer [N/A] means that the core method development in this research does not
1137 involve LLMs as any important, original, or non-standard components.

1138 • Please refer to our LLM policy in the NeurIPS handbook for what should or should not
1139 be described.